分 类 号：TP391
学　　号：202121401520

济南大学
UNIVERSITY OF JINAN

硕士学位论文

(非全日制专业学位研究生)

基于无监督学习的工业数据故障检测系统研发与实现

作　　者　王泽
指导教师　张强
合作导师
学科名称　电子信息
学位类别　电子信息硕士
答辩时间　2025年6月3日

中国知网 https://www.cnki.net

Research and implementation of industrial data fault detection system based on unsupervised learning

By

WANG Ze

Under the Supervision of

ZHANG Qiang

A Thesis Submitted to the University of Jinan

In Partial Fulfillment of the Requirements

For the Degree of Master of Master of Engineering

University of Jinan

Jinan, Shandong, P. R. China

June , 2025

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 研究背景与意义.....1
1.2 国内外研究现状.....3
1.3 论文的主要内容与创新点.....7
1.3.1 论文的主要内容.....7
1.3.2 论文的创新点.....8
1.4 论文组织结构.....9
第二章 锅炉数据的预处理.....11
2.1 锅炉数据集.....11
2.2 数据预处理方法.....12
2.2.1 数据清洗与变换.....12
2.2.2 缺失值处理和时序调整.....14
2.2.3 数据标准化与归一化.....16
2.3 本章小结.....17
第三章 基于参数优化 DPC 聚类算法的异常点发现算法.....19
3.1 异常检测算法概述与分类.....19
3.2 各聚类算法比较分析.....20
3.2.1 DPC 聚类算法的原理与实现.....20
3.3 聚类实验结果分析.....22
3.3.1 经典数据集测试.....22
3.3.2 DPC 聚类算法的优化.....23
3.3.3 DPC 改进算法工业数据实验.....27
3.4 本章小结.....30
第四章 基于 FP-Growth 的关联链发现算法研究.....31
4.1 引言.....31
4.2 FP-Growth 关联规则算法.....31
4.3 基于 2 项频繁项集的 FP-Growth 关联规则算法.....32
4.4 环节间关联规则获取关联链.....33
4.5 本章小结.....35
第五章 基于无监督学习的工业数据故障检测系统研发与实现.....37
5.1 系统的开发环境与系统概述.....37
5.2 系统流程图.....39
5.3 系统功能分析.....40
5.3.1 聚类模块.....41

中国知网 https://www.cnki.net

5.3.2 关联规则功能模块.....41
5.3.3 异常分析功能模块.....42
5.4 本章小结.....46
第六章 结论与展望.....47
6.1 论文总结.....47
6.2 研究展望.....48
参考文献.....49

中国知网 https://www.cnki.net

摘 要

随着工业发展，企业的生产力得到的提升，但是在工业生产流程会不可避免地出现一些突发情况，因此在生产的过程中企业会部署传感器来采集相应的数据，以此来分析各个生产环节是否出现异常，生产流程的安全性也越来越成为工业生产流程的焦点。随着时间的推移，这些传感器所采集到的数据不断地累积，研究者们发现，这些存储起来的海量数据为工业生产的大数据分析环节提供了坚实的数据基础，对这些数据进行分析可以发掘其中的关联趋势，也会发现那些远离趋势的离群点和噪音点。于是对工业历史数据进行异常分析检测，可以及时发现生产流程中出现的异常状态以此来警告工作人员对相应的生产环节设备进行检查，可以避免后期出现相似的问题。本文以完整的锅炉生产流程作为研究对象，针对工业生产流程的异常检测问题，提出一种基于无监督的工业数据异常检测检测方法，对锅炉生产流程中所产生的海量历史数据集进行聚类分析和关联规则发掘，以此来检测当时生产流程中所出现的异常状态。具体内容如下：

首先对锅炉数据进行预处理，包括数据清洗、缺失值处理、时序调整等，在正常的工业生产流程中，传感器会采集海量的历史数据，其中部分数据有着与正常数据明显不同的趋势性和随机性，这些异常数据被称之为离群点，代表着工业生产流程中出现的异常情况。本文对几种常见的异常检测算法进行分析对比，分析出聚类算法在异常检测中的应用优势，然后进行了对不同种类的聚类算法的实验对比分析，根据实验结果最终采取基于密度的 DPC 密度峰值聚类算法对数据集进行聚类分析，并将其与 KNN 近邻思想进行结合，使其自动生成截断距离，为数据集的聚类分析实验提供了更加有效的算法检测参数，实现了工业数据异常检测上的创新性应用。

聚类分析是一种应用性很强的机器学习策略，主要用于将原数据集划分成具有明显区分边界的若干数据，由于该策略对数据自身的性质很敏感，所以在聚类分析的具体实现方法中不存在一种通用的方法，可以处理任意性质的数据集。聚类分析之后，得到了聚类结果和异常点，接着对关联规则算法进行研究，本文为了探讨其与聚类算法的结合应用，选择 FP-Growth 关联规则算法，并利用 2 项频繁项集思想对其进行创新性应用，对生产流程中任两环节的聚类结果数据进行关联规则挖掘，得到环节间的关联规则，合并生成最终的关联链，关联链可以直观地映射出多个生产环节状态之间的单向关系，为系统实现异常点环节原因追溯功能做铺垫，进而搭建后续的基于无监督学习的工业数据

中国知网 https://www.cnki.net

故障检测系统。系统已经在济南某热电厂部署使用，在实际的应用中反馈良好，很好的缓解了在一线工作的工人用户们设备故障检测的精神压力。

关键词：密度峰值聚类算法；异常检测算法；聚类算法；关联规则算法

中国知网 https://www.cnki.net

Abstract

With the development of industry, the productivity of enterprises has been enhanced. However, some unexpected situations are inevitable in the industrial production process. Therefore, during the production process, enterprises will deploy sensors to collect corresponding data to analyze whether there are any abnormalities in each production link. The safety of the production process has increasingly become the focus of the industrial production process. As time goes by, the data collected by these sensors accumulates continuously. Researchers have found that these stored massive amounts of data provide a solid data foundation for the big data analysis process in industrial production. Analyzing these data can uncover the associated trends and also identify outliers and noise points that are far from the trends. Therefore, by conducting abnormal analysis and detection on industrial historical data, abnormal states that occur in the production process can be promptly identified to warn staff to inspect the corresponding production equipment, thus avoiding similar problems in the later stage. This paper takes the complete boiler production process as the research object. Aiming at the anomaly detection problem of industrial production processes, an unsupervised industrial data anomaly detection detection method is proposed. Cluster analysis and association rule mining are conducted on the massive historical data sets generated in the boiler production process to detect the abnormal states that occurred in the production process at that time. The specific content is as follows:

First, the boiler data is preprocessed, including data cleaning, missing value processing, and time series adjustment, etc. In a normal industrial production process, sensors collect a vast amount of historical data, some of which have significantly different trends and randomness from normal data. These abnormal data are called outliers, representing abnormal situations that occur in the industrial production process. This paper analyzes and compares several common anomaly detection algorithms, analyzes the application advantages of clustering algorithms in anomaly detection, and then conducts experimental comparative analysis of different types of clustering algorithms. According to the experimental results, the density-based DPC density peak clustering algorithm is finally adopted to conduct clustering analysis on the data set, and it is combined with the KNN nearest neighbor idea. It enables it

中国知网 https://www.cnki.net

to automatically generate the truncation distance, providing more effective algorithm detection parameters for the clustering analysis experiments of the data set and achieving an innovative application in industrial data anomaly detection.

Cluster analysis is a highly applicable machine learning strategy, mainly used to divide the original data set into several data with distinct distinction boundaries. Since this strategy is very sensitive to the nature of the data itself, there is no universal method in the specific implementation methods of cluster analysis that can handle data sets of arbitrary nature. After cluster analysis, the clustering results and outliers were obtained. Then, the association rule algorithm was studied. In order to explore its combined application with the clustering algorithm, this paper selects the FP-Growth association rule algorithm and innovatively applies it by using the idea of two-item frequent item sets to conduct association rule mining on the clustering result data of any two links in the production process. Obtain the association rules between links, merge to generate the final association chain. The association chain can visually map the one-way relationship among the states of multiple production links, laying the foundation for the system to implement the function of tracing the causes of abnormal point links, and then build the subsequent industrial data fault detection system based on unsupervised learning. The system has been deployed and put into use in a thermal power plant in Jinan. It has received positive feedback in practical applications and has effectively alleviated the mental pressure of equipment fault detection for workers on the front line.

Key Words: Density peak clustering algorithm; Anomaly detection algorithm; Clustering algorithm; Association rule algorithm

中国知网 https://www.cnki.net

第一章 绪 论

1.1 研究背景与意义

在当今工业高度发展的时代，随着生产过程的自动化和信息化水平的日益进步，越来越多诸如计算机和移动终端等的电子设备加入网络中，许多企业的原始的机械式流程工业已经开始向数字化方向转型[1]。目前国内应用广泛的控制系统是分布式控制系统[2](Distributed Control System,DCS)、安全仪表系统(Safety Instrumented System,SIS)、企业资源计划系统(Enterprise Resource Planning,ERP)等较旧的控制系统[2]。在流程工业生产企业中，应用广泛的是分布式控制系统[3]，其依靠分布于各个环节的传感器实时检测得到的数据进行系统控制。随着科技的更新迭代与数据存储技术的更迭，工厂设备长期运行所产生的海量数据能够在设备检测的过程中，被数字化存储记录，为数据挖掘提供了良好的前置基础。对于热电厂这种重要的工厂类型，其自身拥有的锅炉工业系统生产流程由于常年不关闭控制系统、系统底层逻辑不兼容等各种现实原因，无法直接安装使用最新的国外自动化控制系统技术。而且对于不同的控制系统，采集数据和监控数据的方式也会不同，进而造成了对锅炉工业系统的生产流程环境分析的差异化。这时候，安全的生产环境将会成为首要的生产流程环境需求，对工业生产流程进行异常检测来提前对危机进行预警成为了流程工业生产过程的重中之重。

工业系统生产流程中会产生历史数据，这些数据的规模是庞大的，其中蕴含着丰富的信息。由于工业环境的复杂性，以往的数据处理方法已难以满足现代工业系统对数据处理速度与精度的要求，数据的噪声、冗余以及非线性特征给数据分析带来了极大的挑战。对生产设备里累积存储的海量历史数据进行深度剖析，在工业生产流程的监控、优化和故障预警等方面都具有重要的意义[4-7]。

异常点检测[8]是指在海量的数据集合中获取少数孤立的、偏离于其它对象的数据信息。许多应用领域在早期研究中将这些数据视为冗杂噪声，认为这些数据出现后会对正常结果造成异常影响，污染实验准确率[9]，因此，这些数据应被排除在外，以确保其他数据的正常处理。Hawkins[10]教授认为异常点是被视为一种与其他数据行为截然不同的样本对象，其具有独特性，生成的机制或许是一种完全不同的方法。随着步入小康社会以来，工业生产流程不再是追求效率和经济至上，其安全性方面越来越受人瞩目，并且，

中国知网 https://www.cnki.net

随着数据挖掘技术的飞速发展，人们开始将目光投向那些显著偏离数据整体趋势的异常数据中，这些数据往往蕴含着更为重要的信息价值。Han[11]教授曾提出过一个理论，一个点噪声很有可能是另一个点的标志记号，而且离群噪声点也开始逐步地被学者所研究，不再被统一舍弃，其本身也具有越来越高的研究意义[12]。目前离群点检测算法已广泛应用于各种领域，如信用卡欺诈、工业生产检测、网络入侵、环境监测、疾病预防等[13-20]。通过将数据对象中存在未知和威胁的数据进行异常检测，以此来实现其隐藏的高度实用价值，离群点检测的研究有着十分重要的应用意义和实用价值。

数据挖掘[21-22]是指在旧的人工数据分析方法基础上所研究扩展出的高效数据分析方法，单凭借人工的干预与辨别数据中有用的信息实在是效率低下并且花销巨大，严重限制了经济的发展。数据挖掘可以从各领域的庞杂数据信息中获得有效信息并提高有效信息的检索效率。无监督学习是数据挖掘的一项重要分支，无监督学习[23]作为一种不依赖于标记数据的机器学习方法，凭借其独特的优势，在工业数据处理与分析过程中展现出了巨大的潜力。训练数据集有输入有输出是有监督学习范畴，包括所有的回归算法、分类算法，比如线性回归、决策树、神经网络、KNN、SVM 等；而训练数据集只有输入没有输出是无监督学习范畴，无监督学习是机器学习任务的一种，它从无标记的训练数据中推断结论，最典型的无监督学习就是聚类分析，包括所有的聚类算法，比如 K-means、层次聚类、DBSCAN、DPC 密度峰值聚类算法等[24-27]。它可以在探索性数据分析阶段用于发现隐藏的模式或者对给定数据进行分组，寻找隐藏的结构。训练集中所有样本点均处于未知分类中，其呈现出高度的模糊性与多样性特征，无监督学习是一种在未打上标签（即未标记分类）的训练数据集中探寻规律的方法，旨在揭露样本集合中隐含的结构性知识。无监督学习能够在没有先验知识的情况下，自动发现数据中的结构和模式，对于挖掘工业生产流程中的未知关系、识别潜在的异常状态以及提高生产效率等方面均具有重要意义。特别是在故障检测领域，无监督学习能够帮助用户及时发现生产过程中的异常变化，从而实现在工业生产流程中的早期预警效果，减少生产损失，确保生产安全。

本文所用到的数据是在济南某热电厂锅炉的传感器上采集的，传感器输出的是原始的锅炉工业生产流程数据参数，整理形成锅炉工业历史数据集。本文对锅炉工业历史数据集进行数据分析与数据挖掘，找出数据中的异常点，检测锅炉当时的生产流程是否有异常情况。然后与 FP-Growth 关联规则算法相结合，生成当时锅炉生产状态的最优关联链，进而实现对异常点进行分析，找出异常点形成的原因，反推前一环节是否是异常形

中国知网 https://www.cnki.net

成的原因，正推后一环节是否受到影响。如果能够及时准确地发现异常情况，就可以降低生产设备的发生故障的危险，减少企业的维护成本和经济负担，为安全的生产环境保驾护航。

1.2 国内外研究现状

国内外对锅炉工业生产系统相关的安全性技术研究各有不同，将国外发达国家相对成熟的技术机械性地移植到国内工业生产体系中，往往会适得其反。企业在追求自身发展的进程中，始终将软件开发与应用的成本、系统维护的费用等开销因素置于首要地位，这些因素导致在国内不可生搬硬套国外先进技术，需依据企业实情对应的改进安全技术。目前国内的大部分锅炉工业生产系统流程特性是每隔一段时间，传感采样计算系统进行一次数据采样，进行输出加工处理，操作人员根据输出的结果进行系统对应环节设定值的改变或必要的人工操作，从整个锅炉生产环节流程来看，无法统一整合在一起，也导致了无法形成完整的安全操作回路。在此背景下，工业生产安全性问题始终是企业的头等大事，加强企业安全性的方案也在更新迭代，现在研究者们的目光开始落在工业生产过程中产生的海量历史数据上，对其进行数据挖掘，分析异常点产生的原因，进而增强工业生产流程的安全性，成为当今越来越热门的生产安全措施，针对生产过程中可能时不时的会出现异常状态的问题，需要设计出一种基于锅炉工业生产流程采集数据的异常检测方法，将之开发为一个系统，从而提高锅炉生产中的安全性，能及时地给人以预警。

异常点检测是对数据集样本点进行判断，被检测的样本点是否归进某一个簇团中，深受众多研究者的广泛关注[28-29]。异常点检测的目的在于揭示数据集中偏离常态的离群点，也称离群点检测。国外的离群点检测研究涵盖了基于统计、距离、密度、深度学习、聚类的异常检测方法[30-32]。基于统计的方法根植于分布理论，如正态分布模型，在预设目标概率分布框架内，运用假设检验机制进行离群点的判断。基于距离的方法将则将邻近点稀疏的样本点判断为离群点，其中，Ramaswamy 等学者[33]提出的 K-最近邻（KNN）检测算法，其在全局异常点检测方面效果较好，但在处理局部异常点时稍显不足。基于密度的方法通过计算数据样本的密度，将低密度的样本点视为离群点。Breunig[34]提出了一种经典算法 LOF 算法，算法通过给每个数据点都分配一个依赖于邻域密度的离群因子，即 LOF，通过比较对象之间的 LOF 值来判断其离群程度，但由于离群点在数据集中所占的比重较小，该算法的时间复杂度较高，直接计算数据对象的离群度会增大计算量。基于深度学习的异常检测方法是近几年新兴的一种异常检测方法，比较典型的有将

中国知网 https://www.cnki.net

图神经网络（GNN）深度学习方法用于图信息进行采集和异常判断[35]，适用于关系型数据（如社交网络、金融交易、生物分子网络等），能够同时利用节点特征和图结构信息，检测节点、边、子图或图级别的异常。图神经网络本质上是一个图嵌入模型，依靠图节点之间的消息传递（Message Passing）和邻域聚合（Neighborhood Aggregation）机制，学习节点或图的低维嵌入表示。异常节点或边在图结构或特征上与周围邻域存在显著差异，这种差异会在嵌入空间中体现为高重构误差、低相似性或统计偏离，通过对图向量的解构与分析，实现类似于人类推理的过程。但是目前图神经网络有着一些不成熟之处，其依赖图构建质量，若图结构定义错误（如漏边、噪声边）会导致检测性能显著下降，而且计算复杂度高、可解释性弱（异常原因难以直观解释）。模型结构易受外来对抗攻击，因此方法的鲁棒性不强，并且存在图结构的过度平滑和过度压缩问题。基于聚类的异常检测方法依据数据集中样本点的分布特性，将数据点分类划分为不同的簇团。在此过程中，部分数据集中的样本点有着既不归属于任何一个簇团，且与所有簇团均保持较远的距离的特性，利用这种特性，将其识别为异常点。基于聚类的异常检测方法通过研究样本点与聚类结果的簇团之间的关系，在聚类分析的同时即可完成异常点的检测。该技术无需预先设定数据集的分布特征，具有广泛的数据集适用性和伸缩性，因此在处理高维度特征数据集时表现出色。传统的聚类算法有 K-means、层次聚类、密度聚类等，本文的工业数据集和研究方向与基于聚类的离群点检测方法思想不谋而合。

聚类算法作为目前国内外常用的无监督学习方法，其核心原理在于运用聚类算法将数据集合理地划分为不同的簇。自诞生以来，聚类技术已衍生出诸多算法，广泛应用于图像识别、环境监测、工业数据采集等诸多领域[36-40]。传统的聚类算法有基于划分、层次、密度的聚类算法。基于划分的聚类算法预先设定簇的数量，随后分配其余样本，并采用迭代方式不断重新划分簇内对象，直至达到聚类中心不再改变，簇团内部数据点之间的距离较近，不同簇团内数据点之间的距离较远时，达到理想的聚类结果。在 1967 年，由 MacQueen 提出的 K 均值聚类算法(K-means)[41]就属于典型的划分聚类算法。K-means 算法运算简便，算法通过选择初始聚类中心后，不断迭代划分剩余数据点，但前提是需预先输入初始聚类中心的数量，也就是簇团的数量。该算法有着数据点高度重叠就不会被判定为多个簇，以及对数据集中的噪声数据敏感等缺点，这导致了该算法无法直接处理异常值和噪声数据。层次聚类算法依据样本点间的相似性度量进行运算，随后根据相似度结果将数据点划分至不同层级类别中，尽管无需预设初始的聚类中心数量，但算法的复杂度较高，运行效率偏低。其中，以 CURE(Clustering Using Representation)

中国知网 https://www.cnki.net

和 BIRCH[42](Balanced Iterative Reducing and Clustering Using Hierarchies)算法为代表，层次聚类在生物信息解析、文本按类别分组等诸多领域得到了广泛应用。基于密度的聚类算法假设样本点的空间分布可以决定其数据结构，则可将数据样本中被低密度区域所分割的高密度点的集群单元视为一个簇，DBSCAN 和 DPC 等典型算法都属于密度聚类算法。算法在分析样本分布不规则或包含较多噪声的数据集时，性能显著优于层次聚类算法和划分聚类算法。

在国内外异常检测的应用研究方面，基于划分的聚类算法通常遵循先聚类后检测的流程，如 K-means 算法，在完成聚类划分后，是不会有异常点的出现的，需要人工预设的距离度量准则或阈值，对样本点进行异常检测。可见其结果的准确性往往受限于人工在聚类结果中进行簇团和异常点的划分。K-means 算法在面对数据量非常大的问题时，算法的时间开销是非常大的，因为需要多次的迭代，在国内研究中，将此类聚类算法应用于流程工业异常数据检测的实例颇为罕见，其多数情况下是对锅炉工业生产流程的数据辅助分析，应用于优化工业生产生产结构。在锅炉工业生产流程所采集的数据集样本中，无法提前确定聚类中心的数量 K 值，所以不适用于离群点检测。层次聚类算法是通过假设簇团之间存在层次结构，将样本聚类到层次化的簇团中，计算样本间的相似度或距离来构建一个层次化的聚类树。该聚类树可以通过剪枝或划分来得到不同层次的聚类结果。但是其在处理高维数据时容易出现维度灾难。层次聚类有聚合聚类（自底向上）和分裂聚类（自顶向下）两种方法，两种方法的运行逻辑是相反的，聚合聚类是开始将每个样本分为一个簇，然后相距最近的两簇合并建立新簇团，重复操作直到停止来得到层次化的类别，而分裂聚类的运行逻辑正好与之相反来得到层次化的类别。由于层次化的结构，对异常值和噪声敏感，离群点的存在会扰动相似度或距离的计算，影响聚类结果。这些局限性也导致了它不能够适用于离群点的检测。基于密度的聚类算法能够同时承担聚类分析与异常点检测任务，使得异常点检测结果对聚类分析结果的前置依赖性大幅降低。基于密度的聚类算法主要利用样本之间的密度来划分簇，其核心思想是将高密度区域看作是簇，而低密度区域则被视为簇之间的边界。

在国内外都采用了密度聚类算法来对工业生产数据集中的异常点进行检测，算法的主流有两种：DPC 密度峰值聚类算法和 DBSCAN 密度聚类算法，在特定情况下表现出不同的性能。在 1996 年，Ester[43]教授等人提出 DBSCAN(Density-Based Spatial Clustering of Applications with Noise)密度聚类算法，该算法能自动辨识形态多样、密度各异的簇团，但是缺陷也很明显，需要设置扫描半径和最小邻域内样本数两个参数才能够识别离群点。

中国知网 https://www.cnki.net

该算法的关键在于通过样本之间的邻域关系来确定核心点和密度可达性，从而实现聚类操作。但是由于自身存在的缺陷，面对数据分布不是很离散的情况下，扫描半径的设置极为棘手，容易将异常点和边缘点判定为正常点，

罗德里格斯[44]等人于 2014 年设计了一种新的聚类算法，称为基于快速搜索和发现密度峰值的聚类算法 DPC(Density Peaks Clustering)。与传统的聚类算法相比，DPC 更简单易懂，能够快速找到聚类中心。同时，该算法在大多数数据上都表现出良好的聚类效果。在近十年间，DPC 算法已在计算机视觉、图像识别、文本挖掘等领域得到广泛应用[45-47]。DPC 密度峰值聚类算法是对传统密度聚类算法的改进，能够一次性计算出聚类中心，从而避免了多次迭代所带来的高计算复杂度。DPC 密度聚类算法可以发现任意形状的簇，能够自动识别簇的个数，对噪声和离群点的检测具有较好的鲁棒性，能够将异常点与正常点分离出来，适应不同的数据分布，很适合用于异常检测。

根据国内外目前的研究，DPC 密度峰值聚类算法有着不需要事先指定类簇数、对数据分布要求不高，能够发现非球形类簇、原理简单，功能强大的优点，适合应用在锅炉工业生产流程中异常点检测的方面。国内 Du 等研究者[48]开创性地设计出一种基于密度峰值特征的参数自适应聚类算法 DDPA-DP。该算法能够针对任意形态的数据集，依据样本点的实际分布状况灵活且自动地确定截断距离参数。在多种类型与规模的数据集实验中，DDPA-DP 算法相较于传统密度聚类方法，展现出更好的聚类效果。此后，陆春光等国内研究学者[49]提出基于 DPC 算法的新型异常检测方法。该技术采用密度距离归一化乘积策略选择聚类核心，并结合距离与密度的阈值，实现了对异常点的识别，显著优化了异常检测的计算复杂度。然而，该算法在截断距离选择方面仍存在不足。

在国内外锅炉工业的数据挖掘流程中，获取适合分析的数据需经历一系列复杂的数据集预处理流程。在数据预处理和数据内在联系规律的挖掘过程中，众多系统分别采用聚类算法和关联规则算法，而关联规则算法则在数据挖掘阶段得到了普遍而深入的应用，经典关联规则算法目前在国内外的研究主流也是两种算法应用范围比较广：Apriori 算法和 FP-Growth 算法[50-54]。Apriori 算法是挖掘频繁项集以研究关联规则的方法，其过程有两步：首先筛选出所有满足预设最小支持度阈值的频繁项集；随后基于这些频繁项集，进一步产生同时符合最小支持度与最小置信度标准的强关联规则。关联规则挖掘的整体效能在很大程度上依赖于初步筛选频繁项集的阶段。Apriori 算法在关联规则挖掘领域很常见，但也存在两种局限性：一方面，该算法易于产生大量虚假冗余规则，特别是在处理庞大数据集或设定较低的支持度、置信度阈值时，产生的关联规则过多，致使用户难

中国知网 https://www.cnki.net

以筛选出真正有价值的信息。另一方面，算法的效率不高，频繁的数据库扫描影响其计算复杂度，查找一个 K-频繁项目集（k=1,2,...,K）需要扫描 K 次数据库。此外，随着数据库规模的增加，候选项集的数量急剧增长，导致在处理大型数据库或高 K 值时，算法耗时过长，甚至无法完成，从而严重限制了其可扩展性与应用性。因此，在对比了 Apriori 算法之后，FP-Growth 算法的优势就体现出来了，FP-Growth 算法在 Apriori 算法思想上进行了方法的改进，生成一个频繁模式而不需要生成候选模式。FP-Growth 算法利用了被称之为频繁模式树 FP-tree 的树形结构。该树形结构将保持项集之间的关联。数据库使用一个频繁项进行分段。这个片段被称为“模式片段”。分析了这些碎片模式的项集。因此，该方法相对减少了频繁项集的搜索。只需要对原数据集进行两次扫描，无需产生候选集，大大减少扫描原数据集的次数，从而提高了算法的效率，因此广泛应用于多种领域且得到了优化[55-58]。

1.3 论文的主要内容与创新点

1.3.1 论文的主要内容

本文主要是以完整的锅炉工业生产流程的历史数据为研究对象，对锅炉工况的生产状态进行异常检测，由于锅炉数据绝大部分是无标签数据，所以采用无监督学习的方法来进行数据的处理，用 DPC 聚类算法对锅炉数据集进行聚类分析来实现数据异常点的检测，并采用 FP-growth 关联规则算法来处理聚类结果，得到锅炉各环节生产状态数据的关联链，本文以锅炉工业生产流程的异常检测问题为前提，设计了一个基于无监督学习的工业数据故障检测系统，应用于锅炉工业生产流程中历史数据的异常检测。本文的主要研究内容如下：

(1)数据预处理。在锅炉工业生产流程中，会产生海量的历史数据信息，对其进行预处理是后续算法不可或缺的基础环节，于整个系统流程中占据核心地位。数据预处理包括数据集成、空值填充、时序调整等多个流程。数据集成是对原始数据的初步加工，确保所有数据的有效性；空值填充是为了预防数据缺失的空值对后续聚类算法造成干扰，对数据整体过滤，将空值填充；时序调整是针对燃煤锅炉工业生产流程中的环节进行时序发现，依据其相互影响关系，进行前后有序排列。将原始数据预先处理好之后送入下一个环节聚类模块进行聚类分析。

(2)锅炉数据集的异常检测算法研究。对传统经典和近年来新兴的 5 种异常检测方法

中国知网 https://www.cnki.net

(基于统计、基于距离、基于密度、基于深度学习、基于聚类)进行研究，由于锅炉数据集规模庞大，且具有无标签数据特征，依据其对数据集的实行效率的高低与异常点检测准确度选择了基于聚类的异常检测方法。又对 3 种不同的聚类算法(基于划分、基于层次、基于密度)进行分析。从理论上排除基于划分和基于层次的聚类算法，其不适合用于异常点检测，因此采取基于密度的聚类算法。对两种经典的密度聚类算法 DPC、DBSCAN 进行实验对比，通过理论和轮廓系数来进行实验结果对照分析，最终选择了 DPC 密度峰值聚类算法。

(3)关联链挖掘。根据聚类的结果，本文采用了基于 FP-Growth 的关联规则算法，并根据锅炉生产流程化的特点对其进行改进，采用 2 项频繁项集关联规则运算来对任意两个环节的聚类结果进行挖掘，通过计算两两环节之间的关联规则关系，对其进行关联度的归纳整理，以此生成当时锅炉工况的关联链。

(4)工业数据故障检测系统开发。根据上述内容的结合对进行系统开发，系统包含异常检测功能、关联链挖掘功能，异常点故障分析功能，该系统可以更好且直观的观测锅炉生产状态，分析锅炉故障发生的时间与造就故障的原因，为锅炉生产流程提供更好的安全性保障。

1.3.2 论文的创新点

(1)基于 KNN 的参数优化的 DPC 算法研究。

为了提高其异常点检测的准确性，本文将 DPC 算法于 KNN 近邻思想相结合，利用 KNN 的思想对其改进，根据数据集特征自动生成截断距离参数，消除初始参数对聚类结果的影响，提高了聚类精度。以此来设计基于锅炉数据的异常点检测方法，对锅炉数据集进行试验得到聚类结果和异常点，为后续的关联规则算法做铺垫，通过聚类算法计算得到历史数据的聚类结果，为系统的异常检测功能提供了基础，进而对锅炉生产的过程进行异常状态检测。

(2)基于 2 项频繁项集的 FP-Growth 的关联链挖掘算法。

对聚类的结果进行环节之间两两关联规则进行计算得到2项频繁关联规则数据项集，然后归纳生成当前锅炉状态的优质关联链。

(3)基于无监督学习的故障自动检测方法的研究。

结合前两个功能模块，在经过聚类算法对历史数据进行挖掘后，所得到的聚类结果其中包含异常点，将异常点与关联规则算法生成的关联链相结合，对异常点进行分析，

中国知网 https://www.cnki.net

推断该异常点发生的原因，是前后的哪一个环节出现问题导致该点的异常。将这个过程采用可视化、可交互的功能模块，生成异常点生产状态的趋势图，直观展现出检测结果并结合人工分析排查异常状态。

1.4 论文组织结构

根据所做的研究工作，本文分为 6 个章节，每个章节的内容和结构安排如下：

第一章：绪论，介绍了工业数据故障检测的研究背景和意义，阐述了在工业生产中实现故障的早期检测对于提高生产效率和保障生产安全的重要性。概述了国内外在该领域的研究现状，本文的主要研究内容及其创新点，介绍了文章的整体架构。

第二章：锅炉数据的预处理，提出工业数据预处理的必要性和方法，针对锅炉数据集的特点，对其进行数据清洗、缺失值和异常值处理以及数据标准化等操作步骤，确保数据质量满足后续分析的需求。

第三章：异常检测算法研究，对当前常用的异常检测算法进行分类和概述，分析了聚类算法在异常检测中的应用优势。介绍了 DPC 聚类算法的原理、优缺点以及实现过程，并将其与其他算法进行了对比，分析出其在工业数据故障检测中的适用性和先进性。

第四章：采用 FP-Growth 关联规则挖掘算法，并进行应用性创新。介绍了 FP 关联规则算法的原理和实现流程，对聚类的结果进行两两环节之间的关联规则计算，得到 2 项频繁项集关联规则数据，然后归纳生成当时锅炉状态的关联链。

第五章：基于无监督学习的工业数据故障检测系统研发与实现，详细介绍了系统的设计与开发过程。从异常检测模块、关联规则模块到异常原因追溯模块的设计思路与具体实现，全面展示了系统的结构和功能。

第六章：结论与展望，本章综述了毕业论文的整体研究内容合所取得的研究成果，深刻剖析了毕业论文存在的问题与不足之处，并以此为出发点，明确了后续科研工作的大致方向及改进方法，并对未来可能的研究内容提出了展望。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第二章　锅炉数据的预处理

数据预处理是数据挖掘中基础且重要的一步，采集到的锅炉数据集是非常原始的，数据混乱不规范，不能直接用于异常检测。本文的锅炉数据集数据是在工厂传感器上采集的。有着如给煤、主汽压力、炉膛温度、含氧量、送风量等环节数据信息，锅炉数据较全面和完整，可以通过数据预处理方法将原始数据规范化后以便进行后续的数据聚类和异常点检测。

2.1 锅炉数据集

本文以锅炉工业生产流程的历史数据为研究对象，如果锅炉数据有人工打上的标签，那么就可以采取有监督学习的方式，这样可以让训练集得出的结果向着人为打上标签的锅炉历史数据聚集，从而比较轻松的得到想要的训练结果，就像对垃圾邮件的数据进行处理一样，用户给了每封邮件它的标签，然后历史数据中用户告诉每封邮件是垃圾邮件还是不是垃圾邮件，用户就可以很方便的从这样的一些数据中去学习。然而现实中采集得到的燃煤锅炉历史数据是没有人工打上标签的数据，而且会存在很多异常噪声点，当数据为无标签数据时，通过肉眼无法对高维数据进行聚类，如果还想采用有监督学习的方式来对数据进行处理，那么就得给海量的锅炉历史数据人工打上标签，这显然是不可行的，所以对锅炉工业生产流程的历史数据采取无监督学习的方式来进行处理。虽然锅炉历史数据没有标签，但是可以通过常见的聚类算法对这些无标签数据进行处理，将数据进行聚类，这样可以很轻松地发现聚类的数据中心，从而也可以发现偏离数据聚类中心的数据点。由于这些点与大量的聚类数据有着明显的偏离，也可以把它划分为异常的数据点。利用聚类这一经典无监督学习方法实现对无标签的工业数据进行划分，可以有效的发现生产过程中的异常状态，从而更好的为生产过程保驾护航。锅炉内部系统界面如下图 2.1 所示：

中国知网　https://www.cnki.net

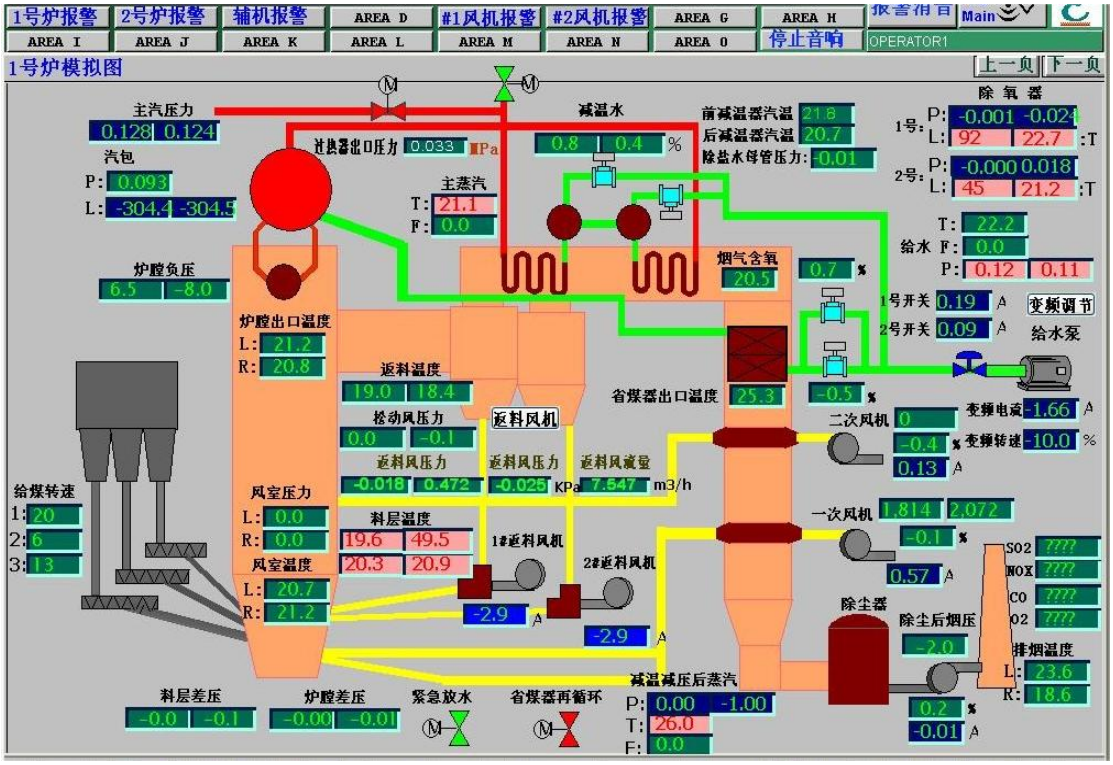


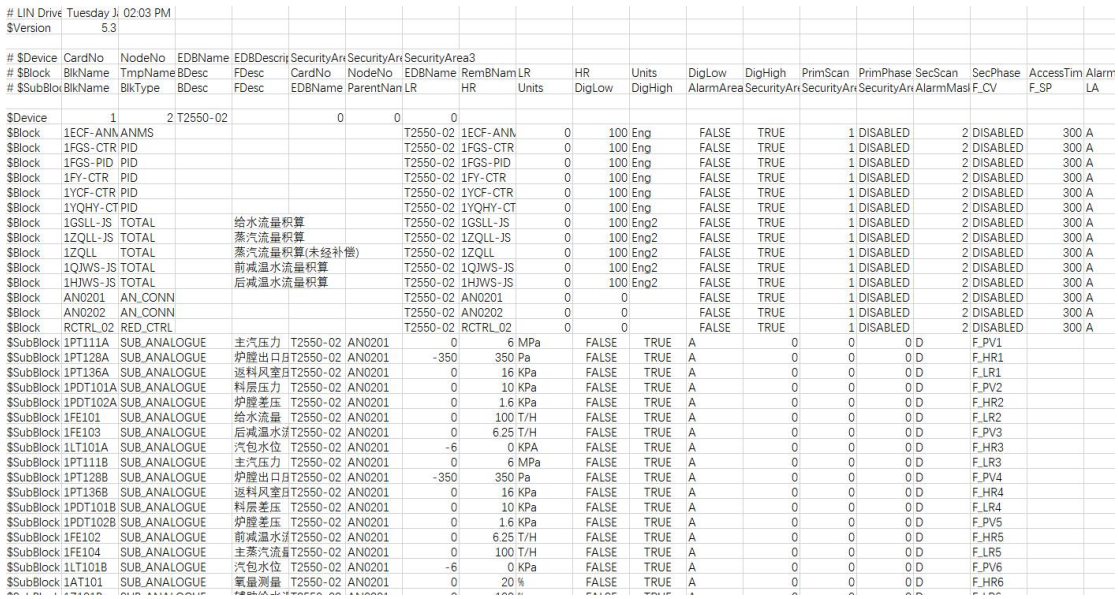
图 2.1 锅炉内部结构图

2.2 数据预处理方法

2.2.1 数据清洗与变换

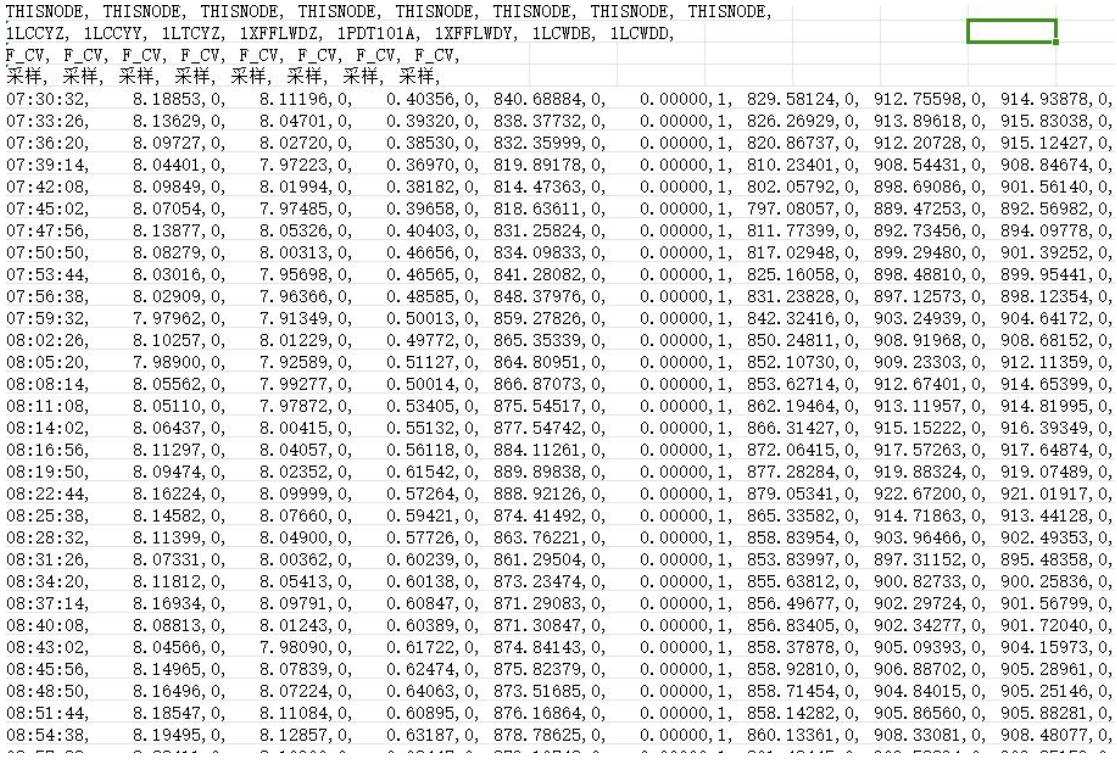
对锅炉数据集进行数据清洗。采集到的锅炉数据集主要存在以下问题，一是数据不规范，从传感器上采集到的数据是锅炉生产系统传输至计算机终端上的，存储的形式非常混乱，如图 2.2 所示。所以需要先将源头数据进行整合，得到修正后的采集数据，如图 2.3 所示。二是数据的缺失问题，原始数据整合后得到的数据集会不可避免的存在空缺值，这个问题会影响到后续的异常检测分析。由于后面章节关联链中的各个环节之间存在前后顺序，本文把每一列锅炉数据集的特征看做一个锅炉工业生产流程环节，各环节构成完整锅炉工业生产流程对象。筛选出所有在同一时间节点上的环节数据，并将其融合成一个全新的数据集。

中国知网 https://www.cnki.net



# LIN Drive	Tuesday J	02:03 PM																		
$Version	5.3																			
# $Device	CardNo	NodeNo	EDBName	EDBDescri	SecurityAr	SecurityAr	SecurityArea3													
# $Block	BlkName	TmpName	BDesc	FDesc	CardNo	NodeNo	EDBName	RemBNam	LR	HR	Units	DigLow	DigHigh	PrimScan	PrimPhase	SecScan	SecPhase	AccessTim	Alarm	
# $SubBlo	BlkName	BlkType	BDesc	FDesc	EDBName	ParentNan	LR	HR	Units	DigLow	DigHigh	AlarmArea	SecurityAr	SecurityAr	SecurityAr	AlarmMas	F_CV	F_SP	LA	
$Device	1	2	T2550-02		0	0	0													
$Block	1ECF-ANN	ANMS					T2550-02	1ECF-ANN	0	100	Eng	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	1FGS-CTR	PID					T2550-02	1FGS-CTR	0	100	Eng	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	1FGS-PID	PID					T2550-02	1FGS-PID	0	100	Eng	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	1FY-CTR	PID					T2550-02	1FY-CTR	0	100	Eng	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	1YCF-CTR	PID					T2550-02	1YCF-CTR	0	100	Eng	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	1YQHY-CT	PID					T2550-02	1YQHY-CT	0	100	Eng	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	1GSLL-JS	TOTAL		给水流量积算			T2550-02	1GSLL-JS	0	100	Eng2	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	1ZQLL-JS	TOTAL		蒸汽流量积算			T2550-02	1ZQLL-JS	0	100	Eng2	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	1ZQLL	TOTAL		蒸汽流量积算(未经补偿)			T2550-02	1ZQLL	0	100	Eng2	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	1QJWS-JS	TOTAL		前减温水流量积算			T2550-02	1QJWS-JS	0	100	Eng2	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	1HJWS-JS	TOTAL		后减温水流量积算			T2550-02	1HJWS-JS	0	100	Eng2	FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	AN0201	AN_CONN					T2550-02	AN0201	0	0		FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	AN0202	AN_CONN					T2550-02	AN0202	0	0		FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$Block	RCTRL_02	RED_CTRL					T2550-02	RCTRL_02	0	0		FALSE	TRUE	1	DISABLED	2	DISABLED	300	A	
$SubBlock	1PT111A	SUB_ANALOGUE	主汽压力	T2550-02	AN0201		0	6	MPa	FALSE	TRUE	A	0	0	0	D	F_PV1			
$SubBlock	1PT128A	SUB_ANALOGUE	炉膛出口日	T2550-02	AN0201		-350	350	Pa	FALSE	TRUE	A	0	0	0	D	F_HR1			
$SubBlock	1PT136A	SUB_ANALOGUE	返料风室日	T2550-02	AN0201		0	16	KPa	FALSE	TRUE	A	0	0	0	D	F_LR1			
$SubBlock	1PDT101A	SUB_ANALOGUE	料层压力	T2550-02	AN0201		0	10	KPa	FALSE	TRUE	A	0	0	0	D	F_PV2			
$SubBlock	1PDT102A	SUB_ANALOGUE	炉膛差压	T2550-02	AN0201		0	1.6	KPa	FALSE	TRUE	A	0	0	0	D	F_HR2			
$SubBlock	1FE101	SUB_ANALOGUE	给水流量	T2550-02	AN0201		0	100	T/H	FALSE	TRUE	A	0	0	0	D	F_LR2			
$SubBlock	1FE103	SUB_ANALOGUE	后减温水流	T2550-02	AN0201		0	6.25	T/H	FALSE	TRUE	A	0	0	0	D	F_PV3			
$SubBlock	1LT101A	SUB_ANALOGUE	汽包水位	T2550-02	AN0201		-6	0	KPA	FALSE	TRUE	A	0	0	0	D	F_HR3			
$SubBlock	1PT111B	SUB_ANALOGUE	主汽压力	T2550-02	AN0201		0	6	MPa	FALSE	TRUE	A	0	0	0	D	F_LR3			
$SubBlock	1PT128B	SUB_ANALOGUE	炉膛出口日	T2550-02	AN0201		-350	350	Pa	FALSE	TRUE	A	0	0	0	D	F_PV4			
$SubBlock	1PT136B	SUB_ANALOGUE	返料风室日	T2550-02	AN0201		0	16	KPa	FALSE	TRUE	A	0	0	0	D	F_HR4			
$SubBlock	1PDT101B	SUB_ANALOGUE	料层差压	T2550-02	AN0201		0	10	KPa	FALSE	TRUE	A	0	0	0	D	F_LR4			
$SubBlock	1PDT102B	SUB_ANALOGUE	炉膛差压	T2550-02	AN0201		0	1.6	KPa	FALSE	TRUE	A	0	0	0	D	F_PV5			
$SubBlock	1FE102	SUB_ANALOGUE	前减温水流	T2550-02	AN0201		0	6.25	T/H	FALSE	TRUE	A	0	0	0	D	F_HR5			
$SubBlock	1FE104	SUB_ANALOGUE	主蒸汽流量	T2550-02	AN0201		0	100	T/H	FALSE	TRUE	A	0	0	0	D	F_LR5			
$SubBlock	1LT101B	SUB_ANALOGUE	汽包水位	T2550-02	AN0201		-6	0	KPa	FALSE	TRUE	A	0	0	0	D	F_PV6			
$SubBlock	1AT101	SUB_ANALOGUE	氧量测量	T2550-02	AN0201		0	20	%	FALSE	TRUE	A	0	0	0	D	F_HR6			

图 2.2 锅炉传感器原始数据集图



THISNODE,	THISNODE,	THISNODE,	THISNODE,	THISNODE,	THISNODE,	THISNODE,	THISNODE,
1LCCYZ,	1LCCYY,	1LTCYZ,	1XFFLWDZ,	1PDT101A,	1XFFLWDY,	1LCWDB,	1LCWDD,
F_CV,	F_CV,	F_CV,	F_CV,	F_CV,	F_CV,	F_CV,	F_CV,
采样,	采样,	采样,	采样,	采样,	采样,	采样,	采样,
07:30:32,	8.18853, 0,	8.11196, 0,	0.40356, 0,	840.68884, 0,	0.00000, 1,	829.58124, 0,	912.75598, 0,	914.93878, 0,
07:33:26,	8.13629, 0,	8.04701, 0,	0.39320, 0,	838.37732, 0,	0.00000, 1,	826.26929, 0,	913.89618, 0,	915.83038, 0,
07:36:20,	8.09727, 0,	8.02720, 0,	0.38530, 0,	832.35999, 0,	0.00000, 1,	820.86737, 0,	912.20728, 0,	915.12427, 0,
07:39:14,	8.04401, 0,	7.97223, 0,	0.36970, 0,	819.89178, 0,	0.00000, 1,	810.23401, 0,	908.54431, 0,	908.84674, 0,
07:42:08,	8.09849, 0,	8.01994, 0,	0.38182, 0,	814.47363, 0,	0.00000, 1,	802.05792, 0,	898.69086, 0,	901.56140, 0,
07:45:02,	8.07054, 0,	7.97485, 0,	0.39658, 0,	818.63611, 0,	0.00000, 1,	797.08057, 0,	889.47253, 0,	892.56982, 0,
07:47:56,	8.13877, 0,	8.05326, 0,	0.40403, 0,	831.25824, 0,	0.00000, 1,	811.77399, 0,	892.73456, 0,	894.09778, 0,
07:50:50,	8.08279, 0,	8.00313, 0,	0.46656, 0,	834.09833, 0,	0.00000, 1,	817.02948, 0,	899.29480, 0,	901.39252, 0,
07:53:44,	8.03016, 0,	7.95698, 0,	0.46565, 0,	841.28082, 0,	0.00000, 1,	825.16058, 0,	898.48810, 0,	899.95441, 0,
07:56:38,	8.02909, 0,	7.96366, 0,	0.48585, 0,	848.37976, 0,	0.00000, 1,	831.23828, 0,	897.12573, 0,	898.12354, 0,
07:59:32,	7.97962, 0,	7.91349, 0,	0.50013, 0,	859.27826, 0,	0.00000, 1,	842.32416, 0,	903.24939, 0,	904.64172, 0,
08:02:26,	8.10257, 0,	8.01229, 0,	0.49772, 0,	865.35339, 0,	0.00000, 1,	850.24811, 0,	908.91968, 0,	908.68152, 0,
08:05:20,	7.98900, 0,	7.92589, 0,	0.51127, 0,	864.80951, 0,	0.00000, 1,	852.10730, 0,	909.23303, 0,	912.11359, 0,
08:08:14,	8.05562, 0,	7.99277, 0,	0.50014, 0,	866.87073, 0,	0.00000, 1,	853.62714, 0,	912.67401, 0,	914.65399, 0,
08:11:08,	8.05110, 0,	7.97872, 0,	0.53405, 0,	875.54517, 0,	0.00000, 1,	862.19464, 0,	913.11957, 0,	914.81995, 0,
08:14:02,	8.06437, 0,	8.00415, 0,	0.55132, 0,	877.54742, 0,	0.00000, 1,	866.31427, 0,	915.15222, 0,	916.39349, 0,
08:16:56,	8.11297, 0,	8.04057, 0,	0.56118, 0,	884.11261, 0,	0.00000, 1,	872.06415, 0,	917.57263, 0,	917.64874, 0,
08:19:50,	8.09474, 0,	8.02352, 0,	0.61542, 0,	889.89838, 0,	0.00000, 1,	877.28284, 0,	919.88324, 0,	919.07489, 0,
08:22:44,	8.16224, 0,	8.09999, 0,	0.57264, 0,	888.92126, 0,	0.00000, 1,	879.05341, 0,	922.67200, 0,	921.01917, 0,
08:25:38,	8.14582, 0,	8.07660, 0,	0.59421, 0,	874.41492, 0,	0.00000, 1,	865.33582, 0,	914.71863, 0,	913.44128, 0,
08:28:32,	8.11399, 0,	8.04900, 0,	0.57726, 0,	863.76221, 0,	0.00000, 1,	858.83954, 0,	903.96466, 0,	902.49353, 0,
08:31:26,	8.07331, 0,	8.00362, 0,	0.60239, 0,	861.29504, 0,	0.00000, 1,	853.83997, 0,	897.31152, 0,	895.48358, 0,
08:34:20,	8.11812, 0,	8.05413, 0,	0.60138, 0,	873.23474, 0,	0.00000, 1,	855.63812, 0,	900.82733, 0,	900.25836, 0,
08:37:14,	8.16934, 0,	8.09791, 0,	0.60847, 0,	871.29083, 0,	0.00000, 1,	856.49677, 0,	902.29724, 0,	901.56799, 0,
08:40:08,	8.08813, 0,	8.01243, 0,	0.60389, 0,	871.30847, 0,	0.00000, 1,	856.83405, 0,	902.34277, 0,	901.72040, 0,
08:43:02,	8.04566, 0,	7.98090, 0,	0.61722, 0,	874.84143, 0,	0.00000, 1,	858.37878, 0,	905.09393, 0,	904.15973, 0,
08:45:56,	8.14965, 0,	8.07839, 0,	0.62474, 0,	875.82379, 0,	0.00000, 1,	858.92810, 0,	906.88702, 0,	905.28961, 0,
08:48:50,	8.16496, 0,	8.07224, 0,	0.64063, 0,	873.51685, 0,	0.00000, 1,	858.71454, 0,	904.84015, 0,	905.25146, 0,
08:51:44,	8.18547, 0,	8.11084, 0,	0.60895, 0,	876.16864, 0,	0.00000, 1,	858.14282, 0,	905.86560, 0,	905.88281, 0,
08:54:38,	8.19495, 0,	8.12857, 0,	0.63187, 0,	878.78625, 0,	0.00000, 1,	860.13361, 0,	908.33081, 0,	908.48077, 0,

图 2.3 传感器采集数据修正后输出数值图

锅炉工业数据表如表 2.1 所示，dt 是时间维度，X1 至 X17 依次是汽包压力、主汽压力左、主汽温度、主蒸汽流量、给水流量、给水压力左、烟气含氧、料层差压左、料层差压右、炉膛差压左、返料温度左、返料温度右、料层温度 B、料层温度 D、一次风量、二次风流量、风室压力左 17 个环节。每天锅炉环节实测数据记录约有 1400 条，锅炉数据集约有 20 万条记录。

中国知网 https://www.cnki.net

表 2.1 锅炉工业数据表

字段名称	字段类型	备注	是否主键	可否为空
dt	datetime	时间	Y	N
x1	float	气包压力	N	Y
x2	float	主汽压力左	N	Y
x3	float	主汽温度	N	Y
x4	float	主蒸汽流量	N	Y
x5	float	给水流量	N	Y
x6	float	给水压力左	N	Y
x7	float	烟气含氧	N	Y
x8	float	料层差压左	N	Y
x9	float	料层差压右	N	Y
x10	float	炉膛差压左	N	Y
x11	float	返料温度左	N	Y
x12	float	返料温度右	N	Y
x13	float	料层温度 B	N	Y
x14	float	料层温度 D	N	Y
x15	float	一次风量	N	Y
x16	float	二次风量	N	Y
x17	float	风室压力左	N	Y

2.2.2 缺失值处理和时序调整

根据上文中整合的到的数据集存在空缺值这个问题，本论文采取两种办法针对不同的空缺值存在情况，一是大量的空缺值数据，直接将其舍弃掉；二是少量的空缺值，采用均值填充方法进行填充(选取前后空缺值数量相同数量的记录数据对其求得平均值来对空值进行填充)。填充数据之后，因为传感器采集的时间是同一时间，但是锅炉生产流程对象中，各个环节之间有着单向影响的相关关系，上一个环节采集到的数据和下一个环节采集到的数据之间有一定的滞后性，后续环节会对前一环节的变化做出反应，还需对数据集进行时序调整，本文采用差分极值的时序发现算法来进行数据处理。算法 2.1 是时序算法的伪代码、图 2.4 是处理完之后的数据集缺失值图，每一行表示一条 60 秒更新周期的数据记录。

中国知网 https://www.cnki.net

dt	x1	x2	x3	x4	x5	x6	x7	x8	x9	x10	x11	x12	x13	x14	x15	x16	x17
2023/10/13	4.0417	3.64633	433.849	66.14407	58.46569	5.80242	5.20562	8.04066	7.99669	0.54733	886.3488	874.221	938.9366	941.4689	43689.65	44778.27	8.66593
2023/10/13	4.04501	3.63888	433.6854	67.27141	59.21963	5.87576	5.15672	8.06447	7.90191	0.47759	889.4589	874.7665	940.1824	943.2573	43624.34	41644.8	8.62049
2023/10/13	4.05405	3.63475	432.8856	68.34064	59.81495	5.90769	5.02107	8.00751	7.85523	0.46922	889.1312	876.8664	941.4299	945.1648	43594.82	43139.47	8.60376
2023/10/13	4.05993	3.6308		69.2167	59.49677		4.8558	8.03176	7.90986	0.49806	890.3177	879.7384	942.493	945.4373	42528.87	40911.91	8.60384
2023/10/13	4.05648	3.6273	430.9407	68.56306	80.76958	5.7914	4.63051	8.06014		0.49279	892.7842	881.4114	943.9706	946.3898	41840.19	42824.18	8.62722
2023/10/13		3.60258	430.7225	68.18172	78.51308	5.66765	4.64502	8.04056	7.91189	0.50632	895.299	883.3897	945.3099	948.3013	42676.23	42193.02	8.66654
2023/10/13			431.5042			5.65439	4.62942	7.98502	7.85774	0.51238	898.8923	886.3996	946.742	950.3742		42582.86	8.62675
2023/10/13		3.55319				5.79248	4.63846	7.99439	7.86966	0.50595	899.6137	889.7607	948.4971	952.9475	42383.55	41842.58	8.61839
2023/10/13		3.54337	433.1583			5.90462	4.69411	8.02807	7.90249	0.49338	901.023		950.4174	954.4028	43106.08	42744.97	8.63024
2023/10/13		3.53363	433.0492			5.86362	4.6484	8.02535	7.87513	0.48261	901.8689	891.8743	951.6521	955.5918	44249.81	41857.17	8.69604
2023/10/13		3.53872	432.2131			5.94158	4.63041	8.01476	7.90593		902.3716			956.8541	42463.33	42001.99	8.65067
2023/10/13		3.53471	431.4133			5.76117	4.6636	8.11282			902.7933			957.9119		41789.35	8.73172
2023/10/13	3.96391			68.48927	80.25061	5.68359	4.70316	8.01947	7.90661		904.4158			958.4044		42166.27	8.63937
2023/10/13	3.95083	3.51471	432.2312	67.78163	80.31806		4.65575	8.01709	7.90119		903.6716			958.4132		42927.88	8.65269
2023/10/13	3.9334	3.50831	433.5036	67.5057	60.6329	5.83109	4.6314	8.0081	7.89659		904.5095			959.1252		40780.33	8.60423
2023/10/13	3.94893	3.50424	434.5125		61.38145	5.90487	5.04701	7.94429	7.87625	0.52864	904.8655			959.7969		41712.89	8.58178
2023/10/13	3.96444	3.51032	435.0487	69.99516	61.68872	5.95158	5.23205	7.97505	7.88559	0.50522	905.8353			959.3901		42636.02	8.58929
2023/10/13	3.97763		434.9396	69.92765	60.31323	5.87098		8.03468	7.91693	0.46766	903.8743			958.4711	43864.9	43938.54	8.59951
2023/10/13		3.53638	434.8214	70.61372	80.72333	5.75166		7.92772	7.77924	0.46524	903.7928	895.4551	955.6099	957.1306	41910.07	43559.76	8.5238
2023/10/13	3.98808	3.53126	434.6306	70.05188	79.55305			7.98225	7.87034	0.50342	902.1424	894.1513		956.5701	43255.55	42077.1	8.60686
2023/10/13	3.97067		435.3031	69.96495	81.55776	5.72709		8.06058		0.49302	902.9884	893.8468	954.5256	955.7886	42020.4	41927.15	8.66105
2023/10/13	3.94884	3.49336	436.0848		81.69199	5.71929		8.02525	7.94841	0.50344	902.9617	894.4071	954.2681	956.0792	43059.48	42796.55	8.69999
2023/10/13	3.94615	3.50061	436.6937	69.36042	61.27197	5.9037		7.95873	7.91291	0.53931	900.9125	894.8172	954.4944	956.3256	43703.24	41004.63	8.60036
2023/10/13	3.95689	3.49974	436.4573	69.91608	61.06673	5.88175		7.88622	7.88855	0.57846	901.0108	893.4938	953.0075	956.3829	41924.35	43744.87	8.55817
2023/10/13	3.96429	3.50135	435.5849	70.08916	61.32545	5.91808		7.89225	7.88196	0.57597	899.9005	892.4983	953.27	956.0483		44132.71	8.61344
2023/10/13	3.97058	3.51243	434.6851	69.78221	74.90462	5.77619	5.22847	8.00105	7.92748	0.5067	900.5039	893.945	953.221	955.5485	42363.38	41213.1	8.63953
2023/10/13		3.49129	434.358	70.07238	80.44994	5.66936	5.30341	8.02929	7.93654	0.48147	900.2929	895.2535	954.0698	955.8801	42946.3	41300.27	8.65849
2023/10/13	3.93951	3.47041	434.7306		80.08184	5.63298	5.23801	8.00334	7.90007	0.49925	901.1863	895.7036	954.4954	957.277	42564.19	44203.51	8.62621
2023/10/13	3.90294	3.43347	435.1214	69.7125	84.00907	5.77141	5.26326	8.01733	7.91063		900.2424	894.6378	954.2956	956.7335	43749.14	43210.79	8.60469
2023/10/13	3.87483	3.41558	435.4122	69.35349	61.49057	5.84587	5.32596	8.04187	7.92201	0.47817	899.4851	894.7811	954.215	955.9275	42961.52	43162.1	8.65609
2023/10/13	3.88001	3.39987	435.0305	70.78543	61.76266	5.84816	5.23921	8.05606	7.94303	0.49407	900.488	893.2549	954.4998	955.6448	42190.39	43834.14	8.68443
2023/10/13	3.86784	3.38762	433.9489	71.21181	62.81058	5.9409	5.38311	7.99488	7.91712	0.51051	899.9649	892.2306	953.5613	955.8305	43478.5	39996.25	8.58426
2023/10/13	3.86822	3.39198	432.8947	70.81075	62.84349	5.90306	5.25769	7.99537	7.90894	0.49574	898.8452	893.5064	952.7575	955.4458	42406.03	42710.5	8.62629
2023/10/13	3.84598	3.37268	431.9495	69.85176	83.36082	5.71305	5.25491	8.02618	7.93364	0.48208	898.7477	890.7483	952.3983	954.8212	43167.54	41323.31	8.61336
2023/10/13	3.8145	3.3401	431.7041	69.4336	81.8489	5.59987	5.29486	7.99668	7.90269	0.48297	897.7661	889.0181	952.0197	954.2553	42620.68	43325	8.59447

图 2.4 数据集缺失值图

算法 2.1 基于差分极值的时序发现算法

```
import numpy as np
from scipy.stats import mode


def time_series_discovery(w, k, m):
    Links = {m}
    q = {((m, m), 0)}

    for n in k:
        if n not in Links:
            interval = []
            for extremum_m in w[m]:
                temp = []
                for extremum_n in w[n]:
                    temp.append(abs(extremum_n - extremum_m))
                interval.append(np.min(temp))
            q.add(((m, n), mode(interval)[0][0]))

    return q
```


中国知网 https://www.cnki.net

```
# 示例数据
w = {
    'A': [1, 3, 5, 7],
    'B': [2, 4, 6, 8],
    'C': [0, 2, 4, 6]
}
k = ['A', 'B', 'C']
m = 'C'

# 调用算法
q = time_series_discovery(w, k, m)
print("延迟间距数组 q:", q)
```

输出：全部环节相比于基准环节 m 的延迟间距数组 q

算法 2.1 接受三个输入参数：w，k 和 m，分别代表全部环节的极值点时刻集合、环节类别集合和基准环节。然后根据算法步骤对时间序列数据进行处理，最终返回延迟间距数组 q。在示例数据中，本文给定了三个环节 A、B 和 C，它们各自的极值点集合作为输入数据 w。环节类别集合 k 包含了所有环节，而基准环节 m 被设为环节 C。最后，调用 time_series_discovery 函数并打印结果。

根据算法调整后，我们得到了在一个时刻生产流程各环节生产状态变化的数据，集中统计后得到根据时间顺序推算出的锅炉数据集，为本文的聚类分析环节打下了基础，集成处理后的数据集如下图 2.5 所示：

	dt	x1	x2	x3	x4	x5	x6	x7	x8	x9	x10	x11	x12	x13	x14	x15	x16	x17
11	2023-10-13 00:10:00.000	3.99229	3.53872	432.21307	70.305	61.07741	5.94158	4.63041	8.01476	7.90593	0.50449	902.37158	891.91571	954.19104	956.85413	42463.3281	42001.9862	8.65067
12	2023-10-13 00:11:00.000	3.9831	3.53471	431.41327	69.09548	61.92155	5.76117	4.6636	8.11282	7.97737	0.4951	902.79333	893.52539	954.57159	957.91193	43633.3515	41789.3515	8.73172
13	2023-10-13 00:12:00.000	3.96391	3.52108	431.57687	68.48927	80.25061	5.68359	4.70316	8.01947	7.90661	0.50746	904.41577	892.38287	956.03009	958.40436	43305.746	42166.2656	8.63937
14	2023-10-13 00:13:00.000	3.95083	3.51471	432.23123	67.78163	80.31806	5.64629	4.65575	8.01709	7.90119	0.50206	903.67157	892.90497	955.98029	958.41315	43262.25	42927.875	8.65269
15	2023-10-13 00:14:00.000	3.9334	3.50831	433.50363	67.5057	60.6329	5.83109	4.6314	8.0081	7.89659	0.49798	904.50952	893.65131	955.5567	959.12518	43099.3945	40780.332	8.60423
16	2023-10-13 00:15:00.000	3.94893	3.50424	434.51245	69.34402	61.38145	5.90487	5.04701	7.94429	7.87625	0.52864	904.86548	896.14307	955.71844	959.79694	41598.2617	41712.8867	8.58178
17	2023-10-13 00:16:00.000	3.96444	3.51032	435.04865	69.99516	61.68872	5.95158	5.23205	7.97505	7.88559	0.50522	905.83527	895.54675	955.73303	959.39014	43274.1015	42636.0195	8.58929
18	2023-10-13 00:17:00.000	3.97763	3.52842	434.93958	69.92765	60.31323	5.87098	5.2883	8.03468	7.91693	0.46766	903.87427	896.37756	955.72522	958.47107	43864.8984	43938.539	8.59951
19	2023-10-13 00:18:00.000	4.00309	3.53638	434.82144	70.61372	80.72333	5.75166	5.08795	7.92772	7.77924	0.46524	903.79279	895.45508	955.60986	957.13062	41910.0703	43559.7578	8.5238
20	2023-10-13 00:19:00.000	3.98808	3.53126	434.63058	70.05188	79.55305	5.67501	5.13536	7.98225	7.87034	0.50342	902.1424	894.15131	955.01172	956.57007	43255.5546	42077.1015	8.60686
21	2023-10-13 00:20:00.000	3.97067	3.50576	435.30313	69.96495	81.55776	5.72709	5.1925	8.06058	7.95674	0.49302	902.9884	893.8468	954.52557	955.78864	42020.3984	41927.1484	8.66105
22	2023-10-13 00:21:00.000	3.94884	3.49336	436.08475	68.6503	81.69199	5.71929	5.19469	8.02525	7.94841	0.50344	902.96167	894.4071	954.26813	956.07922	43059.4843	42796.5507	8.69999
23	2023-10-13 00:22:00.000	3.94615	3.50061	436.69366	69.36042	61.37197	5.9037	5.32756	7.96873	7.91291	0.53931	900.91248	894.8172	954.49438	956.32556	43703.2421	41004.6289	8.69036

图 2.5 集成处理后数据

2.2.3 数据标准化与归一化

数据标准化在数据处理中是一项关键而基础的工作。当数据集中某些属性的数值范围跨度较大时，可能导致不同特征间的差异性很大，进而影响模型的性能。因此，数据

中国知网 https://www.cnki.net

标准化将数据缩放到一个确定的区域是十分必要的。在处理锅炉数据集时，有些环节数值范围可能相当大，直接使用可能会降低异常检测的精度。为了解决这一问题，引入最大最小归一化的方法，对数据进行缩放到[0,1]区间。转换公式如式(2.1)所示。

$$X = \frac{max - min}{x - min} \tag{2.1}$$

其中 X 表示经过归一化处理后的值，x 表示原始数据，max 表示某一环节数据的最大值，min 表示某一环节数据的最小值。通过这个公式，用户可以将原始数据 x 转换为标准化后的值 X，确保其范围在[0,1]区间内。这样的标准化方法能够保证不同特征的数据不会影响后续聚类分析的性能，提高了准确性和稳定性。

2.3 本章小结

数据预处理是数据挖掘的基础，本章主要介绍了锅炉数据集的特点以及针对采集到的锅炉数据集数据中存在的问题进行分析，并采用一系列的数据预处理方法来规范数据集，以便后续的聚类分析。对传感器采集的原始数据进行数据变换，然后是空值填充，最后为了提高准确性将数据集数据标准化和归一化。对数据预处理是为了后续的聚类算法可以更好地进行单维度高效的聚类分析，为关联链的两两环节进行关联规则分析提供基础。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第三章　基于参数优化 DPC 聚类算法的异常点发现算法

3.1 异常检测算法概述与分类

上文提到了 5 种常见的异常检测方法：基于统计、距离、密度、深度学习、聚类的方法。下表 3.1 记录了不同异常检测算法的优劣情况。

表 3.1 各异常检测方法比较

名称	基于统计	基于距离	基于密度	基于深度学习	基于聚类
优点	简单易实现，适用于大规模数据集	能够检测到不同类型的异常值	能够检测到局部异常值	检测全局异常值	检测全局和局部异常值
缺点	对数据分布有严格要求，容易混淆正常点	计算复杂度较高，对高维数据集的性能较差	受到噪声和异常值的影响	需要预定义节点关系，局部异常不敏感	受到噪声和异常值的影响大

由于课题的工业数据集规模庞大、数据具有前后跳跃性等特点，需要选择一种效率高且能检测全局异常值的异常检测方法。针对于实验所用的数据集，基于聚类的异常检测方法相对于其他方法拥有额外的优势，体现在如下三点：

(1)适用于无监督学习：基于聚类的异常检测方法通常属于无监督学习方法，不需要标记的异常数据来训练模型。这使得它们更适用于大多数现实世界中的数据，因为异常通常是未知的，并且在训练数据中可能很难获取到足够数量的标记异常样本。不受数据分布影响：聚类方法不依赖于数据的分布假设，因此对于各种类型的数据(例如高维数据、非线性数据等)都具有较好的鲁棒性。它们能够发现数据中的任何类型的异常值，而不受数据分布的限制。

(2)自适应性：聚类方法可以根据数据自适应地调整聚类簇的数量和形状，从而更好地适应不同数据集的特点。这使得它们能够有效地处理不同大小和形状的异常簇。

(3)可解释性：聚类方法通常产生易于解释的结果，即将异常点划分为与正常数据点不同的簇。这有助于用户理解为什么某些数据点被识别为异常，并且能够更好地解释异常检测的结果。

由上表的优缺点比较可知，要满足对异常值敏感、效率高效、实现全局异常值检测这三个条件，前 4 种异常检测方法均被排除，本文选择基于聚类的异常检测方法来对数据集进行试验。

中国知网 https://www.cnki.net

3.2 各聚类算法比较分析

基于上文所述的优势，本文确定采取基于聚类的异常检测方法，继而开展对聚类算法的深入研究。传统的聚类算法有 K-means、层次聚类、密度聚类等，需要对各种聚类算法的适用性进行比较分析。如下表 3.2 所示。

表 3.2 各聚类算法比较

名称	K-means	层次聚类	密度聚类
优点	算法方便实现，不断迭代寻找聚类中心的位置	构建层次化的聚类树，将聚类样本至层次化簇团	利用样本之间的密度来划分簇，可以检测出异常点
缺点	必须预先设定 K 值，噪声点影响聚类结果	计算复杂度高、效率低，容易出现维度灾难，噪声点影响聚类结果	需要设定聚类参数

经过上表的对比分析后，本文选择密度聚类的方法来进行异常点的检测，因此需要对两种经典的密度聚类算法 DPC 和 DBSCAN 进行分析。在上文中已经提到，DBSCAN 密度聚类算法虽然能够自动发现具有不同密度和形状的簇，但是需要设置邻域半径(ε)和最小邻域内样本数(MinPts)两个参数才能够识别离群点。算法的关键在于通过样本之间的邻域关系来确定核心点和密度可达性，从而实现聚类操作。DPC 密度聚类算法可以发现任意形状的簇，能够自动识别簇的个数，对噪声和离群值具有较好的鲁棒性，能够将异常点与正常点分离出来，很适合用于异常检测，且适应不同的数据分布。因此，本文选择 DPC 密度聚类算法来对人工数据集和锅炉数据集数据集进行实验。

3.2.1 DPC 聚类算法的原理与实现

DPC 密度聚类算法通过计算数据点之间的距离和数据点到其邻域截断距离来确定局部密度和相对距离，将具有相似密度的数据点聚集在一起。DPC 峰值聚类算法基于以下公式设计:

对于聚类中心点，为实现快速的查找，本文引用了两个参数，数据对象 i 的局部密度ρ_i、数据对象 i 与数据对象 j（局部密度更高）间的距离最短距离参数δ_i，以下给出的用于ρ_i的公式：

$$\rho_i = \sum_{i \neq j\varphi} A(d_{ij} - d_c) \tag{3.1}$$

此处的$A_{(a)} = 1$在$A \leq 0$时成立，反之$A_{(a)} = 0$。d_{ij}和d_c表示数据 i 与数据 j 之间的欧式距离和截断距离参数，后者的计算可依据 percent 百分比参数计算，percent 是数据对

中国知网 https://www.cnki.net

象 i 的周围数据对象点的密集数量占数据集数量的比例，用数据对象的近邻数/数据集总数进行计算。DPC 算法的 percent 值一般小于 2 时，进行聚类能达到较好的效果。

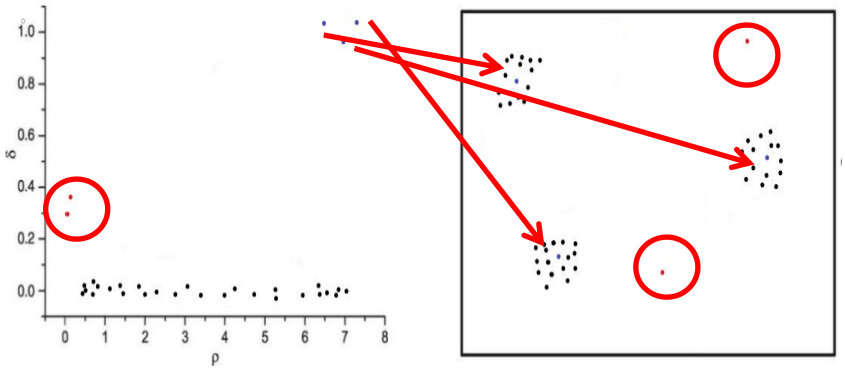
以下公式(3.2)用于δ_i的计算，也就是数据对象 i 到和该点局部密度更高的点之间的最小距离：

$$\delta_i = \min_{j:\rho_j>\rho_i}(d_{ij}) \tag{3.2}$$

对于数据对象中最大的局部密度点 ρ_i，其距离计算公式如下(3.3)

$$\delta_i = \max_{i\neq j}(d_{ij}) \tag{3.3}$$

选择局部密度 ρ 和高局部密度点之间的最小距离 δ 分别为横、纵坐标绘制决策图，如下图 3.1 所示：



(a) 决策图　　(b) 聚类效果图

图 3.1 聚类图示例

从图 3.1(a)中可以发现，图中具备最高的 ρ 和 δ 值的三个点在决策图的右上角，因此确定它们为 DPC 算法的聚类中心点，而左侧的两个点，可判断其为离群点。在图 3.1(b)中，采用 DPC 算法进行聚类后，呈现出的聚类结果中有 3 个类簇和 2 个离群点，其中离群点与决策图中所标记的离群点，即与局部密度低，相对距离高的点相对应。

DPC 峰值聚类算法设计思路有两点：一是聚类中心点总是被低密度点包围；二是聚类中心与其他高密度点间的距离相对较远。其具体步骤如下：

(1) 密度计算：计算每数据集个样本的局部密度。使用距离函数来衡量样本之间的距离，根据邻域半径确定每个样本的邻域内点的数量。

(2) 边界点选择：在计算密度时，根据阈值选择一个核心点的最小局部密度，该阈值用于确定哪些点被认为是边界点。

(3) 相似度计算：通过比较两个样本之间的局部密度，计算每对边界点之间的相对密度。

中国知网 https://www.cnki.net

(4) 簇中心选取：根据每个样本的相对密度和距离选择一个具有较高相对密度和距离的样本作为簇中心。

(5) 聚类分配：将其他样本根据簇中心分配到相应的簇中。距离更近且相对密度更大的样本会被分配到同一个簇中。

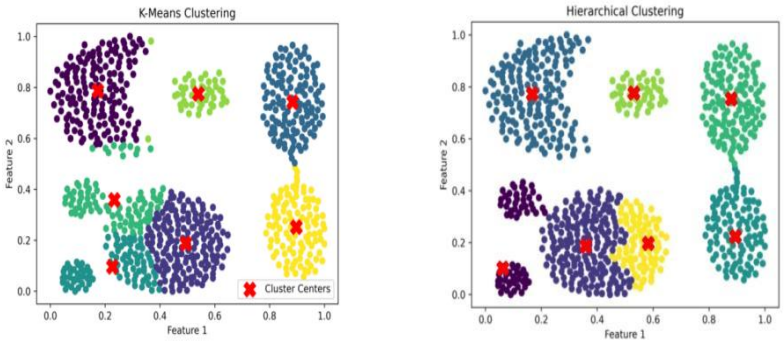
(6) 簇合并：最后，可以根据设定的阈值将相似的簇进行合并，以得到最终的聚类结果。

由于 DPC 聚类算法具有对离群点和噪声数据具有更好的鲁棒性、不需要指定邻域半径参数、可以自动估计簇中心点的邻域范围，更好地处理不同形状和大小的簇等优势，推断出用其进行工业数据集的离群点检测效果会更好。

3.3 聚类实验结果分析

3.3.1 经典数据集测试

为验证 DPC 密度聚类算法在工业大数据异常检测中的有效性，我进行了一系列实验。实验中，我采用一些经典的数据集（Flame、aggregation）和锅炉数据集作为样本数据，以下是一些实验结果，首先是图 3.2(a)，这是使用 K-means 聚类和层次聚类的对经典数据集的实验结果，从图中可以确切地看出 K-means 聚类方法将一些本属于自己簇中心的的数据点划分给了其他簇团，且聚类中心的数量是人工输入的，在自身的迭代过程中，聚类中心的位置并不准确，簇团的分类也不准确，而且自身并不具有检测出离群点的功能。图 3.2(b)是层次聚类的实验结果，与上同理，同样不具备检测出离群点的功能，在此章节验证完毕，对算法进行舍弃，后文不再赘述。

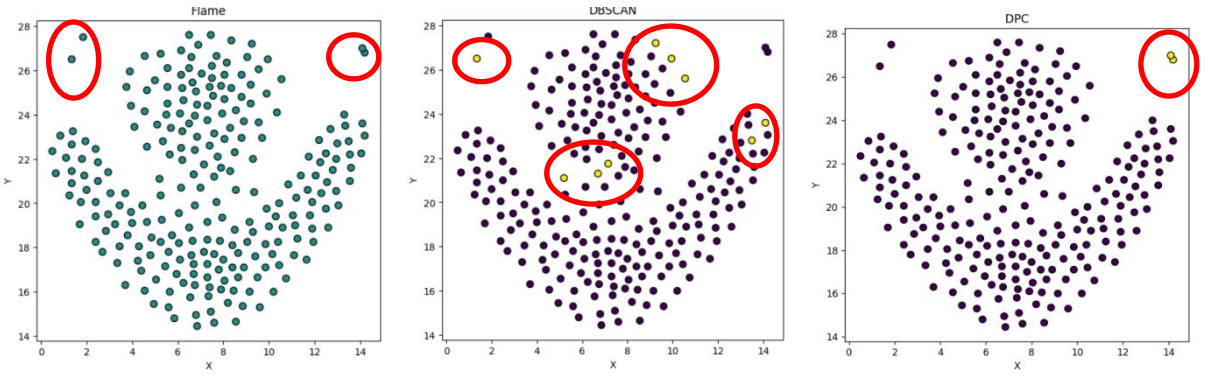


(a) k-means　　(b) 层次聚类

图 3.2 划分聚类和层次聚类 aggregation 数据集示例图

然后对 DPC 和 DBSCAN 这两种不同的密度聚类算法进行数据集实验，先采用人工添加了异常点的 Flame 人工数据集进行聚类效果实验，实验效果对比如下图 3.3 所示：

中国知网 https://www.cnki.net



(a) Flame 样本分布　　(b) DBSCAN　　(c) DPC

图 3.3 人工数据集 Flame 异常检测结果

在上图 3.3 中可以看出，图 3.3(a)是样本数据的分布图，图的左上角和右上角用红圈标记的是人工异常点，图 3.3(b)是 DBSCAN 算法的实验结果图，可以看出 DBSCAN 算法将若干正常数据点错误地归类为异常点，原因是 Flame 数据集中的两个簇团边界太近，两簇团邻近区域的样本密度近似于簇团边缘的密度。在调节 DBSCAN 算法的两个关键参数邻域半径与最小邻域样本数时，很容易产生为了归并簇团的边缘点而调节的参数，会导致一个簇团的点划分到另一个簇团中去的问题，进而导致两个簇团被检测为一个簇团，而为了分离两个不同的邻近簇团，就会把把簇团边缘的正常点检测为异常点。相比较下，图 3.3(c)的 DPC 实验结果图相对令人满意，数据集中的正常点没有出现标记错误的情况，但是左上角的异常点没有检测出来只查出来了右上角的异常点。这是因为左边异常点距离更高局部密度点之间的距离不够远，因此被划为了正常点。图 3.3 经过了多次的调整参数来实验选择的较好实验结果，为了更好的识别出锅炉工业数据集的异常点，本文对 DPC 密度聚类算法进行改进来实现更好的异常点检测效果。

3.3.2 DPC 聚类算法的优化

在数据挖掘和模式识别领域，聚类分析是一种无监督的机器学习方法，旨在将数据集中的样本划分为若干个内部紧密相关的小集群。DPC 聚类算法因其简单高效且无需预先指定小集群数目的特点而受到广泛关注，但在某些情况下对于密度不均匀的数据处理效果不佳，且对参数选择敏感。为了克服这些缺点，本文提出了将 DPC 聚类算法与 KNN(K-Nearest Neighbors)近邻思想相结合的方法，并展示了在实际应用中的案例。

KNN 算法是一种基于实例的学习算法，其核心思想是对于一个给定的查询样本，找出训练集中与其最邻近的 K 个样本，并根据这些近邻样本的类别决定查询样本的类别。

中国知网 https://www.cnki.net

KNN 算法简单直观，适用于分类和回归问题，尤其是在样本分布不均匀或类域交叉较多时仍能保持良好的性能。

由于 DPC 算法本身具有一个缺陷，在 DPC 算法的运算思想中，数据样本点的局部密度需要精确估算，否则会影响异常点的划分与聚类中心的选择，直接影响着最终的聚类效果。然而，在算法流程中，截断距离参数 d_c 需人工预设，受到人为主观的干预。因此要对算法进行优化改进，本文提出一种新的改进方法，那就是将 KNN 近邻思想引入到 DPC 聚类算法中。结合 DPC 和 KNN 的聚类方法首先使用 DPC 算法确定聚类中心，然后利用 KNN 算法为每个非聚类中心的数据点找到其最近的聚类中心，并据此进行小集群簇团划分。这种方法充分发挥了 DPC 算法在识别聚类中心方面的优势，同时利用了 KNN 算法在处理非均匀密度数据时的灵活性，提高了聚类算法的准确性和鲁棒性。为了提高异常点检测的效果，本文致力于研究样本点受其 K 近邻域内点密度的影响，计算截断距离与局部密度所得的数值应适合数据的分布特征。

设 ε_i 为 K-截断距离，中心点 x_i 到其 K 最近邻边缘中最远邻居点的距离称为 k-截断距离。计算如公式(3.4)所示：

$$\varepsilon_i = max\left(D\left(x_i, KNN(x_i,k)\right)\right)，\ \forall \mathrm{x_i} \in \mathrm{X} = \{\mathrm{x_1}, \ldots \mathrm{x_n}\} \tag{3.4}$$

用$\mathrm{KNN_{x_i}}$表示 K 近邻域，其余到中心点 x_i 的距离≤ε_i的点是 x_i 的 K 近邻域点。计算如公式(3.5)所示：

$$KNN_{x_i} = \left\{x_j \middle| d_{ij} \le \varepsilon_i\right\} \tag{3.5}$$

用ρ_i表示样本点局部密度，高斯核函数与 K 近邻的局部密度度量计算如公式(3.6)所示：

$$\rho_i = \sum_{j \in KNN_{x_i}} exp^{-\frac{d_{ij}^2}{d_c^2}} \tag{3.6}$$

截断距离 d_c 取值的计算结合该样本点的 K 近邻域完成，先计算所有样本点 K 近邻域内的平均距离，再计算平均值。这样就会使得样本中密度较小点的 K 近邻域点对其密度贡献变得更小，在样本分布空间不同的数据集处理中，均可自适应的形成 d_c 值。计算如公式(3.7)所示：

中国知网 https://www.cnki.net

$$d_c = \frac{\sum_{i=1}^{N} \frac{\sum_{j \in KNN_{x_i}} d_{ij}}{|KNN_{x_i}|}}{X} \tag{3.7}$$

根据 DPC 算法的相对距离思想，聚类中心和其他高局部密度的样本点距离值应是较远的，为了加强聚类中心与非聚类中心的区别，用下列公式改进样本之间的距离计算量 L，计算如公式（3.8）所示。

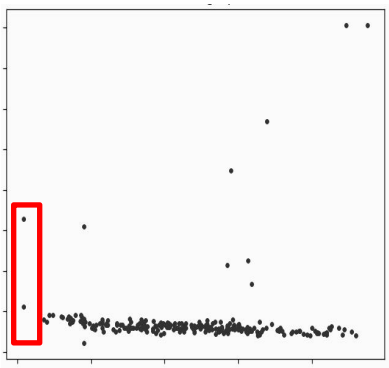
$$L = \delta_i - \varepsilon_i \tag{3.8}$$

原始 DPC 算法依赖距离矩阵和密度计算，无索引优化，时间复杂度是 $O(n^2)$。DBSCAN 算法同样未使用索引结构，直接暴力搜索邻域，因此时间复杂度同样是 $O(n^2)$。DPC 改进算法因引入 k 近邻思想的排序，时间复杂度是 $O(n^2 \log n)$，虽然时间复杂度略有提升，但检测准确率也同样大幅提升，算法的时间复杂度由多个计算阶段构成：计算数据点之间的欧式距离矩阵的时间复杂度是 $O(n^2)$，计算排序和提取第 K 近邻距离的平均距离时间复杂度为 $O(n^2 \log n)$，计算各样本点邻居数量的时间复杂度为 $O(n^2)$，计算局部密度参数的时间复杂度为 $O(n^2)$。

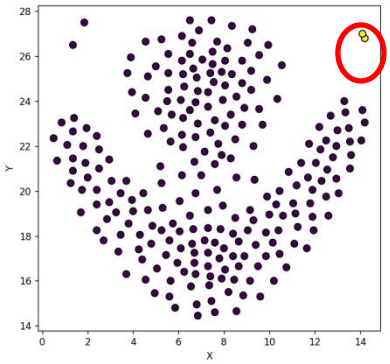
DPC 算法针对不同规模的数据集，需人工选取不同类型的密度度量算法，这些算法的选择往往导致了聚类结果的差异化。采用 K 近邻思想改进局部密度计算技术，该算法适用于不同规模的数据集，有效克服了 DPC 算法的缺点。将 K 近邻思想融入局部密度的计算方法后，仅需计算该样本点 K-截断距离内近邻点的密度贡献，显著降低了计算复杂度。高局部密度点被低局部密度点所包围，局部密度的计算能够更加适合样本的全局与局部分布特征。相较于原算法中的截断距离参数，K 近邻参数 K 的设定更为易于设置，进而提升了算法的效率与鲁棒性。

本文使用结合了基于 KNN 近邻思想的 DPC 改进聚类算法，对人工数据集再加以实验，以下是 DPC 改进聚类算法和 DPC 原始聚类算法的实验对比结果 Flame 聚类结果图 3.4 和 aggregation 聚类结果图 3.5：

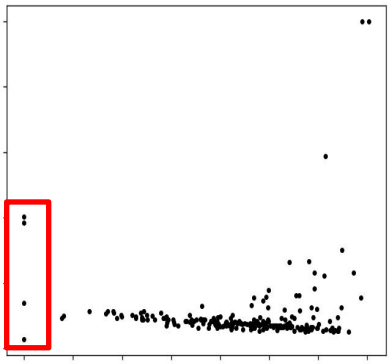
中国知网 https://www.cnki.net



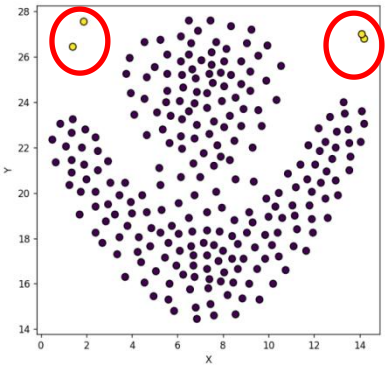
(a) DPC 决策图



(b) DPC



(c) DPC 改进决策图

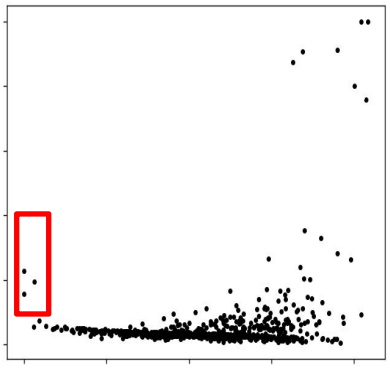


(d) DPC 改进

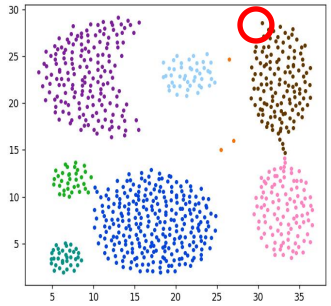
图 3.4 Flame 聚类结果

从上图中，我们可以看到图 3.4(a)左侧有两个异常点，图 3.4(b)的聚类结果中左上角的两个异常点被划分到了上半部分的类簇中。而图 3.4(c)左下角有四个异常点可以被清晰地观察到，再结合图 3.4(d)，可以看到结合了近邻思想的 DPC 改进算法将人工数据集上人为添加的异常点全部都标记了出来，然后是 aggregation 人工数据集的实验：

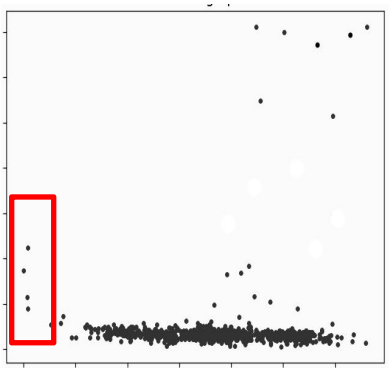
中国知网 https://www.cnki.net



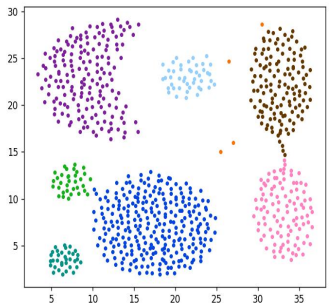
(a) DPC 决策图



(b) DPC



(c) DPC 改进决策图



(d) DPC 改进

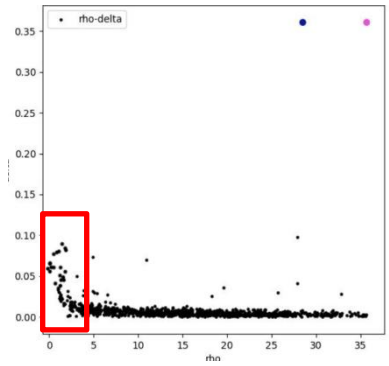
图 3.5 aggregation 聚类结果

由图 3.5(a)和图 3.5(b)分析可以得出 DPC 检测出了 aggregation 人工数据集的 3 个异常点，有一个点没有被检测到，应该是距离右上角的类簇相对距离较近，所以被划为该簇团里了。而图 3.5(c)中可以看到左下角有四个异常点被区分出来，结合图 3.5(d)的 DPC 改进聚类结果图，可以看到 4 个异常点均被检测出来了。对于上面两个实验数据集的对比测试聚类结果，本文验证了 DPC 改进算法在人工数据集上的效果更好。接下来进行工业数据集的实验。

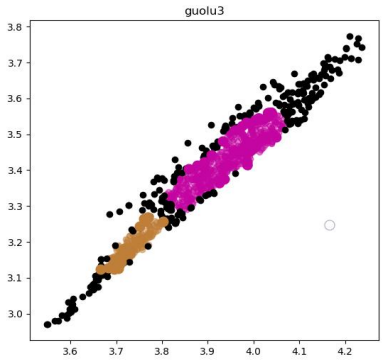
3.3.3 DPC 改进算法工业数据实验

为了进一步验证改进后的 DPC 聚类算法的效果，本文对部分已经训练好打上了标签的锅炉数据集进行试验，以下是锅炉数据集实验的结果图 3.6：

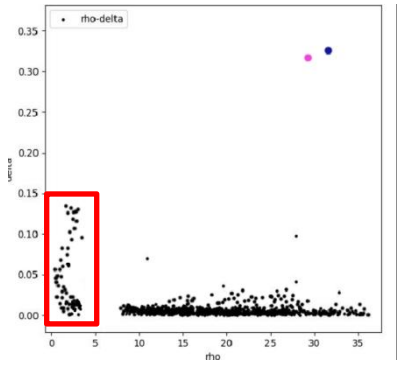
中国知网 https://www.cnki.net



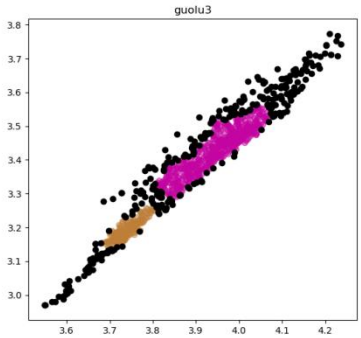
(a) DPC 决策图



(b) DPC



(c) DPC 改进决策图



(d) DPC 改进

图 3.6 guolu_DPC 聚类结果图

从左侧的决策图 3.6(a)和图 3.6(c)可以看到 DPC 算法改进前后的决策图左下角异常点的区分度提升了。但是单凭人工用肉眼从图 3.6(b)和图 3.6(d)的聚类实验结果图中看不出什很大的差异，于是为了加以验证改进的 DPC 聚类算法是否对实验数据结果有所提升，本文引入轮廓系数[59](Silhouette Coefficient)、检测率[60]两个指标来体现出两种算法的聚类效果具体情况：

轮廓系数：衡量聚类算法性能的一种标准，判断聚类结果的紧致性与离散度。该标准综合了簇团内点的紧密程度和点与其他簇团的分离程度，其数值范围为[-1,1]。轮廓系数由以下公式(3.9)给出：

$$\& = (b-a)/\max(a,b) \tag{3.9}$$

计算该数据点与同簇其他点的平均距离，记为 a(簇内紧密度)。对于与该数据点属于不同簇的所有邻近簇，计算该数据点与这些邻近簇中所有点的平均距离，找到其中最小的一个值，记为 b(与其他簇的分离度)。

根据轮廓系数的取值范围，可以对聚类结果进行评估：如果轮廓系数接近于 1，表示样本在自己的簇中更加紧密，并且与其他簇分离较好。如果轮廓系数接近于 0，表示

中国知网 https://www.cnki.net

样本在自己的簇中紧密度和分离度相对均匀或存在重叠。当轮廓系数趋近于-1 时，表明样本点被归入错误簇团的可能性增大。计算所有数据点轮廓系数的平均值，将其作为评估聚类算法整体性能的指标。轮廓系数的锅炉数据集实验结果示例图如下图 3.7 所示：

```
Get dc
dc:  0.016373748671475345
Get rho
Get delta
Assign
Get halo
guolu3_DPC聚类,轮廓系数为0.6131699301803955
```

图 3.7 guolu_DPC 轮廓系数图

检测率：为了检测离群点是否被正确的标记，引入检测率(Detection Rate)概念，其计算公式(3.10)如下：

$$Detection\ Rate = \frac{W}{Z} = \frac{W}{W+N} \tag{3.10}$$

其中 W 表示将离群点成功的标记出来的量，Z 表示离群点总量，N 表示将离群点标记为正常点的量，检测率越高表明算法的效果越好。下表 3.3 是异常点检测结果的部分输出表，从中可以看出最右列的离群异常点被成功检测后会被统一打上-1 的标签便于和正常点区分，可以对检测率的结果进行验证。

表 3.3 部分异常点输出表

x	y	num	聚类结果
7.8	13.7	2	-1
8.85	13.35	2	-1
9	12.7	2	-1
9.7	12.1	2	-1
8.05	12.9	2	-1
7.7	13.25	2	-1
6.8	13.2	2	-1
6.6	6.2	2	-1
5.4	12.85	2	-1
5.7	12.25	2	-1

中国知网 https://www.cnki.net

基于上述的结论，制作一个简易的对比表对实验结果进行分析，如下表 3.4 锅炉数据集对比表所示。通过比较，我们发现在锅炉数据集上 DPC 改进后的算法在轮廓系数和检测率方面相较于原始 DPC 算法均表现出较好的性能。

表 3.4 锅炉数据集对比表

	DPC(K 近邻改进)	DPC
轮廓系数	0.6131699301803955	0.5005098312221726
检测率	0.84	0.79

3.4 本章小结

针对工业流程中的生产安全方面，本章节对异常检测算法的优势和不足做了探讨和研究，选择了基于聚类的异常检测方法，又在聚类算法中进行探究，通过分析与比较，选择密度峰值聚类算法。继而根据上述研究提出了一种从历史中吸取教训的措施，提出采用无监督聚类算法来检测工业生产流程中所产生危险信号。针对工业流程中的生产安全方面，该措施通过 DPC 密度峰值聚类算法对历史数据进行异常点检测来实现，其中通过理论和实验两方面进行的双重分析，首先排除了基于距离的聚类算法和层次聚类算法。然后分别用 DPC 和 DBSCAN 两种密度聚类算法测试经典数据集进行仿真实验，并对实验结果进行对比。

通过对实验结果的具体分析，表明 DPC 算法具有更好的性能，能够更方便准确的用于数据集的离群点检测。

然后，根据 DPC 运算流程中截断距离的人为主观选择对异常检测效果的影响，以及在处理样本点分布不一致的数据集时得到的决策图中无法选取异常点的问题，本文根据 DPC 密度峰值聚类算法运算流程的核心设定，融入了 K 近邻思想，实现了截断距离的自动生成，该改进有效减少了由于截断距离的主观选择对聚类结果的影响，并使新的局部密度能更精确地映射出数据点分布的实际特征。本文通过在训练好的锅炉数据集上开展实验，并将实验结果与原始 DPC 算法的实验结果进行对比分析，进一步验证了该改进方法的有效性。同时引入轮廓系数和检测率这两种评价指标来验证实验的准确性。实验结果表明，结合了 K 近邻思想改进后的 DPC 算法的性能优于原 DPC 算法，并且同时避免了截断距离参数需要基于大量的实验作为参考才能选取的困难问题。

中国知网 https://www.cnki.net

第四章　基于 FP-Growth 的关联链发现算法研究

4.1 引言

基于前面几章节的研究，本文对锅炉数据进行了预处理，整理得到了锅炉数据集，然后采用了改进的 DPC 聚类算法对数据集进行聚类分析，并有效识别并标记出异常数据点。现在本文需要进一步深入挖掘分析聚类结果的关联规则，找到锅炉工业生产状态各环节之间的深层次联系。然而，想要精确提炼锅炉生产流程中各环节的关联规则，适宜锅炉工业生产流程对象的特征，需要挖掘的关联规则生产环节的数目一直是该领域企业的难题。挖掘过多环节之间的关联规则非但不能有效体现其实用价值，反而会导致挖掘过程耗时的大幅上升。

本章是对锅炉工业生产流程中的各个生产环节进行数据关联分析，挖掘其内在关联性。在此过程中，需应对以下核心难题：一是聚类结果数据量庞大，需要一个高效的关联规则算法来计算锅炉工业生产流程中的各个生产环节环节之间的关联规则；二是对锅炉工业生产流程对象中的所有环节进行关联规则挖掘，效率过于低下，运算时间太长，甚至有计算机内存不够炸栈的危险。在锅炉工业流程对象中，生产环节的变化影响是线性的，生产环节产生的变化会影响另一个生产环节，例如主汽温度(温度升高)会影响主汽压力左(压力增大)，主汽压力左(压力增大)影响主蒸汽流量(蒸汽流量增大)，进而产生连锁反应变化。鉴于锅炉工业生产流程中包含众多生产环节，本文采用了基于 FP-Growth 的 2 项频繁项集关联规则算法，通过该关联规则算法的计算，推导各双环节间关联规则的紧密程度，并依此类推，逐步构建出各环节间的关联度矩阵，最终归纳并提炼出各环节的核心关联链。

4.2 FP-Growth 关联规则算法

FP-Growth 关联规则算法可以发现大规模数据集中的频繁项集，它是由 Jiawei Han 等人在 2000 年提出的一种高效的关联规则算法。该算法的核心思想是利用频繁项集的子集也是频繁的性质，通过递归的方式大幅度减少候选项集的数量，从而高效地挖掘出频繁项集。该关联规则算法有以下几个内部概念：

(1) 项(Item)：数据集中的一个元素，通常表示为一个属性值对。

中国知网 https://www.cnki.net

(2) 项集(Itemset)：多个项的集合，每个项由一个或多个属性值对组成。

(3) 支持度(Support)：项集在数据集中出现的频率。

(4) 频繁项集(Frequent Itemset)：支持度大于等于最小支持度阈值的项集。

(5) 关联规则(Association Rule)：形如 A→B 的内部关联关系，A 和 B 是两个无交集的项集，关联规则表示如果项集 A 出现，那么项集 B 也可能出现。

FP-Growth 关联规则算法的运行逻辑包含以下 3 个步骤：

1、构建 FP 树：首先，该算法需要扫描数据集，得到所有单个项的支持度，并按照支持度降序排列。然后再次扫描数据集，对于每个事务，按照支持度排序后的结果构建一棵 FP 树。用 FP 树的数据结构来压缩数据，将相似的事务归并到一起，提高关联规则挖掘的效率。

2、挖掘频繁项集：挖掘频繁项集的过程分为两个主要阶段。首先是构造条件模式基(conditional pattern base)，条件模式基是指以某个频繁项集的节点为根节点的子树所对应的所有路径所构成的集合。具体来说，在 FP 树中，以某个频繁项集的节点为根节点的子树，可以看作是该频繁项集的条件模式基。在构建过程中，得到与该节点对应的所有前缀路径。这些前缀路径又构成了条件模式基，它反映了包含某个频繁项集的所有事务的结构信息。对于 FP 树中的每个节点，算法需要沿着 FP 树中每个频繁项集的节点向上回溯，得到一个条件模式基。然后是递归挖掘，对于每个条件模式基，该规则算法构造一个新的 FP 树，然后在该新树上重复上述过程，直到不能再找到频繁项集为止，并根据出现频率浮动设定阈值大小，这样，我们就可以找到所有频繁项集。

3、生成关联规则：在挖掘到的频繁项集基础上，能够得出相应的关联规则。针对任一频繁项集，构建其全部可能存在的非空真子集，并将此类子集视作前件 A，剩下的部分作为后件 B。然后，我们计算每条规则的置信度和支持度。置信度表示在前件 A 的条件下，后件 B 也会发生的概率有多大。满足算法设定的最小置信度阈值的规则即为所求的关联规则，这些关联规则可以帮助用户理解数据集中的关联关系。

4.3 基于 2 项频繁项集的 FP-Growth 关联规则算法

本文对于锅炉工业生产流程对象中各个环节之间的关联规则分析问题，采取任意两个环节之间进行关联规则分析的方法，对 FP-Growth 关联规则算法进行基于 2 项频繁项集运算规则的优化，提高 FP-Growth 关联规则算法在高维数据集中运行效率和应用效果。

本文以锅炉数据集为例，每一条锅炉状态数据代表着一个事务 $X = \{x_1, x_2, ..., x_z,\}$，

中国知网 https://www.cnki.net

锅炉的全部事务计数为 N。本文对聚类结果数据集中的任意两个环节的聚类数据，进行基于 FP-Growth 关联规则算法的 2 维度挖掘，挖掘任意两个环节之间的关联规则，搜索任意的两环节之间的 2 项频繁项集，进而生成任意两环节聚类结果间的 2 项频繁项集关联规则，同时引入支持度(Support)和置信度(Confidence)这两个概念。

支持度是指某个项集在数据集中出现的频率，即该项集出现在所有事务中的比例。支持度反映了一个项集的普遍程度，支持度越高表示该项集出现几率越大，一般设置一个浮动的阈值基于 0.1%到 2%之间，具体根据一线工人的反馈调整。支持度可以用来衡量一个项集是否频繁，通常使用支持度作为挖掘频繁项集的标准。支持度的定义如公式 4.1 所示：

$$Support = \frac{I(A,B)}{ALL} = \frac{I(A,B)}{N} \tag{4.1}$$

置信度是条件概率的一种度量，表示在 A 先验前提条件成立的情况下，后者 B 也会发生的概率。在关联规则中，置信度是衡量关联规则可信程度和精确度的指标。对于对于一条关联规则 A 到 B，置信度体现为在所有 A 与 B 共存的事务中，该类事务占所有包含 A 事务总数的比例。相应地，对于另一条关联规则 B 到 A，置信度则体现为在所有 B 与 A 共存事务中，该类事务占所有包含 B 事务总数的比例。因此，置信度可以帮助我们评估关联规则的强度，即前件和后件之间的关联程度，由于是出于对工业生产流程中安全性的考虑，操作员建议阈值设定为 70%以上，然后根据锅炉运行状态和一线工人的经验反馈浮动调整。置信度的定义如公式 4.2 所示：

$$Confidence = \frac{I(A,B)}{I(A)} \tag{4.2}$$

由此，我们可以发现，支持度和置信度两者在理论上可以互补结合，支持度衡量了一个项集在数据集中的普遍程度，用于挖掘频繁项集。而置信度衡量了两个项集之间的关联程度，用于评估关联规则的质量。

4.4 环节间关联规则获取关联链

假设得到的两个环节聚类之间关联规则示例如下表 4.1 所示：

表 4.1 关联规则示例表

编号	前项	后项
1	X1 环节 k1 簇	X2 环节 k1 簇

中国知网 https://www.cnki.net

2	X1 环节 k1 簇	X2 环节 k2 簇
3	X2 环节 k2 簇	X1 环节 k1 簇

其中，以 X1 为前项、X2 为后项的所有聚类数据集共产生 2 条聚类关联规则，以 X2 为前项、X1 为后项的所有聚类数据集共产生 1 条聚类关联规则。为了更好的反映出簇类间关联规则的影响，引入了增长度(Lift Rate)的概念，其定义公式 4.3 如下：

$$Lift = \frac{\frac{I(A,B)}{N}}{\frac{I(A)}{N} \times \frac{I(B)}{N}} \tag{4.3}$$

以第一条关联规则 X1 环节 k1 簇到 X2 环节 k2 簇 为例，前项记为 A，后项记为 B。如果增长度 Lift(A,B)等于 1，那么 A 和 B 是相互独立的。如果大于 1，则 A 和 B 两者是正相关并且它们的变动方向具有一致性。如果小于 1，则 A 和 B 两者是负相关变动方向具有相反性。

接下来需要根据任意两个环节聚类数据之间产生的关联规则出现的频率来计算得到任意两个环节之间整体的关联度。因为任何变量与自己的关联总是完美的。所以与自己关联时关联度设置为 1。若两环节间的关联度未达到预设的最小关联度阈值时，将其关联度设置为-2，并在构建关联链时剔除，表明二者没有关联关系。据此，构建出一个各环节间的关联度表，如图 4.1 所示：

	x1	x2	x3	x4	x5	x6	x7	x8	x9	x10	x11	x12	x13	x14	x15	x16	x17
x1	1	0.963919	0.330849	0.031291	0.040825	8.63E-06	-0.06903	-0.14015	-0.12997	-0.02982	0.170884	0.198543	0.374528	0.385387	0.109421	-0.09186	-0.13641
x2	0.963919	1	0.333731	-0.23139	-0.01262	0.033266	0.061135	-0.2294	-0.2117	-0.22066	-0.04168	-0.01694	0.325753	0.319135	0.240096	-0.20774	-0.26415
x3	0.330849	0.333731	1	-0.09129	-0.03951	0.054581	-0.26001	-0.12961	-0.11976	-0.17163	0.366449	0.398462	0.556918	0.590367	0.173997	-0.14581	-0.1418
x4	0.031291	-0.23139	-0.09129	1	0.108084	-0.05962	-0.42637	0.278087	0.246863	0.708841	0.756118	0.756328	0.131309	0.188409	-0.45841	0.446499	0.411301
x5	-2	-2	-2	-2	1	-2	-2	-2	-2	-2	-2	-2	-2	-2	-2	-2	-2
x6	8.63E-06	0.033266	0.054581	-0.05962	-0.57499	1	0.148423	-0.03847	-0.04833	-0.1057	-0.10859	-0.07239	-0.08209	-0.07738	0.038587	0.088008	-0.06636
x7	-0.06903	0.061135	-0.26001	-0.42637	-0.14733	0.148423	1	-0.10447	-0.08212	-0.39639	-0.71307	-0.67125	-0.48095	-0.50042	0.108201	0.285299	-0.24698
x8	-0.14015	-0.2294	-0.12961	0.278087	-0.03948	-0.03847	-0.10447	1	0.991887	0.206512	0.121647	0.197118	-0.29271	-0.21436	-0.69327	0.336177	0.966974
x9	-2	-2	-2	-2	1	-2	-2	-2	1	-2	-2	-2	-2	-2	-2	-2	-2
x10	-0.02982	-0.22066	-0.17163	0.708841	0.079263	-0.1057	-0.39639	0.206512	0.233354	1	0.580105	0.537252	0.030787	0.067519	-0.39234	0.208678	0.377464
x11	0.170884	-0.04168	0.366449	0.756118	0.165106	-0.10859	-0.71307	0.121647	0.101491	0.580105	1	0.949416	0.616164	0.669447	-0.24627	0.134444	0.256977
x12	0.198543	-0.01694	0.398462	0.756328	0.138496	-0.07239	-0.67125	0.197118	0.170315	0.537252	0.949416	1	0.585284	0.650899	-0.28009	0.183131	0.325476
x13	0.374528	0.325753	0.556918	0.131309	0.164358	-0.08209	-0.48095	-0.29271	-0.28711	0.030787	0.616164	0.585284	1	0.986578	0.300290	-0.37147	-0.24223
x14	0.385387	0.319135	0.590367	0.188409	0.170011	-0.07738	-0.50042	-0.21436	-0.21014	0.067519	0.669447	0.650899	0.986578	1	0.225682	-0.31536	-0.16035
x15	0.109421	0.240096	0.173997	-0.45841	-0.01503	0.038587	0.108201	-0.69327	-0.67819	-0.39234	-0.24627	-0.28009	0.300290	0.225682	1	-0.42805	-0.71920
x16	-0.09186	-0.20774	-0.14581	0.446499	-0.03036	0.088008	0.285299	0.336177	0.324671	0.208678	0.134444	0.183131	-0.37147	-0.31536	-0.42805	1	0.349207
x17	-0.13641	-0.26415	-0.1418	0.411301	-0.00398	-0.06636	-0.24698	0.966974	0.950866	0.377464	0.256977	0.325476	-0.24223	-0.16035	-0.71920	0.349207	1

图 4.1 筛选后的关联度表

图中每一行数据反映的是左侧环节与其他各环节之间的关联度，例如第一行数据，表示的是 X1 环节与 X2，X3 等环节之间的关联度大小。

对于本文研究的锅炉工业生产流程对象来说，从一个环节到最后一个环节按环节影响关系进行串联的这种关联度形式记做关联链。各环节间的相互衔接应构成一条单向无环的链式架构，此架构中无任何冗余的流程节点，此特征恰如锅炉工业生产流程中某一运作状态的象征。现已经得到任意两环节间的关联规则和关联度，根据环节间关联度表，然后结合本文锅炉数据预处理的研究中对环节间时序关系进行调整得到的时序数据，保

中国知网 https://www.cnki.net

证了同一时刻环节之间数据是同一影响状态的，最终选取并筛选出关联度最大的环节进行连接来生成最强关联链。

构建关联链的过程是自某一个环节 A 起，查找与环节 A 关联度最高的另一个环节 B（环节 B 在初始状态下不在该关联链中）。一旦确定符合条件的环节 B，即将其纳入关联链中，并继续查找与环节 B 关联最高的新环节 C，重复这个步骤直至关联度降至预设阈值之下结束，最终形成一条以环节 A 为起始点的完整关联链。下图 4.2 是各环节所生成的最强关联链示例图。

Starting from x1: x1 -> x2 -> X3 -> X14 -> X13 -> X11 -> X12 -> X3 -> X10 -> X17 -> X8 -> X9
Starting from x2: x2 -> x1 -> X14 -> X13 -> X11 -> X12 -> X3 -> X10 -> X17 -> X8 -> X9 -> X16
Starting from x3: X3 -> X14 -> X13 -> X11 -> X12 -> X3 -> X10 -> X17 -> X8 -> X9 -> X16 -> X7
Starting from X3: X3 -> X12 -> X11 -> X14 -> X13 -> X3 -> x2 -> x1 -> X15 -> X7 -> X16 -> X17
Starting from X5:
Starting from X6: X6 -> X7 -> X16 -> X3 -> X12 -> X11 -> X14 -> X13 -> X3 -> x2 -> x1 -> X15
Starting from X7: X7 -> X16 -> X3 -> X12 -> X11 -> X14 -> X13 -> X3 -> x2 -> x1 -> X15 -> X6
Starting from X8: X8 -> X9 -> X17 -> X3 -> X12 -> X11 -> X14 -> X13 -> X3 -> x2 -> x1 -> X15
Starting from X9:
Starting from X10: X10 -> X3 -> X12 -> X11 -> X14 -> X13 -> X3 -> x2 -> x1 -> X15 -> X7 -> X16
Starting from X11: X11 -> X12 -> X3 -> X10 -> X17 -> X8 -> X9 -> X16 -> X7 -> X6 -> X3 -> X14
Starting from X12: X12 -> X11 -> X3 -> X10 -> X17 -> X8 -> X9 -> X16 -> X7 -> X6 -> X3 -> X14
Starting from X13: X13 -> X14 -> X11 -> X12 -> X3 -> X10 -> X17 -> X8 -> X9 -> X16 -> X7 -> X6
Starting from X14: X14 -> X13 -> X11 -> X12 -> X3 -> X10 -> X17 -> X8 -> X9 -> X16 -> X7 -> X6
Starting from X15: X15 -> X13 -> X14 -> X11 -> X12 -> X3 -> X10 -> X17 -> X8 -> X9 -> X16 -> X7
Starting from X16: X16 -> X3 -> X12 -> X11 -> X14 -> X13 -> X3 -> x2 -> x1 -> X15 -> X7 -> X6
Starting from X17: X17 -> X8 -> X9 -> X16 -> X3 -> X12 -> X11 -> X14 -> X13 -> X3 -> x2 -> x1

图 4.2 各环节关联链

其中左侧的第一个环节是，依次串联到右侧的尾环节。X5 与 X9 两个环节因与其他环节的关联度过低，没有生成关联链。其余环节则依据各环节之间的关联度大小，依次进行串联生成的关联链。上图中以 X10 环节为首环节的关联链为 X10→X3→X12→X11→X14→X13→X3→X2→X1→X15→X7→X16。

4.5 本章小结

本章主要介绍了锅炉工业生产流程对象中各个环节关联规则的挖掘过程，实现对锅炉各个环节之间的关联分析，生成关联链。本文采用了基于 FP-Growth 的 2 项频繁项集关联规则算法，关联规则只挖掘到 2 项，由此可以显著的提高挖掘效率，缩短挖掘时间。采用此方法挖掘任意两个环节的关联规则，然后定义基于计算关联度的方法，得到任意两环节之间的关联度，并据此构建关联度矩阵，形成关联度表，最终根据关联度大小，最终依据关联度的大小差异，单向串联形成各环节的关联链。现在有了锅炉数据集、聚类结果、聚类异常点、关联链，为下一章节打好了基础，可以实现系统的相应功能了。

中国知网 https://www.cnki.net

中国知网 https://www.cnki.net

第五章　基于无监督学习的工业数据故障检测系统研发与实现

锅炉工业生产流程是一个复杂且体系完备的工业体系，涉及众多工序生产环节。以热电厂的燃煤锅炉生产流程为例，其起始于给煤机的启动与运作，持续将煤粉输送至锅炉炉膛燃烧，炉膛内燃烧的程度则凭借送风机调节风速来实现精细控制。燃烧所释放的热量会加热汽包内水体，使之沸腾并大量转化为水蒸气，这些水蒸气驱动汽轮机旋转，进而驱动发电机发电，这就是燃煤锅炉热电厂电力输出的基本原理。该生产流程由多个环节设备及其搭载的系统协同完成，因此锅炉生产流程的稳定运行与安全保障需要综合多方面因素考虑。通过与一线操作人员的交流得知，工人们大多数情况下是凭借长期积累的实践经验和当前锅炉运行状态来调整设备参数，这表明锅炉工业生产流程中的安全性还需进一步提高。人工调节的是当时的锅炉生产状态，使其从异常状态变为正常状态，那么已经发生的锅炉异常状态或多或少会被遗漏，这些异常状态的发生会埋下非常严重的内在安全隐患。本文设计的基于无监督学习的工业数据故障检测系统，对锅炉工业生产流程中采集到的历史数据集进行研究，通过分析往年采集到的历史数据，来判断当时锅炉是否发生过的异常状态，能针对采集到的锅炉工业历史数据进行知识挖掘，挖掘出历史数据中的异常点，来推断当时锅炉的生产状态是否出现了异常，进而分析异常发生的原因，让工人可以及时排查内在的安全隐患，进而为未来的安全生产扫除内在隐患。

5.1 系统的开发环境与系统概述

基于无监督学习的工业数据故障检测系统的开发工具使用了 pycharm，数据库使用 SQL Server 2012。下表 5.1 是系统的开发调试环境。

表 5.1 开发、调试环境

名称	版本
操作系统及系统配置	Windows 10 64bit， b97 Processor CPU @ 3.20GHz, 8GB RAM
开发工具	Pycharm
编程语言	Python372
数据库	SQL Server 2012
联网方式	局域网连接

本文系统的设计拥有原始数据预处理、聚类算法对数据集聚类分析和关联规则算法生成关联链等过程。锅炉在生产流程中产生了海量的历史数据，这些数据通常具有以下特征：规模大、无标签、缺乏属性特征，生成速度快、具备一定的历史参考价值。本文

中国知网 https://www.cnki.net

对系统的研究与应用，旨在为锅炉操作的专业人员提供一个更加安全的锅炉设备针对性检查的方法，及时从历史数据中发现发生设备故障的时间点，对相应的生产流程环节进行排障，提高锅炉生产流程中的安全性。本系统已经在济南某热电厂进行了部署使用，目前用户反馈良好。

在锅炉数据的存档中进行信息采集，鉴于热电厂锅炉系统尚未部署统一标准的计算机类型数据库，没有实现规范化数字存储功能，因此所采集的数据文件不能直接使用。针对热电厂现存的老旧数据存储系统体系，需要对历史数据进行人工批量采集。数据预处理流程细节见下图 5.1。

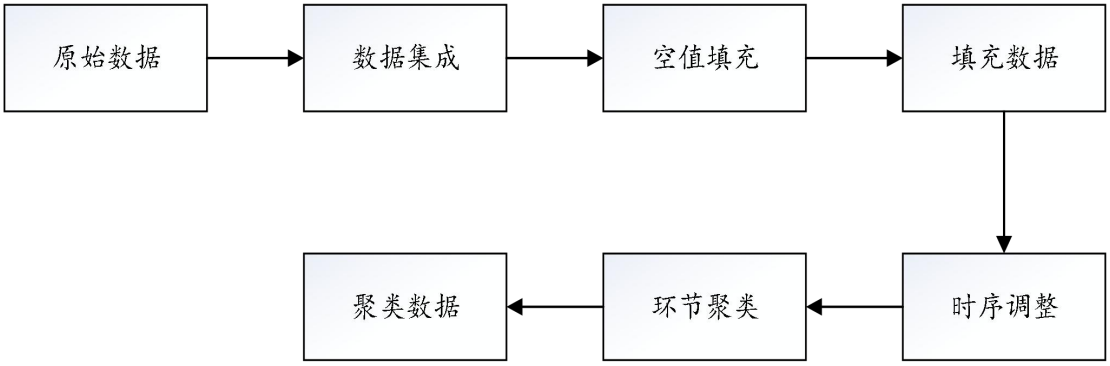


图 5.1 数据预处理流程图

使用人工来采集离散数据并进行汇总整合与初步处理，运用空值填充技术对缺失数据进行补充，然后进行时序校正，对锅炉生产流程中各环节间的时序先后影响关系进行发现。环节聚类分析则是对单个生产环节实施聚类的一个步骤，本文采用 DPC 改进的密度峰值聚类算法，对预处理数据进行聚类分析，找出其中的异常点，从而进行锅炉生产状态的故障检测，实现对工业数据故障检测的数据异常处理功能。

在后续的关联规则挖掘中，本文依据数据集的特性，采用了高效的 2 项频繁项集 FP-Growth 关联规则算法，深入挖掘各环节间的潜在关联关系。通过运用关联规则算法计算每两个环节之间的关联关系，得到生产流程中环节之间的关联规则。随后根据关联度生成关联链结果，便可以很方便的进行锅炉设备发生异常状态时锅炉生产状态工况环节的分析，对异常点产生的原因进行追溯和推导，以下是关联链的发现和获取流程图 5.2：

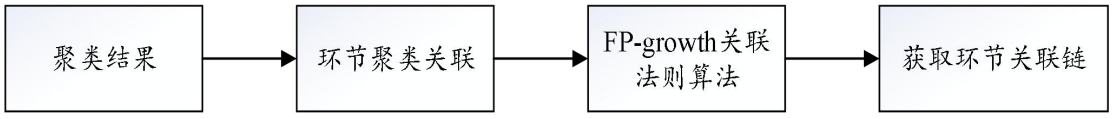


图 5.2 关联链的发现和获取流程图

中国知网 https://www.cnki.net

本系统针对上述流程中聚类得到的异常点结果和锅炉生产流程环节关联链进行结合，通过代入异常点进入到关联链的相应环节之中来对异常点进行分析，推断造成异常的原因，最终研发出基于无监督学习的工业数据故障检测系统。

5.2 系统流程图

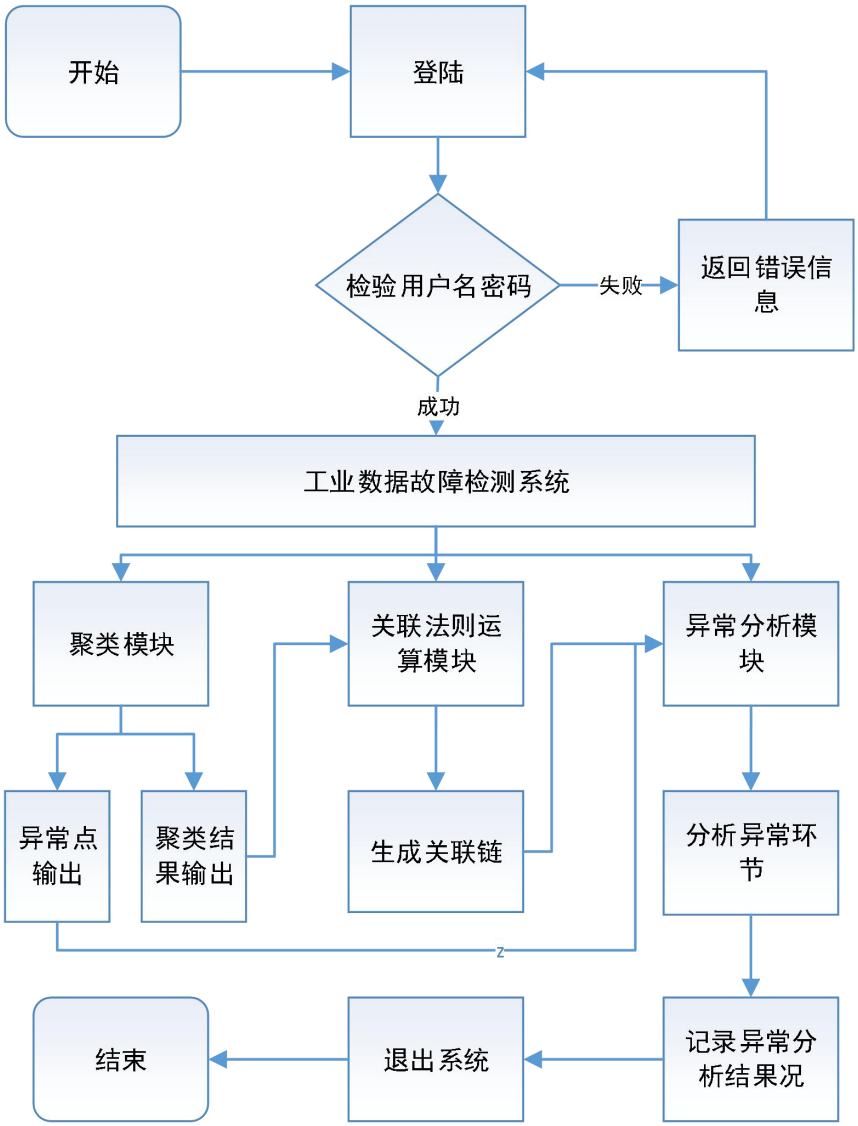


图 5.3 工业数据故障检测系统流程图

依据图 5.3 中的系统流程，用户输入正确的用户名和密码，使用客户端登录系统。然后开始将数据集的导入系统，系统对数据集进行聚类分析，得到异常点和聚类结果，之后再对聚类结果进行关联规则算法挖掘，得到当时锅炉工业生产流程的运作状态，将异常点与关联链相结合，分析异常点发生的原因，然后反馈给一线工人检查相应的生产环节查看是否存有安全隐患，分析完毕后退出系统。

中国知网 https://www.cnki.net

5.3 系统功能分析

基于无监督的工业数据故障检测系统在 python 的环境下，搭建开发了。该系统主要由异常检测功能和异常分析功能组成。根据工业数据故障检测系统系统的功能需求，可将该系统分为四个功能模块，具体的功能模块图如下图 5.4 所示。

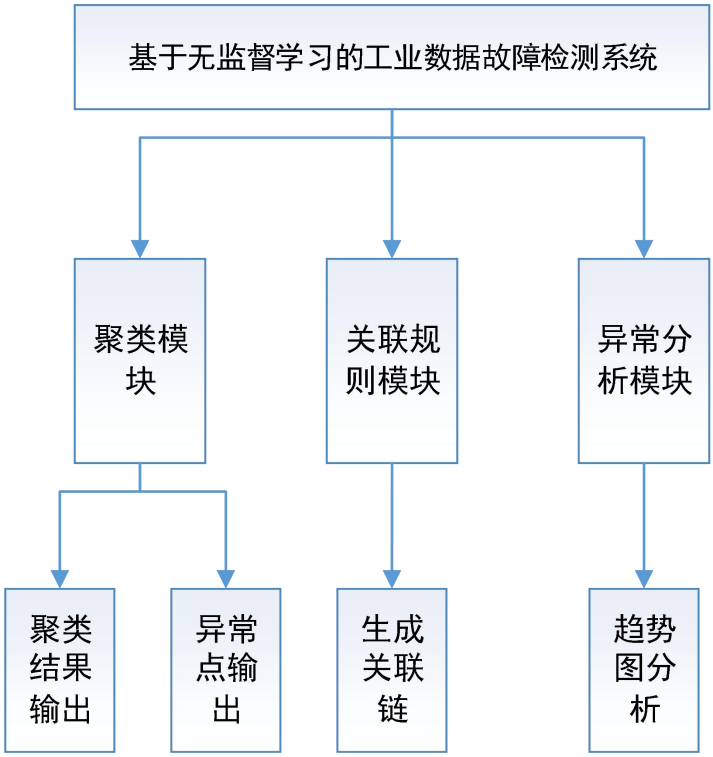


图 5.4 工业数据故障检测系统功能模块图

基于无监督学习的工业数据故障检测系统全程使用 python 语言进行开发，用户进入系统客户端后输入用户名密码进入操作界面，下图 5.5 是客户端登陆界面的截图。

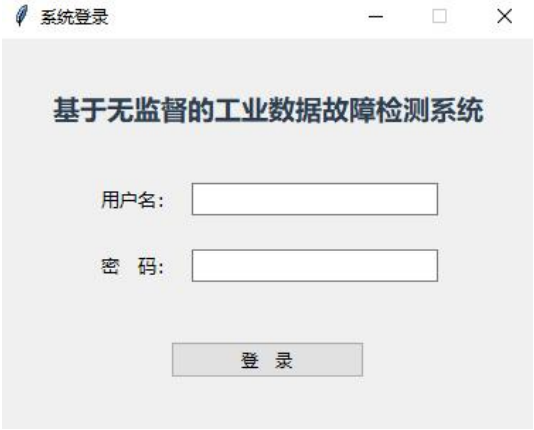
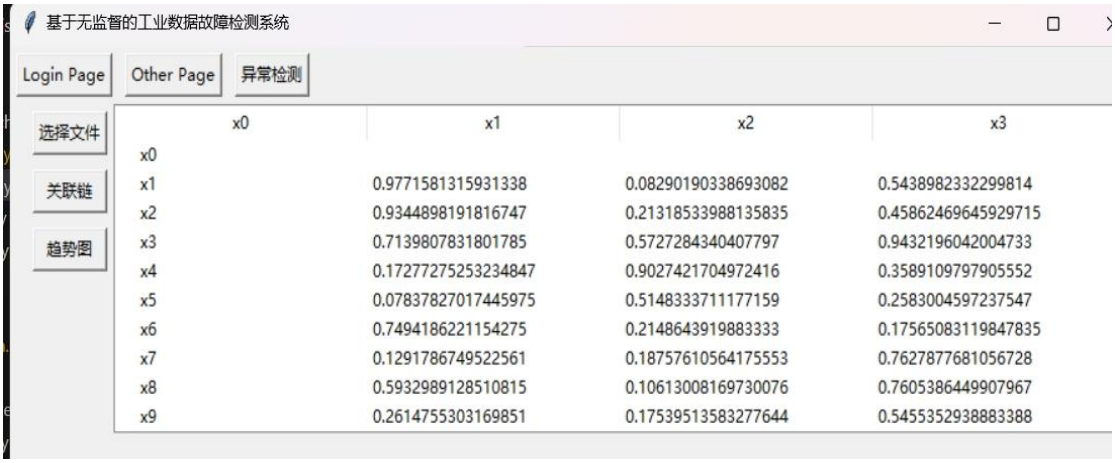


图 5.5 客户端登陆界面图

中国知网 https://www.cnki.net

5.3.1 聚类模块

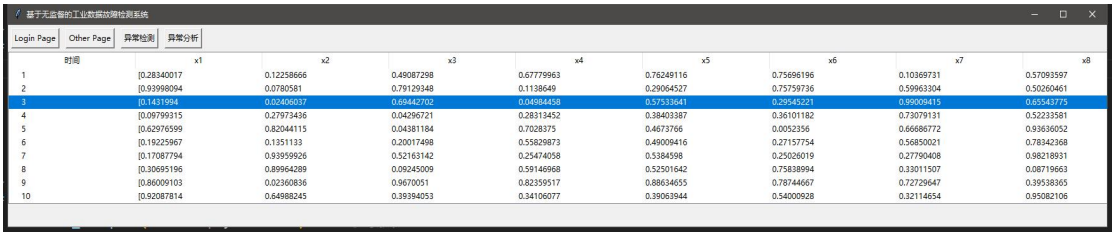
用户登录后进入如图 5.6 所示数据集文件选择界面，该界面即是异常检测的第一个功能。选择数据集后，可视化窗口会显示数据集里面的内容。



	x0	x1	x2	x3
x0				
x1		0.9771581315931338	0.08290190338693082	0.5438982332299814
x2		0.9344898191816747	0.21318533988135835	0.45862469645929715
x3		0.7139807831801785	0.5727284340407797	0.9432196042004733
x4		0.17277275253234847	0.9027421704972416	0.3589109797905552
x5		0.07837827017445975	0.5148333711177159	0.2583004597237547
x6		0.7494186221154275	0.2148643919883333	0.17565083119847835
x7		0.1291786749522561	0.18757610564175553	0.7627877681056728
x8		0.5932989128510815	0.10613008169730076	0.7605386449907967
x9		0.2614755303169851	0.17539513583277644	0.5455352938883388

图 5.6 锅炉数据集选择界面

之后点击异常检测按钮，系统后台进行聚类分析，完成后跳转进入新的界面，在下图 5.7 的可视化窗口中显示聚类的结果：



时间	x1	x2	x3	x4	x5	x6	x7	x8
1	[0.28340017	0.12258666	0.49087298	0.67779963	0.76249116	0.75696196	0.10369731	0.57093597
2	[0.93998094	0.0780581	0.79129348	0.1138649	0.29064527	0.75759736	0.59963304	0.50260461
3	[0.1431994	0.02406037	0.69442702	0.04984458	0.57533641	0.29545221	0.99009415	0.65543775
4	[0.09799315	0.27973436	0.04296721	0.28313452	0.38403387	0.36101182	0.73079131	0.52233581
5	[0.62976599	0.82044115	0.04381184	0.7028375	0.4673766	0.0052356	0.66686772	0.93636052
6	[0.19225967	0.1351133	0.20017498	0.55829873	0.49009416	0.27157754	0.56850021	0.78342368
7	[0.17087794	0.93959926	0.52163142	0.25474058	0.5384598	0.25026019	0.27790408	0.98218931
8	[0.30695196	0.89964289	0.09245009	0.59146968	0.52501642	0.75838994	0.33011507	0.08719663
9	[0.86009103	0.02360836	0.9670051	0.82359517	0.88634655	0.78744667	0.72729647	0.39538365
10	[0.92087814	0.64988245	0.39394053	0.34106077	0.39063944	0.54000928	0.32114654	0.95082106

图 5.7 聚类算法得到聚类结果的界面

运行完毕后会得到生成聚类的结果，将其显示在可视化窗口上，同时也得到了异常点结果，会在第三个功能模块异常分析中调用，在后续文章中再进行讲述。聚类功能模块结束，然后进入下一个关联规则模块功能模块。

5.3.2 关联规则功能模块

系统目前已经得到上一个聚类分析功能模块的聚类结果，现进入关联规则分析功能模块，该功能模块使用关联规则算法对聚类结果进行关联规则分析，如下图 5.8 所示。系统后台运行 FP-Growth 关联规则算法，分析聚类结果，挖掘任两环节的关联性。通过第四章的研究，将各环节以单向链路的形式串联，生成锅炉工业生产流程各环节间的关联链，生成的关联链结果显示在可视化窗口中。

中国知网 https://www.cnki.net



图 5.8 关联规则获取关联链界面

至此，关联规则功能模块结束，系统现在已经有了聚类功能模块的异常点、聚类结果，还得到了锅炉工业生产流程的生产状态关联链，于是进入下一个异常分析模块。

5.3.3 异常分析功能模块

点击异常分析模块按钮，系统跳转到异常点选择的界面，如图 5.9 所示，异常点已经标为红色，这里我们随机选取一个异常点，点击确定后会跳回到上文中的关联链界面中，本文选择第二条关联链进行分析，如图 5.10 所示：

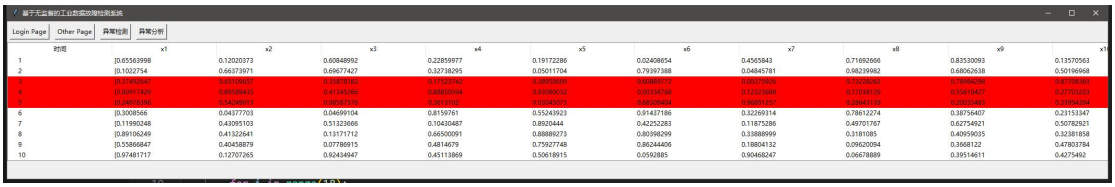


图 5.9 综合查询界面

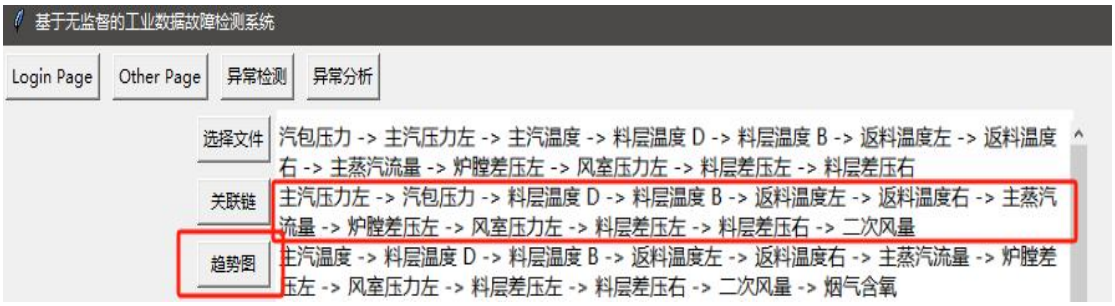


图 5.10 选择关联链

此时选择关联链，再点击趋势图按钮，系统就会开始生成这个关联链各个环节的趋势图，并在其上标出这个异常点。其中有五个锅炉生产环节与当前锅炉生产状态无关。

中国知网 https://www.cnki.net

由于不是每个环节都发生了异常，这里只给出出现部分的的可视化环节趋势图 5.11-5.14，并开始分析异常点的发生原因。

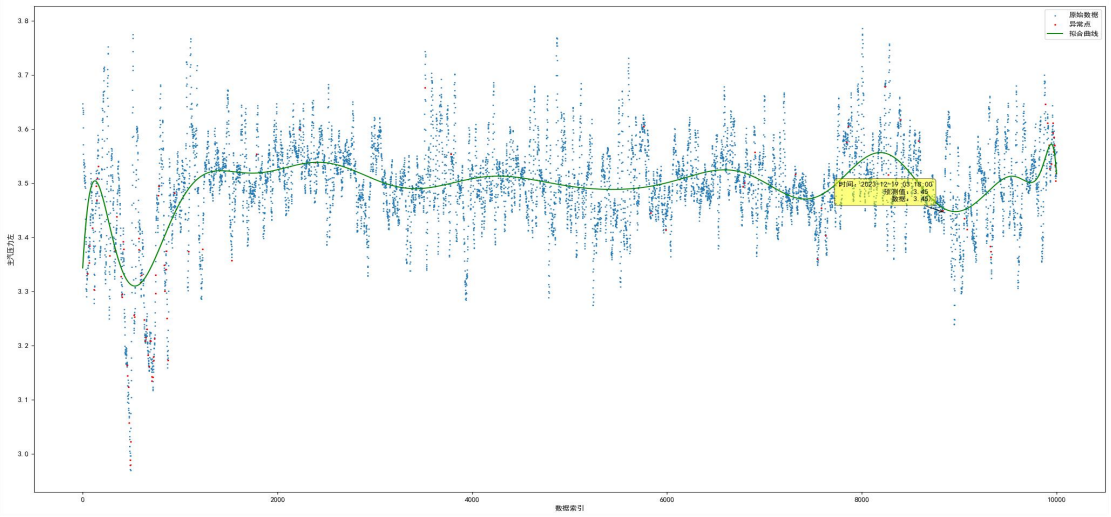


图 5.11 主汽压力左

该异常点在第一个环节显示正常，表明在此时设备运转是正常状态，所以不是导致该时间点异常的原因，接着往后查看该时间点。

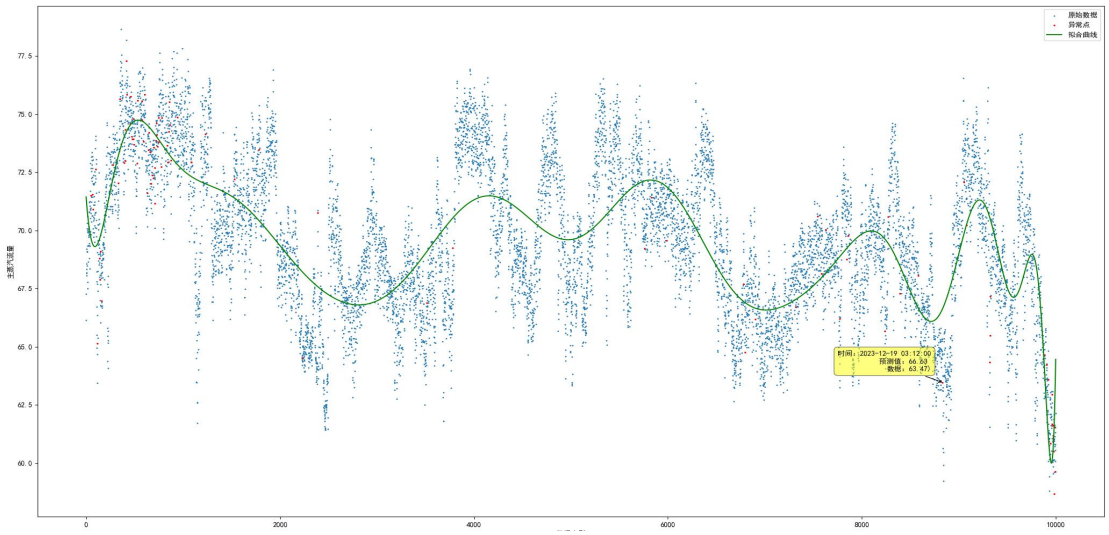


图 5.12 主蒸汽流量

到了第七个关联链环节，发现异常点在这个环节明显的偏离的趋势图，这可能就是导致异常点出现的原因，接着往后推到是否对后续锅炉工业生产系统的关联链环节造成了影响。

中国知网 https://www.cnki.net

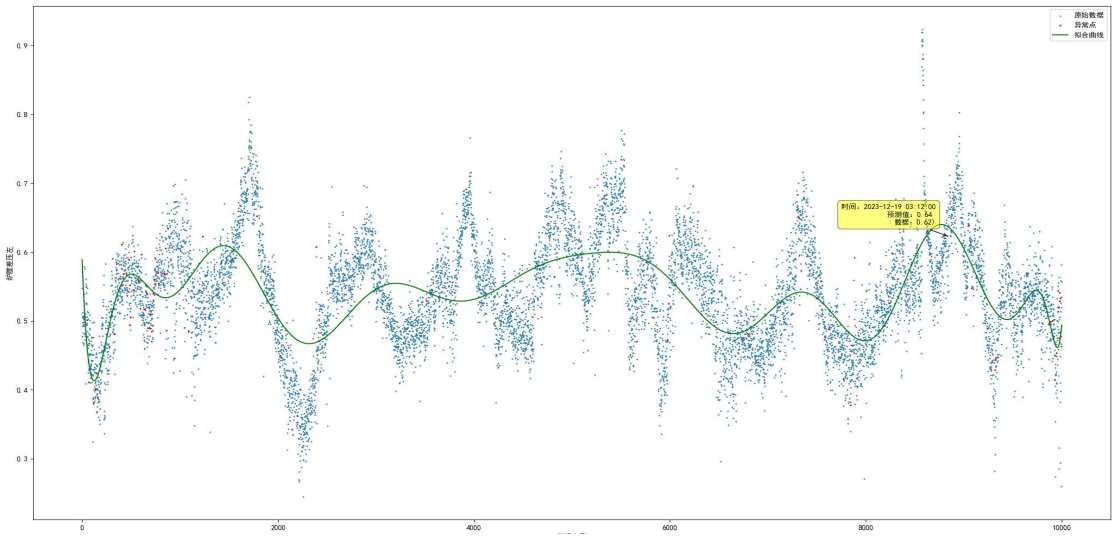


图 5.13 炉膛差压左

第八个环节炉膛差压左是正常的，处于趋势图的范围内且距离很近，第七个环节的异常并未对第八个环节造成影响。

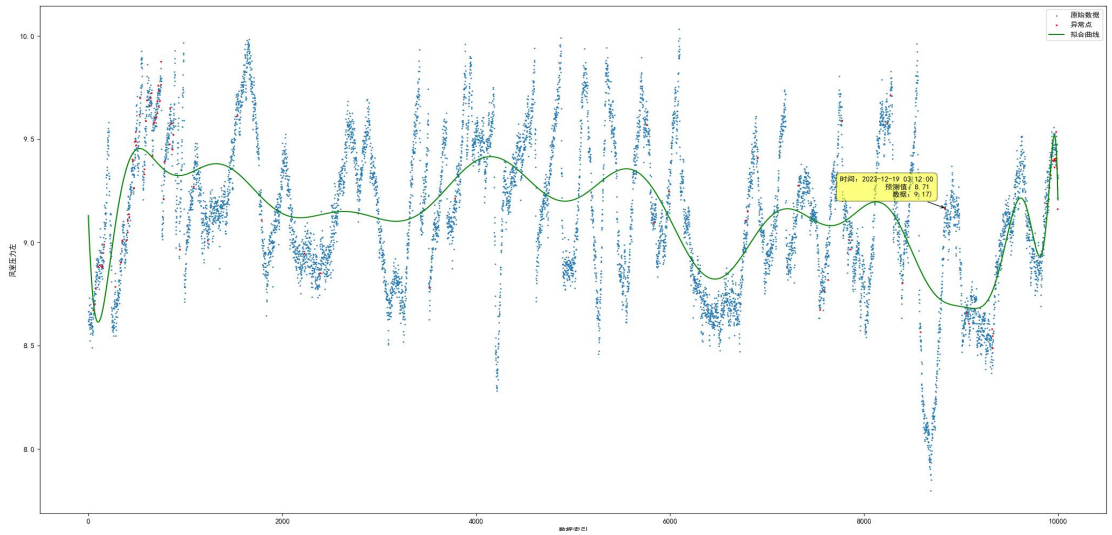


图 5.14 风室压力左

第九个关联链环节风室压力左，发现异常点在这个环节明显的偏离趋势图，这个点可能出现了异常，从此环节开始往后推导是否对后续的关联链环节造成了连锁影响。

中国知网 https://www.cnki.net

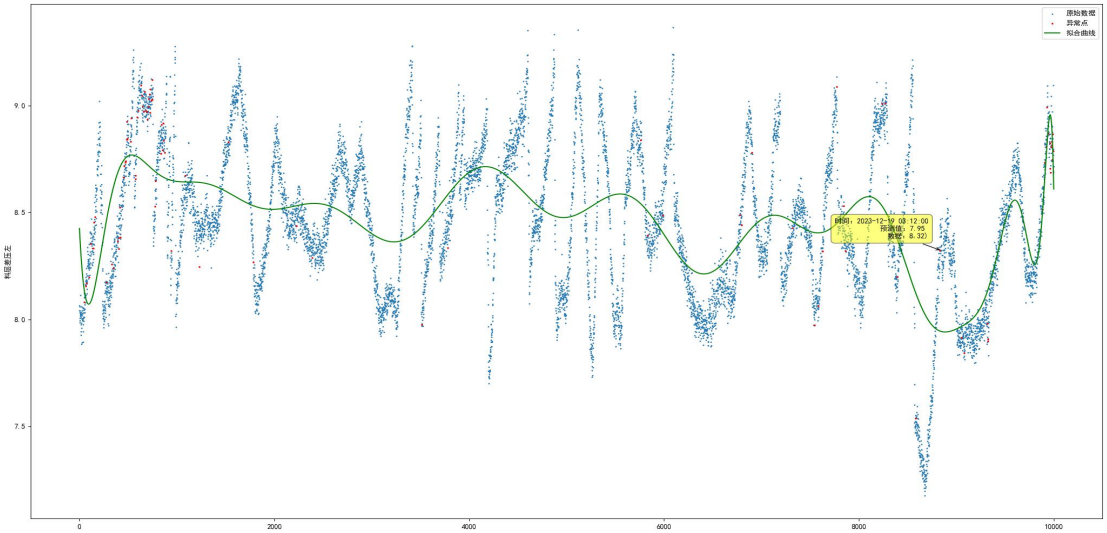


图 5.15 料层差压左

第十个环节料层差压左同样发现异常点偏离趋势图曲线的程度相当之大，因此这个环节的异常极有可能是上一个前置环节风室压力左环节造成的连锁反应。

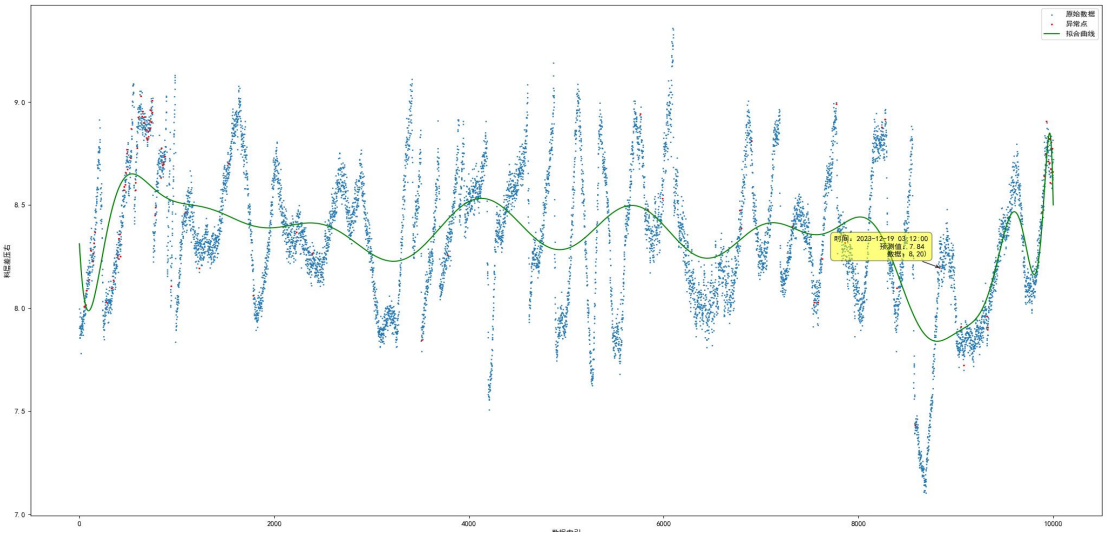


图 5.16 料层差压右

第十一个关联链环节也出现了异常，这个异常原因和上面一样，也极为可能是第十个环节料层差压左环节的异常造成的，但是它并没有对最后一个环节二次风量造成影响，也就是说该环节发生异常的原因是受到了上个环节——第十个环节料层差压左的异常影响，而第九个关联链环节风室压力左的上一个环节并没有发生异常，说明该环节是自身出现了异常，进而影响到了后续的环节。这时就需要派遣工人去检查该环节设备的各项指标，检查设备的安全性。

中国知网 https://www.cnki.net

5.4 本章小结

本章研究的主要内容是对基于无监督学习的工业数据故障检测系统进行主要核心功能的研发与实现。系统页面设计简单，左侧配置有导航栏，便于工人用户轻松实现页面间的顺畅切换。该系统浓缩了本文的研究成果，从最开始的聚类分析，到关联规则的挖掘，再到二者研究内容的结合，分析异常点发生的原因，实现锅炉工业生产流程环节的异常检测分析功能。系统针对工人们想要将技术知识直观呈现在面前的需求，融入了可视化模块组件，使工人用户得以凭借趋势图像，观察异常数据点的分布规律及生产流程各环节的关联特性。

在与基层操作人员的深切交流中，我深刻领悟到锅炉工业生产流程中工况环境的繁杂。对于本文的系统而言，系统的后续迭代更新与优化还需不断地深入探索改进，只有广泛倾听一线操作人员的实际体验与反馈，才能弥补不足之处，进而不断强化系统的各项功能。本课题组将持续深化与热电企业的交流合作，科学而高效地运用系统，以助力企业维持正常的运营状态，致力于为其构筑更为牢固的安全屏障，保障工厂设备的生产安全性和一线工人的人身安全。

中国知网 https://www.cnki.net

第六章　结论与展望

6.1 论文总结

在现代化工业化的时代背景下，各行各业的人们早已迈入了大数据时代，大数据记录人们日常的生活规律，将其转换为数据进行存储，包括人们的作息时间，消费情况，出行距离等。在这个时代背景下，专家提出能否利用大数据来提高人们生活水平的质量的问题，因此，各种利民的措施项目被提上了研究的日程，提高人们生活水平的安全性始终位于高价值研究项目之一。同样，各个领域的企业工厂也是如此，在每一天的运作中会产生无以量计的数据。而这些历史数据具有映射出设备运转状态、高价值挖掘等特性，这些特性可以在一定程度上为评估设备运转的安全性提供研究价值。基于此，本文主要是针对锅炉工业生产流程中产生的大量历史数据进行研究，设计并研发了基于无监督学习的工业数据故障检测系统。

论文研究的重点在于如何通过历史数据的异常点来判断当时设备运转的安全性，以及是哪些锅炉工业生产流程的环节出现了异常现象。本文是在课题组已有的锅炉工业生产流程的基础上进行异常点检测的安全性改进。

论文首先介绍了课题的研究背景和国内外研究的现状，以及论文的主要写作内容。然后，对锅炉的历史数据集进行预处理，整理得到用于后续聚类分析的数据集。接着对各种异常检测算法进行了研究与比较分析，选取密度聚类算法进行本课题的聚类分析研究，并对其进行了改进和实验。通过基于 2 项频繁项集思想改进的 FP-Growth 关联规则算法来关联分析锅炉工业生产流程中任意两个环节之间的关联关系，生成环节之间的关联规则，进而生成当时锅炉工业生产流程中锅炉工况的关联链。除了对上述内容部分进行的设计分析，还结合工厂员工的需求进行系统的设计。系统加入了可视化模块，可以分析异常点发生的原因，可以辅助工人快速的对相应的异常点环节设备进行故障排查。

总而言之，与现有对锅炉工业生产流程的其他提升安全性的措施相比，本文设计的系统不需要工人时时刻刻地盯着设备运转屏幕，不局限于单一特定的机器设备生产环节，而是尤其注重于对历史数据异常故障发生时刻的检测，实现了锅炉工业生产流程中对安全性加强。

中国知网　https://www.cnki.net

6.2 研究展望

在本文的研究中，针对于锅炉工业生产流程中的安全性，对其产生的大量历史数据进行研究，设计了相应的算法，开发了故障检测系统。但是开发的系统与使用的算法难免遗留着一些不足之处，为了提高系统的功能性，将来可从下述几方面加以改进。

首先针对算法部分的流程，聚类算法采用的是 DPC 密度聚类算法，该算法是异常点检测的经典算法。虽然本课题使用的算法是引入了 k 近邻居的思想来提升异常点的检测效果的，但对于后期课题组的同学们继续研究的方向颇有局限性，对于算法本身可以继续优化，后续可学习更新的算法来提供新的改进思想。

然后是在关联规则发现方面，本文是针对得到的环节间的聚类分析结果，采用的 2 项频繁项集思想改进的 FP-Growth 关联规则算法，同时引入了支持度、置信度、增长度三个概念来进行环节间关联规则的分析与计算。虽然本文经过系统实验分析得出生成的关联链有着良好的异常检测效果，但如果能同时对所有环节进行环节间的关联规则分析才能保证其最高的准确性，在后续的研究工作中可以继续对关联规则算法进行创新性应用，研究出更加准确高效的高进思路。

最后在系统设计的方面，系统的设计确实简陋，而且加入了趋势图生成功能来分析异常点，但是系统没有实现动态的智能化趋势图设计，因此在观测上有点不顺人意，后期工作中，可以加入更多智能化的模块来方便观测异常点的分析环节。

中国知网 https://www.cnki.net

参考文献

[1] Zhao X, Cui W, Wu Y, et al. Ouil Outlier Interpretation on Multi-dimensional Data via: Visual Analytics[J]. Computer Graphics Forum, 2019, 38(3): 213-224.

[2] 吴建海, 白云, 郭玉磊. 火力发电企业燃料自动监管系统的设计及应用[J]. 内蒙古电力技术, 2013, 31(04):58-62.

[3] 李然.分布式控制系统在发电厂中的应用研究[D].北京工业大学,2017.

[4] 吴若冰,张振超.考虑新能源接入下的配电网线损综合检测方法[J].电测与仪表,2024,61(09):145-150.DOI:10.19753/j.issn1001-1390.2024.09.019.

[5] 牟国栋.燃煤锅炉生产流程优化辅助决策系统的研究与开发[D].济南大学,2019.DOI:10.27166/d.cnki.gsdcc.2019.000202.

[6] 李国昌. 流程对象在线实时知识发现系统的设计与实现[D]. 济南大学, 2020. DOI:10.27166/d.cnki.gsdcc.2020.000661.

[7] 卢静.碳监测背景下多元数据协同分析及异常检测方法研究[D].北京交通大学,2023.DOI:10.26944/d.cnki.gbfju.2023.002931.

[8] 米改娜. 基于密度聚类的工业数据异常点发现方法的研究与实现[D]. 济南大学, 2022. DOI:10.27166/d.cnki.gsdcc.2022.000545.

[9] 王容容.基于标记分布学习算法的改进及应用研究[D].广西民族大学,2024.DOI:10.27035/d.cnki.ggxmc.2024.000277.

[10] Hawkins D M. Identification of outliers[M]. London: Chapman and Hall, 1980.

[11] Han J, Micheline K. Data mining: concepts and techniques[J]. data mining concepts models methods & algorithms second edition, 2006, 5(4): 1-18.

[12] 薛安荣, 姚林, 鞠时光, 等. 离群点挖掘方法综述[J]. 计算机科学, 2008,35(11):13-18.

[13] Wu X , Yang D , Zhang W ,et al.A Hybrid Ensemble Model for Corporate Bankruptcy Prediction Based on Feature Engineering Method[C]//2019 第四届应用数学与信息技术国际会议.0[2025-05-15].

[14] 甘露情, 刘媛华. 基于离群点检测和误差修正的空气质量指数预测[J]. 计算机系统应用,2021,30(03):250-255.

[15] Zhao H , Yuan P , Mao Z ,et al.Improving Identification of Wind Tunnel Systems Using Clustering-Based Ensemble Outlier Detection Model[J].Journal of Aerospace Engineering,

中国知网 https://www.cnki.net

2021(3):34.DOI:10.1061/(ASCE)AS.1943-5525.0001235.

[16] Hagan R D , Langston M A .Molecular Subtyping and Outlier Detection in Human Disease Using the Paraclique Algorithm[J].Algorithms, 2021, 14(2):63.DOI:10.3390/a14020063.

[17] Young-Geun Choi, Hanrahan L P , Norton D ,et al.Simultaneous spatial smoothing and outlier detection using penalized regression, with application to childhood obesity surveillance from electronic health records[J].Biometrics, 2020.DOI:10.1111/biom.13404.

[18] Gil P , Martins H ,Fábio Januário.Outliers detection methods in wireless sensor networks[J].Artificial Intelligence Review, 2018.DOI:10.1007/s10462-018-9618-2.

[19] Yongchang Gao, Haowen Guan, Bin Gong. CODM: an outlier detection method for medical insurance claims fraud[J]. International Journal of Computational Science and Engineering, 2019,20(3): 404.

[20] Marcus Vinícius Contes Calça, Matheus Rodrigues Raniero, Domingos Mário Zeca Fernando, Sérgio Augusto Rodrigues, Alexandre Dal Pai. Outliers Detection in a Quality Control Procedure for Measurements of Solar Radiation[J]. IEEE Latin America Transactions,2019,11(11): 1815-1822.

[21] Ige A O , Noor M H M .A survey on unsupervised learning for wearable sensor-based activity recognition[J].Applied Soft Computing, 2022.DOI:10.1016/j.asoc.2022.109363.

[22] 闻瑞梅. 半导体工业废水、废气中砷、磷、硫、氟、氯及氮氧化物和重金属的综合治理[J]. 电子学报, 2000, 28(11): 1-3.

[23] Magda B ,Charlotte J ,Al A K , et al. Artificial intelligence for dementia research methods optimization. [J]. Alzheimer's & dementia : the journal of the Alzheimer's Association, 2023, 19 (12): 5934-5951.

[24] Yuyang L ,Suvodeep M ,A. P B . An unsupervised learning approach to diagnosing Alzheimer’s disease using brain magnetic resonance imaging scans [J]. International Journal of Medical Informatics, 2023, 173 105027-105027.

[25] Kareem E ,Mohamed G ,Xiao L . Unsupervised Learning Methods for Data-Driven Vibration-Based Structural Health Monitoring: A Review [J]. Sensors, 2023, 23 (6): 3290-3290.

[26] 任嘉敏, 马延吉. 东北地区工业污染时空格局演变研究[J]. 环境科学学报, 2018, 38(05): 2108-2118.

[27] 宋晓东, 江洪, 余树全, 等. 模拟酸雨胁迫与植物叶片光谱反射率特征间的关系[J]. 光谱学与光谱分析, 2010, 30(01): 165-169.

[28] Chandola V, Banerjee A, Kumar V, et al. Anomaly detection[J]. ACM Computing Suiveys, 2009, 41(3):

中国知网 https://www.cnki.net

1-58.

[29] 左进, 陈泽茂. 基于改进 K 均值聚类的异常检测算法[J]. 计算机科学, 2016, 43(08): 258-261.

[30] 许晓东, 杨燕, 李刚. 基于 K-means 聚类的网络流量异常检测[J]. 线通信技术, 2013, 22(04): 21-26.

[31] 庄池杰,张斌,胡军,等.基于无监督学习的电力用户异常用电模式检测[J].中国电机工程学报, 2016, 36(2):379-387.DOI:10.13334/j.0258-8013.pcsee.2016.02.008.

[32] W. Wang, J. Yang, R. Muntz. Sting: a statistical information grid approach to spatial data mining.Proceedings of the VLDB, 97 (1997), pp. 186-195.

[33] Ramaswamy S, Rastogi R, Shim K, et al. Efficient algorithms for mining outliers from large data sets[J]. International Conference on Management of Data, 2000, 29(2): 427-438.

[34] Breunig M M, Kriegel H, Ng R T, et al. LOF: identifying density-based local outliers[J]. International Conference on Management of Data, 2000, 29(2): 93-104.

[35] 卢光曦.基于图神经网络的目标检测与识别算法研究[D].电子科技大学,2021.DOI:10.27005/d.cnki.gdzku.2021.003929.

[36] Zhang F, Hu H Q, Wang L, et al. Effects of rare earth and acid rain pollution on plant chloroplast ATP synthase and element contents at different growth stages[J]. Chemosphere, 2018, 194(3): 441-449.

[37] Singh G, Singh J, Singh S J, et al. Fructose modified synthesis of ZnO nanoparticles and its application for removal of industrial pollutants from water[J]. Journal of Materials Science: Materials in Electronics, 2018, 29(9): 7364-7371.

[38] Kheirallah D A, El-Samad L M, Spermatogenic alterations in the ground beetle Trachyderma hispida (Coleoptera: Tenebrionidae) induced by ceramic industrial pollution[J]. African Entomology, 2019, 27(2): 418-432.

[39] 曹宏斌, 赵赫, 张笛, 等. 基于高效清洁生产的全过程污染控制(WPPC)——中国钨行业典型案例研究[J]. Engineering, 2019, 5(04): 373-391.

[40] 时志强. 关于工况用电监测系统在环境管理中的应用研究[J]. 科学技术创新, 2020(10): 189-190.

[41] Yu Y, Ren J S, Zhang Q, et al. Research on tire marking point completeness evaluation based on k-means clustering image segmentation[J]. Sensors, 2020, 20(17): 4687-4687.

[42] Madan S, Dana K J. Modified balanced iterative reducing and clustering using hierarchies (m-BIRCH) for visual clustering[J]. Pattern Analysis and Applications, 2016, 19(4): 1023-1040.

[43] Ester M, Kriegel H P, Sander J, et al. A density-based algorithm for discovering clusters in large

中国知网 https://www.cnki.net

spatial databases with noise[C]. Proc.int.conf.knowledg Discovery & Data Mining, 1996.

[44] Rodriguez A, Laio A. Machine learning: clustering by fast search and find of density peaks[J]. Science, 2014, 344(6191): 1492-1496

[45] Hinneburg A. An ecient approach to clustering in large multimedia databases with noise[C]. Proc.int.conf.knowledge Discovery & Data Mining, 1998.

[46] Deng Z, Hu Y, Zhu M, et al. A scalable and fast OPTICS for clustering trajectory big data[J]. Cluster Computing, 2015, 18(2): 549-562.

[47] Wu B, Wilamowski Bogdan M. A fast density and grid based clustering method for data with arbitrary shapes and noise[J]. IEEE Transactions on Industrial Informatics, 2017, 13(4): 1620-1628.

[48] Du T, Qu S N, Wang Q. A data-driven parameter adaptive clustering algorithm based on density peak[J]. Complexity, 2018, 2018(10): 1-14.

[49] 陆春光, 叶方彬, 赵羚, 等. 基于密度峰值聚类的电力大数据异常值检测算法[J]. 科学技术与工程, 2020, 20(02): 654-658.

[50] 辜思怡. 大数据环境下 FP-Growth 算法的并行性研究与实现[D]. 南昌大学, 2023. DOI:10.27232/d.cnki.gnchu.2023.004435.

[51] 武亚光,张才俊,程飞飞.基于 FP-growth 算法的多尺度用电异常行为检测方法[J].电子设计工程,2023,31(23):118-121+126.DOI:10.14022/j.issn1674-6236.2023.23.026.

[52] 刘志鹏,孙世梅. 基于“2-4”模型和 Apriori 算法的商业综合体火灾成因分析 [J]. 安全, 2024, 45 (09): 11-16. DOI:10.19737/j.cnki.issn1002-3631.2024.09.002.

[53] 黄石安. 基于关联规则数据挖掘的 Apriori 算法应用分析 [J]. 无锡商业职业技术学院学报, 2024, 24 (04): 51-57. DOI:10.13659/j.cnki.wxsy.2024.04.005.

[54] 唐学军,周达谋,李慧莲. 基于改进 Apriori 关联规则算法的信令分析 [J]. 邮电设计技术, 2024, (09): 63-67.

[55] 马鹏志. 面向医学数据的改进模糊关联规则挖掘算法研究[D]. 沈阳建筑大学, 2024. DOI:10.27809/d.cnki.gsjgc.2024.000281.

[56] 胡李炜. 基于改进麻雀搜索算法的多目标关联规则挖掘方法[D]. 华东交通大学, 2024. DOI:10.27147/d.cnki.ghdju.2024.000356.

[57] 邓淼. 基于关联规则的网络告警数据挖掘算法研究[D]. 武汉科技大学, 2024. DOI:10.27380/d.cnki.gwkju.2024.000169.

[58] 文强. 基于 GAN 模型和动态遗传算法的区域空气质量影响因素关联规则挖掘研究[D]. 合肥大

中国知网 https://www.cnki.net

学, 2024. DOI:10.27876/d.cnki.ghfxy.2024.000034.

[59] 朱连江, 马炳先, 赵学泉. 基于轮廓系数的聚类有效性分析[J]. 计算机应用, 2010(12):139-141.

[60] 孙昊, 付旭云, 钟诗胜. 基于慢特征密度聚类的气路异常检测方法[J]. 航空动力学报, 2021, 36(10): 2218-2229.

[61] Tong B .Density Peak Clustering Algorithm based on the Nearest Neighbor[C]//Wuhan Zhicheng Times Cultural Development Co.,Ltd.Proceedings of 3rd International Conference on Mechatronics Engineering and Information Technology(ICMEIT 2019).College of Computer & Information Science,Southwest University;,2019:681-686.

[62] Gupta S, Kumar R, Lu K, et al. Local search methods for k-means with outliers[C]. Very Large Data Bases VLDB Endowment, 2017.

[63] Lulli A, Dell'Amico M, Michiardi P, et al. NG-DBSCAN: scalable density-based clustering for arbitrary data[J]. Proceedings of the VLDB Endowment, 2016, 10(3): 157-168.

[64] Xu L K, Jin Y X, Xue H, et al. Outlier detection of light buoy telemetry and telecontrol data based on improved adaptive neighborhood DBSCAN clustering[J]. Mathematical Problems in Engineering, 2021, 2021(2): 1-7.

[65] Song H J, Lee J G. RP-DBSCAN: A superfast parallel DBSCAN algorithm based on random partitioning[C]. Proceedings of the 2018 International Conference on Management of Data, 2018.

[66] 王建元, 张少锋. 基于线性判别分析和密度峰值聚类的异常用电模式检测[J]. 电力系统自动化, 2022, 46(5): 1-12.

[67] Du M, Ding S, Jia H. Study on density peaks clustering based on K-Nearest Neighbors and principal component analysis[J]. Knowledge-Based Systems, 2016, 99(5): 135-145.

[68] Huang J, Zhu Q, Yang J, et al. A non-parameter outlier detection algorithm based on Natural Neighbor[J]. Knowledge Based Systems, 2016, 92(1): 71-77.

[69] Chang H, Yeung D Y. Robust path-based spectral clustering[J]. Pattern Recognition, 2008, 41(1): 191-203.

中国知网 https://www.cnki.net

单位代码：10427
密　　级：公　开



济南大学
UNIVERSITY OF JINAN

中国知网　https://www.cnki.net