分类号：TP301.6
学校代码：11065

密级：公开
学号：2015020506

青岛大学

学术硕士学位论文

工业大数据相似重复记录数据清洗关键技术研究

作者姓名　杨巧巧
指导教师　郭振波　教授
学　　科　软件工程
培养单位　数据科学与软件工程学院
答辩日期　2018 年 5 月 14 日

中国知网　https://www.cnki.net

工业大数据相似重复记录数据清洗关键技术研究

摘　　要

工业大数据是支撑未来智能信息化的基础，企业在发展过程中积攒了大量珍贵的数据信息，这些数据在企业的发展过程中起着举足轻重的作用。但由于存在不完整数据、重复数据、缺省数据、冗余数据等数据质量问题，使得基于这些数据的分析往往产生错误的结果，这就必须关注数据本身的质量问题，

本文主要对工业大数据中的相似重复记录进行研究，并进行相应的处理工作。由于传统的清洗算法对相似重复记录清洗效果较差，本文结合工业大数据数据特点，以及中西文表达不同的特点，针对传统编辑距离因属性缺失造成的重复记录误判情况，提出模式编辑距离以及综合属性权值的概念，可以实现区分中西文表达差异同时可以最大化合理考虑数据的领域特点，从而提高检测精度。工业大数据集中对整个数据集进行相似记录匹配是没有必要的，故提出基于长度过滤和动态伸缩窗口的概念，利用长度过滤（大于阈值）算法将不可能构成相似重复的记录进行筛除；通过设置动态伸缩窗口，比较窗口内的记录间相似度，整个窗口在滑动过程中动态调整其大小，减少了不必要的记录匹配。

本论文的目的在于深化相似重复记录识别方面的研究，并为相似重复记录检测在工业大数据中的应用起到抛砖引玉的作用。实验证明，改进的 SNM 算法在识别相似重复记录方面，检测精度和效率均有所改善，也验证了相似重复记录识别算法在工业大数据中应用的价值性。

关键字：工业大数据；数据清洗；相似重复记录；SNM 算法；

中国知网　https://www.cnki.net

Research on Technologies of Duplicate Record Data Cleaning under Industrial Big Data

Abstract

Big data in industrial is supported the future intelligence information. A large number of valuable data and information is essential for the development of enterprises. However, data quality issues don't get enough attention it deserves, there are data incomplete, duplicated data, data invalid and other quality problems, which make the work based on the analysis of data get error analysis results. Therefore, it must pay attention to the quality problem of the data.

This paper mainly study the duplicated data in the industrial. Because the traditional cleaning algorithm often has poor performance when dealing with large data, this paper introduces the new method. For data is large, multi-dimensionality and has diverse data types, so this paper put forward the new algorithm to deal the detecting approximately duplicate records, which based on multiple edit distance and attributes weight. It can be used to distinguish the differences between Chinese and western languages and to maximize the field characteristics of data, so as to improve the detection accuracy. It is not necessary to make matching for the whole data set in industrial. Therefore, the concept of length filtering and dynamic expansion window is proposed. Using length filtering method will delete part of records that would not be constitute duplicate records; the similarity between the records in the window is compared by setting the dynamic scaling window, and the whole window is dynamically adjusted in the process to reduce unnecessary records matching.

The purpose of this paper is to deepen the research on the recognition of duplicate records and to play a reference role in the application of duplicate records detection in industrial data. The experimental results show that, the improved algorithm has high detection accuracy and high efficiency in identifying duplicate records. It also verifies the value of duplicate record recognition algorithm in industrial big data.

Key words: big industrial data; cleaning algorithm; duplicated data; SNM algorithm

中国知网 https://www.cnki.net

目录

第一章 绪论.....1
1.1 研究背景.....1
1.2 研究意义.....1
1.3 研究现状分析.....2
1.3.1 数据清洗研究现状.....2
1.3.2 工业大数据清洗研究现状.....3
1.3.3 存在的问题.....4
1.4 论文研究内容及组织结构.....4
1.5 本章小结.....6
第二章 数据清洗基础理论和关键技术.....7
2.1 数据质量和数据清洗.....7
2.1.1 数据质量问题分类.....7
2.1.2 数据清洗过程.....8
2.2 相似重复记录清洗.....10
2.2.1 字段相似检测算法.....10
2.2.2 相似重复记录检测算法.....11
2.3 缺省值清洗.....12
2.3.1 缺失值清洗算法总体描述.....13
2.3.2 缺失字段处理方式.....13
2.4 离群点清洗.....14
2.4.1 基于统计的离群点检测.....14
2.4.2 基于距离的离群点检测.....15
2.4.3 基于聚类的离群点检测.....15
2.5 本章小结.....17
第三章 相似重复记录清洗方案.....18
3.1 典型的数据清洗方案.....18
3.2 相似重复记录清洗模型.....18
3.3 数据预处理过程.....19
3.3.1 属性选择及格式统一.....19
3.3.2 记录排序.....20
3.3.3 属性综合权重分配.....20
3.4 重复记录检测.....23
3.4.1 字段匹配算法.....23
3.4.2 记录匹配算法.....25
3.5 重复记录聚类.....27
3.5.1 SNM 算法工作原理.....27
3.5.2 SNM 算法分析.....28
3.5.3 SNM 算法改进详细过程.....29
3.6 冲突解决.....31
3.7 本章小结.....32

中国知网 https://www.cnki.net

第四章　基于改进 SNM 算法的工业大数据清洗机制及仿真实验..... 33
4.1　工业大数据数据采集分析.....33
4.2　工业大数据数据清洗架构.....35
4.3　SNM 算法在工业大数据中的应用.....36
4.3.1　基于长度过滤的并行化实现.....36
4.3.2　改进的 SNM 算法的并行化实现.....37
4.3.3　SNM 算法在工业大数据中的应用.....37
4.4　实验设计与评价标准.....38
4.4.1 实验数据集及参数设置.....38
4.4.2 评价指标.....39
4.5 算法测试结果及分析.....40
4.5.1　基于长度过滤及综合权值的编辑距离算法.....40
4.5.2　基于动态滑动窗口的 SNM 算法.....42
4.6 本章小结.....43
第五章 总结与展望.....45
参考文献.....46
攻读学位期间的研究成果.....49
致　谢.....50
学位论文独创性声明.....50

中国知网　https://www.cnki.net

第一章 绪论

1.1 研究背景

随着我国信息技术的推广，各行各业都在加紧实施管理信息化，其中具有代表性的是工业大数据下的 ERP（Enterprise Resource Planning，企业资源计划）系统，MES(Manufacturing Execution System，制造企业生产过程执行)系统，以及其它各种形式的企事业信息系统，这些系统中记录了大量企业发展有价值的数据。对大数据时代的大部分应用而言，收集数据已不再是发展的瓶颈，而如何从这些数据中提炼出有效信息、并保证收集到数据的一致性[1]正日渐变为必需面临的问题。为了使集成系统中数据更加准确、一致，更能准确的反映企业的发展历程、支持管理者的决策以及分析用户的潜在需求，就需要所管理的数据更加准确、可靠。

目前关于数据清洗，在统计学、人工智能、数据库等领域都已进行过大量的研究，学术界也已提出不少有效提高数据质量的清洗算法。然而，随着大数据时代的到来，传统的清洗算法面临新的挑战，大数据时代数据来源广，结构复杂，数量巨大；互联网应用中存在大量复杂数据结构类型的数据，其采集、收集、分析过程会导致各种数据质量问题；大量数据的清洗操作对算法的运行时间及工作效率提出了更为严格的要求。工业大数据特别是家电行业的兴起，各大厂商保存着大量的产品的生产、组装、销售、售后等各个环节的数据，这些数据可能来自不同数据库系统、不同的生产环节、不同的生产厂商，其在集成的过程中容易产生各式各样的“脏数据”，工业上的各个环节的真实信息被淹没在这些“脏数据”中，使得基于这些数据的分析结果并不能反正企业的真实情况。工业界数据具有数据海量性、数据类型多元化、数据不规范性、数据易变性等特点，这就使得已有的清洗算法处理工业大数据时，往往表现不佳。

相似重复记录是指现实世界中的同一实体，由于各种原因使数据库系统不能正确识别，从而使得基于该数据的分析产生错误结果，这类数据的存在会造成各种各样的问题：1、破坏了数据的一致性。2、存在数据冗余、浪费存储资源。3、不利于数据分析。

1.2 研究意义

工业大数据背景下，数据清洗本身的特点：一方面，数据清洗是为了解决数据质量的问题，一般情况下需要根据情况选择合适的解决方法即具体问题具体分析，很难找到一个统一的方法，这就使得数据清洗问题的建模过程复杂也困难；另一方

中国知网 https://www.cnki.net

面研究的重点就要集中在数据的存储、挖掘和分析等方面，忽略了工业大数据本身的质量问题带来的隐患，且在工业界没有引起足够的重视，针对这方面的研究也较少。虽然数据清洗往往依赖特定领域并且耗时较大，但是数据清洗还有很多方面是值得研究的，例如：1、优化清洗框架应对海量数据的清洗问题。2、进行算法剪枝提高清洗效率。3、提高算法运算能力以及适应能力提高其准确率。

数据清洗是保证数据质量的一种手段，其能够识别工业大数据中的错误记录，并对记录进行修正，能尽最大可能够确保交付数据的准确性和一致性，进而确保参加决策数据的质量。同时，由于工业界每天产生大量信息，如何应对海量数据进行高效的清洗，也是需要解决的问题。已有的数据清洗算法在对大量数据进行操作时，往往表现出较低的准确率和精确率，检查效率也不理想，基于以上问题，传统清洗算法不能很好的处理工业界大数据集。

本文的研究课题就是在上述背景下提出的，以工业大数据中的冰箱生产数据为例子，针对工业界数据集中的数据质量问题，提出基于海量数据的清洗方案，从而达到提高数据清洗的质量和效率的目标。

1.3 研究现状分析

1.3.1 数据清洗研究现状

国外关于清洗技术的研究工作始于 1950 年，其出现是为全美国的保险号纠正服务的。因为信息化在某些发达国家中的发展程度较高，则其对于数据清洗相应的市场需求，反作用促进其发展，因此目前针对数据清洗方面的研究主要集中在国外。数据清洗是数据预处理的一种手段，能够识别、检测数据中的异常信息或错误数据，查找并筛除数据中的相似重复记录，填补记录中的空缺属性，尽最大可能保证数据质量且使其更合适做数据挖掘。随着我国工业信息化、智能化的发展，企事业及科研工作者意识到行业的发展很大程度上依托于数据信息，只有从这些信息中挖掘出行业发展的信息，才能促进行业的进一步发展，因此国内对数据质量问题的研究以及数据清洗的策略的研究也逐步开始，概括为以下两个方面：

1、领域无关的数据清洗

检测并消除数据异常常用以下方法：对数值型字符采用数理统计的方法进行异常检测，通过计算字段的均值、极差、方差、标准差，对字段和记录进行检测和识别；针对字符型字段的异常检测主要是利用字段之间的约束关系进行的，将数据挖掘方法引入到数据清洗中，如聚类方法用于检测异常数据、模型方法用于发现不符合现有模式的异常记录。

中国知网 https://www.cnki.net

识别记录中的相似重复记录常用方法有：基于属性的检测算法的核心是字段的匹配，目前常见的基于字段的算法有：基本字段匹配的算法、基于编辑距离的匹配算法、基于 N-Gram 的相似重复记录检测算法[2]、改进的 Smith-Waternman[3]、递归字段匹配算法[4]等。基于记录的相似重复记录识别算法中，最经典的是 SNM 算法，针对其查全率、查准率较低的缺陷，学者提出了各种基于该算法的改进方案，如：基于 SNM 的多趟排序算法、基于 SNM 的网格过滤算法等等。

目前另一领域无关数据清洗方面的主要研究在于数据清洗工具，目前数据清洗的工具主要有：Weka(Waikato Environment for Knowledge Analysis)[5]、KNIME (Konstanz Information Miner)[6]、XAware、Orange、YALE(Yet Another Learning Environment)，这下工具的设计是为了能够研究出通用的领域无关的数据清洗框架，方便为用户提供海量数据的抽取、转换和集成操作，同时能够降低用户的编程复杂性。这类数据清洗具有的明显特点是：能够应用于不同领域，清洗自动化程度高，处理过程基本可以集成到现有软件中。

2、特殊领域的数据清洗

大多数研究人员认为，如果对某一类数据的质量要求较高，那就必须要结合特定领域的相关知识[7]。针于一个完善的清洗框架，首先需要专家领域知识的参与，然后利用相应的清洗算法和合适的数学模型进行数据清洗工作，最后对于系统不能自动化处理的数据或有特殊需求的数据，就需要专家辅助以及用户的参与来进一步完善清洗过程。同时，清洗系统会通过机器学习、模型构建等方法不断完善和改进。

1.3.2 工业大数据清洗研究现状

大数据时代的到来，伴随着工业领域的革新，两者结合使得工业加速向数据分析、数据挖掘、数据应用的方面进行智能转型，基于工业大数据的分析和应用也必将成为未来产业发展的重要因素。工业界的大数据是制造业各个生产流程智能化的必然产物。工业大数据是一个泛化的概念，它包含企业制造生产过程中产生的内部系统数据，也包括企业产品流通过程中产生的外部数据。这些数据具有数据量庞大、时效性强、价值密度低、复杂度高等特点。工业大数据不同于传统的信息系统中的数据，其采样难度和对分析技术的要求都相对更高，为了确保数据分析的准确性，就必须保证参与分析的数据是准确可用的，这就使得需要对工业大数据进行数据清洗。

目前，国内针对数据清洗方面的研究尚且处于初级阶段，虽然在一些学术汇报或者期刊读物中偶尔存在关于西文数据清洗的观点、文章，但针对中英文方面的数据清洗算法和技术很少有涉猎，特别是针对某一特定领域的数据清洗方法还是少之又少。工业大数据方面的研究相对是欠缺的。

中国知网 https://www.cnki.net

1.3.3 存在的问题

目前，已有的这些清洗算法在处理中文数据时可以借鉴，但是并不是完全适用的，其中工业大数据的表现形式基本是中文和英文结合。从国内外对于数据清洗方面的发展以及清洗现状来看，目前存在的问题总结如下：

（1）中西文的数据清洗在很多方面存在不同，例如近邻排序算法（Sorted-Neighborhood Method，SNM）中，在中文和西文的数据中，排序关键字（key）的选取可能不同、 判定是否是输入错误的标准也不同。

（2）针对中文的清洗工具较少的问题，未来针对特定领域的清洗策略依旧是研究的重点，其他包括对相似重复记录的识别、不完整记录的填充、错误输入数据的检测等方面的问题。

（3）绝大多数清洗算法是领域无关的，如果对数据准确率要求较高的情况，其在应用的过程中就必须考虑结合相关领域的专家辅助，并且适当考虑数据自身的属性及属性间的关系等特点。

（4）识别和检测相似重复记录的绝大多数算法，基本上是采用“排序&合并”的方式[8]，这类方法在处理海量数据时，因对字符串排序需要占用大量的磁盘空间，一般表现出耗时过高的缺陷，且由于中文本身特点决定，使得字符串位置敏感问题严重影响相似重复记录的识别过程。

总之，在工业信息化的过程中，数据质量问题是目前数据质量安全中最具挑战性的研究课题之一。本文的研究采用的数据集是工业大数据中的冰箱数据，研究过程中考虑数据本身的质量问题，也将专业领域知识考虑在内，研究的过程中在一定程度上改善了上述存在的问题。

1.4 研究内容及组织结构

本文重点研究相似重复记录清洗算法，主要从提高算法的查准率、查全率以及检测效率三个方面为目标进行算法设计与分析。通过提高数据质量为目的引入各种清洗策略，对各清洗策略进行分类，引出异构数据库中影响数据质量的相似重复记录。本文主要开展的研究工作如下：

首先，针对传统编辑距离求解相似度的过程中，未考虑属性缺失以及属性权重的问题，本文提出模式编辑距离、长度过滤以及属性综合权值的概念，模式编辑距离的提出充分考虑因属性缺失造成的相似重复数据漏判的情况，长度过滤的概念可以在记录比对之前通过字符串个数、属性长度等提前判定两条记录不可能构成相似记录进行排除，设定属性综合权值的方法可以科学的评判各属性对记录判重中的贡献度的不同。

中国知网 https://www.cnki.net

其次，针对传统的 SNM 算法仅通过固定窗口大小对窗口内的记录进行判重，可能会因窗口过大或过小，导致多余匹配或漏匹配的情况。本文提出伸缩滑动窗口的概念，根据记录之间的相似度动态确定窗口大小，以及扩大和缩小的比例。同时，在记录比对过程中采用属性综合权值法，综合考虑数理统计和专家经验确定各属性在记录判重中的贡献度，并转化为属性的权值。

最后，将提出的多种编辑距离和动态伸缩滑动窗口的概念应用到实际工业大数据中，通过实验结果分别在准确率、召回率和检测效率出发，将提出的方法的有效性进行了验证。

本文组织结构如下：

第一章分析当前工业大数据环境下，数据清洗研究工作的重要意义，并介绍当前学者们在数据清洗研究过程中所做的部分工作，并分析了已有算法的问题，本章末说明了本论文的研究内容以及结构安排。

第二章首先简要介绍数据质量和数据清洗基本概念，从单数据源、多数据源、实例层和模式层多方面分解，分析影响数据质量问题的因素。然后论述了数据清洗的技术的原理、方法，其中重点在于数据清洗算法中相似重复记录的识别算法，为后续章节的研究工作奠定基础。

第三章主要针对现有的清洗算法进行充分研究后，对其在海量数据处理过程中表现出的不适应性进行分析，在数据预处理阶段提出属性综合权重的概念，科学有效的计算各属性的对记录标识的贡献度，在相似重复记录识别阶段提出基于属性编辑距离改进方法，其分为：基于模式编辑距离解决字段缺失问题，基于长度过滤方法解决构不成相似重复记录的筛选问题，属性综合权值的方法解决各属性对记录判重过程贡献度不一的问题。

第四章首先对工业大数据算法进行需求分析设计，并设计清洗流程以及详细的家电行业冰箱生产数据相似重复记录清洗步骤。介绍了改进的 SNM 算法在工业大数据中的具体的设计应用，采用综合权值法计算各属性的权值，能够科学的评判各属性在记录判重中的作用大小；采用滑动可变窗口的方法，能够科学的减少记录之间的匹配次数，两者集合为工业大数据的清洗提供了一种科学的解决方案。

第五章主要结合具体的应用数据，通过实验将本文提出的两种方法实现从理论到实践的落实。通过对工业大数据的冰箱数据进行实验，检测算法在冰箱生产数据中的相似重复记录，分析其查准率、查全率以及效率等方面的提高。

第六章总结了本文提出算法的优点和不足，以及在研究过程中遇到的问题，并展望了接下来可能进行的工作。

中国知网 https://www.cnki.net

1.5 本章小结

本章首先介绍了论文工作的研究背景，同时论述了相关清洗研究的重要性，然后介绍了数据清洗的现状及工业大数据背景下的数据清洗现状，并指出目前数据清洗方面存在的缺陷，最后介绍了本论文的组织结构。

中国知网 https://www.cnki.net

第二章 数据清洗基础理论和关键技术

本章主要介绍目前常见的几种数据清洗算法，并对数据质量问题进行分类说明，对常见的清洗算法进行简要的介绍。

2.1 数据质量和数据清洗

关于数据质量的定义，目前还没有统一的说法，但已有的定义都可以总结为：数据质量指主体的某些特性能够满足客体能力的综合。

数据清洗是提高数据质量中的一个重要环节，其主要思想是通过“排序&合并”方法、建立索引方法、机器学习方法、以及其他的各种方式，对数据进行分析处理，找到问题数据，也就是所谓的“脏数据”，并对问题数据按照一定的规则进行进一步的处理。

2.1.1 数据质量问题分类

数据清洗的意义就在于提高用于决策分析的数据质量，其中影响数据质量问题的因素有很多，主要可以概括为以下几种：相似重复、缺省、错误、不一致等，其中根据产生的原因，文献[9]将数据质量问题进行分类操作，分为四大类分别是：单数据源模式层问题、单数据源实例层问题、多数据源模式层问题和多数据源实例层问题，其具体分类如表 2.1 所示，表中分别列出了造成每一类数据质量问题的主要原因。

表 2.1 数据质量问题分类

数据质量问题	单数据源问题	模式层	不好的模式设计、贫乏的完整性约束等
		实例层	数据本身的错误
	多数据源问题	模式层	不统一模式设计和不统一的数据模型
		实例层	冗余、矛盾、不一致的数据等

中国知网 https://www.cnki.net

模式层的问题在实例层上是不可见的，模式层面的数据质量问题主要是结构设计方面或命名方面的不合理因素造成的，其可以通过优化设计模式进行改善。通过对工业大数据的分析发现，“脏数据”主要集中在实例层，如数据本身的错误包括了数据拼写错误、不完整的数据以及数据的属性值域错误等问题；冗余矛盾或者不一致的数据主要包括不一致的汇总、不一致的时间选择等。总之，无论是单数据源还是多数据源的模式层的问题都是可以通过改进设计模式、进行模式转换、加强模式集成等方式来解决的，因此本文主要从实例层次来考虑数据清洗的问题。

2.1.2 数据清洗过程

从字面上理解清洗就是把“脏”对象去除掉使其变成“清洁干净”的操作，因数据集成来源广泛，并且数据集中包含大量历史陈旧数据，因此不可避免的存在一些错误数据、属性缺失的数据以及相互矛盾的数据，这些不规范数据被称为“脏数据”。根据一定的规范对这些不满足要求的数据进行“清洗”，使其变得“干净”可用，这就是数据清洗的过程。

数据清洗的原理就是利用算法、构建模型、专家参与等方式，分析问题数据将其转换为满足完整性、一致性、有效性等数据质量要求的数据，从而达到提高数据质量的要求[10]，下面介绍数据清洗的原理如图 2.1 所示。

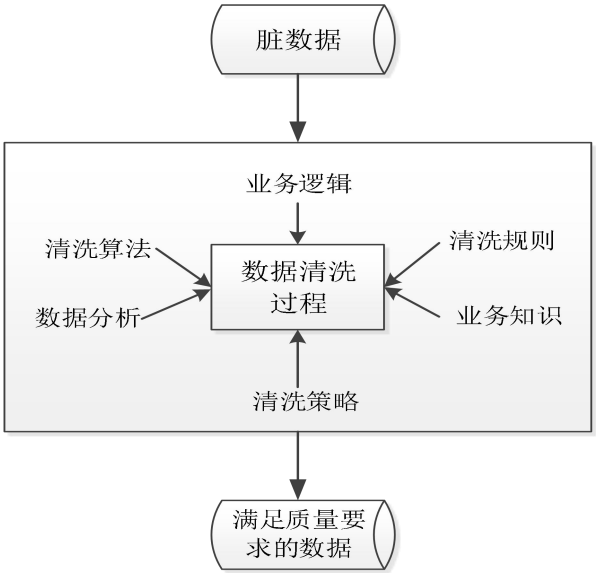


图 2.1 数据清洗过程原理图

衡量数据质量水平是否满足要求关键取决于数据的应用领域，需要结合领域知识对数据的重要性、对业务计划的影响综合考虑，判断数据是否满足可用条件。同时，关于某一个具体数据清洗指标 90%的准确率是好是坏的问题（因耗费的物资、

中国知网 https://www.cnki.net

人力、资源等因素过大），并没有一个统一的书说法（因耗费的物资、人力、资源等因素过大），只有将数据的准确率指标没有达到100%所带来的负面影响量化，才能做出是好是坏的判断，在本论文中关于量化数据质量的细节不做详细介绍，暂不考虑损耗等问题。

数据清洗过程可以分为以下几步：

1、数据分析过程：为了保证数清洗的效果，就需对数据进行分析确定数据存在的问题，可以采用手工检查、采样以及程序自动检测等方式实现数据分析过程。

2、制定清洗规则：参考数据分析结果，综合专家相关领域知识，制定出清洗策略。

3、数据校验和量化：在对海量数据进行大规模的清洗之前，可以先从中选取样本数据进行清洗，通过对清洗结果进行校验来检测所选取的清洗策略的效果是否能够满足要求，若不满足就需要重新确定清洗方案或者对相关策略进行改进。

4、数据清洗过程：结合清洗预先设定的规则与策略，根据选定的清洗算法，编码实现其算法流程。

5、干净数据的回流：将清洗后所得 “干净”记录替换掉系统中的“脏数据”，避免重复检测浪费系统资源，清洗后的“干净”数据可以用来进行下一步得数据分析、数据挖掘、知识库挖掘等。关于数据清洗过程的总体流程如下图 2.2 所示。

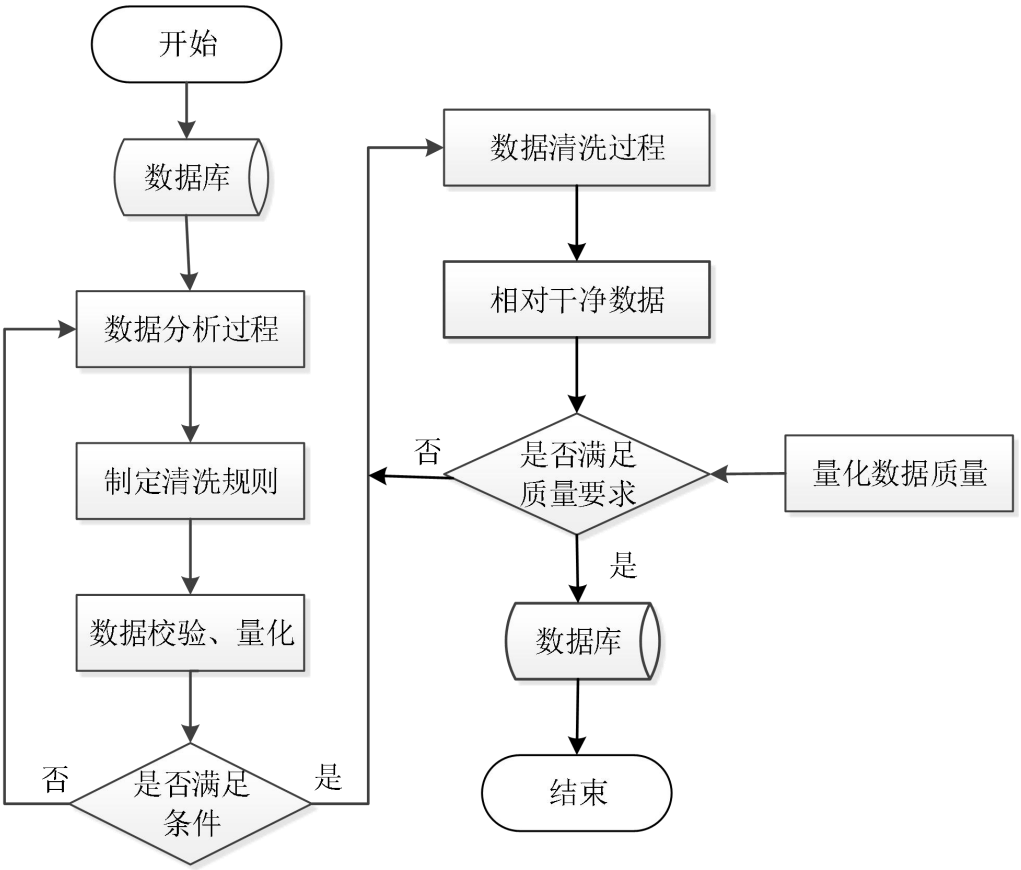


图 2.2 数据清洗总体流程图

中国知网 https://www.cnki.net

2.2 相似重复记录清洗

相似重复记录分为两大类，一类是完全一致的记录，另一类是相似但不是完全相同的记录。其中衡量完全重复记录的标准是：在数据集中，各个字段的值是完全相同的，这里的字段考虑主键这一属性，因为个别设计模式差的数据库中是没有主键的。相似重复记录指的是那些指向同一个实体的记录，但在系统中因为各种各样原因造成记录之间存在一定差异，在系统中不能有效自动判定、识别为同一的记录。通常情况下，相似重复记录是指以上两大类数据的统称，如下表 2.1 所示的三条记录均为相似重复记录。

表 2.1 相似重复记录实例

产品品牌	产品型号	产品体积	产品颜色	出厂日期
X	BCD-123	912x714x1756 mm	红色	2017.06.01
X	BCD-123	912x714x1756 mm	中国红	2017-06-01
X	BCD123	912x714x1756 mm	红色	20170601

2.2.1 字段相似检测算法

关于字段相似性的匹配需要首先需要区分字段所属类型，通常意义上，字段类型一般分为布尔型、数值型和字符型。

定义 2.1　布尔型字段相似度

$$Sim(x_1,x_2)=\begin{cases}100\% & (x_1=x_2)\\ 0 & (x_1\neq x_2)\end{cases}$$ 公式 3-(1)

其中 $Sim(x_1,x_2)$是表示两字段的相似度，x_1 和 x_2 是两个布尔类型的字段。简单来说，布尔型字段匹配中两字段相同则相似度为 100%，否则为 0；数值型的字段匹配过程一般通过比较两数值之间的相对差异来判断两者是否相似；具体定义如下：

中国知网 https://www.cnki.net

定义 2.2　数值型字段相似度

$$\mathrm{Sim}(x_1,x_2)=\left(1-\frac{|x_1-x_2|}{\max(x_1-x_2)}\right)*100\% \qquad \text{公式 3-(2)}$$

其中 $\mathrm{Sim}(x_1,x_2)$表示两字段的相似度，x_1、x_2 是待测的数值型的字段，该定义能够有效地计算数值间的相似度，当 x_1 和 x_2 的绝对差异越大时，对应的 Sim 越小。

字符型的字段匹配过程采用模糊匹配方式，其具体选择的匹配算法主要取决于字符串的类型，特别是在中西文不同语言环境情况下，字符匹配算法的准确率存在较大差异，接下来简要介绍常见的字符串相似度算法，具体算法适用情况第三章基于属性的相似重复记录检测算法会有详细介绍。

定义 2.3 余弦相似性

$$\mathrm{Sim}(x,y)=\cos(\theta)=\frac{x\cdot y}{\|x\|\|y\|}=\frac{\sum_{i=1}^{n}x_i y_i}{\sqrt{\sum_{i=1}^{n}x_i^2}\sqrt{\sum_{i=1}^{n}y_i^2}} \qquad \text{公式 3-(3)}$$

其中，x,y 是两个带比较的字符串。

定义 2.4　欧氏距离

$$d(p,q)=d(q,p)=\sqrt{(q_1-p_1)^2+(q_2-p_2)^2+\cdots+(q_n-p_n)^2}=\sqrt{\sum_{i=1}^{n}(q_i-p_i)^2} \qquad \text{公式 3-(4)}$$

其中 p 和 q 是定义在向量空间模型中的向量。

2.2.2 相似重复记录检测算法

当前，在记录判重方面的算法有：滑动窗口算法[11]、基于聚类的算法[14]、采用距离函数模型的方法[15]、字段匹配算法[12]、递归的字段匹配算法[13]等。这些算法可以分为两大类：第一类是用于记录之间的相似匹配算法，另一类是记录内基于属性的相似匹配算法。目前，第一类算法研究主要是基于“排序&合并”方法是热门领域，如:滑动窗口算法、优先队列算法[16]等；对第二类算法的研究普遍都是对字符串相似匹配算法[17]的直接引用。但是识别相似重复记录时，因不能确保可能相似重复

中国知网　https://www.cnki.net

的记录一定被排在邻近的位置，这就使得“滑动窗口聚类”和“优先队列聚类”不能取得较好的效果。

1．数据预处理阶段

数据预处理主要是对数据表达形式进行格式化，通过标准化转化数据格式，为接下来数据排序进行准备工作。

2．记录排序阶段

在数据量比较大的情况下，相似重复记录的检测是一个非常费时费力的操作，为了减少记录之间的比较次数，提高检测效率，通常采用的方法是按照一定的键值对记录进行排序，这种方法更适用于西文为主的数据集。本文的研究数据主要是针对工业大数据进行的，仅根据键值进行排序不能确保所有相似重复记录在位置上都相邻，本文采用综合排序的方法对记录进行排序操作，具体方法如下：

假如数据是英文字符，排序是按照字典序进行的；若数据是中文汉字，则汉字的偏旁部首、汉语拼音、字母表排序等都不适合作为键值进行排序。这里可以采用汉字的编码进行，构建该领域的数据字典，对于要排序的字段，将相应的字符转化为字典中的对应数值，然后在采用快速排序方法对数据集进行排序，这种方式能尽最大可能把可能构成相似重复的记录划归在位置上相邻，达到提高检测效率的目的。但这种方法也存在不少问题，其仅适用于数据量不大且对数据准确率要求较高的情况下。

3．相似重复记录识别阶段

选择合适的算法，对可能构成相似重复的记录进行判重处理，具体算法的选择在第三章详细介绍。

4．记录合并阶段

相似重复记录进行排序操作后，确定为重复的记录进行相应处理，处理方式有：一是删除重复记录，其中删除的规则有：选取数据最完整的记录保留，剩余的记录删除；选取其中最近一次更新的数据保留，其余的删除；直接指定某条记录保留。二是将每条信息看做是完整记录的一部分，这样完整记录的还原就需要整合每组相似重复记录，这样产生的新纪录具备更完整的信息。

2.3 缺省值清洗

工业信息化进程中，数据库系统中属性缺失的现象普遍存在。数据空缺在数据挖掘领域是一个相对较复杂的问题，空缺值的存在不仅使系统丢失大量的有用信息、系统的不确定因素显著增加，还会造成数据挖掘过程程序混乱，产生不可靠的、错误的输出，更可能这些数据在以后的使用中引发决策错误。这里所说的缺省值不仅

中国知网 https://www.cnki.net

仅包括数据库中的 NULL 值，也包括个别数据库中表示数据缺失的特殊值（例如，在系统中常用-999 表示该数据不存在）。

空缺值的分类方法有很多种，其中根据形成因素不同，可以分为人为原因和非为人原因（也称机械原因）两种。非人为指由机器和收集设备造成的数据收集缺失、数据未存储等。人为原因则主要是由于相关人员的工作失误刻意隐瞒事实造成的数据缺失。根据数据的客观来源空缺值可分为：1，不存在型空缺值，也就是表示该属性的取值是无法获取的，例如：正在使用的冰箱的使用寿命。2，存在型空缺值，表示某属性的取值是非空的，但是目前不能获知，例如某冰箱的出厂日期。3，占位型空缺值，即无法确实是以上两类中的哪一类，但随着时间的推移可以确定。

2.3.1 缺失值清洗算法总体描述

在数据清洗操作中中，对于缺省值的清洗步骤一般概括为以下步骤：

1、检测不完整数据

检测过程需要从数据集中将具有缺失属性的记录检测出来。

2、判断数据的可用性

根据缺省值的价值性，记录中该属性的缺失情况等多方面，决定数据是否可用，对于可用的记录进行下一步。

3、缺省值的填充

通过属性间相互关系、数理统计、机器学习等手段推断出缺失数据的可能取值。

2.3.2 缺失字段处理方式

目前，对于具备缺失字段的数据处理方式有两类：

第一类：直接删除记录，也称为忽略元组法，就是将存在属性缺失的记录删除掉，这种方法简单易行。但仅适用于具有缺失属性的记录所占总数据源的比重非常少的时候适用，绝大多数情况下，直接删除记录会导致大量资源浪费，进而导致错误结论。

第二类：数据补齐法，也称为数据填充法，就是根据数理统计或分类方法对某一空缺值进行填充，使该记录完整，并在后续的分析中可用。基于数理统计的填充法有：人工补齐、平均值补齐、众数补齐等，其中经常使用的是基于平均值的填充方法；基于分类方法的填充方法有：基于 KNN（K-Nearest Neighbor，K 最近邻）算法的补齐方法、基于贝叶斯网络的补齐方法、基于神经网络的补齐方法等，其中 KNN 算法是基于类比学习发展而来的一种填充方法。

中国知网 https://www.cnki.net

平均值填充法：数值类型的缺失，则需要根据缺失属性其他记录的平均值来进行补齐、填充；若缺省值不是数值类型的，则需要根据已有记录在本属性上出现频数最高的字符进行填充。

基于 KNN 算法的填充算法：该算法是用最邻近的记录的平均值代替缺失值，具体实现是将训练样本 n 维数字化之后，给定一个样本数据 S，取该样本的 k 个最近邻数据中的该属性的平均值对缺失属性进行填充。

2.4 离群点清洗

对数据集进行分析的过程中，经常发某些“不合群”的数据，这些数据显著偏离数据集中的其他数据，也可以理解为远离序列的平均水平的极端值，这种极少出现的数据点就是异常点[18]。离群点的形成受到来自系统外部各种各样的干扰，首先在数据取样过程中产生误差，其次如果被研究现象本身受一些偶然因素作用而引起的干扰，以时间序列的某地区人口死亡数据为例，因为某年该地区发生了地震，使得本年度内死亡人数剧增，形成离群点；在基金价格序列中，因为国家某一政策的出台，都可能出现价格幅度极大或者极小等情况，使得产生离群点。

离群点与噪声点不是两个等同的概念，通常现实世界的可见的数据是由真实数据和噪声共同作用产生的，离群点可能由真实的数据产生，也可能由噪声带来。概括来说噪声是被检测数据的随机误差，而离群点则是数据集中不符合模型或者不符合一般行为不一致的数据[19]。一般情况下不能说噪声包括离群点，虽然在大部分数据分析的过程中，离群点视为噪声或者异常数据进行丢弃操作，但是在一些类似诈骗检测、信用卡套现等特殊领域的数据挖掘方面，就需要针对离群点进行深层次的分析检测或者异常挖掘。

目前已有的技术基本能够检测识别出不同于其他数据对象的离群点，本文接下来会介绍了目前常见的离群点检测技术及其适用环境。

2.4.1 基于统计的离群点检测

基于统计分析的离群点检测算法又称为基于分布的算法，在统计领域较为常见的一种方法[20]，该方法是通过数理统计的方法，利用监督、半监督或者无监督的方式对样本数据进行训练，找到适合样本空间数据服从某一分布，然后根据模型对数据集中的每个点进行检测，如果某一数据点不符合假设模型分布，那么该数据点很可能就是离群点。

基于数理统计分析的离群点检测办法的不足之处在于：一方面该方法必须事先假定适合数据集的分布模型是存在的，其具备极大的不确定性，因很多数据集可能

中国知网 https://www.cnki.net

不满足标准的分布，不能用某一单一模型直接表示，如果采用多个概率模型来建模也会带来极大的误差；另一方面该方法对于大多数检测是在处理单维数据的，并不适用于多维数据。

2.4.2 基于距离的离群点检测

基于距离的离群点检测指的是：文献[21]对基于距离的离群点检测的概念做了进一步的明确规定，首先遍历整个数据集，查找每个数据点的 k 个最近邻的数据点，计算该数据与 k 个近邻点间的距离长度并进行排序，距离之和较大的几个数据点就很有可能是离群点。

基于距离的离群点检测方法的不足之处在于：该方法对数据的分布情况是有要求的，仅能接受均匀分布的情况，若分布不均匀，则基于距离的离群点检测算法不再适用。

2.4.3 基于聚类的离群点检测

如果某一数据对象不隶属于聚类后的任何一个类簇，则该数据对象就是基于聚类的离群点。其中聚类方法是对数据集合进行分组的过程，聚类后生成的组称为类簇，类簇简称簇，其是许多个数据记录的集合。聚类分析的过程用于发现局部强相关的对象组，而异常检测用于发现不与其他对象强相关的对象。

聚类过程一般包括聚类前的数据处理阶段、特征选择及提取阶段、计算距离阶段、聚类法分析阶段、结果有效性分析阶段等过程，聚类过程的总体流程如下图 2.3 所示：

中国知网 https://www.cnki.net

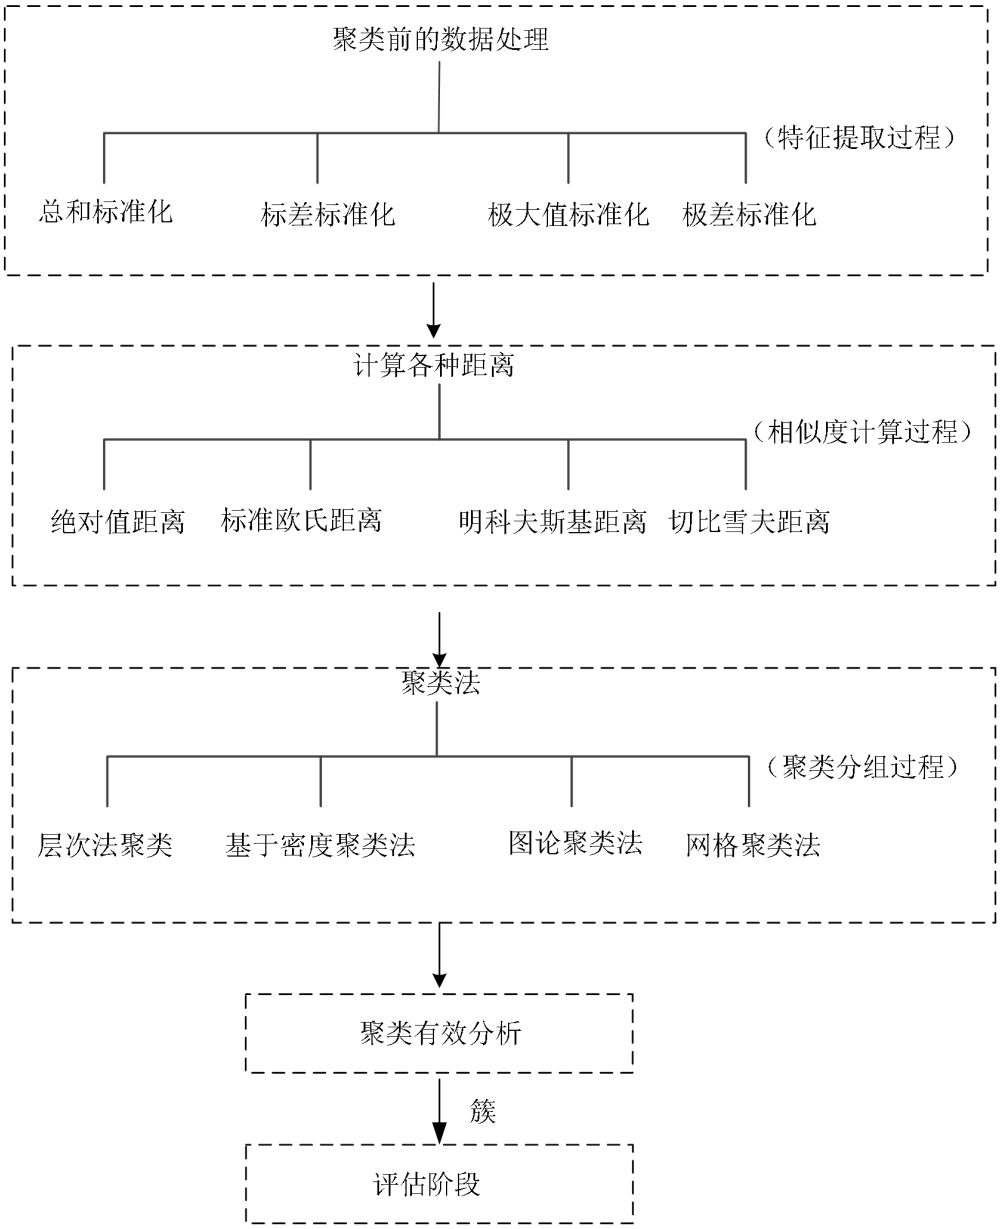


图 2.3 聚类分析过程

基于聚类方法的离群点检测算法不足之处在于：某一数据对象经过处理是否被认定为离群点可能高度依赖于簇的个数。这里提供两种解决办法：一种是改变簇的个数重复检测分析，另一种是聚类得到大量小簇，此时若存在离群点，则该数据点多半真的是一个离群点。

中国知网 https://www.cnki.net

2.5 本章小结

本章对数据质量、数据清洗基本理论做了介绍，其中包括数据质量的定义、质量问题的分类、数据清洗的定义、清洗的基本过程，然后介绍了实例层的各种影响数据质量的问题分类，进而介绍了相应的数据清洗策略，其中包括相似重复记录、缺失值、离群点等常见清洗算法。本章节在对相似重复记录的检测算法总体流程做了详细的描述，将相似重复记录的检测过程细化为对字段的匹配过程以及对记录的匹配过程，为第三章中对相似重复记录的检测和识别奠定理论基础。

中国知网 https://www.cnki.net

第三章 相似重复记录清洗方案

相似重复记录的检测过程也称为相似重复记录的识别，相似重复记录检测是从多源数据集中识别出表达现实世界同一实体的记录。目前关于相似记录的检测主要有三大类：第一类是基本的字段匹配算法，即将两个字段划分为多个原子字符子串，通过计算原子串的匹配个数，计算记录的相似匹配程度；第二类是基于编辑距离的相似重复记录匹配算法，该算法主要是利用数据记录间属性的相似性，从而判断记录间的相似性；第三类是基于排序和滑动窗口的记录匹配算法，对记录进行判重操作，这类算法主要有：邻近排序（sorted Neighborhood）算法、聚类算法等。

3.1 典型的数据清洗方案

本论文的第二章对数据清洗已经进行了比较全面的介绍，对数据清洗已经有了比较清晰的认知，一个典型的数据清洗系统主要应该由以下几个部分构成：

1、数据源：用于存放数据集的数据库、数据表等构成。

2、数据源服务器：负责根据用户需求，提取相应的数据进行下一步操作。

3、数据预处理：对数据结构和组织进行格式统一，为后续清洗操作做准备。

4、知识库：存放的用于数据清洗的各种规则。

5、数据清洗引擎：数据清洗系统基本组成部分，用于对数据进行分析、进行数据处理等功能。

3.2 相似重复记录清洗模型

对相似重复数据进行数据清洗分为以下步骤进行：首先是数据的输入，对输入的数据进行预处理，预处理过程包括属性的选择、记录初步聚类、为各属性分配权重等；然后分析数据特征选择合适算法对相似重复记录进行检测，重复记录识别过程可细分为字段匹配过程和记录匹配过程，记录归并过程是对整个数据集中检测出的相似重复记录进行聚类；满足条件结果输出包括冲突解决过程，即根据一定的规则将检测到的相似重复记录进行合并或者删除，仅保留一条数据的过程。具体清洗模型过程如图 3.1 所示。

中国知网 https://www.cnki.net

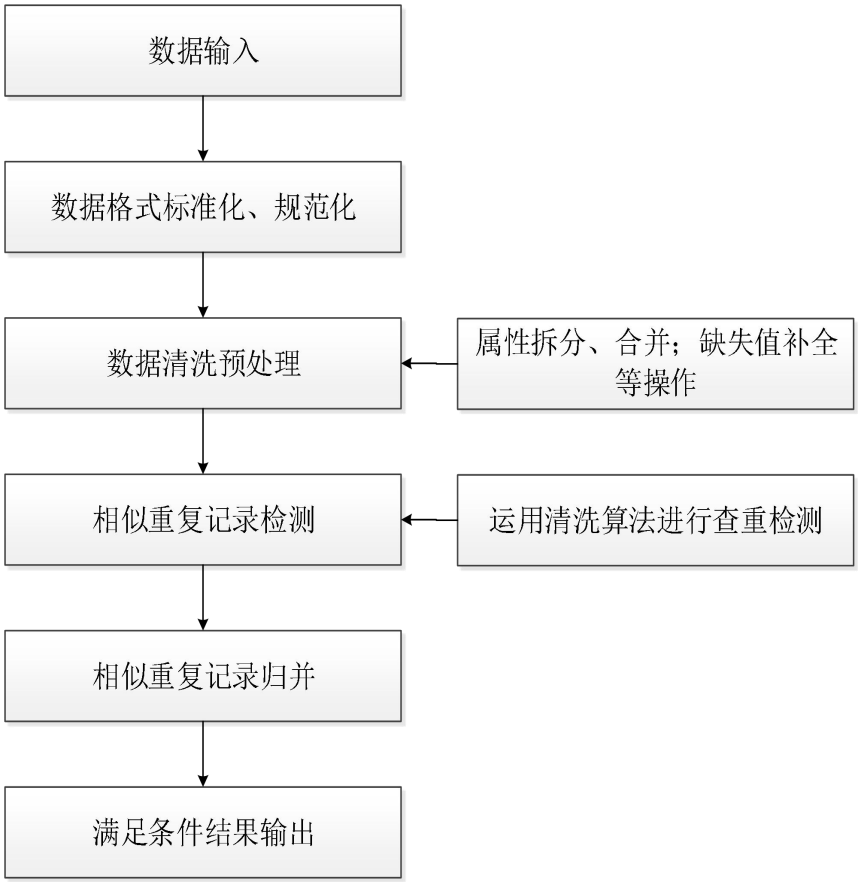


图 3.1 数据清洗过程图

3.3 数据预处理过程

3.3.1 属性选择及格式统一

1、属性的选取

一般情况下，在进行记录匹配之前，首先需要对属性进行特征选择，特别是在属性较多的情况下，其过程应尽可能选取具有代表性的属性参与记录判重匹配。在属性选取过程中，尽量避免选取冗余属性、取值严重缺失的属性、取值固定的属性等不具备记录标识度的属性。

2、对属性取值标准化

进行预处理的过程需要将部分取值表现形式各异的数据进行统一数据格式标准化。比如时间属性的取值表现形式各异，则需要对 2018-01-01、2018/01/01、20180101、2018/01/1、2018.1.1 等格式进行标准化，这里的时间表示标准化预处理将关键字进

中国知网 https://www.cnki.net

行统一规范，统一格式为 ISO 8601[W3CDTF]规范，使用 YYYY-MM-DD 的格式，如：2018-01-01。

3.3.2 记录排序

仅从准确率和召回率考虑，相似重复记录识别的直观办法是:逐一地对比每一项记录与数据库中其余记录进行逐一比较，这种方法的优点是精准度高，能确保找到所有相似重复记录，但缺点是在数据量大时效率低下、处理时间长。在数据量比较大的情况下，为了在有限的时间内完成重复记录的检测，同时还要确保较高的查准率和查全率，这就要求在进行相似匹配前，必需采用某一算法或方式把潜在的相似重复记录调整至位置上相邻，目前记录排序一般采用以下几种方式：

1、按照属性关键字将整个数据集进行排序操作

选取记录的某一属性作为关键字（Key），根据选取的关键字对整个数据集进行排序操作，尽可能使得潜在的可能够构成相似重复记录的属性能够在位置上相邻[12]，该方法的缺陷是排序结果过分依赖关键字，当关键字选取不当的情况下，会造成相似重复记录不在邻近范围内，不能参与匹配，不能被识别、判重。

2、基于 N-Gram 方法的排序方法

基于 N-Gram 方法基本思想是：通过记录本身的内容和参考全局统计信息，给每条记录分配一个 N-Gram 值，并以该数值作为 key 值对记录进行排序[27]，其中 N-Gram 赋值过程中，尽可能确保相似程度更高的记录对应其 N-Gram 取值也要更接近，这样才可以确保以 N-Gram 值作为 Key 值进行排序操作后，将可能构成形似重复记录在位置上邻近。这一方法的缺陷是仅适用于较小的字母表，西文字符可以适用该方法，但对中文不适用。

3、改进的基于关键字排序方法

根据传统的基于关键字的排序算法对关键字的选取异常敏感的问题，本文在排序前对关键字进行部分改进：

① 对关键字进行格式规范统一。

② 对关键字执行必要的拆分与合并操作。必要时可将关键字分割为各个子字符串。

对关键字进行简单处理操作，在一定程度上增加构成相似重复记录的数据在位置上邻近的可能性，从而使其增加被检测到的概率。

3.3.3 属性综合权重分配

传统的编辑距离求解过程中，各属性对记录的标识的贡献度是相同的，各属性默认设置固定权重的方式必将影响记录判重效果，针对传统方法的编辑距离求解不

中国知网 https://www.cnki.net

足之处本文提出一种非领域性的设置综合权值的方法：结合客观的数理统计以及主观的专家经验[22]，综合考虑单个属性值对记录的贡献度的不同，赋予属性不同的权值，其基本思路如下：

（1）一般情况下，在数据集合中，某一属性的值域范围越大，基于该属性的记录之间的差异性就应该越大，该属性在判重中贡献度也就越大，相应的该属性在记录标识方面的权重就越大。因此在计算两条记录之间相似度之前，可进行多次取样操作，根据样本数据求得各个属性的值域范围（连续型和离散型），并列出统计表3.1 如下图所示。

表 3.1　属性取值种类统计表

取样次数	属性种类						
	属性 1	属性 2	属性 3	…	属性 j	…	属性 m
1	Y_{11}	Y_{12}	Y_{13}	…	Y_{1j}	…	Y_{1m}
2	Y_{21}	Y_{22}	Y_{23}	…	Y_{2j}	…	Y_{2m}
…	…	…	…	…	…	…	…
i	Y_{i1}	Y_{i2}	Y_{i3}	…	Y_{ij}	…	Y_{im}
…	…	…	…	…	…	…	…
n	Y_{n1}	Y_{n2}	Y_{n3}	…	Y_{nj}	…	Y_{nm}
属性种类总数	Y_1	Y_2	Y_3	…	Y_j	…	Y_m

表中数值 m 表示记录中共有 m 个属性，n 则表示进行 n 次取样操作，其中，$Y_{ij}(1 \le i \le n, 1 \le j \le m)$ 表示第 i 次取样操作第 j 个属性出现的次数，用数理统计算法中的求和取平均方法生成各属性最终种类数 Y_j，即 $Y_j = \frac{1}{n}(Y_{1j} + Y_{2j} + \cdots + Y_{ij} + Y_{nj})$ 将 $Y_1 \sim Y_m$ 从小到大进行排序，令 Y_1 对应的属性 1 是在多次样本检测中值域范围最小的属性，Y_m 则对应属性 m 为值域范围最广的属性，对各属性 1 至 m 重要性评价指标定义为 1 至 m， 数值 1 表示该属性对记录的辨识度、贡献度最少；m 则表示该属性对记录的辨识度和贡献度最大，具体属性贡献度统计表如下表 3.2 所示。

表 3.2 属性贡献度统计表

属性名称	属性 1	属性 2	属性 3	…	属性 j	…	属性 m

中国知网 https://www.cnki.net

贡献度	1	2	3	…	j	…	m

（2）结合领域知识、根据专家经验为各属性进行贡献度等级分配，范围为 1 至 m 不可重复的正整数，对各属性指定的等级的过程重复多次，避免个人因主观臆断影响等级分配，具体等级表如下表 3.3 所示。

表 3.3　属性经验等级表

专家取样次数	属性取值						
	属性 1	属性 2	属性 3	…	属性 j	…	属性 m
1	G_{11}	G_{12}	G_{13}	…	G_{1j}	…	G_{1m}
2	G_{21}	G_{22}	G_{23}	…	G_{2j}	…	G_{2m}
…	…	…	…	…	…	…	…
i	G_{i1}	G_{i2}	G_{i3}	…	G_{ij}	…	G_{im}
…	…	…	…	…	…	…	…
n	G_{n1}	G_{n2}	G_{n3}	…	G_{nj}	…	G_{nm}
经验等级	G_1	G_2	G_3	…	G_m	…	G_m

表中数值 m 表示记录中共有 m 个属性，n 则表示专家取样次数为 n 次，其中，$G_{ij}(1 \le i \le n, 1 \le j \le m)$ 表示第 i 个专家取样第 j 个属性指定重要性等级，最终经验等级 G_j 是对各属性等级取平均的方法求得即 $G_j = \frac{1}{n} * \sum_{i=1}^{n} G_{ij}$，$G_j$ 表示第 j 个属性的最终经验等级。

（3）关于属性综合权值的确定，依据上述过程的数理统计和专家理论，某一属性的贡献度越大、等级越高、权值越大，其在判重中的作用就越大。下面通过属性综合加权法以及归一法将客观的数理统计结果及主观的经验等级相结合，得到综合属性权值，公式如下所示。

中国知网　https://www.cnki.net

$$W_j = \frac{1}{2}\left(\frac{Y_j}{\sum_{j=1}^{m} Y_j} + \frac{G_j}{\sum_{j=1}^{m} G_j}\right)$$

公式 3-(1)

将记录各属性的综合权值 W_1~W_m 按照从小到大的顺序进行排序操作，这里的 W 为权值评定方法确定的综合属性权重。

3.4 重复记录检测

在许多应用领域，数据库上的重复记录的匹配检测往往与编辑距离的计算相结合。编辑距离算法是常见的用于比较记录相似度的测量算法[23]，文献[24]把整条记录看做一个长字符串，根据 字符串的编辑距离对两条记录是否为相似重复记录进行判断，这种算法对属性缺失反应敏感。文献[25]中是分别计算各属性字段的编辑距离，通过字段的编辑距离计算记录的总编辑距离从而来判断记录是否为相似重复记录。

编辑距离算法是计算字符串之间匹配程度的常用算法，编辑距离计算过程包括字符的增（插入）、删（删除）、改（替换）等，任意两个字符串 a，b 的编辑距离表示为 edit（a,b），换句话说，edit（a,b）描述的是利用插入、替换、删除等操作把字符串 a 与字符串 b 相互转化需要的最小代价数。

但已知编辑距离算法依然存在问题：一方面编辑距离算法仅考虑了字符串的编辑次数，没有考虑不同数据源的属性缺失、异名属性对距离计算过程的影响；另一方面编辑距离算法是针对西文字符提出的记录相似度度量算法，中文则是典型的非字母语言，因没有考虑词语之间的交换以及词语的同义替换等灵活操作问题[26]，所以在中文中不能适用简单的编辑距离算法。基于以上问缺陷本文提出了编辑距离改进算法，其融合了模式编辑距离、中西文字符串的差距，对记录相似度进行求解。

3.4.1 字段匹配算法

1、模式编辑距离

在数据集成过程中，由于数据来自于不同，存在语义表示不一致、拼写等不可避免的问题，造成记录匹配时出现两条记录的属性个数不一致的情况，这就是属性

中国知网 https://www.cnki.net

缺失现象[27]。举例说明记录 M 具有五个属性{型号，名称，类型，智能，备注}，对应的属性值分别为{BS22，容声，多开门，智能，银色风冷}，记录 N 具有四个属性{型号，名称，类型，备注}，对应的属性值分别为{22BS，容声，三门，风冷银色}，N 记录中明显缺失是否支持智能这一属性。此时若直接将缺失属性的取值视为缺省值（默认值），则需要执行编辑距离中的替换操作计算两条记录之间的编辑距离；若将缺失属性视为空值，则需要执行插入操作来计算编辑距离，一般情况下，替换和插入操作的代价是不相同的。这种情况，就需要参考两条记录中的非缺失属性的相似度来确定缺失属性是否参与该记录的相似重复性计算。

若记录中的除缺失属性外的其他属性的相似度均接近 1 或者 0，则该属性赋予有效因子为 0，即该属性是无效的，对记录判重的贡献度为 0，有效因子为 0，即不参与判重。

若非缺失字段的相似度不接近 0，也不接近 1，为该属性赋值为 1，参与相似度的计算，根据数理统计和主观的专家经验结合的方式确定各个属性的综合权值[13]，此时该属性的有效因子为 1。

2、字符串编辑距离

Levenshtein 首次提出字符串编辑距离这一概念，该方法也被称为 Levenshtein Distance[28]。编辑操作有“插入”、“删除”、“替换”三种[29]。编辑距离反映了字符串之间的绝对差异大小[30]，其中编辑距离越大，则说明两字符串之间转化需要的操作越多，两次字符串的相似度就越小。通常情况下，每个编辑操作会被分配不同代价值，假设字符串 A、 B 编辑距离为 edit（A，B），其中 edit（A，B）的取值范围为 $edit(A, B) \in \left[\left|L_A - L_B\right|, \max(L_A, L_B)\right]$，$L_A$ 和 L_B 分别表示字符串的长度大小，相似度的计算方式则为 Sim（A，B）=1- edit（A，B）/max（L_A，L_B）。

接下来给出考虑编辑代价的编辑距离计算公式：edit（i，j）：两字段的编辑距离运用动态规划方法得到：

if i == 0 且 j == 0，edit（i，j）= 0

if i == 0 且 j > 0，edit（i，j）= j

if i > 0 且 j == 0，edit（i，j）= i

if i >= 1 且 j >= 1，edit（i，j）

$= \min\{\text{edit}(i-1, j)+C_1, \text{edit}(i, j-1)+C_2, \text{edit}(i-1, j-1)+C_3\}$ 其中，C1 表示字符串删除操作的代价值，C2 表示插入操作的代价值，C3 表示替换操作的代价值。在不考虑代价的情况下，上述公式可以改写成

中国知网 https://www.cnki.net

$\min\{edit(i-1,j)+1, edit(i,j-1)+1, edit(i-1,j-1)+f(i,j)\}$ 当字符串 A 的第 i 个字符与字符串 B 的第 j 个字符相同时，f(i,j)=1,否则 f(i,j)=0。

但在中文中的某些表达方式，使用上述传统的编辑距离算法计算时会得出错误的结果，例如：字符串 A=“风冷光控”，B=“光控风冷”，若使用传统编辑距离算法求解的编辑距离为 4，相似度为 0，然而实际上 A 和 B 表达的是相同的意思，所以在这种情况下，就需要针对编辑距离计算公式的缺陷进行相应的改进。

if i >= 1 且 j >= 1 且 $a_i=b_{j-1}$ 且 $a_{i-1}=b_j$，edit（i，j）=

$\min\{edit(i-1,j)+1, edit(i,j-1)+1, edit(i-1,j-1)+1，edit(i-2,j-2)+1\}$ 当字符串 A 的第 i 个字符与字符串 B 的第 j 个字符相同时，f（i，j）=1,；否则，f（i，j）=0。

通过传统的编辑距离算法的扩展，添加了交换操作，该操作在中文中应用范围较广，也可以在一定程度上解决异名属性的问题。文献[31]中详细给出了添加“数据字典”来解决异名属性的解决方法，其中主要通过属性阈值范围判断是否为同一属性。针对上述例子，运用改进公式算法求得编辑距离是 1，其相似度为 1-1/4=0.75，能够更加准确的反应字符串的相似程度。在很多情况下，型号或者编号等对英文、数字比较敏感的属性值，应该选择传统的字符串编辑距离算法；当属性值以中文为主，且对词序要求不高的时候，应选择改进后的编辑距离算法。

3.4.2 记录匹配算法

在进行记录匹配前，首先需要采用字段匹配对各个字段进行相似度计算，然后根据字段在记录标识方面的贡献度，求得记录间的相似度，再将求得的相似度与事先规定的某一阈值相比较，若其大于阈值，就说明这两条记录的匹配程度较高，基本可以判定为相似重复记录，反之，则认定记录是指向不同现实实体的记录。

3.4.2.1 记录匹配的定义

记录相似度的定义：假设关系表中现有字段 F[1]，F[2]，…，F[n]，对应权重分别为 W[1]，W[2]，…，W[n]，给定记录 R_1 和 R_2，令 $SF_{(R1,R2)}[1]$，$SF_{(R1,R2)}[2]$，…，$SF_{(R1,R2)}[n]$为记录 R_1 和 R_2 各字段相似度，则记录的相似度 SR 计算公式为

$$SR(R_1,R_2)=\frac{\sum_{i=1}^{n} SF_{(R1,R2)}[i]*W[i]}{\sum_{i=1}^{n} w[i]}$$

公式 3-(2)

中国知网 https://www.cnki.net

由上述公式可知，属性缺失是造成相似度差异较大的一个重要因素。为了尽可能消除因属性缺失造成的相似重复记录误判的情况，本文提出属性选择的概念，通过设置有效权值的概念，对参与比较的记录 R_1 和 R_2，上述公式可改进为：

$$SR(R_1,R_2)=\frac{\sum_{i=1}^{n}V(i)*SF_{(R1,R2)}[i]*W[i]}{\sum_{i=1}^{n}V(i)*w[i]}$$

公式 3-(3)

其中 V(i)取值范围为非 0 即 1，当第 i 个属性上的值均非空时，V(i)取值为 1，即该属性为有效属性可以参与记录判重，否则，V(i)为 0，该属性不能参与判重。该方法能够有效的避免因属性缺失造成的相似重复记录之间的差异性，同时能够减少不必要的属性匹配，提高算法检测效率。

3.4.2.2 长度过滤优化算法

在异构数据库集成过程中，相似重复记录所占比例相对较少，绝大多数记录不是相似重复的，若直接进行记录匹配，则会造成资源的浪费。由前面上一节中详细介绍的编辑距离的求解过程可知：显然两字符串 x，y 编辑距离大小范围为 [|x-y|,max(x,y)]，则在不考虑贡献度的情况下，若两字符串编辑距离差别越大，那么其为相似重复记录的可能就越小，把那些长度小于某一阈值构成相似重复的记录的可能性极小的数据排除掉，可以有效缩小判重范围、减少比对次数、提高算法效率[41]。

长度过滤字符串的算法是根据两字符串的长度差距，找到可能构成相似重复的两条记录之间的长度范围的方法。假设 $Len(X)$ 、$Len(Y)$ 表示两字符串 X、Y 的长度，若 X 和 Y 之间的编辑距离为 k，则两字符串的长度之差最大不超过 k，即 $\left\|Len(X)\right|-\left|Len(Y)\right\|\le k$ 。

记录的长度过滤方法是基于以上字符串长度过滤定义可知，在计算各字段的编辑距离前，可以先通过长度过滤的办法进行筛选，可以有效减少不必要的编辑距离的计算，本文综合多种因素考虑、结合实验证明当两字符串的长度差比超过 0.6 时，即 $Len(Y)/Len(X)\le 0.6$(假设$Len(Y)\le Len(X)$)时，认为两字符串之间不可能构成相

中国知网 https://www.cnki.net

似重复记录，通过实验数据说明，证明该阈值范围在没有明显降低算法查全率的同时提高了算法的运行效率。

3.5 重复记录聚类

常见的基于记录聚类的相似重复记录识别算法中发展比较成熟的有 SNM 算法、MPN（多重临近排序算法）算法以及 KNN（K-最邻近）算法等[32]。其中 SNM 算法是识别数据库中相似重复记录的标准办法，现已有的识别相似重复记录的算法多在此算法的基础上延伸而来[33]。

3.5.1 SNM 算法工作原理

SNM 算法采用的基本思路是：利用一个排序函数对整个数据集中的数据按照关键字进行排序，这里的需要对提前选定的排序关键字进行预处理，在排序的基础上使得可能构成相似重复的记录在位置上相邻近，之后利用滑动窗口将记录匹配空间缩小化，使得相似重复记录始终处于窗口内，窗口中的第一条记录和剩余的记录进行匹配计算，之后当前窗口下移将第一条记录划出，下一条记录滑入，依次计算窗口内记录之间的相似度，通过与预先设定好的阈值比对来判断记录之间是否相似，完成检测[42]。该算法的窗口运动动过程图示如下图 3.2 所示。

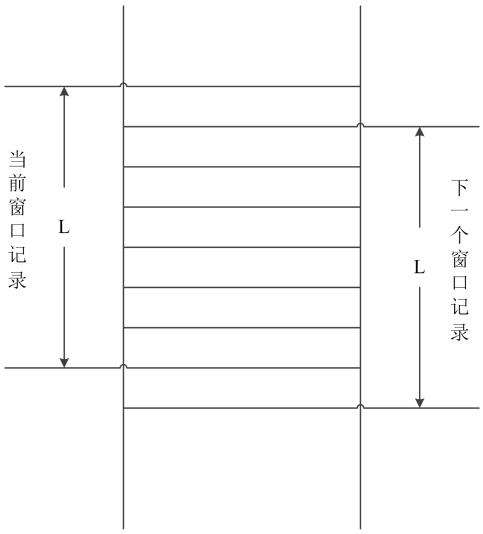


图 3.2 SNM 算法窗口活动示意图

假设数据记录数为 N，则记录间进行笛卡尔积两两比较的次数为（N-1）!，SNM 算法能将记录匹配次数由 N*N 降低为 W*N（其中 W 为固定窗口的大小），W 是远远小于 N，这样能够有效降低记录的比较次数，提高运行效率。

中国知网 https://www.cnki.net

3.5.2 SNM 算法分析

SNM 算法虽然提高了检测效率，但还是存在以下缺点：

1、排序关键字的选取能够直接影响排序结果，因其窗口内的记录是根据 key 值排序后相邻的记录，若关键字的选取不当，可能直接导致相似重复记录在位置上不相邻，即不在窗口内则会造成相似记录不能被识别；

2、滑动窗口的大小 W 固定且难以控制，并且不能伸缩。W 的取值直接影响记录的比对次数，若 W 取值较大则会造成多余的比较，即不可能构成相似重复记录之间进行了比对，若 W 取值过小则会造成相似重复记录不同时出现在窗口内，引起记录的遗漏现象；

3、数据集成过程中若出现部分属性缺失的现象，那么该属性的相似度为 0，则记录之间的相似性判定可能会因达不到阈值而会造成误判。

针对传统的 SNM 算法的在异构数据集成过程中的不适应性，若能够在识别初期能够把构不成相似重复的数据排除在外，这样就可以大大降低比对的次数，提高算法效率。现对传统 SNM 算法进行如下改进：

1、算法预处理过程

①. 选取排序关键字

分析数据特点，为后续算法排序做准备工作。

②. 对排序关键字标准化

传统的 SNM 算法过分依赖排序关键字的选取问题，处理办法是：可在排序前对数据格式进行统一化处理。比如某实验过程以时间序列作为排序关键字，则需要对 2018-01-01、2018/01/01、20180101、2018/01/1、2018.1.1 等格式进行标准化，这里的标准化预处理将关键字进行统一规范，统一格式为 ISO 8601[W3CDTF]规范，使用 YYYY-MM-DD 的格式，如 2018-01-01。

2、记录排序过程

根据关键字对数据集进行排序，该排序算法的过程时间复杂度为 O(nlogn)。

3、缩小比对范围

对传统的 SNM 算法中窗口固定的问题。利用可变滑动窗口的概念，根据数据集中相似重复记录存在的范围窗口滑动过程中进行动态调整，避免窗口过大造成的多余匹配的问题和窗口过小引发的漏匹配的问题。

4、相似重复记录检测过程

相似记录的检测过程采用合适的算法，根据字段的相似度可以计算整条记录的相似度。

中国知网 https://www.cnki.net

3.5.3 SNM 算法改进详细过程

基于滑动窗口的 SNM 算法存在一个问题，就是窗口的大小是实验人为估计且固定不变的。如若记录中包含的重复记录数超过了窗口的大小，因为记录的识别匹配过程是在窗口内进行，则有一些相似重复记录就不能被识别的；反之，如果窗口过小，在一个窗口内没有相似重复记录，算法就做了一些没必要的匹配工作。为解决这一缺陷，现将动态窗口取代固定窗口[34]。其中设计思想为：在数据集上设定一个固定的窗口解决算法冷启动问题，在窗口内相邻两条记录计算相似度，如对第一条数据和第二条数据计算相似度，第二条数据和第三条数据计算相似度再对第一条数据和最后一条数据求相似度，根据窗口内的记录数和记录相似度的差值来确定滑动窗口需要动态扩大还是缩小。

假设窗口的初始大小为 W，窗口包含 n 条数据，计算窗口内第一条记录 R_1 和第二条记录 R_2 的相似度 Sim（R_1，R_2），第二条记录 R_2 和第三条记录 R_3 的相似度 Sim（R_2，R_3），…，第 m 条记录 R_m 和第 m+1 条记录 R_{m+1} 的相似度 Sim（R_m，R_{m+1}），窗口内即将划出窗口的第一条记录 R_1 和最后一条记录 Rn 的相似度用 Sim（R_1，R_n）来表示。这里定义两条记录的差异值 Diff（R_1，R_2）=1- Sim（R_1，R_2），Diff（R_1，R_n）=1- Sim（R_1，R_n），前 m 条记录平均差异为

$$Diff(R_m)=\frac{1}{m}\left\{Diff(R_1,\ R_2)w_1+Diff(R_2,\ R_3)w_2+\cdots+Diff(R_m,\ R_{m+1})w_m\right\}$$

公式 3-(4)

这里 m<<n，w 的取值参考加权移动平均的概念，取 $w_1<w_2<\cdots<w_m$，其中 $w_1+w_2+\cdots+w_m=1$。

If $Diff(R_1,\ R_n)>(n-1)*\left\{Diff(R_m)\right\}$

则需根据差异值比例适当缩小当前窗口，窗口缩小后的大小记为 W’，其计算公式：$W'=\left\{1-\frac{Diff(R_m)}{Diff(R_1,\ R_n)}\right\}*W$，这里规定窗口的最小取值不得小于相同关键字的记录数的最小值。

If $Diff(R_1,\ R_n)<(n-1)*\left\{Diff(R_m)\right\}$

中国知网 https://www.cnki.net

则需扩大当前窗口，窗口扩大后的大小记为 W’，其计算公式：

$W'=\left\{1+\frac{Diff(R_m)}{Diff(R_1,\ R_n)}\right\}*W$，这里规定窗口最大取值不大于相同关键字的记录数的最大值。

基于多种编辑距离和可变窗口的 SNM 改进算法可以实现较高效率的相似重复记录的识别工作。基于上述分析，改进算法的基本步骤如下：

输入：记录集 C，有效因子 V={0,1}，冷启动固定窗口大小 W，相似度阈值 U，。

输出：所有可能构成相似重复的记录集。

Step1：对数据集的排序关键字进行预处理使其标准化，并按照关键字对数据集进行排序，避免因关键字的表达形式不同造成相似重复记录不相邻。

Step2：在窗口 W 内根据 Diff（R_1，R_n）与 n* Diff（R_m）的大小关系，动态调整窗口的大小，在窗口内进行相似重复记录的识别。

Diff（R_1，R_n）>（n-1）*（Diff（R_m））则窗口缩小为 W-（1- Diff（R_m）/Diff（R_1，R_n））*W

Diff（R_1，R_n）<（n-1）*（Diff（R_m））则窗口扩大为 W+（1- Diff（R_m）/Diff（R_1，R_n））*W

Step3：根据模式编辑距离的取值判断选取何种相似度的计算算法。

如果模式编辑距离为 1，说明存在属性缺失情况，根据非缺失属性的情况为缺失属性设置有效因子以及动态调节剩余属性的权值，根据数理统计和主观的专家经验结合的方式确定各个属性的综合权值[35]。

若记录中的除缺失属性外的其他属性的相似度均接近 1 或者 0，则该属性赋予有效因子为 0，即该属性是无效的，不参与判重，即不影响该记录的相似度，如果非缺失字段的相似度不接近 0，也不接近 1，则各字段的相似度保持不变。否则，根据中英文选择不同的编辑距离算法计算相似度。

Step4：直到进行完所有记录的比对工作，输出所有可能构成相似重复的数据集。

具体流程图如图 3.3 所示。

中国知网 https://www.cnki.net

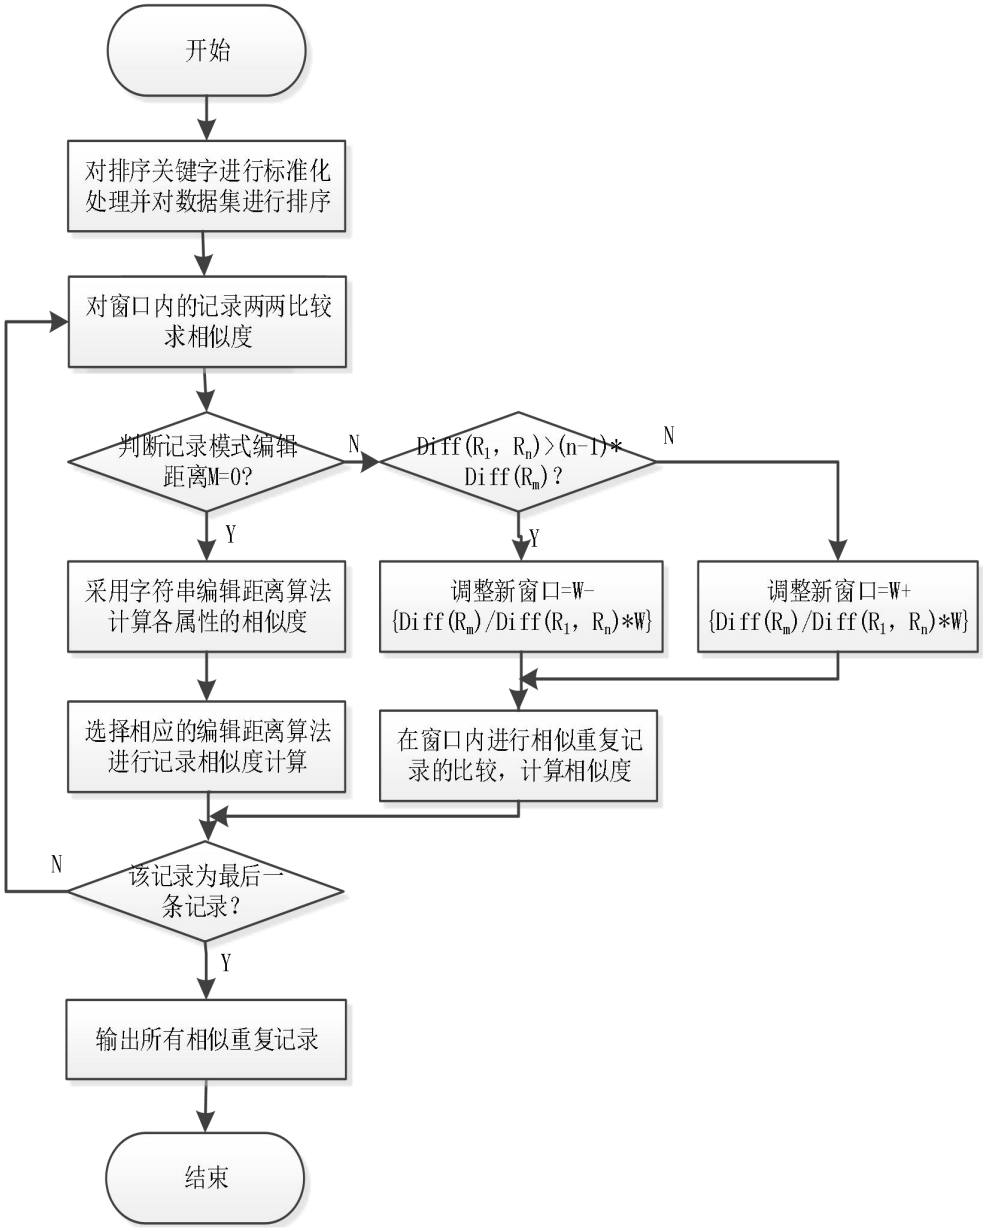


图 3.3 算法流程图

3.6 冲突解决

通常情况下，数据库中的数据应该表示的是现实世界的不同实体，这就必须有要解决聚类过程完成后的数据冲突处理[36]，其中主要的方式如下：

1、自动化处理方式 该方式会认定检测到的相似重复记录中的某一条数据是准确的，而剩余的是不正确的记录，从中随机选取任意一条记录保存。这种方法是最简单的处理方式，但是它不能保证随机选取保存的数据的正确性。

中国知网 https://www.cnki.net

2、半自动化处理方式 该方法需要参考外部源文件中的信息，将检测到的相似重复与外部源文件中的信息进行匹配，保留与外部源文件匹配程度最吻合的，如果出现吻合度相同，可由用户选取某一记录保留或随机选取。这种方式比全自动化处理方法的正确率更高，同时计算量不是很大。

3、人工处理方式 该方法是直接由相关人员参与决定记录的保留与删除。这种方法的准确率极高，但是人工干预过多，增加成本的同时在大数据情况下该方法不再适用。

3.7 本章小结

相似记录检测算法中最经典的算法：临近排序算法，在处理海量数据时，往往表现出检测效率不高、检测精度较低等缺陷，本文先对算法执行过程进行介绍，然后从编辑距离和动态可变窗口两个方面对算法进行改进，在字符串匹配过程中，本文提出多种编辑距离同时考虑的方式，减少属性缺失对判重时造成影响，同时在一定程度上解决异名属性对判重带来的不利影响；在记录匹配的过程中，采用的是自适应的窗口大小，在窗口内进行记录的比对，有效减少了记录之间的比对次数，从而提高检测效率。

中国知网 https://www.cnki.net

第四章 基于改进 SNM 算法的工业大数据清洗机制及仿真实验

目前，关于数据清洗方案的研究已有很多，只有结合相应的数据特点，选择合适的清洗算法，才能取得比较好的清洗效果[37]。当处理海量数据时，常见的清洗算法的效果一般较差，不能满足工业大数据的数据处理要求。因此，本文提出一种基于 hadoop 的分布式数据清洗方案，将基于 hadoop 的分布式清洗平台与清洗算法有机结合，实现高效的清洗工业大数据的效果。

4.1 工业大数据数据采集分析

工业智能化、信息化的趋势是实现研发、生产与销售一体化，工业大数据可以分为以下 7 类数据：研发中心产生的研发数据、计量中心产生的计量器具管理数据、制造中心产生的现场生产信息、综合质量主管部门产生的信息、采购部产生的采购以及质量信息、销售部门产生的销售与售后服务信息、信息中心产生的信息技术支持数据，数据信息分类如图 4.1 所示。

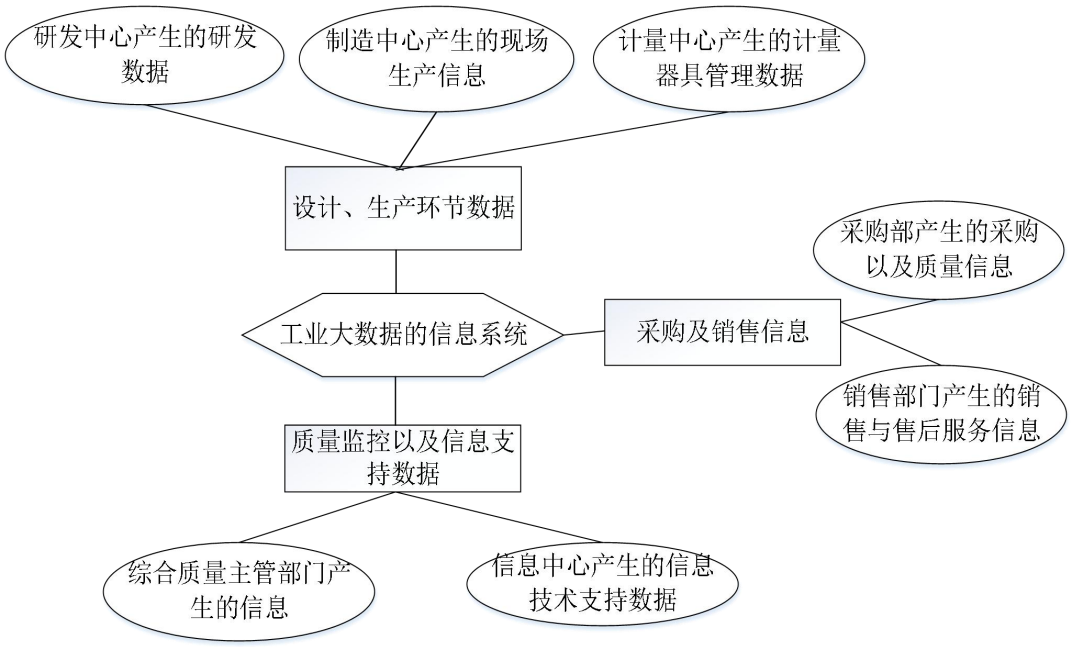


图 4.1 工业大数据数据信息分类

1、设计、生产环节数据

中国知网 https://www.cnki.net

设计、生产环节的数据记录设计到生产环节的数据全覆盖，包含 3 个子信息系统，其中研发数据主要记录产品设计和开发任务的数据；现场生产数据主要是记录产品生产过程产生的生产数据，这些数据用于对现场生产的管理、分析与处理；计量中心产生的数据包括：计量器具购置、发放、使用与周期性检查产生的数据，在各生产车间和采购部均设有计量站。

2、采购以及销售环节信息

采购部门负责外购生产过程元器件的采购业务管理，同时对到货的元器件和器材进行质量检验过程中，产生的需要上报综合管理处的信息。销售部门产生的数据主要来源于各地区的基础技术服务站，以及负责产品安装、使用过程中维修和技术支持产生的数据。

3、质量监控以及信息支持数据

质量监控部门的数据向上对总信息中心负责，向下负责设计、生产、采购、销售各个环节，质量监管部门的数据业务来源包括质量计划、质量评审、质量改进、可靠性、供应商评价、售后服务质量等等各个环节。

工业大数据主要存在的问题：数据重复。通过上述数据来源可以看出，在工业大数据的各个环节的数据采集过程中，都可能会导致“脏数据”的产生，其中包括生产线上的信息采集模块出现问题，网络信号影响自动化信息采集，数据集成中出现重复记录等。

如何高效、准确的将工业界大数据集中的相似重复记录识别出来，这是目前急需解决的问题，通过对传统 SNM 算法进行改进、对工业大数据集进行分析、借助 hadoop 分布式平台等方式[38]，提出改进的清洗算法和流程，能够更好的解决相似重复记录的识别问题。

工业大数据数据清洗方案的提出需要考虑的因素是多方面的：清洗算法的选择、领域知识的参与、清洗工作的耗时、查全率和查准率的权衡等等。本文提出来的工业大数据背景下的相似重复记录清洗方案能够实现以下功能：

1、实现数据的预处理，通过属性选取标准化对记录进行预处理。

2、实现基于各属性记录间的相似度计算，利用字段匹配以及记录匹配的方式实现工业大数据相似度计算。

3、实现相似重复记录的聚类过程，利用排序算法和阈值限定的方式对可能构成相似重复的记录进行聚类。

4、能够实现相似重复的记录冲突解决问题。

中国知网 https://www.cnki.net

4.2 工业大数据数据清洗架构

总体的检测过程除了考虑算法的执行过程，也要关注数据的存储和计算过程，大数据环境下，可以借鉴 hadoop 的 HDFS 作为海量数据的存储平台，因 HDFS 有吞吐量较高、容错性较好等特点，可在海量数据集上应用。HDFS 提供了可用的平台供异构数据库的数据导入以及结果的输出。Hadoop 平台上的 MapReduce 计算模块，能够将计算任务分配至集群中的各个相互联系的节点，在此过程中，MapReduce 会抽象出 Map 及 Reduce 模块可以满足相似重复记录检测算法的并行化实现，提高执行效率。系统架构图如下图 4.2 所示：

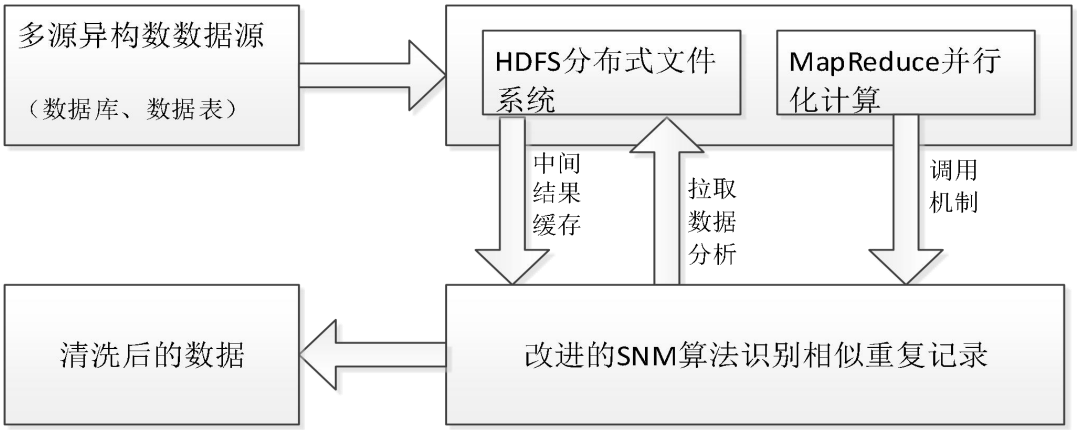


图 4.2 系统总体架构图

该系统主要分为三个功能模块：

（1）第一模块：异构数据库的存储模块，通过一定预处理规则，将来自不同文件的数据存储到 hadoop 的 HDFS 中。

（2）第二模块：数据的存储和计算模块，hadoop 分布式环境可以用来实现数据集的存储和计算，其中 HDFS 分布式系统是用来做文件的存储和管理的，MapReduce 是用来实现并行化的计算的。

（3）第三模块：数据清洗模块是该数据处理系统中的核心模块，数据清洗模块包括基于编辑距离的相似度计算模块、基于滑动窗口的相似记录比较模块。

基于编辑距离的计算模块中，首先考虑长度过滤算法把构不成相似重复记录的数据进行筛除，其次将数据的模式编辑距离考虑在内，尽可能排除因个别属性缺失造成的判重错误，最后适应属性综合权值法为各属性赋予一定权值，为后续相似重复记录的识别做准备。这一模块的处理可以明显降低算法运行时间，同时最大化的利用了领域知识。

中国知网 https://www.cnki.net

基于可变滑动窗口的近邻相似重复记录检测模块，采用窗口自适应大小内的记录匹配，避免窗口过大造成的多余匹配，以及窗口过小造成的漏匹配的情况。

（4）清洗后数据的存储模块，清洗后的结果一部分存在到指定的 HDFS 文件系统中，一部分可以直接用于工业生产中的生产、销售、维修以及其他各个环节的数据挖掘工作。

4.3 SNM 算法在工业大数据中的应用

4.3.1 基于长度过滤的并行化实现

在基于 MapReduce 的长度过滤算法的并行实现过程可以分为两个阶段来执行：Map 过程和 Reduce 过程。整个 MapReduce 的过程图如下图所示。

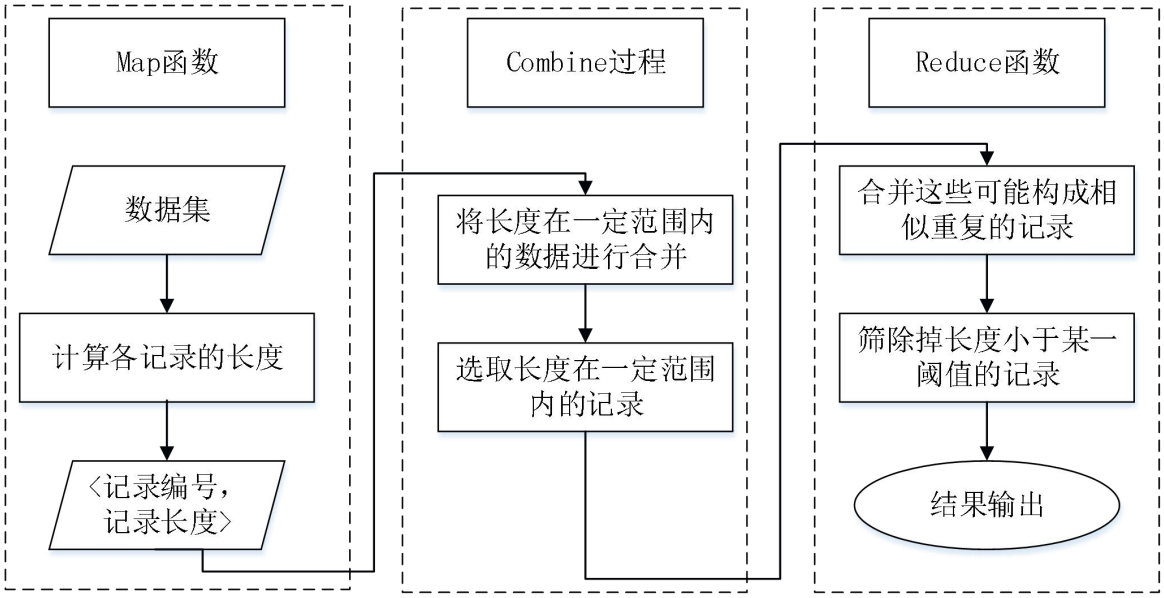


图 4.3 MapReduce 过程图

上述 Map 过程的主要任务是计算各记录的长度，各属性的权值是提前根据实验取样以及人工参与计算确定的，将生成的综合属性权重存放在对应的数组中以备后续计算需要，记录中的各个属性与数组中的权值进行一一对应，Map 过程的数据输出形式为<key,value>键值对，其中 key 为记录的编号，value 为记录的长度。Reduce 过程主要负责将 Map 过程输出的数据进行合并，即记录的长度和某一事先设定的长度阈值进行比较操作，若样本记录长度小于阈值，则对其进行删除操作。

中国知网 https://www.cnki.net

4.3.2 改进的 SNM 算法的并行化实现

进行过长度过滤的样本数据集以<key,value>键值对的表达方式存储在 HDFS 中，首先按照记录排序方式把每条记录与其可能构成相似重复的记录存储在 hashMap 数据结构中，其中 key 记录的是数据集中数据的编号信息，value 记录的是相似重复记录的信息。在进行相似重复记录比对的过程中，需要重复遍历 hashMap 数据结构中的信息，并计算相似度。

在临近排序算法的 Map 过程中，每条记录与可能构成相似重复记录的数据进行相似度的计算，在 Reduce 过程中，汇总整个数据集的相似重复记录。

4.3.3 SNM 算法在工业大数据中的应用

在工业大数据清洗方案中，相似重复记录的检测是清洗方案的核心模块，针对工业大数据中的相似重复记录进行清洗，下面实验过程将以冰箱数据为例进行数据清洗，为了能够准确提高识别的效率。

文提出的基于多种编辑距离和动态可变滑动窗口的 SNM 改进算法（以下称 SNM 改进算法）实现对工业大数据集中冰箱生产数据相似重复记录的检测，改进 SNM 算法在进行冰箱生产数据清洗的过程是：

（1）对原始冰箱生产数据的格式进行标准化，对原始数据进行标准化是保证后续记录排序的首要步骤。表 4.1 显示的是部分冰箱生产信息，在这个表中，由于种种原因，冰箱的生产信息是不规范的，如编号为 5858、5863 的记录机柜颜色这一属性是不规范的，编号为 5859、的记录出厂时间这一属性是不规范的。由于数据库中的记录的差异性，很容易出现上述情况，导致很多有价值信息不能及时被发现，严重影响工作人员对于信息的掌握。

表 4.1 部分冰箱生产信息

编号	型号代码	产品品牌	机柜颜色	支持 LED	除霜方式	出厂时间
5858	BCD-452WDPF	A	雅韵白	LED 显示	智能除霜	2015-01-22
5859	BCD-108	B	红色	不支持	智能除霜	2014.05.22
5860	BCD-241WM	C	银色	不支持	智能除霜	2015-05-06
5861	BC-50B	D	白色	其它	手动除霜	2016-06-28
5862	BCD-518WDYB	G	金色	LED 显示	智能除霜	2016-10-08

中国知网 https://www.cnki.net

5863	BCD-108	B	中国红	不支持	智能除霜	2014-05-22
5863	BCD-108	B	红色	不支持		2014-05-22

对记录进行排序。在上表示例中，可选取型号代码作为 Key 值，或在关注品牌的数据分析中可选取型号代码和品牌的组合作为 key 值。

（2）对当前窗口内的记录进行长度过滤，设置初始窗口解决滑动窗口冷启动问题。

（3）采用综合编辑距离算法计算各属性对记录的而贡献度，并转化为权值。上表 4.1 中，根据数理统计得属性值域范围：出厂时间>型号代码>产品品牌>机柜颜色>支持 LED>除霜方式，根据专家主观经验各属性对记录识别的贡献度：型号代码>产品品牌>出厂时间>机柜颜色>支持 LED>除霜方式，最后根据公式(3.1)计算属性综合权重参与后续相似重复记录判重。

（4）根据综合属性权值法加权计算记录相似度。

4.4 实验设计与评价标准

为了对算法的准确性、有效性进行验证，将对改进算法进行详细的对比实验，并对进行相应实验分析以及算法性能测评。

4.4.1 实验数据集及参数设置

实验数据是由国内家电行业某公司近五年冰箱组装过程中的生产数据，生产数据主要由冰箱型号、冰箱品牌、机柜颜色、开门方式等属性组成。由于数据采集模块采集错误或者人工输入导致数据错误情况时有发生，在时间取样范围很短以及数据量很小的情况下，可以采用人工对数据集进行读取、判断、修改、清洗处理。但是由于冰箱生产已有多年且期间生产规模不断扩大，同时积累了大量的生产信息，采用人工处理的方式不太现实。为了验证改进算法的有效性，需要手工将数据集进行处理，提供真实的相似重复记录的数量，方便进行对比。本实验从抽取了八组数据，分别为 3000，4000，5000，6000，7000，8000，9000，1 万条。其他通过人工统计以及人工操纵等方式检测出其分别具有 263，308，387，423，576，493，539，606 条相似重复记录，对实验参数设定如下。

1、字段权重设置，研究决定采用以下字段对记录进行匹配：型号代码、产品品牌、机柜颜色、箱门结构、支持 LED、冷柜机型、除霜方式、工作方式、出厂时间。样本数据如下表 4.2 所示。

中国知网 https://www.cnki.net

表 4.2 部分样本数据表

冰箱型号	产品品牌	机柜颜色	智能类型	冷柜机型	……	箱门结构	出厂时间
BCD-430WEZ50	D	红色	不支持	冷藏冷冻	……	对开双门	2015-05-06
BCD-312WDPM	G	银色	不支持	冷藏冷冻	……	多门式	2016-06-28
BCD-456WDGK	B	白色	不支持	冷藏冷冻	……	多门冰箱	2016-10-08
BCD-518WDYB	B	金色	支持	冷藏冷冻	……	三门	2015-05-22
BCD-108	D	红色	支持	风冷	……	对开门	2014-05-22
BCD-636WT	A	钛灰	支持	冷藏冷冻	……	双对开门	2017-06-15
……	……	……	……	……	……	……	……
BCD-1308	C	中国红	支持	风冷	……	双门式	2016-06-11
BCD-133ES	F	白色	不支持	冷藏冷冻	……	双开门	2017-05-16
BCD-108	B	白色	支持	风冷	……	三门	2016-09-08

属性种类数：型号代码>产品品牌>出厂时间>机柜颜色>箱门结构>支持 LED>冷柜机型>除霜方式>工作方式，则其贡献度顺序同上。

根据采集专家经验对各个字段分配不同的等级，形成属性经验等级表。根据公式 3.1 计算可得属性的综合权值。

2、相似度检测过程中的记录相似阈值取 0.75。

3、长度过滤阈值设置为 0.6。

4、集合冰箱数据特点，两个算法的冷启动窗口均设为 40。

4.4.2 评价指标

本对比实验主要从运行时间、召回率和查准率这三个方面进行的。

1、查准率和查全率

其中查全率和查准率的定义[39]：查准率（Precision Ratio）表示在数据集中，能够被准确识别出的相似重复记录与算法检测出的相似重复记录的比值。查全率（Recall Ratio）表示：也称召回率，是被正确识别出的相似重复记录占数据集中真实的相似重复记录的比值。具体公式如下图所示。

$$\text{Precision Ratio} = \left(\frac{TP}{TP+FP}\right)*100\%$$

$$\text{Recall Ratio} = \left(\frac{TP}{TP+FN}\right)*100\% \qquad \text{公式 4-(1)}$$

中国知网 https://www.cnki.net

其中，TP 表示算法准确检测出的相似重复记录数目， FP 是指真实情况下不是相似重复记录却被算法认定错误，当做相似重复记录的数目，FN 是指算法没有检测出来的相似重复记录的数目。举例说明：假定有十条数据 A_1、A_2、A_3、B_1、B_2、B_3、C、D_1、D_2、D_3，其中集合{A_1、A_2、A_3}、{B_1、B_2、B_3}、{D_1、D_2、D_3}分别是记录 A、B、D 的不同表示。假设经过算法检测，识别出{A_1、A_2、A_3、C}、{B_1、B_2}、{D_1、D_2}，则

Precision Ratio=7/8=87.5%

Recall Ratio=7/9=77.8%

2、算法检测时间

检测时间 Time 是指对数据集进行相似重复记录检测花费的时间，用来衡量算法的检测效率[40]。

4.5 算法测试结果及分析

4.5.1 基于长度过滤及综合权值的编辑距离算法

基于上述方案的评价指标，在同一实验环境下，对上述同一数据集进行测试。分别采用传统的基于传统的编辑距离算法与改进的基于长度过滤以及综合权值的编辑距离算法进行实验，对以上八组数据进行相似重复记录检测验证，对比实验的查准率如下图 4.3，查全率如下图 4.4，实验的运行效率如下图 4.5。

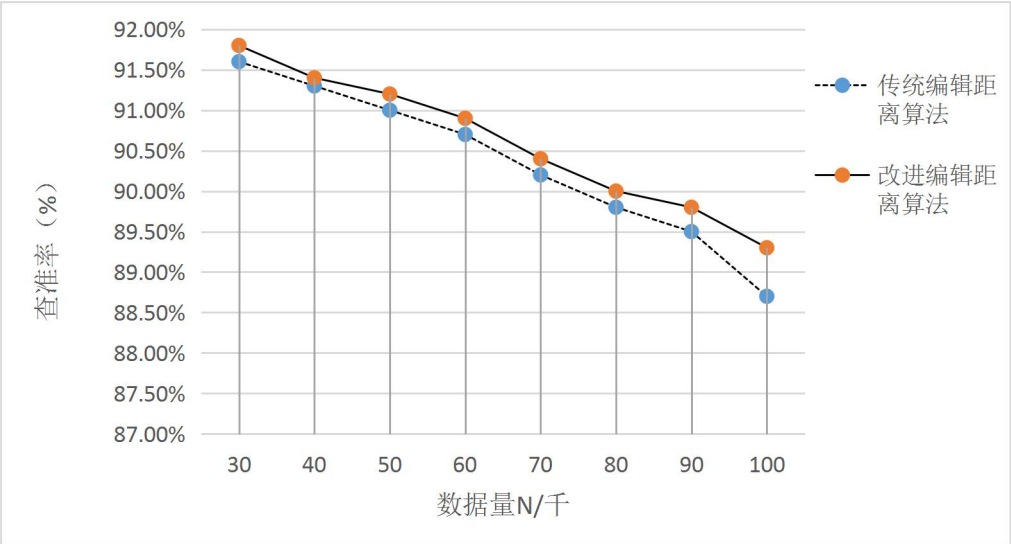


图 4.3 传统算法与改进算法查准率比较图

中国知网 https://www.cnki.net

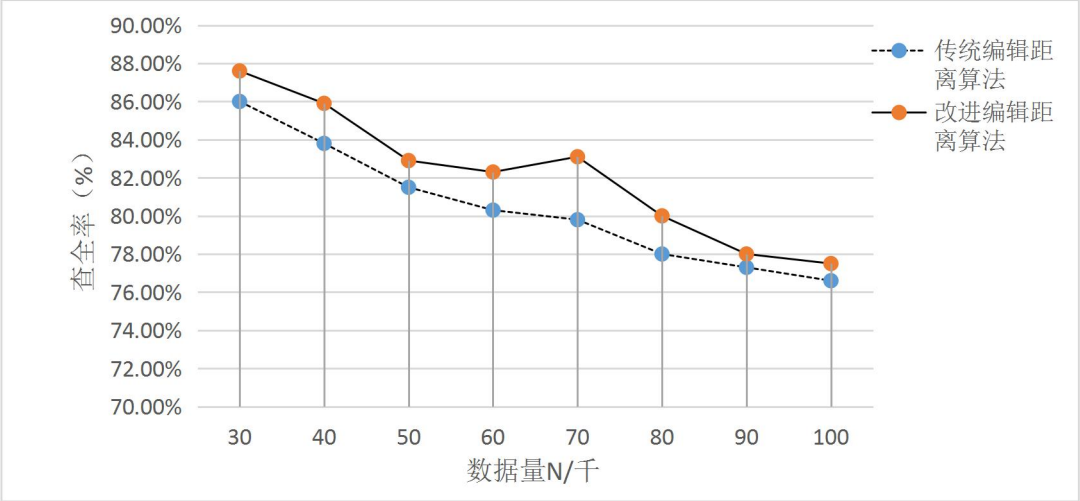


图 4.4　传统算法与改进算法查全率比较图

通过图 4.3 和 4.4 分析发现改进算法比传统的编辑距离算法在查准率有明显提高，主要是因为改进的编辑距离算法考虑到属性贡献度不同，同时考虑中西文差距不同选取不同的编辑距离求解方法，实验同时也说明了长度过滤方式没有明显降低算法的查全率。

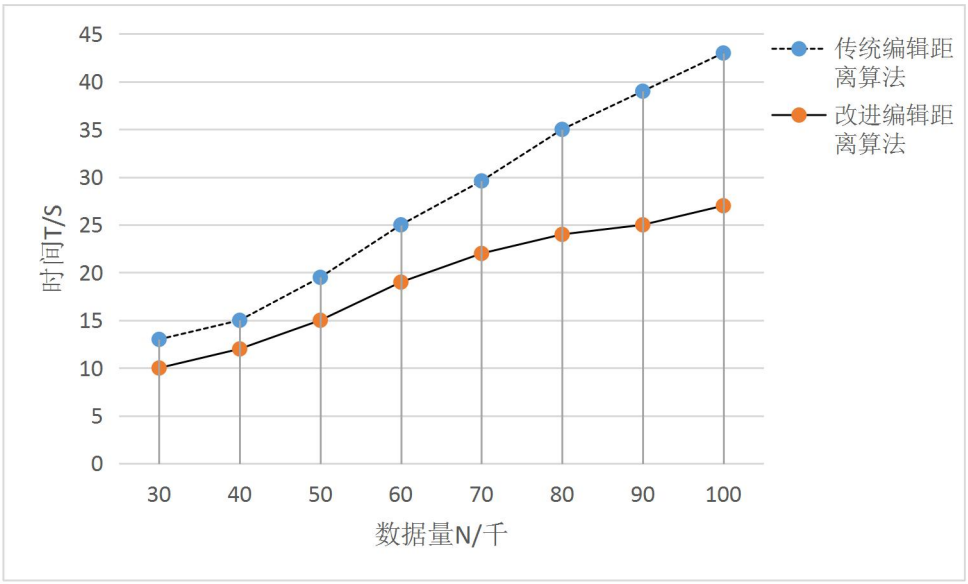


图 4.5　传统算法与改进算法运行时间比较图

通过图 4.5 可以明显观察到改进的编辑距离求解算法在运行时间上明显小于传统编辑距离求解算法，其主要原因是长度过滤方法的使用去除了不必要的计算过程，节省了算法的运行时间。

中国知网　https://www.cnki.net

由图 4.3，4.4，4.5 综合来看，改进的编辑距离算法在查准率、查全率和运行时间三个方面均优于传统编辑距离算法。

4.5.2 基于动态滑动窗口的 SNM 算法

为了验证论文中提出的基于动态滑动可变的 SNM 算法，设计对比实验如下，改进的 SNM 算法首先根据冰箱生产信息中的关键字对数据集进行聚类，然后窗口内进行相似记录的匹配，传统 SNM 算法作为标准算法进行对比，为了书写的表达方便，本文提出的的改进算法简称为 D-SNM 算法，上述两算法对八组数据进行相似重复记录检测实验，其召回率、查准率以及运行时间如图 4.6，4.7，4.8 所示。

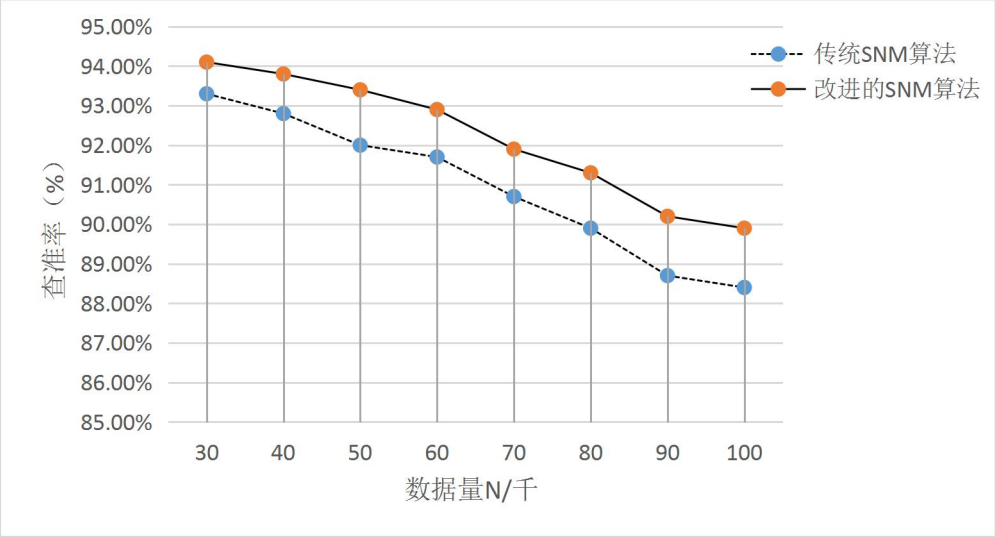


图 4.6　SNM 算法与 D-SNM 算法查准率比较图

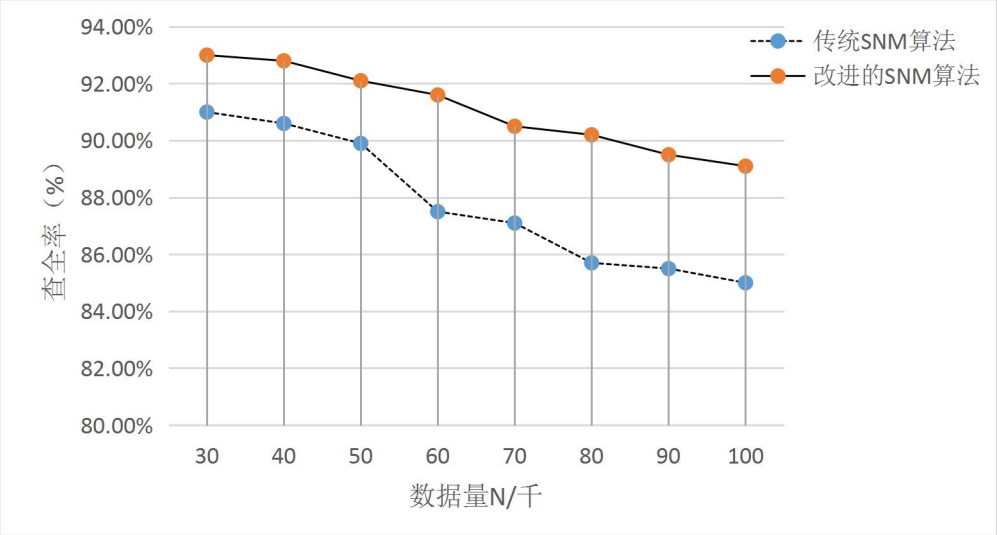


图 4.7　SNM 算法与 D-SNM 算法查全率比较图

中国知网　https://www.cnki.net

通过图 4.6 和 4.7 可得，相同时间内同一数据集进行实验，SNM 算法比 D-SNM 算法的查准率和召回率都低，分析其原因主要是因为 D-SNM 算法采用的基于综合权值和滑动窗口的机制，属性综合权值的方法能够同时考虑到主观因素和客观因素的结合，保证属性权重向量的有效性和科学性，从而提高检测精度，滑动窗口机制能够确保可能构成相似重复的记录保持在窗口内，提高了查全率。

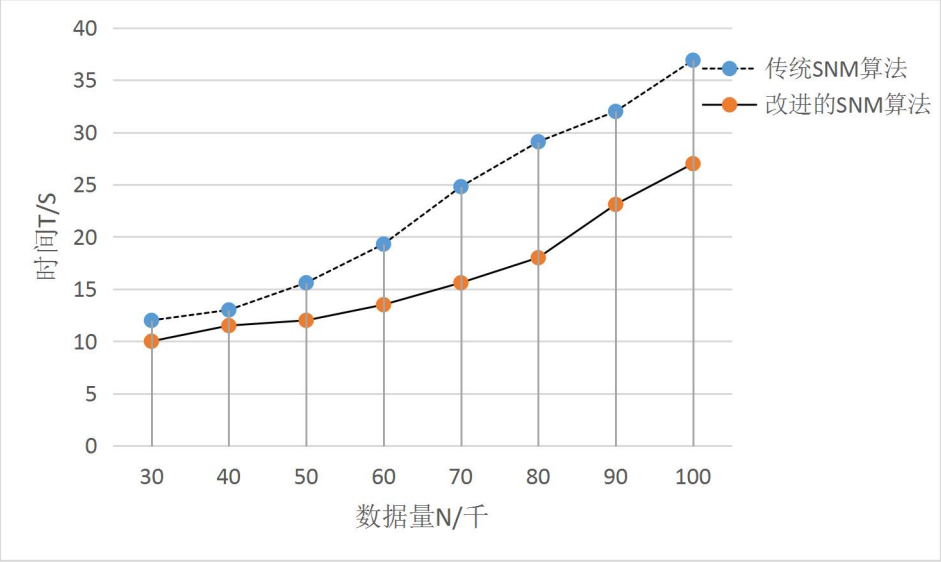


图 4.8　SNM 算法与 D-SNM 算法运行时间比较图

通过图 4.8 可知，在处理相同数据集时，D-SNM 算法运行时间更短，主要是因为 D-SNM 算法能够动态缩小检测窗口的机制避免不可能构成相似记录的匹配过程，同时减少了对比的时间。

由图 4.6，4.7，4.8 综合来看，改进的 SNM 算法在查准率、查全率和运行时间三个方面均优于传统 SNM 算法。

4.6 本章小结

本章着重介绍了改进的 SNM 算法在工业大数据中的具体的设计应用，采用综合权值法计算各属性的权值，能够准确的反应各字段在记录标识中的贡献度；采用滑动可变窗口的方法，能够科学的减少记录之间的匹配次数，两者集合为工业大数据的清洗提供了一种科学的解决方案。结合具体的工业大数据的冰箱生产数据对算法进行检测，通过实验有效的证明了：属性综合权值法能够有效的分配字段对记录的贡献度，使字段属性权值分配更合理；同时在编辑距离计算过程中，长度过滤方

中国知网　https://www.cnki.net

法明显降低参与匹配记录的数目；可变滑动窗口的概念能够避免不必要的记录匹配同时解决漏匹配的问题。

中国知网 https://www.cnki.net

第五章 总结与展望

相似重复记录的存在严重影响数据分析、数据挖掘的建模环节，其在现实中同一实体在数据库中有多种表现形式，如何通过数据清洗消除相似重复记录成为本文重点。本文对影响数据质量问题的因素进行深入讨论，对已有清洗算法进行分析，客观说明各算法的有效性和缺陷。

本文以 SNM 算法为基本底层算法，首先通过对数据本身的操作（预处理）使其干净化，其次通过算法对数据进行剪枝（长度过滤），以及在数理统计的基础上最大化专家经验参与判重，最后通过滑动窗口机制改进已有算法。针对其中的问题，提出自己的解决方案，并开展了以下几个方面的研究工作：

1．数据预处理过程中，提出属性综合权重的概念，将数理统计和专家经验进行有效结合，为各字段分配合理的权重。

2．在记录检测字段匹配过程中，提出了多种编辑距离判重的方法，其中模式编辑距离的提出有效解决因属性缺失造成的记录误判的情况，基于长度的剪裁能够实现对数据的初步过滤。

3．对已有的 SNM 算法的滑动窗口进行动态处理，在滑动的过程中，根据窗口内的记录之间的相似度进行大小的动态调整。

尽管本文已经开展了相应的研究工作，但是很多相关理论还处在探究阶段，未来可能在如下方面开展研究工作：

1．本文中对相似度阈值的设定是根据经验而来的，阈值的高低直接能够影响相似重复记录的检测效果。

2．在相似记录判重的过程中，对于中英文的缩写问题，给相似度的计算带来一定的挑战，应该进一步结合语言特点，构建数据字典来解决这一问题。

3．论文中的相似重复记录的识别范围仅限于结构化数据，关于非结构化数据的清洗又是一个全新的领域。

因客观上的时间和条件的约束，本论文在记录判重方面的深度研究尚且不足，本文提出的改进算法依旧存在很多不足之处。相似重复记录识别这一课题很有发展前景，本论文仅仅是探索性质的工作，希望可以为后来的研究者提供一定的参考价值，起到抛砖引玉的作用。。

中国知网 https://www.cnki.net

参考文献

[1]李建中，刘显敏.大数据的一个重要方面：数据可用性[J]. 计算机研究与发展，2013,50（6）：1147-1162.

[2]邱岳峰, 田增平, 季文赘等. 一种高效的检测相似重复记录的方法[J]. 计算机学报, 2001, 24(1): 69—77

[3]Minton S N, Nanjo C, Knoblock C A, et al. A Heterogeneous Field Matching Method for Record Linkage [A], in IEEE International Conference on Data Mining. IEEE [C], 2005:8 pp.

[4]Monge A, Elkan C. An efficient domain-independent algorithm for detecting approximately duplicate database records [J]. 1997.

[5]Garner S R. WEKA: The Waikato Environment for Knowledge Analysis [A], in of the New Zealand Computer Science Research Students Conference [C]. 1995:57--64.

[6]Berthold M R, Cebron N, Dill F, et al. KNIME: The Konstanz Information Miner [J]. Acm Sigkdd Explorations Newsletter, 2011, 11(1):26-31.

[7]郭志懋，周傲英. 数据质量和数据清洗研究综述[J]. 软件学报，2002，13(1 1)：2076-2082.

[8]Hernández M A, Stolfo S J. The merge/purge problem for large databases [A], in ACM Sigmod Record. ACM [C], 1995, 24(2): 127-138.

[9]Rahm E, Do H H. Data cleaning: Problems and current approaches [J]. IEEE Data Eng. Bull., 2000, 23(4): 3-13.

[10] Wang J, Zhang H, Fang B, et al. A Survey on Data Cleaning Methods in Cyberspace [A], in IEEE Second International Conference on Data Science in Cyberspace. IEEE [C], 2017:74-81.

[11]俞荣华. 数据质量和数据清洗关键技术研究[D]. 复旦大学, 2002.

[14]Mong A E, Elkan C P. The field matching problem: algorithms and applications [A], Proceedings of the 2nd Conference on Knowledge Discovery and Data Mining. Cambridge: AAAI [C]. 1996:267—270.

[12]鲁均云,李星毅,施化吉,等.基于内码序值聚类的相似重复记录检测方法[J].计算机应用研究, 2010, 27(3):874-878.

[13]Bilenko M, Mooney R, Cohen W, et al. Adaptive name matching in information integration [J].IEEE Intelligent Systems, 2003,18(5):16-23.

中国知网 https://www.cnki.net

[15]俞荣华,田增平,周傲英.一种检测多语言文本相似重复记录的综合方法[J].计算机科学, 2002, 29(1):118-121.
[16]Guttman A. R—trees: A dynamic index structure for spatial searching [J]. Acm Sigmod Record, 1984,14(2):47-57.
[17]冯玉才,桂浩,李华,等.数据分析和清理中相关算法研究[J].小型微型计算机系统,2005,26(6):1018-1022.
[18]程艳云, 张守超, 杨杨. 基于大数据的时间序列异常点检测研究[J]. 计算机技术与发展, 2016, 26(5):139-144.
[19]韩家炜, 坎伯. 数据挖掘: 概念与技术[M]. 机械工业出版社, 2012.
[20]Hido S, Tsuboi Y, Kashima H, et al. Statistical outlier detection using direct density ratio estimation[J]. Knowledge and information systems, 2011, 26(2): 309-336.
[21]洪沙, 林佳丽, 张月良. 基于密度的不确定数据离群点检测研究[J]. 计算机科学, 2015, 42(5):230-233.
[22]杨巧巧, 郭振波, 王开西. 基于聚类分组和属性综合权值的SNM改进算法[J].工业控制计算机, 2017(9):27-28.
[23]邵清, 叶琨. 基于编辑距离和相似度改进的汉字字符串匹配[J]. 电子科技, 2016, 29(9): 7-11.
[24]Jin L, Li C, Mehrotra S. Efficient record linkage in large data sets [A], in Database Systems for Advanced Applications, 2003. (DASFAA 2003). Proceedings. Eighth International Conference on. IEEE [C], 2003: 137-146.
[25]韩京宇, 徐立臻, 董逸生. 一种大数据量的相似记录检测方法[J]. 计算机研究与发展, 2005, 42(12):2206-2212.
[26]朱蔚恒, 印鉴, 邓玉辉等. 大数据环境下高维数据的快速重复检测方法[J].计算机研究与发展, 2016, 53(3): 559-570.
[27]王妍, 刘赓浩, 王俊陆, 等. 基于压缩的海量不完整数据近似查询方法[J].计算机研究与发展, 2016, 53(3):571-581.
[28] Bunke H, Jiang X, Abegglen K, et al. On the Weighted Mean of a Pair of Strings [J]. Pattern Analysis & Applications, 2002, 5(1):23-30.
[29]Levenshtein V I. Binary codes capable of correcting deletions, insertions and reversals [J]. Soviet Physics Doklady, 1966, 10(1):707-710.
[30]Zhang Zhongnan, He Ling, Tan Yize, et al.A heuristic approximately duplicate records detection algorithm based on attributes analysis

中国知网 https://www.cnki.net

[J].International Journal of Digital Content Technology & its Applications, 2012, 6(4):259-267.
[31] 李润洲, 方 明. 基于异构集成的元数据及其多表动态查询算法[J]. 计算机工程, 2007, 33(17): 111-113.
[32]郭文龙. 一种改进的相似重复记录检测算法[J]. 计算机应用与软件, 2014(1):293-295.
[33]Beskales G, Ilyas I F, Golab L, et al. On the relative trust between inconsistent data and inaccurate constraints [A], in IEEE International Conference on Data Engineering. IEEE [C], 2013:541-552.
[34]周朝栋, 张有全, 许竞文, 等. 基于变动窗口和移动序列的基因识别算法[J]. 基因组学与应用生物学, 2017(6):2380-2386.
[35] 孟坚, 董逸生, 王永利. 一种基于规则的交互式数据清洗技术[J]. 计算机技术与发展, 2005, 15(4):141-144.
[36]敖莉, 舒继武, 李明强. 重复数据删除技术[J]. 软件学报, 2010, 21(5):916-929.
[37]刘芳, 何飞. 基于聚类分析技术的数据清洗研究[J]. 计算机工程与科学, 2005, 27(6):70-71.
[38]陈伟. 数据清理关键技术及其软件平台的研究与应用[D]. 南京航空航天大学, 2005.
[39]张保明. 查全率—查准率互逆相关性的数学解释[J]. 情报科学, 1982(2):12-15.
[40]周典瑞, 周莲英. 海量数据的相似重复记录检测算法[J]. 计算机应用, 2013, 33(8) :2208-2211.
[41]郭文龙. 基于长度过滤和有效权值的SNM改进算法[J]. 计算机工程与应用, 2014, 50(19):123-127.
[42]Hernandez M A,Stolfo S J.Real-world data is dirty:data cleansing and the merge/purge problem[J].Data Mining and Knowledge Discovery,1998,2(1):9-37.

中国知网 https://www.cnki.net

攻读学位期间的研究成果

[1]杨巧巧，郭振波，王开西．基于聚类分组和属性综合权值的SNM改进算法[J]．工业控制计算机，2017(9):27-28.
[2]杨巧巧，郭振波，王开西．基于网格分组和属性权值的相似重复记录识别算法[J]．青岛大学学报(自然科学版)，2017，30(2):69-73.
[3]Yang Qiaoqiao,Guo Zhenbo,Wang Kaixi. The SNM Algorithm Based on Multiple Edit
Distances and Variable Window[A].in 7th International Conference on Computer Engineering and Networks [C]，2017:488-494

中国知网 https://www.cnki.net

致　谢

光阴似箭、日月如梭，转眼间，在青岛大学校园的三年学习生活也已接近尾声。回忆过去，思绪万千。首先我要感谢我的导师郭振波教授，郭老师和蔼可亲、兢兢业业、尽心尽力。同时，我还要感谢王开西老师，若没有他的孜孜不倦、尽职尽责，就没有我现在论文的顺利完成。在研究生期间，老师们不仅教授我专业知识，而且还教育我如何做人。不管是在学习上，还是在生活中，他们都给予我帮助。老师丰富了我的心灵，开发了我智力，为我点燃了希望的光芒。若没有老师为我指引方向，那我的人生道路将会是一片迷茫。对于论文的撰写，从框架结构到细枝末节，都离不开老师的悉心指导。

最后感谢实验室的师弟师妹，师哥师姐，是他们陪我度过了充实、开心、幸福的研究生时期，是他们让我的生活不孤单，且富有情趣。

父母恩，师生情，同窗谊，万分感谢。

中国知网　https://www.cnki.net

中国知网 https://www.cnki.net