学校代码：**10255**

学　　号：**2191476**

东华大学

工业物联网中基于边缘计算的大数据清洗算法的研究

Research on Big Data Cleaning Algorithm Based on Edge Computing in Industrial Internet of Things

学　　院：　信息科学与技术学院

专　　业：　电子与通信工程

姓　　名：　陈茂

学　　号：　2191476

指 导 教 师：　陈雯

2021 年 5 月

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

工业物联网中基于边缘计算的大数据清洗算法的研究

摘 要

物联网（Internet of Things，IoT）是一项逐渐兴起的技术，实现众多行业的智能化，使得有限的资源能够更加合理的分配使用，从而提高行业的效率和收益，如智能工业、智能交通、智慧社区以及远程监控等。工业物联网（Industrial Internet of Things，IIoT）作为物联网技术中最大和最重要的组成部分，充当了智能制造中信息和实体之间通信的桥梁。工业锅炉系统通过实时监测控制感知层的物理设备，实现资源的调度和分配以降低资源消耗和提高制造效率。工业锅炉系统中连接了海量的数字设备，包括传感器、控制设备、制造机器和终端设备等，这将会产生大量的数据。由于锅炉系统中的传感器环境恶劣，收集的大数据不可信，严重影响云端的判断和反馈。依赖传感器节点进行数据清洗的方法不足以处理大数据，结合移动边缘计算（Mobile Edge Computing，MEC）技术和数据清洗方法正好可以解决以上的问题。MEC 通过将传感器节点、聚合节点和云服务的一些工作转移动边缘服务器上，除了可以减少云服务器的工作量来提高云的性能，还可以减少数据的传输时延，这是因为边缘服务器更加接近工业的感知层设备。所以本文主要研究了基于 MEC 的工业物联网大数据清洗的方案。

首先，由于工业锅炉系统中的数据量太大，以至于需要消耗大量的资源进行计算分析，而且这些数据的维度过大，这使分析人员陷入“维度灾难”的困境，在实践中也难以进行有效的分析。因此，本文提出了一种以核函数的主成分分析(Kernel Principal Component Analysis，KPCA)的方法，用来挑选一些有价值的数据，将高维混合数据嵌入到连续空间中。将它构建成一个连续的、降维的物理数据，使得与低维连续域的异常检测算法相匹配。

其次，基于数据降维的前提下，本文提出了隔离森林(Isolation Forest，iForest)的异常值检测算法。在工业数据中，难以避免地会产生噪声、数据错误和数据丢失等异常信息，而异常数据不仅会增加上传的带宽和节点的能耗，还会严重影响分析的结果。为了提高服务器的处理速度来满足工业领域上的空间和时间上的要求，需要空间复杂度和时间复杂度低的算法。根据上述情况，提出一种基于整体数据的异常值检测算法。通过与 K 最近邻(K-NearestNeighbor，KNN)算法与支持向量机(Support Vector Machine，SVM)算法来作比较，证明隔离森林算法在工业锅炉系统中的数据清洗有着更高的精确性和高效性。

最后，利用软件 Jupyter notebook 对本文提出的 iForest 算法进行数据仿真。仿真结果表明，KPCA 的算法可以对工业数据进行降维，选择出有效的属性。基

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

于 KPCA 方法下的 iForest 异常检测算法不仅具有高准确性和高检出率，而且执行效率也得到了巨大的提升。

关键词：工业物联网，边缘计算，数据降维，异常值检测

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Research on Big Data Cleaning Algorithm Based on Edge Computing in Industrial Internet of Things

ABSTRACT

The Internet of Things (IoT) is a gradually emerging technology that realizes the intelligence of many industries, so that limited resources can be more reasonably allocated and used, thereby improving the efficiency and benefits of the industry, such as smart industry, smart transportation, Smart community and remote monitoring, etc. The Industrial Internet of Things (IIoT), as the largest and most important part of the Internet of Things technology, acts as a bridge for communication between information and entities in intelligent manufacturing. Industrial boiler system realizes resource scheduling and allocation through real-time monitoring and control of physical devices at the perception layer to reduce resource consumption and improve manufacturing efficiency. In the Industrial boiler system, a large number of digital devices are connected, including sensors, control equipment, manufacturing machines, and terminal equipment, which will generate a large amount of data. Due to the harsh sensor environment in the industry, the collected big data is not credible, which seriously affects the judgment and feedback of the cloud. Data cleaning methods that rely on sensor nodes are not enough to process big data. Combining Mobile Edge Computing (MEC) technology and data cleaning methods can just solve the above problems. MEC transfers some work of sensor nodes, aggregation nodes and cloud services to mobile edge servers. In addition to reducing the workload of cloud servers to improve cloud performance, it can also reduce data transmission delays. This is because edge servers are closer Industrial perception layer equipment. So the main research in this article is based on the MEC-based industrial IoT big data cleaning solution.

First of all, because the amount of data in the Industrial boiler system is so large that it needs to consume a lot of resources for calculation and analysis, and the dimensionality of these data is too large, this makes analysts fall into the dilemma of "dimensional disaster", and it is difficult to carry out in practice. Effective analysis. Therefore, this paper proposes a Kernel Principal Component Analysis (KPCA) method to select some valuable data and embed high-dimensional mixed data into continuous space. It is constructed into a continuous, dimension-reduced physical data to match the anomaly detection algorithm in the low-dimensional continuous domain.

Secondly, based on the premise of data dimensionality reduction, this paper proposes an Isolation Forest (iForest) outlier detection algorithm. In industrial data, it is inevitable that abnormal information such as noise, data errors, and data loss will be generated. Abnormal data

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

will not only increase the upload bandwidth and node energy consumption, but also seriously affect the results of the analysis. In order to increase the processing speed of the server to meet the space and time requirements in the industrial field, algorithms with low space complexity and time complexity are required. According to the above situation, an outlier detection algorithm based on overall data is proposed. By comparing with the K-Nearest Neighbor (KNN) algorithm and the Support Vector Machine (SVM) algorithm, it is proved that the isolation forest algorithm has higher accuracy and efficiency in data cleaning in the Industrial boiler system.

Finally, the software Jupyter notebook is used to simulate the iForest algorithm proposed in this paper. The simulation results show that the KPCA algorithm can reduce the dimensionality of industrial data and select effective attributes. The iForest anomaly detection algorithm based on the KPCA method not only has high accuracy and high detection rate, but also the execution efficiency has been greatly improved.

Mao Chen (Information and Communication Engineering)

Supervised by Wen Chen

Keywords: Industrial Internet of Things, edge computing, data dimensionality reduction, outlier detection

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

目录

摘 要 ..... **I**

ABSTRACT ..... **III**

第一章 绪论 **1**

1.1 课题研究背景及意义 1

1.2 课题研究现状和问题的提出 3

1.3 研究的主要内容 5

1.4 论文的章节安排 6

第二章 相关技术 **8**

2.1 移动边缘计算的网络概述 8

2.1.1 设备层 9

2.1.2 IIoT-MEC 层 9

2.1.3 云服务器层 10

2.1.4 IIoT- MEC 网络架构的优势 10

2.2 机器学习算法介绍 11

2.2.1 机器学习的基础概念 11

2.2.2 数据降维算法 12

2.2.3 异常检测算法 14

2.3 本章小结 16

第三章 基于 KPCA 的数据降维方案 **17**

3.1 问题描述与相关工作 17

3.2 基于 KPCA 的特征选择方法 18

3.2.1 核函数以及参数选取 18

3.2.2 KPCA 算法步骤 19

3.3 本章小结 20

第四章 基于隔离森林的异常检测算法 **22**

4.1 问题描述与相关工作 22

4.2 基于隔离森林算法的检测模型 23

4.2.1 隔离森林的构建子模块 23

4.2.2 森林的构建 25

4.2.3 隔离森林判定异常 27

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

4.3 隔离森林算法参数设置.....29
4.4 本章小结.....30
第五章 仿真与分析.....31
5.1 仿真环境的搭建.....31
5.1.1 实验环境参数.....31
5.1.2 仿真工具介绍.....31
5.2 数据集介绍.....33
5.2.1 锅炉系统的构成.....33
5.2.2 数据集的构成.....34
5.3 KPCA 数据特征选取的仿真与分析..... 35
5.4 基于隔离森林的异常检测算法的仿真.....37
5.4.1 异常检测模型的数据基础.....37
5.4.2 仿真指标介绍.....38
5.4.3 仿真结果分析.....39
5.4.4 与其他异常检测模型对比.....40
5.5 本章小结.....42
第六章 总结与展望.....43
6.1 工作总结.....43
6.2 展望.....44
参考文献.....45
致 谢.....50
攻读硕士学位期间主要成果.....51

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第一章 绪论

随着传感器变得小巧和廉价，特别是第五代移动通信技术（5G）的推出和普及，5G 高带宽、低时延和广覆盖的特点，使得 4G 网络无法实现的工业互联网场景在 5G 时代变成可能。工业物联网中连接了海量的数字设备，包括传感器，控制设备，制造机器，终端设备，这会产生产生大量的数据。因此，许多学者愈发关注工业物联网大数据分析处理的问题。通过在边缘节点进行数据处理，提高信息传输能力和云端服务器的响应能力，这已经成为未来工业物联网的发展方向之一。本论文便是通过边缘计算来辅助工业物联网大数据处理的研究。

本章首先，介绍基于移动边缘计算的大数据降维与异常值检测算法的研究背景与意义。其次，介绍大数据降维与异常值检测算法的研究现状，并针对当前还未解决的问题，重点阐述本文主要的研究工作。最后，给出论文整体的章节安排。

1.1 课题研究背景及意义

最近几年，随着信息产业的迅速发展，物联网也让人耳熟人详，是被称之为继计算机与互联网之后的世界信息产业的第三次革命。物联网大致可分为两类：消费者物联网和工业物联网[1]。物联网的发展涉及到生活的方方面面，可以实现人与人，人与物，物与物之间的通信，从而提升行业的互动与合作效率，使得人们生活更加便捷。根据爱立信的预测，到 2024 年底，全球蜂窝物联网连接数将突破 41 亿，其中 45%为大规模物联网，网络流量和服务数据量也随之迅速增加[2]。伴随着物联网的日益普及，需要一种能够高效且以高的带宽支持大量数据传输的技术。目前，物联网设备的需求便是容量增加，数据速率提高，等待时间缩短。5G 的发展与推出能够满足复杂物联网框架的要求[3]。

随着国内 5G 技术的发展，相比于过去的通信系统，它有着更高的带宽、传输速率和广覆盖的优点。5G 迎合了物联网中一些场景下的低时延、高可靠性的业务需求，例如智能驾驶、智能社区、智能医疗和智能工业等。其中 IIoT 作为物联网技术在工业领域的一个应用分支，充当了智能制造中信息和实体之间通信的桥梁[4]。工业物联网通过实时监测控制感知层的物理设备，实现资源的调度和分配以降低资源消耗和提高制造效率。Gartner 预测[5]，在未来，工业物联网设备将占据一半以上的物联网设备。工业物联网中连接了海量的数字设备，包括传感器，控制设备，制造机器，终端设备，这会产生产生大量的数据。如果将这些数据从网络边缘发送到数据中心处理，不仅会消耗许多的网络带宽和增加传输时

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

延，而且也很难实时地对数据进行分析及响应处理。面对数十亿个可编程 IIoT 设备，基于云计算的传统 IIoT 体系结构不再适用。为了解决这个问题，利用移动边缘计算(MEC)增强 5G 对工业物联网的支持能力，已成为学术界和业界的共识[6]。

MEC 最早由 Satyanarayanan 等人[7]于 2009 年提出，最初是为了解决云计算造成的过度延迟和网络拥塞问题，通过在接入网[8]中部署具有计算、存储和通信能力的 MEC 服务器。欧洲电信标准协会（ETSI）于 2014 年成立了一个新的和行业规范组织(ISG)，允许创建 MEC 行业规范。该项目是由 Nokia、Intel、IBM、华为等共同发起的。同时，5G 基础设施公私合作(5G PPP)也认为 MEC 是 5G 网络[9]的主要新兴技术。移动边缘计算（MEC）作为云计算的演变，将应用托管从集中的数据中心转移到网络边缘，更接近物理设备生成的数据，并利用近端部署的优势获得高带宽和低延迟[10]。移动边缘计算还可以弥补无线传感器网络计算能力的不足。对于普通传感器节点难以完成的任务，可以在边缘层实现。通过对 MEC 的不断研究，研究人员不再局限于利用 MEC 去解决因云计算架构而导致的网络拥塞和延迟问题。越来越多的研究人员正在考虑利用 MEC 来实现更多功能来支持 IIoT，例如数据预处理，应用程序开发，本地服务提供，访问设备管理等。

为了分析边缘网络的数据，需要采集来自于底层传感器网络中的海量数据。物联网中的传感器是必不可少的部分，并且是捕获原始数据的第一个端口。对于任何的无线传感器网络（WSN）框架，传感器都是生成数据的基本设备，它们负责感测，处理和存储数据，这些数据对于许多决策都十分重要[11]。

许多与数据收集有关的领域都会受到异常值的影响，这些异常值包括天气监视[12]、欺诈和入侵检测[13]和交通异常检测[14]等。大多数传感器节点部署在恶劣的工业环境中，特别容易受到恶意的攻击，可以人为操纵产生无效甚至具有误导性的数据[15]。这些条件将使物联网中的传感器生成异常和错误的数据，通常称为离群值。在工业物联网中，数据异常不仅会增加上传带宽和节点能耗，还会严重影响分析结果。因此，为了避免这些问题，引入了结合机器学习（Machine Learning，ML）的移动边缘节点数据清洗技术[16][17]。异常值检测在工业物联网中十分重要，检测出错误读取或数据损坏从而确保传感器采集的数据质量。因此，本文中的边缘服务器扮演缓解云服务器的压力的角色，在这种网络框架下，结合以核函数的主成分分析方法选择关键特征与隔离森林算法来找出异常值，从而减少节点的能源消耗，并提高云服务器的决策性。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

1.2 课题研究现状和问题的提出

随着通信技术、互联网应用，传感器技术和新能源及材料等技术高速的发展，形成了强大的产业能力和巨大的市场。因此，工业物联网将会是传统工业生产的一种变革，传统工业生产技术和物联网的结合，实现了制造业的自动化和智能化，将会提升整个工业生产体系的制造能力。作为提高国家竞争力的重要因素之一，工业物联网已经在全球行业、学术界、政府和监管机构引起了关注。

世界上的许多国家制定并提出了工业物联网的发展战略，比如日本的 i-Japan 战略 2015、德国工业 4.0 计划与韩国的 u-Korea 战略[18]，将 IIoT 技术列入国家经济产业发展规划中，力求提高工业产品质量和工业链的效率。我国也陆续陆续发布了《中国制造 2025》、《国务院关于深化制造业与互联网融合发展的指导意见》、《关于深化“互联网+先进制造业”发展工业互联网的直到意见》等系列指导[19]，提出加速推动信息技术与制造业的深度融合，大力发展智能制造。在传统的无线传感器网络架构中，清理数据仅依靠传感器节点本身。如果传感器仅需要收集单个特征数据，其自身的计算能力可以满足基本的要求。但是，由于 5G 的出现和大量的集成多功能数据采集的传感器被添加到工业 SCS 中，这将会产生很多复杂的数据[20]。由于成千上万的传感器，各类移动设备用于监视工业生产，所以 IIoT 大数据涵盖了各种大规模复杂的数据，除了工业智能化中许多有价值的信息，其中还包含大量的噪声和异常数据。因此，需要有效 IIoT 大数据处理和分析方法来保存有价值的数据和清除异常值。

近年来，学者们在数据清洗及其相关领域提出了很多的研究成果。现有的大数据异常检测方案大多基于机器学习模型。该方案是一种混合方案来检测工业传感器中的异常数据。该方法包括三个阶段。在第一阶段，将采集过来的数据进行收集、识别、选取；在第二阶段，为了有效地处理大数据，需要进一步数据降维。最后在第三阶段，利用不同的检测算法来对异常实例进行检测。

数据降维的目的是为了减小数据集的大小，从而使得数据集能够得到有效的处理。在非相关特征的高纬度数据中，隐藏异常性能而导致“维的灾难”[21]。特征选择工程是一个重要的预处理步骤，有助于从原始数据中选择重要的特征，这将简化机器学习模型，并提高机器学习算法结果的质量。在过去的几十年里，大量的降维技术被用来过滤考虑数据集的数据样本。在这项工作中，有两个突出的维数减少技术，即无监督方法和有监督方法。主成分分析（PCA）是一种常用于减少数据量的无监督学习方法。文献[22]中，作者整合 PCA 和 K-means 算法来预测糖尿病。在这项工作中，作者首先应用 PCA 进行降维，然后应用 K-means 对数据分类。这两种技术的结合有着更高的准确率。文献[23]中采用了一种集成的

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

PCA-SVM 算法来增强数字图像识别。实验结果表明，这两种策略的混合具有较高的识别精度和识别速度。在监督方法中，基于判别分析（例如线性判别分析（LDA）[24]）可减少数据量。然而在工业物联网中，大多数数据需要研究人员进行非线性的映射才能找到合适的低维度进行嵌入。在复杂的非线性系统中，会产生误报。本文综合考虑了数据缺失和高维问题，提出以核函数的主成分分析方法从数据集中选择重要的特征，然后对预处理后的数据进行进一步分析。其中，选择后的特征是指与最终输出高度相关的特征。

在异常数据检测领域中，局部离群因子（Local Outlier Factor，LOF）是一种使用 KNN 思想的异常检测的模型，该模型在物联网中得到了许多应用。比如，在高速列车的无线传输设备系统中已集成了基于 LOF 的异常检测模型，以监视列车轴箱轴承的温度状态[25]。在工业物联网传感器系统中，就缺陷诊断和故障检测的任务而言，已经成功地将 LOF 用作各种类型的旋转机械的预测性维护中[26][27][28]。文献[29]提出了一种基于顶点分布表示和 LOF 算法的复杂网络混合顶点离群值检测方法，目的是寻找复杂网络中与群或社区不同的异常顶点。通过基于顶点分布表示和局部离群值因子将顶点或边映射到密度连续的实值空间中，然后使用 LOF 算法检测离群值。文献[30]提出了一种基于网格的近似平均离群点检测(GAAOD)框架，以支持基于 KNN 算法的物联网流数据的离群点检测。基于邻居的离群值检测使用对象之间的距离关系来评估异常值。但是，其计算复杂度很高，并且无法在未来 IIoT 流数据环境下有效地工作。文献[31]提出了一种双向长短期记忆(BiLSTM)网络算法来分析异常数据并发现故障类型，并结合支持向量机的算法来提高检测效率。该算法在加油站物联网系统中具有较高的故障检测效率和准确性。然而，BiLSTM 结构复杂，计算速度慢，也不适合对时间敏感的工业物联网场景。Nguyen 等人提出了一种离群值检测序列集成方法(SEQ)。序列集成方法是通过一个算法识别出的实例然后进一步发送到另一个算法以作进一步分析。通过对 SEQ 方法进行改进，它不是识别最高可疑异常实例，而是识别正常实例[32]。Chaurasia 等人提出了一种基于神经网络和 k 近邻分类器[33]的异常点检测集成方法。该方法在 KDD 数据集上实现，并利用 bagging 对多个分类器进行集成。在文献[34]中提出了一种分布式离群值检测方法，Dai 等人利用最近的邻居规则来实时检测离群值。传感器节点的多个故障不会影响系统性能，因为离群值可以可靠而有效地处理，但是在空间相关的聚类网络中，定义基于加权距离的离群值是一项开销。

与上述算法相比，我们需要一种时间复杂度和内存开销都较低的算法。本文采用隔离森林算法，该算法不同于基于密度或距离测量来检测异常。iForest 算法去除了计算距离的成本，一定程度上减少了算法计算的复杂度。由于 iForest 是一种整体的算法，当数据集包含大量数据时，树越多，算法越稳定。因为每个

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

树都是独立生成的，所以可以将其部署到大规模分布式系统上以加速操作。iForest 算法不仅具有较低的线性时间复杂度，而且满足了低内存开销[35]的要求。结合工业物联网大数据的特点，iForest 算法更适合该场景。

1.3 研究的主要内容

如前文所述，本论文首先分析了 5G 发展背景和工业物联网的研究现状，揭示了当前工业物联网大数据处理存在的问题和挑战。以工业生产作为背景和将检测大数据中异常值作为主要目标，提出了以核函数的主成分分析方法来选取数据的重要特征，接着使用隔离森林算法进行数据的异常值检测。具体来说，本课题主要研究内容总结如下：

1、以核函数的主成分分析的数据降维方法

在工业物联网中数据种类纷繁复杂，数据间可能还会存在特定联系。虽然维度的增加方便数据的分类，但是维度增大到一定程度将会产生维度灾难。高纬度数据会存在大量噪音或者无关维度。传统的低维连续域的异常检测算法不能有效地处理高纬度数据。比如，iForest 算法是一种不适用于高维度数据的异常检测算法之一。它依据随机选择的一个维度特征进行划分数据空间，损失了大量的维度信息，因而大大降低了 iForest 算法的可靠性。本文使用核化线性降维的方法来选择重要特征，为隔离森林算法找出异常数据做准备。

2、基于工业物联网下的 iForest 异常数据检测算法

在工业生产场景中，一般的异常检测算法由于时间复杂度高，不能及时地处理工业中海量的数据。文章提出低时间复杂度和低内存开销的隔离森林算法来检测工业物联网中的异常数据。该算法将机器学习和移动边缘计算相结合，可以实时地对数据进行分析及响应处理。它通过构建 iTree 来组成森林，iTree 的数量越多，iForest 算法的性能越稳定。由于所有的 iTrees 都是相互独立构建而成的，因此可以运行在大规模的分布式系统上。

3、仿真与验证

本文利用 Jupyter notebook 软件进行数据仿真与分析。首先选择合适的工业数据集进行数据降维。接着使用隔离森林算法进行异常值检测。最后与 KNN 异常检测算法和支持向量机算法作比较，观察运算时间性能指标、异常值的检出率和准确率，证明隔离森林算法在工业物联网中数据清洗有着更高的精确性和高效性。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

1.4 论文的章节安排

本文总共有六个章节的内容，具体的论文结构如图 1.1 所示，每个章节的内容安排如下：

第一章：绪论。主要介绍 IIoT 平台下数据异常检测的研究背景与研究意义，目前国内外的研究现状和存在的问题，同时对论文主要的研究内容和论文框架进行概述。

第二章：相关技术研究介绍。本章主要结合论文的研究方向，对相关技术进行介绍。首先介绍移动边缘计算网络架构，然后介绍数据降维和异常值检测等相关算法。

第三章：以核函数的主成分分析方法挑选重要特征的数据降维方案。将高维混合数据嵌入连续空间，从中选择一个较低维的子空间，这个子空间可以很好地分离出异常值。我们通过减小数据集的方法，使得数据集能够得到有效的处理。

第四章：基于隔离森林的异常检测算法。在降维后的数据集上，利用基于集体的检测异常算法，检测出异常值从而提高服务器的决策性。

第五章：仿真与分析。首先，介绍了仿真软件的特点和仿真运行的环境。其次，通过 MATLAB 软件进行数据的特征选择工作。接着，通过 Jupyter notebook 软件进行异常的数据检测，验证第四章隔离森林算法的合理性。最后，与 KNN 异常检测算法和支持向量机算法作比较，验证隔离森林算法在工业生产场景下的优势。

第六章：总结与展望。首先，本章主要对论文进行全方面的总结，接着，讨论论文存在的不足之处并对未来的研究内容进行展望。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

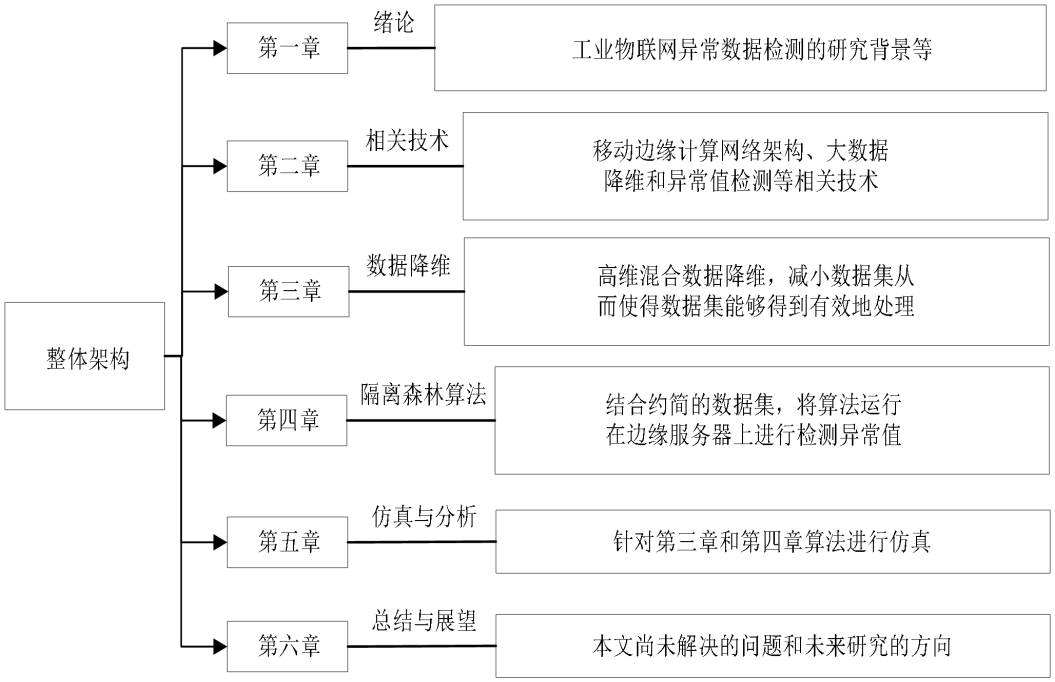


图 1.1 论文结构图

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第二章 相关技术

本章主要介绍了工业物联网大数据异常检测的相关技术。本章的第一部分，主要介绍移动边缘计算网络架构的特点以及优势。第二部分中，首先，简单地介绍 ML 中的相关基础概念。接着，介绍目前研究中几种数据降维的方法。最后，介绍工业物联网中几种经典的异常值检测的算法原理以及特点，为第四章节应用异常值检测算法奠定理论基础。

2.1 移动边缘计算的网络概述

工业物联网设备的迅速增加给骨干网络和中央云基础架构上的处理通信数据上带来了前所未有的压力。为了克服这个问题，最近提倡的 MEC 是一项很有前途的方案。MEC 是一项不断发展的技术，被认为是满足 IMT 对 5G 通信定义的技术的关键推动力之一。预计启用 MEC 的 IoT 可以有效减轻骨干网和中央云基础架构的负担，从而大大提高服务质量[36]。

移动边缘计算是一项从云计算发展演变而来的新技术，该技术可通过任务关键型 IoT 服务支持低延迟。在无线接入网(RAN)内提供应用服务运行环境、数据存储和云计算等功能，它为 5G 移动通信技术铺平了道路。随着对 MEC 深入的研究，研究人员不再局限于利用 MEC 解决云计算架构导致的网络延迟和拥塞问题。越来越多的研究人员正在利用移动边缘计算来实现支持 IIoT 的更多功能性服务，比如数据的预处理、应用程序的开发、本地服务提供和访问设备管理等。针对当前主流的工业物联网框架存在的问题，本文采用一种基于 IIoT-MEC 的网络体系结构，如图 2.1 所示。在此基础上，对 IIoT-MEC 的框架进行论证。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

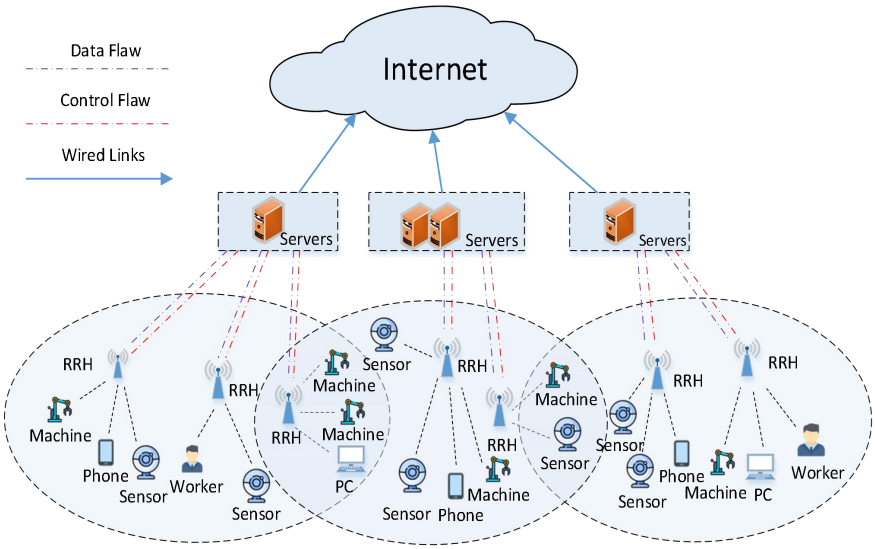


图 2.1 基于 IIoT- MEC 的工业物联网体系结构

2.1.1 设备层

设备层是工业物联网的核心部分，位于体系结构中的最底层。它主要负责信息数据采集的工作。感知层可以由许许多多的工业物联网设备组成，比如传感器、执行器、机器和终端设备等。这一层负责连接物理世界和数字世界。如同人类的感官一样，它可以使用各种传感器设备采集现实世界中的数据，然后可以使用工业现场总线、wiFi、bluetooth 和 ZigBee 技术等短距离无线通信技术进行数据传输。它主要承担两个功能。一个是收集数据并将其传递给上层，另一个是执行上层发出的命令。

2.1.2 IIoT-MEC 层

移动边缘计算层由宏基站、微基站和边缘服务器组成，集成了数据处理、通信和存储的功能。移动边缘计算层可以分为基础物理层、平台层和应用层。

（1）移动边缘计算的基础物理层：基于一般的服务器，采用网络功能虚拟化 NFV 的技术提供底层硬件的数据计算、数据存储、控制功能和网络等资源。

（2）移动边缘计算的平台层是：虚拟化的基础设施层上运行程序的必要功能的集合。它除了可以提供资源按需分配之外，还可以提供多个应用程序运行环境。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

（3）移动边缘计算的应用层：以容器或虚拟机方式运行的应用程序，比如工业物联网大数据的降维、异常检测等。移动边缘计算的应用层为第三方业务的运用商提供标准的 API。

2.1.3 云服务器层

云服务器层通常是由许多的高性能计算机构成，具有强大的数据存储和计算分析的能力。此外，云计算层的其他常见功能，比如大数据处理、网络资源管理、长期数据存储、服务器管理和远程开发等。高级云服务器不仅需要处理来自不同边缘服务器的数据，还需要从全局角度协调各种本地任务决策。

2.1.4 IIoT- MEC 网络架构的优势

与传统的数据清洗模型不同，该框架将传感器节点、聚合节点和云服务的一些工作转移动边缘服务器上，可以减少云服务器的工作量从而大大提高云的性能。由于 MEC 位于基站或无线电网络控制器上，它还可以提供对实时无线电和网络信息的访问，如用户位置、手机负载和应用程序，可以利用这些信息来提供与上下文相关的服务。MEC 还提供了一个以接近、超低延迟、高带宽以及实时访问无线网络信息的服务环境。另一方面，考虑到在汇聚节点上上传的数据可能会受到攻击，从而导致上传的数据不可靠。边缘服务器不仅能够抵抗恶意的攻击、还能提高吞吐量和降低传输延迟。此外，移动边缘节点能量[37]相对充足，与传统的无线传感器网络数据采集相比，移动边缘节点可以降低能量消耗，提高采集数据的效率。

在 MEC 框架中，我们将设备层划分为几个集群，其中可能包含工业设备、传感器和用户等。每个集群将被分配给边缘服务器，每个边缘服务器可以对采集的数据进行特征选择，并在采集的过程中快速删除异常数据，最后将数据上传到云端。在采集范围内，边缘节点会根据选择一个重要特征进行基于集体的离群点检测。根据收集到的可靠数据建立清洗模型，并不断迭代。与传统的清理数据模型不同，不再需要对每个感知层节点进行单独计算，只需要在移动节点进行计算。一方面，将传感器节点、聚合节点和云服务的工作部分转移到边缘服务上，可以大大提高云的性能。反之，如果汇聚节点在向汇聚节点上传数据过程中受到攻击，则上传的所有数据都不可信。然而，这种情况可以在我们提出的 IIoT-MEC 架构中得到改善，因为边缘节点有一定的能力来抵御恶意攻击。利用边缘节点收集、

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

清理和上传数据，防止恶意节点的攻击来提高安全性。在 IIoT-MEC 网络架构下，我们的算法也支持这些机制，算法构建的每棵树都是相互独立生成的，可以部署在大规模边缘服务器上进行运算，下面章节将对此进行详细阐述。

总而言之，我们的架构包括三个部分，与传统的数据清洗相比有三个主要优势：延长传感器的寿命、提高检测异常数据的效率和更加安全可靠。

2.2 机器学习算法介绍

本小节首先将介绍 ML 的相关基本概念，接着介绍论文中相关 ML 的算法和术语，比如数据降维算法和异常检测算法。

2.2.1 机器学习的基础概念

机器学习是一门涉及数理统计、概率论和数据挖掘的多领域学科。ML 使人们可以对计算机编程，以便机器可以识别模式或者从输入的内容中学习。ML 算法可以训练数据集，从中学习出模型，使得计算机能够作出预测或者分类。

ML 的训练过程如下图 2-2 所示：

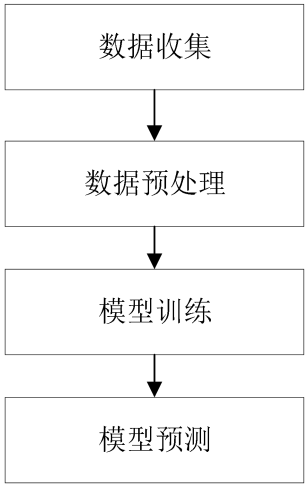


图 2.2 机器学习的训练过程

无监督学习方法与有监督学习方法可以用来训练数据集[38]。对于高纬度的数据，ML 的降维方法主要包括特征选择和特征提取[39]。

无监督学习[38]：利用没有标签的数据训练学习方法，训练数据并不知道类别，通过模型自我训练学习，对训练数据作出类别标识。大部分物联网系统和应

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

用程序采用无监督学习的技术，因为外部环境设置的初始值很少，比如，在面向零日漏洞攻击的 Iot 网络上绝对没有任何信息。

有监督学习[38]：有带标签的数据训练学习方法，通过训练数据集得到模型，接着用模型训练新的数据，确定新的数据标签。它会努力从数据集可用性中自动识别规则，并进一步定义几个类。最后，它考虑了对诸如标准，个人和对象之类的组件所有物的预测。

特征提取[39]：通过对原始特征空间的一系列变换生成新的特征空间，将原始的数据空间从 n 维度降到较低的 m 维空间，这 m 个特征最大程度地代表原始数据的特征。

特征选择[39]：不同于特征提取，无需改变原始特征意义，仅仅对原始特征进行筛选，去掉部分噪声和冗余的信息，留下最能够表达数据的特征信息，比如从原始的 n 维数据空间中选择 m 维数据空间，并没有改变原始特征空间。

2.2.2 数据降维算法

由于人为错误，传输过程中的噪声和其他干扰，从工业过程系统收集的数据可能会在过程中丢失，从而影响数据的整体质量。另外，由工业控制系统收集的数据通常由大量的高维数据组成。高维数据存在样本数据稀疏、大量的非相关特征而导致计算复杂度高的问题，也被称为“维数灾难”。可以通过数据降维的手段来解决“维数灾难的问题”，即利用线性或者非线性的变化将初始高纬度空间的数据样本映射到一个低维度空间。在这个低纬度空间中，数据样本的密度会大幅度的增加，非相关特征也会减少，异常值检测算法也会变得更加简便。数据降维手段包括特征选择、线性代数方法、投影方法和自动编码器[40]。特征选择主要分为三类：包装、过滤和混合方法。作为选择过程的一部分，包装器方法试图优化一些预定义的关于特征集的标准，换而言之，包装式的特征选择为给定训练算法选择最合适的特征子集。虽然算法具有较高的准确率，但是时间代价较大。过滤方法依赖于训练数据的一般特征来选择相互独立且高度依赖于类标签的特征。它具有较强的通用性，目前应用在特征选择的过滤式方法包括粗糙集、多目标粒子群算法、共同空间模式等。混合方法试图利用包装和过滤方法[39]的特性。如文献[41]使用了相关系数(CC)来衡量特征之间的相关性，作为筛选特征的手段。CC 是最简单的特征选择方法，它的目的是消除最相关的特征。当一个相关值接近于+1 或-1 时，这些特征是高度相关的，从而分散了最终特征集的注意力。零相关值表示特征之间没有相关性。选取排名最低的 N 个特征作为最重要的特征。文献[42]利用深度前馈神经网络(DFFNN)生成嵌入特征来降低数据维数。嵌入的特征是将

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

输出层从 DFFNN 中移除后的最后一层。在文献[43]中，提出了一种两步混合方法。第一步是使用皮尔森和费雪滤波器选择特征子集。第二步使用第一步的输出作为包装器方法的输入。包装步骤使用 k -近邻和随机森林树(RFT)根据 F1 评分选择特征。此外，包装步骤考虑了序列前向特征选择(SFFS)和序列后向特征消除(SBFE)两种分类器。文献[44]提出了一种混合方法来检测天气传感器数据中的异常值。该方法包括降维，预测的分类和模式分类三个阶段。通过使用连续的方差分析方法来实现降维去除不相关的特征。但是方差分析方法要涉及全部数据，并且计算复杂。

本文提出了基于核函数的主成分分析的特征选择方法。KPCA 算法采用非线性变换将输入数据空间映射到高维度空间，将非线性问题转化为线性问题。然后利用高纬度空间的主成分分析方法提取主成分。主成分分析作为一种线性降维的技术，通过对数据变化程度的获取来判断最优性。它识别出若干相互正交的向量，称为加载向量，根据方差对加载向量的方向进行排序。假设数据集 X 有 n 个测量变量和 m 个样本。用 PCA 对数据矩阵进行分解，从 n 个变量中提取 k 个主成分，使 k 个主成分中的任意两个主成分不相关。k 小于 n，达到降维目的。这里的分解方法可以有协方差矩阵谱分解、奇异值分解、迭代算法等。分解后，原始数据空间 X 变成主成分空间和残差空间，其中主成分空间中的 k 个主成分反映了数据主要信息的变化，而残差空间主要反映了测量误差和噪声的影响，所以 PCA 可以抑制噪声的影响，减少系统冗余。PCA 算法的主要优点是，一旦找到模式并压缩数据，即通过减少维数而不会丢失太多信息。但是，传统的主成分分析是一种常见的线性降维算法，线性降维是指将高维空间通过线性函数映射到低维，它可以从高维变量中提取出低维的少数分量，虽然降低了数据的维数和复杂度，但所提取的特征只能表征器件状态的线性，丢失了原始数据中的非线性成分和有效信息，应用于实际场景时不能很好地满足预测目标。以核函数的主成分分析算法是基于主成分分析，利用核函数将原始数据映射到高维线性特征空间，然后利用主成分分析方法进行特征提取[45]。以核函数的主成分分析算法可以解决 PCA 算法无法处理的非线性特性问题。

总而言之，数据降维是用来减少实验样本的数量，可以分为特征选择与特征提取两种方法。特征选择方法是从初始数据空间中查找相关度最高的特征变量即初始特征变量的子集，特征提取方法是将高维度空间的样本提取特征转化为低维空间，即低维空间的样本数据能够更大程度上代表原始数据集。数据降维的后果是舍弃一部分信息，但是能够使得数据实例的密度增大，这也正是数据降维的正要动机。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

2.2.3 异常检测算法

随着 IIoT 技术的进步，传感器收集与存储的数据的准确性变得至关重要。数据清洗以去除异常值为目的，是部署数据挖掘技术以提高传感器数据的精确性的基本步骤之一。由 Hawkins 提出的异常值的标准定义，它指出异常数据是一种与其他大部分数据不相关、不一致或恶意的数据，通常异常数据只占所有数据集中一小部分。从数据集中识别和删除这些数据的过程称为异常值检测。忽视工业物联网中的异常数据是特别危险的行为，把影响决策的异常值加进正常数据中计算分析，会使得研究人员作出的错误的决策。常于异常值检测的方法主要有：基于聚类的方法、基于分类的方法、基于整体的方法以及多种技术结合的混合方法，具体如图 2.2 所示。

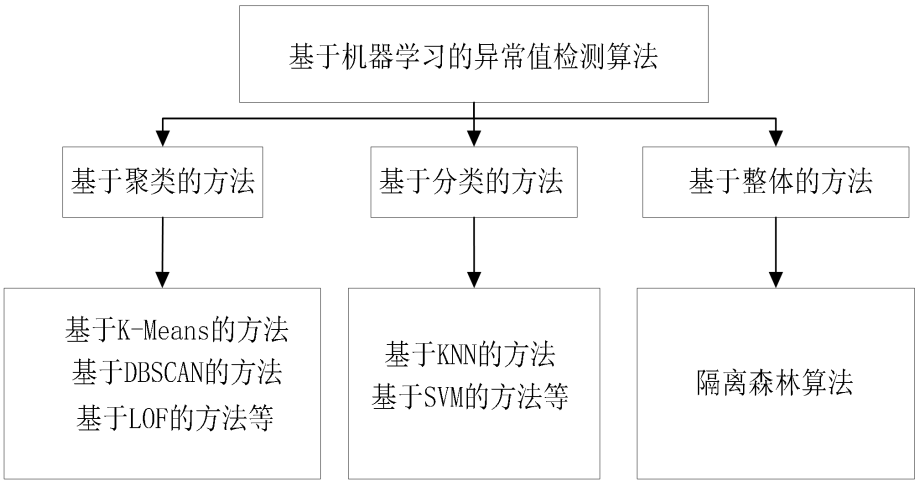


图 2.2 异常值检测算法分类图

(1) 基于聚类的异常值检测算法

基于聚类的方法是依据数据实例的相似度或者差异性划分为几个聚类。将离群点标记为不属于任何集群的点或者一个集群中的数据量明显小于其他集群中的数据量。

K-means 算法将实验的数据集划分为 K 个簇，以保证簇内数据相似度较高，簇间相似度较低，然后，将每个聚类中心点与其所有成员进行比较，具有一定距离的成员可以被视为异常[46]。K-means 作为一种无监督学习算法，算法简单，时间和空间复杂度是线性或者接近线性，但是聚类结果对 K 参数的选择非常敏感，不同簇个数产生的结果完全不一样且容易受到噪声的影响。Kumari 等[47]利用 K-Means 算法对网络上相关的流量异常检测进行了研究。这样做是为了发现用户具有破坏性的可疑行为。该研究是通过将用户活动与特定代码分组进行的，这可以防止对特定网络的攻击/破坏。Zhang 等[48]研究通过确定电池的充电、放电、

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

释放等特性来检测电池的状态。确定电池是否仍然处于良好状态的方法是将这些特征以某种曲线的形式与使用 K-Means 方法进行异常估计的结果进行比较。通过这项研究，可以更可靠、安全、高效地了解电池的状态。

Ester 等人于 1996 年提出了 DBSCAN 算法，这种算法是一种基于密度的聚类算法[49]。与基于距离的 K-means 聚类算法不同的是，它不需要事先知道簇的数量即 K-means 算法中的 K。DBSCAN[50]的核心思想描述如下：从空间数据集中选择一个点 A，如果 A 是核心点，以 A 为圆心的圆周围所有的点包括 A 点都是同属一个集群，圆内其他的样本点将后面的候选点，查找这些候选点以扩展其聚类，直到找到完整的聚类。如果 A 不是核心点，它将被暂时标记为离群值，重复上述过程以扩展其他集群，最后不属于聚类的点便是异常值。因为通常都用欧几里得距离来衡量点是否可以划分为同一簇，使用传统的距离测量很难定义高维数据的密度，所以说 DBSCAN 不适合用于高维数据聚类。此外，DBSCAN 对输入参数(如邻域半径)很敏感，研究人员选择的中心点和半径太大或太小，都会导致聚类结果不准确[51]。DBSCAN 具有与 K-Means 类似的高计算复杂度，在高维数据和数据量巨大的工业物联网中，算法效率低下。

局部离群因子算法是一种基于密度的异常值检测算法。LOF 为数据集中的每个点赋值一个离群度，离群度最大的数据点便被标记异常值。在文献[52]中提出了一种基于改进 LOF 算法的异常网络流量检测方法。通过分析传统 LOF 算法中参数的特征，将模型与 DBSCAN 算法结合，以实现针对变化的数据对参数进行自适应动态调整，并优化了网络流量场景的准确性。然而 LOF 在处理海量或者高维数据具有高的复杂性。在实际应用中，通常不能准确判断异常点的情况。尤其是应用于工业生产场景时，算法参数 MinPts 的选择对结果影响很大。当参数 MinPts 不适合选择时，算法可能会将大量的正常数据视为异常值，或将一部分异常值视为正常数据。因此，如何正确配置参数 MinPts 的值是提高算法精度的一个非常重要的部分。

(2) 基于分类的异常值检测算法

KNN 算法是一种距离的异常值检测算法。文献[53]描述算法的核心思想：通过给定的预定义的参数 n 和 k(n 表示待发现的异常值的个数，k 表示最近邻居的个数)，计算每个点到其第 K 个最近邻居的距离，接着对所有计算的距离进行排序，将排序中距离最大的前 n 个数据点视为异常值。由此可见基于 KNN 的离群检测方法对 k 值敏感，k 值选择不同明显影响算法的性能和结果。

Vapnik 推出的支持向量机在样本数据之间构造超平面进行分类。如果数据是不可分割的，则可以将实验样本映射到高维度空间，在高维空间中构造超平面进行分类，从而进行异常值检测。在文献[54]中，作者采用 One-Class-SVM 的离群

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

点检测方法进行泄漏判断。One-Class-SVM 是一种无监督的支持向量机算法，通过学习检测决策函数，将新数据分类为与训练集类似或不同的数据。现有的基于 SVM 的异常值检测方法都是基于向量表示的，然而对于高维工业数据，基于向量的方法可能会破坏它们之间的相关关系和原始的结构信息，最终导致对一些异常值的错误判断。因此，在文献[55]中，提出了一种张量表示和一类支持塔克机(OCSTuM)用于传感器数据的异常值检测，OCSTuM 通过塔克分解将 OC-SVM 扩展到张量空间，在异常值检测性能上优于单类算法，但由于迭代步骤耗时较长，导致执行时间较长。因此，进一步提出了 GA- OCSTuM 方法来解决这一问题，该方法使用遗传算法(GA)来选择传感器数据的特征，识别最优模型参数。然而，这个方案作为一种集中式算法而不能运行在边缘服务器上。

(3) 基于隔离森林的异常值检测算法

隔离森林算法[35]于 2008 年由 zhou 等人提出，核心思想是把异常值当作分布稀疏或者是离密度高的集群标远的点，不同于以上的算法，iForest 训练的样本无需带有标签，通过随机选择一个特征作为超平面来分割数据，每次的分割都会有两个数据子空间产生，接着递归地随机分割数据集，直到每个子空间里面只有一个数据实例为止。简而言之，密度高的集群可能需要被切割很多次才能停止，但是远离高密度集群的点只要很少次就停到了子空间里。这是一种基于整体数据的异常检测方法，具有线性时间复杂度、准确率高的优点，且能够满足大数据处理要求的新算法。虽然 iForest 算法提出来的时间不是很长，但它的应用却十分广泛，比如数据的除噪、金融交易欺诈检测和疾病检测[56]。此外，iForest 是一种无监督学习算法，它不需要标记或分类信息来训练机器。iForest 不适合处理高纬度的数据，每次随机地切割数据空间致使大量的维度信息没有使用，从而可靠性降低。本论文将结合以核函数的主成分分析方法挑选重要特征进行数据降维，通过改进的 iForest 算法能够处理高维数据。

2.3 本章小结

本章首先介绍了工业物联网场景下移动边缘计算网络架构的基本定义以及特点。然后，介绍了机器学习的基础概念。接着，介绍了工业大数据下数据降维算法。最后，介绍了异常值检测算法中几种经典的算法之间的优势与不足之处。下一章将主要介绍以核函数的主成分分析方法挑选重要特征进行数据降维。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第三章 基于 KPCA 的数据降维方案

上一章节简单介绍了论文研究过程中所涉及的机器学习的相关技术，为后续工作的展开奠定好了良好的基础。本章提出了一种以核函数的主成分分析方法来选择重要样本特征，将高维度混合数据嵌入到连续空间中，最后将得到的数据集用于无监督的异常值检测算法中。

3.1 问题描述与相关工作

随着对工业物联网(IoT)的研究日益深入，大量的传感器已广泛应用于生活中的各个领域，我们目睹了实时，流式传输和高维数据量的快速增长。工业物联网满足了大数据的 5V 特征：量、速度、多样性、准确性、价值。在工业数据中，高维数据不仅会增加 ML 训练模型的处理时间，还会携带大量噪声，影响训练模型的精度。特征选择能够很好的克服这些问题带来的负面影响，提高模型的训练性能。因此，特征选择是克服异常检测模型性能差问题的必要步骤。特征选择是预处理数据阶段[57]的关键步骤，定义为基于合理准则选择最小特征子集的过程，目的是提高算法性能[58]。同时，它被定义为去除无关的、冗余的和有噪声的特征[41]的过程。有时，它被称为相关的特征识别过程[59]。就算法的复杂度和准确性而言，特征选择对异常值检测算法的性能会有很大程度上的影响，它只在数据类型之间选择最相关和最显著的特征，它减少了不需要考虑的特征数量，从而降低了问题[41]的复杂性。此外，通过消除噪声、冗余和无用的特征，异常值检测的准确性提高了，产生的假警报数量也减少了。

在上述研究的基础，本文既要考虑到节省边缘服务器的资源空间，也要考虑到复杂的非线性系统而导致一些降维算法的精确性下降的问题，我们利用以核函数的主成分分析方法将复杂的非线性问题转化为线性特征空间问题，去除不相关的特征，有效地处理大量的数据。首先应用 KPCA 算法从数据集中选择重要的特征，然后只考虑这些特征进行进一步分析。显著特征是那些对分析结果有很大影响的特征，或者换句话说，与最终输出高度相关的特征。实验结果表明，KPCA 算法不仅可以保持结果稳定，而且可以保持数据的相似性结构。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

3.2 基于 KPCA 的特征选择方法

以核函数的主成分分析方法是 PCA 算法的非线性提升[60]。PCA 是一种线性的算法，对于非线性工业数据处理效果不是很好，而 KPCA 算法能够挖掘到工业数据集中隐藏的非线性特征。与 PCA 比较，KPCA 算法利用非线性映射函数 ϕ，将样本数据从低维子空间转换到高维空间 F，最终在高维空间 F 的基础上执行线性 PCA。

3.2.1 核函数以及参数选取

在 KPCA 算法中，核函数和核参数的选择非常重要。核函数和核参数直接影响实际应用。核函数的定义：如果存在一个将数据 X 映射到 P 的函数 $\phi(x):X\longrightarrow P$，使得所有 x,z 属于 X，函数 $K(x,z)$ 满足的条件：$K(x,z)=\phi(x)\bullet\phi(z)$，则 $K(x,z)$ 为核函数，ϕ 为映射函数。

核函数的类型比较多样，常见的核函数如下：

（1）高斯核函数：

$$k(x,y)=\exp(-\frac{\|x-y\|^2}{2\sigma^2}) \tag{3-1}$$

（2）多项式核函数：

$$k(x,y)=[(x,y)+\theta]^d \tag{3-2}$$

（3）感知核函数：

$$k(x,y)=\tanh[v(x,y)+c] \tag{3-3}$$

本文采用高斯核函数，通过选择合适的σ值，高斯核主成分分析将有一个合适的捕获范围，这将增强原始特征空间中相互接近的数据点之间的联系。然后通过特征向量分析，使得特征向量能够最大程度地描述不同数据簇分散在高维空间中的方向。理论上，通过选择合适的核参数，可以完全解决非线性问题。因此，高斯核函数比其他核函数具有很好的灵活性。

此外，在 KPCA 算法中，k 值指的是从样本的特征属性中选择需要保存的主成分数量。假定 k 值选取过大，实验样本压缩率低，当 k 值等于 n 个特征时，相当于原始的实验样本；如果 k 值选取过小，那么数据的误差太大，k 个特征属性不能够代表原始的实验样本。一般取 k(主成分数)最小，得到有效对角线元素之和(对角线化后得到)与所有元素之和的比例，该比值一般在 0.95-0.99 范围内，相应的值被认为是需要考虑的主要成分。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

3.2.2 KPCA 算法步骤

基于 KPCA 的算法首先将实验样本 $x_i(i=1,2,3,...,n)$ 从低维的子空间变换到高维特征空间。然后在高维的特征空间中继续采用 PCA 算法分析实验样本 $\varphi(x_1),\varphi(x_2),\varphi(x_3),...,\varphi(x_n)$。下面介绍算法的细节：

首先，

$$x_i \to \phi(x_i) \tag{3-4}$$

并且高维特征空间 H 中的数据满足集中化条件：

$$\frac{1}{n}\sum_{i=1}^{n}\phi(x_i)=0 \tag{3-5}$$

于是在高维特征空间中，协方差矩阵为：

$$C=\frac{1}{n}\sum_{i=1}^{n}\phi(x_i)\phi(x_i)^T \tag{3-6}$$

求解协方差矩阵的特征值、特征向量：

$$\lambda\sum_{i=1}^{n}\alpha_i\phi(x_i)=C\sum_{i=1}^{n}\alpha_i\phi(x_i) \tag{3-7}$$

为得到核函数的形式，求解 $\varphi(x_k)(k=1,2,3,...,n)$ 的点积和上式：

$$\lambda\sum_{i=1}^{n}\alpha_i(\phi(x_k),\phi(x_i))=\frac{1}{n}\sum_{i=1}^{n}\alpha_i\sum_{j=1}^{n}(\phi(x_k),\phi(x_j))(\phi(x_j),\phi(x_i)) \tag{3-8}$$

定义 $N\times N$ 核函数：

$$K_{i,j}=k(x_i,x_j)=(\phi(x_i,x_j)) \tag{3-9}$$

根据式（3-9)，式（3.8）可以被化简为：

$$n\lambda\alpha=K\alpha \tag{3-10}$$

式（3-10）中 $\alpha=(\alpha_1,\alpha_2,\alpha_3,...,\alpha_n)^T$，$\alpha_1,\alpha_2,\alpha_3,...,\alpha_n$ 便是矩阵 K 的特征向量，特征值是 $\lambda_1\geq\lambda_2\geq\lambda_3\geq...\geq\lambda_n$。

最终原始样本数据在高维特征空间中的映射数据沿其对应特征向量方向上的投影便是我们需求的非线性主成分向量：

$$t_k=\sum_{i=1}^{n}\alpha_i^k K(x_i,x) \tag{3-11}$$

式（3-5）中推导假设映射数据的均值为零。然而，实际情况和理想状态存在着差异。我们可以通过以下方式解决这个问题：

将映射数据集中：

$$\bar{\phi}(x_i)=\phi(x_i)-\frac{1}{n}\sum_{i=1}^{n}\phi(x_i) \tag{3-12}$$

相应的核函数：

$$\bar{K}_{i,j}=(\bar{\phi}(x_i),\bar{\phi}(x_j))=K-1_n K-K 1_n+1_n K 1_n \tag{3-13}$$

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

式（3-13）中，ln 是一个 n*n 的矩阵，所有元素都是 l/n。

在得到特征值λ和特征向量α后，通过 Schmidt 正交化和单元化得到一个新的特征向量β。然后通过累积贡献率提取第一个 t 个特征向量$\beta_1,\beta_2,\beta_3,...,\beta_t$。最后，$\beta_1,\beta_2,\beta_3,...,\beta_t$便是特征提取后的数据。

综合以上的分析，可以提取出特征数据，整个 KPCA 算法的伪代码如算法 3.1 所示。

算法 3.1 以核函数的主成分分析算法

1:procedure K - PCA(X)

2:Given Input: $R_{n\times m}\leftarrow[x_1,x_2,x_3,...,x_m]$

3:Centralize: $X_{centered}\leftarrow X_{n\times m}$

4:Kernel Matrix: $Km\times m:kij\leftarrow k(x_i,x_j)$

5:Centralization in F space:

6: $K:K\leftarrow K-1_n K-K1_n+1_n K1_n$

7:Extracting eigenvectors: $n\lambda\alpha=K\alpha$

8:Normalization:

$$\alpha\leftarrow\frac{\alpha}{\mathrm{mod}(\alpha)\sqrt{m\lambda}}$$

9:loop: $i\leftarrow 1:p$

10: $P_i(x)=\sum_{i=1}^{m}a_{ij}k(x_i,x)$

11:goto top

本文所提出的 KPCA 数据降维算法如上所述，并在此基础上利用 MATLAB 软件进行了实验仿真。具体仿真详见第五章仿真与分析。

3.3 本章小结

本章提出了一种基于 KPCA 的非线性数据降维算法。首先，在本章的第一节中描述了工业物联网大数据的特性，为了消除噪声、冗余和无用的特征，需要引入特征选择的技术。接着，第二节中首先介绍了高斯核函数、多项式核函数和感知核函数以及参数选取，最终我们选择了更加灵活的高斯核函数。然后，详细描述了 KPCA 的数学模型。线性主成分分析只能提取两个可见的聚类，核函数

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

是线性到非线性之间的转换媒介，以核函数的主成分分析可以更好地在二维子空间中可视化。KPCA 算法除了通过特征提取来减少数据集的维度之外，还可以达到增加样本的密度和达到去噪的目的。下一章将主要介绍基于 KPCA 方法下的隔离森林的异常检测算法。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第四章 基于隔离森林的异常检测算法

上一章节主要针对工业数据提出了以核函数的主成分分析的降维算法。本章内容是在第三章数据预处理下再对数据进行异常检测。本章主要提出了一种在移动边缘节点的数据清洗方案，在边缘节点上采用隔离森林常检测方法。这是一种具有较低的时间复杂度、较高的检出率和准确率的算法。

4.1 问题描述与相关工作

如今，物联网、传感器技术和嵌入式系统等已经无处不在。由于这些技术的进步，工业系统产生了大量的数据，为了从海量的数据中提取有价值的信息，大数据分析应运而生。从海量数据中检测异常事件更是一项具有挑战性的任务。异常事件或异常值是指无法确认系统预期行为的事件。异常值不仅会使得上传带宽和节点能耗增加，还会严重影响分析结果。这需要新的框架和技术来从这些应用程序中检索有意义的信息。根据数据可用信息的类型，离群点检测方法可以分为不同的三类[61]。第一类是基于检测离群点的监督分类模型。在这种方法中，标记数据(标记为正常或异常的数据)是可用的，分类器在此基础上进行训练。接着使用训练后的分类器把新样本分为正常样本与异常样本。在这个学习模型中，如果正常实验样本和异常实验样本的参数发生变化，则需要再次训练分类器。在第二类中，使用半监督学习模型检测异常值。在这种方法中，分类器是在数据的清晰泛化上训练的，然后用于离群点检测。只要数据可用，模型就会渐进地学习，以便适应数据中的变化并相应地进行分类。第三类中，使用无监督学习模型检测异常值，该方法需要基于正常和异常实例可被很好分离的条件。因此，本文使用无监督学习模型进行数据集分类。

在机器学习方法方面，基于密度的局部离群因子分析用于检测[62]中低质量的同步相位数据测量。文献[63]提出了一种结合隐马尔可夫模型(HMM)的混合聚类算法来检测事件。在文献[64]中，作者提出了分层聚类的事件检测方法。然而，基于密度或基于距离的聚类方法计算复杂度高，不适合在工业系统中在线实现。针对工业数据集中的异常点检测速度慢、准确性低的问题，本文提出了一种基于整体的 iForest 异常点检测方法，在存在低质量数据测量的情况下实现快速事件检测。在该方法中，首先，采用基于相关性的降维技术对数据集进行降维。然后，

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

为了检测异常事件，在相同简约的数据集上，同 KNN 算法和 SVM 算法对比，来证实 iForest 算法是一种时间复杂度和空间复杂度低的异常值检测。

4.2 基于隔离森林算法的检测模型

为了证明 iForest 算法能够对传感器的异常数据进行判断，我们选择从算法的判断原理来说明。首先，对于高维数据，iForest 会选择一个环境属性进行判断，我们利用 KPCA 算法把数据集进行了降维处理，选择出与这个环境属性高度相关的特征，并进行基于 iForest 的异常判断，在最后阶段再进行组合。对于单个属性的工业环境数据，比如 PM2.5 浓度、湿度、温度和气压等，这些属性的值都是按时连续的，满足 iForest 的输入条件。简而言之，此方法是在数据集的单个属性中随机选择一个值，把大于和小于该值的数据进行划分到左右子树，之后在分开后的各部分内重复这个过程直到空间只有一个值被划分出来，此时我们只要计算样本所在二叉树的深度，样本在二叉树中的深度越大，异常值的可能性越小。反之，样本在二叉树的深度越小，异常值的可能性越大。在服从正太分布的传感器数据集中，传感器的数值过小或者过大都可能是异常行为表现，这值得引起研究人员的注意。接下我们详细介绍 iForest 的构造方法。

4.2.1 隔离森林的构建子模块

iForest 是由大量的树(iTree)构成的，每一棵子树都是是二叉树。本模块的二叉树的基础构造特征为工业环境的 PM2.5 浓度、温度、湿度、气压、热指数和风速。每棵孤立树中的样本数据集是采用 KPCA 方法降维后的优化样本数据，去掉了电压、电流等对工业环境影响不相关的特征。改进隔离森林算法的具体的步骤如图 4.1 所示：

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

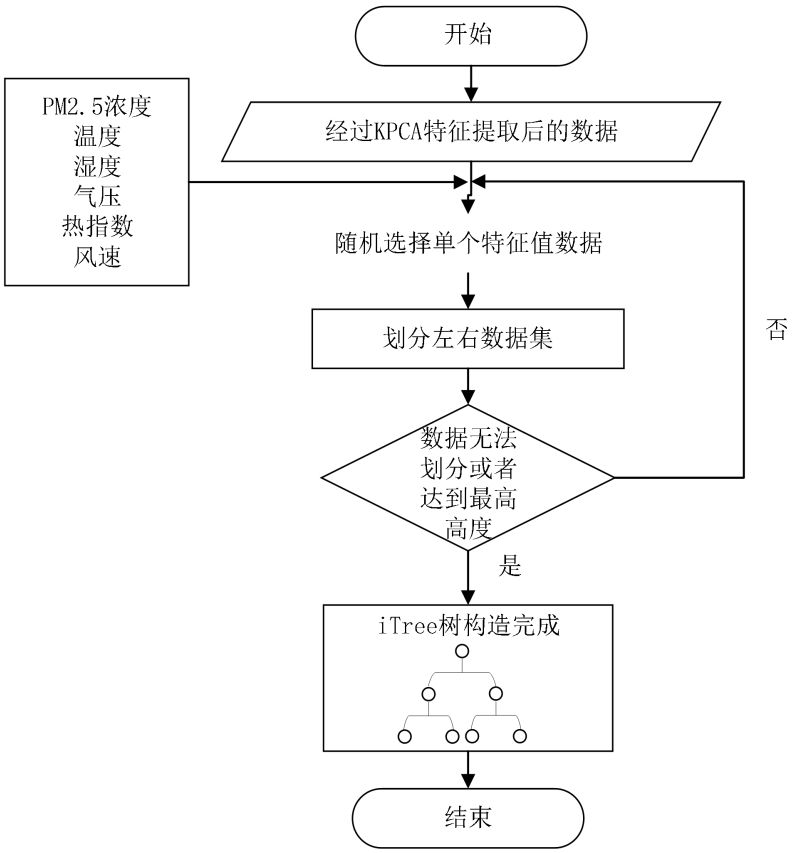


图 4.1 iTree 的构建流程图

我们每次从优化好的实验样本中随机选取一个特征，然后在该特征中随机选一个样本值，样本值属于与最大值和最小值之间，利用该样本值把实验样本分为两个分支，接着，递归地继续，直到不能被划分为止，从而构造一个二叉树- itree。在对异常值进行判断时，我们会发现异常值在 iTree 树中的深度较浅。主要步骤如下：

(1)在六项工业环境指标中选择一个指标 q，将子样本集放入树的根节点中。

(2)在随机指定的特征 q 中随机选择一个样本值 p（样本值介于当前抽样数据中指定特征的最大值和最小值之间）。

(3)用此随机选择的超平面 p 来切割数据空间。将当前抽样数据划分为 2 个类：第一类为小于样本值 p 的实验数据并且将它们放在父节点的左孩子节点，第二类为大于样本值 p 的实验数据并且将它们放在父节点的右孩子节点。

(4)在左右孩子节点中递归步骤 2 和 3，不断构造新的孩子节点，直到孩子节点中满足以下任意条件停止。

a.树达到了限制高度

b.节点上的样本所有特征都相同

c.节点上有且只有一个样本，不能继续划分

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

当一颗 iTree 完全成长时候，每个样本都会被分别隔离到一个外部叶子节点。这时，外部节点数据为 S，与子采样规模相同；内部节点的数目是 S-1；iTrees 的节点总数为 2S-1。综上所述，在工业环境检测系统中，本文提出的 iTree 的构建的伪代码如图 4.1 所示。

算法 4.1 iTree 的构造

Require: sets of industrial equipment $S=\{x^{(1)},x^{(2)},x^{(3)},...,x^{(n)}\}$, h - current iTree height

Ensure: an iTree

1: Initialize Forest

2: Maximum height of each tree H_{max} is set to 8

3: if $h \geqslant 8$ OR $D_i \leqslant 1$ then

4: return exNode ($Size \leftarrow D_i$)

5: else

6: Randomly select an attribute q;

7: Randomly select a split point p between main and max values of attribute q in D_i;

8: $D_l \leftarrow filter(X, q < p)$,

9: $D_r \leftarrow filter(X, q \geq p)$;

10: return inNode (Left $\leftarrow iTree(D_l, h+1)$, $Right \leftarrow iTree(Dr, h+1)$, $SplitAttr \leftarrow q$, $SplitValue \leftarrow p$)

11: end if

4.2.2 森林的构建

单棵 iTree 构造完成后，iForest 模型可由许多的 iTree 的共同构建。其构建过程如图 4.2 所示：

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

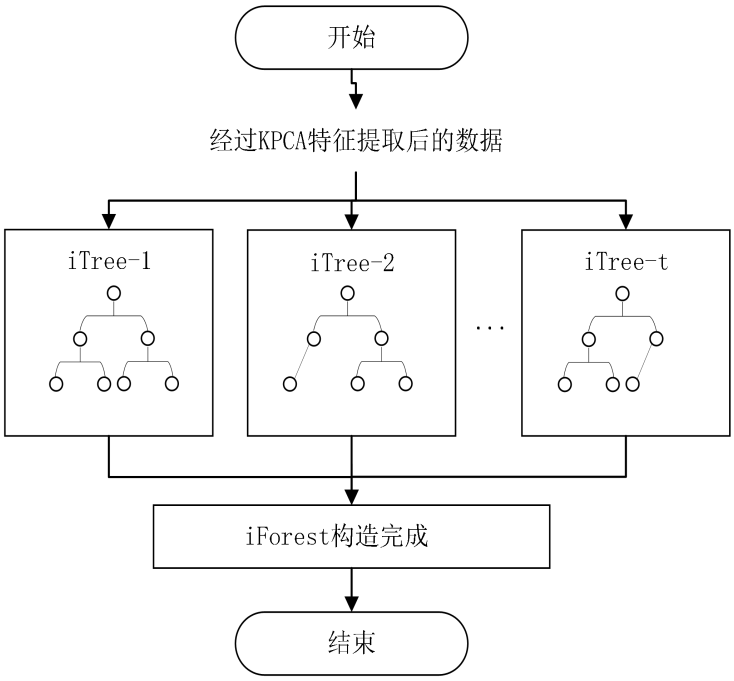


图 4-2 隔离森林构建流程图

iForest 是一组 iTrees 的集合，其有 iTree 的数目 t 和子采样规模 n 两个参数，需要研究人员在 iForest 模型的构造之前设置好 t 和 n。通常 iTree 的数目越多，算法的精确性就越高，其实现效果也越好。但是算法运行时间也会逐渐增加。因此，需要研究人员对比选取不同的 iTree 的数目 t 的实验效果，找到合适的 t。除了找到合适的 t 值之外，还需要关注树的高度。由于工业环境的监测数据符合正太分布，异常的样本比较少，异常值在二叉树中的深度比较低，我们只需要关心在二叉树中深度低于 iTree 平均高度的那部分数据。具体构造 iForest 的伪代码如 4.2 所示如下：

算法 4.2 隔离森林的构建

Inputs: S- raw training data set, t-number of iTree, n-Sub-sampling size

Output: iTrees

1: Initialize *Forest*

2: set height limit $h = ceiling(\log_2 n)$

3: for i=1 to t

$S' \leftarrow$Data sampling(S, n)

$Forest \leftarrow Forest \bigcup iTree(S')$

4: end for

5: return *Forest*

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

4.2.3 隔离森林判定异常

iForest 构造成功之后，需要对实验样本进行异常判定。会通过复现隔离树构建的过程，来计算出实验样本的路径高度。接着，计算出实验样本在森林中的平均路径高度，并代入公式计算出异常分数，最后根据异常分值排序判定出异常。其判定过程如图 4.3 所示：

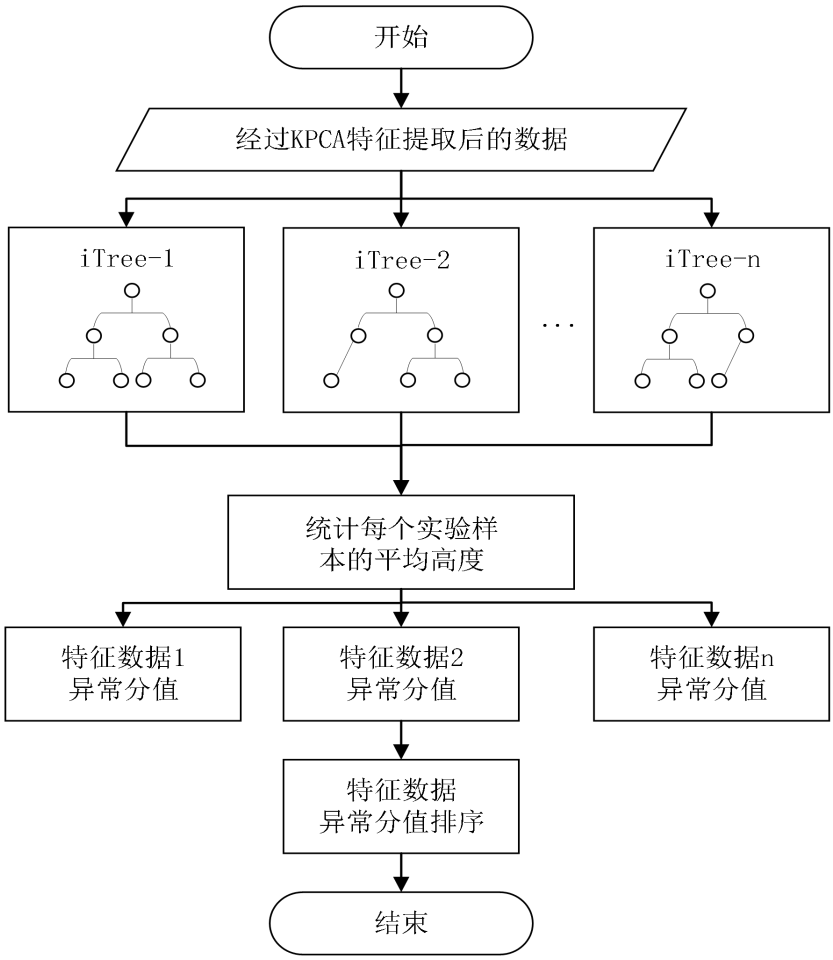


图 4-3 隔离森林构建流程图

比如，当实验样本 n_1 从根节点开始遍历一棵 iTree，直到叶子节点时，该样本在这棵树上的路径长度 $h(x)$ 可以通计算 iTree 边的数量得出。接着，得出实验样本 n_1 在每棵树上的路径长度的集合。最后，计算集合的所有元素的均值，该均值便是 n_1 的平均路径长度如公式(4-1)所示。

$$c(n) = 2H(n-1) - (\frac{2(n-1)}{n}) \tag{4-1}$$

其中，$H(x)$ 调和函数，可以估计为 $H(x)+\varepsilon$，$\varepsilon = 0.5772156649$ 是欧拉常数。因为构造的树的高度归一化不方便表示，所以 $c(n)$ 用来标准化路径长度的。通过 $c(n)$ 可以进一步将异常值归一化。归一化的公式如式(4-2)所示。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

$$score(n_1,n)=2^{-\frac{E(h(x))}{c(n)}} \tag{4-2}$$

通过式（4-2）可以求得样本n_1在采样的 n 数据中异常分数。$E(h(x))$为数据在在所有 iTree 上的路径长度期望。经过 iForest 算法输出的分数是一个 0 到 1 之间的。

- 如果$E(h(x))\to H_{\max}-1$，$score(n_1,n)\to 0$，$H_{\max}$表示 iTree 的最大路径深度，当n_1的样本在所有的孤立树上的平均路径越接近采样的 n 数据的树的最大路径深度，异常分数越是接近零，此时n_1可以当作一个正常样本。
- 如果$E(h(x))\to 0$，$score(n_1,n)\to 1$，当n_1的样本在所有的孤立树上的平均路径越接近 0，异常分数越是接近 1，此时n_1可以当作一个异常值样本。
- 如果$E(h(x))\to \text{ave}(H)$，$score(n_1,n)\to 0.5$，当n_1的样本在所有的孤立树上的平均路径越接近 0.5，异常分数越是接近 0.5，需要对异常分数进行排序，来确定n_1异常情况。假如当大部分实验样本的异常分数近似 0.5，那么说明整个样本集中没有异常值。

实际上，在工业环境数据的异常监测方案中，若上述的环境越恶劣则代表其异常程度越高。此时，该测试样例在 iForest 异常检测模型中更容易被检查出来，即该测试样本路径深度较短，异常得分较大。具体 iForest 异常判定的伪代码如 4.3 所示如下：

算法 4.3 隔离森林异常值判定

```
Inputs: n1 - an Sample instance, T-an iTree, e-current path length;
Output: The length of the path  L
1: if T is an external node then
2:     return e+c(T.size)
3: end if
4: a ← T.splitAtt
5: if x_a < T.splitValue then
6:     return PathLength(x, T.left, e+1)
7: else{x_a ≥ T.splitValue}
8:     return PathLength(x, T.right, e+1)
9: end if
```


(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

4.3 隔离森林算法参数设置

iForest 是 iTrees 的集合，其中有两个参数 iTree 的数目 t 和每次抽样的规模 n 需要研究人员手动设置。文献[35]发现当 n 值增加到 256 时，对于大范围的数据进行异常检测就足够了，而不需要再增加 n 值。因为 n 的增加会使得数据处理的时间和内存大小也逐渐增加。但是，如果采样规模 n 和 iTree 的数目 t 偏小，可能会检测不全数据集，遗漏部分重要的数据。在本文中，我们针对工业的数据集经过多次实验，得出了图 4-4 和图 4-5，分别是采样规模 n 和 iTree 的数目 t 与数据覆盖率的关系图表。最终，我们选择了将采样规模 n 设为 280，iTree 的数目设为 180，这样基本覆盖了所有的实验数据样本。那么根据 iTree 的构造原理，iTree 本质上是一颗二叉搜索树，iTree 树的高度限制 H 与采样规模 n 之间的关系为 $H = ceiling(\log_2(n))$，得出每棵 iTree 的高度为 8。

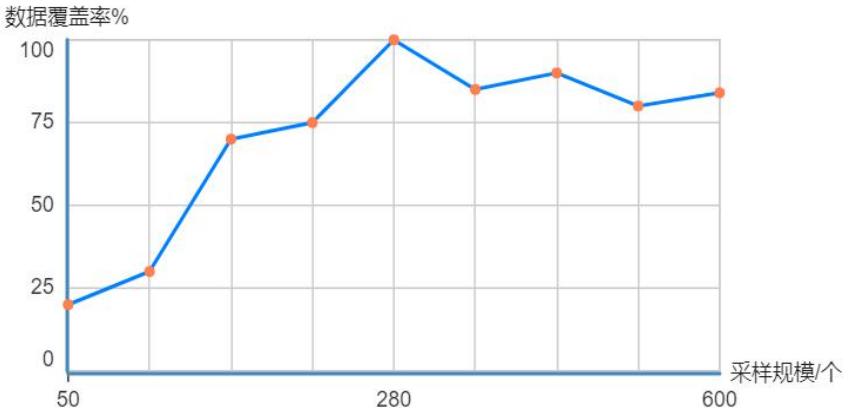


图 4-4 采样规模与数据覆盖率折线图

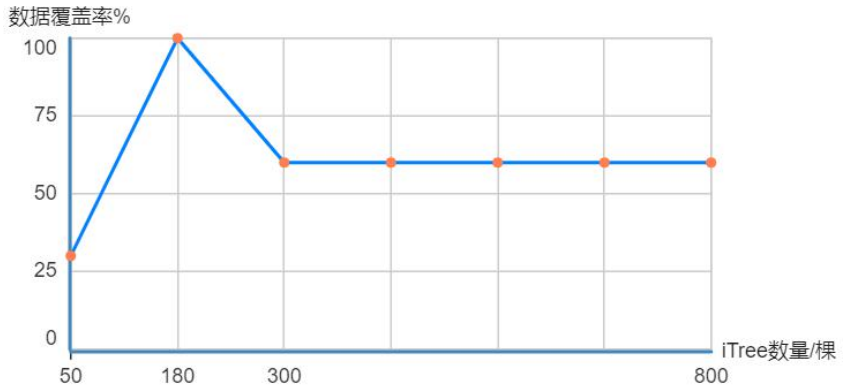


图 4-5 iTree 数量与数据覆盖率折线图

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

4.4 本章小结

本章提出了一种基于工业物联网环境下的大数据异常检测的算法。首先，介绍了数据异常检测的相关工作与问题描述。接着，提出了隔离森林算法的检测模型，模型分为三个阶段，第一阶段为 iTree 的构建，本模块通过选取工业环境的特征属性来构建 iTree。第二阶段为森林的构建，将众多 iTrees 组合形成森林。第三阶段为隔离森林的预测，使用每个样本实例在 iTree 上的平均高度计算出异常分数，做出异常判断。最后，我们说明了 iTree 的数目 t 和每次采样规模 n 两个参数的选择对实验的重要影响并且选择合适的参数进行仿真。具体的仿真结果和分析见第五章。下一章，将对本文研究工作的进行实验仿真。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第五章 仿真与分析

5.1 仿真环境的搭建

5.1.1 实验环境参数

本次实验所用的实验环境描述如下表 5-1：

表 5-1 实验仿真环境参数

参数	数据值
操作系统	windows 10
内存	8GB
CPU	Intel Corei7
编程语言	Python
数据集文件大小	7MB
数据数量	769540
传感器数量	150

5.1.2 仿真工具介绍

（1）MATLAB 应用软件

MATLAB 是一款简称为矩阵实验室的软件。经过多年的发展改进，MATLAB 包含了算法开发、数据可视化和数据分析等功能。由于强大且操作简易的优点，它在科学技术、金融学等领域上应用十分广泛。本文运用 MATLAB 软件的变量相关分析，用以研究工业环境中 PM2.5 浓度与湿度、温度等之间的规律。用作于工业数据的特征选取。

（2）Jupyter notebook 应用软件

由于实际条件限制，本文主要通过仿真软件模拟实际在边缘服务器执行异常数据的清洗情况，进而对本文提出的改进的 iForest 的检测算法进行仿真。下面将介绍本文仿真软件的定义、特点等。

Jupyter Notebook 是一种基于 Web 的交互式计算开发平台，可以支持多种的编程语言，由于它是一个 Web 端的开发平台，除了能够为用户提供便捷的可视化界面，还可以记录研究人员的每次的编写程序[65]。Jupyter Notebook 的操作界面如图 5-1 所示。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net



图 5.1 Jupyter Notebook 操作界面

Jupyter Notebook 主要包括三个组件：

(1) Jupyter Qt 控制台：运行代码的交互式 Web 应用程序。

(2) Jupyter Notebook 文件格式：基于 JSON 数据类型的开发文档格式，记录用户的 session，程序代码和文本输出。

(3) Kernel：可以满足同一种 kernel 不同种的前端，方便支持与开发前端；同一类前端不同种的 kernel，方便支持与开发语言。

实验将工业设备采集的数据集，比如湿度、温度和 PM2.5 浓度等，汇总到一个.csv 文件。将数据集导入 Jupyter Notebook 中实现。接着，使用 KPCA 算法选择所需的属性，比如我们检测 PM2.5 浓度的异常，特征选择的算法会从数据集中的众多属性中挑选出几个相关性高的属性，这些属性包括气压，湿度和温度等，而等出水温度属性相关性不高，便会舍弃。然后，使用 iForest 的异常检测算法，根据相关性高的属性进行预测。最后依据异常得分排序得出异常值。Jupyter Notebook 具体仿真流程图如图 5-2 所示。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

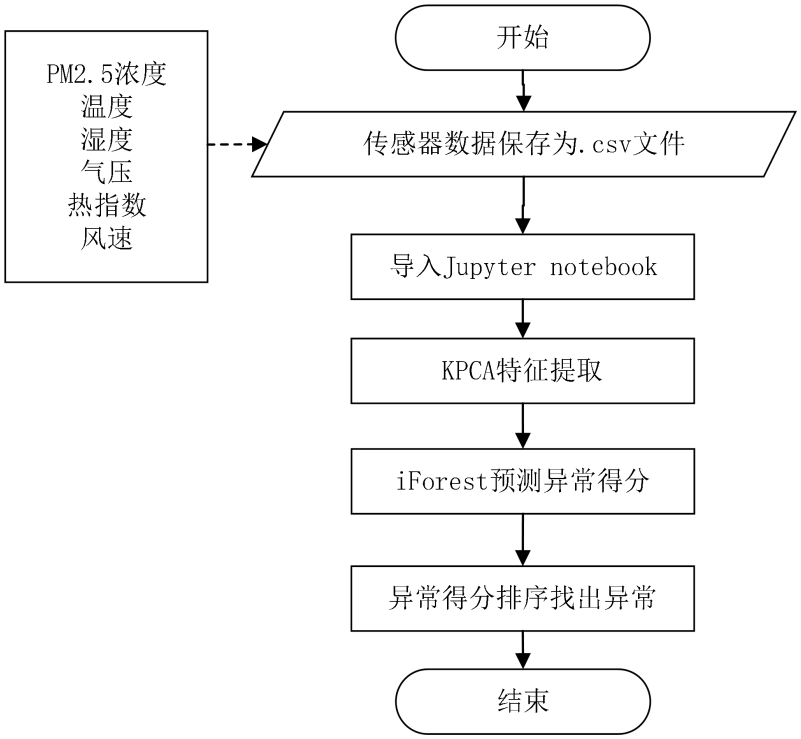


图 5-2 Jupyter Notebook 仿真流程图

5.2 数据集介绍

本次工业环境异常检测实验仿真的数据来自 Siemens 的锅炉监控系统。工业锅炉用作于工业生产的锅炉。一个锅炉监控系统主要包含以下几个部分：锅炉本体、燃烧器、控制装置和辅助设备等。目前我国工业锅炉多数是以燃煤为主，所以现在通过对燃煤锅炉的监控达到安全可靠生产、燃烧效率高、节能环保和减少对大气的污染和的目的。

5.2.1 锅炉系统的构成

锅炉监控系统分为硬件和软件系统。锅炉系统一般是有上位机监控系统、下位机控制系统和传感器采集数据三部分组成。下面简单介绍三个部分的作用。

（1）上位机监控系统：人机交互的功能，研究人员可以随时查看锅炉工作情况，并给锅炉的下位机系统下发指令。

（2）下位机控制系统：负责监测数据的集中处理，使用通信模块等方式上传到上位机。一般 PLC(Programmable Logic Controller)可以通过常用的工业协

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

议，比如 Modbus、ProfiBus 等来控制设备。除了可以完成各种控制的功能，又可以与其他计算机通信。它主要由 CPU 模块、通信模块等组成。

（3）传感器：有传感器组成的现场仪表负责采集水温、气压、环境温度、PM2.5 浓度等数据。

系统软件功能主要负责数据采集、数据集中显示的功能。用于对锅炉水温、气压、PM2.5、湿度等参数进行实时采集，将数据汇总分析。

5.2.2 数据集的构成

最终，我们从西门子 mindsphere 云平台中收集了一年内的室内温度、水温、PM2.5 浓度、湿度、气压、压力、热指数等 18 种数据特征，总共 765940 个。由于篇幅的限制，本文只选取了部分的样本数据如图 5-3 所示。

	A	B	C	D	E	F	G	H	I
1	时间	监测点	PM25(ug/m³)	PM10(ug/m³)	室外温度(℃)	湿度(%)	气压(10^5Pa)	炉排气温度(℃	出水温度(℃)
2	2019-01-01 00	1号锅炉	36	60	3.82	74.19	1.013.00	130.57	85.67
3	2019-01-01 01	1号锅炉	32	61	3.43	73.6	1.003.82	136.19	82.34
4	2019-01-01 02	1号锅炉	31	58	4.4	68.31	1.014.07	138.28	92.53
5	2019-01-01 03	1号锅炉	34	66	3.61	65.83	1.016.16	138.08	92.28
6	2019-01-01 04	1号锅炉	34	55	5.4	62.7	1.013.32	139.47	90.44
7	2019-01-01 05	1号锅炉	29	54	4.2	66.89	1.023.02	131.32	91.82
8	2019-01-01 06	1号锅炉	29	53	5.19	64.97	1.017.31	132.44	87.17
9	2019-01-01 07	1号锅炉	30	61	4.59	66.78	990.02	139.2	95.4
10	2019-01-01 08	1号锅炉	32	63	6.29	62.27	992.17	139.41	93.11
11	2019-01-01 09	1号锅炉	31	55	11.03	47.69	992.11	139.47	99.08
12	2019-01-01 10	1号锅炉	44	79	14.79	39.14	993.89	139.34	97.33
13	2019-01-01 11	1号锅炉	70	114	10.46	48.53	1093.12	139.22	98.83
14	2019-01-01 12	1号锅炉	48	89	11.28	44.02	993.11	147.89	96.73
15	2019-01-01 13	1号锅炉	47	78	11.67	44.14	1013.11	148.52	97.33
16	2019-01-01 14	1号锅炉	32	55	13.19	36.32	997.43	147.06	92.47
17	2019-01-01 15	1号锅炉	30	46	12.24	36.38	1023.11	149.11	99.42
18	2019-01-01 16	1号锅炉	37	57	7.49	40.81	999.23	126.54	92.46
19	2019-01-01 17	1号锅炉	42	65	4.98	46.67	1000.11	146.02	97.21
20	2019-01-01 18	1号锅炉	30	57	4.41	51.2	1023.11	145.77	97.07
21	2019-01-01 19	1号锅炉	29	53	4.31	53.51	992.14	125.9	98.09
22	2019-01-01 20	1号锅炉	31	57	3.73	57	1003.11	124.9	99.99
23	2019-01-01 21	1号锅炉	46	103	5.88	56.24	1040.71	145.34	99.78
24	2019-01-01 22	1号锅炉	39	69	5.92	57.67	1020.00	123.44	98.98
25	2019-01-01 23	1号锅炉	38	61	6.04	57.97	1020.11	133.77	99.58

Sheet1

图 5-3 工业锅炉的环境数据集

由于数据量大，我们在进行异常检测之前需要通过去除不相关的特征来降低数据集的维数。去除对异常检测输出影响最小或者不影响的特征。通过分析 PM2.5 浓度与不同特征之间的相关性可知，PM2.5 浓度和环境温度、气压等高度相关，因此被认为是显著特征。但于出水温度等相关性不高，则被认为是无关特征。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

5.3 KPCA 数据特征选取的仿真与分析

本次实验针对工业环境 PM2.5 浓度的进行异常检测。为了验证降维效果，本次 KPCA 降维的核函数分别使用感知核函数、多项式核函数和高斯核函数进行对比实验。

得出的特征值情况如下表 5-2 所示，其中的 λ_1 为使用感知核函数的特征值情况，λ_2 为使用多项式核函数的特征值情况，λ_3 为使用高斯核函数方法的特征值情况：

表 5-2 不同核函数的特征值

$\lambda_1=$	$\lambda_2=$	$\lambda_3=$
0.1901	-0.0001	0.0921
0.2122	-0.0001	0.1084
0.2347	0.0000	0.1313
0.2601	0.0000	0.1447
0.2703	0.0001	0.1606
0.3102	0.0002	0.1731
0.3412	0.0002	0.1953
0.3856	0.0004	0.2012
0.4017	0.0005	0.2318
0.4212	0.0008	0.3663
0.4738	0.0009	0.5492
0.8211	0.0010	0.6329
1.7412	0.0012	0.7428
3.0417	0.0013	0.7925
4.1826	0.0015	0.8215
5.5470	0.0021	4.2381
7.0053	0.0023	12.5320
9.1341	24.1825	18.1716

为了方面查看，我们将特征值情况绘制成折线图，并输出。其中，图 5-4 表示使用感知核函数方法的特征值 λ_1 的情况，图 5-5 表示多项式核函数的特征值 λ_2 的情况，图 5-6 表示高斯核函数的特征值 λ_3 的情况。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

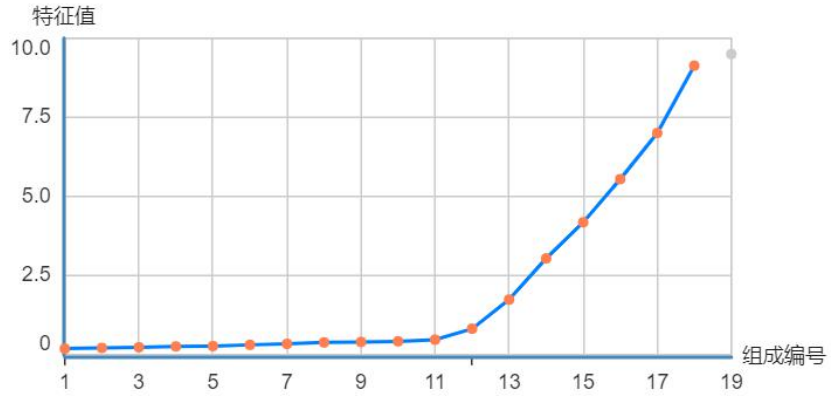


图 5-4 感知核函数的特征值折线图

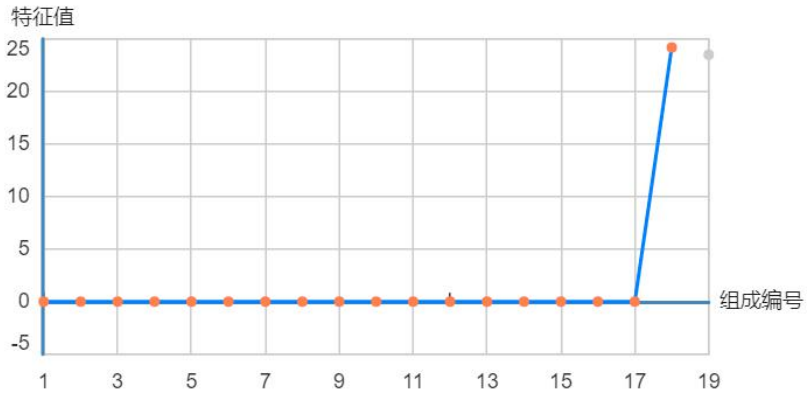


图 5-5 多项式核函数的特征值折线图

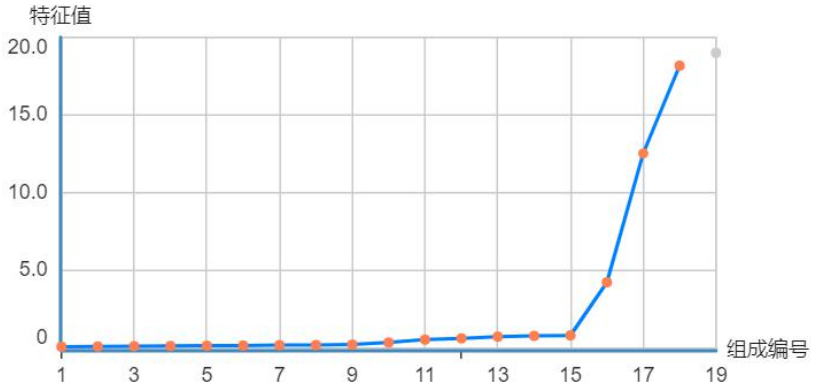


图 5-6 高斯核函数的特征值折线图

在收集的数据集中，包含 18 个特征因素，每个因素中包含了 4042 个数据。图 5-3、5-4、5-5 中， X 轴表示特征因数， Y 轴表示特征值。

我们发现使用感知核函数的特征值相对集中，使得提取的主成分特征数量过多，对后面使用无监督算法提升不高；使用多项式核函数算法的特征值有负值，并且每个特征值的主成分特征过少，大部分信息都是在第一主成分，数据太集中，信息之间的差异性不明显会影响后面无监督算法的准确性。使用高斯核函数的特

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

征值克服了上述的两个问题的缺点，每个特征之间的差异性信息都很明显，特征提取可以取得很好的效果。在累计贡献率达到 85%的情况下，提取的主成分特征的情况如下表 5-3 所示。在满足累计贡献率达到 85%的条件下，t_1为感知核函数的主成分提取的特征个数，t_2为多项式核函数的主成分提取的特征个数，t_3为高斯核函数的主成分提取的特征个数。

表 5-3 不同核函数选择的主成分特征数量

t_1=	t_1=	t_1=
8	2	4

从上表中各个核函数得到的主成分特征数量来看，使用感知核函数提取了 8 个特征，它起源于神经网络，从效果上来看，它擅长考虑特征之间的差异性，而特征之间的共性考虑较少，所以导致提取的主成分因子过多。使用多项式核函数提取除了两个特征，这说明它的全局能力强，提取的更多式特征之间的共性。高斯核函数式提取了 4 个特征值，它也是应用最广泛的一个，它不仅适用于样本少的数据集，对于样本多的数据集仍然有着不错的表现，而且因为它只有一个σ参数，这使得它使用起来更加方便，性能方面也是综合了前两个的优点，不仅考虑了数据之间的差异性也考虑了共性，所以它取得了不错的效果。

5.4 基于隔离森林的异常检测算法的仿真

iForest[35]是一种基于整体的快速异常检测算法，基于距离和密度的异常检测算法计算复杂度高，iForest 可以消除这些不必要的计算。iForest 不仅具有时间复杂度低和内存开销小的优势，而且它的精确性也很高。上一节完成了数据特征选择的仿真工作，在此之上，本节通过使用隔离森林算法进行数据的异常检测并比较其他异常检测算法来验证它的优势。

5.4.1 异常检测模型的数据基础

上一节中，为了提高 iForest 算法对 PM2.5 浓度检测效率，通过 KPCA 方法只保留了相关系数高的特征，降低了数据集的维数。相关系数高的特征与离群点检测特征的具有很强的相关性，因此被称为显著特征。在表 5-3 中，展示了一个具有很少特征的数据的实例。湿度、室内温度、气压相关，因此被认为是显著特

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

征。但是回水温度等其他的因素相关性不高，被认为是无关特征。图 5-7 是一年内锅炉环境的 PM2.5(ug/m^3)浓度数据的二维散列图。图 5-8 是基于 k-means 聚类算法的高维图。

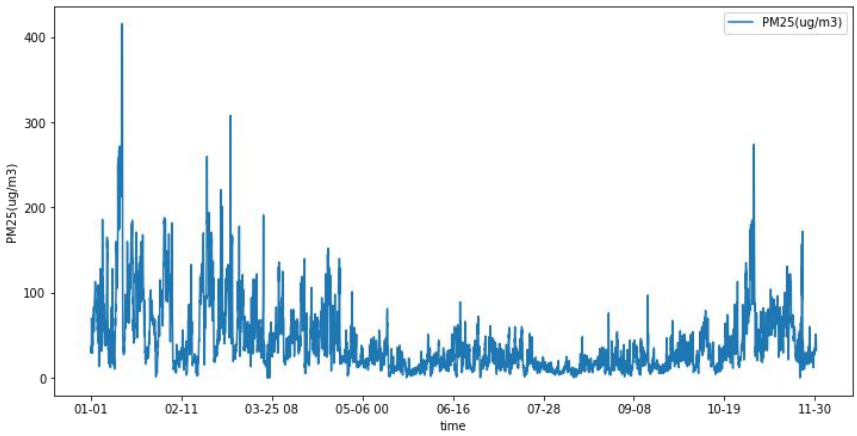


图 5-7 PM2.5(ug/m^3)浓度二维散列图

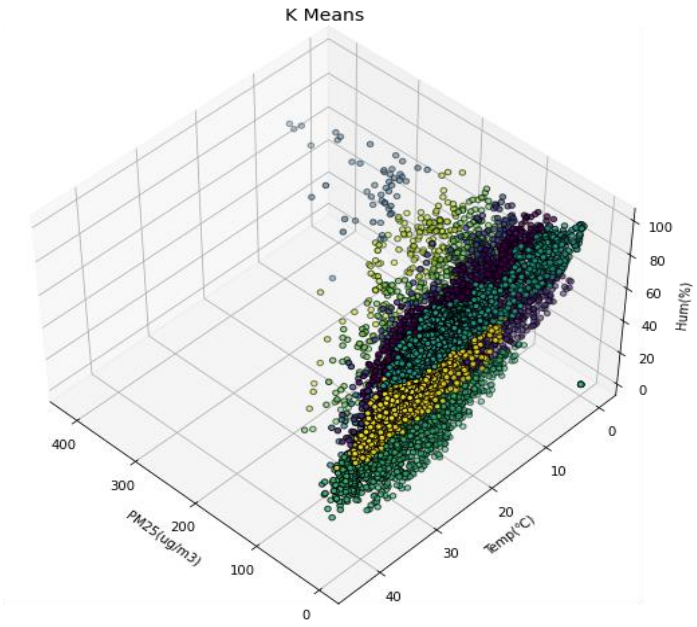


图 5-8 k-means 聚类图

5.4.2 仿真指标介绍

本文选择检出率和准确性两个指标作为算法的评价标准。它们的计算公式表示如下：

$$precision_rate = \frac{TP}{TP + FP} \times 100\% \qquad (5\text{-}1)$$

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

$$detection_rate = \frac{TP}{TP + FN} \times 100\% \quad (5\text{-}2)$$

其中TP表示数据集中被检测准确的异常样本数量，FN表示数据集中没有检测出来的异常样本数量，FP表示数据集中被检测错误的正常样本数量。准确性可以反映出算法对异常数据的识别是否正确，而检出率则可以反映出算法对异常数据的识别是否全面。在评价检测结果过程中，如果降低异常值判定的阈值，就会导致检测更多的数据，检出率提升，但是也加大了正常样本被误检的可能。同理，如果提高异常值判定的阈值，就会导致检测出来的数据变少，检出率便会降低。因此，需要研究人员在准确率和检出率之间寻找一个平衡点，确保可以算法有较高的准确性和检出率。

5.4.3 仿真结果分析

本文根据上述提出的仿真参数指标进行了仿真实验，在传统的隔离森林算法的基础上，本文将 KPCA 降维算法加入其中，基于 KPCA 算法来找出与待检测特征高度相关的特征数据来进行划分空间。较之传统的隔离森林算法，这种数据划分方式虽然都是随机的，但是改进的算法划分是在特征提取后的数据集中随机抽取，这种方式可以让 iForest 算法能够处理高维度数据。因为减少了不相关的特征数据削减了数据集合，这有助于提高 iForest 的准确性和执行效率。图 5-9 是 PM2.5 浓度的异常值检测效果图。

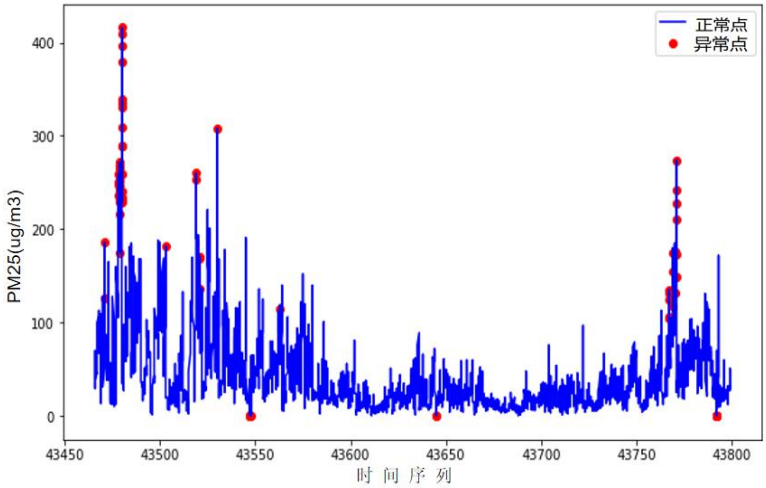


图 5-9 iForest 的训练结果图

从图 5-9 中，蓝色为正常数据,红色点为异常数据点。可以看出，经过训练的模型对训练数据产生一定的误差，这也符合机器学习的本质，训练结果不能 100%的拟合训练集。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

iForest 算法分为两个阶段：样本训练阶段与结果评估阶段。在 iTree 训练的阶段，iForest 算法的时间复杂度最糟糕情况为 $O(t\xi^2)$，空间复杂度为 $O(t\xi)$。在评估阶段，iForest 算法时间复杂度最糟糕的情况为 $O(nt\xi)$，其中 n 为待见检测数据的大小。所以 iForest 整个阶段的时间复杂度为 $O(t\xi(\xi+n))$，对于大数据集来说，$n>>t\xi^2$，所以时间复杂度接近于线性 $O(n)$，空间复杂度为 $O(t\xi)$。线性的时间复杂度算法也能够更快地处理工业大数据。

5.4.4 与其他异常检测模型对比

为了验证本文所选的 iForest 算法的优势，本文选取了两种广泛使用的异常检测算法，K 最近邻异常检测和基于支持向量机算法。分别基于本节训练样本实例构建异常检测模型，并对模型的准确度和检出率进行对比。

（1）基于 KNN 的异常检测算法

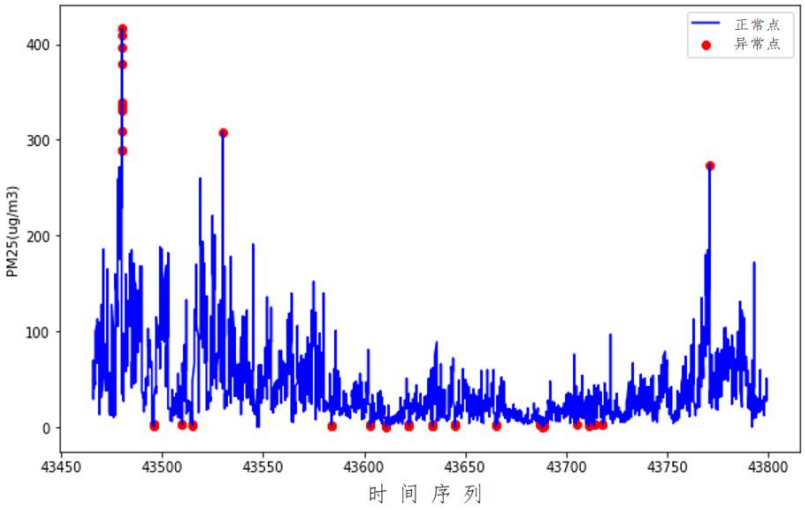


图 5-10 基于 KNN 的训练结果图

图 5-10 是基于 K 最近邻异常的训练结果图。当 K 最近邻算法对未知标签的样本数据进行分类的时候，计算每个点到其第 K 个最近邻居的距离，接着对所有计算的距离进行排序，将排序中距离最大的前 n 个数据点视为异常值。KNN 算法的关键在于 K 值参数的设置与计算距离公式的选择。一般来说，距离公式可以是曼哈顿距离、欧式距离、余弦距离和汉明距离等[66]，但是 K 的值需要研究人员通过多次的实验进行修改优化。实验结果表明，KNN 算法异常点检测率不高，有些波峰异常点并没有被检测出来。

（2）基于支持向量机的异常检测算法

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

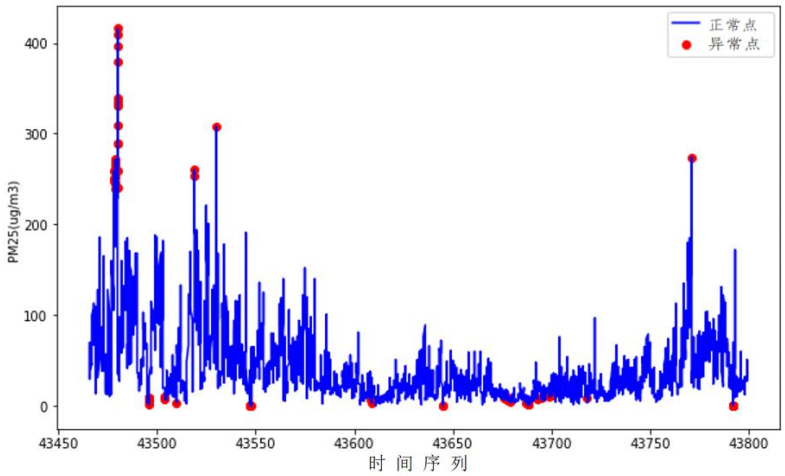


图 5-10 基于 SVM 的异常检测

它是一种统计学习理论中的结构风险最小化原理的有监督机器学习方法，同时也是一种十分流行的分类算法。它的受欢迎程度在于，SVM 在大量数据集上始终提供良好的性能。它解决了凸目标函数，因此，给定一组参数，每次运行的解决方案都保持不变。SVM 的目标是制作一个广义分类器，即一个分类器，不仅适用于训练数据，而且适用于大多数看不见的数据。实验中发现 SVM 能够识别更多的点，可以检测出峰谷异常值，但精度较低。SVM 的优点在于：由于支持向量机具有完备的理论基础、优良的泛化能力、全局最优解以及在非线性系统中使用核函数很方便，所以避免了维数灾难。此外，也是由于支持向量机的稀疏性，SVM 模型仅与支持向量的一部分有关，因此可以大大地降低异常检测地计算地复杂度。尽管支持向量积算法有种种优势，但是仅仅对于小样本数据集有着很好的表现，但是面对目前以及未来的工业大数据，可能处理不了。iForest、KNN 和 SVM 时间复杂度对比如表 5-4 所示。

表 5-4 iForest、KNN 和 SVM 时间复杂度

Model	Run Time complexity
KNN	$O(n*d)$
SVM	$O(s*d)$
iForest(Proposed)	$O(n)$

(3)检出率和准确性

表 5-5 和表 5-6 分别展示了基于 KNN 的算法、支持向量机的算法和 iForest 算法的检测率和准备率比较结果。实验结果表明，KNN 算法异常点检出率不高，有些异常点并没有被检测出来。使用 KNN 算法计算复杂度高，研究人员无法对预测的误差有一个统计意义上的估计，得出的结果波动较大，但是 KNN 的实现简单，

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

使用比较灵活。向量机算法可以识别更多的点，波峰和波谷的异常值都被检测出来，而且也有着不错地准确性。然而由于时间复杂度高，只能使用于小样本数据集合。改进的 iForest 算法不仅有着高检出率和准确性，而且时间复杂也是近似线性。

综上所述，本文提出的 iForest 异常检测算法，适用于工业物联网大数据的清洗，通过使用 KPCA 算法进行特征选择，解决了 iForest 的检测高维数据能力不足的问题。

表 5-5 基于检测率/召回率的比较结果

Model	Detection rate/recall
KNN	86%
SVM	93.7%
iForest(Proposed)	95.63%

表 5-6 基于准确性的比较结果

Model	Accuracy
KNN	88.4%
SVM	95.2%
iForest(Proposed)	97.8%

5.5 本章小结

本章主要介绍了 KPCA 降维和异常值检测的仿真实验并且分析实验结果。首先，介绍了相关的仿真环境的搭建和仿真软件。接着，说明了实验的数据集来源。然后，根据第三章提出的以核函数的主成分分析的降维方法进行了数值仿真的验证分析，本文通过 MATLAB 软件进行数据的特征选择。接着，依据第四章提出的基于 iForest 的异常检测算法进行了仿真验证。本文将仿真结果与经典的 k 最近相邻的算法和基于支持向量机的算法进行了比较，发现本文提出的 iForest 检测算法可以不仅有着高准确性和检出率，还可以有着数据检测效率高的优点。下一章将对本文研究工作的进行总结，并对今后的研究内容提出了展望。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

第六章 总结与展望

6.1 工作总结

本文首先介绍了工业物联网大数据处理的必要性和发展前景，分析了移动边缘计算 IIoT-MEC 网络架构和特点，并研究了数据特征选取的方法和异常值检测算法的研究现状。针对工业大数据具有 5V 的特性，本文首先提出了数据降维的处理，通过使用 MATLAB 工具对数据进行特征选择。接着，在简约的数据集上，执行异常数据检测的无监督模型，最后对比了经典的 k 最近相邻的算法和基于支持向量机的算法。本文的主要工作和贡献有：

（1）首先，针对工业中传统的无线传感器网络架构，我们提出了采用移动边缘计算 IIoT-MEC 的架构，由于边缘服务器更加靠近工业中数据采集的节点，所以在一定程度上具有抵抗恶意攻击的能力，还有提高了吞吐量和减少传输延迟。

（2）其次，针对工业大数据异常检测的问题。本文将其分为两各阶段：数据预处理和 iForest 的异常检测。第一阶段，由于 5G 的普及和传感器技术的发展，工业数据的将不会变得单调，数据将会爆炸式地增长，数据与数据之间得关联性也变得更加紧密。一方面，传统的异常检测算法已经不在有能处理高纬度空间的数据。为了能够将异常检测算法能够应对高维度数据，需要对高维度数据进行降维来减少数据量的大小，从而减轻模型的训练压力。本文采用的非线性的 KPCA 方法对样本数据进行特征选择。从理论上验证了 KPCA 比较适合处理工业环境中的非线性数据。另一方面，由于一般异常检测算法的时间复杂度与空间复杂度高，计算复杂的缺点，使得其并不符合工业的高时效性、高可靠性的要求。iForest 算法是一个基于整体学习的快速异常检测算法，既不需要数学模型也不需要有标签的训练，是具有线性时间复杂度、内存开销低和精准度高的优点。但是传统的 iForest 算法不能够很好处理高维度的数据，我们便结合 KPCA 算法对进行数据特征选择，发现改进后的 iForest 算法在处理高纬度数据的时候也有很好的表现。

（3）最后，利用 MATLAB、Jupyter notebook 等软件联合仿真，对比其他的算法分析了它们各自的优势和不足。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

6.2 展望

虽然本文提出的 KPCA 特征提取算法可以减小工业大数据的维度，从而提高机器学习算法的执行效率。针对工业大数据异常值检测的问题，提出的基于 iForest 的异常检测算法，它有着线性的时间复杂度、空间复杂度低、高准确性和高检出率的优势。但是由于本人知识水平有限，本课题仍存在许多不足之处，现将其总结为以下几点：

（1）缺乏异常分析功能

对于异常检测系统来说，有必要在判断出异常值后继续开展相关问题的研究和分析的工作。可以结合一些工业生产过程时记录的仪器故障日志进行异常分析，协助运维人员尽快地找出异常根因解决问题。

（2）缺乏实际操作的经验

由于硬件条件有限，本文只是通过 Jupyter notebook 软件进行模拟仿真，与在真实的场景验证的结果可能有些许差别，希望日后有条件可以在实际场景中进行检验。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

参考文献

[1] Good Practices for Security of Internet of Things in the context of Smart Manufacturing, ENISA, 2018, 118 p.
[2]舒文琼.爱立信发布移动市场报告 2024 年 5G 用户数将达到 19 亿[J].通信世界,2019(17):17.
[3] M. K. Weldon. “The Future X Network, A Bell Labs Perspective”, 2016 CRC Press, Taylor & Francis Group, pp356, 382
[4] K. Wang, Y . Wang, Y . Sun, S. Guo, and J. Wu, “Green industrial Internet of Things architecture: An energy-efficient perspective,” IEEE Commun.Mag., vol. 54, no. 12, pp. 48–54, Dec. 2016.
[5] M. Hung, “Leading the iot, gartner insights on how to lead in a connected world,” Gartner Research, pp. 1–29, 2017.
[6]ETSI, “Mec in 5g networks,” https:// www. etsi. org/ images/ files/ ETSIWhitePapers/ etsi_wp28_mec_in_5G_FINAL. pdf.
[7] M. Satyanarayanan, V . Bahl, R. Caceres, and N. Davies, “The case for vm-based cloudlets in mobile computing,” IEEE pervasive Computing,2009.
[8] X. Lyu, H. Tian, L. Jiang, A. Vinel, S. Maharjan, S. Gjessing, and Y . Zhang, “Selective offloading in mobile edge computing for the green internet of things,” IEEE Network, vol. 32, no. 1, pp. 54–60, 2018.
[9] N. Abbas, Y . Zhang, A. Taherkordi, and T. Skeie, “Mobile edge computing: A survey,” IEEE Internet of Things Journal, vol. 5, no. 1, pp. 450–465, 2018.
[10] T. Wang, H. Ke, X. Zheng, K. Wang, A. K. Sangaiah and A. Liu, ”Big Data Cleaning Based on Mobile Edge Computing in Industrial Sensor-Cloud,” in IEEE Transactions on Industrial Informatics, vol. 16, no. 2,pp. 1321-1329, Feb. 2020.
[11] N. Ghosh and I. Banerjee, "Iot-based freezing of gait detection using grey relational analysis", Internet of Things, pp. 100068, 2019.
[12] J. M. Shepherd and S. J. Burian, "Detection of urban-induced rainfall anomalies in a major coastal city", Earth Interactions, vol. 7, no. 4, pp. 1-17, 2003.
[13] S. Hajiheidari, K. Wakil, M. Badri and N. J. Navimipour, "Intrusion detection systems in the Internet of things: A comprehensive investigation", Computer Networks, 2019.
[14] K. Xie, X. Li, X. Wang, J. Cao, G. Xie, J. Wen, et al., "On-line anomaly detection with high accuracy", IEEE/ACM Transactions on Networking, vol. 26, no. 3, pp. 1222-1235, June 2018.
[15] H.-N. Dai, Z. Zheng, and Y . Zhang, “Blockchain for internet of things: A survey,” IEEE Internet of Things Journal, pp. 1–19, 2019.
[16] L. Liu, H. Li, and M. Gruteser, “Edge assisted real-time object detection for mobile augmented reality,” in MobiCom, ACM, 2019.
[17] C. Xu, K. Wang, P . Li, S. Guo, J. Luo, B. Ye, and M. Guo, “Making big data open in edges: A resource-efficient blockchain-based approach,”IEEE Transactions on

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Parallel and Distributed Systems, 2019
[18] M. H. Rehman, E. Ahmed, I. Yaqoob, I. Hashem, M. Imran and S. Ahmad, "Big data analytics in industrial IoT using a concentric computing model", IEEE Commun. Mag., vol. 56, no. 2, pp. 37-43, Feb. 2018.
[19] 王婷婷.物联网发展前景研究[J].电子制作,2014,10:129
[20] X. Deng, P. Jiang, X. Peng and C. Mi, "An intelligent outlier detection method with one class support Tucker machine and genetic algorithm toward big sensor data in Internet of Things", IEEE Trans. Ind. Electron., vol. 66, no. 6, pp. 4672-4683, Jun. 2019.
[21] Sarah M.Erfani, Sutharshan Rajasegarar,Shanika Karunasekera,Christopher Leckie.”High-dimension and large-scale anomaly detection using a linear one-class SVM with deep learning. Pattern Recognition” 58(2016)121-134e
[22] K. Orphanou, A. Dagliati, L. Sacchi, A. Stassopoulou, E. Keravnou, and R. Bellazzi, ‘‘Incorporating repeating temporal association rules in Naïve
Bayes classifiers for coronary heart disease diagnosis,’’ J. Biomed. Informat., vol. 81, pp. 74–82, May 2018.
[23] L. Hu and J. Cui, ‘‘Digital image recognition based on Fractional-order-PCA-SVM coupling algorithm,’’ Measurement, vol. 145, pp. 150–159,Oct. 2019.
[24] K. Fukunaga, Introduction to Statistical Pattern Classification, San Diego, CA, USA:Academic, 1990.
[25] Y. Cheng, Z. Wang and W. Zhang, "A novel condition-monitoring method for axle-box bearings of high-speed trains using temperature sensor signals", IEEE Sensors Journal, vol. 19, no. 1, pp. 205-213, 2018.
[26] L. Zheng, W. Hu, Y. Min, W. Ge and Z. Wang, Weighted distance based outlier factor identifying and its application in wind data pre-processing, 2014.
[27] R. Liu, H. Zuo, J. Sun and L. Wang, "Electrostatic monitoring of wind turbine gearbox on oil-lubricated system", Proceedings of the Institution of Mechanical Engineers Part C: Journal of Mechanical Engineering Science, vol. 231, no. 19, pp. 3649-3664, 2017.
[28] X. Xu, Y. Lei and X. Zhou, "A lof-based method for abnormal segment detection in machinery condition monitoring", 2018 Prognostics and system health management conference (PHM-Chongqing), pp. 125-128, 2018.
[29] Z. Li and L. Zeng, "A Hybrid Vertex Outlier Detection Method Based on Distributed Representation and Local Outlier Factor," 2015 IEEE 12th Intl Conf on Ubiquitous Intelligence and Computing and 2015 IEEE 12th Intl Conf on Autonomic and Trusted Computing and 2015 IEEE 15th Intl Conf on Scalable Computing and Communications and Its Associated Workshops (UIC-ATC-ScalCom), 2015, pp. 512-516, doi: 10.1109/UIC-ATC-ScalCom-CBDCom-IoP.2015.104.
[30] R. Zhu et al.,“KNN-Based Approximate Outlier Detection Algorithm Over IoT Streaming Data,” in IEEE Access, vol. 8, pp. 42749-42759,2020.
[31] Y . Jiahao, X. Jiang, S. Wang, K. Jiang and X. Y u, ”SVM-BiLSTM: A Fault Detection Method for the Gas Station IoT System Based on Deep Learning,” in IEEE

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

Access, vol.8, pp. 203712-203723, 2020.
[32] H. V. Nguyen, T. T. Nguyen, Q. U. Nguyen, “Sequential ensemble method for unsupervised anomaly detection”, in proceedings of International Conference on Knowledge and Systems Engineering (KSE), IEEE, pp. 71-76, 2017.
[33] S. Chaurasia, A. Jain, “Ensemble neural network and k-NN classifiers for intrusion detection”, International Journal of Computer Science and Information Technology, vol. 5, pp. 2481-2485, 2014.
[34] T. Dai and Z. Ding, "Online distributed distance-based outlier clearance approaches for wireless sensor networks", Pervasive and Mobile Computing, vol. 63, pp. 101130, 2020.
[35] Liu, F.T., Ting, K.M., Zhou, Z.H.: Isolation forest. In: Proceedings of the Eighth IEEE International Conference on Data Mining, pp. 413–422(2008)
[36] A. Yousefpour, G. Ishigaki, R. Gour and J. P. Jue, "On reducing IoT service delay via fog offloading", IEEE Internet Things J., vol. 5, no. 2, pp. 998-1010, Apr. 2018.
[37] B. Cao, J. Zhao, P . Yang, Z. Lv, X. Liu, and G. Min, “3d multiobjective deployment of an industrial wireless sensor network for maritime applications utilizing a distributed parallel algorithm,” IEEE Transactions on Industrial Informatics, vol. 14, no. 12, pp. 5487–5495, 2018.
[38] 李航. 统计学习方法[M]. 北京：清华大学出版社.2012.
[39] Morente-Molinera J A，Jozsef Mezei,Carlsson C,et al.Improving Supervised Learning Classification Methods Using Multigranular Linguistic Modeling and Fuzzy Entropy[J]. IEEE Transactions on Fuzzy Systems, 2017,25(5):1078-1089.
[40] J. Han, J. Pei, and M. Kamber, Data Mining: Concepts and Techniques. Elsevier, 2011.
[41] N. Moustafa, B. Turnbull, and K.-K. R. Choo, “An Ensemble Intrusion Detection Technique Based on Proposed Statistical Flow Features for Protecting Network Traffic of Internet of Things,” IEEE Internet of Things Journal, vol. 6, no. 3, pp. 4815–4830, Jun. 2019, doi:10.1109/JIOT.2018.2871719.
[42] Y. Zhou, M. Han, L. Liu, J. S. He, and Y. Wang, “Deep learning approach for cyberattack detection,” in IEEE INFOCOM 2018 - IEEE Conference on Computer Communications Workshops (INFOCOM WKSHPS), Apr. 2018, pp. 262–267, doi: 10.1109/INFCOMW.2018.8407032.
[43] A. Guerra-Manzanares, H. Bahsi, and S. Nõmm, “Hybrid Feature Selection Models for Machine Learning Based Botnet Detection in IoT Networks,” in 2019 International Conference on Cyberworlds (CW),Oct. 2019, pp. 324–327, doi: 10.1109/CW.2019.00059.
[44] B. Saneja and R. Rani, "A Hybrid Approach for Outlier Detection in Weather Sensor Data," 2018 IEEE 8th International Advance Computing Conference (IACC), Greater Noida, India, 2018, pp. 321-326, doi: 10.1109/IADCC.2018.8692127.
[45] B. Scholkopf, A. Smola, Klaus Robert Muller Nonlinear Component Analysis as a Kernel Eigenvalue Problem,Neural Computation, V ol.10, N0.5, 119-130,1998.
[46] E. H. Budiarto, A. Erna Permanasari and S. Fauziati, "Unsupervised Anomaly Detection Using K-Means, Local Outlier Factor and One Class SVM," 2019 5th

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

International Conference on Science and Technology (ICST), Yogyakarta, Indonesia, 2019, pp. 1-5, doi: 10.1109/ICST47872.2019.9166366.
[47] R. Kumari, Sheetanshu, M. K. Singh, R. Jha, and N. K. Singh, "Anomaly detection in network traffic using K-mean clustering," 2016 3rd International Conference on Recent Advances in Information Technology (RAIT), Dhanbad, 2016, pp. 387-393.
[48] J. Zhang, L. Geng, and Y. Ma, "Battery anomaly and degradation diagnosis for renewable energy plant," in CIRED - Open Access Proceedings Journal, vol. 2017, no. 1, 2017,pp. 46-49.
[49] Jiawei Han, Micheline Kamber and Mingyi FAN, "Data mining: Concepts and Techniques[M]" in Mechanical industry press, Beijing (in Chinese), pp. 306-309, 2012.
[50] D Birant and A. Kut, "ST-DBSCAN: An algorithm for clustering spatial-temporal data[J]", Data &Knowledge Engineering, vol. 60, no. 1, pp. 208-221, 2007.
[51] Luning Xia and Jiwu Jing, "SA-DBSCAN:A self-adaptive density-based clustering algorithm[J]", Journal of the Graduate School of the Chinese Academy of Science, vol. 26, no. 4, pp. 530-538, 2009.
[52] Z. Gan and X. Zhou, "Abnormal Network Traffic Detection Based on Improved LOF Algorithm," 2018 10th International Conference on Intelligent Human-Machine Systems and Cybernetics (IHMSC), 2018, pp. 142-145, doi: 10.1109/IHMSC.2018.00040.
[53] Jiang J , Han G , Liu L , et al. Outlier Detection Approaches Based on Machine Learning in the Internet-of-Things. IEEE Wireless Communications, 2020.
[54] H. Lin, H. Lin, X. Fang, M. Wang and L. Huang, "Intelligent Pipeline Leak Detection and Analysis System," 2020 15th International Conference on Computer Science & Education (ICCSE), 2020, pp. 206-210, doi: 10.1109/ICCSE49874.2020.9201761.
[55] H.Bosman et al., “Spatial Anomaly Detection in Sensor Networks Using Neighborhood Information,” Info. Fusion, vol. 33, 2017, pp. 41–56.
[56] Z. Lv et al., ”The Data Cleaning of Electric Industrial Control Terminal Based on the iForest and Genetic BP Neural Network Algorithms,” 2019 IEEE 2nd International Conference on Information Communication and Signal Processing (ICICSP), Weihai, China, 2019, pp. 490-494.
[57] A. Blum and P. Langley, “Selection of Relevant Features and Examples in Machine Learning,” Artificial Intelligence, vol. 97, pp. 245–271, 1997.
[58] H. Liu and H. Motoda, Feature Selection for Knowledge Discovery and Data Mining, vol. 454. Springer Science & Business Media, 2012.
[59] M. H. Bhuyan, D. K. Bhattacharyya, and J. K. Kalita, “Network Anomaly Detection: Methods, Systems and Tools,” IEEE Communications Surveys Tutorials, vol. 16, no. 1, pp. 303–336, First 2014, doi: 10.1109/SURV.2013.052213.00046.
[60] http://max.book118.com/html/2016/0720/48715523.shtm.
[61] P. Lison, “An introduction to machine learning." 2015.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

[62]M. Wu and L. Xie, “Online Detection of Low-Quality Synchrophasor Measurements: A Data-Driven Approach,” IEEE Trans. Power Syst.,vol. 32, no. 4, pp. 2817–2827, July 2017.
[63] H. Jiang, J. J. Zhang, W. Gao, and Z. Wu, “Fault Detection, Identification, and Location in Smart Grid Based on Data-Driven Computational Methods,” IEEE Trans. Smart Grid, vol. 5, no. 6, pp. 2947–2956, Nov2014.
[64] O. P . Dahal, S. M. Brahma, and H. Cao, “Comprehensive Clustering of Disturbance Events Recorded by Phasor Measurement Units,” IEEE Trans. Power Del., vol. 29, no. 3, pp. 1390–1397, June 2014
[65] Randles B M,Pasquetto IV,Golshan M S,etal.using the Jupyter notebook as a Tool for open science: An empirical study[C]//2017 ACM/IEEE Joint Conference on Digital Libraries(JCDL).IEEE,2017:1-2.
[66] 莫凡.机器学习算法的数据解析与 Python 实现[M].北京:机械工业出版社，2020：278-365.

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

致 谢

时间如白驹过隙，不知不觉我的研究生生涯已经快要结束了。回想刚进入东华大学的校园还历历在目。短短的两年的时间，经历了很多，收获了很多。很感谢自己遇见了东华大学，遇见了这么一群可爱的人们，在我未来的生活中，这些回忆都似一杯热茶永远温暖着我，亦似一捧清水让我时时观摩自己，督促自己。感恩遇见，让我的余生都充满喜乐与满足。

首先，我非常感谢研究生期间的导师陈雯老师。陈老师给我研究生生涯留下一笔宝贵的财富。她的严谨认真的学术态度，给我无论在学习还是生活都具有导向型的表率。从第一次模型的建立，再到模型的求解，最后到论文的撰写，陈老师在方方面面中都耐心的指导我，循循善诱，孜孜不倦。他的细心亲切的态度，让我从一开始的小心翼翼的汇报，渐渐的学会如何在学术会议上自信的表达自己， 如何怡然自得调节学习与生活之间的关系。陈老师关心着我们的学术进展，也关 心我们身心健康。遇此良师，此生收益不尽。

其次，我深深的感谢实验室的小伙伴们以及我的同门师兄师姐师弟师妹们。因为他们的鼓励与相伴，让我的两年半的求学经历充满了欢声笑语。感谢西门子高飞技术员在小论文撰写上给出的指导意见。非常感谢我的同门朱永琦，王鹤云。他们在我遇见烦恼时候细心的排忧解愁，当我自我怀疑的时候，给予的肯定。这短短的两年的时间，自己成长了很多，走过的青春的因为有他们才会显得如此的绚烂。遇此益友，此生暖我心扉。

最后，我要特别的感谢我的父母，感谢他们的支持与陪伴。让我可以全身心的关注自己的学业，勇敢且坚定的追求自己的梦想。肯定我的选择，支持我的选择，让我心无旁骛的继续向前。望云之情，此生无以为报。

在此，向所有陪伴我走过青春岁月的人表示深深的感谢，唯愿此生，汝与吾皆永安永健。

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

攻读硕士学位期间主要成果

[1] Mao Chen, Wen Chen, YongQi Zhu. ”A Novel Big Data Cleaning Algorithm Based On Edge Computing In Industrial Internet of Things,“ 2020 2nd International Conference on Advances in Computer Technology, Information Science and Communications (CTISC),[已录用]

(C)1994-2022 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net