武漢理工大學

（申请电子信息硕士专业学位论文）

# 设备时序数据异常检测方法及其物联网平台应用


培 养 单 位：　　信 息 工 程 学 院

专业学位类别：　　电 子 信 息 硕 士

论 文 作 者：　　李 光 耀

指 导 教 师：　　戴 亚 文　教 授

副 指 导 教 师：　　余 道 志　工 程 师



2024 年 5 月



中国知网　https://www.cnki.net

分类号_____ 密　　级_____

UDC _____ 学校代码 10497

# 武漢理工大學

# 学 位 论 文

题　　目 设备时序数据异常检测方法及其物联网平台应用

英文题目 Method for anomaly detection in device time series and its application on the Internet of Things platform

论文作者 李光耀

| | | | | | | |
|---|---|---|---|---|---|---|
| 指导教师 | 姓名 | 戴亚文 | 职称 | 教授 | 学位 | 博士 |
| | 单位 | 武汉理工大学理学院 | | | 邮编 | 430070 |
| 副指导教师 | 姓名 | 余道志 | 职称 | 工程师 | 学位 | 学士 |
| | 单位 | 湖北华鑫科技股份有限公司 | | | 邮编 | 437000 |

| | | | |
|---|---|---|---|
| 申请学位级别 | 硕士 | 学科专业名称 | 电子信息 |
| 论文提交日期 | 2024 年 5 月 | 论文答辩日期 | 2024 年 5 月 |
| 学位授予单位 | 武汉理工大学 | 学位授予日期 | 2024 年 6 月 |
| 答辩委员会主席 | 周建 | 评　阅　人 | 学院内审专家 |
| 答辩委员会委员 | 陈德军 教授、王逸群 高级工程师 | | |
| | 郑林 教授、唐金锐 副教授 | | |

2024 年 5 月

中国知网 https://www.cnki.net

# 摘 要

随着物联网的快速发展，物联网平台在各个行业特别是在工业领域中扮演着重要角色。工业物联网 (IIoT) 通过连接设备和传感器，有助于生产过程的数字化和自动化。然而，面对大规模设备和传感器的连接和数据流的爆发式增长，物联网平台也面临着一些挑战，包括数据集成、数据管理、数据安全性、实时响应能力和灵活性等方面的问题。因此，开发一个综合性物联网平台将设备连接、数据管理、可视化分析和决策支持等功能融合在一起具有重要意义。同时，物联网平台通过连接大量设备和传感器，收集了丰富的时序数据，包括设备运行状态、传感器读数、生产过程参数等信息。对这些数据进行分析可以帮助发现潜在的设备故障、优化生产流程、提高效率和保证产品质量。其中，时序数据异常检测技术可以实时监测设备运行状态，并及时发现异常情况，如设备故障、异常行为等。通过准确地识别异常，可以避免设备故障导致的停工和损失，提高生产效率和设备可靠性，给相关运营和决策提供帮助。

对于以上问题，本文的工作内容如下：

（1）同时考虑多传感器变量时间维度与空间维度的关联信息，提出时空关联信息挖掘的设备多传感器时序数据异常检测算法。改进图注意力网络（GAT），实现图注意力网络的稀疏表示，进行多传感器关联的空间特征提取。改进 Transformer 模型的多头自注意力计算，实现基于卷积多头自注意力 Transformer 的多传感器时序数据的时间特征提取。基于稀疏 GAT 和卷积多头自注意力 Transformer 进行设备多变量时序数据异常检测实验，在公开数据集 SWaT 上的异常检测结果表明，本文提出的模型性能优于其他多个先进的异常检测模型。

（2）设计和实现了一个多层架构的物联网平台，包括感知层、边缘层和云端服务层。感知层通过各种设备和传感器获取物理量数据，边缘层负责解析和转换感知层数据，并通过网络传输给云端服务层。云端服务层提供设备管理、数据采集和存储、数据处理、规则引擎、可视化仪表盘等丰富功能。同时集成设备时序数据异常检测算法，帮助管理者提前做出决策和发现异常情况。

**关键词：**时序数据；异常检测；GAT；Transformer；物联网平台



中国知网 https://www.cnki.net

# Abstract

With the rapid development of the Internet of Things (IoT), IoT platforms play a crucial role in various industries, particularly in the industrial sector. Industrial IoT (IIoT) facilitates the digitization and automation of production processes by connecting devices and sensors. However, IoT platforms face challenges in dealing with the massive connectivity of devices and the exponential growth of data streams, including issues related to data integration, data management, data security, real-time responsiveness, and flexibility. Therefore, the development of a comprehensive IoT platform that integrates device connectivity, data management, visualization analytics, and decision support is of paramount importance. Furthermore, IoT platforms collect abundant time-series data by connecting a large number of devices and sensors, including information on device operating status, sensor readings, and production process parameters. Analyzing this data can help identify potential equipment failures, optimize production processes, improve efficiency, and ensure product quality. Among the various analysis techniques, time-series data anomaly detection is particularly valuable. It enables real-time monitoring of device operating states and timely detection of anomalies such as equipment malfunctions and abnormal behaviors. Accurate anomaly identification can prevent downtime and losses caused by equipment failures, ultimately enhancing production efficiency and device reliability. This offers significant assistance to decision-makers and operational management. In this regard, this paper focuses on the following research contributions:

(1) Considering the temporal and spatial correlations among multiple sensor variables, proposing a method for mining spatiotemporal correlation information to achieve device time-series data anomaly detection. The method improves the Graph Attention Network (GAT) to achieve sparse representation of the graph attention network for spatial feature extraction with multiple sensor correlations. Additionally, it enhances the multi-head self-attention calculation of the Transformer model to extract temporal features from multi-sensor time-series data using a convolutional multi-head self-attention Transformer. Experimental results on the publicly available SWaT dataset demonstrate the superior performance of the proposed model for device multivariate time-series data anomaly detection compared to other advanced anomaly detection



中国知网 https://www.cnki.net

models.

(2) Designing and implementing a multi-layer architecture for an IoT platform, comprising the perception layer, edge layer, and cloud service layer. The perception layer acquires physical data from various devices and sensors, the edge layer is responsible for parsing and transforming the data from the perception layer, and the cloud service layer provides rich functionalities including device management, data collection, storage, processing, rule engine, and visualization dashboard. Additionally, it integrates algorithms for device time-series data anomaly detection to aid in decision-making and anomaly detection.

**Key words:** Time series data; Anomaly detection; Graph Attention Network; Transformer; IOT platform



中国知网 https://www.cnki.net

# 目 录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 设备物联网平台研究现状.....2
1.2.2 设备时序数据异常检测研究现状.....4
1.3 研究内容和组织架构.....7
第二章 时序数据异常检测研究基础.....9
2.1 数据预处理.....9
2.2 时序数据时空关联性分析.....11
2.2.1 空间特征建模方法.....13
2.2.2 时间特征建模方法.....15
2.3 异常检测方法.....17
2.4 本章小结.....18
第三章 基于时空关联性的设备时序数据异常检测.....19
3.1 基于稀疏 GAT 的空间特征提取.....20
3.1.1 图注意力网络.....20
3.1.2 稀疏图注意力.....23
3.2 基于卷积注意力 Transformer 的时间特征提取.....25
3.2.1 Transformer 编码器.....25
3.2.2 基于卷积注意力的 Transformer.....29
3.3 基于稀疏 GAT 和改进 Transformer 的异常检测模型.....30
3.3.1 异常检测定义.....30
3.3.2 异常检测模型.....32
3.3.3 评价指标.....33
3.4 异常检测实验.....34
3.4.1 数据集及预处理.....34
3.4.2 实验环境与模型参数.....35
3.4.3 实验结果分析.....36
3.4.4 模型对比.....40
3.5 本章小结.....41
第四章 设备物联网平台设计.....42
4.1 平台需求分析.....42
4.1.1 功能性需求分析.....43
4.1.2 非功能性需求分析.....43

中国知网 https://www.cnki.net

4.2 平台相关技术.....44
4.2.1 Web 开发技术.....44
4.2.2 数据库.....45
4.2.3 设备通信协议.....46
4.2.4 数据流通道.....47
4.2.5 高并发技术.....48
4.3 系统总体架构设计.....49
4.4 功能模块设计.....51
4.4.1 设备协议适配模块.....51
4.4.2 管理模块.....52
4.4.3 规则引擎模块.....55
4.4.4 异常数据检测模块.....57
4.5 本章小结.....58
第五章 设备物联网平台实现和功能测试.....59
5.1 平台搭建.....59
5.2 系统实现.....59
5.2.1 设备协议适配模块.....59
5.2.2 数据库实现.....61
5.2.3 管理模块.....64
5.2.4 规则引擎模块.....67
5.2.5 异常检测模块.....69
5.3 系统应用实例.....70
5.4 本章小结.....75
第六章 总结与展望.....76
6.1 总结.....76
6.2 不足与展望.....76
参考文献.....78

中国知网 https://www.cnki.net

# 第一章 绪论

## 1.1 研究背景及意义

随着数字化转型的加速，越来越多的行业和企业开始依赖于先进的信息技术来提高效率、降低成本并创造新的价值。物联网作为这一转型的关键技术之一，通过将现实世界的物体连接到互联网，实现数据的实时采集和交换，对环境、设备和用户行为的实时监测和交互，为各行各业带来了革命性的变化。随着设备互联数量的增加，数据量呈爆炸式增长，产生了对数据处理和智能分析技术的需求。企业和组织需要有效地管理和分析这些数据，以便洞察业务运营、优化决策过程和预测未来趋势。然而，数据的价值并不是自动显现的，它需要通过智能分析来挖掘。这就带来了对高级数据处理技术的需求，包括数据挖掘、机器学习和深度学习等。通过应用这些技术，企业可以从庞大的数据集中识别模式、预测趋势和发现异常，从而实现更加精准和智能的决策支持。

在工业领域，设备和传感器是生产过程中不可或缺的组成部分。随着工业4.0 革命的推进，这些设备和传感器越来越多地被连接到互联网，形成了所谓的工业物联网（IIoT）。IIoT 的核心价值在于通过收集和分析来自设备和传感器的数据，以提高生产效率、降低运营成本，并提升产品质量。在这一背景下，异常检测技术的应用具有重要意义。异常检测技术可以实时监控设备和传感器的运行状态，一旦检测到偏离正常范围的数据，就能立即发出警报。这对于及时发现设备故障、防止生产事故和保证产品质量至关重要。

物联网的一个核心特点是其设备和数据的多样性。从家庭的智能设备到工业传感器，从城市交通系统到农业监测装置，这些设备不仅种类繁多，而且使用了各种不同的数据格式和通信协议。这种异构性带来了显著的挑战，尤其是在数据集成、管理和分析方面。企业需要开发和部署能够处理多种数据类型和协议的技术解决方案，以确保数据的顺畅流动和有效利用。此外，保障数据的安全性和隐私也变得更加复杂。要应对这些挑战，需要更加灵活和强大的数据处理平台，这些平台不仅要能够支持广泛的数据类型和通信协议，还要能够确保数据的安全和合规。

随着工业物联网中设备和传感器数量的增加，数据量呈爆炸性增长，这就对数据的收集、存储、处理和分析提出了更高的要求。在这种情况下，一个综



中国知网 https://www.cnki.net

合性的物联网平台变得尤为重要。这样的平台要能够处理来自不同来源、不同设备和传感器的异构数据，包括不同的数据格式和通信协议，实现数据的无缝集成。在工业环境中，对实时数据的处理和分析尤为重要。平台需要能够实时收集和分析数据，以便快速响应设备状态的变化。鉴于工业数据的敏感性和对生产过程的重要性，平台需要确保数据的安全性和系统的可靠性，保护企业免受数据泄露和系统故障的影响。为了适应不断变化的业务需求和技术发展，平台需要具有良好的用户体验和灵活的扩展性，支持定制化和模块化设计。同时在兼容性和标准化方面能够与现有的企业 IT 系统和其他工业控制系统无缝集成，遵循行业标准，以促进数据和应用的互操作性。

综上所述，异常检测技术在工业设备和传感器的应用对于提高生产效率、降低运营成本具有重要意义。而一个综合性的物联网平台则是实现这些技术应用的基础，它能够帮助企业有效地管理和分析来自物联网设备和用户的大量数据，充分利用物联网的潜力，实现生产和运营的优化，支持企业的数字化转型和智能制造。

## 1.2 国内外研究现状

### 1.2.1 设备物联网平台研究现状

截至 2024 年，工业物联网（Industrial Internet of Things，IIoT）平台的研究和应用已经取得了显著的进展，平台在连接设备、收集数据、实现智能制造和提高工业效率方面起着至关重要的作用。物联网平台目前在集成不同类型的工业设备和系统方面变得更加高效和灵活，这包括了对老旧设备的兼容性改进，同时集成能力的提升也体现在跨平台数据共享和协同工作的能力上。数据是物联网的核心，当前物联网平台在数据处理和分析能力上取得了显著进步。利用先进的数据分析技术和机器学习算法，平台能够提供更深入的洞察，帮助企业预测维护需求、优化生产流程和提高能效。实时数据分析和边缘计算的应用也越来越普遍，这使得数据处理更加高效，减少了延迟，提高了决策速度。同时，安全性和隐私保护成为研究的重点，包括加强数据加密、设备身份验证和访问控制等方面。物联网平台也越来越多地针对特定行业的需求提供定制化解决方案，包括针对制造业、能源、交通和医疗等行业的专用平台和应用。

Ferencz 等人[1]概述了 IIoT 系统以及基于云服务的实现方式，并提出了开源替代方案，总结了平台在数据收集、云服务、人工智能分析、数据可视化和网



中国知网 https://www.cnki.net

络安全等挑战。还研究了安全方面和 SOC 在 IIoT 系统中的集成。Savaglio 等人[2]探讨了 EI（边缘智能），这是一种边缘计算和人工智能融合的新范式，分析了 EI 对在感兴趣事件附近（而不是在云服务器上）处理 IIoT 数据的影响，提供了基于云和 EI 的 IIoT 部署之间的全面比较（在可靠性、响应能力、带宽使用、能源占用和可用性方面）。He 等人[3]利用物联网和智能控制技术，开发了一个实时灾害信息采集和提供平台。通过安装在桥梁上的传感器实时收集振动信息，异常时向居民和桥梁运营商发送警告，利用桥上的可变消息系统显示振动信息从而为驾驶员提供安全操作指导实现交通和行人安全。Rasyid 等人[4]利用物联网技术建立了一个平台，通过传感器检测红树林森林的各种水质指标，借助 Arduino 和 ESP32 将数据发送到 MQTT 并使用 ELK-Stack 可视化数据。并采用支持向量机（SVM）校准的水污染指数（IP）方法进行海水质量异常分析。陈[5]利用开源平台开发了大学环境监测管理平台，利用 LoRa 节点传输传感器数据，实现了校园环境指标的监测和可视化管理，并利用深度学习算法实现温度的预测和异常报警。Henschke 等人[6]提出了一种无线传感器网络（WSN）数据可视化的命题，利用开源硬件和软件在 WSN 的节点上收集数据，使用开源的物联网平台进行可视化，提高了物联网系统的经济效率。Chandrasekaran 等人[7]介绍了一种智能太阳能热水器系统，使用开源硬件和物联网平台进行设计和监测，实现实时控制，适用于智能家居和工业 4.0。Blechmann 等人[8]使用基于 FIWARE 软件框架和其他开源组件的开源平台，在智能建筑和智能电网领域的两个应用案例中进行实验性云控制，第一个案例控制传统供暖回路的供水温度，第二个通过实际相量测量单元监测模拟微电网的功率平衡。Okhovat 等人[9]构建了一个旨在收集、可视化和监控来自传感器和基础设施组件的数据流的架构，物联网平台用于数据收集和可视化。Node-Red 用于对传感器名称上的数据进行分类。Elsisi 等人[10]提出了一种基于工业物联网架构和深度卷积神经网络（CNN）的新型可靠解决方案，用于实现弹性的 DSM 和能量管理操作。建立了实时信号处理模型，并开发了基于 CWT 的 CNN 的物联网平台。Dwiyaniti 等人[11]创新性地采用基于 Modbus TCP/IP 连接到 ESP32 的 PLC 和通过 MQTT 协议连接到物联网平台实现数字化控制系统。该系统能够在不同负载下保持感应电机速度恒定。Dwiyaniti 等人[12]设计了一个基于物联网的温度、振动和电机速度监测系统。PLC 集成了输入输出设备和处理数据。PLC 通过 node-red 将数据发送到 IoT 平台。Ottolini 等人[13]对三个开源平台（FIWARE、ThingsBoard 和 Konker）进行了定性分析。模拟两个基于物联网的环境（智慧城市和智能健康）进行性能评



中国知网 https://www.cnki.net

估，查看平台的可扩展性、响应时间和计算机资源使用情况。Nammouchi 等人[14]提出了一种开放式架构，利用机器学习算法在边缘进行能耗和生产的预测，并通过开源平台和 Kafka Streams 在云中的集中式市场中进行数据聚合，可插拔的优化算法使不同的微电网实现实时最佳能源计划。

### 1.2.2 设备时序数据异常检测研究现状

在复杂的物联网系统中，多传感器被广泛部署用于监测和收集设备的运行状态和环境条件。各类传感器采集的时序数据往往存在着复杂的相关性和隐藏的模式，这给异常检测带来了很大挑战。传统的基于统计模型或规则的异常检测方法，往往需要依赖对系统拓扑结构和变量间关系的深入理解，才能设计出合适的检测策略。然而在实际部署中，物联网系统的规模和复杂度通常超出了人工分析的能力范围，缺乏足够的先验知识来构建这些传统方法。因此，开发基于深度学习的多变量时序数据异常检测算法显得尤为必要。深度学习模型能够自动从大量历史数据中学习系统的潜在模式和变量间的复杂关系，无需依赖对系统的先验知识。这种数据驱动的方法能够更好地捕捉非线性相关性、时空依赖等复杂特征，从而显著提高异常检测的准确性和鲁棒性。同时深度学习模型具有良好的迁移学习能力，可以应用于不同物联网场景。因此，这种方法更适合解决实际部署中的异常检测难题，为复杂物联网系统提供智能化的运维支持。

开发基于深度学习模型的多变量时序数据异常检测算法，对物联网应用具有重要意义。这种算法能够自动学习数据的复杂模式，发现隐藏的异常模式，为平台运维人员提供及时的预警和诊断支持。与传统的统计方法相比，深度学习模型能够更好地捕捉时序数据中的非线性相关性和时空依赖关系，从而提高异常检测的准确性和鲁棒性。

目前，传统的异常检测方法如基于阈值、基于统计学的方法、以及机器学习方法（如支持向量机和随机森林等）已被广泛应用。然而，这些方法往往依赖于手工特征提取，且在处理高维、高关联性的多传感器数据时效果不佳。研究者们通过开发和应用多变量时间序列分析技术，如向量自回归（VAR）模型、多变量长短期记忆网络（LSTM）、Transformer 模型和图神经网络（GNN），来捕捉数据的动态关系，提高了异常检测的准确性。Transformer 模型，尤其是其自注意力机制，为时序数据异常检测提供了新的解决方案。Transformer 的优势在于其能够捕捉长期依赖关系，可以通过重建或预测未来的时间步来识别异常。



中国知网 https://www.cnki.net

图注意力网络（GAT）通过将时间序列数据视为图结构，利用节点（传感器变量）之间的关系来提高异常检测的准确性。GAT 的优势在于其能够动态地学习节点间的权重，即使在节点间的关系不明显或数据动态变化的情况下也能有效工作。这种方法特别适用于多传感器系统，其中传感器之间的相互作用可能指示潜在的异常。这些模型能够从原始时间序列中自动学习和提取复杂的特征，无需人工干预，从而提高了异常检测的效率和准确性。

Saha 等人[15]提出名为 qLSTM 的新颖异常检测方法，基于 LSTM 网络结构估计条件分位数，并针对估计的分位数定义了三种不同的异常类型，在多个工业时间序列数据集非常有效。Chen 等人[16]针对多变量时间序列异常检测引入先验知识去除变量间不存在的依赖关系，同时构建了一个深度卷积残差自编码器，以保留空间维度上的季节性特征信息。使用 ConvLstm 预测网络，实现了对异常的细粒度决策。Altindal 等人[17]针对钻井作业中的异常事件提出了一个通用框架。通过应用主成分分析（PCA）、隔离森林（IF）和 lstm-autoencoder（LSTM-AE）等无监督学习算法，识别钻井数据中的异常模式和不规则性。Çokaj 等人[18]关注海底结构系统异常检测中的时间序列分类问题，研究中使用了统计离散和降维技术对时间数据进行预处理，探讨了监督机器学习分类算法的应用。Bilakanti 等人[19]关注在物联网设备中识别因传感器篡改而引起的异常，并专注于应用机器学习技术进行解决，研究了无监督算法（如隔离森林和局部异常值因子）的实用性，并结合监督技术提高异常检测的准确性。Cho 等人[20]关注多传感器信号分类的问题，旨在解决有效利用完全标记数据对多传感器信号建模的挑战。引入了监督对比学习（SCL）方法进行多传感器信号分类，验证了该方法在汽车发动机制造中的实际适用性。Mahmud 等人[21]针对工业控制系统（ICS）的异常检测和分类问题，使用隔离森林模型，异常识别准确率达到 77%，实现了自动异常检测、分类和数据标注。Shao 等人[22]提出了一种基于布隆过滤器和哈希的实时流异常检测方法，用于保护物联网设备的安全。该方法通过哈希算法扩展数据维度，并采用竞争学习（胜者通吃）构建多层布隆过滤器异常检测模型。刘[23]针对城市地质灾害易发地区部署的传感器提出了一种边坡监测数据异常事件检测方法。通过多传感器信息融合对监测数据噪声、模式分析困难和预警阈值不确定等问题。陈[24]介绍了 GNN 的基本框架，利用图结构和特征信息提高异常检测的准确性和鲁棒性，并讨论了其在静态图、动态图和时序数据异常检测方面的最新研究进展。李[25]通过注意力机制和时间模式注意力，提出了两种基于自编码器的异常检测模型，能够有效提取多元时序数据



中国知网 https://www.cnki.net

的特征并进行异常检测。刘[26]提出基于 MQTT 协议的数据采集模型和使用 TDengine 时序数据库，实现了加油站数据的安全传输和存储。采用 Transformer 和 Bi LSTM 相结合的深度学习方法进行异常检测，提高了准确率。操[27]研究了基于边云协同的异常检测系统，利用边侧设备和云平台的协同计算进行运行状态数据的异常检测。Zhao 等人[28]提出一种基于生成对抗网络（SGAD-GAN）的同步生成和异常检测框架，用于解决机械传感器数据异常检测中的不平衡数据集挑战。Hasani 等人[29]介绍了一种针对智能城市中大规模物联网传感器数据的异常检测创新框架。该框架结合了无监督机器学习技术、统计分析和专家特征工程，旨在实时检测智能城市环境下的异常情况。王[30]提出了基于 Transformer 的 DMRformer 模型用于长时序分解预测，通过渐进式分解和多尺度融合捕捉时序间的依赖关系。同时，还提出了基于 Transformer 和 GAN 的多维时间序列异常检测模型。Nakamura 等人[31]讨论了时间序列异常检测中的不一致性问题，不一致性被定义为时间序列中与其最近邻居距离最大的子序列，提出 MERLIN 算法，高效、准确地找到海量时间序列档案中所有长度的不一致性。Zhao 等人[32]提出了一种用于多元时间序列异常检测的新型自监督框架，将每个单变量时间序列视为一个单独的特征，并包括两个并行的图注意层，以学习多变量时间序列在时间和特征维度上的复杂依赖性。Deng 等人[33]提出结合结构学习和图神经网络的方法，可以更准确地检测多元时间序列异常，捕捉传感器间关系，并提供对检测到异常的可解释性。Zhang 等人[34]对于多元时间序列数据异常检测提出一种新的深度学习算法 CAE-M，结合卷积自编码器和记忆网络，能更好地捕捉时空相关性，并区分正常、异常和噪声数据。Tuli 等人[35]提出了一种基于深度变压器网络的异常检测和诊断模型 TranAD，使用基于注意力的序列编码器快速执行推理，并采用自我调节的特征提取和对抗训练方法提高稳定性。郑[36]基于图注意力网络和共演进时序数据提出了一个 DWGAT 异常检测模型，结合了先验信息和神经网络自适应特征挖掘功能实现异常检测。Zhang 等人[37]结合 Transform 和 GAN，用于检测工业控制系统中的异常行为。Wang 等人[38]提出了一种用于多元时间序列异常检测（TSAD）的新型无监督模型，采用深度自编码器来捕获多元时间序列数据的空间特征，同时使用多尺度稀疏 Transformer 网络来提取时间特征，采用基于动态阈值 POT 方法的异常检测模块来检测异常。Yan 等人[39]对深度迁移学习进行了深入回顾，并探讨了其在工业领域时间序列异常检测任务中的应用。Kang 等人[40]提出了一种变量时间变换器（VTT）模型，利用自注意力机制建模变量之间的时间依赖性和关系，从而实现多元时间序列



中国知网 https://www.cnki.net

异常检测。Wang 等人[41]使用频率增强条件变分自动编码器（FCVAE），通过将全局和局部频率特征集成到条件中，并使用目标注意力机制，捕获时间序列长周期异质模式和详细的短周期趋势实现异常检测。Zeng 等人[42]提出了一种新的多元时间序列异常检测结构，利用对抗性变压器结构有效检测异常，并融合异常概率策略以及重建误差作为先验知识来增强异常检测性能。Ding 等人[43]提出多模态时空图注意网络（MST-GAT），利用 MST-GAT 和时间卷积网络来建模多模态时间序列的时空相关性，并同时优化重建和预测模块。Jeong 等人[44]提出一种使用自监督模型训练的方法，设计基于 Transformer 的架构 Anomaly BERT，能够有效识别时间上下文并检测复杂时间序列中的异常。Xia 等人[45]提出基于注意力的耦合神经网络框架 CAN，将自适应图学习方法与图注意力相结合并结合时间自注意力模块实现异常检测。Nguyen 等人[46]通过解决两个时间序列数据的最长公共子序列（LCS）问题来进行时间序列异常检测，还提出了一种间隙搜索约束和阈值来减少计算时间。Chen 等人[47]提出两种基于深度学习的半监督异常检测方法 LR-SemiVAE 和 RT-SemiVAE，分别使用 LSTM 和 Transformer 结构来捕获时间序列数据的短期和长期依赖关系，实现更快、更准确地检测异常。Liu 等人[48]基于时间卷积网络和动态图注意力的异常检测框架，能够有效建模变量和时间序列之间的复杂相关性，检测航天器的异常状态。Matar 等人[49]基于多头注意力 Bi-LSTM 方法，同时建模多个传感器的时间序列，实现无线传感器网络数据流异常检测。Ma 等人[50]提出一种无监督的双向 Transformer 异常检测方法，利用 Bi-Transformer 结构提取数据关联特征，并使用改进的自适应多头注意力机制并行推断多元时间序列数据的异常趋势。

## 1.3 研究内容和组织架构

本文对于工业设备的多变量时序数据异常检测问题，分析了当前时序数据异常检测方法研究的必要性和研究现状，整理了国内外针对时序数据异常检测研究的工作成果，提出了面向工业设备的多传感器时序数据的异常检测方法。异常检测方法基于稀疏的图注意力网络和卷积自注意力 Transformer，从时间和空间维度进行多变量时序数据关联信息挖掘，在公开数据集上面验证了异常检测模型的性能，可以对工业过程中的多个非平稳传感器变量构成的多元时序数据进行比较准确的异常检测。

同时，为了解决物联网领域存在的数据孤岛、可视化和分析、实时监控、



中国知网 https://www.cnki.net

设备管理混乱等一系列问题，基于开源技术，实现了一个通用的物联网数据管理和分析平台，包括感知层、边缘层和云端服务层，实现异构设备接入和管理，数据管理、可视化开发以及设备时序数据异常检测等功能，并介绍了平台的应用实例。

本文的研究内容与组织结构展开如下：

第 1 章：绪论。主要介绍了当前物联网平台应用面临的挑战，以及设备时序数据异常检测的研究现状，明确了本文主要的研究内容为搭建一个通用的设备物联网平台以及实现设备时序数据异常检测算法。

第 2 章： 时序数异常检测研究基础。对于时序数据异常检测基础知识进行介绍。介绍了时空关联性特征提取的常用方法，比如图神经网络和 Transformer 等。介绍了基于预测和基于重构的两种主流异常检测方法。

第 3 章：基于时空关联性的设备时序数据异常检测。改进图注意力网络实现稀疏表示，改进 Transformer 实现卷积多头自注意力。使用稀疏图注意力和卷积多头自注意力 Transformer 从时空维度进行时序数据特征提取，实现设备多变量时序数据异常检测，在同一数据集与多个先进异常检测模型进行了对比。

第 4 章：设备物联网平台设计。整理了物联网平台的功能性与非功能性需求，并且介绍了相关的 Web 开发技术、数据库、设备通信协议和技术架构等。提出整个物联网平台的总体架构，分为感知层、边缘层和服务层并详细介绍了系统各个功能模块的设计。

第 5 章：设备物联网平台实现和功能测试。介绍了系统的搭建过程，以及系统的协议适配、数据库、业务管理、规则引擎和异常检测等多个模块的实现过程，并对系统的设备接入，可视化和异常检测等功能进行测试。介绍了工业设备接入物联网平台的实际案例。

第 6 章：总结与展望。对设备时序数据异常检测方法和上述物联网平台进行总结，分析不足之处以及可以优化的方向。



中国知网 https://www.cnki.net

# 第二章 时序数据异常检测研究基础

对工业设备的多传感器时序数据进行分析时，主要的工作包括数据的预处理、时空关联特征分析以及预测和异常检测等部分。

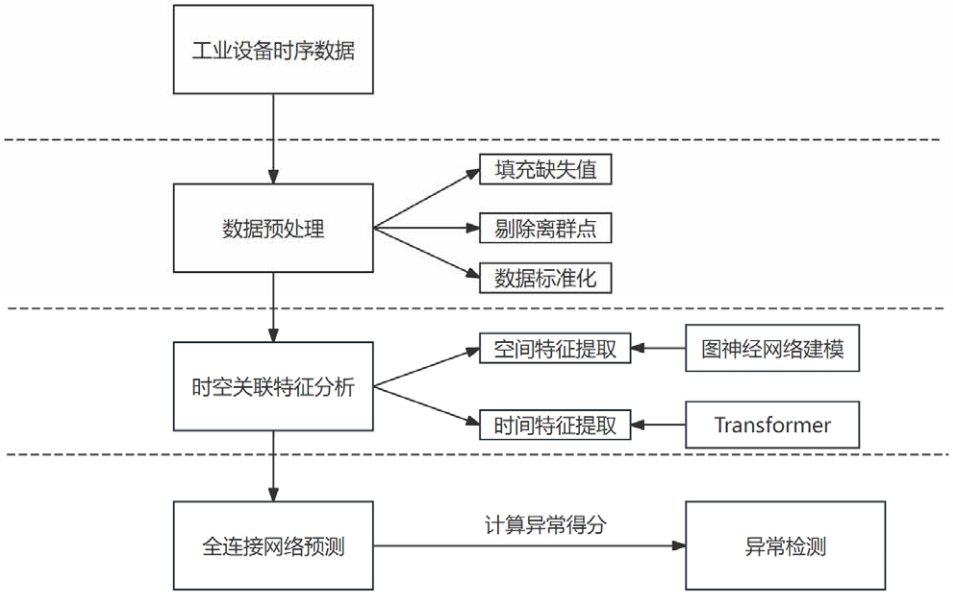



图 2-1 时序数据分析及异常检测流程

如图 2-1 展示了设备多传感器时序数据分析和异常检测的典型流程。首先，需要从工业设备的多个传感器收集时序数据。这些数据可能包括温度、压力、振动、电流等各种参数。收集到的原始数据通常需要进行预处理，以便于模型训练。对预处理后的数据进行时空关联特征分析，提取数据中的时间特征和空间特征。根据分析结果，提取出能够有效反映设备运行状态的特征。最后，通过全连接网络对特征聚合后的数据进行预测，可以实现多变量时序数据的异常检测。

## 2.1 数据预处理

在工业生产过程中，获取的原始数据往往受到噪声、数据丢失或失真等因素的影响。这些问题源于传感器数据采集、传输和记录过程中的不可避免的误差。数据质量对模型预测精度的影响至关重要，因此对原始数据进行预处理至关重要。数据预处理主要包括以下三个方面：

（一）离群点剔除



中国知网 https://www.cnki.net

离群点是与其他数据点明显不同的异常值，它们可能是由于传感器故障、设备故障、异常操作或其他异常情况引起的。如果在模型训练过程中保留了离群点，模型可能会受到这些异常值的影响，导致模型的性能下降或产生错误的异常检测结果。因此，剔除离群点可以避免模型受到异常值的干扰，提高模型的精度和鲁棒性。

时序数据分析中常用的离群点剔除方法包括：

（1）基于统计的方法：使用统计指标（如均值、标准差）或基于分布的方法来识别并剔除离群点。例如Z-Score方法是通过计算数据点与均值之间的标准差倍数，将超过阈值的数据点标记为离群点。箱线图方法是利用数据的四分位数和箱线图来识别低于下四分位数或高于上四分位数一定倍数的数据点。

（2）基于距离的方法：使用距离度量来判断数据点是否为离群点。例如最近邻方法是通过计算数据点与其最近邻之间的距离，将距离超过阈值的数据点视为离群点。孤立森林方法则是利用随机树的构建和路径长度来评估数据点的异常程度等。

（3）基于聚类的方法：使用聚类算法来识别离群点。例如 k-means 算法是通过将数据点聚类到 k 个簇中，将与其他簇距离较远的数据点标记为离群点。基于密度的聚类算法则是通过将数据点聚类到高密度区域，并将低密度区域中的数据点标记为离群点。

（二）缺失值填充。

缺失值是时序数据中的一种常见情况，可能是由于传感器故障、数据采集问题、人为错误或其他原因导致的数据缺失。在异常检测模型训练中，保持数据的完整性是非常重要的，因为缺失值可能会导致模型无法正常学习和预测异常模式。通过填充缺失值，可以使数据集保持完整，确保模型能够对整个时间序列进行建模和分析。填充缺失值可以采用多种方法，可以分为以下几种：

（1）均值填充：使用时间序列数据的均值来填充缺失值。这种方法假设缺失值与其他数据点的平均值相似。

（2）前向填充/后向填充：使用前一个时间点或后一个时间点的值来填充缺失值。这种方法适用于时间序列数据中的连续性较强的情况。

（3）插值方法：使用插值技术（如线性插值、样条插值）来填充缺失值。这种方法使用已知数据点之间的关系来估计缺失值。

（4）回归方法：基于已知数据点的回归模型来预测缺失值。这种方法适用于存在变量之间相关性的情况。



中国知网 https://www.cnki.net

选择合适的缺失值填充方法应考虑数据的特点、缺失值的分布和分析的目标。在填充缺失值之后，可以使用已填充的数据进行异常检测模型的训练和评估。

（三）数据标准化。

时序数据通常具有不同的尺度和范围。例如，某些特征可能具有较大的数值范围，而其他特征可能具有较小的数值范围。尺度差异可能导致模型在训练过程中对某些特征更加敏感。通过数据标准化，可以将所有特征的数值范围映射到相似的尺度，避免模型受到数值范围不同的特征的影响。同时通过将数据标准化为相似的尺度，可以使优化算法在训练过程中更均匀地更新模型参数，从而加快模型的收敛速度。

当在时序数据分析中应用标准化时，常用的方法包括最小-最大值（Min-Max）标准化和 Z-score 标准化等。

（1）最大-最小标准化（Min-Max 标准化）：将数据线性地缩放到指定的范围（例如[0，1]）。这种方法通过将数据减去最小值并除以最大值与最小值之差来实现。Min-Max 方法的优势在于适用于有界特征，处理后的数据具有较小的数值范围和更接近于标准分布的形态，这可以加速梯度下降等优化算法的收敛速度。同时由于标准化是基于数据范围的，异常值受到的影响相对较小。

（2）对于每个特征，Z-Score 标准化将数据减去该特征的均值，并除以该特征的标准差。通过将数据转换为标准分数，Z-Score 标准化确保数据的均值为0，标准差为1，使得数据在整个分布中的位置更具可比性。Z-Score 标准化对于存在极端值（离群点）的数据较为敏感，离群点可能导致均值和标准差的计算受到影响，从而影响标准化结果。

选择合适的标准化方法应考虑数据的特点、分布以及分析的需求，根据具体情况选择合适的标准化方法可以提高时序数据分析的准确性和可解释性。

## 2.2 时序数据时空关联性分析

工业生产领域的时序数据具有以下特点：

（1）高维度：工业生产过程通常涉及大量传感器和设备，传感器会产生多维度的数据。例如，温度、压力、湿度、速度和电流等参数可以同时进行采集和记录。这导致工业生产领域的时序数据具有高维度的特点。

（2）时序关系：工业生产过程中的数据具有明显的时序关系。传感器数



中国知网 https://www.cnki.net

据的采样是按照时间顺序进行的，数据点之间存在时间上的依赖关系。这种时序关系对于分析和预测工业生产过程中的异常行为非常重要。

（3）噪声和异常值：工业生产环境通常存在噪声和异常值的干扰。噪声可能来自于传感器的测量误差、环境干扰或设备故障等。异常值可能是由于设备故障、操作失误或其他突发事件引起的，这些异常值可能对工业生产过程的正常运行产生重大影响。

（4）大规模性：工业生产过程通常涉及大规模的数据采集和处理。生产线上可能存在成千上万个传感器和设备，每个传感器都产生大量的数据点。因此，工业生产领域的时序数据往往具有大规模性，需要有效的方法来处理和分析。

工业生产领域的时序数据具有高维度、多样性、时序关系、噪声和异常值以及大规模性等特点。这些特点使得对工业生产时序数据的分析和异常检测具有挑战性，需要采用适当的方法和技术来处理和提取有用的信息。

多传感器时序数据通常来自于不同位置或不同部件的传感器，每个传感器收集到的数据可能代表了系统中不同的状态或行为。通过进行空间关联性分析，可以揭示不同传感器之间的关联关系和相互影响。这对于综合理解整个系统的状态和行为非常重要。在工业设备中，某些异常情况可能会在一个传感器上表现为正常，但在多个传感器之间的关联性分析中会显示出不一致的模式。因此，通过空间关联性分析可以揭示潜在的异常模式和故障。

一方面，工业设备中的多传感器时序数据中存在的复杂关联关系可以通过图结构来表示，其中传感器节点对应于图中的节点，传感器之间的连接关系对应于图中的边。图结构能够捕捉到传感器之间的空间关联性和相互作用。图神经网络是一类专门用于处理图结构数据的神经网络模型，能够有效地学习和表示图中节点之间的关系。图神经网络通过消息传递和聚合的方式，可以在传感器之间传递和整合信息，从而捕捉到传感器之间的关联特征。同时，图神经网络具有自适应性和泛化能力，能够从数据中学习到传感器之间的关联关系，而无需依赖预先定义的规则或特征工程。因此本文使用图神经网络提取和表示工业设备多传感器时序数据中的空间特征，并用于异常检测任务。

另一方面，工业设备多传感器时序数据中的时间维度包含了重要的信息。通过时间特征提取，可以捕捉到数据在时间上的动态变化和趋势，揭示设备的运行状态和行为模式。时间特征可以提供关于设备运行状态的线索，帮助检测异常情况和预测设备故障。工业设备的传感器时序数据通常存在着长期的依赖



中国知网 https://www.cnki.net

关系，传统模型如循环神经网络（RNN）在处理长序列时容易出现梯度消失或梯度爆炸的问题。相比之下，Transformer 模型通过自注意力机制捕捉到较远时间步之间的相关性，更准确地建模序列数据中的长期依赖关系。Transformer 模型中的自注意力机制允许并行计算不同时间步之间的特征提取，大大加快了模型的训练和推断速度。同时，传统方法通常需要通过手动设计和提取特征来表示时序数据的特点，这依赖于领域知识和特征工程的经验。而 Transformer 模型可以自动学习输入序列中的关键特征和模式，不需要依赖人工设计的特征，更具有灵活性和适应性。因此本文考虑使用 Transformer 进行设备的时序数据特征提取。

### 2.2.1 空间特征建模方法

图神经网络（Graph Neural Networks，简称 GNN）是一类专门用于处理图数据的机器学习模型。传统的神经网络模型主要针对向量数据，而 GNN 扩展了神经网络的能力，能够处理具有图结构的数据，如社交网络、推荐系统、分子结构等。

一种常见的 GNN 模型是图卷积网络（Graph Convolutional Network，简称 GCN）。图卷积网络的基本思想是通过图的结构信息来进行卷积操作。一个图 $G$ 通常由节点集 V 和边集 E 组成，表示为 G=(V,E)。每个节点 $v \in V$ 有一个特征向量 $x_v$，整个图的特征矩阵表示为 $X$。图的结构信息通常通过邻接矩阵 $A$ 来表示，其中权值 $A_{ij}$ 表示节点 i 和节点 j 之间的连接关系，$A_{ij}$ 越大表示节点间的关联越强。

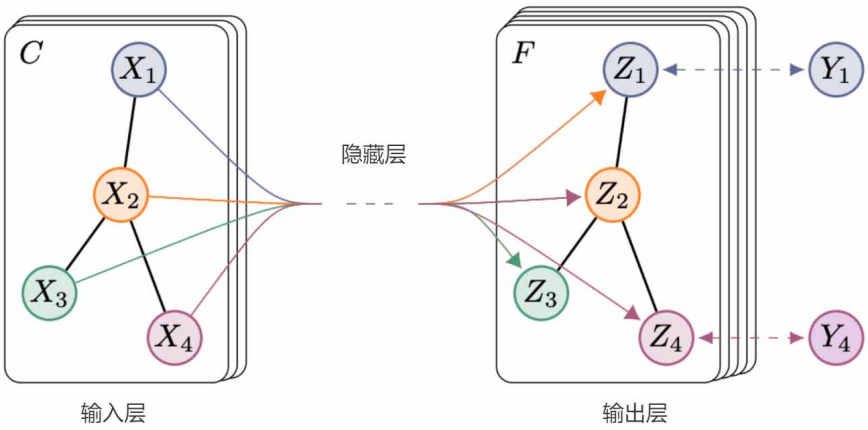



图 2-1 GCN 示意图



中国知网 https://www.cnki.net

图数据经过多层 GCN 处理后，节点特征由 $X$ 更新为 $Z$，和隐藏层的数量无关，节点间的邻接矩阵 $A$ 都是共享的。对于一个两层的 GCN，其正向传播过程可表示为：

$$Z = f(X, A) = softmax\left(\tilde{A}ReLU\left(\tilde{A}XW^{(0)}\right)W^{(1)}\right) \tag{2-1}$$

其中， $softmax$ 和 $ReLU$ 为激活函数，$W$ 为参数矩阵。

图卷积操作的核心是通过邻接矩阵 $A$ 和特征矩阵 $X$ 来进行卷积。一个典型的图卷积层的计算公式如下：

$$H^{l+1} = \sigma\left(\tilde{D}^{-1/2}\tilde{A}\tilde{D}^{-1/2}H^{l}W^{l}\right) \tag{2-2}$$

$$\tilde{A} = A + I \tag{2-3}$$

$$\tilde{D}_{ii} = \sum_{j}\tilde{A}_{ij} \tag{2-4}$$

其中 $H^l$ 第 $l$ 层的节点特征矩阵，初始时 $H^0$ 初始为 $X$，$A$ 为邻接矩阵，$I$ 为单位矩阵，$\tilde{A}$ 是加上自环的邻接矩阵，$\tilde{D}$ 是的度矩阵，$\tilde{D}^{-1/2}\tilde{A}\tilde{D}^{-1/2}$ 为归一化的邻接矩阵，$W^l$ 是第 $l$ 层的权重矩阵，$\sigma$ 是激活函数，如 $ReLU$ 函数。

对于归一化的邻接矩阵，值为 0 的位置表示节点之间不存在关联，节点 i 的邻居节点集合 $N(i)$包括节点 i。在图卷积网络中，节点 i 的特征向量是通过聚合其邻居节点 j 的特征向量来更新的。

$$h_i^{l+1} = \sigma\left(\sum_{j\in N(i)} a_{ij}h_j^{l}W^{l}\right) \tag{2-5}$$

GCN 基于图的局部邻域结构，通过聚合节点的邻居信息来更新节点的表示。其主要思想是将节点的特征与其邻居节点的特征进行加权平均，以获取节点的新表示。总的来说，GCN 通过邻接矩阵捕捉图结构信息，并在每一层将节点的邻居特征向量加权求和，经过非线性变换后作为该节点的新特征向量，从而实现了在图结构数据上的卷积操作。这种邻居聚合机制使 GCN 能够很好地利用图数据的拓扑结构和节点特征信息。

进一步发展的图神经网络模型是图注意力网络（Graph Attention Network，简称 GAT）。GAT 引入了注意力机制来确定节点之间的重要性权重，使得节点能够对不同邻居节点进行不同程度的信息聚合。



中国知网 https://www.cnki.net

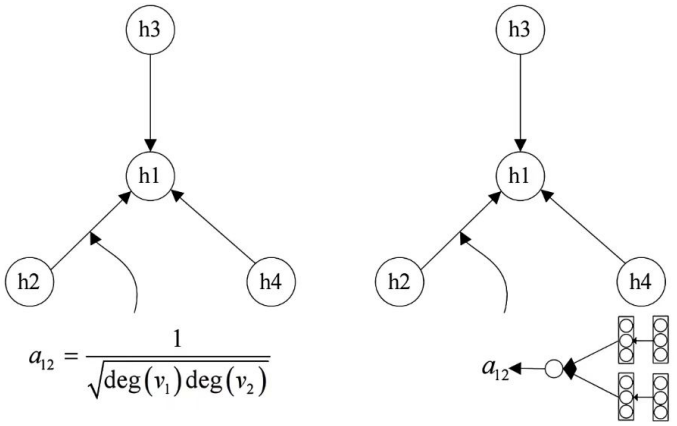



图 2-2 GCN 和 GAT 计算图节点间权重对比

在 GCN 中，节点之间的权重计算是基于固定的均等权重，即每个邻居节点对当前节点的贡献相同。而在 GAT 中，通过引入注意力机制，可以学习得到每个邻居节点对当前节点的自适应权重，从而实现更细粒度的信息聚合。邻居节点特征与对应的注意力权重进行加权求和，得到聚合后的邻居特征表示。这种方式能够根据节点的重要性动态地调整邻居节点的贡献，更加灵活地更新节点特征。

GAT 通过学习注意力权重，可以得到每个邻居节点对当前节点的贡献度，从而提供了一种对结果的解释机制。这种可解释性对于理解模型的决策过程和结果分析非常有帮助。因此，GAT 在处理图结构数据时能够更好地捕捉节点之间的关系，提供更准确的节点表示。

### 2.2.2 时间特征建模方法

在时序数据分析中，RNN（Recurrent Neural Network，循环神经网络）、LSTM（Long Short-Term Memory，长短期记忆网络）和 Transformer 等序列模型可以通过学习时间序列中的模式和依赖关系，从数据中提取有关时间的特征信息，从而实现预测任务。

RNN 是一类经典的神经网络模型，通过在隐藏层中引入循环连接，可以在处理每个时刻的输入时考虑之前的上下文信息，使得网络能够捕捉序列数据中的动态时间行为和时序依赖关系。LSTM 是 RNN 的一种特殊变体，通过门控机制解决了 RNN 在处理长序列时容易出现的梯度问题，可以更好地捕捉长期依赖关系，适用于处理具有长期依赖性的序列数据。



中国知网 https://www.cnki.net

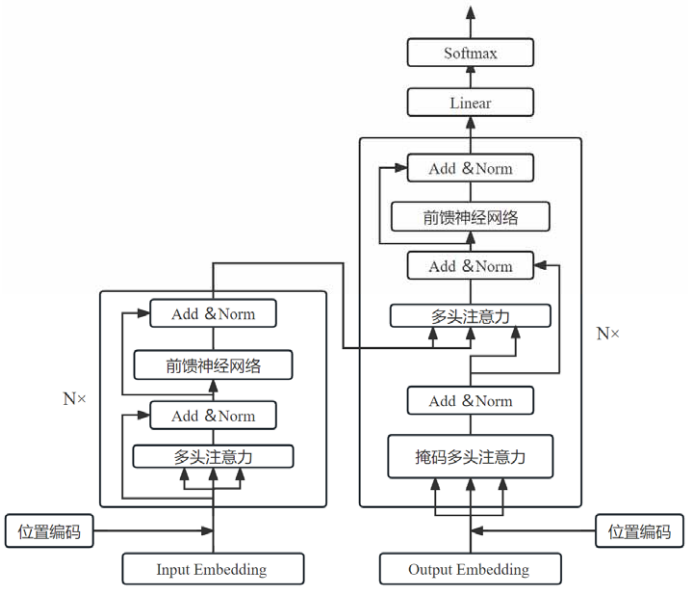



图 2-3 Transformer 结构图

Transformer 是一种基于自注意力（Self-Attention）机制的序列模型。它完全摒弃了 RNN/LSTM 的递归结构，使用注意力机制来直接建模序列数据中任意两个位置之间的依赖关系。近年来，Transformer 也被成功应用于时间序列预测等时序数据分析任务中。

Transformer 主要由编码器（Encoder）和解码器（Decoder）两部分组成。其中，编码器由多个相同的编码器层堆叠而成，同时，每个编码器层包含两个主要子层分别是多头自注意力机制（Multi-Head Self-Attention）和前馈神经网络（Feed-Forward Neural Network），每个子层后面都跟有残差连接和层归一化（Add ＆Norm）。解码器与编码器类似，也由多个解码器层堆叠，每个解码器层包含三个主要子层：多头自注意力机制、多头交叉注意力机制（Multi-Head Cross-Attention）和前馈神经网络，同样每个子层后面也有残差连接和层归一化。

Transformer 结构中的多头自注意力机制允许模型在计算每个位置的表示时，关注输入序列中所有其他位置的信息，并通过多个注意力头从不同子空间提取特征。前馈神经网络用于对输入序列的每个位置的表示进行独立的非线性变换。多头交叉注意力机制允许解码器关注编码器输出的所有位置信息。

Transformer 在多变量时序数据分析中的优势包括：

（1）并行计算效率：Transformer 的并行计算能力使其在处理多变量时序数据时具有高效性，能够加速模型训练和推理过程。

（2）全局依赖关系捕捉：自注意力机制使 Transformer 能够捕捉序列中任



中国知网 https://www.cnki.net

意两个时间步之间的依赖关系，这对于多变量时序数据中复杂的关联关系至关重要。

（3）灵活的特征提取：Transformer 的自注意力机制和多头机制使其能够同时关注不同子空间的特征，从而更好地捕捉多变量之间的交互关系，有助于发现关键特征和异常模式。

## 2.3 异常检测方法

时序数据异常检测是一种技术，用于识别时间序列数据中的异常或不寻常的模式。这些异常可能指示系统性能问题、潜在的故障或外部干扰。异常检测在多个领域中都非常重要，如金融服务、网络安全、工业制造等。通过利用先进的学习算法和物联网平台，可以充分发挥时序数据的潜力，通过提高系统可靠性、安全性、效率和预测性维护来实现相关领域的业务价值。

基于重构和预测的方式是当前两种常见的时间序列异常检测方法。基于预测的异常检测方法通过构建一个预测模型来预测未来的时间序列值，然后将预测值与实际值进行比较。如果预测误差超过某个阈值，则认为该点是异常的。该方法的核心在于预测模型的准确性和预测误差的度量。基于重构的异常检测方法通过构建一个重构模型来重构时间序列数据，然后将重构误差与实际值进行比较。如果重构误差超过某个阈值，则认为该点是异常的。该方法的核心在于重构模型的重构能力和重构误差的度量。

设备的多传感器时序数据本质上是多变量时序数据。基于预测的方法可以同时对多个时间序列进行联合建模和预测，从而捕捉不同变量之间的相关性和交互作用，提高异常检测的准确性。而基于重构的方法通常需要先将多变量数据拼接或堆叠成高维数据，然后再进行重构，可能无法很好地利用变量间的相关性。同时，预测模型的输出是对未来时间点的预测值，与实际观测值的差异可以直接用于异常检测和定位。这种直接的预测误差更易于解释和诊断，有助于分析设备异常的根源和影响范围。而重构方法的输出是重构误差，不太直观。

本文使用基于预测的方法，主要基于以下几点优势：

（1）趋势识别：预测模型可以识别数据中的长期和短期趋势，这有助于区分正常的波动和真正的异常。

（2）使用预测模型可以动态地生成预测值和置信区间，这些可以作为动态阈值来判断何时的数据点可以被认为是异常的。



中国知网 https://www.cnki.net

（3）适应性：许多预测模型，如 LSTM 和 Transformer 等，具有很好的适应性，能够根据新数据自我调整，从而提高对新型异常的检测能力。

（4）减少误报：通过与预测值的比较，可以更准确地识别异常，从而减少误报的情况，以下是一些常用的时序数据预测模型介绍。

自回归模型（AR）使用过去的时间序列值来预测未来的值。移动平均模型（MA）使用过去的误差项来预测未来的值。自回归移动平均模型（ARMA）结合了 AR 和 MA 模型的优点。自回归积分移动平均模型（ARIMA）在 ARMA 模型的基础上加入了差分操作，以处理非平稳时间序列。长短期记忆网络（LSTM）通过记忆单元和门控机制来控制信息的流动，从而提高预测精度。Transformer 通过自注意力机制捕捉时间序列中的长短期依赖关系，具有并行计算的优势，适合处理长时间序列数据。

对于工业设备多传感器的时序数据异常检测任务，工业设备通常包含多个传感器，产生多变量时序数据，AR、MA 和 ARMA 等传统模型主要针对单变量时序数据，Transformer 能够同时处理多个时间序列，并通过自注意力机制捕捉不同变量之间的相关性。同时，AR 和 MA 等线性模型在处理非线性数据时存在局限性，Transformer 由于其深层非线性结构，能够更好地捕捉时序数据中复杂的非线性模式。

## 2.4 本章小结

本章对于多传感变量时序数据分析时进行的研究基础进行了介绍，包括填充、剔除和标准化处理等数据预处理步骤。同时，对时序数据时空特征关联性分析常用的方法进行了介绍，给出了使用图注意力网络和 Transformer 进行时空特征提取的理由。对于基于预测和重构的异常检测方式进行了比较，基于本文异常检测方法的应用场景，选择了基于预测的方式实现异常检测。



中国知网 https://www.cnki.net

# 第三章 基于时空关联性的设备时序数据异常检测

本文提出的模型同时考虑多传感器变量时间维度与空间维度的关联信息，通过时空关联信息挖掘实现设备多变量时序数据异常检测。

从空间维度来看，时间序列模型，包括 LSTM、Transformer 和 TCN 等等，是挖掘时间维度的关联信息，空间维度并不能识别到，因此考虑通过图注意力神经网络 GAT 实现不同节点（即不同传感器变量）关联信息提取。如不同节点之间存在同时升高或降低的变化，即可以认为传感器之间存在空间上的关联。本文在原有图注意力神经网络（GAT）基础上进行改进，添加稀疏性，即原始 GAT 默认所有节点两两相连，但是现实世界中的设备，并不是所有传感器之间都是有关联的。这样的改进更适配设备多传感器数据的异常检测。

从时间维度来看，传统 Transformer 是输入序列点对点之间的关联信息挖掘，对于时间序列来说，并没有充分利用时间维度信息。因为时间序列单个点所含信息有限，序列段（多个时间点）反而包含更多信息，因此考虑序列段对序列段的关联信息挖掘。因此在计算 Transformer 的多头自注意力部分进行改进时，通过引入一维卷积实现多个时间点的特征聚合，实现基于卷积自注意力的 Transformer 编码器结构。

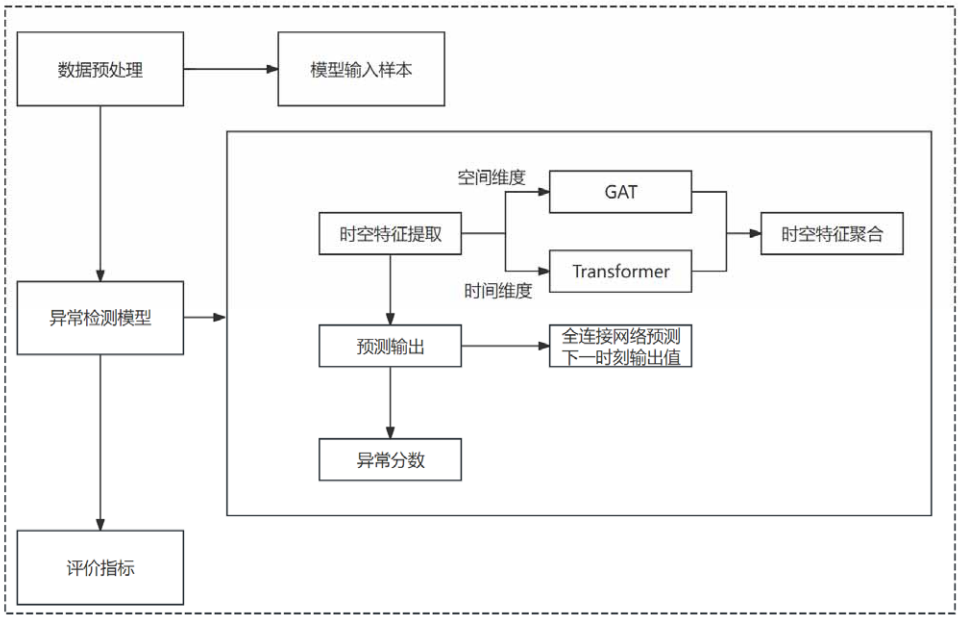



图 3-1 基于 GAT 和 Transformer 的异常检测总体框架



中国知网 https://www.cnki.net

多变量时序数据异常检测模型的总体架构如图 3-1 所示，输入的工业设备的多传感器时间序列，经过稀疏的图注意力网络 GAT 进行不同变量间的特征聚合，然后经过基于卷积自注意力的 Transformer 学习时间序列段与段之间的关联，最后通过全连接层根据所有变量特征的预测输出值，与真实值计算的异常得分与阈值进行比较，实现异常检测。

## 3.1 基于稀疏 GAT 的空间特征提取

### 3.1.1 图注意力网络

图注意力网络（Graph Attention Networks, GAT）是一种用于处理图结构数据的神经网络模型[51]。在 GAT 模型中，图中的每个节点代表一个实体，而边表示实体之间的关系或连接。GAT 将自注意力的概念从序列数据（如 Transformer 模型）扩展到图数据。在多传感器时序数据的异常检测应用中，GAT 可以非常有效地被用于不同变量间特征聚合。

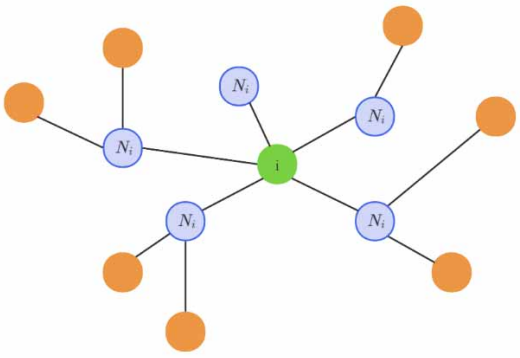



图 3-2 图结构示例

在 GAT 模型中，图中的每个节点都与一个特征向量相关联。GAT 的主要思想是计算每个节点的注意力系数，以捕捉其相对于图中其他节点的重要性。然后，使用这些注意力系数来计算相邻节点特征向量的加权和，从而有效地聚合邻域信息。

假设一个图有 N 个节点，输入为节点的 F 维特征集合可以表示为式（3-1）：

$$h=\left\{\vec{h}_1,\vec{h}_2,\ldots,\vec{h}_N\right\},\vec{h}_i\in R^F \tag{3-1}$$

首先经过一个以注意力为核心的聚合操作即图注意力层来强化特征，图注意力层的输出为新的节点特征集合：



中国知网 https://www.cnki.net

$$h^{'}=\left\{\vec{h_1^{'}},\vec{h_2^{'}},\ldots,\vec{h_N^{'}}\right\},\vec{h_i^{'}}\in R^{F^{'}} \tag{3-2}$$

GAT 的核心步骤包括计算注意力系数（Attention Coefficients）、特征加权求和（Aggregate）以及多头注意力（Multi-Head Attention）。

在 GAT 中，注意力系数的计算过程如下：

首先对所有的节点先初始化一个权重矩阵 $W\in R^{F^{'}\times F}$，注意力机制为单层的前馈神经网络，通过自注意力计算节点 $i$ 与节点 $j$ 的权重关系，$e_{ij}$ 可以理解为节点 j 对节点 i 的"重要性"或"贡献度"。

$$e_{ij}=LeakyReLU(\vec{a}^{T}[W\vec{h}_i\,\|\,W\vec{h}_j]) \tag{3-3}$$

节点 $i$ 与节点 $j$ 的特征向量分别为 $\vec{h}_i$ 和 $\vec{h}_j$，$W$ 是一个可训练的权重矩阵，用于线性变换节点特征，使得注意力机制能够在这个新的向量空间中更好地捕捉节点之间的关系和重要性。

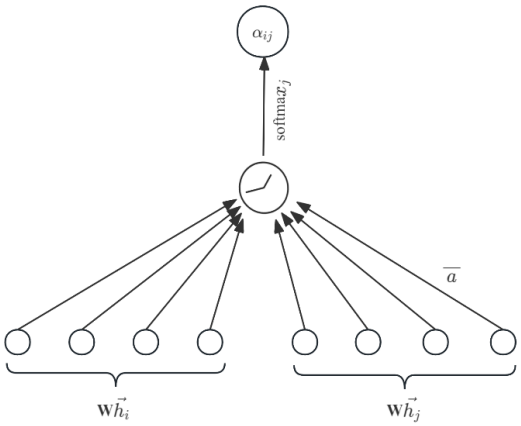



图 3-3 归一化注意力系数计算过程图

$\vec{a}$ 是一个可学习的参数向量，学习节点和邻居节点之间的相对重要性，以便实现对邻居的加权聚合。该参数向量通常被共享在图的所有节点上，并且只需要在训练过程中更新这些参数。‖表示特征向量的拼接操作，*LeakyReLU* 是 *ReLU* 激活函数的变体，用于引入非线性变换到 GAT 模型中。得到注意力系数 $e_{ij}$ 以后，对其进行归一化操作，如公式（3-4）所示：

$$\alpha_{ij}=softmax_j\left(e_{ij}\right)=\frac{exp\left(e_{ij}\right)}{\sum_{k\in N_i}exp\left(e_{ik}\right)} \tag{3-4}$$

其中 $N_i$ 为节点 $i$ 的所有相邻节点，包括节点 i 本身。



中国知网 https://www.cnki.net

$$\alpha_{ij}=\frac{exp(LeakyReLU(\vec{a}^{T}[W\vec{h}_i \| W\vec{h}_j]))}{\sum_{k\in N_i} exp(LeakyReLU(\vec{a}^{T}[W\vec{h}_i \| W\vec{h}_k]))} \tag{3-5}$$

*LeakyReLU* 是一个激活函数，用于引入非线性变换到 GAT 模型中。它与传统的 ReLU 函数类似，但在负数部分具有一个小的斜率，以解决 ReLU 函数的零梯度问题。

得到归一化的注意力互相关系数后，使用该系数计算相邻节点特征的线性组合，作为节点 i 的输出特征：

$$\vec{h}_i'=\sigma(\sum_{j\in N_i}\alpha_{ij}W\vec{h}_j) \tag{3-6}$$

其中$\sigma$为非线性激活函数。

在图数据中，节点之间可能存在多种不同的关系。多头注意力机制允许不同的注意力头专门关注不同类型的关系，从而更好地捕捉图数据中的复杂结构。多头注意力允许模型同时从不同的表示子空间捕捉不同的特征，增强了模型对复杂模式的建模能力。每个注意力头可以关注输入数据的不同部分，最终将这些不同子空间的特征融合，使得模型能够学习到更加丰富的特征表示。

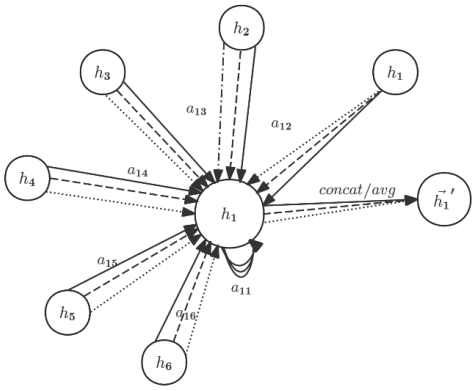



图 3-4 多头注意力特征融合

多头注意力的输出是单个头输出的串联或平均。对于 k 个头，节点 i 的新特征拼接方式可以通过以下公式计算：

$$\vec{h}_i'=\|_{k=1}^{K}\sigma\left(\sum_{j\in N_i}\alpha_{ij}^{k}W^{k}\vec{h}_j\right) \tag{3-7}$$

其中$\sigma$为非线性激活函数，连接保留了所有注意力头的原始信息，而平均聚合操作则是对来自不同注意力头的特征表示取平均，得到节点的最终表示，在输出层使用平均聚合而不是连接，可以一定程度上提高模型的泛化性能。



中国知网 https://www.cnki.net

$$\vec{h}_i' = \sigma\left(\frac{1}{K}\sum_{k=1}^{K}\sum_{j\in N_i}\alpha_{ij}^k W^k \vec{h}_j\right) \tag{3-8}$$

利用计算得到的注意力权重，GAT 将邻近节点的特征加权聚合，生成新的节点表示。通过以上过程，GAT 能够更好地捕捉图结构数据中的模式和关系。

### 3.1.2 稀疏图注意力

本文在图注意力网络基础上进行改进，通过在注意力机制中实现稀疏表示，选择性地聚合邻居节点的信息，从而减少计算复杂度并提高模型的效率和可解释性。具体来说，这种稀疏图注意力机制通过在计算节点的新特征表示时，只考虑权重系数最大的一部分邻居节点，而不是所有邻居节点。这样做的好处包括减少不必要的计算和噪声，同时关注最有信息量的连接，这对于处理大规模图数据或具有复杂连接模式的图尤其有效。

在图注意力网络（GAT）中，使用稀疏图注意力机制能有效地集中于每个节点最重要的 k 个邻居，只选择聚合权重系数较大的邻居特征来更新自己的特征表示，这样的操作具有以下好处：

（1）降低计算复杂度：通过选择权重系数较大的邻居进行聚合，可以显著减少每个节点需要处理的邻居数量，从而降低计算复杂度和运行时间。

（2）减少噪声影响：忽略权重系数较小的邻居可以视为一种噪声过滤机制，有助于模型专注于最重要的信息，提高模型的泛化能力和性能。

（3）提高模型的稀疏性：这种方法自然地增加了模型的稀疏性，有助于模型在大规模图数据上的扩展性和效率。

选择邻居的具体标准，主要是基于注意力系数的大小，即在计算注意力系数时，只考虑每个节点最重要的 k 个邻居节点的特征。

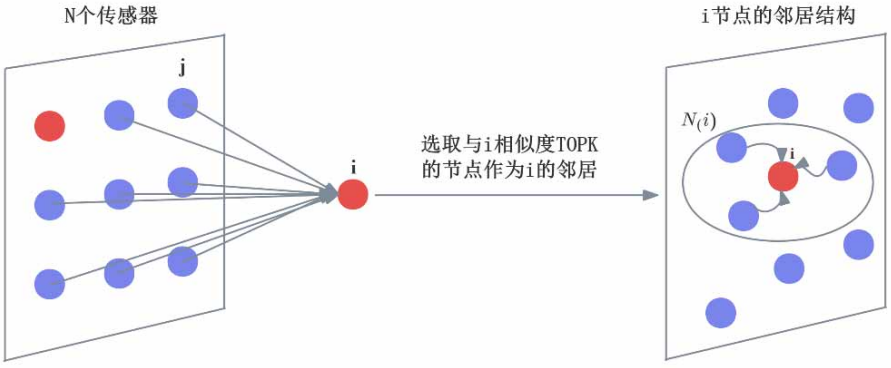



图 3-5 节点 i 寻找 k 个邻居节点



中国知网 https://www.cnki.net

对于每个节点 i，在计算注意力系数时，进行如下处理：

$$e_{ij}^{'}=\begin{cases}e_{ij} & j<k\\ e_{ij}\times e^{-14} & j\geq k\end{cases} \tag{3-9}$$

对节点 i 的所有邻居节点 j 的未归一化的注意力系数 $e_{ij}$ 进行排序，对于所有邻居节点其中最大的 k 个值不做处理，对于不在最大 k 个值中的将其乘以 $e^{-14}$ 使其接近于零，但不完全为零。 然后应用 softmax 进行归一化操作：

$$\alpha_{ij}=softmax_j\left(e_{ij}^{'}\right)=\frac{exp\left(e_{ij}^{'}\right)}{\sum_{k\in N_i}exp\left(e_{ik}^{'}\right)} \tag{3-10}$$

对公式（3-10）得到的 $e_{ij}^{'}$ 归一化为概率分布，其中数值较大的 k 个 $e_{ij}$ 占据主导地位，而其他接近零的值几乎不影响结果，最终得到归一化注意力系数，再进行节点特征更新的后续计算。

传感器节点之间的空间关系对于多传感器变量时序数据的异常检测非常重要。在没有先验知识或清楚传感器节点之间关联的情况下，使用稀疏图注意力机制（Sparse GAT）能有效进行不同变量间的空间关系建模。GAT 可以自动学习节点之间的空间关系，而无需事先指定或假设节点之间的连接方式。通过考虑权重系数最大的一部分邻居节点，稀疏 GAT 能够捕捉到数据中最相关的节点之间的关联，从而更准确地建模传感器之间的空间关系。

同时，在传感器网络中，节点的数量可能非常大。如果默认使用完全连接的图结构，将会导致计算复杂度的显著增加。相比之下，稀疏 GAT 只考虑权重系数最大的一部分邻居节点，大大减少了计算量。稀疏性表示可以提高模型的计算效率，并且使其能够适用于大规模的传感器网络数据。

最后，稀疏 GAT 的邻居节点选择是基于权重系数进行自适应选择的。通过在计算节点的新特征表示时仅考虑最相关的邻居节点，稀疏 GAT 能够根据输入数据的特点自动适应地选择重要的节点，并忽略不相关的节点。这种自适应性使得稀疏 GAT 更具灵活性和泛化能力，适用于不同类型的多传感器变量时序数据。

通过以上几点优势，稀疏 GAT 能够有效地学习多变量间的空间关系，进行空间特征聚合，为多传感器变量时序数据的异常检测提供更准确和高效的建模能力。



中国知网 https://www.cnki.net

## 3.2 基于卷积注意力 Transformer 的时间特征提取

### 3.2.1 Transformer 编码器

Transformer 模型是一种基于自注意力机制的深度学习架构，由编码器和解码器组成，用于处理序列到序列的任务[52]。编码器由多个相同的层堆叠而成，每个层包含两个子层：

（1）多头自注意力机制（Multi-Head Self-Attention）：这个机制允许模型在序列中的不同位置之间建立直接的依赖关系。在自注意力机制中，每个词都可以与序列中的其他词进行交互，以捕捉全局依赖关系。

（2）前馈神经网络（Feed-Forward Neural Network）：每个子层包含一个全连接的前馈神经网络，用于对每个位置的表示进行独立的转换。

Transformer 的编码器结构如下：

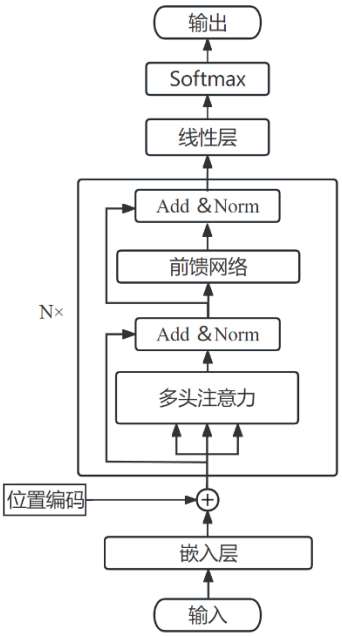



图 3-6 Transformer 编码器

Transformer 模型的 Encoder 层是由多个相同的层（通常称为 Encoder Block）堆叠而成的。每个 Encoder Block 主要包含两个子层：多头自注意力机制（Multi-Head Attention）和前馈神经网络（Positionwise Feed-Forward Network）。这两个子层都包含残差连接，并通过层归一化（Layer Normalization）处理。以下为 Transformer 编码器部分的结构和计算过程。



中国知网 https://www.cnki.net

（1）输入嵌入：输入序列首先被转换为嵌入向量。假设输入序列为 $x$，每个元素通过嵌入矩阵转换为对应的嵌入向量：

$$x_{embi} = W_{emb} x_i \tag{3-11}$$

$$X_{\text{emb}} = \{x_{emb1}, x_{emb2}, \ldots, x_{embn}\} \tag{3-12}$$

（2）位置编码：由于 Transformer 的输入序列为并行输入，处理时序数据时未保留输入时间序列的顺序。为了使 Transformer 模型能够利用时间序列的顺序信息，输入嵌入向量会与位置编码向量相加，用于将位置信息注入到输入序列中。位置编码通常使用正弦和余弦函数的组合来生成，每个维度的位置编码与位置的频率有关，计算公式如（3-13）和（3-14）：

$$PE_{(pos,2i)} = sin\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \tag{3-13}$$

$$PE_{(pos,2i+1)} = cos\left(\frac{pos}{10000^{2i/d_{\text{model}}}}\right) \tag{3-14}$$

其中 pos 为位置索引，i 是维度索引，dmodel 是嵌入向量的维度。

（3）Transformer Blocks：模型的核心部分，包含多个 Transformer 块。每个编码器层包含多头自注意力机制和前馈神经网络两个子层。多头自注意力机制用于计算输入时间序列中每个时间点元素之间的关联信息，前馈神经网络用于对输入序列进行线性变换和激活函数处理。

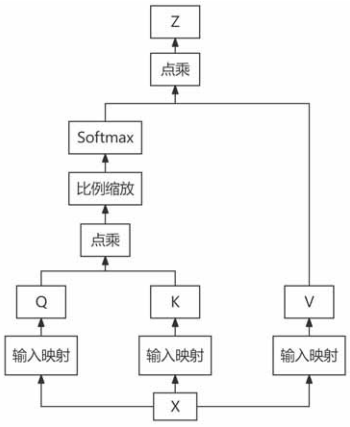



图 3-7 Transformer 自注意力计算

在 Transformer 的多头自注意力计算过程中，有三个重要的输入矩阵：查询矩阵（Q）、键矩阵（K）和值矩阵（V）。Q、K 和 V 通过对输入矩阵 X 做线性



中国知网 https://www.cnki.net

变换得到：上述矩阵等分为$(Q_1,K_1,V_1)$

$$\begin{cases} Q = XW^Q \\ K = XW^K \\ V = XW^V \end{cases} \tag{3-15}$$

假设注意力头数为 h，通过将上述矩阵等分为$(Q_1,K_1,V_1)$至$(Q_n,K_n,V_n)$，可以使模型在不同的表示子空间中并行捕获信息。

对于每个注意力头，使用点积注意力机制计算查询 Q 和键 K 之间的相似度得分，并通过 Softmax 函数归一化，从而获得每个值向量的注意力权重。计算公式为：

$$Z = Attention(Q,K,V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{3-16}$$

$$head_i = Attention\left(QW_i^Q, KW_i^K, VW_i^V\right) \tag{3-17}$$

其中 $Q$，$K$，$V$ 分别是查询（Query）、键（Key）和值（Value）向量矩阵，$d_k$ 为 $K$ 矩阵的向量维度，$W_i^Q$，$W_i^K$ 和 $W_i^V$ 是可学习的参数矩阵。

最后，将所有注意力头的输出按列拼接，并通过一个线性变换层将其维度转换回模型的嵌入维度，以便进行后续处理或生成最终输出。

$$MultiHead(Q,K,V) = \text{Concat}(head_1,...,head_h)W^O \tag{3-18}$$

Transformer 块在每个子层之间，残差连接结构是通过 Add & Norm 操作实现的。例如 Encoder 层，多头自注意力子层和前馈网络子层之间添加残差连接和层归一化。

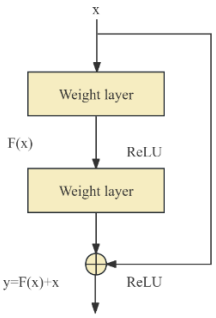



图 3-8 残差连接计算

残差连接将前一层的输出直接传递到后面的层，这使得后面的层不仅可以利用当前层的特征，还可以重用前面层的特征，使得梯度可以直接传递到更深



中国知网 https://www.cnki.net

层，从而缓解了梯度消失或爆炸的问题。残差连接的计算如公式（3-19）：

$$y = F(x) + x \tag{3-19}$$

其中 x 为残差连接的输入，$F(x)$ 为残差，y 为残差连接的输出。

残差连接后的输出进行层标准化，层标准化的步骤包括计算每个层的输入的均值和方差，标准化每个层的输入减去均值除以方差，应用缩放因子并添加偏置项，使输出在一定范围内。

$$\begin{cases} \tilde{x} = \dfrac{x - E(x)}{\sqrt{\sigma^2 + \varepsilon}} \\ y = \gamma\tilde{x} + \beta \end{cases} \tag{3-20}$$

其中，$x$ 是输入到每个层的输入，$E(x)$ 是输入的均值，$\sigma$ 是输入的方差，$\gamma$ 是缩放因子，$\beta$ 是偏置项。

Transformer 编码器的前馈全连接网络（Position-wise Feed Forward Network，简称 FFN）是编码器的核心组件，它们负责将输入序列转换为更高维度的表示。FFN 由两个线性变换组成，后跟一个 ReLU 激活函数。FFN 引入非线性，使得编码器可以学习复杂的关系。同时提取输入序列中的特征，这些特征用于计算注意力权重。FFN 可以增加模型的深度，提高模型的准确率。

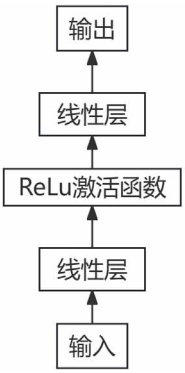



图 3-9 Transformer 编码器的前馈全连接网络

FFN 的计算公式为：

$$\mathrm{ReLU}(x) = \max(0, x) \tag{3-21}$$

$$FFN(x) = max(0, xW_1 + b_1)W_2 + b_2 \tag{3-22}$$

其中 $W$ 为前馈神经网络中线性变换的权重矩阵，$b$ 为偏置矩阵。

Transformer 编码器通过输入嵌入、位置编码、多头注意力、前馈神经网络和残差连接等组件，实现了对输入序列的编码和特征提取，最终通过线性层和



中国知网 https://www.cnki.net

softmax 函数输出编码后的结果。这些组件可以帮助模型捕捉多变量之间的相互作用和长短期依赖关系，从而更好地学习和预测多变量时序数据。

### 3.2.2 基于卷积注意力的 Transformer

一维卷积网络（Conv1D）是一种专门用于处理序列数据（如时间序列、自然语言等）的卷积神经网络结构。一维卷积网络的优点是能够很好地捕捉序列数据中的局部模式和时间依赖关系，同时保留了一定的平移不变性。相比传统的循环神经网络，一维卷积网络结构更加并行化，计算效率更高。通过局部卷积和层次特征提取，能够高效地对序列数据进行建模和处理。

在标准的 Transformer 编码器结构中，自注意力机制直接使用线性层来转换输入序列以生成 Q、K 和 V 矩阵。这种方法虽然有效，但可能不足以捕捉时间序列数据中的局部模式和依赖关系，因为它没有显式地模拟输入数据中的时间维度。对于时间序列数据的处理，每个时间点的输入向量只与其自身进行注意力计算，而没有考虑到时间序列段之间的关系。这可能导致模型在处理时间序列数据时无法捕捉到全局的依赖结构，特别是对于长期依赖关系。

因此，本文对 Transformer 编码器的结构进行改进，在 Transformer 的多头自注意力机制引入了一维卷积网络。通过引入一维卷积层来提取时间序列数据的特征，可以在一定程度上改善上述问题。一维卷积层可以捕捉输入序列的局部模式和特征，通过滑动窗口的计算，它可以有效地提取不同时间点之间的相关性。通过使用一维卷积层提取的特征，可以在计算 Q、K、V 向量时考虑到多个时间点之间的关系。

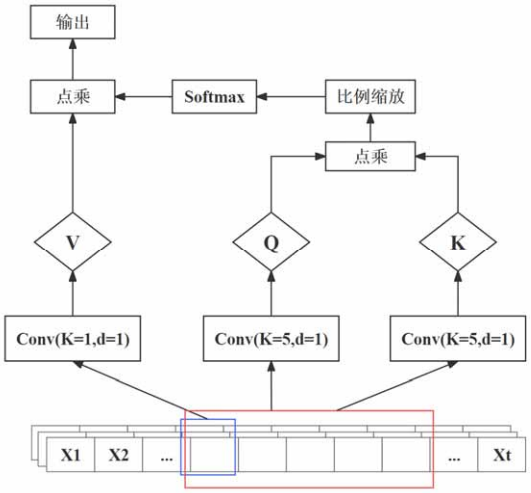



图 3-10 基于一维卷积的 Transformer 自注意力机制



中国知网 https://www.cnki.net

如图 3-10，在计算 Transformer 的多头自注意力之前，加入了一维卷积层，其作用是将输入的时间序列表示转换为Q、K、V三个向量，这三个向量将被用来计算注意力权重。具体来说，一维卷积层包含三个不同的卷积核，分别对应于Q、K、V三个向量。k为1表示卷积核的大小为1，即只考虑单个时间步长，d 为 1 表示步长为 1，即卷积核在时间序列上移动一个时间步长。V 向量对应的一维卷积层的作用是提取每个时间步长的原始特征。假设 Q 和 K 之前的一维卷积层卷积核的大小为 5，即考虑 5 个时间步长。

卷积的计算过程如公式（3-23）：

$$\begin{cases} y=\sum_{i=1}^{k} x_{i-1} w_i + b \\ Q^{'} = Conv(Q,K,d) \\ K^{'} = Conv(K,K,d) \\ V^{'} = Conv(V,1,d) \end{cases} \tag{3-23}$$

其中 $x$ 是输入序列，$w$ 是卷积核，$b$ 是偏置项，$k$ 是卷积核的大小，d 是时间步长。

这种卷积操作会在输入序列上滑动一个卷积核，并对每个时间步计算一个新的特征向量。使用一维卷积网络计算 Q、K 和 V，这些计算会将输入序列的局部依赖关系映射到不同的特征空间中，这意味着输入序列经过一维卷积处理后会得到一个新的特征向量。例如图 3-10 中，其中新的特征向量的每个时间步都与其周围的 4 个时间步相关。即实现了序列段与序列段之间的特征关系学习。

这不仅考虑了时序数据每个时间点的特征，还考虑了邻近的多个时间点数据的特征，从而捕捉时间序列的局部依赖性。

## 3.3 基于稀疏 GAT 和改进 Transformer 的异常检测模型

### 3.3.1 异常检测定义

异常检测的数据集为连续时间点采集到的 n 个节点（传感器）的数据，假设采集数据为$V=\{v_1,v_2,v_3\ldots\ldots s_t\ldots\ldots\}(v_t \in R^n)$，$v_t$表示 t 时刻采集到的 n 个传感器数据。



中国知网 https://www.cnki.net

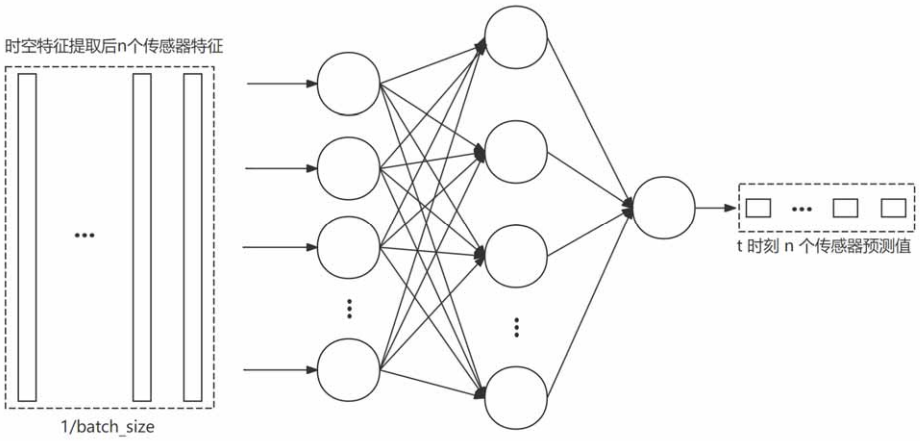



图 3-11 全连接层预测过程

将t时刻以前的k个时间步长的采集到的时序数据组成一个时间窗口，作为模型的一个输入样本 $X(t)=\{v_{t-k},v_{t-k+1},\ldots\ldots v_{t-1}\}$，模型的目标是利用时间窗的样本 $X(t)$，经过时空关联特征聚合以后，通过全连接层预测 t 时刻 n 个传感器的值，表示为 $Z(t)=\{\tilde{s}_t\}$。然后将预测值 $Z(t)$ 与时间t时采集过程中获得的实际值进行 $Y(t)=\{s_t\}$ 比较，得到时间点t的异常得分 $A(t)$。

$$E_i(t)=\left|Y_t[i]-Z_t[i]\right| \tag{3-24}$$

公式（3-24）中 $Y_t[i]$ 为t时刻第 i 个传感器的采集值，$Z_t[i]$ 为对应的预测值，$E_i(t)$ 表示第 i 个传感器预测值与实际采集值的误差。然后对误差 $E_i(t)$ 进行鲁棒归一化得到归一化后的 $a_i(t)$：

$$a_i(t)=\frac{E_i(t)-\tilde{\mu}_i}{\tilde{\sigma}_i} \tag{3-25}$$

$\tilde{\mu}_i$ 和 $\tilde{\sigma}_i$ 为一个 batch 里 $E_i(t)$ 的中位数以及 IQR（四分位数极差），使用分位数做参考，因此使用鲁棒归一化处理后的值不会受异常值影响。

使用 n 个传感器的 $E_i(t)$ 的最大值作为t时刻的异常得分 $A(t)$：

$$A(t)=\max_n a_i(t) \tag{3-26}$$

由于异常检测模型使用的训练集无异常标签，因此可使用 $A(t)$ 作为异常检测模型的系统误差。

$$y(t)=\begin{cases}1, & if\ A(t)>A_c\\ 0, & \text{otherwise}\end{cases} \tag{3-27}$$

使用网格搜索法确定异常检测阈值。在预定义的参数范围内对多个候选阈



中国知网 https://www.cnki.net

值进行穷举搜索，并通过异常检测评价指标选择最佳的阈值 $A_c$。

如果异常得分 $A(t)$ 超过设置的阈值 $A_c$，就将 t 时刻的数据标记为异常，正常和异常通过二进制标签 $y(t) \in \{0,1\}$ 区分，分别表示正常和异常状态。

### 3.3.2 异常检测模型

基于 3.1 节提出的稀疏 GAT 以及 3.2 节的卷积自注意力 Transformer 结构实现的多变量时间序列数据异常检测模型如图 3-12 所示：

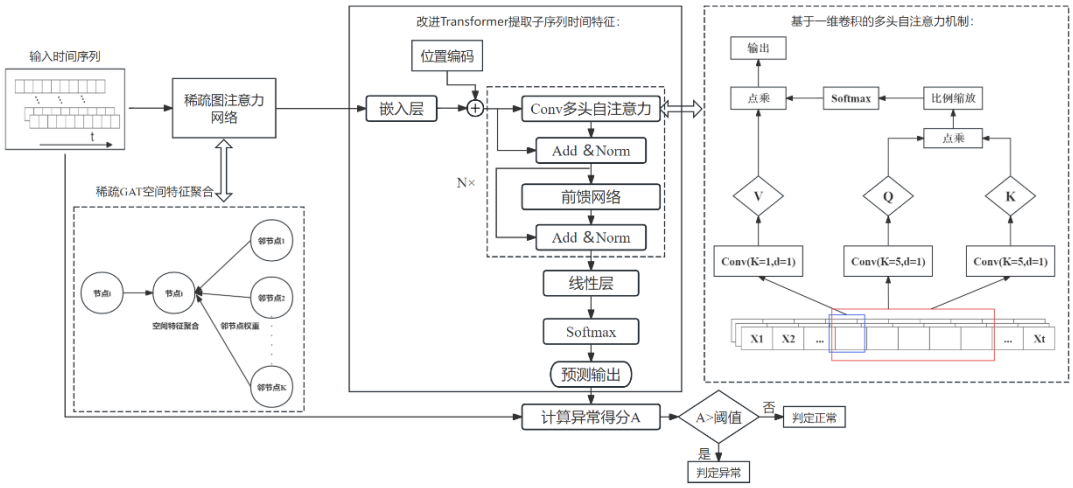



图 3-12 基于稀疏 GAT 和卷积 Transformer 的异常检测模型

该异常检测模型是为多变量时间序列数据设计的，同时考虑了时间维度与空间维度上的关联信息，以实现更精确的异常检测。

模型接收来自多个传感器的时间序列数据作为输入。首先，输入数据被送入稀疏 GAT 层。在这一层，模型通过图注意力机制学习不同传感器（节点）间的关联性。稀疏性的引入意味着模型只考虑重要的节点连接，忽略那些关联性较弱的连接，这有助于降低计算复杂度并过滤掉噪声。经过稀疏 GAT 处理后的特征被送入一个基于卷积多头自注意力机制的 Transformer 结构。模型的 Transformer 部分由 N 个编码器结构组成。改进的 Transformer 结构一维卷积层首先处理输入的时间序列特征，将单个时间点的信息扩展到包含其邻近时间点的信息，从而使得 Transformer 能够捕捉时间序列段与段之间的关联。时序数据经过稀疏 GAT 层和改进的 Transformer 结构处理后，输出是时间序列的一个综合特征表示，经过全连接层来预测每个时间点的输出值。最后进行时序数据的异常判断，模型计算预测值与真实值之间的最大残差，并将其与阈值进行比较，



中国知网 https://www.cnki.net

最终判断时间序列是否存在异常。

稀疏图注意力网络在处理多变量时间序列数据时仅关注重要的节点连接，稀疏 GAT 减少了计算资源的消耗，使模型更加高效。同时，忽略权重较小的邻居节点有助于过滤掉数据中的噪声，提高模型的鲁棒性。通过专注于关键的节点连接，稀疏 GAT 能够更好地捕捉不同传感器节点间的本质联系，提高模型在未见数据上的表现。

传统 Transformer 关注点与点之间的关联，可能忽略了时间序列的连续性和整体性，而卷积处理进行多时间点的特征聚合，使得 Transformer 模型更适合处理时间序列数据。基于卷积自注意力的 Transformer 在处理时间序列数据首先通过一维卷积层的处理，卷积层通过聚合多个时间点的数据到单个时间点的特征上，能够增强时间序列中的局部特征，学习时间段与时间段之间的特征关联性，这有助于捕捉到更复杂的时间序列动态。

综上，这种结合了稀疏 GAT 和基于卷积注意力的 Transformer 的多变量时间序列异常检测模型，通过有效整合时间和空间维度的关联信息，为复杂环境下的多变量时序数据异常检测提供了一种有效的解决方案。

### 3.3.3 评价指标

在异常检测领域，精度（Precision）、召回率（Recall）和 F1 分数（F1-score）是评价模型效果的标准性能指标。

精度是指模型的预测的正例中有多少是真正的异常。精度越高，表示模型在预测为正例的情况下更加可靠。其中 TP 是正确预测为正例的样本数量，表示真正的异常样本（True Positives），FP 表示错误地将正常样本预测为异常样本（False Positives）。

$$precision = \frac{TP}{TP + FP} \tag{3-28}$$

召回率是指模型在所有实际正例中成功预测为正例的比例，即模型成功捕获异常样本的比例。其中 FN 表示错误地将异常样本预测为正常样本（False Negatives）。

$$recall = \frac{TP}{TP + FN} \tag{3-29}$$

$$F1\ score = \frac{2 * precision * recall}{precision + recall} \tag{3-30}$$



中国知网 https://www.cnki.net

F1 分数是精度和召回率的调和平均数，综合考虑了模型的精准性和全面性。它能够综合考虑模型在正负样本上的性能表现。

## 3.4 异常检测实验

### 3.4.1 数据集及预处理

为了验证本文提出的稀疏 GAT 与改进 Transformer 结构的异常检测模型在时间序列分析中的有效性，采用了 SWaT（the secure water treatment）安全水处理数据集。该数据集源于工业生产领域，展示了一个大规模现代化水处理设备的运作过程。作为关键基础设施的典型示例，SWaT 系统包括六个子流程：原水供应与储存、预处理阶段、超滤及反冲洗、脱氯阶段、反渗透和清洗阶段，系统测试场景如图 3-13 所示。研究团队在 SWaT 平台上进行了为期 11 天的连续监测，记录了传感器和执行器的读数变化。系统正常运行的数据记录持续 7 天，而剩余 4 天则记录了系统面临 36 种不同模拟攻击的情况，数据的采集频率为每秒一次[53]。该数据集适用于工业设备时序数据异常检测研究。



图 3-13 SWAT 平台实物

结合实验环境考虑，为了降低数据集的大小并提高模型的训练效率，本文对原始数据集进行了下采样：将原始数据集中每秒钟采样的数据进行分组，每组包含 10 个数据点。对每组数据中的每个传感器，计算其 10 个数据点的中位数作为该传感器该时刻的数据。对每组数据中的系统状态标签（异常或正常），计算其 10 个标签的众数作为下采样后对应时刻的系统状态标签。这种下采样方法可以有效地降低数据集的大小，同时保留大部分重要的信息。



中国知网 https://www.cnki.net

表 3-1 采样后的 SWaT 数据集

| 数据集 | 训练样本 | 测试样本 | 特征总数 | 异常比例 |
|---|---|---|---|---|
| SWaT | 47340 | 44991 | 51 | 11.97% |

针对数据集中的缺失传感器数据，可根据其类型和特征采用不同的处理方法。主要可分为三种情况。对于连续值变量，如果部分时间戳缺失数值，可以用未缺失部分的均值来填充。对于离散值变量，如果缺失值限定有限的个数，用前一个相邻的观测值来填充缺失部分。对于某些变量全部缺失或全部为 0，说明该变量可能与其他变量无关，此时直接删除整列该变量。

由于 GAT 和 Transformer 等模型通常包含大量的线性变换和非线性激活函数，这些操作对输入数据的尺度非常敏感。因此进行多变量时序数据异常检测之前，对数据进行最大最小归一化（Min-Max Normalization）。在一些深度学习框架中，如 TensorFlow 和 PyTorch，最大最小归一化的实现也更为简单和直观。这使得在实际工程应用中更容易进行数据处理，减少了归一化步骤的复杂性。

给定一个连续特征向量 X 为[X1,X2,…,Xn]，最大-最小归一化通过以下线性变换将其映射到区间 [0, 1]：

$$X_{\text{normalized}} = \frac{X - \min(X)}{\max(X) - \min(X)} \tag{3-31}$$

其中，$\min(X)$ 是特征向量中的最小值，$\max(X)$ 是特征向量中的最大值。这一变换确保了所有特征值都落在 [0, 1] 的范围内，应用上述公式对采样后的 SWaT 数据集进行处理。

### 3.4.2 实验环境与模型参数

使用稀疏 GAT 和卷积自注意力 Transformer 组成的模型进行多变量时序数据异常检测，实验环境基于一台个人计算机，具体的硬件配置为：AMD Ryzen 7 5800H with Radeon Graphics，3.20 GHz，16G 内存和 512GB 固态硬盘，受限于硬件条件只使用 CPU 进行训练。本文中所有的实验是在 Windows 下进行的，操作系统为 Win10 22H2 版本，使用 python 开发语言，开发环境为 PyCharm 和 Anaconda3。由于涉及了深度学习的开发，使用 PyTorch 框架搭建异常检测模型。

训练集和测试集的时间序列样本数分别为 47340 和 44991，训练集为正常数据学习正常数据模式，测试集带有异常标签。每个时间点包括 51 个传感器的值，训练集和验证集的划分参数设置为 0.9。防止过拟合，设置全连接层层数为 1，



中国知网 https://www.cnki.net

维度为 128。模型训练使用 AdamW 优化器，它是 Adam 优化器的一种变体，引入了权重衰减的概念，用于惩罚模型中的参数，防止过拟合。为了模型能够准确地预测目标变量的值，并尽量使预测值与真实值之间的误差最小化，使用均方误差损失函数（MSELoss）。

训练模型时 epochs（迭代次数）设置为 100，使用早停法当模型在验证集效果没有提升时停止训练， batchsize（批次大小）为 64 或 128，学习率为 0.00001，Transformer 部分的深度 depth 设置为 2 到 5，注意力头数 header 为 6，一维卷积层的卷积核大小 kernel_size 设置为 7。时间窗口大小（windowsize）的选取决定了模型能够观察的历史时间步长，由于缺乏先验知识，根据多次实验结果确定为 30。

### 3.4.3 实验结果分析

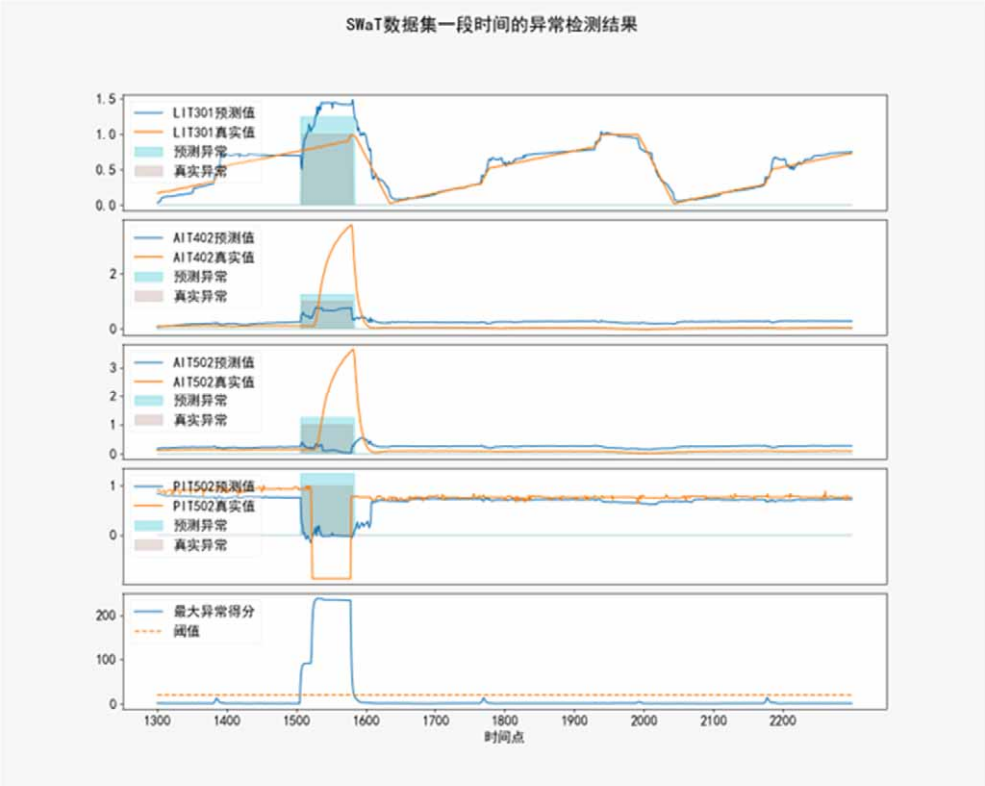



图 3-14 SWaT 测试集在 1000 个时间点内的异常检测图

图 3-14 为测试集在模型训练完成后，在测试集第 1300 个到 2300 个时间点的异常检测效果图，每个时间点实际间隔为 10 秒。图中列举了 LIT301，AIT402，AIT502 和 PIT502 四个传感器的预测值与真实值曲线对比，这段时间内模型预测的数据异常与测试集数据中的真实异常数据使用不同颜色的阴影区



中国知网 https://www.cnki.net

分，为了便于观察，将预测异常的高度设置为真实异常的 1.25 倍。

从图中可以分析得出，真实的数据异常主要集中在[1500,1600]的区间内，在[1500,1600]时间段，基于稀疏GAT和卷积注意力的Transformer模型对LIT301，AIT402，AIT502 和 PIT502 这四个特征的预测值与真实值具有很大的误差，而在其他时间点的预测值与真实值实现了良好的拟合效果，根据所有特征预测值与真实值计算的异常分数与阈值的比较结果，最终模型判断的真实异常和预测异常在该区间重合度较高，证明本文提出的模型对于多变量时序数据实现了良好的异常检测效果。

在实现稀疏图注意力机制时，只需要聚合权重系数较大的 Top k 个邻居特征，由于数据集共有51个传感器节点，因此在Transformer模型的depth、header和kernel_size分别设置为2，6和5时，分别测试对每个传感器聚合 10，20，30 和 40 个邻居节点时最终的异常检测结果。

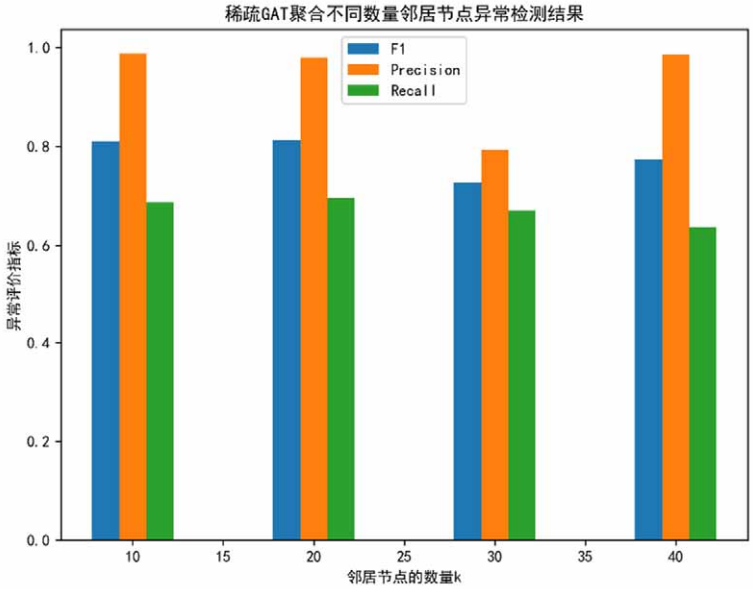



图 3-15 稀疏 GAT 聚合不同数量邻居节点的异常检测性能

从图 3-15 可以观察到设置不同聚合邻居节点数量 k 时的异常检测指标（F1 分数、精确率和召回率）的变化情况。聚合 20 个邻居节点时获得了最高的 F1 分数，达到了 0.81，召回率为 0.70，均为最大值，F1 分数被认为是一个更全面和平衡的评估指标，因此可以认为 k=20 时实现了更好的异常检测效果。

当聚合较少的邻居节点时（如 10 个），可能无法捕捉到足够的信息来准确地描述传感器节点之间的关系。聚合过多的邻居节点（如 30 个或 40 个）可能会引入更多的无关信息。而聚合 20 个邻居节点时，可以保持一定的信息丰富性，



中国知网 https://www.cnki.net

同时减少噪声的影响，提高模型预测精度从而获得最好的异常检测效果。

K=20 时，以传感器节点 0 为例，根据模型从稀疏图注意力层保存的节点之间的注意力权重矩阵，绘制有向图并添加 51 个传感器节点，得到的有向图为图 3-16。

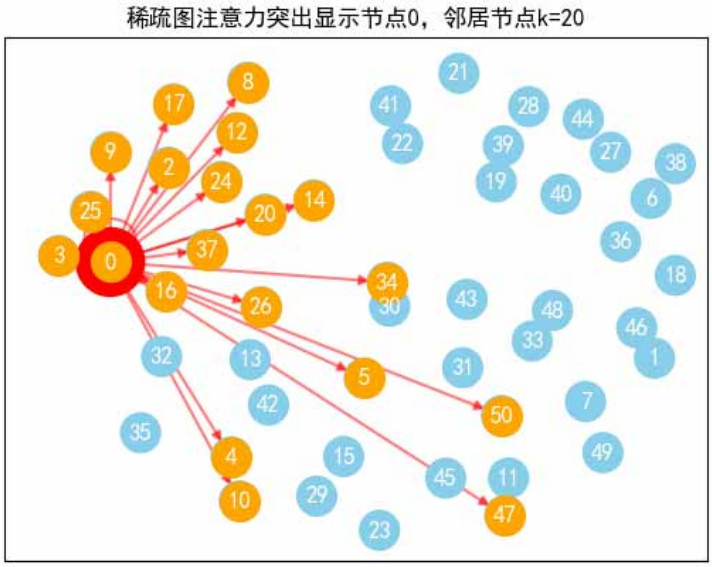



图 3-16 稀疏 GAT 选取 20 个邻居节点时生成的图结构

突出显示节点 0，20 个橙色的邻居节点特征聚合到节点 0，邻居节点包括节点 0 自身，图中显示为红色。节点 0 到节点 50 对应 SWaT 数据集的 51 个传感器，数据集传感器型号对应的解释见表 3-2：

表 3-2 数据集传感器型号对应的解释

| 传感器型号 | 解释 |
|---|---|
| FITs | 电磁流量计 |
| LITs | 超声波液位传感器 |
| MVs | 水流动阀门 |
| Ps | 化学计量泵 |
| AITs | 化学传感器 |
| PITs | 压力传感器 |
| DPITs | 差压变送器 |
| UV | 脱氯流程阀门 |



中国知网 https://www.cnki.net

节点 0 即为 FIT101 传感器，其中 FIT 代表型号，101 代表安全水处理第一个流程中的第一个电磁流量计。以节点 0 即 FIT101 传感器为例，其他邻居节点与 FIT101 的注意力系数，从大到小排列为图 3-17。

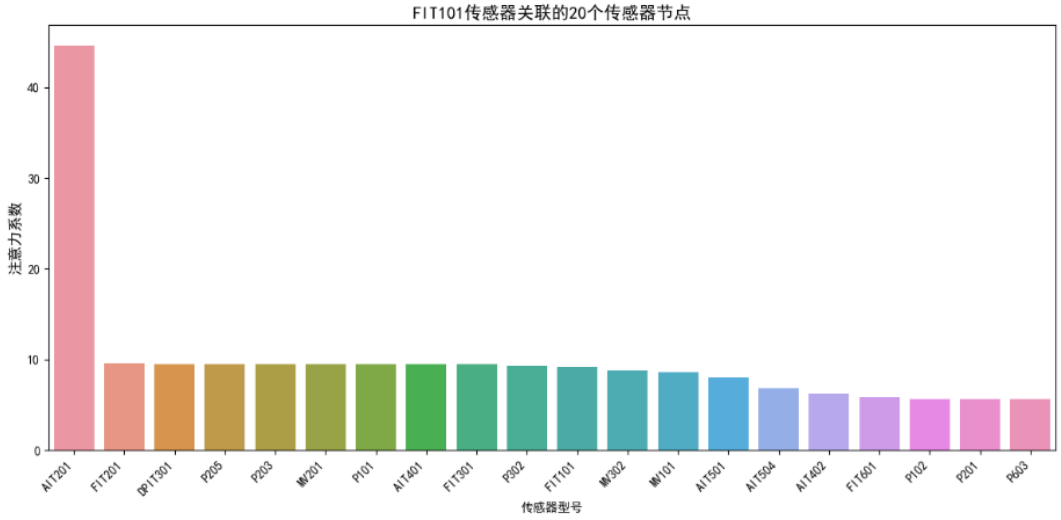



图 3-17 FIT101 传感器的 20 个邻居节点注意力系数

图 3-17 表明在稀疏的 GAT 模型中，这 20 个传感器对 FIT101 的影响比其他节点更重要，如 AIT201，FIT201，DPIT301 和 P205 传感器等，并将这些传感器特征聚合到 FIT101。同理，其他传感器特征也聚合了对应的关联传感器特征。

对上述图注意力实验结果进行分析，多传感器数据通常包含来自不同位置和传感器类型的信息，在缺乏具体的物理联系和先验知识的情况下，通过使用图注意力进行空间特征聚合，可以将不同传感器之间的潜在关联信息整合到单个传感器的特征表示中，填补不同传感器之间的信息缺失，并提供更全面和丰富的特征表示。

但是从图 3-13 实验结果可以看出，当 k=30 和 40 时，将过多的可能是冗余或不相关的传感器特征进行聚合反而造成了模型预测精度下降从而异常检测效果变差，由此证明本文提出的稀疏图注意力网络是合理的，通过选择合适数量的 20 个邻居节点的特征进行聚合，增强了整个模型对多变量时序数据的预测能力。

对于卷积自注意力 Transformer 部分的参数选取，待优化的参数主要由 Transformer 的注意力头数、深度和一维卷积的卷积核大小等。稀疏图注意力邻居节点数设置为 20，Transformer 编码器的深度 depth 分别设置为 2，3，4 和 5 时，时间窗口设置为 30，batch_size 为 128，卷积核大小设置为 7 时，对 SWaT 数据集进行实验最终的异常检测结果如图 3-18。



中国知网 https://www.cnki.net

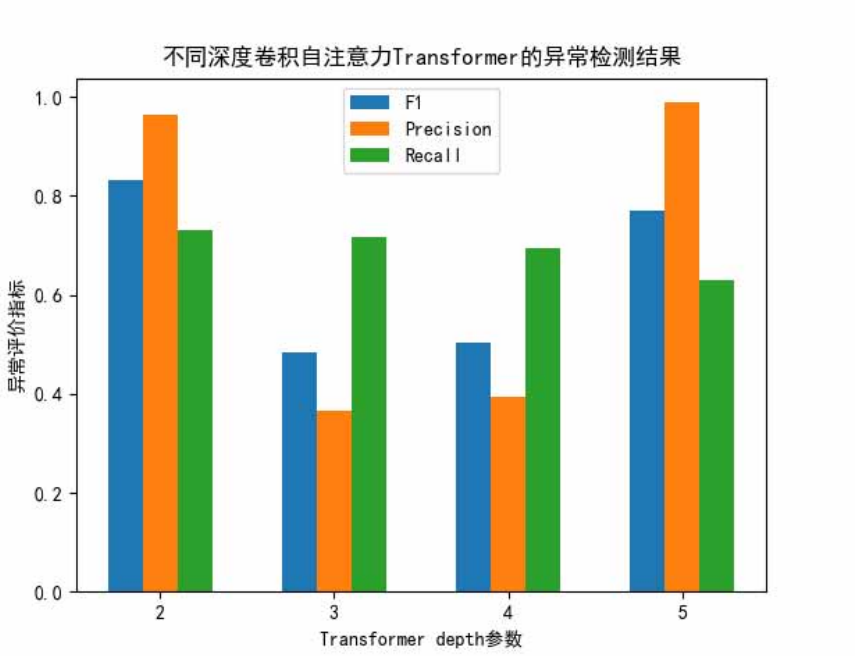



图 3-18 Transformer 设置不同深度时异常检测性能

从图 3-18 可以看出在设置不同的深度值时，深度较大时异常检测性能不够理想，在深度等于 2 时模型达到最佳的异常检测效果。对于该数据集，数据集的特点和异常模式可能与较低深度的模型更加匹配，较低的深度值如 2 更适合捕捉该数据集中的简单、局部特征。当深度增加导致过度拟合，捕捉到数据中的噪声或无关特征，另一方面较高的深度值可能需要更多的训练样本来学习数据中的复杂模式和异常，因此降低了异常检测的准确性。

### 3.4.4 模型对比

在稀疏图注意力层选择的邻居节点数 k=20 时，并且基于卷积自注意力的 Transformer 模型的 depth、header 和 kernel_size 分别设置为 2，6 和 7 时，时间窗口大小取 30 时，本文提出的模型在 SWaT 数据集取得了最好的异常检测效果，Precision、Recall 和 F1 分数分别达到了 0.9640、0.7315 和 0.8318。与其他几种优秀的基线方法，包括 LSTM-NDT、MTAD-GAT、GDN、CAE-M、TranAD、DWGAT 和 TSAD，在 SWaT 数据集进行时序数据异常检测结果对比，评价指标包括 Precision、Recall 和 F1，如表 3-3 所示。



中国知网 https://www.cnki.net

表 3-3 本文模型与其他基线方法在 SWaT 上的性能比较

| 异常检测模型 | Precision | Recall | F1 |
|---|---|---|---|
| LSTM-NDT[31] | 77.78 | 51.09 | 0.62 |
| MTAD-GAT[32] | 97.18 | 69.57 | 0.81 |
| GDN[33] | **99.35** | 68.12 | 0.80 |
| CAE-M[34] | 96.97 | 69.57 | 0.81 |
| TranAD[35] | 96.51 | 0.6570 | 0.78 |
| TGAD[36] | 97.64 | 69.97 | 0.81 |
| DWGAT[37] | 95.88 | 71.86 | 0.82 |
| TSAD[38] | 98.22 | 68.78 | 0.81 |
| 本文 | 97.40 | **73.15** | **0.83** |

从表 3-3 的实验结果可以分析得出，对比其他八种先进的基线方法，本文提出的基于稀疏 GAT 和卷积注意力 Transformer 的异常检测模型在召回率和 F1 两个指标都取得了最高分数，在召回率上比第二名高出 1.29%，在 F1-score 上高出 1%，表明模型在识别异常的能力和综合性能方面都优于其他方法。精度指标反映的是模型的误报情况，召回率反映的是漏报情况，在设备实际应用场景中，精度相比召回率和 F1 分数来说相对不够重要，因此本文提出的异常检测模型对于设备时序数据异常检测具有较好的应用价值。

## 3.5 本章小结

对于工业设备的多传感器时序数据异常检测问题，本章提出了基于时空关联性的设备时序数据异常检测模型。在原有图注意力神经网络（GAT）基础上，对其进行改进添加稀疏性，使用稀疏 GAT 进行多传感器变量间的空间特征聚合。使用一维卷积计算改进 Transformer 的多头自注意力，实现时序数据时间特征聚合。使用稀疏 GAT 和卷积自注意力 Transformer 模型，在公开数据集 SWaT 进行异常检测实验，并与多个先进异常检测模型对比，证明本文提出模型的有效性。



中国知网 https://www.cnki.net

# 第四章 设备物联网平台设计

## 4.1 平台需求分析

本文物联网平台来源于某研磨机企业以及石油压裂装备企业的设备物联网需求，实现对工业设备及传感器数据的监测和部分业务的智能管理系统，在此基础上扩展功能成为一个面向多领域的通用物联网应用平台。

平台的设计目标是为物联网应用提供一个可扩展、灵活且可靠的平台，以实现设备管理、数据接入、存储和分析、可视化和仪表板、规则引擎和自动化、告警和通知、安全性和权限管理等功能。具体的设计目标如下：

（1）数据存储和数据处理

物联网平台需要保存较多类型的数据，包括管理员和各级用户信息，接入设备基本信息，以及接入设备的历史数据存储，为后台管理人员提供快速检索和分析功能。可以通过规则引擎进行数据过滤，只处理满足特定条件的数据。提供数据转换功能，可以对设备传输的原始数据进行处理和转换。

（2）设备接入和管理

支持各种协议的物联网设备接入和管理，包括 TCP，MQTT，HTTP，COAP 等常见协议；提供设备注册机制，确保每个设备都有唯一标识，并能够安全地接入平台；设备可以分配给对应的用户，确保只有授权用户能够访问相关设备和数据。

（3）数据可视化

支持多种数据源，包括网关、设备和 API 等，通过各种可视化图表形式例如折线图、柱状图和饼图等形式对实时数据和历史数据进行展示，提供地图组件。提供灵活的可视化仪表板以及自定义布局选项，方便用户自定义展示关键数据，以适应不同用户的个性化需求。

（4）事件和报警管理

提供事件和报警功能，使用户能够有效地监控设备状态并及时采取行动。用户可以配置事件触发条件，例如设备数据超过或低于某个阈值、设备断线等。用户可以定义报警规则，设置报警触发的条件和阈值。允许配置多个报警级别，以区分不同紧急程度的报警，支持报警确认和清除功能，并通过邮件和其他推送方式通知用户。



中国知网 https://www.cnki.net

（5）可扩展性和集成功能

具备卓越的可扩展性和集成功能，为用户提供丰富的工具和接口，以适应不同的 IoT 应用场景。引入插件系统，使用户能够轻松地扩展平台的功能。通过开发自定义插件，用户可以引入新的特性、数据处理逻辑以及可视化组件，方便用户实现更高度定制化的物联网解决方案。提供丰富的 API，允许用户通过 API 与平台进行交互。为用户提供在平台上执行各种操作、获取数据以及实现自动化集成的机会。支持与外部系统的集成，包括通过 REST API、MQTT 等方式。能够与其他业务系统、数据存储系统等进行无缝连接，实现信息的双向传递。

### 4.1.1 功能性需求分析

系统的功能性需求分为以下方面：

（1）设备管理功能：支持设备注册和管理，包括设备的添加、删除、编辑和状态监控。提供设备分组和标签功能，便于对设备进行分类和组织。

（2）数据接入和传输功能：支持多种通信协议，如 HTTP、MQTT、COAP 等，以接收设备数据。提供数据传输的安全机制，如加密和身份验证。

（3）数据存储和查询功能：提供可靠的数据存储机制，将设备数据存储到数据库中。支持数据的历史记录和查询，以便用户对设备数据进行分析和检索。

（4）提供可视化的仪表板，展示设备数据的实时状态和历史趋势。支持自定义仪表板和图表，以满足用户对数据可视化的需求。

（5）规则引擎和自动化功能：提供规则引擎，用于实时数据处理和触发自动化操作。支持基于设备属性和数据的条件触发器，执行相应的规则操作。

（6）告警和通知功能：支持告警规则的定义和触发，以监测设备状态和数据异常。提供通知机制，向用户发送告警通知和警报信息。

（7）安全性和权限管理功能：支持用户身份验证和访问控制，确保只有授权用户可以访问设备数据。

### 4.1.2 非功能性需求分析

（1）性能需求：平台需要具备处理大规模数据的能力，以应对高并发的数据传输和处理需求。数据存储和检索性能需要高效，确保实时性和响应性。

（2）可扩展性需求：平台需要支持根据需求扩展设备类型、传感器和数



中国知网 https://www.cnki.net

据处理算法，以适应未来的业务扩展。平台需要具备可扩展的架构和接口，方便集成其他系统和服务。

（3）系统需要具备高可用性，确保平台连续运行和数据的可靠性。平台需要具备故障恢复和容错机制，以应对可能的故障情况。同时需要具备监控和日志记录功能，以便及时发现和解决问题。

## 4.2 平台相关技术

### 4.2.1 Web 开发技术

在整个物联网平台中，前端是用户与平台之间的桥梁，负责实现用户与设备之间的交互、数据可视化和物联网相关功能的管理。提供了用户与物联网设备之间的交互界面。通过前端界面，用户可以轻松地管理和控制物联网设备，例如注册新设备、配置设备参数、发送指令和接收设备状态。这种交互性使用户能够与设备进行实时的双向通信，实现对设备的远程监控和控制。

平台使用 Angular 作为主要的前端框架。Angular 是由 Google 开发的一套完整的 JavaScript 框架，用于构建现代化的单页面应用程序。它采用了组件化的开发模式，将应用程序划分为多个可复用的组件，并通过数据绑定和依赖注入等机制实现组件之间的通信和交互。Angular 还提供了丰富的工具和库，用于处理路由、表单验证、HTTP 请求等常见的前端任务。前端是一个单页面应用，也称为 SPA。在 SPA 中，整个应用程序的代码和资源在首次加载后被下载到客户端，之后的页面切换和数据交互通过 AJAX 和前端路由等技术实现，无需每次都重新加载整个页面。通过在一个页面中动态加载内容和更新页面状态，实现了更快速、流畅的用户体验。使用 Webpack 作为模块打包工具，Webpack 是一个现代化的 JavaScript 应用程序静态模块打包工具，它可以将前端应用程序中的各种资源（如 JavaScript、CSS、图片等）打包成静态文件，提供代码分割、模块化管理、资源优化等功能，使得前端开发更加高效和灵活。

WebSocket 作为前端与后端的实时通信协议。WebSocket 是一种全双工、双向通信协议，可以在浏览器和服务器之间建立持久的连接，实现实时数据的传输和更新，例如接收传感器数据、发送指令和获取实时更新等。它允许服务器推送实时数据到前端应用，无论是浏览器还是移动应用。这对于监控和控制物联网设备至关重要，因为它减少了轮询服务器的需要，从而降低了延迟和带宽消耗。



中国知网 https://www.cnki.net

后端开发使用 JAVA 语言，使得平台能够构建可靠、高性能的后端服务。Spring Boot 作为主要的开发框架，其提供了自动化配置和约定优于配置的原则，使得开发者可以快速搭建和部署应用程序。使用 Maven 作为构建工具，它提供了依赖管理、项目构建和部署的功能，可以帮助开发人员轻松地管理项目的依赖库。

### 4.2.2 数据库

平台使用混合数据库策略，使用关系型数据库（PostgreSQL）和非关系性数据库（Cassandra）来存储物联网平台的大量数据。

PostgreSQL 作为一个完全免费且开源的关系型数据库管理系统（RDBMS），已经被广泛使用并在多个生产环境中得到验证，具有出色的稳定性和可靠性。PostgreSQL 支持高级查询语言（如 SQL）和复杂数据类型（如 JSON、数组等），可以处理复杂的数据分析和查询需求，同时具有可扩展的架构，可以通过插件和扩展模块来增加额外的功能和特性，以适应特定的物联网平台需求。PostgreSQL 作为主数据库，存储和管理平台的结构化数据。

（1）配置数据：包括平台的系统配置信息，如租户、用户等。这些配置信息具有关系性，适合存储在关系型数据库 Postgres 中。

（2）元数据（Metadata）：包括设备、资产、规则等实体的元数据信息，例如设备的名称、描述、所属租户等属性。具有一定的结构性和关联性,适合存储在 Postgres 数据库中。

（3）关联关系数据：包括实体之间的关联关系，如设备与资产、设备与规则等，需要依赖关系型数据库的事务特性，也存储在 Postgres 中。

（4）审计日志：包括用户操作、系统事件等审计日志信息。

Cassandra 是一个高度可扩展、分布式的开源 NoSQL 数据库系统。它被设计用于处理大规模数据集，具有高性能、高可用性和容错性的特点。Cassandra 采用分布式架构，数据可以在多个节点上进行复制和分片，从而实现数据的高吞吐量和低延迟访问。时序数据是按时间顺序排列的数据流，例如传感器的实时测量值、设备的事件记录等。由于物联网应用通常涉及大量的设备和实时数据流，因此需要一个高性能的数据库来存储和管理这些时序数据。在本文提出的物联网平台中，Cassandra 被用作时序数据库，用于存储物联网设备生成的时间序列数据。在本文提出的物联网平台中，启用 PostgreSQL 和 Cassandra 混合模式后，Cassandra 只存储和时序数据相关的三张表。具体来说，Cassandra 数



中国知网 https://www.cnki.net

据库保存以下类型的数据：

（1）设备遥测数据（Telemetry Data）：包括设备周期性上报的各种传感器数据，如温度、湿度、电压等。这类数据具有时间戳，需要高效的时间序列查询支持，非常适合使用 Cassandra 这种 NoSQL 数据库。

（2）设备属性数据（Device Attributes）：包括设备的静态配置信息，如设备型号、固件版本、地理位置等。属性数据也具有时间序列特性，需要高效的时间维度查询，适合存储在 Cassandra 中。

（3）设备事件数据（Device Events）：包括设备产生的各类事件，如设备上线/下线和故障告警等。事件数据也属于时间序列数据，存储在 Cassandra 中。

通过使用 Cassandra 存储这些时间序列数据，平台可以提供高性能的数据查询和分析能力，满足物联网场景下海量设备数据的管理需求。而 Postgres 则用于存储一些关系型的配置数据和元数据。这种混合数据库策略发挥了两种数据库各自的优势，为平台提供了强大的数据存储和查询能力。

### 4.2.3 设备通信协议

消息队列遥测传输（MQTT）是一种极其轻量级的机器对机器数据协议[54]。MQTT 特别适合物联网应用，因为该协议支持资源有限的应用，例如低带宽，低计算能力，低内存，电池等物联网常见应用环境。MQTT 协议运行在 TCP/IP 连接上，可以在有线（以太网）和无线局域网等各种网络上实现。

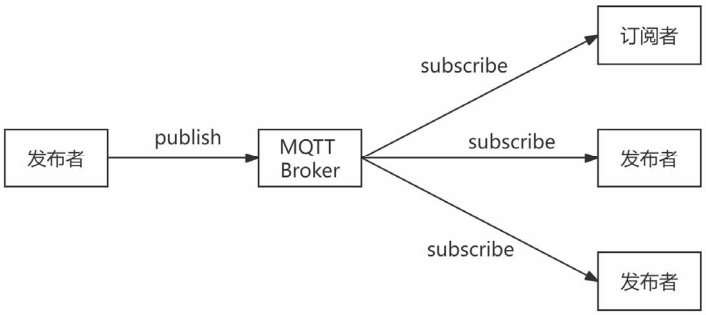



图 4-1 MOTT 发布/订阅机制

如图 4-1，本质上 MQTT 使用发布/订阅（Publish/Subscribe）消息传递机制，它由代理（Broker）和客户端（Client）组成。 MQTT Broker 通常是运行在云端或互联网上的服务器，负责存储基于不同主题（Topic）的发布数据，并将消息发布给合法的订阅者。MQTT 客户端可以是任意硬件、软件或硬件和软件的组合，MQTT 客户端连接到代理才能交换数据。当连接的设备或客户端从代理



中国知网 https://www.cnki.net

（服务器）下载数据时，该过程称为订阅，并且该特定客户端称为订阅者。另一方面，当连接的设备向服务器发送数据时，Client 称为发布者（Publisher）。因此，发布和订阅机制是 MQTT 协议的基础。值得注意的是，一个 Broker 可以为多个订阅者和发布者提供服务，具体取决于运行 Broker 的机器的功能。客户端也可以充当发布者和订阅者。当客户端发布数据时，它会为数据分配一个特定的主题，每个主题之间用正斜杠分隔。

Netty 是一个高性能的异步事件驱动的网络应用程序框架，提供了基于事件驱动的异步网络编程模型，可以轻松处理大量并发连接，并提供了高度可扩展性和性能优化。通过使用 Netty，平台能够处理设备和后端之间的实时双向通信，包括接收设备发送的数据、向设备发送指令以及处理设备注册和认证等操作。

平台使用 Netty 实现了对多种协议的支持，MQTT、COAP（受限应用协议）和 HTTP（超文本传输协议）等以满足不同类型设备的通信需求。每种协议都有相应的解析器和处理器，以确保协议消息的正确解析和处理。Netty 提供了高性能的通信通道，使得多个设备或客户端可以同时连接和通信，同时能够方便地扩展和定制协议支持，以满足不同应用场景的需求。

### 4.2.4 数据流通道

物联网平台为了方便连接、管理和分析物联网设备数据，数据流通道是一个关键的设计组件，用于处理设备数据的流动和传输。整个数据流通道由设备层、网关层、传输层到服务端传输层、平台核心服务以及与外部系统的集成等多个关键部分组成，如图 4-2 所示。

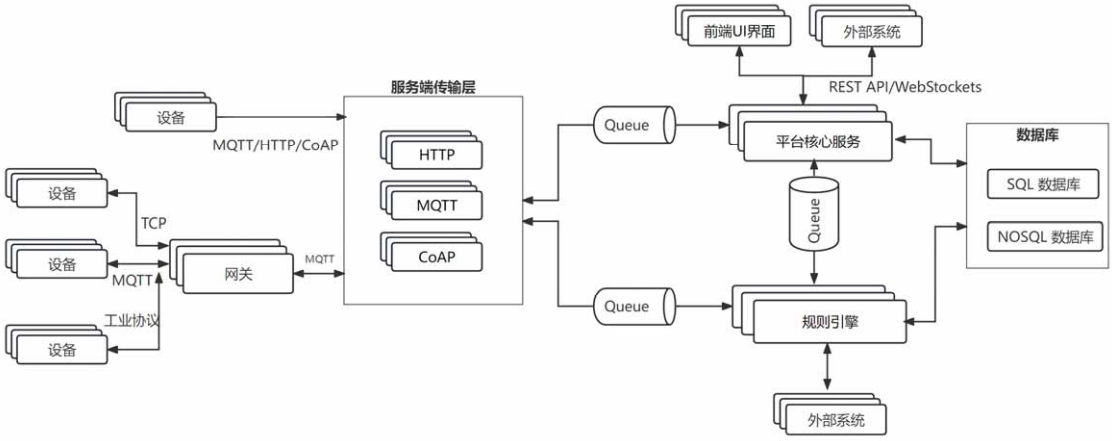



图 4-2 物联网云平台数据流通道设计

设备层包含了各种类型的物联网设备，包括传感器和执行器等，是数据产



中国知网 https://www.cnki.net

生的源头。网关设备连接物联网设备和平台，扮演数据传输的中间枢纽角色。传输层使用 MQTT、HTTP 和 CoAP 等常见物联网通信协议，实现设备与平台之间的数据传输。服务端传输层中，队列模块用于缓存和排队设备上报的数据，确保数据传输的可靠性，规则引擎模块可对数据进行实时处理和分析，触发相应的业务逻辑。平台核心服务负责设备管理、数据存储和数据分析等关键功能，并通过 REST API 和 WebSockets 等方式向外部系统提供数据访问能力。外部系统包括数据库、云服务等与平台进行集成和交互，实现对物联网数据的持久化存储、分析挖掘等高级应用场景。

### 4.2.5 高并发技术

平台使用 Akka 作为底层框架和运行时环境，以实现 Actor 模型的并发处理和消息通信。Actor 是一种轻量的并发计算模型，用于构建可扩展、高性能的并发系统。它可以看作是 CPU 的时间片并且每个 Actor 总是在单线程下执行，根据经验和测试，通常情况下，1GB 内存可以容纳数百万个较小的 Actor。Actor 之间通过消息进行通信，每个 Actor 具有自己的状态和行为，它们是相互隔离的，这种隔离性可以避免并发冲突和数据竞争问题，并且可以通过接收和处理消息来改变其状态和执行相应的操作。

每个设备、用户或事件在物联网平台里都被建模为一个独立的 Actor。这些 Actor 可以并行地处理来自不同设备或用户的请求和消息。通过将并发任务分配给不同的 Actor，可以实现系统的高并发处理能力。Actors 之间通过消息进行通信，消息是异步发送和接收的，不需要等待对方的响应。这种异步通信机制可以提高系统的响应速度和吞吐量。同时，Actor 之间可以形成层级结构，其中一些 Actor 可以监督其他 Actor 的行为。当子 Actor 发生异常或错误时，监督者 Actor 可以采取相应的故障处理和恢复策略，保证系统的可靠性和容错性。

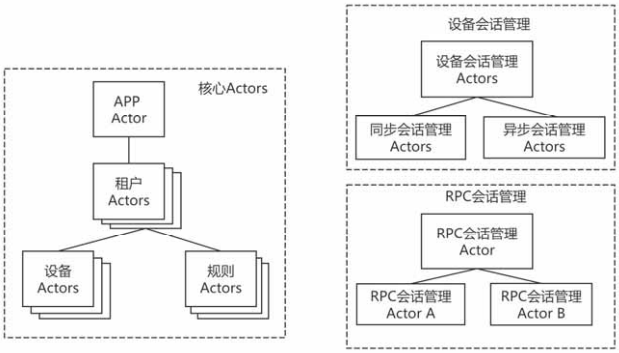



图 4-3 物联网平台 Actor 体系架构



中国知网 https://www.cnki.net

本文物联网平台 Actor 体系架构的设计思想是将复杂的任务分解成多个小的、独立的单元，每个单元都由一个单独的 actor 来处理，这种设计方式使得系统更易于扩展和维护。主要有以下三种类型的 Actor：

（1）核心 Actors：包括 App Actor、租户 Actor、设备 Actor、规则链 Actor 和规则节点 Actor。App Actor 负责处理应用程序相关的功能，例如处理用户请求、管理用户会话、执行应用程序逻辑等。租户 Actor 负责处理租户相关的功能，例如管理租户的设备、规则链等。设备 Actor：负责管理设备相关的功能，包括设备连接、数据处理和与设备通信。规则链 Actor 负责执行规则链中的规则节点，处理设备数据、生成事件和执行命令等。规则节点 Actor 负责执行规则链中的单个规则节点逻辑。

（2）设备会话管理 Actors：包括 Session Manager Actor、Sync Session Actor A 和 Async Session Actor B。Session Manager Actor 负责管理设备与服务器之间的连接会话。它跟踪设备连接的状态、处理设备的连接和断开连接请求，并将连接的设备分配给相应的设备 Actor 进行处理。Sync Session Actor A 负责同步处理设备会话，例如设备的状态同步、数据传输等。Async Session Actor B 负责异步处理设备会话，例如设备的命令执行、事件生成等。

（3）RPC 会话管理 Actors：包括 RPC Sessions Manager Actor、RPC Session Actor A 和 RPC Session Actor B。这些 actor 负责管理设备与服务器之间的数据传输。RPC Sessions Manager Actor 负责管理设备与服务器之间的 RPC（远程过程调用）会话。它管理 RPC 会话的状态、处理 RPC 请求和响应，并将它们分配给相应的 RPC Session Actor 进行处理。RPC Session Actor A 负责处理同步的 RPC 请求和响应，确保它们按照顺序进行处理和传输。RPC Session Actor B 负责处理异步的 RPC 请求和响应，允许并发处理多个 RPC 请求和响应。

这种设计方式使得平台能够实现高并发支持、异步消息传递和可靠的设备管理与通信，并保持稳定运行，同时物联网平台能够很容易地扩展，以支持更多的设备和功能。

## 4.3 系统总体架构设计

图 4-4 为本文提出的系统总体架构图。整个系统被划分为三层，包括感知层、边缘层和云端服务层。



中国知网 https://www.cnki.net

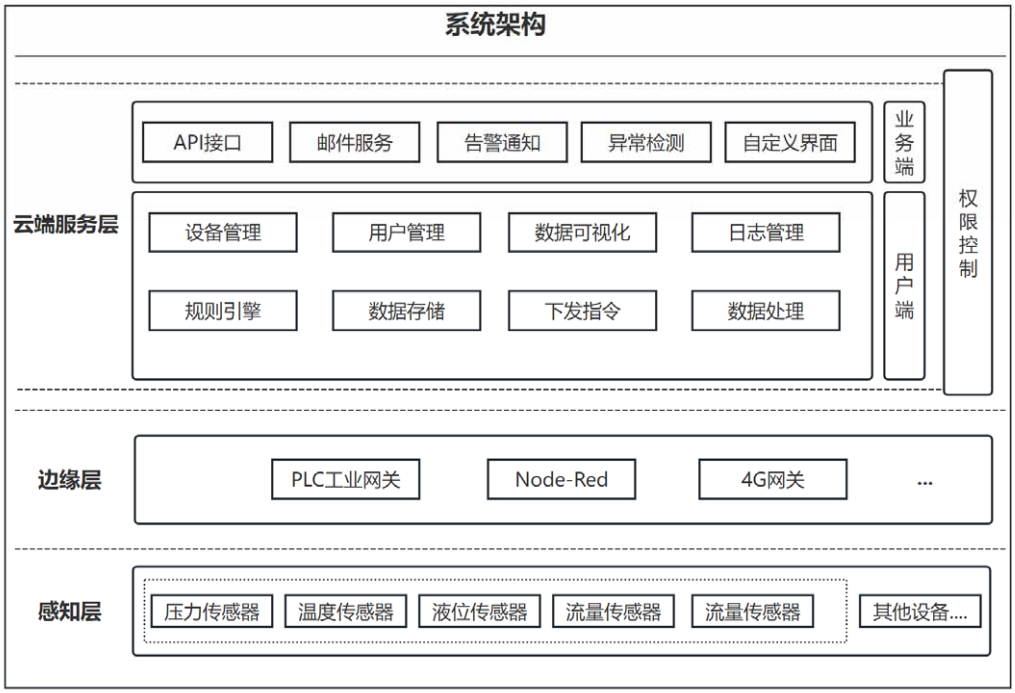



图 4-4 物联网平台系统架构图

感知层也可以理解为传感器层，包括各种设备和传感器。以接入平台的某工厂生产的卧式研磨机为例，研磨机上面接入 PLC 的各种压力，温度，流量，液位传感器，电机数据，以及没有接入 PLC 的动力轴无线应变传感器，以及其它设备共同组成了系统的感知层，感知层作为基础接口层将物理量转换为数字量，感知层大部分设备获取到的数据传递到系统边缘层做进一步的处理，少数直连设备也可以通过 MQTT 等协议将数据直接传输到服务端。

系统的边缘层主要由网关组成。边缘层的目的是对感知层数据进行解析和协议转换，并将数据通过网络传递给服务端。例如接入平台的研磨机和其他设备的 PLC 上的传感器数据，通过支持 PLC 协议的工业网关解析和转换 PLC 数据格式，研磨机动力轴的无线应变传感器由于无法集成到 PLC，使用 4G 网关将数据转发到 Node-Red 服务上，在 Node-Red 上做数据解析和协议转换后再转发到服务端。边缘层具有一定的数据计算和处理以及协议转换能力，可以减少数据传输的延迟和服务层的压力，节省服务层的网络资源。同时，边缘层能够提高整个物联网系统的容错性，即使服务端发生故障时也可以独立运行，从而使整个系统更加可靠和灵活。

系统的云端服务层提供了丰富的功能，比如设备管理，数据搜集和存储，权限控制，数据处理，规则引擎，用户管理，可视化仪表盘，报警功能，远程



中国知网 https://www.cnki.net

控制，规则引擎，邮件发送，自定义插件开发等功能。同时为了方便实现数据流转，允许第三方通过 API 访问平台服务层，同时支持与外部系统的集成，包括 REST API、MQTT 等方式实现信息传递。同时根据平台搜集的设备物联网时序数据，应用时序数据异常检测算法，可以帮助特定业务和系统及时发现异常情况，比如工业生产过程中的异常状况，方便采取对应的预警和维护措施。

## 4.4 功能模块设计

### 4.4.1 设备协议适配模块

整个物联网云平台的数据来源是工业设备上的传感器，网关以及其它的软件模块。设备可以直接接入，也可以通过网关接入。直接接入是指设备直接与平台通信，不通过任何中间件或网关。这种方式适用于能够自主连接到互联网的智能设备。

创建设备后，系统会自动生成一个访问令牌（Access Token），设备与平台通信需使用令牌。根据设备支持的通信协议（如 MQTT、CoAP 或 HTTP），在设备端配置相应的参数，包括服务器地址、端口和访问令牌。MQTT 协议的直连设备发布消息到特定的主题（Topic），如“v1/devices/me/telemetry”，用于发送遥测数据。不支持 MQTT 的设备或需要通过 Web API 与平台交互的场景，设备可以通过 HTTP 的 POST 请求发送 JSON 格式的数据。资源受限的设备则支持 COAP 协议。数据通常以 JSON 格式发送。

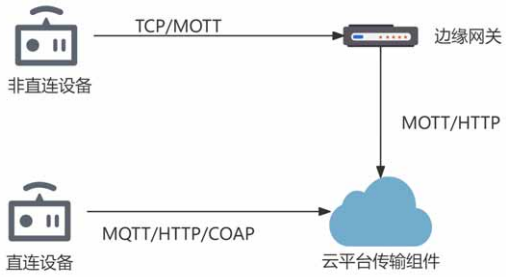



图 4-5 不同协议接入云平台

网关接入是指多个设备通过一个中间件（网关）与平台通信。这适用于无法直接连接到互联网的设备或需要集中管理的场景。在网关设备上配置与平台的通信参数（服务器地址、端口和访问令牌）。网关可以使用 MQTT、HTTP 等协议与平台通信。网关还需要能够识别并管理下属的设备，包括收集和转发设



中国知网 https://www.cnki.net

备的数据，平台实现不同协议接入的方式如图 4-5。

工业设备的物联网使用 PLC 边缘网关实现，通过协议转换和数据传输，实现工业设备与云平台或上位机系统的连接。网关的工作原理包括数据采集、协议解析、协议转换和数据传输等过程，它可以同时采集多种协议的数据。PLC 网关功能如图 4-6。

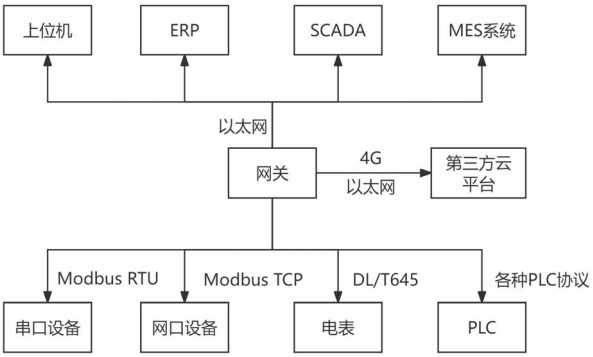



图 4-6 PLC 网关功能

### 4.4.2 管理模块

为了方便用户管理和控制物联网设备，以及配置和监控系统的各方面信息，需要提供设备模块、用户模块、可视化模块、日志模块和仪表盘模块等，下面选取部分模块进行介绍。

设备管理模块是用于管理和操作设备的核心功能，涉及设备的注册、校验、监控、控制等多个环节。设备可以通过 API、UI 界面或集成脚本进行平台注册。图 4-7 为在平台进行注册的流程。

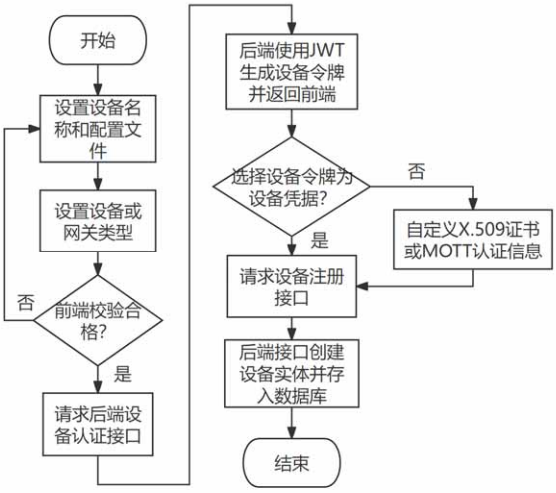



图 4-7 平台设备注册流程



中国知网 https://www.cnki.net

管理员可以在管理界面中手动添加设备，填写设备名称和设备配置文件，并选择是否为网关类型，注册过程中系统默认为新设备生成唯一的标识符（Device ID），并使用 JWT（JSON Web Tokens）为设备生成一个唯一的访问令牌（Access Token），也可以选择 pem 格式的 X.509 证书，或者使用 MOTT 认证的客户端 ID、用户名和密码，作为设备凭据。设备使用其访问令牌或者其他设备认证方式通过支持的协议（如 MQTT、CoAP 或 HTTP）发起与平台的连接请求，如果认证成功，平台与设备之间的连接就会建立。设备此时可以开始发送数据或接收来自平台的命令。

在管理界面，管理员可以设置三种类型的设备属性分为：共享属性、客户端属性和服务器属性。共享属性是设备的常规属性，例如设备的名称、型号、位置、和状态等，可以由设备本身更新，也可以由平台发起更新；客户端属性是由设备主动上报的属性，用于描述设备的当前状态和数据，例如传感器读取的实时数据，如温度、湿度、压力等和一些告警状态；服务器属性是由平台向设备发送的属性，比如由平台发送给设备的配置指令，如更新固件、调整参数等，以及控制指令如开启/关闭设备、执行特定操作等。

平台用户分为系统管理员，租户管理员，普通用户这几个级别，每个级别有不同的权限和功能。

（1）系统管理员：具有最高级别的权限，可以管理整个系统，创建、编辑和删除租户组、租户管理员、客户组和客户用户，可以访问和管理系统设置和配置，包括规则引擎、仪表盘、插件等，查看和管理所有租户和设备的数据和状态以及审计日志。

（2）租户管理员：可以创建、编辑和删除客户用户。管理所属租户的所有设备、规则引擎、仪表盘等资源，查看和管理所属租户的数据和状态。

（3）普通用户：普通用户是具有最低级别的用户，关联到特定的客户。可以访问所属客户的设备和相关资源，查看所属客户的设备数据和状态。

这些用户级别和权限层次使得物联网应用可以支持多租户，每个用户级别具有不同的权限和访问级别，从而实现对系统和设备的灵活管理和控制。普通用户的创建流程如图 4-8 所示。



中国知网 https://www.cnki.net

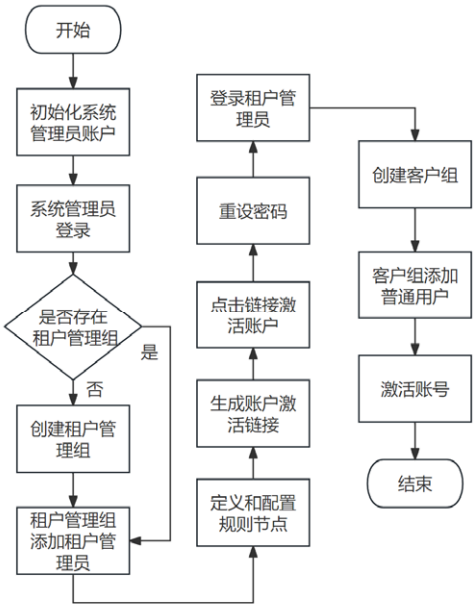



图 4-8 平台普通用户创建流程

可视化模块被设计用于创建交互式仪表盘和可视化数据。其中，仪表盘设计器使用户能够轻松创建自定义仪表盘，可以通过拖放添加和配置各种可小部件，支持自定义布局和样式；设备数据以图表的形式呈现，如折线图、柱状图、饼图等，提供各种图表选项和配置；用户可以创建自定义小部件，用于呈现特定的数据或实现特定的功能，支持与第三方图表库和工具的集成，以扩展可视化能力；用户可以与仪表盘进行交互，如选择时间范围、切换设备、筛选数据等。支持通过点击、鼠标悬停、滑块等方式与可视化元素进行交互，也可以通过仪表盘上的控制按钮和操作来控制设备，如发送指令、调整参数等。

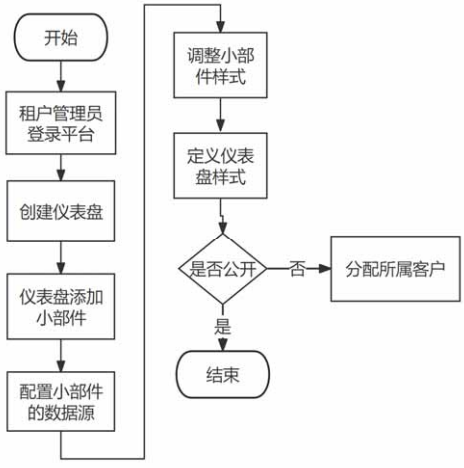



图 4-9 可视化仪表盘创建流程



中国知网 https://www.cnki.net

租户管理员创建自定义可视化仪表盘流程如图4-9，部件的数据源来自接入设备，平台的其他实体或者某个功能。租户管理员创建仪表盘，选择适合的小组件以及配置数据源以后，可以对仪表盘进行调整，最后创建好的仪表盘可以设置公开或者分配给对应的用户。

日志管理模块主要包括审计日志功能。审计日志用于记录系统中的重要事件和操作，以便进行安全性监控、故障排查。审计日志记录系统中的关键事件和操作，如用户登录、设备连接、规则引擎执行等。记录的事件包括时间戳、事件类型、操作对象、操作者、IP 地址等相关信息。可以根据时间范围、事件类型和其他筛选条件来检索和过滤事件记录，以便用户根据需求查看特定类型的事件记录。帮助用户监控系统的安全性，记录用户登录、权限更改、敏感操作等安全相关事件。可以追踪用户的活动和操作，以发现异常行为或潜在的安全威胁。

### 4.4.3 规则引擎模块

规则引擎模块作为物联网平台的重要组成部分，可以根据用户的需求自定义规则，并根据需要进行调整，使得物联网平台能够适应不同的业务场景和需求。其核心功能包括消息处理、规则执行以及输出生成。

规则引擎主要由消息输入、规则树、规则节点、连线和消息输出这五个部分组成。其中，消息输入接收来自客户设备的消息；规则树为用户自定义的逻辑处理树，包含系统提供的节点和客户自行放置的规则节点；规则节点对输入消息进行处理，包括解析、过滤、转换等操作；连线的作用是连接规则节点，带有标签，表示消息的流向；消息输出是根据规则执行生成的最终结果。规则引擎工作流程如下图。

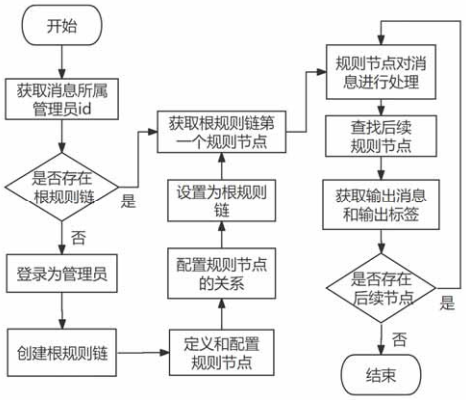



图 4-10 规则引擎工作流程图



中国知网 https://www.cnki.net

规则引擎中，常见的消息来源包括设备（设备的遥测数据、属性上传、报警信息、设备状态变化等）、客户端（通过 HTTP 或 MQTT 等协议与平台进行通信的客户端应用程序）、平台事件（由平台内部的事件触发所产生的消息如用户登录、设备注册、规则链执行完成等）、规则节点和 REST API 操作（来自外部系统的请求、响应或通知）。规则引擎将接收各种来源的消息，并根据定义的规则和逻辑进行处理和响应，使得平台能够适应各种数据流和应用场景的需求。

规则节点主要包括以下几种类型，每种节点用于执行对应的数据处理任务：

（1）过滤型节点：根据特定的条件过滤消息。它可以基于消息的元数据、有效载荷或其他属性进行条件匹配，只允许符合条件的消息通过。过滤节点可用于对数据流进行筛选。

（2）增强型节点：丰富消息内容，可以从外部数据源（如数据库、API）中获取额外的信息，并将其添加到消息的有效载荷中。增强节点可用于在数据处理过程中补充和扩展消息。

（3）转换节点：对消息进行转换和重构。它可以执行各种数据转换操作，如格式转换、数据清洗、数据合并等。转换节点可以修改消息的结构和内容，以便后续的处理和分析。

（4）动作节点：执行特定的操作或任务。它可以触发外部动作，如发送通知、调用 Web 服务、写入数据库等。动作节点可以根据消息的内容或上下文，采取适当的行动响应。

（5）外部节点：与外部系统或服务集成。它可以与其他系统进行数据交换、调用外部 API 或执行外部任务。外部节点可以扩展规则引擎的功能，实现与其他系统的集成和协作。

（6）流程节点：进行数据流的组织，比如将消息转发到另一规则链。

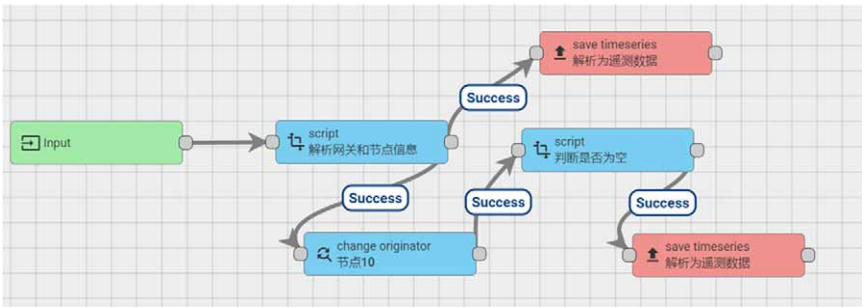



图 4-11 可视化规则链示意图



中国知网 https://www.cnki.net

可视化规则引擎为消息处理提供了强大的功能支持，通过规则链的交互式配置，可以定义设备事件或数据的过滤、告警条件设置、跨系统联动控制、数据路由设定等业务逻辑，只需要编写简单的 Javascript 脚本即可实现对应的业务功能。规则引擎主要应用场景包括：在存储之前，将设备上行数据进行校验或修正；基于预置条件，生成、刷新或清除告警信息，触发执行动作；基于预置条件，触发对外部系统的 REST API 调用；将数据转发到消息队列中，第三方应用可以通过消息队列获取到设备上行数据。

### 4.4.4 异常数据检测模块

本文对于物联网平台采集得到的设备多传感器时序数据，基于图注意力网络（GAT）和 Transformer 结合的深度学习模型，进行多变量时序数据异常检测。检测传感器时序数据中的异常情况可以及时发现设备故障、异常行为或异常事件，从而保障物联网系统的正常运行和数据质量。异常检测模块的详细实现过程如下图。

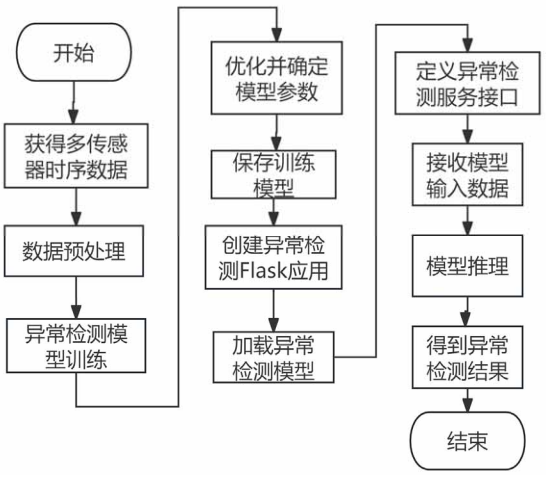



图 4-12 时序数据异常检测实现流程图

首先，对获得的传感器时序数据进行预处理，包括缩放、归一化或标准化等操作，以确保数据适用于模型的输入要求。使用基于 GAT 和改进 Transformer 的异常检测模型，对准备好的数据进行训练，优化并确定模型参数，最后保存训练好的模型。

然后通过创建自定义插件并使用 Flask 框架构建异常检测应用，加载训练好的异常检测模型，定义异常检测服务接口，接收模型数据的输入。使用 Python requests 库或其他 HTTP 客户端，利用物联网平台的 Rest API 获取传感器数据，



中国知网 https://www.cnki.net

处理响应数据，从获取的数据中提取出需要的特征并将其转换为适合异常检测模型输入的格式，发送 POST 请求到异常检测服务接口并处理响应数据，根据需要对异常检测结果进行进一步处理和分析，最后将结果推送给物联网平台。

## 4.5 本章小结

本章对物联网平台的需求进行整理，包括设备管理、数据接入、存储和分析、可视化和仪表板、规则引擎和自动化、告警和通知、安全性和权限管理等功能，同时对平台开发相关的 Web 技术、数据库、通信协议、微服务架构和高频发技术进行了介绍，最后详细说明了平台的协议适配、管理、规则链和异常检测等模块的流程设计。



中国知网 https://www.cnki.net

# 第五章 设备物联网平台实现和功能测试

## 5.1 平台搭建

本文软件平台在 windows 本地环境编译完成以后再部署到云服务器。开始编译之前，确保系统满足以下基本条件：

（1）安装 JAVA JDK：安装 JDK1.8 以上版本，本文选择 JDK11 并在本地配置系统环境变量。

（2）安装 MAVEN 和 IDEA：安装 MAVEN3.3.1 或以上版本作为 JAVA 编译工具并配置环境变量，本文选用 MAVEN3.6.3 版本。使用当前主流 JAVA 开发工具 IntelliJ IDEA 进行源码开发。

（3）安装 Node.js 和 yarn：安装 v16.15.0 版本的 node.js 和 v1.22.4 版本的 yarn。

（4）数据库配置：平台支持多种数据库，包括关系型数据库 PostgreSQL、分布式 NoSQL 数据库 Cassandra 以及内存缓存数据库 Redis。

在本地开发环境完成源代码获取、后端和前端编译等关键步骤以后，就可以在 Windows 平台上构建和定制物联网软件平台。

本地完成源代码的开发并编译生成 deb 包以后，在 Ubuntu 20.04 云服务器进行环境配置，安装物联网云平台 deb 包，实现云平台的部署。

## 5.2 系统实现

### 5.2.1 设备协议适配模块

平台支持多种协议直连设备，包括 HTTP、CoAP 和 MQTT。下面是实现这三种协议的详细介绍。

HTTP 协议：使用 Tomcat 作为 HTTP 服务器来处理来自设备和客户端的 HTTP 请求。Springboot 框架内置了 Tomcat，在配置文件中，指定应用启动时使用的 HTTP 端口号和 IP 地址。应用启动后，Tomcat 接收到来自设备或客户端的 HTTP 请求后，将其路由到正确的控制器（Controller）或服务（Service）进行处理。



中国知网 https://www.cnki.net

```
server:
  # Server bind-address
  address: "${HTTP_BIND_ADDRESS:0.0.0.0}"
  # Server bind port
  port: "${HTTP_BIND_PORT:8080}"
```

图 5-1 HTTP 端口和 IP 设置

CoAP 协议：使用 Eclipse Californium 框架来实现 CoAP 服务器。Eclipse Californium 是一个开源的 CoAP 框架，提供了实现 CoAP 协议的核心功能，使用 Californium 提供的类和方法来创建和管理 CoAP 服务器，在 Maven 配置文件引入相关依赖即可使用。创建并启动 CoAP 服务类的示例代码如下图。

```
//创建一个 CoAP Server
this.serverInstance = new CoapServer();
//调用自定义的方法，添加资源，映射 CoAP 请求
addResource();
//context 包含配置文件对 CoAP Server 的一些配置
InetSocketAddress addr = new
InetSocketAddress(InetAddress.getByName(context.getHost()), context.getPort());
server.addEndpoint(new CoapEndpoint(addr));
//启动 CoAP Server
serverInstance.start();
```

图 5-2 创建并启动 CoAP Server

MQTT 协议：使用 Netty 提供的类和方法来创建和管理 MQTT 服务器。应用启动时，Netty 创建一个 MQTT 服务器实例，并监听指定的端口。MQTT 服务器类的初始化方式如图 5-3。

```
workerThreadGroup = new NioEventLoopGroup(workerThreadNumber);
bossThreadGroup = new NioEventLoopGroup(bossThreadNumber);
ServerBootstrap server = new ServerBootstrap();
server.group(bossGroup, workerGroup) .childHandler(new
MqttServerChannelInitializer(context).channel(NioServerSocketChannel.class);
channel = server.bind(host, port).sync().channel();
```

图 5-3 MOTT Server Service 初始化

使用了 Netty 的 EventLoopGroup、ServerBootstrap 和 ChannelInitializer 来创建和配置 MQTT 服务器。EventLoopGroup 用于管理线程池，ServerBootstrap 用于引导和配置服务器，ChannelInitializer 用于初始化服务器通道。通过绑定主机和端口来启动服务器，并返回一个 Channel 对象，用于后续的操作。MQTT 服务器启动后，它将等待客户端的连接。一旦有客户端连接到服务器的指定主机和端口，主线程组将接受连接请求，然后将请求分配给工作线程组处理。MqttServerChannelInitializer 的实现将负责初始化客户端连接的 MQTT 通道，并



中国知网 https://www.cnki.net

配置相应的处理器链来处理客户端请求和响应。

### 5.2.2 数据库实现

数据库的数据表包含用户表、遥测数据表、仪表盘信息表和规则链表等。选取部分重要数据表介绍，其结构设计如下：

（1）系统用户表

该表存储系统管理员的信息，可以创建租户管理员，租户可以创建对应的客户信息。

表 5-1 系统用户信息

| 字段名 | 数据类型 | 注释 |
| --- | --- | --- |
| id | varchar(31) | 唯一 ID |
| additional_info | varchar | 添加详细描述 |
| authority | varchar(255) | 各级用户权限 |
| customer_id | varchar(31) | 客户 ID |
| email | varchar(255) | 邮箱 |
| name | varchar(255) | 用户姓名 |
| Search_text | varchar(255) | 搜索文本 |
| Tenant_id | varchar(31) | 租户 ID |

（2）接入设备表

这里的设备是指接入平台的各种实体，存储传感器和其他设备的基本信息和所属用户等。

表 5-2 系统用户信息

| 字段名 | 数据类型 | 注释 |
| --- | --- | --- |
| id | varchar(31) | 唯一 ID |
| additional_info | varchar | 设备详细信息 |
| customer_id | varchar(31) | 客户 ID |
| type | varchar(255) | 设备类型 |
| Name | varchar(255) | 设备名称 |
| Label | varchar(255) | 标签信息 |
| search_text | varchar(255) | 查询文本 |
| tenant_id | varchar(31) | 租户 ID |



中国知网 https://www.cnki.net

（3）告警信息

该表存储警告的产生以及清除的详细数据，包括警告来源，开始和结束时间，警告严重程度和所属租户等信息。

表 5-3 告警信息表

| 字段名 | 数据类型 | 注释 |
| --- | --- | --- |
| id | varchar(31) | 唯一 ID |
| ack_ts | bigint | 告警创建时间 |
| clear_ts | bigint | 告警清除时间 |
| additional_info | varchar(255) | 详细描述 |
| originator_id | varchar(31) | 原因实体 ID |
| originator_type | integer | 原因实体类型 |
| severity | varchar(255) | 严重程度 |
| start_ts | bigint | 开始时间 |
| end_ts | bigint | 结束时间 |
| status | varchar(255) | 状态 |
| tenant_id | varchar(31) | 租户 ID |

（4）遥测数据表

该表存储收集的设备历史遥测数据 key 和对应的 value，组成时间序列数据集。

表 5-4 设备遥测数据表

| 字段名 | 字段类型 | 字段说明 |
| --- | --- | --- |
| entity_type | varchar(255) | 设备实体类型 |
| entity_id | varchar(31) | 实体 ID |
| key | varchar(255) | 设备属性 key |
| ts | bigint | 属性上报时间 |
| str_v | Varchar(10000000) | 设备属性字符串 |
| long_v | bigint | 设备属性的数字 |
| Dbl_v | Double_precision | 设备属性的小数 |



中国知网 https://www.cnki.net

（5）属性数据表

属性信息存储形式为 k-v 键值对，分为服务端属性、客户端属性和共享属性。属性只有实时最新值，无历史数据。

表 5-5 属性数据表

| 字段名 | 字段类型 | 字段说明 |
| --- | --- | --- |
| entity_type | varchar(255) | 实体类型 |
| entity_id | varchar(31) | 实体 ID |
| attribute_type | varchar(255) | 属性范围 |
| attribute_key | varchar(255) | 属性键名 |
| str_v | varchar(10000000) | 存储属性字符串 |
| long_v | bigint | 存储属性数字值 |
| dbl_v | precision | 存储属性的小数 |
| last_update_ts | bigint | 最后更新时间 |

（6）仪表盘信息表

该表存储用于可视化平台遥测数据和属性的仪表盘数据，包括仪表盘的详细配置信息，仪表盘所属用户和租户等。

表 5-6 仪表盘信息表

| 字段名 | 字段类型 | 字段说明 |
| --- | --- | --- |
| id | varchar(31) | 唯一 ID |
| configuration | varchar(10000000) | 组件配置信息 |
| assigned_customers | varchar(1000000) | 仪表盘所属客户 |
| search_text | varchar(255) | 查询文本 |
| tenant_id | varchar(31) | 租户 id |
| title | varchar(255) | 仪表盘标题 |

（7）规则节点信息表

该表存储规则链中定义的规则节点的信息，比如规则节点的名称、类型以及规则节点里自定义的 JavaScript 脚本等内容。



中国知网 https://www.cnki.net

表 5-7 规则节点信息表

| 字段名 | 字段类型 | 字段说明 |
| --- | --- | --- |
| id | varchar(31) | 唯一 ID |
| rule_chain_id | varchar(31) | 所属规则链的 ID |
| additional_info | varchar | 详细 json 信息 |
| configuration | varchar(10000000) | 节点的配置信息 |
| Type | varchar(255) | 规则节点所属 java 类 |
| Name | varchar(255) | 规则节点名称 |
| Debug_model | boolean | 定义调试节点 |

### 5.2.3 管理模块

整个物联网云平台的管理界面包括首页、仪表板管理、设备管理、各级用户管理、规则链管理、日志管理和可视化部件库管理等。

租户管理员登录平台首页如下图。

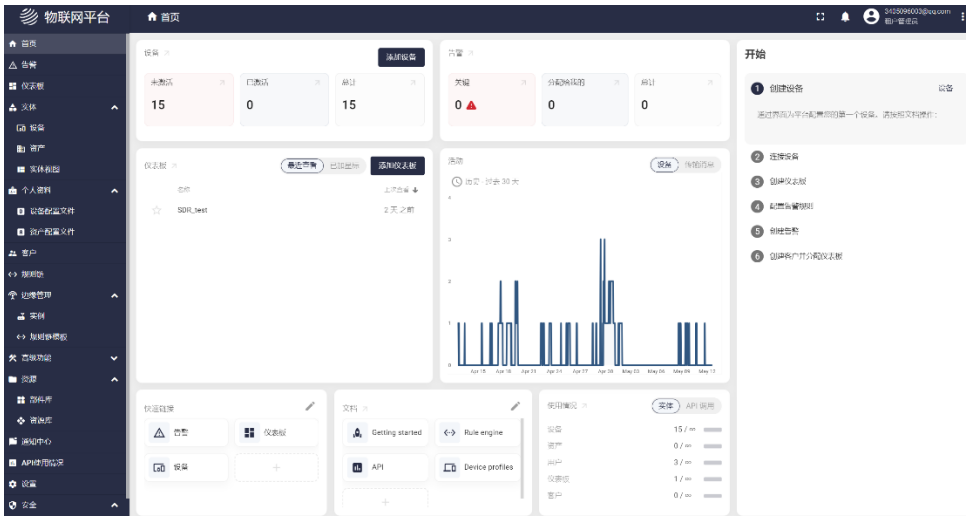



图 5-4 平台租户管理员登陆首页

租户管理员可以在首页查看平台关键信息，如设备激活数量、设备传输消息量和设备告警数量等统计指标，快速进入设备或仪表盘管理界面。

租户管理员注册新的设备的界面如图 5-4，用户首先对设备的名称，标签和设备配置文件进行设置，然后创建设备凭证，使用设备令牌或者 MOTT Basic，即可实现在平台添加设备。



中国知网 https://www.cnki.net

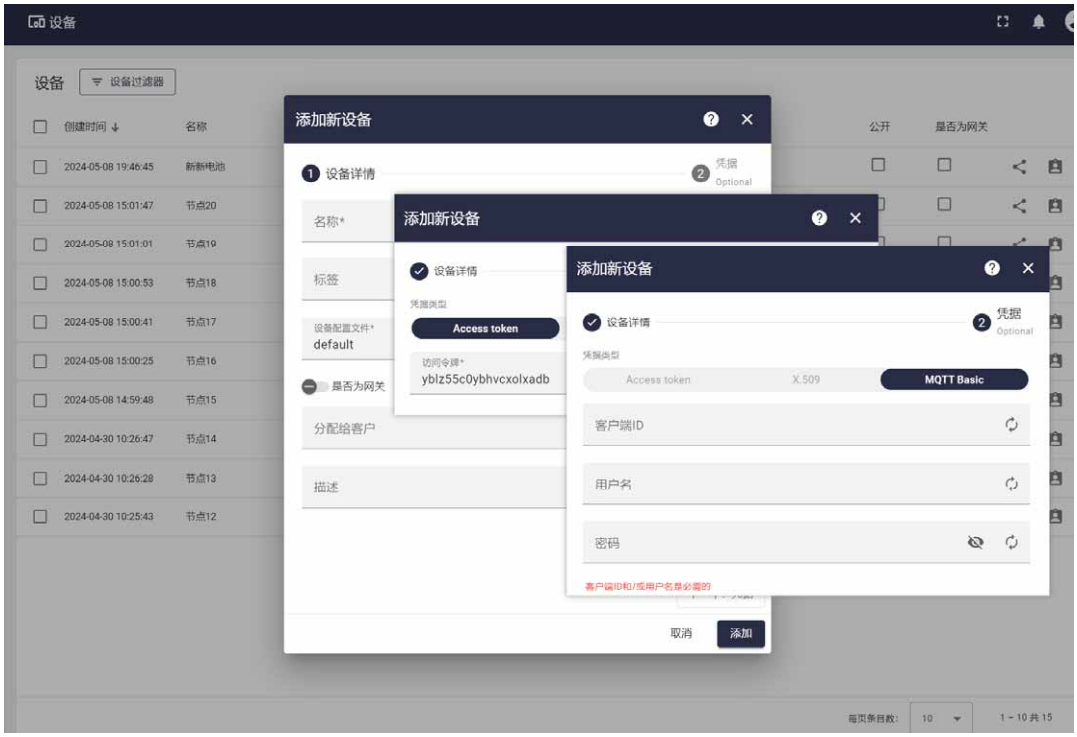



图 5-5 用户在平台添加设备

用户在平台在设备管理界面可以管理设备的最新遥测数据和设备属性，遥测数据由更新时间，键名以及对应的值组成，选择对应的数据键可以添加到可视化组件以及仪表盘，实现在仪表盘里数据的可视化分析。同时，能够管理设备的三种属性，如设备活跃状态和地理位置等信息。

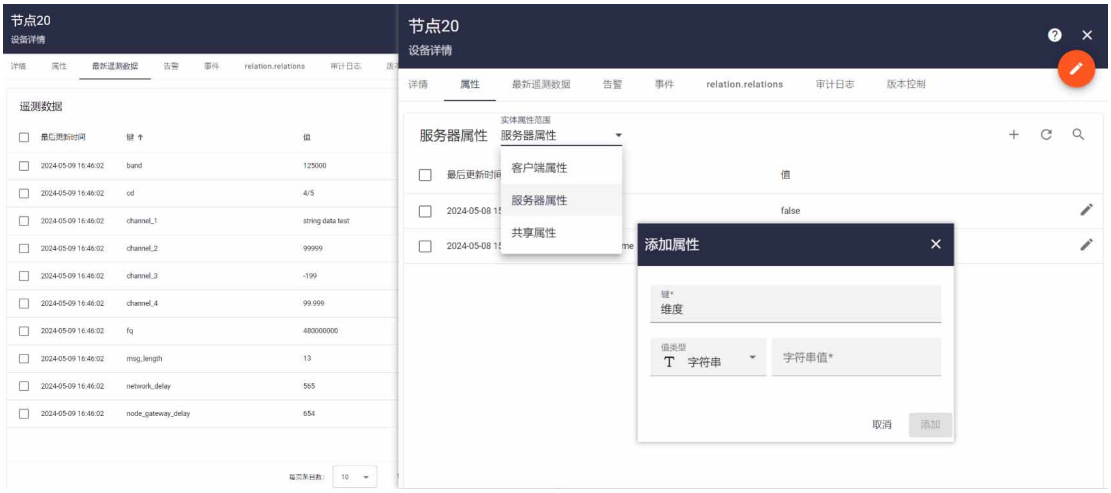



图 5-6 查看和管理设备遥测数据与属性



中国知网 https://www.cnki.net




图 5-7 平台可选的小组件示例

小组件可分为：图表类小组件将数据以图形的形式展示，如折线图、柱状图、饼图、表格和卡片等，可查看历史数据和实时数据；控制类小部件允许用户通过界面向设备发送命令或调整设备设置，如按钮，开关，滑动条等；地图类小部件用于在地理位置上展示设备或数据点，适用于需要跟踪设备位置或展示基于位置的数据的应用场景，包括位置地图、热力图和路径地图等。同时支持自定义开发小组件，引入第三方图表库进行自定义开发。

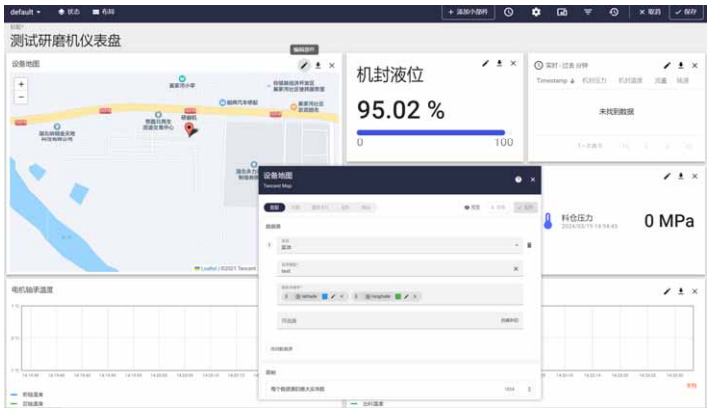



图 5-8 可视化仪表盘编辑界面

小部件的数据源来自接入设备，平台的其他实体或者某个功能。租户管理员创建仪表盘，选择适合的小组件以及配置数据源以后，在创建好的仪表盘可以设置公开或者分配给对应的用户。仪表盘可以实时显示设备和传感器的数据，



中国知网 https://www.cnki.net

允许用户自定义布局，根据自己的需求和偏好进行配置。用户可以添加、移动和调整小部件，使用拖拉拽方式以及设置界面布局参数进行方便的调整，以创建符合自己工作流程的仪表盘界面。

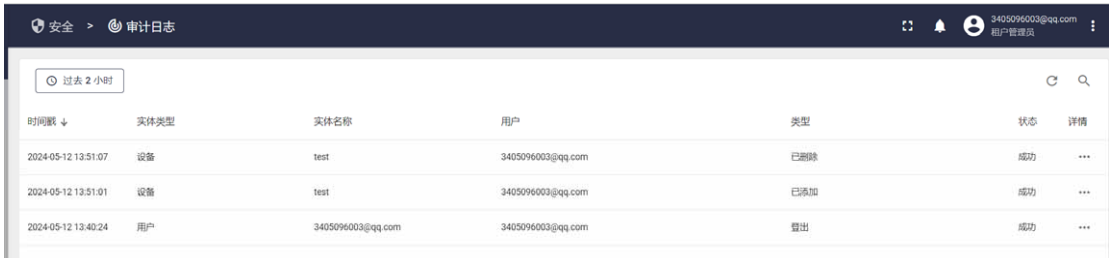



图 5-9 系统审计日志

审计日志记录了用户的操作行为和系统事件，可以用于安全审计和追踪潜在的安全问题，包括系统活动的时间戳、实体类型、实体名称、所属用户和操作类型等详细信息。通过实时监控审计日志，管理员可以识别异常的操作模式、异常的访问请求或其他异常事件，并及时采取相应的措施。

### 5.2.4 规则引擎模块

作为管理员或具有相应权限的用户，在规则链管理页面，可以创建新的规则链或者对规则链模块进行导入导出操作。根规则链为该账户下设备默认处理设备消息的规则链，规则链可以作为另一规则链的节点，从而实现复杂的业务处理流程。

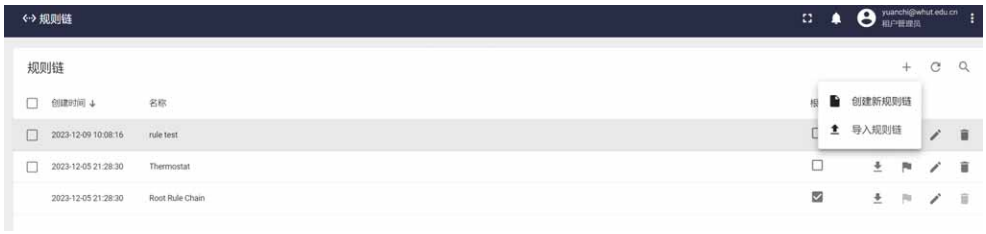



图 5-10 规则链管理界面

在规则链编辑界面，可以配置规则链的条件、操作和处理流程。根据业务需求，设置规则链的触发条件、数据过滤条件和相关操作。通过使用可视化的界面组件或编辑器来创建和编辑规则链的配置。节点是规则链中的基本处理单元，每个节点执行一个特定的功能，如消息转换、外部 API 调用、数据过滤、判断逻辑等，规则节点可以是条件节点、转换节点或操作节点。例如，你可以添加一个转换节点来计算传感器数据的平均值或进行单位转换。节点接收输入数据，根据内部逻辑处理数据，然后输出结果。输出可以是转发到下一个节点



中国知网 https://www.cnki.net

的数据，也可以是触发警报、发送邮件等操作。规则链通过节点的有序连接实现数据的链式处理。数据从规则链的入口节点开始流动，经过一系列节点的处理，最终达到出口节点或触发特定动作。用户可以通过拖放方式自由组合节点，灵活定义数据处理逻辑。规则链处理过程中，可以利用上下文数据（Context Data）在节点之间共享信息。这使得不同节点可以访问前面节点处理的结果，实现复杂的逻辑判断和数据处理。

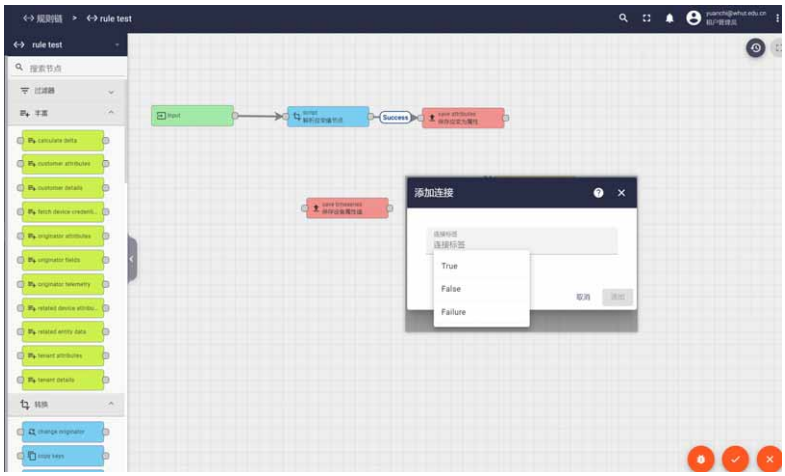



图 5-11 规则链编辑页面

下面以邮件节点 SendEmailRuleNode 为例子说明规则节点的实现过程。首先，规则节点需要实现 RuleNode 接口：

```
public interface RuleNode {
        void init(EngineContext context, NodeConfiguration config);
        void onEngineMessage(EngineContext context, EngineMessage message);
        void destroy();
}
```

图 5-12 规则节点接口类

Init 方法用于读取并解析节点配置参数，SendEmailRuleNode 会处理和保存发送邮件节点的配置参数，包括邮件服务器地址、端口、登录账户、密码等信息。OnEngineMessage 方法用于处理规则节点的输入消息，当规则引擎收到待处理的消息时，从消息负载中提取出发送邮件需要的一些字段。Destroy 方法用于释放初始化过程中申请的资源，例如关闭与邮件服务器的连接。其他规则节点实现类参考邮件节点，都需要实现 RuleNode 接口中定义的方法，并且平台利用 Akka 框架为每个规则节点创建一个 Actor 实例，确保规则节点的高并发处理能力。



中国知网 https://www.cnki.net

### 5.2.5 异常检测模块

基于设备物联网平台采集的设备多传感器时序数据，使用 Flask 和 PyTorch 实现异常检测模块。该模块旨在接收实时数据，并使用训练好的 PyTorch 模型来预测数据是否异常，并将异常检测结果返回给物联网平台。

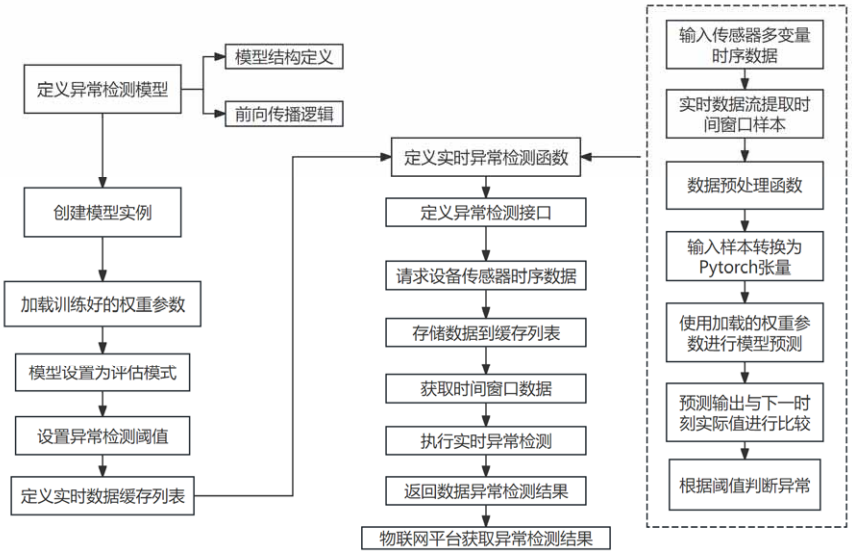



图 5-13 实时异常检测实现过程

在 Flask 应用中，首先需要定义异常检测模型的结构和前向传播逻辑，包括图注意力层、嵌入层、位置编码、Transformer 块和全连接层等。接着加载训练好的权重参数 pth 文件，将模型设置为评估模并定义异常检测阈值。定义异常检测的服务接口，输入数据通过 HTTP 访问该接口。

然后定义实时异常检测函数，根据时间窗口，如划分 30 个时间步为一个样本，利用模型的权重参数进行预测，将该样本的预测值与下一时刻实际值比较，根据训练模型时得到的最优阈值判断数据是否存在异常。物联网平台通过 Rest API 与异常检测应用接口进行交互，实现时序数据异常检测功能。

数据异常检测功能的测试由于缺乏实际运行的工业数据集，鉴于 SWaT 的数据贴合许多工业生产领域的时序数据特点，因此本文物联网平台接入 SWaT 设备的多变量时序数据。

使用 Flask 异常检测模块，检测安全水处理设备 6 小时内，以每秒为频率采集的设备数据，一共 20000 个，并将该段时间内异常数据总数的统计结果通过 API 提交到物联网平台，在仪表盘界面配置警告卡片小组件，显示异常监测情况如图 5-24，误报率为 3.6%，达到了预期效果。



中国知网 https://www.cnki.net

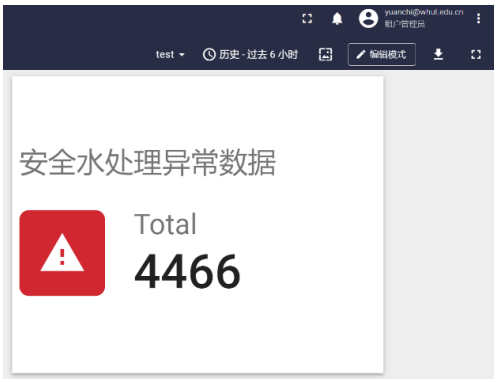



图 5-14 平台异常数据检测统计小组件

在实际工业环境中，异常检测模块可以接收和处理真实的工业设备多变量时序数据，使用训练好的模型和权重，进行准确的异常检测。

## 5.3 系统应用实例

以模拟直连设备和通过网关接入的工业 PLC 设备等为例，介绍本文物联网平台的相关功能测试。

（1）模拟直连设备接入：

使用 MQTTX 软件模拟物联网设备将安全水处理数据集的多个传感器数据发送到平台的 MQTT 服务组件，实现传感器数据的采集。例如发送 LIT101 和 LIT401 的数据到平台指定的 MQTT 遥测数据主题。

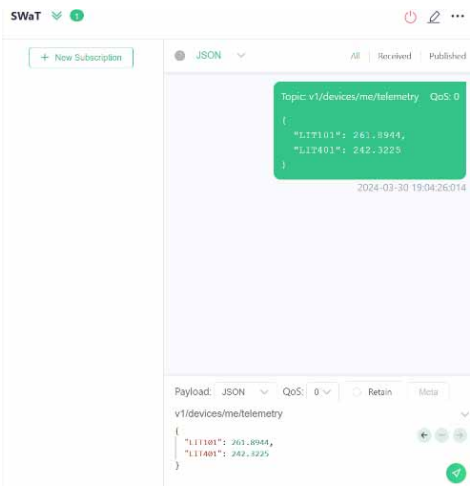



图 5-15 使用 MOTTX 模拟发送数据



中国知网 https://www.cnki.net

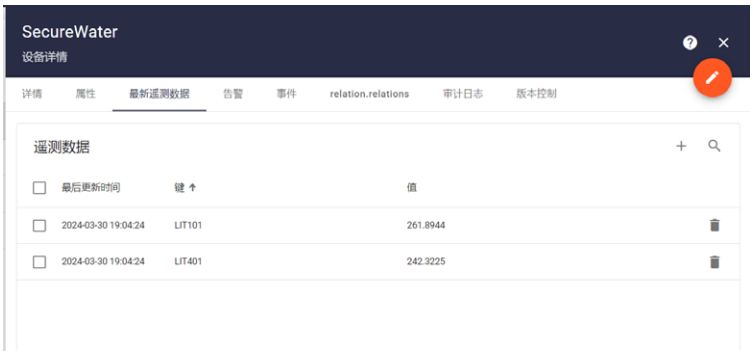



图 5-16 平台接收的传感器值

平台成功查看到设备的 LIT101 和 LIT401 两个传感器的最新遥测数据，证明 MQTT 设备接入功能正常。

（2）工业 PLC 设备接入：

以某工厂生产的研磨机为例，对于研磨机的压力，温度，流量，电机参数等物理量，由于已经集成到西门子 PLC 上，使用 PLC 工业网关采集相关的物理量。PLC 一般使用地址点表来表示各个传感器和执行器的数据，地址点表描述了各个变量的数值类型，寄存器地址，地址类型以及读写的权限等。PLC 网关按照 PLC 协议与 PLC 建立通信，根据地址点表中的寄存器位置，请求对应地址的传感器原始数据，并根据 PLC 协议解析传感器数据。




图 5-17 PLC 网关配置界面图

如图 5-17 所示，在网关配置界面配置变量对应的寄存器地址类型和数据类型，如研磨机机封温度地址类型为 VD，地址为 12，数据类型为 float，变量标签 VD12 是物联网平台表示机封温度的属性名。



中国知网 https://www.cnki.net

| 变量名称 | 地址类型 | 地址 | 值 | 单位 | 数据类型 | 变量标签(Key) | 映射地址 | 系数 |
|---|---|---|---|---|---|---|---|---|
| 料仓压力 | VD | 0 | | | float32 | VD0 | 14(M.400015) | 1 |
| 进料温度 | VD | 16 | | | float32 | VD16 | 16(M.400017) | 1 |
| 出料温度 | VD | 20 | | | float32 | VD20 | 18(M.400019) | 1 |
| 机封压力 | VD | 4 | | | float32 | VD4 | 20(M.400021) | 1 |
| 机封液位 | VD | 8 | | % | float32 | VD8 | 22(M.400023) | 1 |
| 机封温度 | VD | 12 | | | float32 | VD12 | 24(M.400025) | 1 |
| 流量 | VD | 24 | | | float32 | VD24 | 26(M.400027) | 1 |
| 电机前轴承温度 | VD | 28 | | | float32 | VD28 | 28(M.400029) | 1 |
| 电机后轴承温度 | VD | 32 | | | float32 | VD32 | 30(M.400031) | 1 |
| 状态 | VW | 60 | | | int16 | VW60 | 32(M.400033) | 1 |
| 运行时间 | VW | 500 | | | uint16 | VW500 | 33(M.400034) | 1 |
| 转速 | VW | 292 | | | uint16 | VW292 | 34(M.400035) | 1 |
| 电流 | VW | 354 | | | uint16 | VW354 | 35(M.400036) | 1 |
| 电压 | VW | 358 | | | uint16 | VW358 | 36(M.400037) | 1 |
| 功率 | VW | 352 | | | uint16 | VW352 | 37(M.400038) | 1 |

图 5-18 研磨机采集点位图

PLC 网关将采集到的研磨机的各项数据转换平台的 mqtt 服务指定的数据格式，将数据发布到主题：v1/gateway/telemetry，保存为遥测数据。

同时，对于研磨机上安装的动力轴无线应变传感器，应变传感器上的数据包含动力轴的转速和应变数据，是高频时序数据，以 100hz 的采集频率为例，应变传感器每 1s 打包一包数据使用 MQTT 通过 4G 上传到平台的规则链，使用 Node-Red 做数据格式解析和转换。一包数据的格式如图 5-19：

00bb010b02a2000207 05ccdd00e6b800 00e6b80100e6b80200e6b80300e6b80400e6b80500e6b8
0600e6b80700e6b80800e6b80900e6b80000e6b80100e6b80200e6b80300e6b80400e6b80500e
6b80600e6b80700e6b80800e6b80900e6b80000e6b80100e6b80200e6b80300e6b80400e6b805
00e6b80600e6b80700e6b80800e6b80900e6b80000e6b80100e6b80200e6b80300e6b80400e6b
80500e6b80600e6b80700e6b80800e6b80900e6b80000e6b80100e6b80200e6b80300e6b80400
e6b80500e6b80600e6b80700e6b80800e6b80900e6b80000e6b80100e6b80200e6b80300e6b80
400e6b80500e6b80600e6b80700e6b80800e6b80900e6b80000e6b80100e6b80200e6b80300e6
b80400e6b80500e6b80600e6b80700e6b80800e6b80900e6b80000e6b80100e6b80200e6b8030
0e6b80400e6b80500e6b80600e6b80700e6b80800e6b80900e6b80000e6b80100e6b80200e6b8
0300e6b80400e6b80500e6b80600e6b80700e6b80800e6b80900e6b80000e6b80100e6b80200e
6b80300e6b80400e6b80500e6b80600e6b80700e6b80800e6b809eeff

图 5-19 100hz 频率采集的一包应变数据

一包应变数据长度为 414 个字节，用十六进制表示，00bb 为包头，02a2 为包序号，0002 为转速，00e6b800 为一百个应变值里面的第一个应变值。

表 5-8 无线应变传感器接入协议

| 包头 | 标识符 | 包序号 | 转速 | 应变数据 | 包尾 | 其他 |
|---|---|---|---|---|---|---|
| 2 字节 | 2 字节 | 2 字节 | 2 字节 | 400 字节 | 2 字节 | 4 字节 |

由于平台本身并没有在其规则链中提供一些用于处理 hex 数据的关键节点，因此在云端服务器扩展安装了 Node-Red（Node-Red 由 IBM 开发，是一种基于流的编程工具，用于表示系统或应用程序的行为，构建在 node.js 运行时上[55]）。



中国知网 https://www.cnki.net

作为边缘网关，实现协议转换、过滤和解析数据。如图 5-20 所示，创建了一个流程，首先读取传感器的原始数据，然后使用 function 节点根据传感器数据协议对数据进行解析。然后每个数据流被引导到相应的输出。之后，输出节点使用 MQTT 协议发送处理之后的数据到云平台。

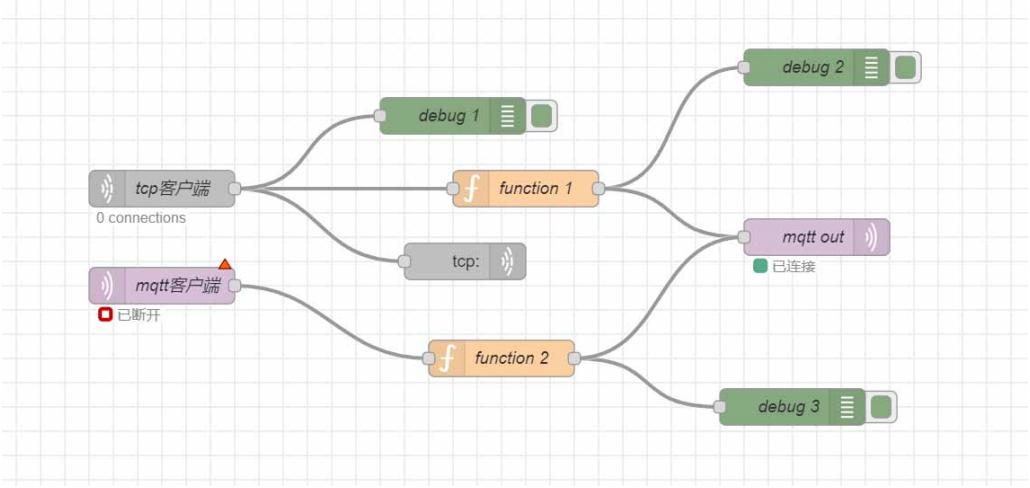



图 5-20 边缘端使用 Node-Red 处理数据

对于平台接收到的研磨机动力轴应变数据，在平台可视化组件引入 Echarts 图表库，自定义了应变数据专用小组件，展示 1s 内应变传感器的 100 个应变值，如图 5-21 所示：




图 5-21 规则链解析 100hz 的应变值数据



中国知网 https://www.cnki.net

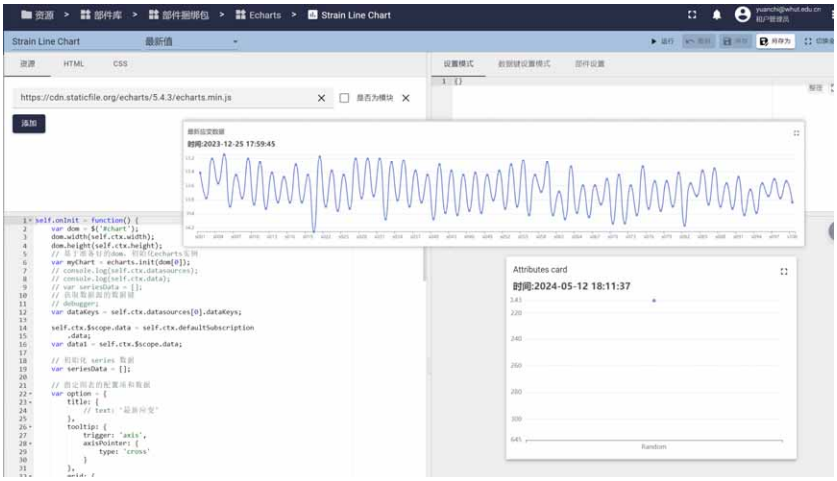



图 5-22 自定义可视化小组件显示应变值

研磨机的经度纬度等信息设置为该设备的服务端属性，存储在数据库的属性数据表，通过 PLC 网关上传的遥测数据通过 MQTT 存储在遥测数据表。




图 5-23 根据设备经纬度属性配置设备地图

最终实现的客户研磨机仪表盘界面如下，点击地图界面进入对应的设备列表即可查看对应机器的详细数据，可以查看研磨机械的温度、压力、液位和电机参数等信息。

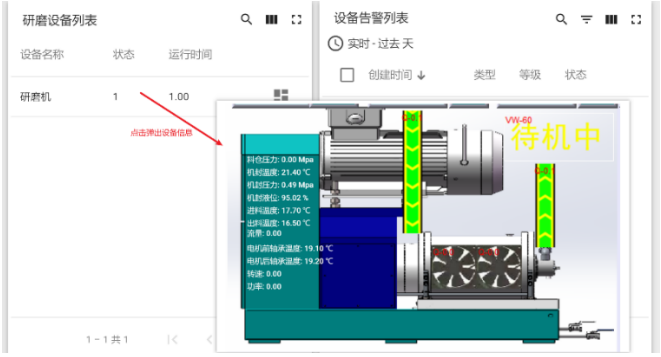



图 5-24 研磨机客户仪表盘



中国知网 https://www.cnki.net

## 5.4 本章小结

本章详细介绍了物联网平台各个模块的详细实现，包括设备和用户管理、可视化、规则引擎和设备时序数据异常检测等功能，基于模拟的设备以及实际接入本平台的工业设备，对该平台的各项功能进行了验证和介绍，符合预期的功能需求。



中国知网 https://www.cnki.net

# 第六章 总结与展望

## 6.1 总结

本文对于设备多变量时序数据异常检测方法，基于时空关联性分析角度，提出了使用稀疏 GAT 和卷积注意力 Transformer 实现时序数据时空特征聚合，进行时序数据的异常检测，实现了较好的多变量时序数据异常检测效果。同时，对于设备物联网问题，设计了一个通用的物联网平台，包括设备管理、规则链、可视化、规则链、异构设备接入等功能，并将异常检测方法应用于平台的异常检测模块，为设备的传感器时序数据分析和决策提供了更多依据，总的工作成果如下。

（1）使用图注意力神经网络 GAT 实现不同节点（即不同传感器变量）关联信息提取。通过使用图注意力进行空间特征聚合，将不同传感器之间的潜在关联信息整合到单个传感器的特征表示中。在原有 GAT 基础上进行改进，实现稀疏性，即原始 GAT 默认所有节点两两相连，但是现实世界中的设备，并不是所有传感器之间都是有关联的。在进行多变量时序数据异常检测时，稀疏的 GAT 减少了冗余信息的聚合，更适合实际场景应用。

（2）传统 Transformer 关注点与点之间的关联，可能忽略了时序数据的连续性和整体性，在 Transformer 模型的注意力计算部分进行改进，引入一维卷积进行多时间点的特征聚合，使得 Transformer 模型更适合处理时间序列数据。基于卷积自注意力的 Transformer 在处理时间序列数据，增强了时间序列中的局部特征，提升了模型对于设备多变量时序数据预测和异常检测效果。

（3）设计通用的设备物联网管理平台，使用三层架构，包括感知层，边缘层，云端服务层。实现异构设备包括工业设备的数据采集和解析、可视化、规则链等功能，并将异常检测算法应用于物联网平台实现设备的时序数据异常检测功能。

## 6.2 不足与展望

（1）可以进一步扩展物联网平台支持更多物联网设备协议和数据格式，提高通用性。在对物联网系统的边缘层的数据预处理和清洗方面可以更加优化，



中国知网 https://www.cnki.net

提高数据质量。在大规模部署时，可以优化平台的计算性能和资源开销，确保能够高效运行。

（2）对于本文提出的基于预测的异常检测模型，可以尝试融合更多先进的时间序列异常检测算法，如基于生成对抗网络的方法，进一步提高检测精度。可以加强对检测结果的解释性，比如给出异常的具体原因分析，方便用户理解和处理。

（3）在某些工业领域应用中，大型设备的时序数据可能存在采集频率不一致的问题，如何对采集到的时序数据进行处理以后再使用异常检测模型是一个待解决的问题。



中国知网 https://www.cnki.net

# 参考文献

[1] Ferencz K, Domokos J, Kovács L. Cloud Integration of Industrial IoT Systems. Architecture, Security Aspects and Sample Implementations[J]. Acta Polytechnica Hungarica, 2024, 21(4): 7-28.

[2] Savaglio C, Mazzei P, Fortino G. Edge Intelligence for Industrial IoT: Opportunities and Limitations[J]. Procedia Computer Science, 2024, 232: 397-405.

[3] He E, Liu Z, Haghani S. Design and Implementation of a Smart Rain Barrel Network via the Blynk IoT Platform[C]//2024 IEEE International Conference on Consumer Electronics (ICCE). IEEE, 2024: 1-3.

[4] Rasyid M U H, Basofi A, Sukaridhoto S, et al. Implementation of IoT Platform Analytics for Monitoring Coastal Water Conditions[C]//International Conference on Applied Science and Technology on Engineering Science 2023 (iCAST-ES 2023). Atlantis Press, 2024: 587-606.

[5] 陈孙胜. 基于物联网的校园环境监测系统设计与研究[D]. 浙江:浙江大学,2022.

[6] Henschke M, Wei X, Zhang X. Data visualization for wireless sensor networks using ThingsBoard[C]//2020 29th Wireless and Optical Communications Conference (WOCC). IEEE, 2020: 1-6.

[7] Chandrasekaran G, Kumar N S, V G, et al. IoT enabled smart solar water heater system using real time ThingSpeak IoT platform[J]. IET Renewable Power Generation, 2023.

[8] Blechmann S, Sowa I, Schraven M H, et al. Open source platform application for smart building and smart grid controls[J]. Automation in Construction, 2023, 145: 104622.

[9] Okhovat E, Bauer M. Monitoring the Smart City Sensor Data Using Thingsboard and Node-Red[C]//2021 IEEE SmartWorld, Ubiquitous Intelligence & Computing, Advanced & Trusted Computing, Scalable Computing & Communications, Internet of People and Smart City Innovation (SmartWorld/SCALCOM/UIC/ATC/IOP/SCI). IEEE, 2021: 425-432.

[10] M. Elsisi, C. -L. Su and M. N. Ali. Design of Reliable IoT Systems With Deep Learning to Support Resilient Demand Side Management in Smart Grids Against Adversarial Attacks [J]. IEEE Transactions on Industry Applications. 2024, 60(2): 2095-2106.

[11] Dwiyaniti M, Situmorang Y E S, Handoyo Y D, et al. Implementation of IoT on PLC-Based Induction Motor Speed Control[C]//2023 International Conference on Converging Technology in Electrical and Information Engineering (ICCTEIE). IEEE, 2023: 118-123.



中国知网 https://www.cnki.net

[12] Dwiyaniti M, Adita F A, Muhammad N, et al. IoT Monitoring System for Real-Time Temperature, Vibration, and Motor Speed on Overhead Crane[C]//2023 6th International Conference of Computer and Informatics Engineering (IC2IE). IEEE, 2023: 198-202.

[13] Ottolini D, Zyrianoff I, Kamienski C. Interoperability and scalability trade-offs in open iot platforms[C]//2022 IEEE 19th Annual Consumer Communications & Networking Conference (CCNC). IEEE, 2022: 1-6.

[14] Nammouchi A, Aupke P, Kassler A, et al. Integration of AI, IoT and edge-computing for smart microgrid energy management[C]//2021 IEEE International Conference on Environment and Electrical Engineering and 2021 IEEE Industrial and Commercial Power Systems Europe (EEEIC/I&CPS Europe). IEEE, 2021: 1-6.

[15] Saha S, Sarkar J, Dhavala S, et al. quantile-Long Short Term Memory: A Robust, Time Series Anomaly Detection Method[J]. IEEE Transactions on Artificial Intelligence. 2024, 1-11. ISSN: 2691-4581.

[16] Chen H, Li X, Liu W. Multivariate time series anomaly detection by fusion of deep convolution residual autoencoding reconstruction model and ConvLstm forecasting model[J]. Computers & Security, 2024, 137: 103581.

[17] Altindal M C, Nivlet P, Tabib M, et al. Anomaly detection in multivariate time series of drilling data[J]. Geoenergy Science and Engineering. 2024, 237: 212778. ISSN: 2949-8910.

[18] Çokaj E, Gustad H S, Leone A, et al. Supervised Time Series Classification for Anomaly Detection in Subsea Engineering[J]. arXiv preprint arXiv:2403.08013, 2024.

[19] Bilakanti H, Pasam S, Palakollu V, et al. Anomaly detection in IoT environment using machine learning[J]. Security and Privacy, 2024: e366.

[20] Cho Y S, Kim S B. Supervised Contrastive Learning for Multisensor Signals Classification in Automobile Engine Manufacturing[J]. IEEE Transactions on Industrial Informatics. 2024, 1-13. ISSN: 1941-0050.

[21] Mahmud J S, Birihanu E, Lendak I. A Semi-supervised Framework for Anomaly Detection and Data Labeling for Industrial Control Systems[C]//Conference on Information Technology and its Applications. Springer, Cham, 2024: 149-160.

[22] Shao W, Wei Y, Rajapaksha P, et al. Low-latency Dimensional Expansion and Anomaly Detection empowered Secure IoT Network[J]. IEEE Transactions on Network and Service Management, 2023, 20(3): 3865-3879.

[23] 刘刚,叶立新,陈麒玉,等.基于多传感器信息融合的城市边坡监测数据异常事件检测[J].地质科技通报,2022,41(02):13-25.

[24] 陈佳乐,陈旭,景永俊,等.图神经网络在异常检测中的应用综述[J/OL].计算机工程与应用:1-20[2024-03-29].http://kns.cnki.net/kcms/detail/11.2127.TP.20240113.1222.004.html.



中国知网 https://www.cnki.net

[25] 李蕊汐. 基于自监督学习的多元时间序列异常检测算法研究[D]. 四川:电子科技大学,2023.

[26] 刘凯. 基于深度学习的加油站物联网异常检测技术研究[D]. 浙江:浙江工商大学,2023.

[27] 操余璐. 基于边云协同的异常检测系统的研究与实现[D]. 北京:北京邮电大学,2023.

[28] Zhao P, Ding Z, Li Y, et al. SGAD-GAN: Simultaneous Generation and Anomaly Detection for time-series sensor data with Generative Adversarial Networks[J]. Mechanical Systems and Signal Processing, 2024, 210: 111141.

[29] Hasani Z, Krrabaj S, Krasniqi M. Proposed Model for Real-Time Anomaly Detection in Big IoT Sensor Data for Smart City[J]. International Journal of Interactive Mobile Technologies. 2024, 18(3): 32. ISSN: 1865-7923.

[30] 王琪林. 基于深度学习的时序数据异常检测和预测方法研究与应用[D]. 四川:西南科技大学,2024.

[31] Nakamura T, Imamura M, Mercer R, et al. Merlin: Parameter-free discovery of arbitrary length anomalies in massive time series archives[C]//2020 IEEE international conference on data mining (ICDM). IEEE, 2020: 1190-1195.

[32] Zhao H, Wang Y, Duan J, et al. Multivariate time-series anomaly detection via graph attention network[C]//2020 IEEE International Conference on Data Mining (ICDM). IEEE, 2020: 841-850.

[33] Deng A, Hooi B. Graph neural network-based anomaly detection in multivariate time series[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(5): 4027-4035.

[34] Zhang Y, Chen Y, Wang J, et al. Unsupervised deep anomaly detection for multi-sensor time-series signals[J]. IEEE Transactions on Knowledge and Data Engineering, 2021, 35(2): 2118-2132.

[35] Tuli S, Casale G, Jennings N R. Tranad: Deep transformer networks for anomaly detection in multivariate time series data[J]. arXiv preprint arXiv:2201.07284, 2022.

[36] 郑梦思. 基于图注意力网络的共演进时序数据异常检测研究[D].华中科技大学,2022.

[37] Zhang Y, Li B, Zhang X. Deep Learning-Based Anomaly Detection for Time-Series Data in Industrial Control Systems[C]//2023 42nd Chinese Control Conference (CCC). IEEE, 2023: 8825-8829.

[38] Wang F, Yan M, Li Q, et al. A Multivariate Time Series Anomaly Detection Model Based on Spatio-Temporal Dual Features[C]//2023 International Conference on Networking and Network Applications (NaNA). IEEE, 2023: 416-421.



中国知网 https://www.cnki.net

[39] Yan P, Abdulkadir A, Luley P P, et al. A comprehensive survey of deep transfer learning for anomaly detection in industrial time series: Methods, applications, and directions[J]. IEEE Access, 2024.

[40] Kang H, Kang P. Transformer-based multivariate time series anomaly detection using inter-variable attention mechanism[J]. Knowledge-Based Systems, 2024: 111507.

[41] Wang Z, Pei C, Ma M, et al. Revisiting VAE for Unsupervised Time Series Anomaly Detection: A Frequency Perspective[J]. arXiv preprint arXiv:2402.02820, 2024.

[42] Zeng F, Chen M, Qian C, et al. Multivariate time series anomaly detection with adversarial transformer architecture in the Internet of Things[J]. Future Generation Computer Systems, 2023, 144: 244-255.

[43] Ding C, Sun S, Zhao J. MST-GAT: A multimodal spatial–temporal graph attention network for time series anomaly detection[J]. Information Fusion, 2023, 89: 527-536.

[44] Jeong Y, Yang E, Ryu J H, et al. Anomalybert: Self-supervised transformer for time series anomaly detection using data degradation scheme[J]. arXiv preprint arXiv:2305.04468, 2023.

[45] Xia F, Chen X, Yu S, et al. Coupled attention networks for multivariate time series anomaly detection[J]. IEEE Transactions on Emerging Topics in Computing, 2023.

[46] Nguyen T P Q, Phuc P N K, Yang C L, et al. Time-series anomaly detection using dynamic programming based longest common subsequence on sensor data[J]. Expert Systems with Applications, 2023, 213: 118902.

[47] Chen N, Tu H, Duan X, et al. Semisupervised anomaly detection of multivariate time series based on a variational autoencoder[J]. Applied Intelligence, 2023, 53(5): 6074-6098.

[48] Liu L, Tian L, Kang Z, et al. Spacecraft anomaly detection with attention temporal convolution networks[J]. Neural Computing and Applications, 2023, 35(13): 9753-9761.

[49] Matar M, Xia T, Huguenard K, et al. Multi-Head Attention based Bi-LSTM for Anomaly Detection in Multivariate Time-Series of WSN[C]//2023 IEEE 5th International Conference on Artificial Intelligence Circuits and Systems (AICAS). IEEE, 2023: 1-5.

[50] Ma M, Han L, Zhou C. BTAD: A binary transformer deep neural network model for anomaly detection in multivariate time series data[J]. Advanced Engineering Informatics, 2023, 56: 101949.

[51] Veličković P, Cucurull G, Casanova A, et al. Graph attention networks[J]. arXiv preprint arXiv:1710.10903, 2017.

[52] Wen Q, Zhou T, Zhang C, et al. Transformers in time series: A survey[J]. arXiv preprint arXiv:2202.07125, 2022.



中国知网 https://www.cnki.net

[53] Goh J, Adepu S, Junejo K N, et al. A dataset to support research in the design of secure water treatment systems[C]//Critical Information Infrastructures Security: 11th International Conference, CRITIS 2016, Paris, France, October 10–12, 2016, Revised Selected Papers 11. Springer International Publishing, 2017: 88-99.

[54] Mishra B, Kertesz A. The use of MQTT in M2M and IoT systems: A survey[J]. Ieee Access, 2020, 8: 201071-201086.

[55] Lee J, Lee J, Jeong J. Design and Implementation of Injection Data Preprocessing & Monitoring System Based on Node-RED[C]//2021 15th International Symposium on Medical Information and Communication Technology (ISMICT). IEEE, 2021: 19-23.



中国知网 https://www.cnki.net