中图分类号：TP391　　论文编号：1028716　23-SF002
学科分类号：085405

硕士学位论文

面向工业时序大数据异常检测方法的研究与应用

研究生姓名　　杨辰泽
专 业 类 别　　电子信息
专 业 领 域　　软 件 工 程
指 导 教 师　　陈 兵 教 授

南京航空航天大学

研究生院 计算机科学与技术学院

二〇二三年四月

中国知网　https://www.cnki.net

Nanjing University of Aeronautics and Astronautics
The Graduate School
College of Computer Science and Technology

Research and Application of Anomaly Detection Method for Industrial Time Series Big Data

A Thesis in
Computer Science and Technology
by

Chenze Yang

Advised by

Prof. Bing Chen

Submitted in Partial Fulfillment

of the Requirements

for the Degree of

Master of Software Engineering

April, 2023

中国知网 https://www.cnki.net

摘　要

随着 5G 和工业互联网 IIoT（Industrial Internet of Things）的发展，传统制造工业已经开始转型智能化制造。工业互联网自发展之初，就将数据驱动的优化闭环作为实现工业互联网赋能价值的关键，但在实际的生产环境中，传感器等数据采集设备受自身所处环境以及人为操作的影响，数据受噪声干扰严重，导致数据出现缺失、无效甚至误导的现象，严重影响工厂生产的判断。同时，工业大数据具有时序性、高维度、样本分布不均、价值密度低和闭环性等特点，尤其是工业中生产线的周期性运转和定期的数据采集，数据是具有强时序性的。如果能利用好这类时序数据，可以极大方便工厂通过整合相应时间段的相关数据来提取有价值的信息，提前预判和检测出异常，减少工厂计划外停机时间。

本文以工业互联网为背景，以工业生产设备时序数据为研究对象，针对工业大数据质量低下、异常检测精度不高等问题，提出了一种基于时序卷积网络的异常检测模型，设计并实现了一个提供工业数据清洗、异常检测可视化的数据分析系统，提高了工业数据质量和异常检测精度，并将其已应用于实际工业生产环境中。具体研究包括：

(1) 针对工业时序大数据的数据清洗问题，本文主要研究工业数据中冗余值的清洗和缺失值的填补。其中，对于数据冗余问题，采用基于“排序合并”思想的邻近记录排序算法 SNM（Sorted Neighborhood Method）对数据进行重复值检测，在保证相似重复记录检测率的同时降低了时间复杂度。针对缺失数据的填充问题，采用了长短期记忆网络 LSTM（Long Short Term Memory）预测填补缺失数据。通过实验验证，本文采用的填充方法相比于传统方法，在缺失率较高的情况下，有着更小的均方根误差，且在原始数据集上有着良好的拟合效果。

(2) 针对工业时序数据的异常检测问题，采用时序卷积网络 TCN（Temporal Convolutional Networks）进行建模，嵌入了注意力机制进行模型优化，通过调整数据特征的权重，降低无关维度对于模型训练效果的干扰。相比传统的时序模型，如循环神经网络 RNN（Recurrent Neural Network），其具有更加稳定的梯度，支持并行训练，占用内存更低，模型的异常检测精度更高，适合用作工业部署。

(3) 基于实际的工业生产场景，将本文所提出的基于时序卷积网络和注意力机制的异常检测模型部署在工业大数据分析平台的研发项目中，设计并实现工业大数据分析平台，实现了数据导入、数据清洗、异常检测、告警通知和数据可视化等功能，并将其应用在实际的工业设备监测中。

关键词：工业互联网；时序大数据；异常检测；时序卷积网络；注意力机制

中国知网 https://www.cnki.net

ABSTRACT

With the development of 5G and the Industrial Internet of Things (IIoT), the traditional manufacturing industry has begun to transform into intelligent manufacturing. Since the beginning of the IIoT and big data eras, the data-driven optimization closed-loop analysis has been regarded as the key to realizing the value of the IIoT. At the same time, industrial big data has the characteristics of time series, high dimensionality, uneven sample distribution, low value density and closed loop. Especially in the periodic operation of production lines and regular data collection in industry, the characteristics of time series are more obvious. If this kind of time series data can be used well, it can greatly facilitate the factory to extract valuable information by integrating the relevant data of the corresponding time period, predict and detect abnormalities in advance, and reduce the unplanned downtime of the factory.

Based on the IIoT, this paper takes the time series data of industrial production equipment as the research object. For the problems of low quality of industrial big data and low accuracy of anomaly detection, this paper proposes an anomaly detection model based on time series convolutional network, designs and implements a data analysis system that provides industrial data cleaning and anomaly detection visualization, improves the quality of industrial data and the accuracy of anomaly detection, and has been applied to the actual industrial production environment. The specific research content is as follows:

(1) For the problem of data redundancy in industrial data, the adjacent record sorting algorithm SNM(Sorted Neighborhood Method) based on the idea of "sorting and merging" is used to detect duplicate values of data, which ensures the detection rate and reduces the time complexity. For the filling problem of missing data, the long short-term memory network LSTM (Long Short Term Memory) is used to predict and fill the missing data. Through experimental verification, the filling method used in this article has better results than traditional methods.

(2) For the problem of anomaly detection in industrial data, temporal convolutional network(TCN) is used to model industrial time series problems. Compared with traditional time series models, such as recurrent neural network RNN(Recurrent Neural Network), it has a more stable gradient, supports parallel training, and occupies less memory. It is suitable for industrial deployment. At the same time, considering the interference of irrelevant dimensions on the model training effect, this paper embeds the attention mechanism for optimization, and improves the anomaly detection accuracy of the model by adjusting the weight of data features.

(3) Based on actual industrial production scenarios, the anomaly detection model proposed in this paper is deployed in the industrial big data analysis application system. At the same time,

中国知网 https://www.cnki.net

the industrial big data analysis application system is designed and implemented, which realizes the functions of data import, data cleaning, anomaly detection, alarm notification and data visualization, and has been specifically applied in the actual industrial equipment monitoring, and the accuracy has been improved after verification.

Keywords: Industrial Internet of Things; time series data; anomaly detection; TCN; attention mechanism

中国知网 https://www.cnki.net

目 录

第一章 绪论.....1
1.1 研究背景及意义.....1
1.2 国内外研究现状.....2
1.2.1 数据清洗技术.....2
1.2.2 时间序列分析的研究现状.....3
1.2.3 异常检测方法的研究现状.....4
1.3 论文研究主要内容.....5
1.4 论文组织结构.....6
第二章 相关理论和技术分析.....8
2.1 工业互联网介绍.....8
2.2 时序模型介绍.....9
2.2.1 时间序列概念.....9
2.2.2 工业时序数据特点.....9
2.2.3 时序模型的分类.....9
2.3 异常检测介绍.....10
2.3.1 异常检测概念.....10
2.3.2 异常的类型.....11
2.4 注意力机制.....13
2.5 本章小结.....15
第三章 工业大数据的冗余值清洗与缺失值填补.....16
3.1 引言.....16
3.2 数据清洗过程.....16
3.3 基于 SNM 算法的冗余值清洗.....17
3.3.1 问题背景.....17
3.3.2 SNM 算法模型清洗冗余值.....18
3.3.3 实验过程与结果.....19
3.4 基于 LSTM 模型的缺失值填补.....20
3.4.1 问题背景.....20
3.4.2 LSTM 算法模型填补缺失值.....22
3.4.3 实验过程与结果.....24
3.5 本章小结.....25
第四章 基于时序卷积网络的异常检测机制.....26
4.1 引言.....26
4.2 基于时序卷积网络的异常检测.....26

中国知网 https://www.cnki.net

4.2.1 TCN 网络捕获时间依赖.....26
4.2.2 注意力机制的结合.....28
4.2.3 利用 IAD-TCN 模型进行异常检测.....29
4.3 实验过程与结果.....29
4.3.1 数据集描述.....29
4.3.2 模型评价指标.....30
4.3.3 异常检测结果.....30
4.4 本章小结.....31
第五章 工业大数据分析应用平台的设计与实现.....32
5.1 引言.....32
5.2 系统架构和功能模块设计.....33
5.2.1 系统功能架构.....33
5.2.2 系统技术架构.....33
5.2.3 功能模块设计.....34
5.3 系统实现.....39
5.4 本章小结.....44
第六章 总结与展望.....45
6.1 总结.....45
6.2 未来展望.....45
参考文献.....47

中国知网 https://www.cnki.net

图表清单

图 1.1 Yahoo EGAD 框架 5
图 1.2 总体研究图 6
图 2.1 工业互联网平台架构[40] 8
图 2.2 时序模型分类 10
图 2.3 单点异常图 12
图 2.4 关联异常图 12
图 2.5 序列异常图 13
图 2.6 注意力机制本质思想 14
图 2.7 attention 值计算步骤 14
图 3.1 数据清洗过程原理图 16
图 3.2 数据清洗过程的总体流程 17
图 3.3 SNM 窗口运动过程图 18
图 3.4 不同窗口大小检测结果折线图 19
图 3.5 不同文本相似度阈值检测结果折线图 20
图 3.6 工业缺失数据分类 21
图 3.7 RNN 单元结构 22
图 3.8 LSTM 单元结构 22
图 3.9 遗忘门、输入门、输出门所属部分 23
图 3.10 缺失值填补 RMSE 对比 24
图 3.11 LSTM 在数据集上的预测效果 25
图 4.1 因果卷积图示 27
图 4.2 膨胀卷积图示 27
图 4.3 残差连接图示 28
图 4.4 IAD-TCN 系统模型 28
图 4.5 算法性能对比 31
图 5.1 工业数据系统 32
图 5.2 系统功能架构 33
图 5.3 系统技术架构 34
图 5.4 数据导入功能架构 35
图 5.5 数据清洗模块设计 36
图 5.6 清洗规则配置业务场景 36
图 5.7 数据清洗模型管理业务场景 38
图 5.8 数据清洗实施业务场景 38

中国知网 https://www.cnki.net

图 5.9 异常检测模块流程 39
图 5.10 清洗规则配置页面 39
图 5.11 用户自定义清洗规则 40
图 5.12 数据清洗模型管理 40
图 5.13 数据清洗实施页面 41
图 5.14 数据清洗实施 41
图 5.15 清洗结果记录页面 42
图 5.16 模型管理界面 42
图 5.17 异常检测结果页面 43
图 5.18 异常检测动态信息 43

表 3.1 常见的相似重复记录检测方法 18
表 3.2 不同窗口大小的相似重复记录检测结果 19
表 3.3 不同文本相似度阈值的相似重复记录检测结果 20
表 3.4 不同缺失值填补方法的简单比较 22
表 4.1 水泵机组数据集描述 30
表 4.2 不同算法的性能对比 31
表 5.1 系统使用的主要技术 34
表 5.2 多种数据源导入支持情况 35
表 5.3 过滤规则介绍 37

中国知网 https://www.cnki.net

注释表

k	相似重复记录占数据表中所有相似重复记录的比例	N_d	算法检测相似重复记录的数量
N	数据表中相似重复记录的总量	S	窗口大小
u	文本相似度阈值	$RMSE$	均方根误差
$score(h_s, h_t)$	注意力分数	h_s	输入的隐藏状态
h_t	输出的隐藏状态	$a_{t,s}$	注意力权重
c_t	上下文向量	At_{vector}	输出向量
$m_{residual}$	窗口内点的预测误差	$score_{window}$	窗口异常分数
y_t	真实值	$y_t^{'}$	模型预测值
ΔC	基准值	t_0	窗口的开始时间
t_{end}	窗口的结束时间	$score_{point}$	点的异常分数
Pr	精度	Re	召回率
F_1	F1 分数	Acc	准确率
TP	真阳性样本	FP	假阳性样
TN	真阴性样本	FN	假阴性样本

中国知网 https://www.cnki.net

缩略词

缩略词	英文全称
IIoT	Industrial Internet of Things
EM	Expectation Maximization
MI	Multiple Imputation
KNN	K-Nearest Neighbor
AR	Autoregressive
ARMA	Autoregressive moving average
MA	Moving Average
ARIMA	Autoregressive Integrated Moving Average
RNN	Recurrent Neural Network
GRU	Gated Recurrent Unit
LSTM	Long Short Term Memory
BiLSTM	Bi-directional Long Short Term Memory
LOF	Local Outlier Factor
IaaS	Infrastructure as a Service
PaaS	Platform as a Service
SaaS	Software as a Service
SVM	Support Vector Machine
SNM	Sorted Neighborhood Method
TCN	Temporal Convolutional Networks
IAD-TCN	Temporal Convolutional Networks for Industrial Anomaly Detection

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景及意义

制造业的发展是国家科技水平和综合实力的重要标志，也是国民经济高速开展的发动机，同时也是衡量一个国家核心竞争力的重要标准之一。伴随着 5G 和工业互联网 IIoT（Industrial Internet of Things）的发展，传统的流程型制造工业，如石化、化工、造纸、水泥、有色、钢铁、制药、食品饮料等已经开始转向智能化制造。工业互联网自发展之初，就将数据作为核心要素，将数据驱动的优化闭环作为实现工业互联网赋能价值的关键。为提高工业的盈利效率和转型智能制造，大量的生产设备和机械投入工业互联网，数据变得越加重要，用于采集多特征数据的集成传感器数量将大幅增加，工业大数据来源将越来越多元化，呈爆发式增长趋势。因此，对这些海量数据的分析与应用逐渐成为了一个技术难题。另一方面，工业生产设备随时存在着不同的异常和故障，导致其完成不了工厂预计好的任务，甚至直接或间接引起严重事故，造成人员伤亡和重大财产损失。因此，保证工业生产设备安全稳定的运行，及时对设备做出系统评估和检测，排除潜在异常，是关乎人民生命财产安全的重要问题。

由于在实际的工业生产环境中，传感器等数据采集设备所处环境恶劣，并可能被人为操纵产生无效甚至误导的数据，严重影响工厂最后的判断，尤其是在安全设备的监测环节，对数据的正确性要求很高。工业大数据覆盖的数据范围广泛，本身还具有多维时序性、数据样本分布不均、生产闭环且价值密度低等特点。考虑到以上问题，这就要求工厂能够高效合理地利用工业数据进行分析和判断，规避计划外风险、提高生产效率、降低成本。从本质上来说，其实是对工业数据质量提出了更高的要求。因此，如何解决数据“低质性”以及高效检出生产环境中的异常数据，满足对早期机器健康预测的需求，减少计划外停机时间，提高工厂的安全性以及降低人工维护成本，都是当前工业领域中面临的重要挑战。

目前，在实际的工业生产中，数据采集、数据清洗、数据分析与异常检测是工业数据驱动生产制造的三个重要阶段，为后续的工业决策和优化奠定着基础。

在数据采集阶段，由于大量的生产设备和机械投入工业互联网使用，这些大规模的设备在生产运行时，传感器数量多、采样频率高且工艺流程复杂，会产生海量的生产数据。在这个过程中，常常会由于传感器故障、设备停机或人为操作失误而造成数据缺失、存在冗余值和异常数据等情况。

面对工业传感器等设备采集上来的海量高维数据，前期有效的数据清洗工作是十分重要的，它为后续进一步的数据分析和异常检测提供更高质量的数据支撑，使工业的判断结果更加准确可靠。传统的数据清洗方法大多是基于数理统计，如均值插补、拉格朗日法等方法去解决缺失值填补；暴力删除和“两两比较”等方法去解决冗余值问题。然而近年来机器学习的广泛应用，能很好的利用学习模型去高效完成数据清洗工作，发现海量数据中所存在的“脏

中国知网 https://www.cnki.net

数据”，对其进行清洗处理，使其数据质量得到提升和保障。

异常检测在数据分析领域有着十分广泛的应用，也是机器学习中一个非常重要的子分支。简单而言，异常检测就是识别与正常数据不同的数据，与预期行为差异大的数据，如如信用卡欺诈，工业生产异常，网络流里的异常（网络侵入）等问题，针对的是少数的事件。此处主要考虑到以下两点：首先，面对完整庞大的数据集，异常发生频率是很低的。另外，相对于标准正常的数据，异常值的数据分布其实是显而易见的。根据不同的数据特征数量，可以将异常检测区分为单变量（univariate）和多变量（multivariate）异常检测问题。信息化时代加速发展的背景之下，负责监测工业设备的传感器所采集的数据，可作为工业大数据集合。当考虑到工业生产的需求和未来场景应用价值时，需要更好的掌握生产设备的实时状态，因此高效可靠地判断其是否处于异常状况是十分重要的。

在工业时序数据异常检测阶段，数据庞大且指标多维，数据堆积快速，而异常数据又是海量数据中的少数。因此，传统的人工判断往往是被动式接收信息，处理和分析工作变得愈加不切实际和低效，无法满足工况多变的实际需求。同时，工业中生产线的周期性运转和定期的数据采集，数据是具有强时序性的。然而在现有的研究中，无论是在金融还是气象领域，时间序列数据的研究探索与开拓运用都是领先于工业方面的。因此，如果能利用好这类工业时序数据，可以更好地整合相应时间段的相关数据来提取有价值的信息。

考虑到上述问题，本文以工业时序数据作为研究对象，基于机器学习，对工业传感器等采集设备收集上来的初始数据进行数据清洗，将原始的低质数据转化为较高质量数据，为后续的异常检测工作提供有效可靠的数据支撑。同时，本文基于时序卷积网络模型和注意力机制，采用数据真实值和预测值之间的误差进行异常的判断，找寻时间序列下数据的底层特征，调整多维数据中的特征权重，高效且可靠的检测出工业时序数据中的异常。相比传统的异常检测，本文所提出的模型不仅更加符合工业生产数据的特点，还能保证较高的检测准确度。最后在实际的工业大数据分析平台中验证了模型的可用性。

1.2 国内外研究现状

1.2.1 数据清洗技术

数据清洗归属于数据预处理工作。一般情况下，数据预处理主要包括数据清洗、集成、转换、离散和归约等操作。数据清洗的定义是指在数据分析之前，为了提高数据的质量，应用数据分析的软件或者方法，把低质量的数据样本通过一系列的处理转化提升成为高质量的数据样本。当前，冗余数据的清洗和缺失数据的填补是数据清洗研究工作的两个重要应用方向。

对于工业时序数据的冗余状况，一般是指相似重复记录。相似重复记录是指对于现实世界中同一个实体，在各个数据源数据库或平面文件中存储时，由于可能出现格式错误、结构不一致、拼写差异等问题导致数据库管理系统没有正确识别而产生的两条或者多条不完全相

中国知网 https://www.cnki.net

同的记录[1]。消除重复记录的基本思想是“合并和消除”，但由于工业数据量庞大，传统的检测算法常常因为时空复杂度过高或者检测效果不佳，无法满足工业需求。文献[2]通过字段匹配算法来确定两个字段值是否可替换，并用实验对它们的性能进行了验证。Smith 和 Waterman [3]在 1981 年提出了著名的 Smith-Water Man 算法，引入间隙（Gap）以及罚值(Penalty)的概念，确定两个字符串的匹配程度。Monge 等人[4]提出用优先队列来代替固定大小的窗口，优先队列的每一项代表的是一个重复记录聚类，但存在识别精度不高的问题。朱等人提出了动态优先队列聚类算法和合并逆序算法, 尽可能使相似重复的属性值聚为同一类, 但这也增加了属性值类的误识别率。

对于缺失数据的插补，最经典的算法还是 EM（Expectation Maximization）算法[5]，通过计算期望值最大化的方法来检测出缺失的数据, 但如果数据集中缺失数据的所占比例较大时，会导致估计值与真实值之间的偏差过大。随着学者们对缺失数据不断地深入研究，Little R 等人在对简单插补方法研究的基础上，通过对该方法的改进以及扩展，提出了一种多重插补算法 MI（Multiple Imputation）[6]，这种算法现已经被广泛的应用在多个领域，如 Anand V 等人[7]提出使用多重插补法去填补市场金融领域的缺失数据，并阐述了常用的缺失数据处理方法，指出各方法的优缺点。随着机器学习的发展，考虑到数据项之间的相似性度量，Qi X 等人[8]提出了基于 k-近邻算法（K-Nearest Neighbor，KNN）来填充缺失数据，在反复的实验过程中，得出了最终结论，即 k-近邻算法下的缺失值填补效果优于常规的均值填补法，然而随之带来的问题是算法最终的性能效果受 k 值波动影响。在之后的研究中，伴随着计算机计算能力和神经网络的发展，通过训练神经网络从而去预测缺失数据也成为了一种方法。Kyrtsoglou 等人[9]对含有缺失值的天气预报数据进行分析，并构建了时序模型进行数据预测, 填补缺失的天气数据。HS Hipper[10]提出了 ARIMA 模型与多层神经网络相结合的混合预测系统，来进行数据的预测和缺失值的填补。Sridevi[11]等人提出了自回归模型(AR，Autoregressive-model-based)，这种方法可以有效估计时间序列中的缺失项。该文的作者对其性能优势描述为，在面对诸如大段时间空白下的或者某时间节点下的样本丢失、缺少，AR 模型可以表现出比 k-近邻算法插补效果更加强势与亮眼的表现。

1.2.2 时间序列分析的研究现状

时间序列数据是一组按时间顺序排列的观测序列。时间序列的数据分析是数据挖掘领域的研究热点之一, 尤其在时序预测问题上, 已经被综合全面应用在气象播报[12]、金融经济[13]、医学检测[14]、数字化交通[15]、机械等多个领域[16]。1970 年，国际著名统计学家 G.E.P.BOX 和 G.M.JE-NKINS[17]合作出版了《时间序列分析-预测和控制》，该书阐述了关于时序模型的原理说明、估算判断、判别诊断、预报推测等等，为时间序列分析的建模和社会方面的应用以及其未来走向做出了有效关键的指示。

在时间序列的分析问题中，关键在于从时序数据中挖掘出时间序列中潜在的趋势[18]，具体可分为回归模型与机器学习方法两大类。回归模型方法，主要适合用于平稳时间序列，

中国知网 https://www.cnki.net

例如：自回归模型（Autoregressive，AR）、自回归滑动平均模型(Autoregressive moving average，ARMA）、移动平均模型（Moving Average，MA）和差分整合移动平均自回归模型（AutoregressiveIntegratedMovingAverage，ARIMA)[18]。然而，时间序列的方差、均值、频率并非一成不变，而是受时间影响不断波动，这也使得时间序列的不稳定进一步导致了回归模型方法的表现力大打折扣[19]。随着机器学习的发展，在 2002 年，钟颖等人[20]将遗传算法与 BP 神经网络相结合，应用于时间序列的预测。此外，一些序列预测模型被用于处理序列数据，如隐马尔可夫模型[21]和 Kalman 滤波[22]，但它们仍然缺乏学习数据中长期隐藏的相关性的能力。近年来，递归神经网络（Recurrent Neural Network，RNN）被广泛拿来解决长期预测任务的问题[23]，但由于其自身结构的缺陷，在较长的时间序列任务上容易发生梯度爆炸或消失梯度。这使得长期预测时间依赖性变得困难。随着门控循环单元网络（Gated Recurrent Unit，GRU）的引入，长短期记忆（Long Short Term Memory，LSTM）网络在某种程度上缓解了 RNN 中消失和爆炸的梯度问题[24]。同时，双向 LSTM（Bi-directional Long Short Term Memory，BiLSTM）作为递归神经网络的扩展，在一定情况下取得了一些良好的效果[25]。

随着技术的发展，工业界也涌现出了很多优秀的时间序列框架。在 2017 年，FaceBook 自研了时序预测算法 fbprophet，并开源了用于单变量时间序列预测的框架 Prophet[26]。该模型所实现的是一个基于可加模型的时间序列数据预测过程，拟合了年度、周度、日度的季节性周期变化及节假日效应的非线性趋势[26]，这种方法在可获得高准确度预测的同时，只需要做不太复杂的参数拟合。然而，这种方法的局限性在于当数据集具备周期性与趋势性时，预测效果极佳，反之则不然。Amazon Sagemaker 集成了 Deep AR[27]，这是一种基于 LSTM 的时间序列预测算法，适用于高通量时间序列预测。该方法不仅能给出预测结果，还能给出结果的置信区间。

1.2.3 异常检测方法的研究现状

传统的异常检测方法一般分为基于统计的方法、基于距离的方法以及基于密度的方法[28]。对于基于统计的异常检测方法认为异常数据样本的坐标本身呈现直观的偏移，其余标准数据的分布和占比普遍具有规律性和稳定性。例如，高斯分布[29]下异常数据样本的判定依据平均值加减三倍标准差外的数据分布，数值上通常为 0.2%附近。使用这种方法存在的问题是，均值和方差本身都对异常值很敏感，因此如果数据本身不具备正态性，就不适合使用这种检测方法。除此之外，还有最简单的箱线图、3σ 准则等。这些基于统计的方法简单高效，但处理高维数据困难。关于基于距离的检测方法，需要提前假定，在正常点的附近通常存在大量的近邻点，相比之下，当某个点距离其他所有点的距离都非常远时，系统会通过计算周遭距离后判定此点出现异常情况[30]。比如熟知的 KNN、K-Means，都可以通过计算距离来做异常检测。基于密度的方法是针对所研究的点，计算它的周围密度和其临近点的周围密度，基于这两个密度值计算出相对密度，作为异常分数。即相对密度越大，异常程度越

中国知网 https://www.cnki.net

高。如 Tian H 等人[31]提出了一种基于局部离群点方法 LOF（Local Outlier Factor）的云计算自适应异常检测方案，取得了不错的检测效果。

随着人工智能在各个领域的广泛应用，异常检测的方法也随之更迭。周志华等人提出了孤立森林算法，并利用异常样本与其他样本之间的疏离程度来检测数据的异常值[32]。Yang K 等人[33]将支持向量机 SVM 用于物联网设备的异常检测，通过于高斯混合模型相结合，在各物联设备的异常检测中实现了预测时间和空间的显著加速，而不牺牲异常检测精度。P Yang 等人[34]提出了一种基于 KNN 的高效离群点挖掘算法，考虑属性之间的重要性和相关性，通过定义相关矩阵可以更准确地找到异常值，相比传统的 KNN 算法更为有效。杨月麟等人[35]为了解决网络流量数据的远程依赖性及数据集样本不平衡导致的长尾效应等问题，基于视觉 Transformer 提出一种网络流量异常检测模型，在提高检测性能的同时减少了检测时间。针对工业互联网中激增的传感器数据异常检测，D Wu 等人[36]提出了一种长短期记忆网络和高斯贝叶斯模型结合的办法，通过 LSTM 对未来时间点数据的强大预测能力，利用高斯贝叶斯模型的预测误差来检测异常值。

与此同时，工业界也产生了许多优秀的异常检测框架。在 2015 年，Yahoo 开源了可扩展通用的异常检测框架 EGADS[37]，用于自动检测大规模时序数据中的异常，如图 1.1 所示。

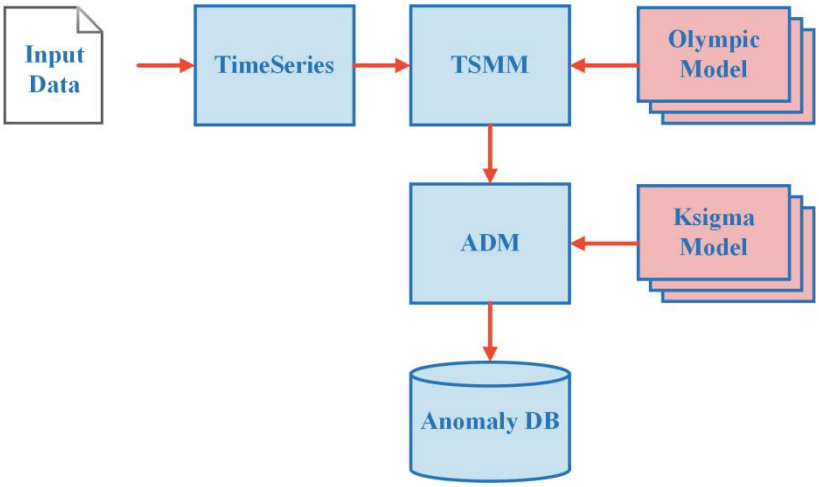


图 1.1 Yahoo EGAD 框架

EGADS 主要包括以下三个模块：报警模块（AM）、时间序列建模模块（TSMM）以及异常检测模块（ADM）。给定一个时间序列，TMM 组件模拟产生时间序列，由 ADM 和 AM 组件进行消费处理，分别计算误差并过滤不显著异常，最终把检测出的异常点写入 DB。在 2019 年，X Zhang 等人[38]提出了基于迁移学习和主动学习的跨数据集异常检测框架，可以有效地在不同时间序列数据集之间进行迁移，用户只需进行少量的人工标注，即可达到高精度的异常检测。

1.3 论文研究主要内容

本文的主要研究内容主要是对海量的工业数据进行数据清洗工作，提高初期数据质量，

中国知网 https://www.cnki.net

再对其进行异常检测分析工作，提高异常检测的精度和可靠性，最后设计并开发工业大数据分析平台，提高数据管理效率，如图 1.2 所示。

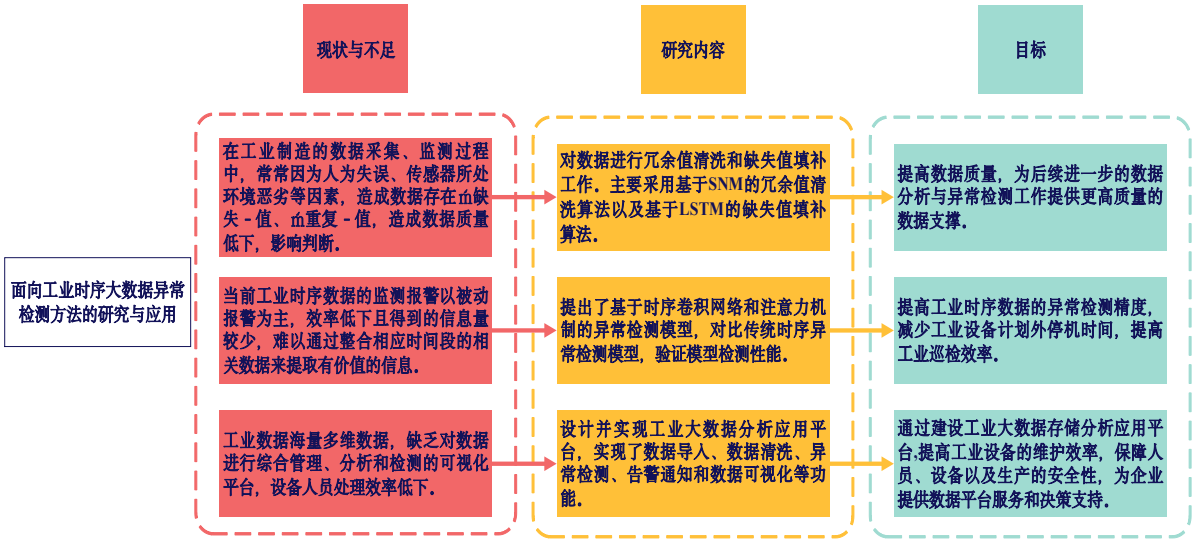


图 1.2 总体研究图

具体工作如下：

(1) 对前期工业传感器所采集上来的数据进行清洗工作，解决工业数据低质性问题。主要集中在冗余值的清洗和缺失值的插补。对于冗余值的清洗，选用稳定的邻近记录排序算法 SNM（Sorted Neighborhood Method），在保证相似重复记录检测率的同时降低了时间复杂度。对于缺失值的填补，考虑到长时序的建模问题，以及拟合数据原本趋势，采用基于深度学习的 LSTM 模型。

(2) 分析时序数据的特点和异常分类的方式，对比传统时序异常检测模型中存在的问题，如泛化能力不足、精度低、和无法捕捉长期的时间依赖等。提出了基于时序卷积网络和注意力机制的异常检测模型以改进当前所存在的问题。

(3) 所提出模型在工业大数据分析平台中的应用。平台是 B/S 结构的应用系统，采用 J2EE 多层体系架构提高系统的稳定性、可靠性和可扩展性。功能主要包括数据导入、数据清洗、异常检测、告警通知和数据可视化等。系统对真实的实际工况设计了相应的数据库，在完成数据清洗之后，系统会使用本文所提出的基于时序卷积网络和注意力机制的异常检测模型进行异常值的检测。通过与实际工况所设定的阈值比较，确定是否需要进行预警和巡检排查。系统在实际的工业设备监测中得到了具体应用，经验证提升了异常检测的准确度。

1.4 论文组织结构

论文分为六个章节，各章节具体内容如下：

第一章：绪论。首先介绍了工业互联网背景下，工业时序大数据异常检测的研究背景、研究意义以及与本课题相关的国内外研究现状。然后概述了本文的主要研究内容以及全文的章节安排。

中国知网 https://www.cnki.net

第二章：相关理论和技术分析。主要阐述了工业互联网平台的概念，介绍了时序模型，包括时间序列的概念、时序数据的特点以及常见的时序模型分类。然后介绍了异常检测的概念以及常见的工业异常类型，最后分析了注意力机制的原理和过程。

第三章：工业大数据的冗余值清洗与缺失值填补。这一章节主要包括两部分：冗余值的清洗和缺失值的填补。分别先介绍了冗余值的概念，所采用冗余值检测算法的原理和细节，以及工业场景下的适用性对比；其次介绍了缺失值填补的概念，所采用缺失值填补方法的原理和细节，以及工业场景下的适用性对比。最后在真实的数据集上，进行算法验证测试。

第四章：基于时序卷积网络的异常检测机制。这部分主要概述了所提出模型的整体设计构思，架构详细情况以及其理论支撑，叙述了模型如何检测出工业时序数据中的异常，对其检测原理进行了分析。最后在真实的工业传感器采集数据集上应用了模型，并选取相应的评价指标，评估所提出的异常检测模型。

第五章：工业大数据分析应用平台的设计与实现。作为系统的设计与应用章节，介绍了工业大数据分析应用平台的功能架构以及技术架构，对各个功能模块进行了系统阐述。最后展示了平台系统的运行效果，验证了本文所采用算法模型的可用性。

第六章：总结与展望。总结了本文的整体工作和所取得成果，并对后续的工作方向进行了展望，同时也提出未来可改进之处。

中国知网 https://www.cnki.net

第二章 相关理论和技术分析

2.1 工业互联网介绍

“工业互联网”的概念最早由通用电气于 2012 年提出[39]：“工业互联网，就是把人、数据和机器连接起来。”这意味着，人、数据、机器是工业互联网的三个关键本质要素。

工业互联网的本质和核心是通过工业互联网平台把设备、生产线、工厂、供应商、产品和客户紧密地连接融合起来，让数据“流动”起来[40]。工业互联网并非互联网在工业产品上的一个简单使用，它存在丰富的内涵和外延。其中一个标准的工业互联网平台系统应该具有以下四个层级：即边缘层、IaaS（Infrastructure-as-a-Service）、PaaS（Platform-as-a-Service）和 SaaS（Software-as-a-Service）。如图 2.1 所展示的内容。工业互联网平台需要大量异构多源的数据样本提供支撑，这样庞大的数据汇集，可以方便后续工业行为的定义、剖析以及运用。接下来，数据的深度挖掘与分析处理，离不开各类仿真软件工具技术的帮助，无论是 AI（Artificial Intelligence）、大数据的算法模型还是工业智能和数字孪生技术，某种程度上都可以为下一步应用场景提供科学化、高效化的决策与查验。为了全面提升工业数字化管理水平，不断提高使用者决策科学性和工作效率，构建体量庞大、质量过关、具有成熟开发条件的模型库、知识库是非常有必要的。这样可以充分利用经验知识组织和知识开发技术，提高工业相关的知识复用能力。最后，聚焦工业 APP、云化软件高质量融合创新，努力研发推广各场景下计算机辅助设计、仿真、计算等工业工具软件，构建高端产业生态体系，促进企业提质增效。

由此可见，在互联网创新发展与新工业革命处于历史交汇期的当下，工业互联网成为新工业革命的关键支撑和深化新一代信息技术与制造业智能融合的重要基石。而在工业互联网承载数据汇聚、信息交互、产品服务交易和价值共创的同时，其必将发展成为产业链的“新链主”，生态核心资产属性也必然强化。



图 2.1 工业互联网平台架构[40]

中国知网 https://www.cnki.net

2.2 时序模型介绍

2.2.1 时间序列概念

通常，在相等间隔的时间段内，按照既定的采样频率对一段过程进行观测得到的由时间顺序排列的序列，称之为时间序列（Time series）[12]。对于上述的相等间隔的时间段，根据不同的实际场景对应出不同的单位大小。故在获取此类时间序列数据样本时，可将其视为离散变量加以剖析处理。时间序列分析有助于不同领域企业做出明智高效的决策，包括经济、天气预报、电子计算机、宇宙航空、股票价格、零售销售等应用科学与工程学。

时间序列变量的方差并非一个简单的常数亦或线性函数，长期上它无法趋于某个单一数值，这体现出时间序列不具备可控的稳定性。另外，对于时间序列数据的分析难度还体现在其依照时间递推所呈现的波动性。

因此，由于时间序列的复杂性和独特性，需要针对其特点采用不同的方法进行分析，从传统的统计学方法到机器学习方法再到最近的深度学习方法，国内外研究人员已经做了大量的工作。

2.2.2 工业时序数据特点

在实际工业生产中，海量、异构且多源的数据是每分每秒动态产生的，这样的工业场景包括，油品温度、密度的定时定点测定与计量，污水处理过程中废液、废渣、废气的组分测定与排放量测量，各类过程流体机械诸如压缩机、泵与分离机的功率、转速以及压力监测等等。以上这些工业过程，都需要监控设备的辅助监测从而保证设备能够安全稳定的运转，为企业不断产生带动各项效益。而在当下的智能化发展过程中，信息化技术不断促进产业变革，工业设备的监测需求与日俱增，由此各类高精度传感器推陈出新，实时捕获、定期采集的数据样本被称之为工业设备时序数据[41]。为保证整个生产过程能够平稳进行，对该类数据样本进行监测分析，故障预警和后续维护是必不可少的。

具体而言，相比广泛存在的互联网数据，工业时序数据主要有以下特点：

(1) 数据由于存在时间、空间和属性等多个方面特征，其呈现出多维的时空动态关联的复杂特性。

(2) 由于各种应用场景的不同，数据的物理意义不尽相同，其传输采集和存储的格式也是多种多样的。这意味着工业时序数据采集样本具备多维性和异构性。

(3) 考虑到信息化工业最终服务的对象仍是经济价值的创造、转化与实现。因此对于各项监测数据例如航空航天，核电，轨道建设等核心行业，其把控、预测都需要做到高精度、高准度以及高强度。

2.2.3 时序模型的分类

时序模型可以分为基于统计学方法和基于机器学习方法[18]，具体分类如图 2.2 所示：

中国知网 https://www.cnki.net

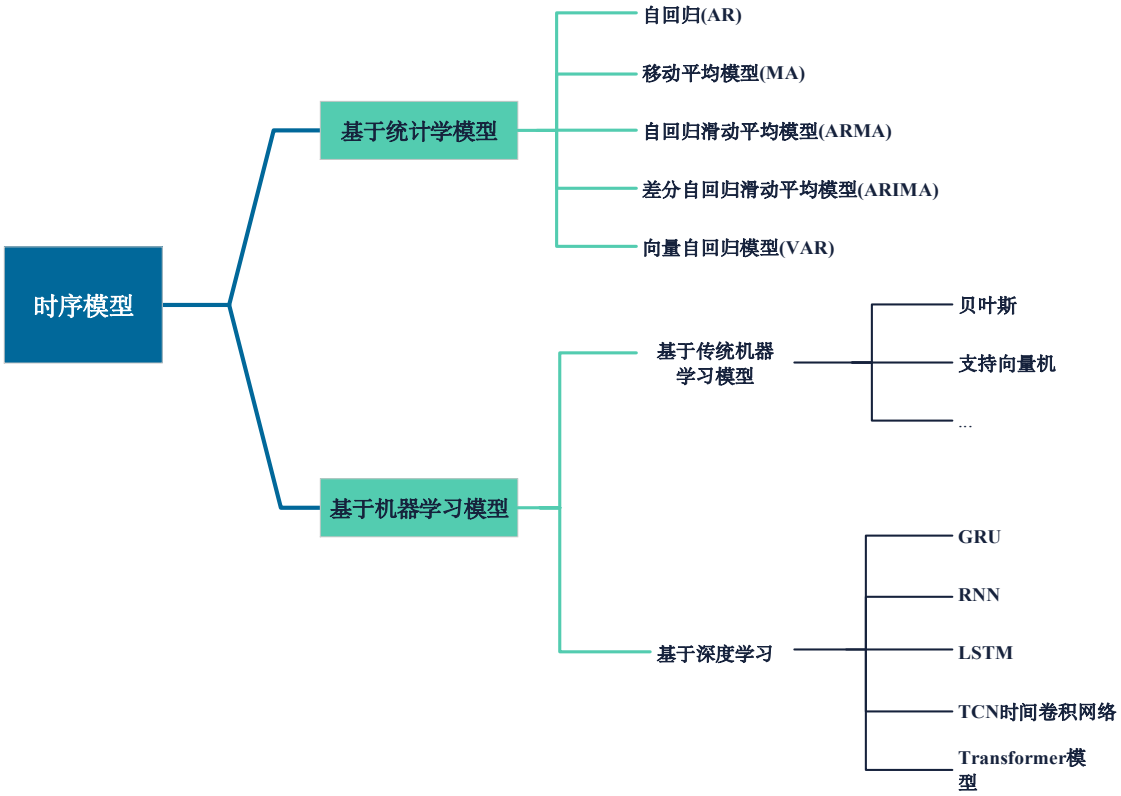


图 2.2 时序模型分类

基于统计学的时序模型，包括了 AR(Auto Regressive Model)自回归模型、MA(Moving Average Model)移动平均模型、ARMA(Auto Regressive and Moving Average Model)自回归移动平均模型、ARIMA(Auto Regressive Integrate Moving Average Model)差分自回归移动平均模型等等模型[17]，此外还包括卡尔曼滤波、马尔科夫链、指数平滑等模型。而另一种预测方法是使用传统机器学习模型，包括了贝叶斯、支持向量机 SVM 等。本文所提出时序模型是基于深度学习的，故不再赘述。

2.3 异常检测介绍

2.3.1 异常检测概念

当下，关于异常的学术定义并没有统一的标准。人们通常采用的是 Hawkhins D.M.给出的解释，异常是在数据集中偏离大部分数据的数据[42]。统计学、信息理论以及数据挖掘、机器学习等方向领域为异常检测方法相关学说原理提供了主要支撑。在机器学习领域中，数据的标签通常指的是实际数据的标识信息，这种信息是多样的，可以是实际数据的目标值、属于什么类别、是否正常或处于何种工况等等。考虑数据样本是否具有标签，是机器学习算法分类的一大衡量标准，通常主要分为监督学习和无监督学习两大类。而对于异常检测来说，标签通常指的是正常及异常两种类别。获取标签的过程是很耗时耗力的，因为通常标签需要专家手动标注。尤其对于海量的多维工业数据而言，人工标注或者获取异常数据的标签往往

中国知网 https://www.cnki.net

是一件困难的事，特别是想要训练数据中包含所有可能出现的异常类型[43]。因此，通常来说对于有限的异常类型且带标签的异常数据足够多的情况，才会采用监督学习的方法进行精确的定位，即模型输出为确定的某类异常或正常。而对于异常类型过多，同时带标签的异常数据又较少的情况，可以采用无监督学习的方法，即输出为正常或异常。

（1）基于监督学习的异常检测

监督学习的异常检测要求数据集中每一个数据都贴上标签，正常或异常。然后选择合适的模型，用数据集进行训练，得到最优的参数。常见的如支持向量机 (Support Vector Machine, SVM)、决策树 (Decision Tree)、朴素贝叶斯 (Naive Bayesian)和逻辑回归 (Logistic Regression)等。

（2）基于无监督学习的异常检测

无监督异常检测适用于既有正常又有异常的数据集，且数据集不需要贴上标签。在训练时只需将数据输入到模型中，获取一个异常分数；在测试时，如果输入到模型的测试数据取得的分数大于异常分数，则判定异常，反之则判定为正常。整体可以划分为统计模型、深度学习模型以及预测模型。

现如今，异常检测方法已经广泛应用于多个领域。如网络的入侵检测[44]、金融的风险控制[45]、工业的控制管理[46]、无线传感器网络监测[47]等。通过利用异常检测技术，可以识别出网络通信过程中的恶意入侵行为、分析股票市场中的异常波动、优化工业的设备控制和维护、监测无线传感器的实时采集数据，做好预测性维护工作。当然，数据的性质以及时序数据，文本数据是否涉及连续属性数据等一系列问题在不同的生产应用场景中，其应对的风险和问题是全然不同的。此外，标签的设定也需要对应领域专家的指导，这里需要考虑标签在不同数据样本类别下的不同，即标准的正常数据与异常数据的分类标记，以及面临异常时的输出标记和异常分数的制定设置。同时，异常检测的时效性也是一个重要考量指标，其对应的是异常检测的在线及离线方式。总之，关于异常检测的方法选择和如何具体实施应用往往受限于不同生产场景下的实际需求。

2.3.2 异常的类型

异常检测主要针对的异常类型包括单点异常、关联异常以及序列异常等[43]。具体如下：

(1) 单点异常：对比之下某个数据样本较其余样本整体来看，单点数值极为突出，并且从数据整体来看，该点处于异常状态时，这一类个别的数据点就被称作单点异常，如图 2.3 所展示的情况，这类异常往往是大多数检测研究的主流重点，也通常被认为是比较单一不太复杂的异常情况。

中国知网 https://www.cnki.net

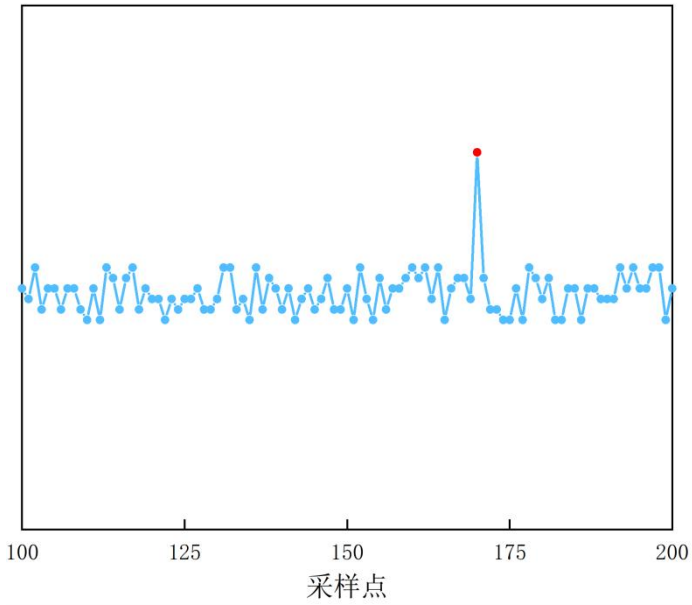


图 2.3 单点异常图

(2) 关联异常：当数据样本在既定的上下文中产生了异常表现，则称为关联异常（也称为上下文异常或条件异常）。这里需要说明的是，此处的上下文属性不同于往常的定义，具体是用来表明该数据样本位于整个序列的位置意义，即被用来作为订阅条件的属性。数据样本的经纬度在空间数据集中是它的上下文属性，而数据样本的时间则是时间序列数据样本的上下文属性。如下图 2.4 所示，如果只考虑 B 点的数据大小，则其在整个数据空间中本身没有异常（点 B 数值大小近似于正常状态下点 A 的数值大小），但考虑其处于泵体输量下降的工况下，并与其前后的数据对比，则判断该点为上下文异常。

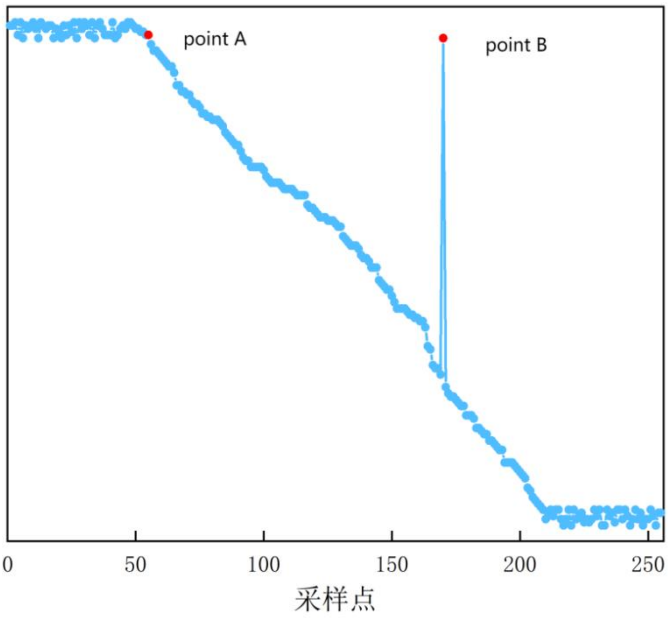


图 2.4 关联异常图

中国知网 https://www.cnki.net

(3) 序列异常：也被称作子序列异常和聚集异常。这表示，可能存在部分点的集合同时出现时较数据样本整体判定为异常，但聚焦于其中某个点较这个单一集合来看并非异常的情况。如图 2.5 所示。如下图所示，圆圈范围内的点集合被定义为异常子序列，这个单一集合极大程度上影响了温度这个物理量的测量范围与波动趋势。也可以想象一个拼写错误的单词或排列错乱的句子，每一个字母或文字都不是异常，但组成的词句是异常。

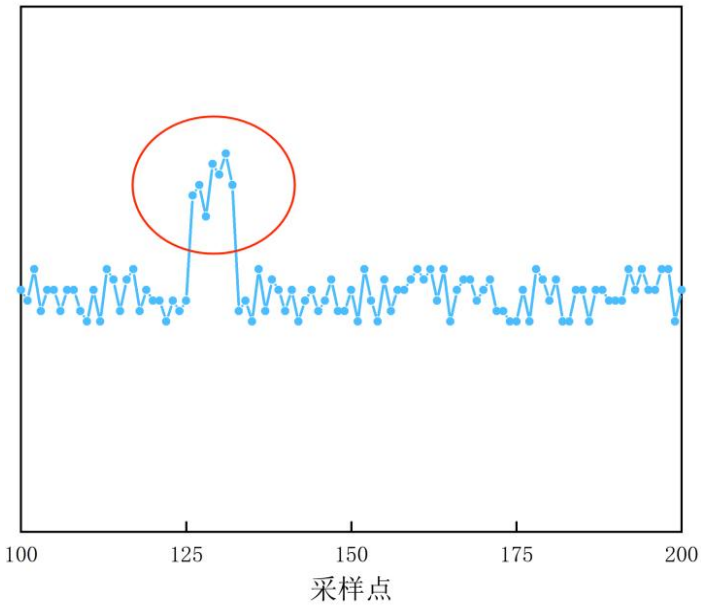


图 2.5 序列异常图

2.4 注意力机制

注意力机制是伴随深度学习快速发展的又一核心产物。从本质上来说，注意力机制目的就是为了实现信息处理资源的高效分配[48]。早在 1995 年，注意力机制出现在了图像视觉领域[49]，作用就是选择性地调整视觉对网络的处理，优化以往传统的视觉搜索方法。在 2014 年，google mind 团队将循环神经网络（RNN）模型与 attention 机制相结合[50]，将注意力集中在图片中特定的部分，缩短了处理数据的时间并且保留了重要信息。自此之后，注意力机制开始流行起来。Bahdanau 等人[51]将注意力机制扩展运用到自然语言处理中，大大提高了翻译精度。在 2017 年，Vaswani 等人提出了 Transformer 模型[52]，将注意力机制推向了研究热潮。

注意力机制的生物借鉴来源与人工神经网络一样，皆为关注人类在观察、感知物体时所反馈的内在选择。即人类并没有刻意判断和分类第一视觉所带来的信息冲击，但在信息接收抵达的瞬间，已经在某种程度上给予所扫描到的事物图像不同的关注占比。这与注意力机制的本意一样，将更多的关注分配给重要的信息，而对于那些无关紧要的讯息则选择忽略甚至采取抑制行为。

中国知网 https://www.cnki.net

注意力机制的本质思想，是将 Source 中的元素看成是一系列由<key，value>数据对构成的特殊结构，这时对于某个元素 Query 来说，可以计算每个 key 与 Query 之间的相似性，或者说是相关性。接着将相关性进行归一化，就可以得到每个 Key 对应 Value 的权重系数，最后用 Value 和权重系数进行加权求和，得到最终结果。可以预见的是，权重越大，该处的 Value 的重要性就越高。因此在长串序列压缩时就可以通过重要程度，对原始数据信息进行取舍，如图 2.6 所示。

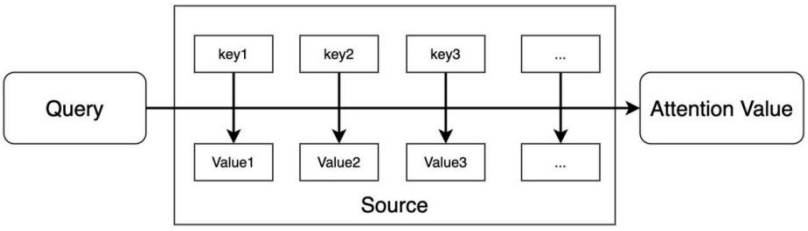


图 2.6 注意力机制本质思想

其中权重系数是通过 Query 和 Key 计算相似度来推出的。可以通过以下公式来表示该过程：

$$Attention(Query, Source) = \sum_{i=1}^{L_x} Similarity(Query, Key_i) * Value_i \qquad (2.1)$$

Attention 的计算步骤分为以下三步：

①首先需要得到相似度分值，即计算 Query 和 Key 的相似度。

②其次，通常选取 softmax 函数来做进一步的归一化处理。

③第三，在获取 Attention 之前，还需要对上述步骤所获得的权重以及 value 做加权求和计算。

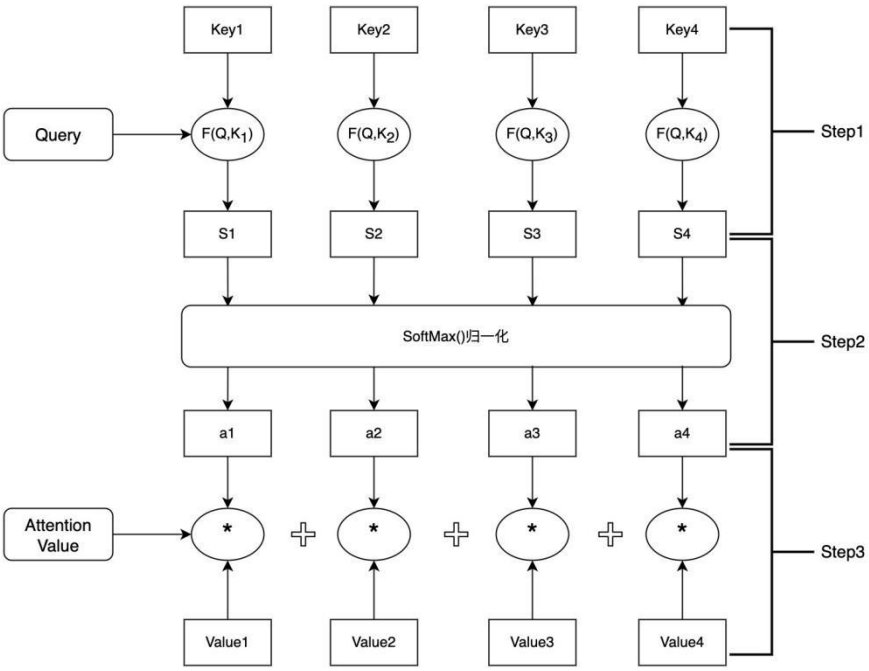


图 2.7 attention 值计算步骤

中国知网 https://www.cnki.net

图 2.7 分步展示了计算流程：

(1) 点乘：

$$F(Q,\ K_i)=Q^T K_i \tag{2.2}$$

(2) 通用方式：

$$F(Q,\ K_i)=Q^T K_i F(Q,K_i) \tag{2.3}$$

(3) 连接方式：

$$F(Q,\ K_i)=W_a[Q,K_i] \tag{2.4}$$

(4) 多层感知机：

$$F(Q,\ K_i)=V_a^T * \tanh(W_a Q+U_a K_i) \tag{2.5}$$

(5) Scaled-dot product：

$$s(x_i,q)=\frac{x_i^T q}{\sqrt{d}} \tag{2.6}$$

(6) Cos 相似度：

$$s(q,k)=\frac{q^T k}{|q|\cdot|k|} \tag{2.7}$$

然后经过 softmax 得到权重系数。具体公式如下：

$$a_i = soft\max(f(Q,K_i))=\frac{\exp(f(Q,K_i))}{\sum_j \exp(f(Q,K_j))} \tag{2.8}$$

最后将权重矩阵乘以，得到加权的每个输入向量的评分，公式如下：

$$Attention(Q,K,V)=\sum_i a_i V_i \tag{2.9}$$

为了便于理解本文所提出的异常检测模型，以上内容分析了注意力机制的原理和实现过程。

2.5 本章小结

本章内容主要包括了工业互联网概念特点、时序模型的相关介绍以及工业异常检测相关的方法理论。第一节中首先对工业互联网工业的基本概念、本质原理、核心方法，以及工业互联网平台所涵盖的内容做出了整体介绍和架构预览，总结了工业互联网的优势所在。第二节中阐述了时间序列的理论概念，分析列举了工业时序数据的特点，最后总结了当前研究中，时序模型的各种模型算法，概括它们的优点和缺点。第三节中叙述了异常检测的理论概念，对异常的类型做出了不同的分类，并对其不同的异常特点做出了分析，最后归纳了工业异常检测的常用算法模型，为之后论文所提出的异常检测模型章节铺垫了理论基础。在第四节中，本文介绍了 Attention 注意力机制的原理和实现过程，便于后续理解论文所提出的异常检测模型。

中国知网 https://www.cnki.net

第三章 工业大数据的冗余值清洗与缺失值填补

3.1 引言

工业大数据覆盖范围广泛，一般主要包含两类：一类是工业生产过程中的制造数据，包括设备监测、工艺规范等数据；另一类是工业管理、销售和流通类数据。本章主要研究的是工业生产过程中的制造数据，区别于传统的互联网数据，工业的制造数据不仅具有海量多维的特征，还具有时序相关、闭环性以及价值密度低等特点。同时，传感器自身所处环境恶劣、人为操作失误以及工业设备本身故障等工况频发，使得工业数据无法保证其准确性，加大了工业数据的管理和分析难度。因此，需要提升初期的数据质量，对工业大数据进行清洗工作。

数据清洗作为提升数据质量的一种方式，其目的是为了更加准确的识别和修正工业大数据中所存在的问题记录，保证数据的质量，提高工业判断分析的准确性。基于以上问题，本文对于冗余值的清洗，选用稳定的邻近记录排序算法 SNM，在保证相似重复记录检测率的同时降低了时间复杂度。对于缺失值的插补，考虑到工业环境下的数据缺失不仅要对短时缺失数据进行填补，还要对长时缺失数据做出趋势的拟合，所以采用基于深度学习的 LSTM 模型，解决时序的依赖性问题。

3.2 数据清洗过程

数据清洗是数据分析工作中必不可少的关键一环。现如今工业的发展，带来了海量的数据信息，但这些原始工业数据仓库中，包含着许多历史冗余、错误以及缺失数据，又称为“脏数据”。数据清洗的原理，主要就是利用相关技术，高效且可靠地清洗工业“脏数据”，使其数据质量得以提高，如图 3.1 所示。

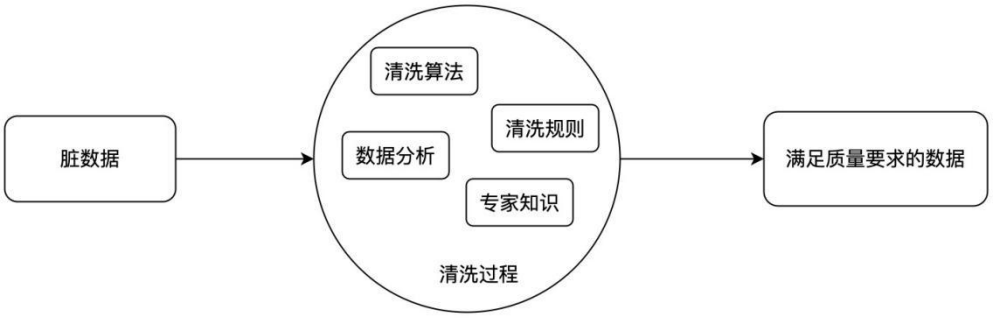


图 3.1 数据清洗过程原理图

在数据清洗的过程中，主要分为以下四步，总体流程如下图 3.2 所示：

(1) 取出工业数据进行分析：这是数据清洗过程中的先行步骤，目的是为了确定当前工业数据中所存在的问题，确定下一步数据分析计划。

(2) 添加清洗规则：根据所分析的工业数据特点，结合目标需求，自定义配置数据清洗规则。

(3) 数据核验：这一过程主要是为了确定所配置的清洗规则是否符合预期要求，如果不

中国知网 https://www.cnki.net

满足条件，则需要重新进行改进。

(4) 数据清洗：根据所选定的算法模型以及所配置的清洗规则，进行数据清洗操作，得到清洗后数据。

(5) 清洗后数据：可用作数据清洗前后效果对比，如果清洗后数据满足质量要求，则可以进行后续的持久化存储操作。如果不满足质量要求，则需要重新确定清洗方法。

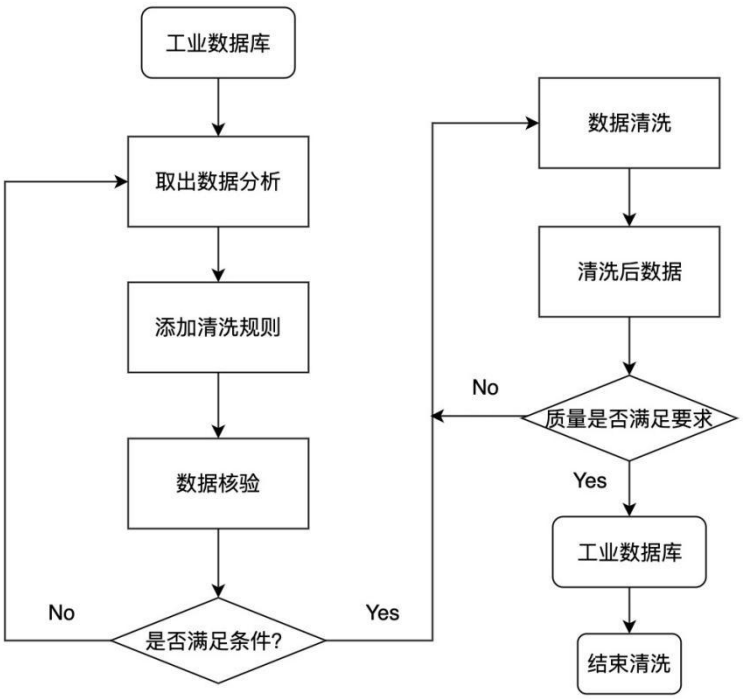


图 3.2 数据清洗过程的总体流程

3.3 基于 SNM 算法的冗余值清洗

3.3.1 问题背景

在工厂企业中，各级设备维护人员需要管理和分析工业数据，方便及时掌握工厂设备变化和故障，做好维护和保养工作。考虑到效率和成本，工厂通常利用长期积累的分散数据构建自己的数据仓库，然后基于数据仓库中的数据进行分析判断，这就对数据仓库中的数据质量提出了较高的要求。然而，冗余值是最常见的数据质量问题之一，这是由于工厂设备长期积累的数据往往量大且分散，并且可能出现人为干预错误、重复记录、设备停机故障等问题，破坏了数据的唯一性原则，造成数据冗余，浪费工业系统资源。

冗余值又叫做相似重复记录，一般是指以下两类记录：

(1) 完全一致的记录。对于这类记录而言，各字段的属性和对应的值均相同。

(2) 相似但不完全相同的记录。这类记录都指向同一个实体，但由于各类原因，记录之间彼此存在差异，系统无法自动判定为同一条记录。

对于冗余值检测的算法选择，首先要考虑到工业数据仓库中海量数据的算法效率，然后

中国知网 https://www.cnki.net

提高相似重复数据的检出率，消除相似重复记录，以此提高数据质量。

3.3.2 SNM 算法模型清洗冗余值

目前的研究中，对于工业相似重复记录的检测，主要分为以下几个方法，如表 3.1 所示：

表 3.1 常见的相似重复记录检测方法

算法	原理	优势	不足
两两检测	全部扫描，逐条比较	算法思想简单	时间复杂度过高
优先队列	用一个重复记录的优先队列扫描记录，如果包含，则扫描下一条记录。	解决了窗口的选取问题，减少了记录比较次数。	识别精度不高，海量数据的环境下效率较低。

考虑到在工业数据量大的前提下会耗费大量资源，逐条记录比较的方法，时间复杂度为 $O(n^2)$。同时，考虑到优先队列是先排序所有记录，然后顺序扫描并将相似聚类，可能存在重复记录遗漏严重，导致相似重复记录检测率不高。所以本文采用的是邻近记录排序 SNM 算法。其基本思路是：在选取完数据之后，预处理排序的关键字，使得相似的记录邻近，将记录转为字符串，利用排序函数对其进行排序。之后基于滑动窗口的思想，对数据进行记录的匹配，让相似重复记录保存在窗口之中。当所设定窗口容量不足时，将窗口中的首条记录和剩余记录匹配，并将首条记录滑出，窗口滚动到下一条记录进行包含，以此完成检测，算法的时间复杂度为 O(W*N)，其中 W 为固定窗口的大小，N 为数据记录的条目，相对于 N，W 值很小，因此在保证相似重复记录检测率的同时降低了时间复杂度。窗口运动过程如下图 3.3 所示：

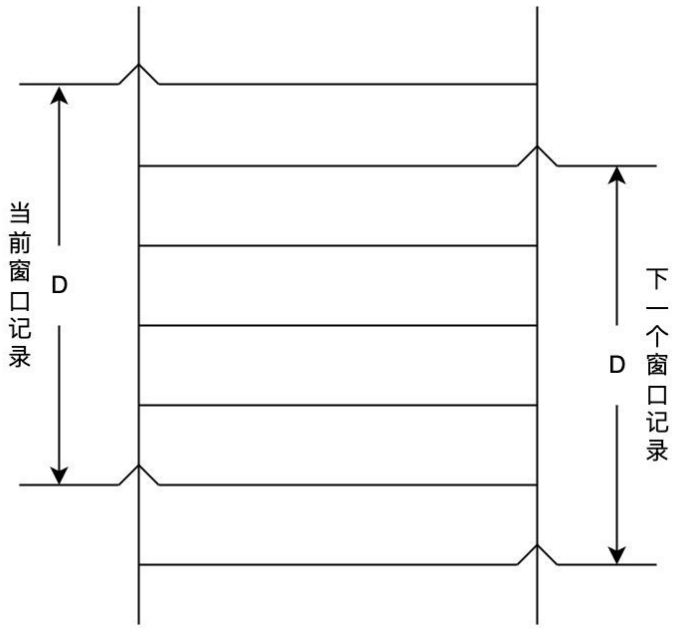


图 3.3 SNM 窗口运动过程图

中国知网 https://www.cnki.net

3.3.3 实验过程与结果

(1) 实验环境和数据选择

本文选用真实环境下的油气水多相流动差压传感器的监测数据集,其中数据表主要包括流量 Q、压力 P、温度 T 以及差压 dp 共有数据 2000 多条，其中部分数据来源于人工估计读数，因此存在着同一时刻，和传感器采集数据相违背的多条数据，总计 674 条相似重复记录。

(2) 评价指标

本文将相似重复记录的检测率作为算法评价的指标。从数据集的分布可知相似重复记录的数量，所以可以快速计算出算法的相似重复记录检测率，在此定义为：

$$k = \frac{N_d}{N} \tag{3.1}$$

其中：N_d 表示算法检测到的相似重复记录数量；N 表示数据集中的总记录数。

(3) 结果分析

根据 SNM 的算法原理可得，窗口大小和文本相似度阈值会影响实验结果，所以本文挑选不同的窗口大小以及文本相似度阈值进行对比实验。

a. 窗口大小 W 对检测结果的影响

为验证为窗口大小 W 对检测结果的影响，此处固定文本的相似度阈值为 μ =0.85。测试结果如表 3.2 所示：

表 3.2 不同窗口大小的相似重复记录检测结果

窗口长度	3	5	10	15	20	25
重复值检测率/%	78.7%	87.5%	91.6%	93.2%	94%	94%

由图 3.4 的实验结果可知，随着窗口 W 增大，相似重复记录的检测率也逐渐升高，当窗口 W 增大到一定程度时，相似重复记录的检测率逐渐趋于平稳。由结果可知，本文实验的最优窗口大小为 W = 15。

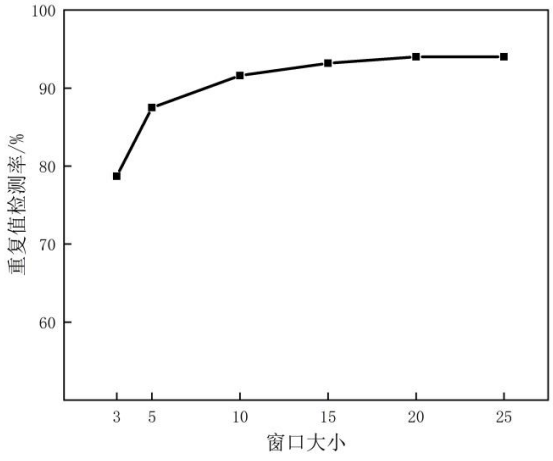


图 3.4 不同窗口大小检测结果折线图

中国知网 https://www.cnki.net

b. 文本相似度阈值μ 对检测结果的影响

为验证文本相似度阈值μ对相似重复记录检测结果的影响, 此处固定窗口大小为 W = 15, 测试结果如表 3.3 所示：

表 3.3 不同文本相似度阈值的相似重复记录检测结果

文本相似度阈值μ	0.75	0.80	0.85	0.90	0.95
重复值检测率/%	94.8%	93.7%	93.2%	87.2%	82.4%

由图 3.5 的实验结果可知, 随着文本相似度阈值的增大, 相似重复记录的检测率在降低, 当文本相似度阈值增大到一定程度时，相似重复记录检测率趋于平稳。这也证明，但文本相似度的要求越加严格时，相似重复记录的检测率会越低。由实验结果可得，本文实验的最佳文本相似度阈值为 μ = 0.85。

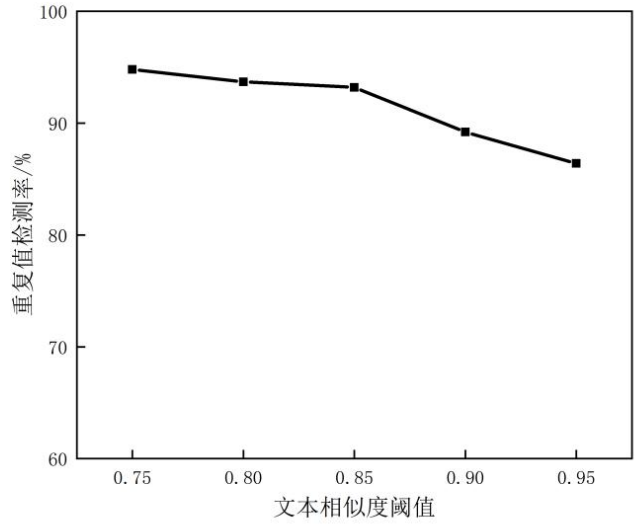


图 3.5 不同文本相似度阈值检测结果折线图

3.4 基于 LSTM 模型的缺失值填补

3.4.1 问题背景

在工业的数据仓库中，数据缺失是一个普遍存在的现象，也是影响工业数据质量的一个关键因素。缺失值会带来许多弊端，比如“污染”原有数据库的数据统一性，增加许多不确定的因素，造成关键工作生产片段的信息丢失。相应的，基于这些数据在进行后续的数据分析工作时，会严重干扰工厂的判断，引发决策失误，造成财产和安全损失。考虑到工业缺失数据的重要性以及缺失率，可以将缺失数据划分为四种类型，如图 3.6 所示。

中国知网 https://www.cnki.net

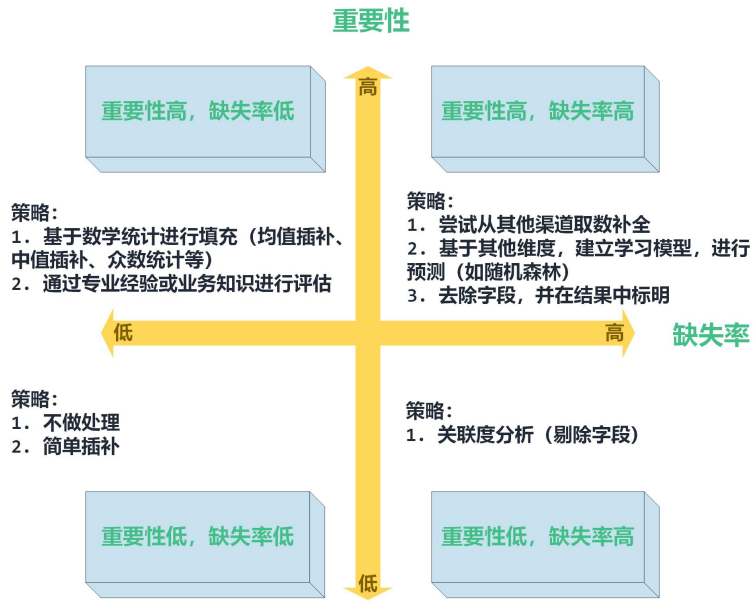


图 3.6 工业缺失数据分类

造成工业中出现数据缺失值的原因主要分为两类：机械原因和人为失误原因。机械原因具体是指工业生产设备在工作过程中，不可避免地发生了故障或停机等现象，造成数据丢失，如数据采集未上传、传感器受到干扰停止运行、设备系统死机、工厂网络传输故障以及数据库出现读写失误等。人为失误原因主要包括工人操作不当、记录失误或者存在瞒报、漏报等情况。

目前，对于缺失值的数据处理方式多种多样，大致分为以下几类：

(1) 忽略缺失值，采取暴力删除记录。一般来说，不建议采取这种方式。原理很简单，就是直接将缺失的记录统一删除掉。如对于单个数据属性特征的缺失，常采取整体删除；但这也会带来许多弊端，比如损坏了原始数据的完整性，导致信息资源浪费，甚至可能产生误导性结论。

(2) 基于数理统计的估计方法。对于数据中所存在的缺失值，可以观测数据的分布情况，从而对缺失的数据作出估计，如采用期望值的最大化法（EM，Exception Maximation），但前提是数据的必须是大样本，不然无法趋近真实分布。其次，常使用的是基于平均值的填充方法，这类方法主要是根据其他记录的平均值来进行填充。

(3) 基于机器学习的填补方法。主要是利用机器学习模型学习数据的潜在特征，模拟出缺失数据。主要有最近邻（K-Nearest Neighbour，KNN），递归神经网络（Recurrent Neural Networks，RNN）等方法。

对于常见的不同缺失值处理方法的简单比较，如表 3.4 所示。

中国知网 https://www.cnki.net

表 3.4 不同缺失值填补方法的简单比较

方法	算法稳定性	填补精度	时间复杂度	适用范围
均值插补	低	很低	低	小
EM 算法	很低	受样本影响很大	低	小
多重插补	好	较高	较高	广泛
基于机器学习	好	高	高	广泛

3.4.2 LSTM 算法模型填补缺失值

LSTM（Long Short Term Memory）是 RNN 发展过程中所衍生出来的一个特殊模型，因其强大的预测能力和性能表现，LSTM 在许多领域都得到了应用。就结构和原理而言，RNN 的特征在于，对于每个 RNN 神经元，其参数始终共享，其隐藏层信息只来源于当前输入和上一时刻的隐藏层信息，如图 3.7 所示。

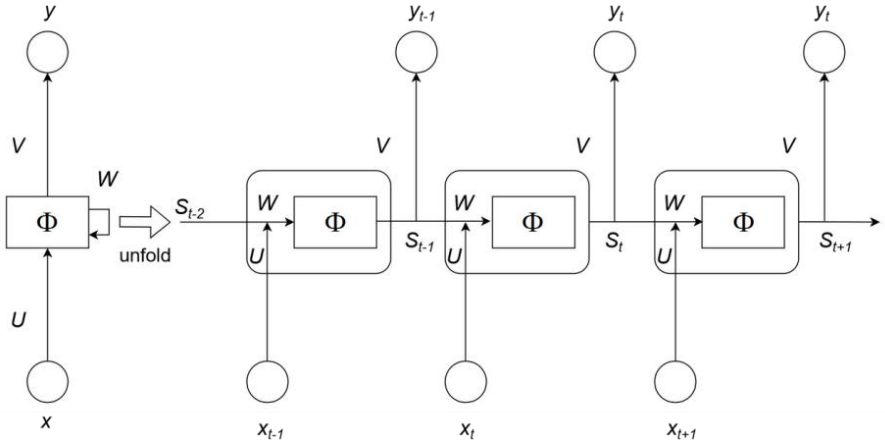


图 3.7 RNN 单元结构

因其结构的单一性，RNN 在面对长序列的数据输入时，很容易发生梯度弥散，造成信息丢失。在 LSTM 中，单元状态（cell state）是 LSTM 的关键，每一个模块结构如图 3.8 所示。图中 LSTM 单元上方从左贯穿到右的水平线，将信息从上一个单元C_{t-1}传递到下一个单元C_t。

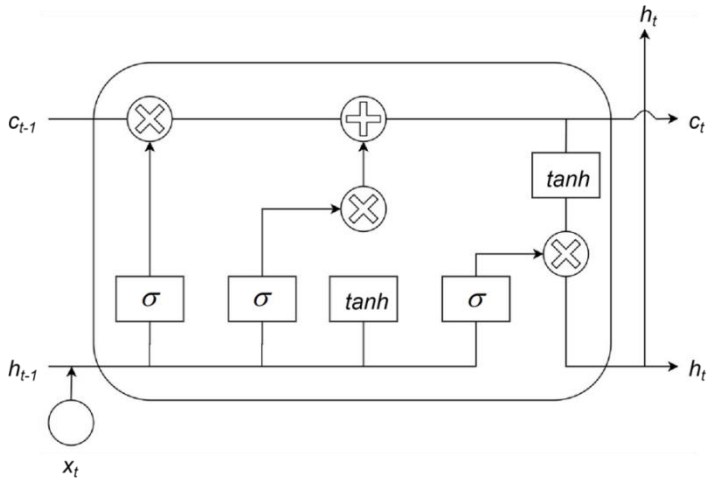


图 3.8 LSTM 单元结构

中国知网 https://www.cnki.net

与此同时，LSTM 引入了特别的门控机制来控制信息：遗忘门、输入门和输出门，如图 3.9 所示。

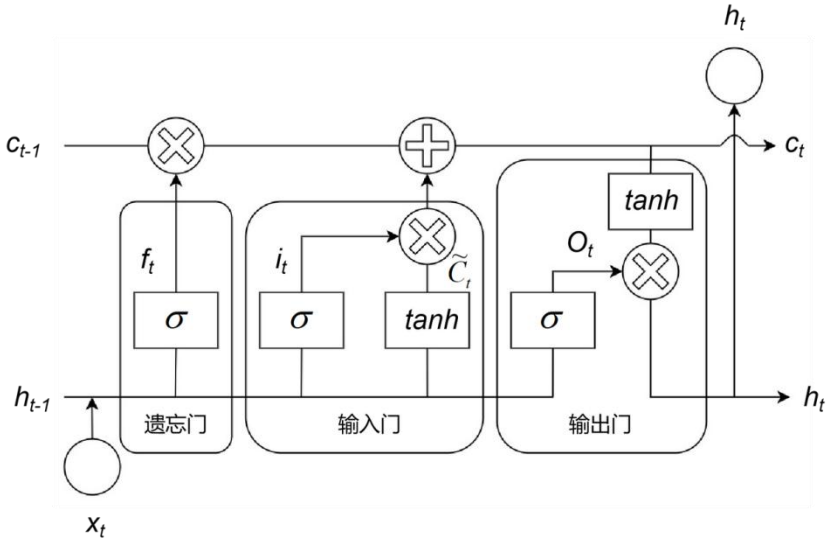


图 3.9 遗忘门、输入门、输出门所属部分

整体的过程如下：首先，遗忘门f_t会结合上一时刻的隐藏层状态 h_{t-1}和当前的输入 x_t ，乘上权重和加上偏置后通过 sigmoid 函数σ，决定旧信息的舍弃与否。sigmoid 函数的值域介于 0 到 1 之间，当值接近于 0 时，意味着丢弃一部分信息，当值接近于 1 时，保留信息。具体计算公式如下：

$$f_t = \sigma\left(W_f \cdot \left[h_{t-1}, x_t\right] + b_f\right) \tag{3.2}$$

其次，输入门 i_t 和 tanh 决定新信息的加入，从上一时刻的隐藏层状态 h_{t-1}和当前输入值 x_t 中保存哪些新信息，并得到候选值$\tilde{C}_t$，公式如下：

$$i_t = \sigma\left(W_i \cdot \left[h_{t-1}, x_t\right] + b_i\right) \tag{3.3}$$

$$\tilde{C}_t = \tanh\left(W_c \cdot \left[h_{t-1}, x_t\right] + b_c\right) \tag{3.4}$$

结合遗忘门和输入门进行信息的舍弃和保存，得到当前时刻的细胞状态C_t，公式如下：

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \tag{3.5}$$

最后，输出门o_t用来控制当前的单元状态有多少被过滤掉。公式如下：

$$o_t = \sigma\left(W_o\left[h_{t-1}, x_t\right] + b_o\right) \tag{3.6}$$

然后结合 tanh 决定 h_{t-1}、x_t、C_t中哪些信息输出为本时刻的隐藏层状态h_t，公式如下：

$$h_t = o_t * \tanh\left(C_t\right) \tag{3.7}$$

本文进行缺失值填补的算法流程主要包括以下 3 步：

(1) 计算相关系数，确定待填补数据的相关维度，计算公式为：

中国知网 https://www.cnki.net

$$\rho_{XY}=\frac{Cov(X,Y)}{\sqrt{D(X)}\sqrt{D(Y)}} \tag{3.8}$$

(2) 先忽略缺失值，选择双向 LSTM 模型，设置训练的参数进行模型训练。

(3) 调用训练好的 LSTM 模型来预测填补缺失值，使用之前时间步的数据来预测缺失值，同时选取评价指标评估模型填补性能。

3.4.3 实验过程与结果

(1) 实验环境和数据选择

本文选用某测试汽车发动机温度传感器的监测数据集，数据表主要包括时间戳和温度的加速度采集值，共 18000 多条记录。为了进一步验证所采用算法的填充效果，本文随机剔除数据集中的部分数据，分别是 5%、10%、20%，然后与其他常见的填补方法，拉格朗日插值法和 K 近邻进行对比。

(2) 评价指标

算法模型的基本思路是在训练完模型后，调用训练好的 LSTM 模型来进行预测估计，即使用之前时间步的数据来预测缺失值，因此评价指标采用均方根误差 RMSE，计算公式为：

$$RMSE=\sqrt{\frac{1}{n}-\sum_{i=1}^{n}\left[X_{pre}(i)-X(i)\right]^2} \tag{3.9}$$

其中，Xpre(i)为填补值，X(i)为实际值，n 为缺失值的总数。

(3) 结果分析

在随机去除 5%、10%、20%的数据后，本文在不同缺失率下对比了 LSTM、拉格朗日插值法和 KNN 的填充性能，结果如图 3.10 所示：

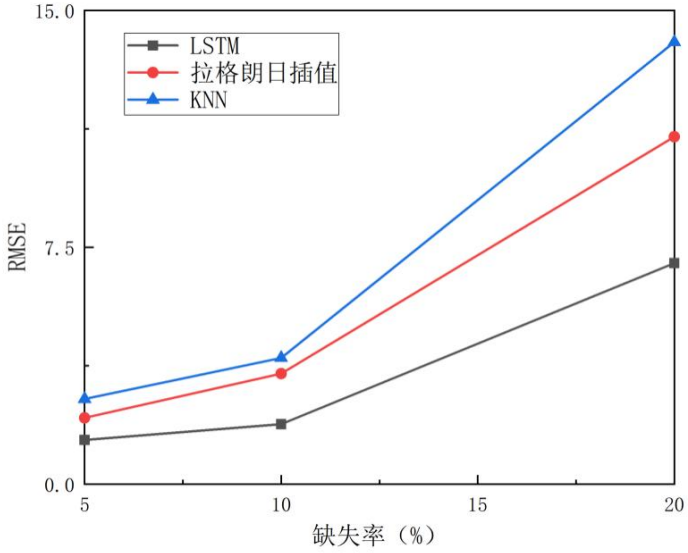


图 3.10 缺失值填补 RMSE 对比

中国知网 https://www.cnki.net

从对比结果中可以看出，本文采用的 LSTM 算法填补缺失值的均方根误差远低于常见的拉格朗日插值法和 KNN 算法，取得了最佳效果。当缺失率越高时，LSTM 算法填补的均方根误差越小。同时，由图 3.11 可知，LSTM 在数据集上的拟合效果走势很好，在工业时序数据缺失的情况下，可以利用其进行填补。其中，蓝线为实际数据，橙线为 LSTM 预测结果。

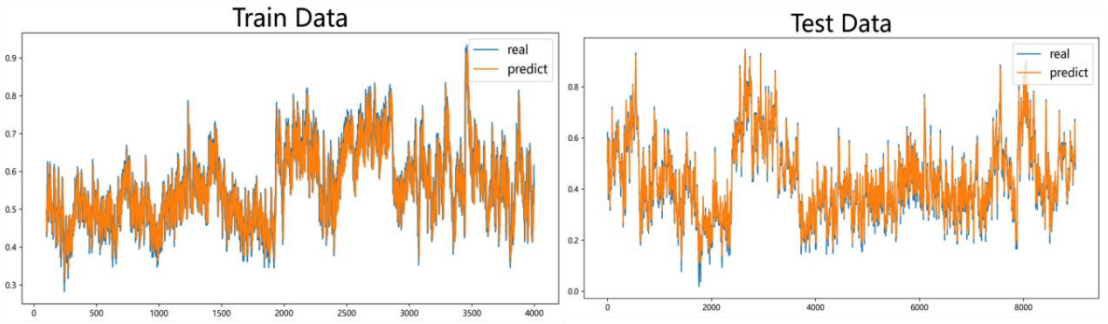


图 3.11 LSTM 在数据集上的预测效果

3.5 本章小结

本章内容主要阐述了工业采集上来的数据中，因传感器自身故障或人为操作、设备损坏等原因，含有许多“脏数据”，主要集中体现在数据冗余和数据缺失两方面。所以，为提高数据质量，需要对工业时序大数据进行清洗工作。在第二节，主要讲述了数据清洗的整个过程，其原理就是利用算法、构建模型、专家参与等方式，提高数据质量，把“脏数据”清洗干净。在第三节，完整阐述了冗余值的概念及数据清洗中常用的冗余值清洗方法，提出采用 SNM 算法并介绍了其原理，并通过真实的工业数据集对其重复值检测效果进行了验证，达到了较高的重复值检测率。在第四节，主要阐述了缺失值的概念及数据清洗中常用的缺失值填补方法，提出采用 LSTM 算法并介绍了其原理，并通过真实的工业数据集对其填补效果进行了验证，达到了不错的数据填充效果。

中国知网 https://www.cnki.net

第四章 基于时序卷积网络的异常检测机制

4.1 引言

时间序列数据越来越多地在各种应用系统中被收集。基于此类数据检测异常，对于确保系统的正常运行具有重要意义。工业时序数据通常是由传感器采集的数据，如起重设备、锻造设备、机械泵、干燥设备等监测数据。在对其进行异常判断时，一般会根据其运行环境数据和工况数据进行分析，如环境中的气压、水中的液压、温度、湿度、工作压力、设备倾斜度、振动幅度等等。为提高工业的生产效率和转型智能化，大量的设备和机械投入工业生产之中，采集多特征数据的集成传感器也将大量增加，这也使得工业中的时序异常检测变得越加困难。

为解决以上问题，改善传统的工业时序异常检测模型准确率较低的问题，本章提出了一种基于时序卷积网络的异常检测模型，称为 IAD-TCN（Temporal Convolutional Networks for Industrial Anomaly Detection）。具体而言，本文使用 TCN 模型来捕捉时间序列中的相关性，考虑到传统的 TCN 网络模型为每个输入特征分配相等的权重，并可能在异常检测中带来许多负面的影响和干扰。为了有效的异常检测，模型中需要调整输入特征的权重。因此，本文将注意力机制嵌入到模型中以解决这个问题。通过注意力机制，模型可以根据不同特征在数据中的重要性调整其权重，从而提高模型的性能。最后，本文在实际的工业时序数据集上验证了该模型，结果表明，本文所提出的方法优于传统的 TCN 模型、BiLSTM 模型、通用的 LSTM 模型和 RNN 模型。

在本章，论文先整体介绍时序卷积网络 TCN 的结构和原理，然后阐述注意力机制与模型的融合，最后在真实工业时序数据集上进行异常检测验证，并选取合适的评价指标评估模型的性能表现。

4.2 基于时序卷积网络的异常检测

4.2.1 TCN 网络捕获时间依赖

TCN 最初被提出作为 CNN 的扩展，但与传统的 CNN 相比，TCN 能够整合因果卷积来保存顺序信息，而不会从未来泄露到过去。TCN 在处理任意长度的序列和生成相同长度的输出序列方面也更加灵活。同时，得益于其更灵活和更长的感受野大小，TCN 在不同任务中的表现优于 LSTM 和 GRU 等一般递归架构。

TCN 的网络结构一般主要包括三个部分：因果卷积（Causal Convolution）、膨胀卷积（Dilated Convolution）和残差连接（Residual Connections）。

（1）因果卷积。因果卷积如图 4.1 所示。在因果卷积中，某一时刻的输出只与该时刻及更早时刻的输入有关。如给定时间序列 $X = \{x_1, x_2, \ldots, x_{t-1}, x_t\}$，时序卷积网络 TCN 会输出一个同长度的预测结果 $Y = \{y_1, y_2, \ldots, y_{t-1}, y_t\}$。其中，预测值 y_t 与未来的输入无关，y_t

中国知网 https://www.cnki.net

仅依赖于此前时刻的输入。相比于传统的卷积神经网络，因果卷积是一种更为严格的时间约束性模型，它是单向而非双向的。

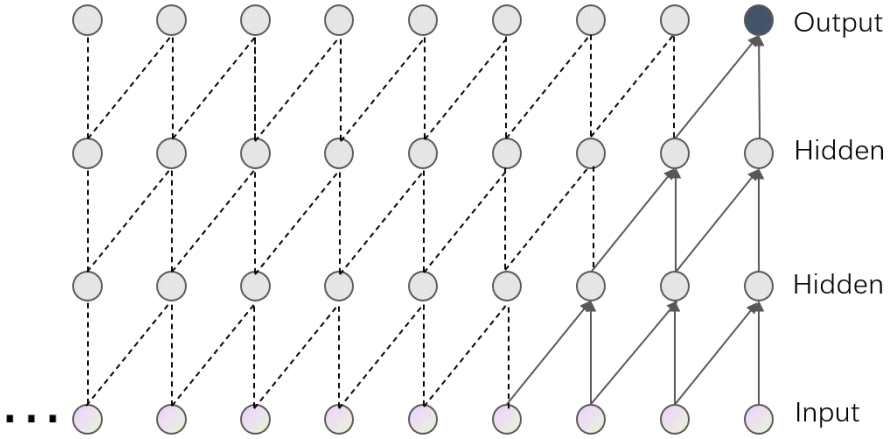


图 4.1 因果卷积图示

(2) 膨胀卷积。在对时间的建模问题上，传统卷积网络往往受限于卷积核大小。如果想获取到更长的时间依赖关系，就意味着卷积网络需要去堆叠更多的网络层，但这样也会造成所构建的网络模型过深，影响性能。为了解决这个问题，时序卷积网络 TCN 引入了膨胀卷积，从而在确保获取足够长的历史有效信息的情况下，大大降低网络的深度和复杂程度。对于膨胀卷积的卷积过程而言，输入可以存在间隔采样。其中采样率由图 4.2 中的间隔参数 d 来调控。例如，在图 4.2 中底层网络结构中的 d=1，这意味着输入时，每个点都会进行采样。第二层网络中 d=2，这表示输入时，每次间隔 2 个点进行采样。通常而言，网络的层级越高，对应的间隔参数 d 也会调整的越大。也正因如此，在膨胀卷积中，用相对较少的层，就可以得到更大感受野。

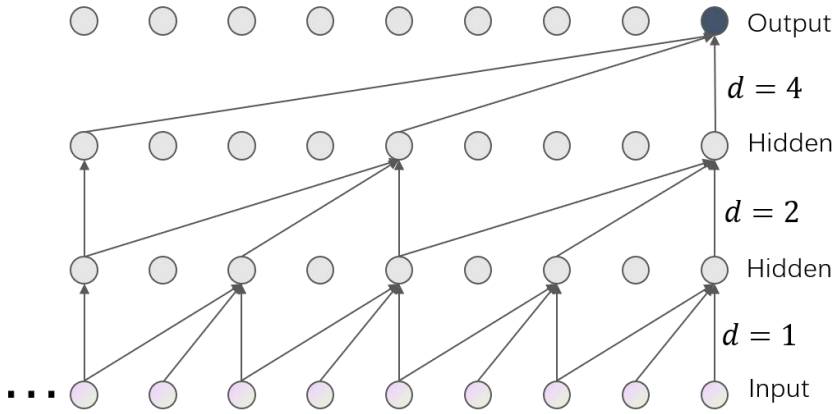


图 4.2 膨胀卷积图示

(3) 残差连接。残差连接已经被证明是训练深层网络的有效方法[53]，它可以较好的避

中国知网 https://www.cnki.net

免梯度爆炸和消失问题，整个网络使用跳转连接来加速训练过程。TCN 的残差连接模块包含了两层卷积层和非线性恒等映射，不仅如此，残差连接模块还引入了线性整流函数(ReLU)作为激活函数，引入了权重标准化(WeightNorm)以实现正则化，引入空间缺失(Dropout)对每次训练的整个通道进行置零归一化[54]，如图 4.3 所示。

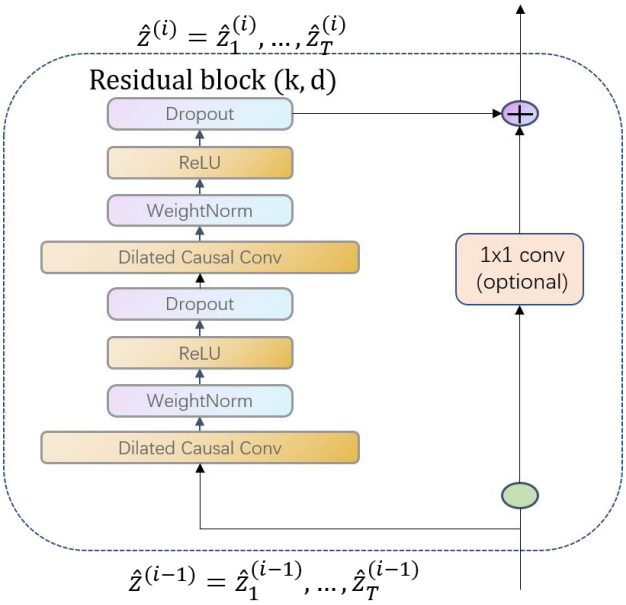


图 4.3 残差连接图示

4.2.2 注意力机制的结合

通常情况下，对于神经网络模型的训练，一般参数越多，模型的表征能力会越强，所承载的信息量也会越大，但这也会造成信息资源超载的问题。结合注意力机制，可以辅助模型捕捉重要信息，提高模型的检测性能。

如图 4.4 所示，本文将注意力机制嵌入到 TCN 网络中，在每一层卷积顶端加入一层 Attention 层，用于捕获每层输入的隐藏信息。以提高 TCN 的性能和异常检测的效率。

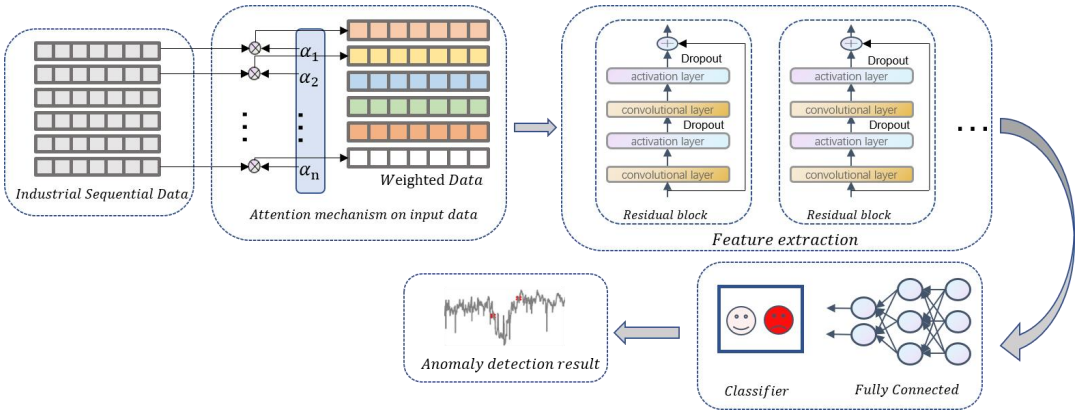


图 4.4 IAD-TCN 系统模型

(1) 每一层隐藏卷积层在经过残差连接后，注意力模块会通过输入的隐藏状态和输出的隐藏状态计算注意力分数，如下所示：

中国知网 https://www.cnki.net

$$score\left(h_s, h_t\right) = h_s \times h_t^T \tag{4.1}$$

(2) 然后使用 softmax 激活函数计算注意力权重，如下所示：

$$a_{t,s} = \frac{\exp\left(score\left(h_s, h_t\right)\right)}{\sum_{s'} \exp\left(score\left(h_{s'}, h_t\right)\right)} \tag{4.2}$$

(3) 对注意力权重和 h_S 进行点乘操作，得到上下文向量，记录输入时序数据中对预测结果影响最大的时间点，如下所示：

$$c_t = \sum_{s=1} a_{t,s} \times h_s \tag{4.3}$$

(4) 连接上下文向量和 h_t，使用 tanh 函数计算出最终的输出向量，如下所示：

$$At_{vector} = \tanh\left(W_c\left[c_t : h_t\right]\right) \tag{4.4}$$

4.2.3 利用 IAD-TCN 模型进行异常检测

IAD-TCN 模型是基于预测进行异常的判断，简单而言，就是利用原始数据中的真实值和 IAD-TCN 模型预测值两者之间的误差进行判断。异常具体分为两类：窗口异常和点异常。对于窗口异常，会首先计算出窗口内各点的预测误差，统计超出标准参考值的点的个数，然后计算其在窗口内点数所占的比例，最后得出窗口异常分数。如下所示：

$$m_{residual} = \left(y_t - y_t^{'}\right)^2 \tag{4.5}$$

$$score_{window} = \frac{\sum_{t=t_0}^{t_{end}} if\left(m_{residual} > \Delta C\right)}{t_{end} - t_0} \tag{4.6}$$

式中，y_t为真实值，$y_t^{'}$为模型预测值，ΔC 为标准参考值，t_0 为窗口的开始时间，t_{end} 为窗口的结束时间，$score_{window}$为窗口异常分数，当$score_{window}$高于所设定的阈值时，就判定该窗口内发生了异常。

对于点异常的判断，首先计算出当前时刻 t 下的 IAD-TCN 模型预测值与真实值间的欧式距离，作为该时刻 t 的点异常分数，如下所示：

$$score_{point} = \sqrt{\left(y_t - y_t^{'}\right)^2} \tag{4.7}$$

式中，y_t为真实值，$y_t^{'}$为模型预测值，$score_{point}$为点异常分数，当异常分数高于给定的阈值，则该点判断为发生异常。

4.3 实验过程与结果

4.3.1 数据集描述

水泵机组的运行是一个典型的工业场景，以水泵传感器采集数据集为例，该数据集是城镇供水的大型抽水站的运行数据。该水泵机组配备了 55 个传感器，用于检测不同的机组部

中国知网 https://www.cnki.net

件和环境变量。数据的采样频率为 1 分钟，共计约 22 万条数据，时间为 4 月 1 日至 8 月 31 日，包括健康和异常数据，如表 4.1 所示。

表 4.1 水泵机组数据集描述

数据集	特征维数	正常数据	停机后恢复数据	故障点	总计
pump_sensors	55	205836	14477	7	220300

实验在内存大小为 64GB、CPU 为 Intel Xeon E5-2699 v4 服务器上进行，操作系统为 Ubuntu16.04。机器学习框架为 TensorFlow2.4.1。

4.3.2 模型评价指标

为了验证本文所提出的异常检测模型的性能，使用精度、召回率、F1 得分和准确度四个指标进行性能评估。它们的含义与计算过程如下：

（1）精度是我们最常用的评估指标。如等式所示，精度定义为模型判断为阳性的所有样本中有多少是真阳性：

$$\mathrm{Pr} = \frac{TP}{TP + FP} \tag{4.8}$$

（2）召回率表示正确检测到的阳性与所有实际阳性的比率，召回率越高，表明检测出的异常越全，如等式所示：

$$\mathrm{Re} = \frac{TP}{TP + FN} \tag{4.9}$$

（3）为了评估不同算法的优缺点，考虑到精度和召回率，F1 分数用于评估整个模型的精度和召回率，如等式所示：

$$F_1 = \frac{2\,\mathrm{Pr}\cdot\mathrm{Re}}{\mathrm{Pr}+\mathrm{Re}} \tag{4.10}$$

（4）准确率是最常见的评估指标之一。如等式所示，它表示正确分类记录与总记录的比率，准确率越高，表明正确检测出的异常越多。

$$Acc = \frac{TP + TN}{TP + FN + FP + TN} \tag{4.11}$$

其中 TP、FP、TN 和 FN 分别代表真阳性样本、假阳性样本、真阴性样本和假阴性样本。

4.3.3 异常检测结果

为了评估我们提出的算法模型在工业大数据异常检测中的性能，我们将其与传统 TCN 模型、BiLSTM 模型、通用 LSTM 模型和 RNN 模型进行了比较，结果如表 4.5.3 所示。

在表 4.2 中，可以看到不同算法的性能对比，IAD-TCN 模型以 0.9817、0.9686、0.9751 和 0.9804 获得了最佳的精度、召回率、F1 得分和准确性。这表明本文所提出的模型是有效的。

为了进一步描述所提出算法模型的评估指标并说明实验结果，图 4.5 中绘制了与其他算

中国知网 https://www.cnki.net

法模型的比较。结果表明，本文所提出的模型 IAD-TCN 在工业时间序列数据的异常检测中表现更好。

表 4.2 不同算法的性能对比

算法	评价指标（%）			
	Pr	Re	F_1	Acc
Simple RNN	0.8794	0.8593	0.8692	0.8862
LSTM	0.9106	0.8957	0.9031	0.9279
BiLSTM	0.9379	0.9267	0.9323	0.9343
TCN	0.9583	0.9365	0.9473	0.9496
IAD-TCN	0.9817	0.9686	0.9751	0.9804

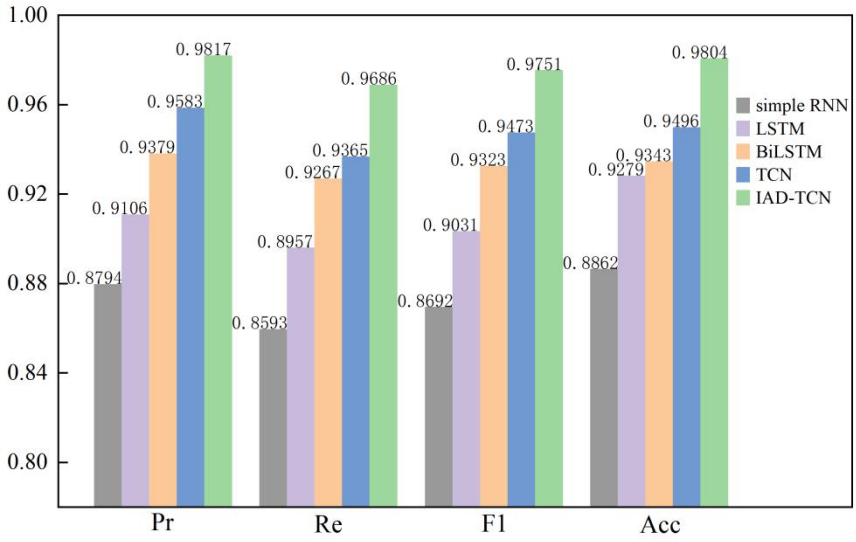


图 4.5 算法性能对比

4.4 本章小结

传统的异常检测算法存在异常检测类型不全面、检测精度不高的情况，本章针对这个问题，结合了时序模型和异常检测方法，提出了新的基于时序卷积网络的异常检测模型 IAD-TCN，该模型用 TCN 模型捕获时间序列相关性，然后嵌入了注意力机制进行优化。第二节分析了 TCN 模型的基本框架和原理，第三节介绍了注意力机制与 TCN 模型的结合过程和系统模型，在第四节，本文详细阐述了如何通过 IAD-TCN 模型检测出异常，在第五节，本文通过在真实数据集上进行实验，验证了 IAD-TCN 模型对于异常的检测具有较好的性能表现。

中国知网 https://www.cnki.net

第五章 工业大数据分析应用平台的设计与实现

5.1 引言

随着信息化和产业化进程的加快，新型工业化道路应运而生。对于设备生产现场来说，获取到的生产数据以及质量数据通常是不完整的、有噪声的和不一致的，如在泵体的监测过程中，传感器采集周期性的运转数据上报，这类工业时序数据与设备自身的条件以及工作环境紧密相关，如泵体的压力、工作温度、振动频率等等。在这期间的生产过程中，可能由于设备故障、传感器采集失效或是人工操作失误等问题，导致原始数据中混入很多“脏数据”，影响数据分析的结果，进而呈现给决策者以有偏差甚至与事实相反的结论。同时，当前工业设备的异常报警通常是被动式响应，常常会造成巨大的财产和人员安全损失。

为解决上述问题，通过建设工业大数据存储分析应用平台，对设备生产数据进行清洗、分析和异常检测工作。不仅有利于及时开展维护工作，而且能保障生产人员以及设备的安全性，为企业提供数据平台服务和决策支持。

本章设计并实现了数据导入模块、数据清洗模块与异常检测模块，将本文所采用的数据清洗方法以及所提出的时序异常检测模型 IAD-TCN 应用到了大数据存储分析应用平台中，并设计了响应的数据库做持久化存储，可视化显示到系统界面中。系统支持多源异构的工业生产数据导入，再数据导入完成之后，系统会自动提供数据清洗功能，用户可以使用系统自带的清洗模型，如本文中所采用的数据清洗方法。考虑到系统的泛化性，用户也可以自定义数据清洗模型，之后导入到系统中使用。此外，通过专家或相关专业操作人员的自定义阈值设置，系统在异常检测模型结果生成之后，会将结果与所设定阈值进行比较，确定当前工业设备是否需要发出预警或者请求维修，如图 5.1 所示。

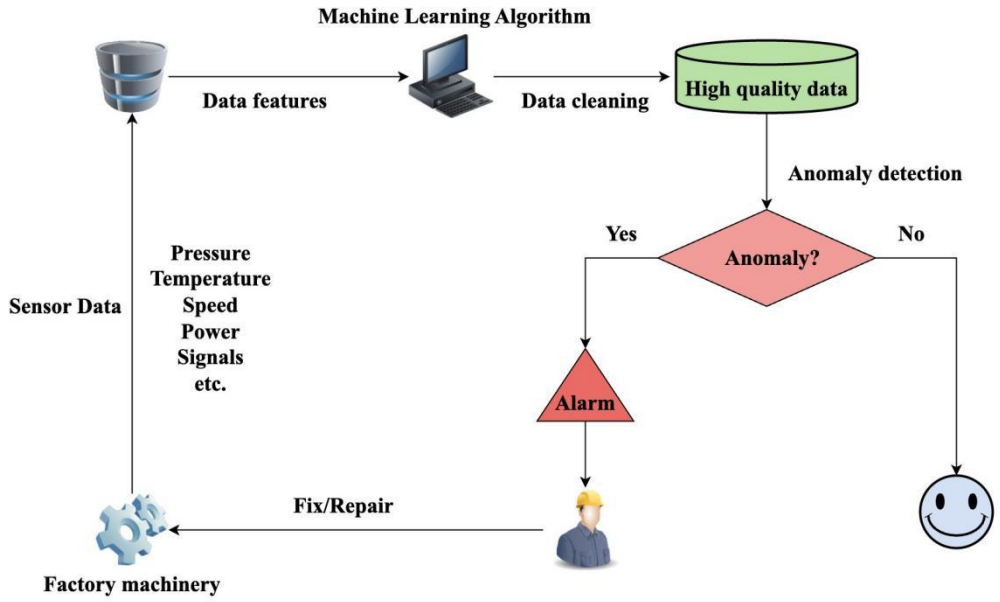


图 5.1 工业数据系统

中国知网 https://www.cnki.net

5.2 系统架构和功能模块设计

5.2.1 系统功能架构

在工业大数据存储分析应用平台中，主要的功能架构包括：数据的采集，传输到远程数据库中进行存储，在得到数据之后，系统会自动进行数据预处理工作：包括数据清洗、格式的转换、时间序列的构建等等。在得到预处理之后的高质量数据之后，系统会利用这些数据进行下一步数据分析：包括异常的检测，设备健康度的预测等等，最后可视化呈现出分析结果。系统的总体功能架构如图 5.2 所示：

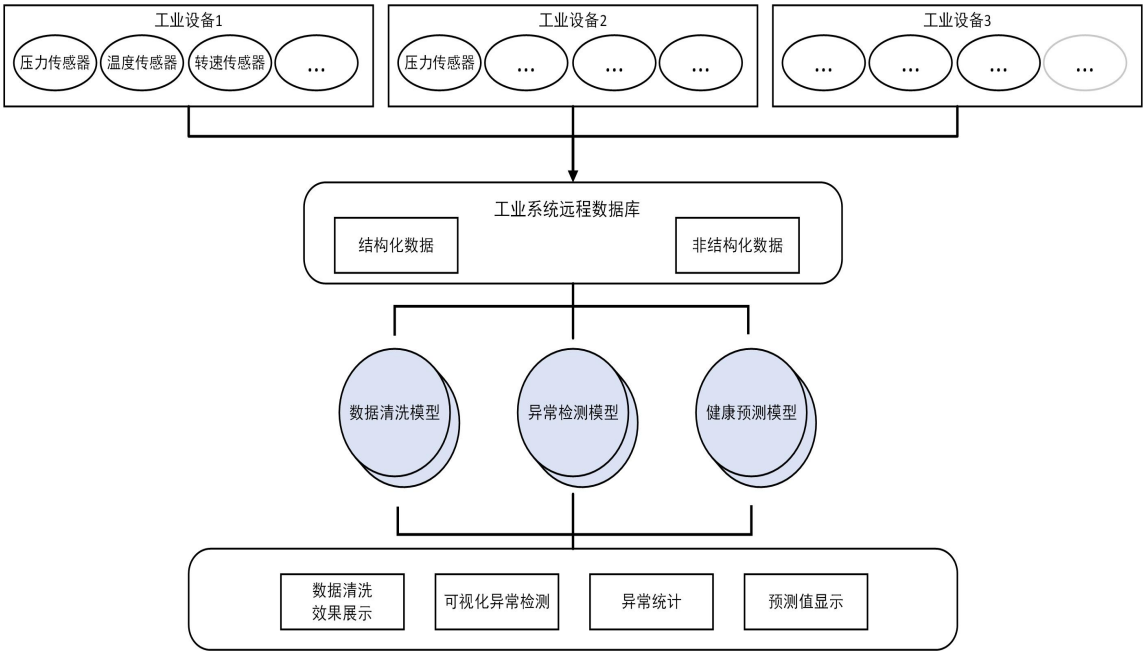


图 5.2 系统功能架构

5.2.2 系统技术架构

系统采用 MVC 的软件架构模式，把系统规划为三个主要部分，分别是：模型(Model)、视图(view)和控制器(controller) 。MVC 分层可以方便管理复杂的应用程序，例如可以在不依赖业务逻辑的情况下专注于视图设计，这也让应用程序的测试更加容易，简化了分组开发和后续拓展复用。对于模型层来说，主要负责封装数据，比如对数据库记录列表的增删改查；对于视图层，主要是显示模型数据，通常视图是依据模型数据创建的；在控制器层，主要是处理系统和用户的交互逻辑，比如页面的跳转。

为了保证系统的低耦合和可拓展性，工业大数据存储分析应用平台使用 MVC 这种设计模型，主要有后端、前端和数据库三个部分组成。后端主要负责机器学习模型的管理，包括 IAD-TCN 异常检测模型、数据清洗模型，此外对前端的各个请求作出响应，并从数据库中查询并返回响应的数据，给前端对应的数据支撑。前端主要负责平台页面信息的展示，包括数据的导入信息、数据清洗模型的配置按钮、导入以及自定义清洗规则、异常检测的可视化

中国知网 https://www.cnki.net

结果以及设备健康度的预测信息等等，主要为用户呈现出一个友好美观的交互逻辑视图页面。数据库主要针对工业数据做一个持久化存储，同时存储一些操作用户的信息、预测信息、数据清洗结果和异常检测结果等，为视图层提供数据支撑。系统整体采用的技术栈如表 5.1 所示：

表 5.1 系统使用的主要技术

名称	相关技术名称
前端	Vue/Ant Design/Apache ECharts/HTML/CSS/ JavaScript
后端	Java/Python/Springboot/Mybatis/Kafka
数据库	MySQL/Redis/Neo4j

此外，考虑到系统的后续维护和技术迭代，系统整体的技术架构如图 5.3 所示：

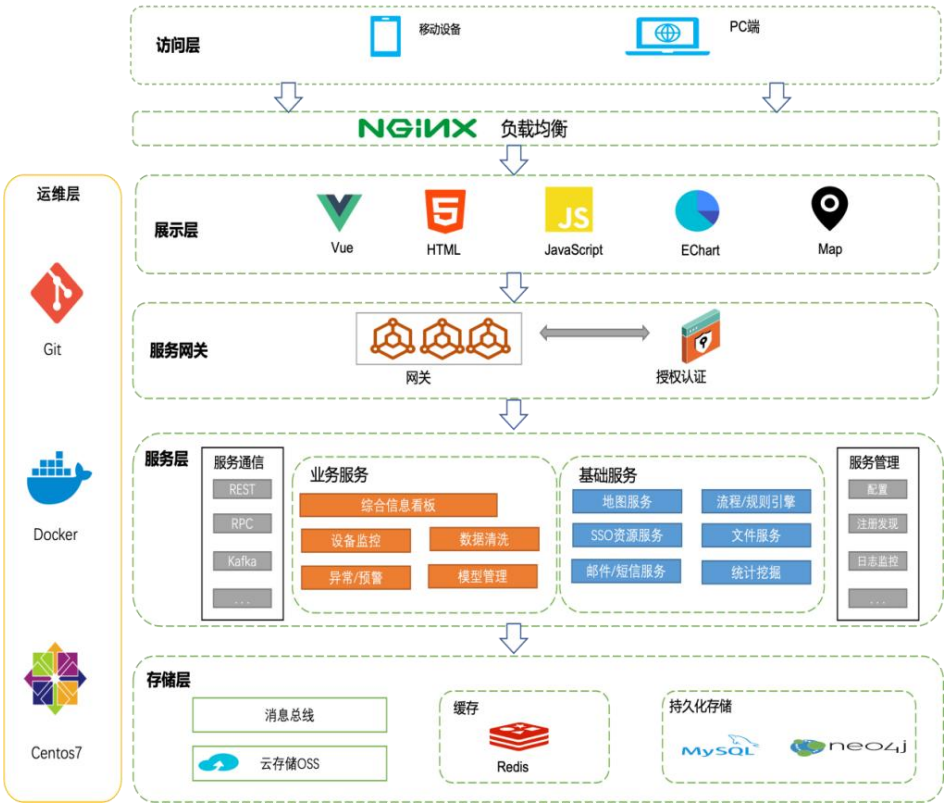


图 5.3 系统技术架构

5.2.3 功能模块设计

（1）多源数据导入模块。支持多源异构数据数据的融合与导入，包括常见数据库、文本数据、大数据组件数据等类型，数据源的具体支持情况如表 5.2 所示。

中国知网 https://www.cnki.net

表 5.2 多种数据源导入支持情况

序号	支持类型	数据源	支持情况
1	常见数据库	MySQL、Oracle、PostgreSQL	支持
2	文本数据	csv、xml、txt、json（和操作系统的接口）	支持
3	大数据组件数据	HDFS、Hive、HBase（接口）	支持

本系统采用 Flume、RFID、传感器等不同的采集方法，通过部署在不同环境和场所下的工业物联设备进行数据采集，然后对多传感器及其观测信息进行合理的分类、支配和使用。之后通过大数据计算引擎记录汇总数据，利用现有的关系型数据库 MySQL、图数据库 Neo4j 以及 NoSQL 数据库进行持久化操作，整合来自多个数据源的数据，屏蔽数据之间类型和结构上的差异，实现对数据的统一存储、计算、管理和分析，向上层数据分析业务提供高效稳定的数据支撑。整体架构如图 5.4 所示:

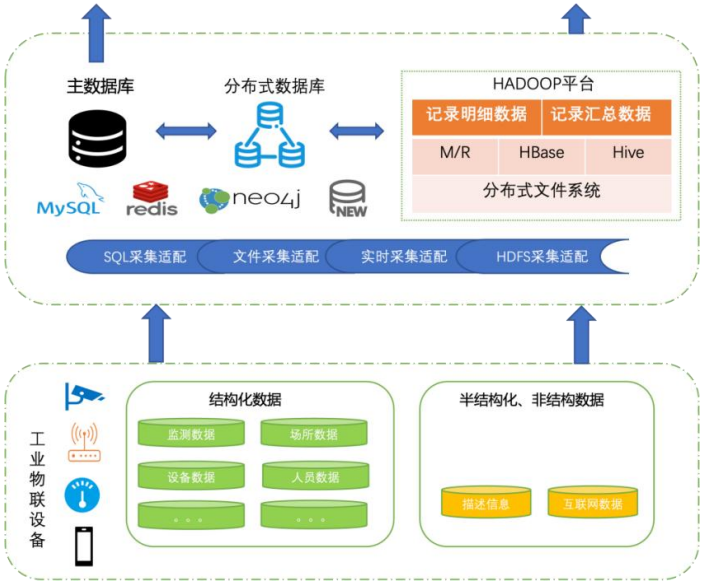


图 5.4 数据导入功能架构

本模块要实现的功能是实现不同数据源数据的导入，支持异构数据的融合，即用户可以在此模块中进行待清洗数据的导入操作。在编写此模块时，要分别实现数据库数据加载、文本数据加载、大数据组件加载的具体方法。在这里，要考虑到数据量有可能会变大的情况，在接收数据时可以对数据的输入流量进行评估，若是大数据，有一定的针对性处理方法，使得模块在面对大数据输入时有一定的弹性可以应对。

（2）数据清洗模块。用户可以上传待处理数据，对数据清洗的规则进行配置，或者选择需要的清洗模型，然后进行清洗的实施操作，最终得到清洗过的数据。本模块功能将分为清洗规则配置、清洗模型管理、清洗实施三个部分进行开发，并对结果进行可视化展示，如图 5.5 所示。

中国知网 https://www.cnki.net

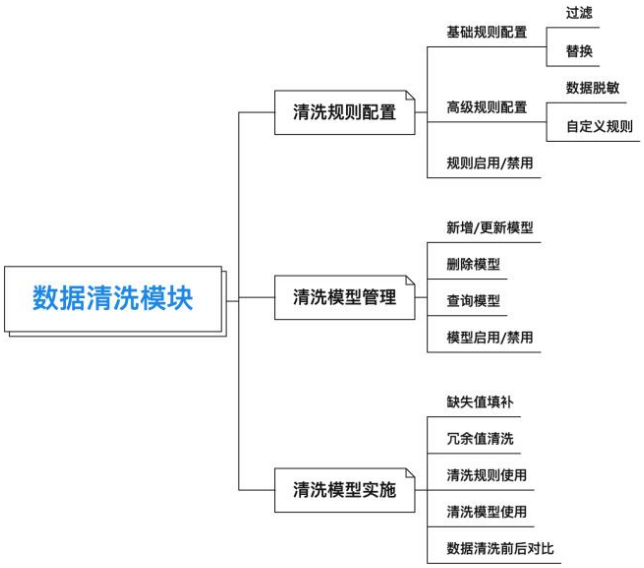


图 5.5 数据清洗模块设计

数据清洗规则配置是实现数据清洗的第一步。主要包括基础规则配置、高级规则配置以及规则的启用/禁用。具体操作流程如图 5.6 所示。在导入工业数据之后，用户可以选择配置所需要的清洗规则。

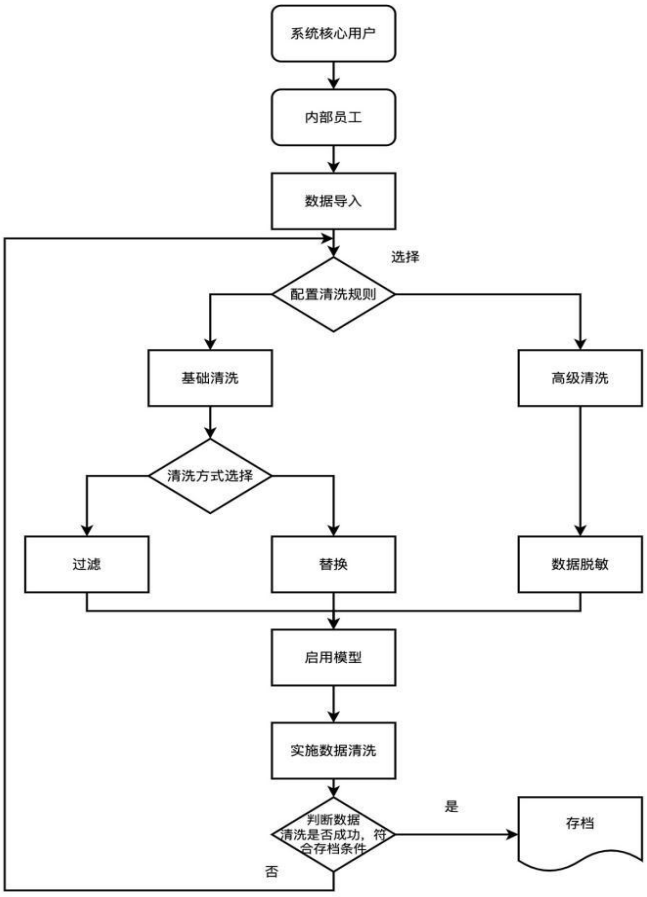


图 5.6 清洗规则配置业务场景

中国知网 https://www.cnki.net

如果选择系统默认提供的基础清洗，主要包含了过滤和替换两个方面。其中过滤包括按值范围、数据类型、数据完整度、时间范围作为过滤规则，如表 5.3 所示。替换的数据清洗规则包括整列替换和单值替换。整列替换是将所有行的某个特定属性的值进行替换；单值替换是替换掉某特定行的某一特定属性值。

表 5.3 过滤规则介绍

过滤规则	规则介绍
按值范围过滤	对于某些数据，是有一个合理的值范围区间的，如果超出这个区间，就可以把此条数据去掉
按数据类型过滤	在数据表中的每一项数据信息根据自身的性质，都是一定类型的数据，如果数据类型有误，说明是错误的数据，将其过滤掉
按数据完整度过滤	不完整的数据在数据分析中是无法作为合法数据使用、进行统计分析的，所以要将其过滤处理
按时间范围过滤	在实际生产中，机器在一段时间内产生的数据可以代表在这段时间内的生产质量，如果超出这个时间范围，就不能作为一个衡量标准，故不再特定时间范围内的数据可被过滤掉

其中，高级清洗规则主要是从数据脱敏的角度对数据进行清洗。数据脱敏主要是指屏蔽敏感数据，保护隐私数据，防止用户对数据的滥用。比如操作用户的关键信息、重要的工业机密信息等。常见的脱敏规则包括替换、重排、加密等，用户也可以根据具体需求自定义脱敏规则。清洗规则的启用/禁用具体是指用户可以根据自己的需求使用特定的清洗规则，当用户启用某一规则，则此规则生效，并应用到后续的清洗实施当中。

清洗模型管理功能支持用户对清洗模型的进行管理，包括对模型的查询、新增、删除、更新的基础操作，以及对清洗模型的启用和禁用。数据清洗模型中包括了一系列预设的或者用户自定义的清洗规则，用户可以选择在进行数据清洗处理之前逐个选择所需的清洗规则，也可以选择系统中已有的，存储在数据库中的清洗模型，如图 5.7 所示。

中国知网 https://www.cnki.net

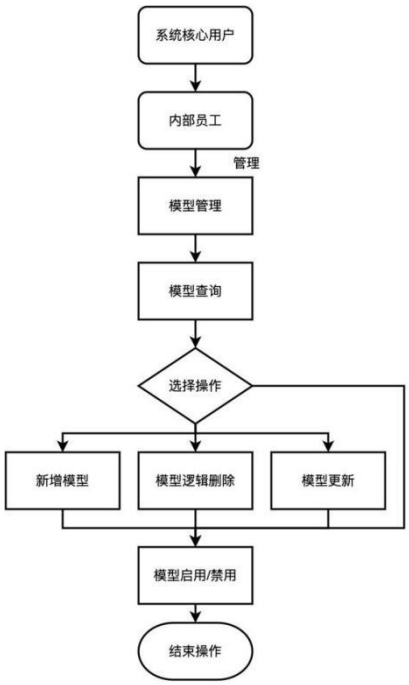


图 5.7 数据清洗模型管理业务场景

清洗模型实施是真正实施数据清洗的模块。在缺失值插补和冗余值清洗之后，系统将按照用户配置好的清洗规则和清洗模型继续对数据进行处理。最后，对数据清洗前的“脏数据”和数据清洗后的数据进行对比展示，以显示数据清洗的效果，如图 5.8 所示。

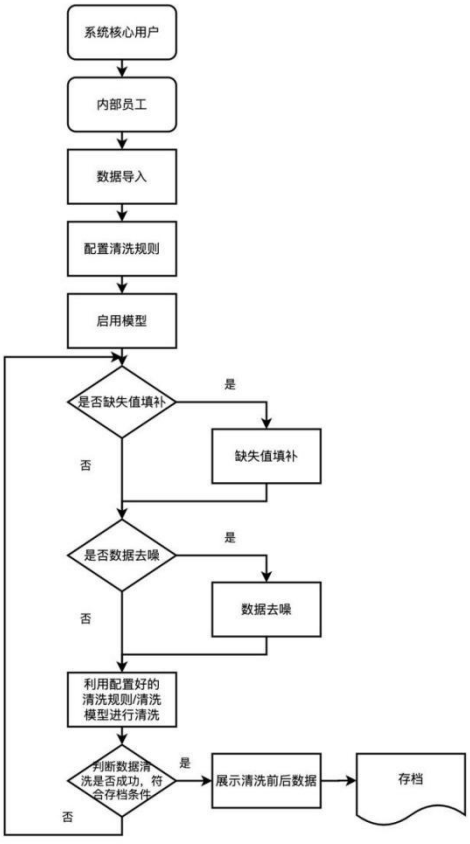


图 5.8 数据清洗实施业务场景

中国知网 https://www.cnki.net

（3）异常检测模块。异常检测模块的功能基于前期清洗好的较高质量的数据，然后利用本文所提出的异常检测模型 IAD-TCN 进行异常检测，并将检测结果可视化反馈给系统平台的用户，如图 5.9 所示。

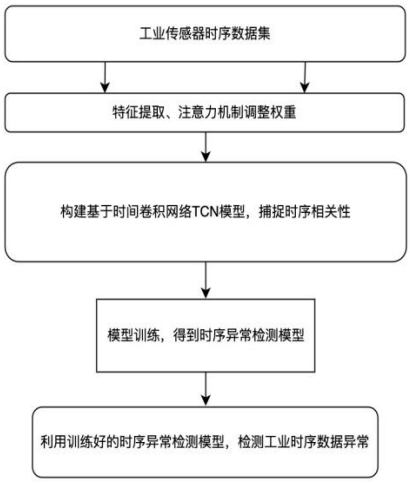


图 5.9 异常检测模块流程

5.3 系统实现

（1）数据清洗模块：此模块功能支持数据导入、大数据加载、清洗规则管理、清洗模型管理、数据清洗实施和清洗结果记录。

在清洗规则配置功能界面中，用户可以根据待清洗工业数据的特点，查询和选用清洗规则，系统会显示出正在使用的清洗规则的名称、类型、版本号、规则创建时间、规则更新时间、用户是否启用、清洗规则描述以及编辑删除操作，如图 5.10 所示；如果用户需要根据数据的特点自定义清洗规则，系统支持用户配置规则文件和附加模型，按需配置，如数据过滤、数据替换和数据脱敏等，如图 5.11 所示。

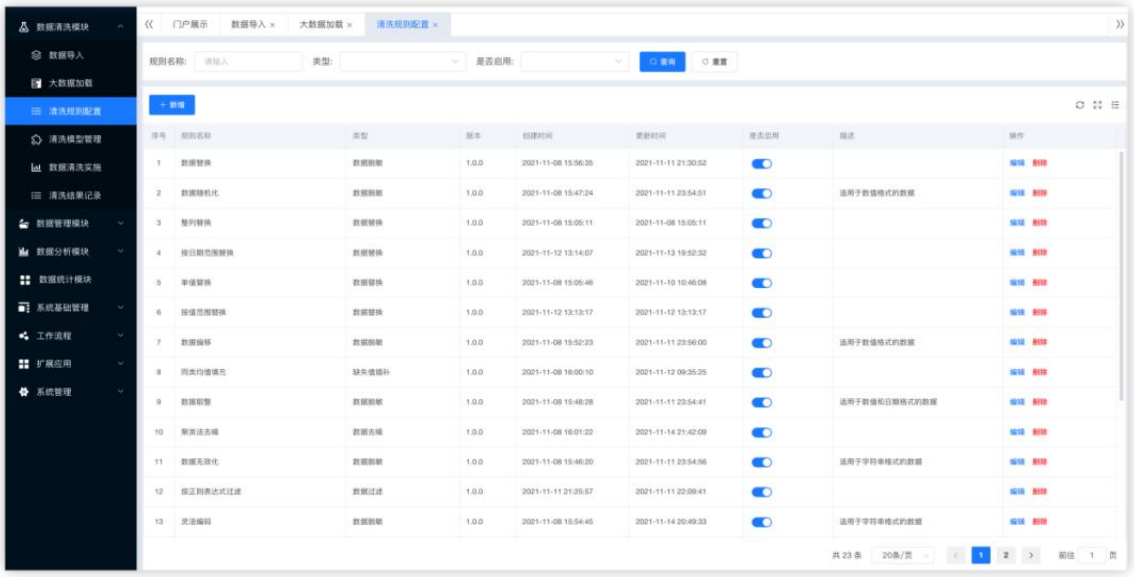


图 5.10 清洗规则配置页面

中国知网 https://www.cnki.net



图 5.11 用户自定义清洗规则

在清洗模型管理功能中，用户可以查询、增删和修改清洗模型。为了提高系统的泛化能力，系统还支持用户自定义数据清洗模型，可以根据不同的数据类型需求，如缺失值插补，自定义清洗模型并上传模型文件，如图 5.12 所示。系统默认接受用户所提供的 Python 模型文件，算法框架目前支持 Tensorflow 以及 PyTorch。待用户上传完自定义的模型文件之后，系统会对模型文件做持久化保存，方便用户下次直接启用对应的清洗模型。

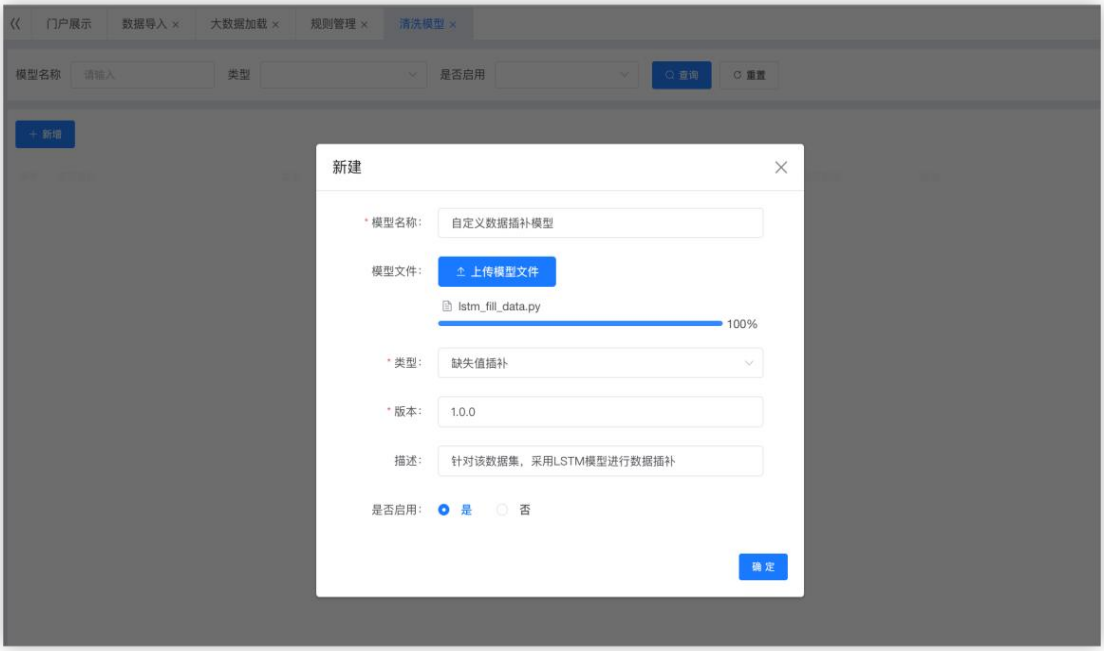


图 5.12 数据清洗模型管理

中国知网 https://www.cnki.net

在数据清洗实施界面，用户在选择完数据之后，可以根据需要添加数据处理流程，如过滤、替换、脱敏、缺失值插补和数据去噪等，如图 5.13 所示。在该模块中，清洗规则和清洗逻辑的下拉列表是可以查询到用户在清洗规则配置界面所自定义的规则的，客制化用户的需求。

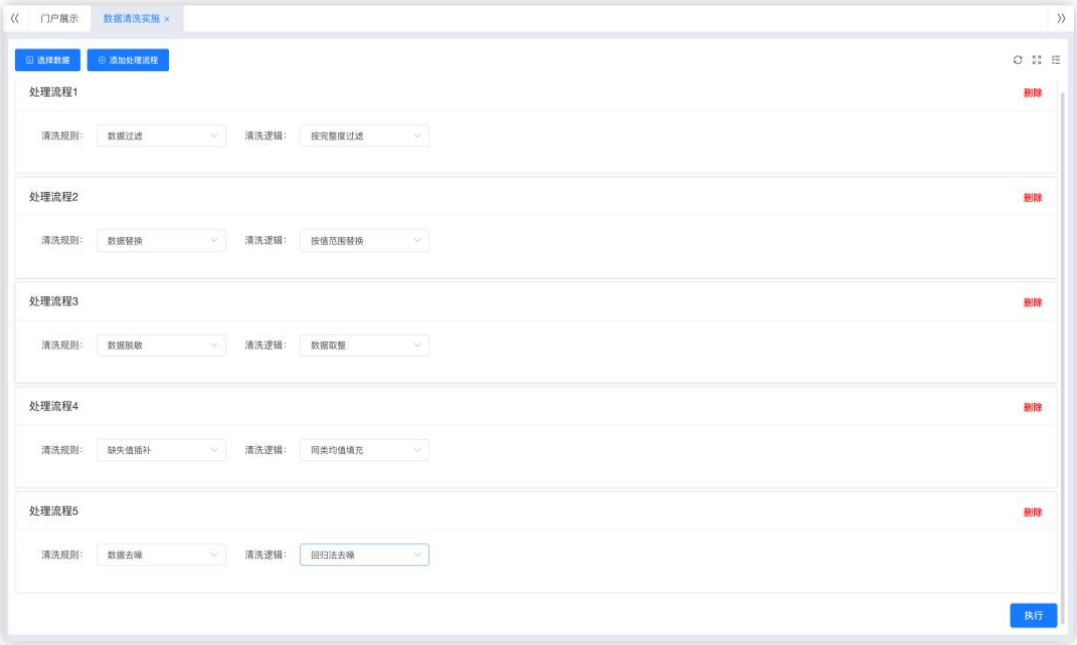


图 5.13 数据清洗实施页面

在用户添加完处理流程之后，当点击执行按钮，系统会跳转到确认步骤并开始处理数据，如图 5.14 所示，最后保存清洗后结果，方便后续对比展示。

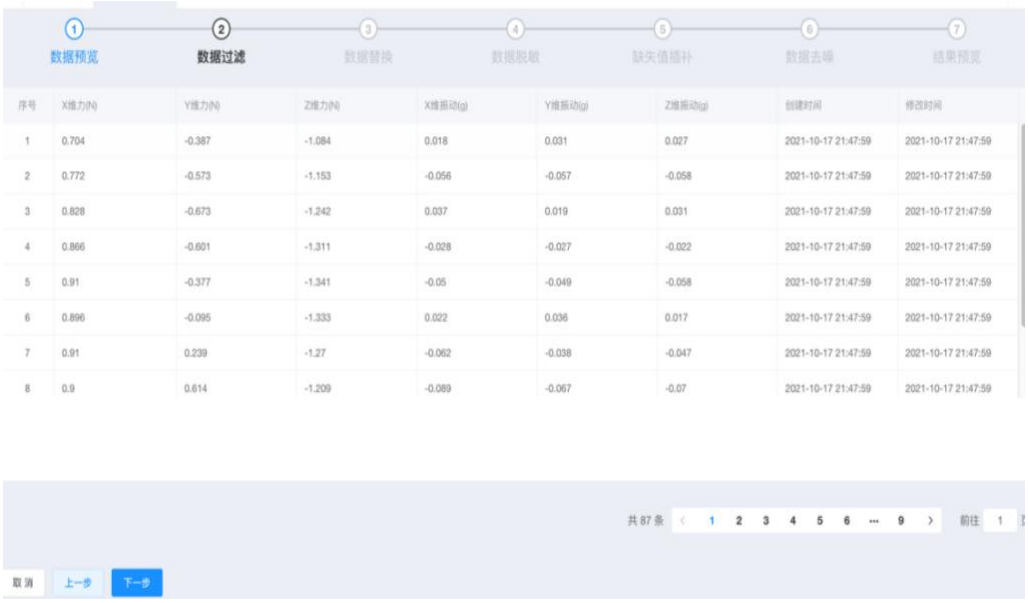


图 5.14 数据清洗实施

在清洗结果记录页面，用户可以看到数据清洗前后的对比，并提供清洗后的数据下载。

中国知网 https://www.cnki.net

如图 5.15 所示。为了方便用户快速检索到自己的清洗结果记录，系统还提供了按照清洗规则名称和数据名称查询清洗后结果。



图 5.15 清洗结果记录页面

（2）异常检测模块：异常检测模块属于系统数据分析功能中的子模块，主要涵盖模型管理、异常检测和动态监测三个部分。

在模型管理模块，用户可以使用系统所提供的模型，也可以自定义并上传自己的 Python 模型文件，并将其用到合适的应用场景中，如图 5.16 所示。算法框架目前支持 Tensorflow 以及 PyTorch，在上传完模型文件之后，系统会持久化保存模型，方便下次直接调用。

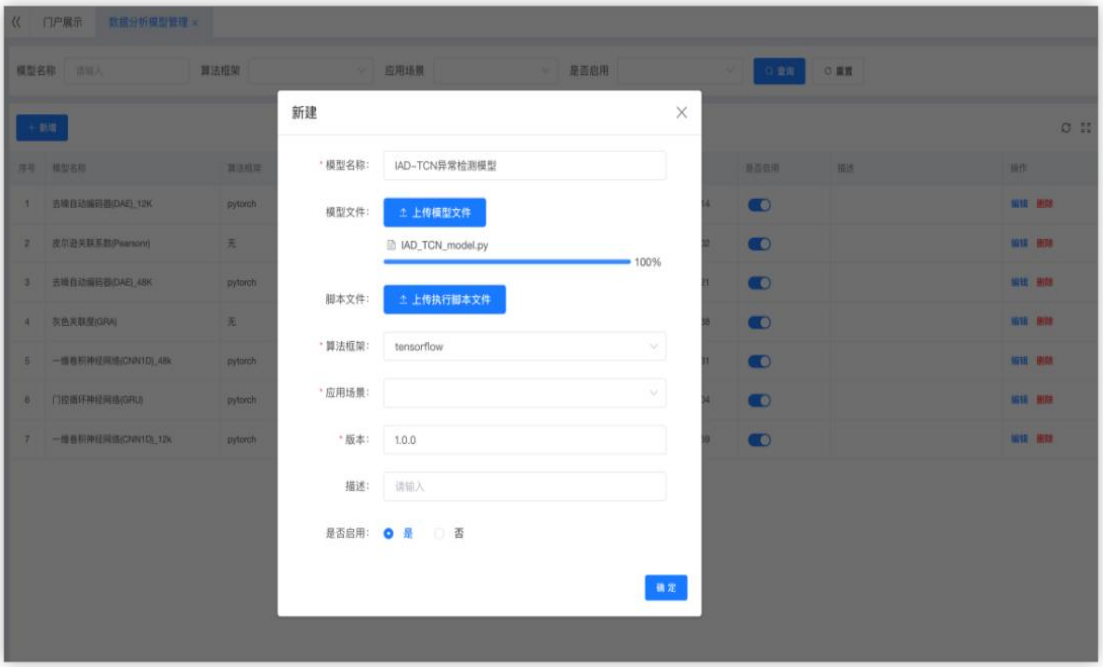


图 5.16 模型管理界面

在异常检测界面，用户可以使用系统或者自定义的异常检测模型对工业数据进行异常检测，在页面中，用户可以查看一些详细信息，如数据文件名称、算法名称、算法框架、异常检测结果、算法耗时、检测时间、查看结果以及删除操作，如图 5.17 所示。

中国知网 https://www.cnki.net

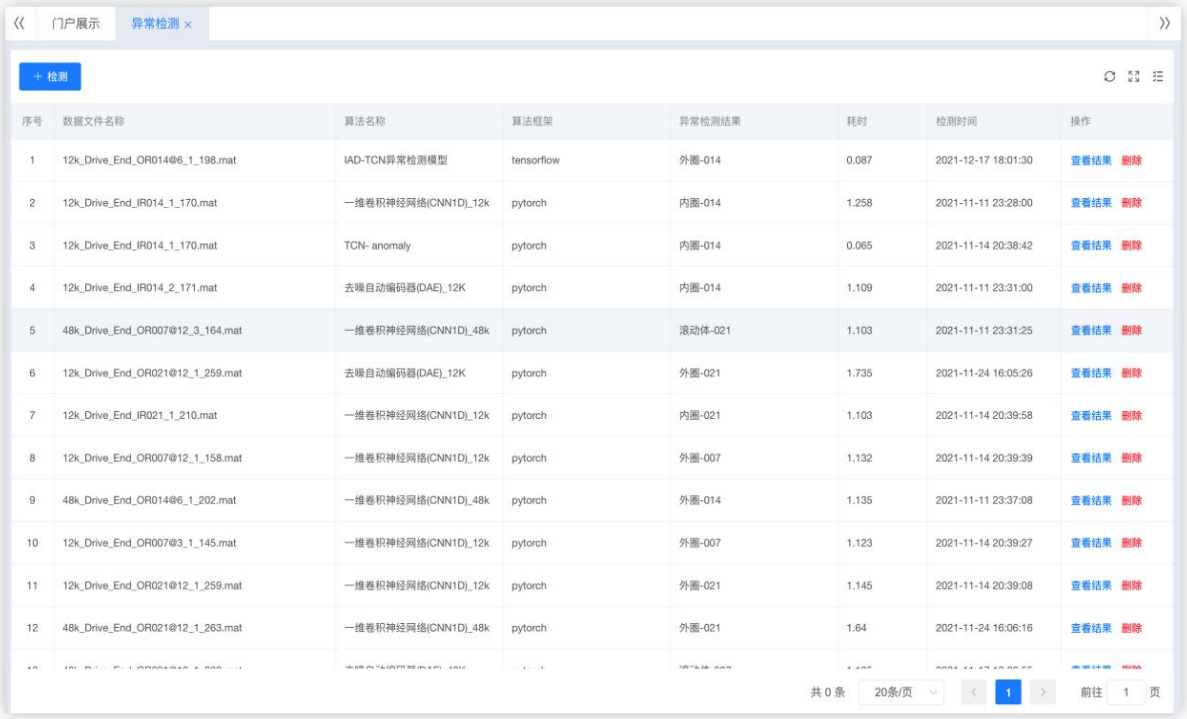


图 5.17 异常检测结果页面

如果用户需要进一步查看更详细的异常检测结果报告，获得实时的工业异常检测信息和预警报告，可点击查看结果按钮进行查看，如图 5.18 所示。在该结果页，系统会动态显示出实时的传感器等采集设备的监测值，这些采集值会实时通过本文所提出的异常检测模型 IAD-TCN 作出异常判断，同时系统还会利用 TCN 强大的预测能力为采集设备下一个时间步的采集值提前作出预测（时间步系统默认设置为 5s，可根据采集设备的采集时间粒度进行调整）。当系统收集到异常告警信息之后，会自动记录保存，并绘制成统计图表，如今日、本周、本月、本年或者选择时间段，方便工厂进行后续的汇总分析工作。



图 5.18 异常检测动态信息

中国知网 https://www.cnki.net

5.4 本章小结

本章主要介绍了工业大数据分析应用平台的设计与实现，阐述了其动机和背景，介绍了平台系统的功能架构以及技术架构，包括前端、后端和数据库的具体技术栈，并详细介绍了各部分模块功能的设计，最后展示了平台的实现效果，并将本文所提出的异常检测模型 IAD-TCN 部署应用到系统之中验证其效果。

中国知网 https://www.cnki.net

第六章 总结与展望

本章针对以上研究内容做了简单概括描述和总结，并对后续的研究工作进行了展望。

6.1 总结

当前，为了提高生产效率和成本，传统的工业已经在不断的进行智能化改造。同时，工业的发展进步成为了衡量国家硬实力的一个标准。随着大数据技术和人工智能的不断发展，大量的生产设备和监测传感器投入了工业生产使用，成为了工业互联网的关键一环，这也就意味着如何处理这些海量的数据，从中分析和提取出关键信息来指导生产和工厂决策成为了值得研究的重要问题。

在工业领域中，海量多源的数据涌出，普通的人工处理已无法满足需求。同时，由于生产设备或传感器所处的环境恶劣或者自身发生故障，亦或者是人为操作失误，造成数据可能会出现冗余、缺失等“脏数据”，为提高数据质量，为下一步数据分析提供更可靠的数据来源，数据清洗是工业数据分析业务中重要的前驱步骤。在完成数据清洗后，基于这些较高质量数据的异常检测工作，可以极大的降低人工巡检成本，提前预警和可视化检出潜在异常，预防和减少生产设备计划外停机时间，降低财产和人员安全损失。

为了解决以上问题，本文主要研究工业大数据清洗以及数据中的异常检测问题，具体内容包含如下：

首先，本文针对工业大数据中冗余值的清洗，采用了基于“排序合并”思想的邻近记录排序算法 SNM 进行重复记录检测，在保证相似重复记录检测率的同时降低了时间复杂度，最后在真实的工业数据集上验证，取得了良好的相似重复记录检测效果；其次，针对缺失值的插补，本文采用 LSTM 算法并解释了其算法原理和过程，然后在真实的工业数据集上做出了验证，对比了常见的缺失值填补方法 KNN 和拉格朗日插值法，得到了最佳的填补效果，并对算法在原始数据集上的拟合效果做出了验证。

然后，本文论述了时序卷积网络 TCN 的结构构成，包括因果卷积、膨胀卷积和残差连接过程等，然后阐述了注意力机制如何嵌入到模型中，提升模型的检测性能。通过在真实工业数据集上的实验对比，验证了本文所提出的异常检测模型 IAD-TCN 性能优于传统的异常检测模型，检测精度高，通用性强。

本文的最后，将所采用的数据清洗方法和所提出的异常检测模型 IAD-TCN 部署并应用到了实际的项目工业大数据存储分析应用平台中。其中详细介绍了工业大数据存储分析应用平台的动机和背景，功能架构的规划安排以及技术架构的具体实现，包括前端、后端和所采用的数据库技术等，展示了系统平台的运行效果。

6.2 未来展望

本文对工业时序大数据的异常检测做了一定的研究，通过回顾过程中遇到的问题，反思

中国知网 https://www.cnki.net

了未来可进一步优化的地方，主要为以下几个方向：

（1）对于所提出的异常检测模型 IAD-TCN，虽然嵌入了注意力机制可以提升模型检测精度，但也带了一些训练性能损失，如速度降低等问题，后续考虑模型在结构上是否可以继续优化，比如多头注意力机制；

（2）对于模型中异常判断阈值的选择，目前还是主要依赖于人工经验，对于不同的生产设备和流程，需要设定不同的数值，如果在后续的研究中可以自适应计算出不同环境下的阈值设置，实用性会得到更大的提升。

（3）由于工业大数据涉及到企业的核心利益问题，因此在本论文的研究中，所使用的工业数据量远低于实际生产过程中产生的数据量，虽然实际部署应用中所取得的效果不错，但仍可能会存在一些偏差，在未来的研究中，会不断扩充实验数据集模块，争取在更多工业数据量的前提下优化理论方法，减小偏差。

中国知网 https://www.cnki.net

参考文献

[1] Kanmani D , Ezhilarasi G . Data Quality Problems in Data Warehousing With Descriptive Classification. 2017.

[2] 陈挺, 郭颖, 刘云超. 中文字段匹配算法[J]. 计算机工程, 2003, 29(13):3.

[3] Smith T . Waterman MS: Identification of common molecular subsequences[J]. Journal of Molecular Biology, 1980, 147(1):195 – 197.

[4] Monge A E , Elkan C P . An Efficient Domain-Independent Algorithm for Detecting Approximately Duplicate Database Records. 2001.

[5] Dempster A P . Maximum likelihood from incomplete data via the EM algorithm[J]. Journal of the Royal Statistical Society, 1977, 39.

[6] Little R , Rubin D B . Statistical Analysis with Missing Data, 2nd Edition. 2014.

[7] Anand V, Mamidi V. Multiple Imputation of Missing Data in Marketing[C]//2020 International Conference on Data Analytics for Business and Industry: Way Towards a Sustainable Economy (ICDABI). 2020.

[8] Qi X , Guo H , Wang W . A reliable KNN filling approach for incomplete interval-valued data[J]. Engineering Applications of Artificial Intelligence, 2021, 100(315):104175.

[9] A.Kyrtsoglou et al., "Missing Data Imputation and Meta-analysis on Correlation of Spatio-Temporal Weather Series Data," 2021 IEEE 12th Annual Information Technology, Electronics and Mobile Communication Conference (IEMCON), 2021.

[10] Hippert H S , Pedreira C E . Combining Neural Networks and ARIMA Models for Hourly Temperature Forecast[C]// IEEE-INNS-ENNS International Joint Conference on Neural Networks. IEEE, 2000.

[11] Sridevi S , Rajaram S , Parthiban C , et al. Imputation for the analysis of missing values and prediction of time series data[C]// International Conference on Recent Trends in Information Technology. IEEE, 2011.

[12] Karevan Z , Suykens J . Transductive LSTM for time-series prediction: An application to weather forecasting[J]. Neural Networks, 2020, 125:1-9.

[13] Song D , Baek A , Kim N . Forecasting Stock Market Indices Using Padding-Based Fourier Transform Denoising and Time Series Deep Learning Models[J]. IEEE Access, 2021, PP(99):1-1.

[14] Araujo A S , Issa M , Medeiros P , et al. Monitoring Breast Cancer Neoadjuvant Treatment using Thermographic Time Series[C]//2021 IEEE 34th International Symposium on Computer-Based Medical Systems (CBMS). IEEE, 2021.

[15] Zhang S, Zheng H, Su H, et al. GACAN: Graph Attention-Convolution-Attention Networks

中国知网 https://www.cnki.net

for Traffic Forecasting Based on Multi-granularity Time Series[C]// 2021.

[16] Jin Y , Hou L , Chen Y. A Time Series Transformer based method for the rotating machinery fault diagnosis[J]. Neurocomputing, 2022(Jul.14):494.

[17] Box G , Jenkins G M . Time Series Analysis, Forecasting, and Control[J]. Holden-Day, Incorporated, 1990.

[18] Min H , Xu M . Laplacian Echo State Network for Multivariate Time Series Prediction[J]. IEEE Transactions on Neural Networks & Learning Systems, 2018, 29(99):238-244.

[19] Liu Z , Zhu Z , Gao J , et al. Forecast Methods for Time Series Data: A Survey[J]. IEEE Access, 2021, PP(99):1-1.

[20] 钟颖, 汪秉文. 基于遗传算法的 BP 神经网络时间序列预测模型[J]. 系统工程与电子技术, 2002, 24(4):3.

[21] Hassan M R , Nath B , Kirley M , et al. A hybrid of multiobjective Evolutionary Algorithm and HMM-Fuzzy model for time series prediction[J]. Neurocomputing, 2012, 81:1-11.

[22] Arnold M , Milner X , Witte H , et al. Adaptive AR modeling of nonstationary time series by means of Kalman filtering[J]. IEEE Trans Biomed Eng, 1998, 45(5):553-562.

[23] Cai X , Zhang N , Venayagamoorthy G K , et al. Time series prediction with recurrent neural networks using a hybrid PSO-EA algorithm[J]. Neurocomputing, 2007, 70(13-15):2342-2353.

[24] B X M A , C Z T A , D Y W , et al. Long short-term memory neural network for traffic speed prediction using remote microwave sensor data[J]. Transportation Research Part C: Emerging Technologies, 2015, 54:187-197.

[25] Kong F , Li J , Jiang B , et al. Integrated Generative Model for Industrial Anomaly Detection via Bi-directional LSTM and Attention Mechanism[J]. IEEE Transactions on Industrial Informatics, 2021, PP(99):1-1.

[26] Taylor, Sean, J,等. Forecasting at Scale[J]. American Statistician, 2018.

[27] Flunkert V , Salinas D , Gasthaus J . DeepAR: Probabilistic Forecasting with Autoregressive Recurrent Networks:, 10.1016/j.ijforecast.2019.07.001[P]. 2020.

[28] A. A. Cook, G. Mısırlı and Z. Fan, "Anomaly Detection for IoT Time-Series Data: A Survey," in IEEE Internet of Things Journal, vol. 7, no. 7, pp. 6481-6494, July 2020.

[29] Gu M , Fei J , Sun S . Online Anomaly Detection with Sparse Gaussian Processes[J]. Neurocomputing, 2020, 403(11).

[30] 卓琳, 赵厚宇, 詹思延. 异常检测方法及其应用综述[J]. 计算机应用研究, 2020(S01):7.

[31] Tian H , Yan Z , Zhang Q , et al. An LOF-Based Adaptive Anomaly Detection Scheme for Cloud Computing[C]// Computer Software & Applications Conference Workshops. IEEE, 2013.

[32] Fei T L , Kai M T , Zhou Z H . Isolation Forest[C]// IEEE International Conference on Data

中国知网 https://www.cnki.net

Mining. IEEE, 2008.

[33] Yang K, Kpotufe S, Feamster N . An Efficient One-Class SVM for Anomaly Detection in the Internet of Things[J]. 2021.

[34] Yang P , Huang B . An Efficient Outlier Mining Algorithm for Large Dataset[M]. IEEE Computer Society, 2008.

[35] 杨月麟, 毕宗泽. 基于深度学习的网络流量异常检测[J]. 计算机科学, 2021, 48(S02):7.

[36] Wu D , Jiang Z , Xie X , et al. LSTM Learning With Bayesian and Gaussian Processing for Anomaly Detection in Industrial IoT[J]. IEEE Transactions on Industrial Informatics, 16.

[37] Laptev N , Amizadeh S , Flint I . Generic and Scalable Framework for Automated Time-series Anomaly Detection[C]// Acm Sigkdd International Conference on Knowledge Discovery & Data Mining. ACM, 2015:1939-1947.

[38] Zhang X , Lin Q , Xu Y , et al. Cross-dataset time series anomaly detection for cloud systems[C]// USENIX Annual Technical Conference. USENIX Association, 2019.

[39] Evans P C , Annunziata M . Industrial Internet: Pushing the Boundaries of Minds and Machines[J]. sci.rep.kanazawa univ, 2012.

[40] 张凯编译. 工业数字化转型白皮书[J]. 互联网经济, 2021(3):8-19.

[41] Dagnino A . Data Analytics in the Era of the Industrial Internet of Things[M]. 2021.

[42] Grubbs, Frank E. “ Procedures for Detecting Outlying Observations in Samples. ” Technometrics 11 (1969): 1-21.

[43] A. A. Cook, G. Mısırlı and Z. Fan, "Anomaly Detection for IoT Time-Series Data: A Survey," in IEEE Internet of Things Journal, vol. 7, no. 7, pp. 6481-6494, July 2020 .

[44] Bhuyan M H , Bhattacharyya D K , Kalita J K . Network Anomaly Detection: Methods, Systems and Tools[J]. IEEE Communications Surveys & Tutorials, 2014, 16(1):303-336.

[45] Fang Z , Luo G , Xu S , et al. Stock Fluctuations Anomaly Detection Based on Wavelet Modulus Maxima[C]// International Conference on Business Intelligence & Financial Engineering. IEEE, 2009.

[46] Stojanovic L , Dinic M , Stojanovic N , et al. Big-data-driven anomaly detection in industry (4.0): An approach and a case study[C]// 2016 IEEE International Conference on Big Data (Big Data). IEEE, 2016.

[47] Wang Q . Traffic Analysis & Modeling in Wireless Sensor Networks and Their Applications on Network Optimization and Anomaly Detection[J]. Network Protocols & Algorithms, 2010, 2(1).

[48] ChaudhariSneha, MithalVarun, PolatkanGungor, et al. An Attentive Survey of Attention Models[J]. ACM Transactions on Intelligent Systems and Technology (TIST), 2021.

中国知网 https://www.cnki.net

[49] Tsotsos J K , Culhane S M , Wai W , et al. Modeling visual attention via selective tuning[J]. Artificial Intelligence, 1995, 78(1 – 2):507-545.

[50] Mnih V , Heess N , Graves A , et al. Recurrent Models of Visual Attention[J]. Advances in Neural Information Processing Systems, 2014, 3.

[51] Bahdanau D , Cho K , Bengio Y . Neural Machine Translation by Jointly Learning to Align and Translate[J]. Computer Science, 2014.

[52] Vaswani A , Shazeer N , Parmar N , et al. Attention Is All You Need[J]. arXiv, 2017.

[53] He K , Zhang X , Ren S , et al. Deep Residual Learning for Image Recognition[J]. IEEE, 2016.

[54] Salimans T , Kingma D P . Weight Normalization: A Simple Reparameterization to Accelerate Training of Deep Neural Networks:, 10.48550/arXiv.1602.07868[P]. 2016.

中国知网 https://www.cnki.net