面向工业设备监控的时序数据质量分析与智能预测方法

重庆大学硕士学位论文

（专业学位）

学生姓名：陈彦卿

指导教师：张　毅 教授

专业学位类别：电子信息（软件工程）

研究方向：大数据技术

答辩委员会主席：桑军

授位时间：2025 年 06 月

中国知网　https://www.cnki.net

Time Series Data Quality Analysis and Intelligent Forecasting Methods for Industrial Equipment Monitoring

A thesis submitted to Chongqing University

in partial fulfillment of the requirement

for the professional degree of Master of

Electronic Information

by

Yanqing Chen

Supervisor: Prof. Yi Zhang

June, 2025

中国知网 https://www.cnki.net

摘 要

工业设备运行安全监测关系到国家经济建设平稳运行、人民生命财产安全和社会稳定。在工业大数据领域，低质量数据可能引发生产决策链的系统性风险，高质量数据是优化工业生产流程、提升设备维护效率和改进产品质量的基础。工业时序数据预测作为智能制造的核心使能技术，对于挖掘工业系统的动态演化规律具有重要价值。研究工业设备时序数据质量的量化分析和预测方法并应用于实践，对于提升工业系统的智能化水平具有重要意义。

本文研究的主要工作内容如下：

（1）对比分析国内外数据质量评估模型和时序预测算法，分析传统方法在领域适配性和动态权重分配方面的不足，找出现有预测模型在工业噪声抑制、精确度不足、长程依赖捕捉等维度的局限性。

（2）提出一种面向工业设备时序数据的时序滑动窗口偏差（Time-series Sliding Window & Deviation, TSWD）质量量化算法。针对传统静态评估模型分析维度模糊不清、在复杂工况下灵敏度不足等问题，通过多维度量化体系精确评估数据质量，设计基于滑动窗口的动态偏差更新算法，构建了一种可靠的实时数据质量评估框架。实验结果表明，TSWD 算法具备良好的数据描述能力和高度的自适应性和可定制化性。

（3）提出一种基于深度学习的奇异谱分析-混合注意力-PatchTST（SSA-Hybrid Attention-PatchTST, SHAPT）时序数据预测模型。针对传统时序预测方法难以捕捉复杂工业数据的非线性关系和长程依赖性的问题，通过奇异谱分析分解数据趋势、周期和残差信息，结合 PatchTST 模型进行预测，并利用混合注意力机制实现局部与全局信息的加权融合，构建了高效的时序预测模型。实验对比结果验证了 SHAPT 模型在工业时序数据集上的预测能力，体现出其在复杂工况下的优越性。

（4）基于典型工业设备监测云平台的实际应用场景，将前述 TSWD 算法与 SHAPT 预测模型集成到工业设备监测云服务平台的研发中。通过应用相关的软件开发技术，并结合软件工程的实践方法，设计了工业设备数据质量评估与预测系统，实现从理论研究到实际应用的转化。

关键词：数据质量；时序数据预测；深度学习；自注意力神经网络

中国知网 https://www.cnki.net

Abstract

Ensuring the operational safety of industrial equipment is critical to the stable progression of national economic development, the protection of lives and property, and the maintenance of social stability. Within the domain of industrial big data, low-quality data can introduce systemic risks throughout the production decision-making chain. In contrast, high-quality data forms the foundation for optimizing production processes, improving equipment maintenance efficiency, and enhancing product quality. As a core enabling technology in intelligent manufacturing, time series forecasting of industrial data plays a vital role in uncovering the dynamic evolution patterns of industrial systems. Therefore, developing quantitative analysis and predictive methods for assessing the quality of time series data, and applying these methods in real-world scenarios, holds significant importance for advancing the intelligence level of industrial systems.

The main contributions of this thesis are as follows:

(1) A comparative analysis is conducted on domestic and international data quality assessment models and time series forecasting algorithms. The study identifies the limitations of traditional methods in terms of domain adaptability and dynamic weight allocation. Furthermore, it explores the shortcomings of existing predictive models in handling industrial noise, achieving high precision, and capturing long-range dependencies.

(2) An algorithm is proposed for quantifying the quality of industrial equipment time series data, referred to as the Time-series Sliding Window & Deviation (TSWD) method. To address the limitations of traditional static assessment models—such as ambiguous analytical dimensions and insufficient sensitivity under complex operating conditions—the TSWD algorithm introduces a multidimensional quantitative framework. It incorporates a sliding window-based dynamic deviation update mechanism to establish a reliable framework for real-time data quality evaluation. Experimental results demonstrate that the TSWD algorithm exhibits strong descriptive capabilities, high adaptability, and high customizability.

(3) A deep learning-based time series forecasting model, termed Singular Spectrum Analysis–Hybrid Attention–PatchTST (SHAPT), is introduced. This model addresses the challenges traditional forecasting methods face in capturing the nonlinear relationships and long-range dependencies inherent in complex industrial data. The SHAPT model

中国知网 https://www.cnki.net

decomposes data into trend, periodic, and residual components via SSA, utilizes the PatchTST architecture for efficient forecasting, and incorporates a hybrid attention mechanism to achieve weighted integration of local and global information. Comparative experimental results validate the superior predictive performance of the SHAPT model on industrial time series datasets, particularly under complex working conditions.

(4) In alignment with real-world application scenarios, the proposed TSWD algorithm and SHAPT model are integrated into the development of a cloud-based industrial equipment monitoring platform. By employing relevant software development technologies and leveraging practical software engineering methodologies, a comprehensive system for data quality assessment and time series forecasting is designed. This system facilitates the translation of theoretical research into practical industrial applications.

Keywords: data quality; time series forecasting; deep learning; self-attention neural network

中国知网 https://www.cnki.net

目 录

摘 要 I
Abstract II
目 录 IV
1 绪 论 1
1.1 研究背景与意义 1
1.2 国内外研究现状 2
1.2.1 工业设备时序数据质量量化分析方法的研究现状 2
1.2.2 工业设备时序数据预测方法的研究现状 4
1.3 主要研究内容 7
1.4 论文章节安排 8
2 数据质量分析方法及时序数据预测方法 10
2.1 引言 10
2.2 工业时序数据的特征 10
2.3 数据质量核心维度 12
2.3.1 数据质量维度定义与划分 12
2.3.2 数据质量核心维度定义 14
2.4 数据质量评估框架 16
2.4.1 面向工业应用的自适应数据质量评分操作框架 16
2.4.2 五维数据质量评估框架 17
2.4.3 面向油气工业场景的全流程数据质量管理框架 18
2.5 基于深度学习的时序数据预测方法 19
2.5.1 循环神经网络 19
2.5.2 注意力机制 22
2.5.3 Transformer 23
2.6 本章小结 27
3 TSWD 数据质量量化计算方法 28
3.1 问题定义与方法总览 28
3.2 TSWD 算法提出 30
3.2.1 时序滑动窗口 30
3.2.2 偏差更新 31
3.3 TSWD 算法模型构建 32

中国知网 https://www.cnki.net

3.3.1 准确性 33
3.3.2 完整性 33
3.3.3 一致性 34
3.3.4 时效性 35
3.4 实验设计 36
3.4.1 数据集介绍与构建 36
3.4.2 实验相关参数 37
3.5 实验过程和结果分析 37
3.5.1 基准实验 37
3.5.2 定制化实验 39
3.5.3 结果分析 41
3.6 本章小结 41
4 SHAPT 时序数据预测模型 42
4.1 问题定义与方法总览 42
4.2 SHAPT 预测模型提出 42
4.2.1 基于奇异谱分析的时序数据分解 42
4.2.2 基于混合注意力改进的 PatchTST 的时序数据预测 45
4.3 实验设计 50
4.3.1 数据集介绍与构建 50
4.3.2 实验环境 50
4.3.3 实验相关参数 51
4.3.4 实验指标 52
4.4 实验过程和结果分析 53
4.4.1 对比实验 53
4.4.2 消融实验 56
4.5 本章小结 59
5 工业时序数据质量分析与预测应用平台实现 60
5.1 应用背景 60
5.2 系统设计 60
5.2.1 系统架构设计 60
5.2.2 功能模块设计 63
5.2.3 数据库设计 64
5.3 系统实现 66
5.4 本章小结 69

中国知网 https://www.cnki.net

6 总结与展望 70
6.1 总结 70
6.2 研究展望 71
参考文献 72
附 录 77
A. 作者在攻读学位期间的学术论文 77
B. 作者在攻读学位期间取得的专利 77
C. 作者在攻读学位期间参与的科研项目 77
D. 学位论文数据集 78
致 谢 79

中国知网 https://www.cnki.net

1 绪 论

1.1 研究背景与意义

在“工业 4.0”与“中国制造 2025”国策的推动下，我国众多产业正迈向智能制造的转型需求之路。5G 技术的引入进一步增加了对于工业物联网产生的大规模数据在质量监控与分析方面的精确与及时性要求。工业设备的时序数据在现代工业生产中发挥着越来越关键的作用，其质量直接影响着工业系统的运行效率、决策的准确性以及预测的精度。因此，对工业设备的时序数据进行质量分析和预测，是确保数据可靠性和有效性的重要环节。

数据质量问题由来已久，并且随着数据规模的不断扩大而日益凸显。早期的研究主要关注数据质量的分析及其在应用中的体现[1]，以及数据质量管理的相关实践[2][3]。然而，随着大数据时代的到来，数据质量的内涵和挑战也随之演变，例如，从传统的数据质量概念逐渐扩展到更宏观的“大数据质量”[4]。近年来，国内外学者对大数据质量的研究持续深入，包括其历史沿革、发展趋势[5]、评估方法、治理策略以及与操作绩效的关系[6]。尤其是在工业领域，数据质量问题显得更为复杂，例如，在可持续时尚供应链中，数据质量面临来自区块链、政府支持和环境税等多重挑战[9][10]。此外，研究也开始探讨大数据质量评估与数据治理之间的关系[11]。

对工业设备时序数据进行质量分析及预测，具有重要的理论和实践意义。工业时序数据常用于监控设备状态、预测故障以及优化生产流程。如果数据存在缺失、异常或冗余等问题，将直接导致错误的决策，进而造成生产中断或资源浪费。通过对数据质量的及时分析和预测，可以迅速发现并处理问题数据，为管理者提供更准确、更可靠的决策依据。高质量的工业时序数据是实现智能制造和工业物联网等先进技术的基础，有助于优化系统性能。对数据质量的预测有助于保障预测模型的可靠性。工业生产常常利用时序数据构建各种预测模型，例如设备剩余寿命预测或产品质量预测。数据的质量直接影响着这些模型的准确性和鲁棒性。数据质量分析和预测也是促进数据治理的关键组成部分。通过深入研究数据质量的评价对象、体系、方法与技术[12]，可以建立起完善的数据质量管理体系。这不仅能提升企业数据资产的价值，也为工业的智能化转型奠定了坚实的基础。

工业设备时序数据质量分析及预测是当前工业领域亟待解决的关键问题，它对于保障工业系统的稳定运行、提升生产效率以及推动工业智能化发展具有深远而重大的意义。

中国知网 https://www.cnki.net

1.2 国内外研究现状

1.2.1 工业设备时序数据质量量化分析方法的研究现状

数据质量量化分析方法的研究发展历程可追溯至 21 世纪初，初期主要聚焦于数据质量概念的界定、评估维度及基础方法论的构建。Pipino 等人[13]在 2002 年就系统性地探讨了数据质量评估的基本原则，为后续研究奠定了理论基础。Eppler 等人[14]则针对 Web 环境下的信息质量，调研了当时的先进工具和应用方法，体现了早期对特定应用场景数据质量的关注。与此同时，国内研究者也积极探索，如杨青云等人[15]对数据质量评估方法进行了深入研究。这一阶段的研究核心在于明确数据质量的各项属性（如准确性、完整性、一致性等）并探索初步的度量手段，例如 Su 等人[16]提出了机械产品设计制造过程中的信息质量评估方法，韩京宇等人[17]也着手研究了数据质量维度的量化方法，为后续的量化分析提供了理论基础。

随着数据应用场景的拓展和复杂性的增加，数据质量量化分析逐渐迈向体系化和智能化。Batini 等人[18]在 2008 年便提出了针对 Web 和结构化数据的综合数据质量方法，并于次年在文献[19]中系统总结了数据质量评估和改进的多种方法论，极大地推动了数据质量管理体系的完善。研究也开始关注数据质量的可测量性，如 Arazy 等人[20]探讨了信息质量的量化问题。进入大数据时代，数据质量量化分析面临新的挑战，研究重心开始向适应大数据特性的方向转变。Aggarwal[21]提出了评估大数据“3V”维度的框架，而 Ardagna 等人[22]则进一步探索了大数据环境下情境感知的数据质量评估，强调了评估的动态性和适应性。丁小欧等人[23]也研究了数据质量多种性质的关联关系，揭示了数据质量维度间的复杂互动，为大数据背景下多维度的质量评估提供了理论支撑。

近年来，数据质量量化分析的研究趋势日益呈现出深度学习与智能化的特点，以应对现代数据环境的复杂性和规模。Kulkarni[24]和 Mo[25]分别从元数据管理和大数据质量建模的角度进行了探索，Li 等人[26]则研究了大数据环境下数据源质量的综合评价。尤为值得关注的是，人工智能技术的引入，使得数据质量评估的精度和自动化水平大幅提升。Liu 等人[27]提出的基于多头注意力机制的多维数据质量评估模型，利用深度学习捕捉复杂关系，标志着数据质量评估向智能化迈进。此外，针对特定领域的应用，如谷阳阳[28]提出的基于信息熵的遥测数据质量维度量化方法，以及 Bayram 等人[29]提出的自适应数据质量评分框架，都体现了数据质量量化分析在不同场景下的实践与创新。当前，研究仍持续关注数据质量评估面临的挑战和机遇，例如 Belgoumri 等人[30]和 Mohammed 等人[31]的综述就指出了边缘机器学习等新兴技术对数据质量评估带来的新挑战，以及 Kang 等人[32]将数据质量管理框架应用于工业故障风险估计，进一步拓展了数据质量量化分析方法的应用边界。

中国知网 https://www.cnki.net

工业领域的数据质量量化分析方法，其发展历程与通用数据质量研究既有共通之处，又因工业生产的特殊性而呈现出鲜明的独特性。早期工业数据质量研究主要以基于规则的检测和人工干预为主，缺乏系统性的量化评估体系。随着工业信息化进程的加速，数据量激增，传统方法难以应对。此时，研究开始关注工业大数据处理流程中数据质量的影响，莫祖英[33]分析了数据质量问题对工业大数据应用链条的负面作用，这标志着对工业数据质量重要性的认识从局部扩展到全局。

进入工业大数据时代，工业领域的数据质量量化分析方法研究开始凸显其区别于其他领域的特性。工业数据，尤其是工业时序数据，具有高并发、高维度、强关联性、强实时性以及噪声多、异常值频繁等特点，且数据质量问题往往直接关联到生产安全、设备健康与经济效益。这些特性使得通用领域的数据质量评估方法难以直接应用。丁小欧等人[34]聚焦于工业时序大数据质量管理，致力于解决工业场景下海量时序数据的质量挑战。此外，工业数据的质量评估往往需要深入结合物理机理和领域知识。例如，传感器数据如果超出物理允许范围，则可直接判定为质量问题，这与金融、电商等领域纯粹依赖数据统计特征的质量评估有本质区别。Toothman 等人[35]在工业预测与健康管理解决方案中强调了数据质量的重要性，也从侧面反映了工业数据质量直接影响物理系统运行的特殊性。

近年来，数据质量领域在理论建模与实践框架方面取得了长足进展，尤其是在人工智能与工业智能背景下的融合研究日益增多。尤祺等人[36]提出的基于神经网络的工业时序数据质量管理方法，通过机器学习模型自动识别和修复工业时序数据中的质量问题，极大地提升了处理效率和准确性。Cate[37]提出了一种基于预测分析的风险管理增强框架，将数据质量嵌入决策流程，强调历史数据的可用性与准确性在预测模型中的重要地位。在多领域交叉融合的背景下，Olawade 等人[38]聚焦于 AI 在法医心理健康中的数据使用，系统评估了数据质量、隐私保护与算法偏差之间的复杂关系，其所提出的“AI 法律数据责任框架”对数据质量监管提出更高要求，也体现了领域对高质量数据需求的制度化趋势。Raddy 等人[39]则面向医疗健康领域，提出了跨系统互操作性框架中用于评估健康数据质量的结构性方案，强调了在数据共享与平台对接过程中完整性和一致性的重要性。Zhao 等人[40]提出了一种名为 TFE-IVBRE 的深度特征提取与增量集成建模框架，用于工业质量指数预测任务。其核心是利用时序特征编码对工业数据进行高效建模，并引入数据质量感知机制，使得模型不仅关注预测值本身，还内嵌对数据有效性与置信度的判别能力。Lu 等人[41]则从不确定性优化出发，利用贝叶斯学习和马尔可夫过程建构任务终止判定模型，并通过观测数据进行动态学习，强调了数据观测过程中的质量评估对建模收敛性与效率的影响，提供了数据质量在“主动学习-反馈决策”闭环中的应用路径。

中国知网 https://www.cnki.net

当前数据质量领域的研究逐步从早期静态、多维描述性方法转向动态、决策敏感型的质量评估机制。无论是 AI 决策系统、健康互操作平台，还是工业深度预测框架，数据质量都从外围保障演化为模型核心变量之一，成为确保模型可靠性、任务稳定性与跨系统协同的关键支撑因素。这些研究不仅延续了传统评估方法中的维度体系，也结合具体任务需求提出了任务驱动型、语境感知型的数据质量评估新范式，展现出强烈的智能化与系统集成趋势。

1.2.2 工业设备时序数据预测方法的研究现状

时序数据预测是数据分析领域的核心任务之一，其发展历程伴随着统计学与人工智能技术的演进。早期，传统统计学方法占据主导地位，其中最具代表性的是由 Box 和 Jenkins 等人系统提出的自回归移动平均（ARIMA）模型及其变体[42]。这类模型通过分析时间序列自身的历史模式（如趋势、季节性、自相关性等）进行预测，在许多领域展现出良好的性能，成为时序预测的基石。然而，面对复杂非线性和高维时序数据时，传统统计模型的表达能力受到限制。

进入 21 世纪，随着机器学习技术的兴起，时序数据预测方法取得了显著进展。混合模型的提出是这一时期的重要突破，例如 Zhang[43]将 ARIMA 模型与神经网络结合，旨在融合线性与非线性建模优势。神经网络，尤其是循环神经网络（RNN）及其变体长短期记忆网络（LSTM），因其处理序列数据的天然优势，在时序预测中得到广泛应用。例如，Wang 等人[44]利用 CT-LSTM 进行空气质量预测，Wei 等人[45]将多头注意力机制融入 LSTM 以提升交通流量预测，Priya 等人[46]也采用注意力机制的 LSTM 模型进行作物产量预测。这些方法有效捕捉了时序数据中的复杂依赖关系，提升了预测精度。此外，针对电力负荷预测等特定领域，研究人员也积极探索人工智能方法，Raza 等人[47]对基于 AI 的负荷预测技术进行了综述，Martínez-Álvarez 等人[48]也调查了应用于电力相关时序预测的数据挖掘技术。

当前，时序数据预测的研究正朝着深度学习和自注意力机制的方向深入发展。特别是 Transformer 模型及其变体，因其强大的并行计算能力和捕捉长距离依赖的优势，在时序预测领域展现出巨大潜力。Li 等人[49]通过改进 Transformer 的局部性和内存效率，使其更适用于时序预测。Liu 等人[50]则提出了基于样本卷积和交互的 SciNet 模型，进一步优化了时序建模。此外，多变量时序建模也成为研究热点，例如 Zhang 等人[51]利用 DCGNet 对烧结炉烧结温度进行预测。这些前沿研究致力于克服传统模型的局限性，提升对复杂、高维时序数据的预测能力，并在能源、环境、工业控制等多个领域得到了广泛应用，如 An 等人[52]在水质预测中的应用。同时，研究人员也持续关注模型评估的严谨性，例如 Bergmeir 和 Benítez[53]就探讨了交叉验证在时序预测评估中的应用，确保模型性能的可靠性。

中国知网 https://www.cnki.net

早期工业领域的时序数据预测主要依赖于机理模型和传统控制理论，但随着数据量的激增和过程复杂性的提升，数据驱动的预测方法逐渐崭露头角。文献[54]体现了数据驱动预测在工业过程中的应用。这一阶段，统计方法如 ARIMA 模型也被引入，但其线性假设和对稳定性的要求，在面对工业生产中常见的非线性、非平稳、多变量耦合等复杂时序数据时，往往表现出局限性。

进入工业大数据时代，工业时序数据预测的研究进入了快速发展期，并开始凸显其区别于其他领域的特点。一方面，数据规模庞大且更新速度快，使得数据处理和特征提取成为重要挑战，Christ 等人[55]关注了工业大数据应用的分布式并行时序特征提取。Villalobos 等人[56]的工作也强调了工业时序数据存储系统的需求。另一方面，工业数据的多源异构性、高噪声和潜在的强关联性对模型提出了更高要求。例如，设备运行数据、传感器数据、环境数据等需要融合处理，且其中可能存在大量由传感器故障或通信中断引起的异常值和缺失值。这些特性促使研究人员探索更为鲁棒和高效的预测模型。

当前，深度学习技术已成为工业时序数据预测的主流方向，并针对工业场景特性进行了诸多创新。循环神经网络（RNN）及其变体长短期记忆网络（LSTM）因其处理序列数据的天然优势被广泛应用，并进一步结合注意力机制以捕捉关键时序依赖和多变量关联，如 Yuan 等人[57][58]利用带时空注意力机制的 LSTM 开发工业软测量模型，Ren 等人[59]则将 CNN 与 LSTM 结合预测锂电池剩余使用寿命。此外，Transformer 模型因其强大的并行计算能力和处理长序列的能力，在工业领域也备受关注，周哲韬等人[60]将其应用于滚动轴承剩余使用寿命预测，黄飞虎等人[61]和骆钊等人[62]也改进 Transformer 模型用于电力负荷和风电功率预测。这些方法不仅提升了预测精度，更重要的是能够适应工业生产过程中的动态变化和复杂关联，为工业设备健康管理、智能控制、质量预测等提供了关键技术支撑。Kashpruk 等人[63]对工业 4.0 中的时序预测进行了全面综述，进一步体现了该领域在工业智能发展中的重要地位。工业领域的时序预测，其核心在于如何有效处理工业数据特有的高噪声、多变量强耦合、实时性要求高以及结果直接影响物理世界等挑战，这使得其研究方法论往往更侧重于模型的鲁棒性、可解释性和与实际工业过程的紧密结合。

近年来，时序数据预测作为智能制造、能源调度和交通管理等多个工业领域的关键技术，持续吸引研究者关注。Tessoni[64]系统研究了离线与在线预测维护中的多变量时序建模问题，提出一种集成深度学习架构，融合卷积神经网络（CNN）与门控循环单元（GRU）模型用于工业传感数据的异常检测与预测。Duan 等人[65]将数据预处理与机器学习模型紧密耦合，构建了面向集装箱海运市场（SCFI）的预测系统。在新能源交通领域，Huang 等人[66]提出结合鲸鱼优化算法（WOA）与

中国知网 https://www.cnki.net

LSTM的充电桩故障预测模型。该方法通过WOA自动调整LSTM网络的超参数，以增强模型在小样本与突发故障数据中的稳定性与准确性。Ashour 等人[67]研究了天然气产量预测中的循环神经网络应用，结合金融、气象与工业三类数据源，使用多输入 RNN 实现产量动态估计。Kong 等人[68]在工业过程少样本预测领域引入了多域图元学习网络（MD-GMLN）。该模型通过对跨工艺领域的小样本数据构建图结构关系，实现类比迁移学习，显著降低了预测对数据量的依赖，并提升了对稀缺工况预测的准确性。

目前，时序数据预测研究展现出明显的多样化技术融合趋势。从卷积循环混合架构、到预处理与集成优化结合的系统设计，再到引入进化优化算法与跨模态多输入建模，反映出对模型泛化性、可解释性与小样本建模能力的广泛追求。同时，预测建模也不断扩展其在工业材料科学与图结构少样本学习等边界场景的应用。

通过对于国内外相关研究内容进行分析和归类后，可以发现一些不足之处：

(1) 随着数据量的爆炸性增长，手动评估数据质量变得越来越不现实。然而，当前的研究和实践中，自动化评估工具和方法仍然不足，特别是在处理复杂数据结构和大规模数据集时的高效性和准确性方面。

(2) 虽然一些国际组织和研究机构已经开始制定数据质量标准，但全球范围内的标准化进程仍然缓慢。数据质量评估和管理的标准不统一，使得跨领域、跨行业的数据质量保证和评估工作变得复杂。

(3) 许多现有的数据质量衡量指标往往依赖于主观评价标准，而缺乏明确的、客观的量化依据。这种依赖主观判断的评估方式可能导致评估结果的高度依赖个体经验或专业领域的偏好，从而降低了结果的客观性和一致性。在实际应用中，尤其是在复杂的工业大数据分析和决策支持中，缺乏统一标准的主观评价可能引发数据解释的歧义或决策误差。

(4) 尽管时序数据预测已在等多个领域得到了广泛应用，并且取得了显著的成果，然而，针对时序数据本身质量预测的研究仍然是一个相对较为薄弱且待开发的领域。传统的时序数据预测方法主要侧重于对未来趋势和数值的预测，较少关注数据质量层面的预测与评估。

(5) 数据质量的理论研究已经取得了一定的成就，但如何将这些理论有效地应用于实际中，尤其是在新兴的数据应用场景中（如物联网、大数据分析等），还存在一定的差距。实践中的复杂问题往往需要理论更加具体和实用的指导。如何在这些新环境下保证数据质量的研究还不够深入。

中国知网 https://www.cnki.net

1.3 主要研究内容

目前，针对数据质量量化计算以及将时序数据预测引入数据质量评估的研究仍处于起步阶段，相关文献和方法的数量较为有限，尚未形成系统化的理论和应用框架。这种研究不足使得现有方法在应对复杂的时序数据质量问题时显得捉襟见肘，难以满足实际应用中的高精度和实时性需求。为此，本文从这一研究空白出发，深入探讨数据质量量化计算的理论与方法，并将时序数据预测技术引入数据质量评估与预测的框架中，以构建一套兼具实用性和学术价值的综合解决方案，期望在丰富数据质量评估理论体系的同时，为工业领域及其他应用场景中复杂数据的质量管理提供新的技术手段和实践方向。

本文的主要研究内容如下：

(1) 分析对比了国内外数据质量的标准和维度划分和时序数据预测的算法模型，分析传统预测模型泛化能力不足、精确度低等问题。研究了时序数据的特点以及数据质量评估维度的分类方法，并系统梳理了国内外现有的数据质量评估模型和时序数据预测算法模型。

(2) 构建了数据质量量化计算方法 TSWD，以弥补现有数据质量评估模型在量化计算能力上的不足。针对工业时序数据的特性，该算法重新设计并改进了核心数据质量维度的量化计算方法，能够显著提高评估的精度和细致程度。

(3) 提出了时序数据预测模型 SHAPT。引入奇异谱分析方法对原始时间序列数据进行预处理。以 PatchTST 模型[77]为基础，引入混合注意力机制，融合局部注意力与稀疏全局注意力，对预处理后的时序数据进行深度表征学习，最终通过线性投影与预测头生成目标时间段的预测值。整体框架实现从原始工业时序数据出发，依托结构性分解、混合注意力感知与深度特征建模的完整预测流程，为工业过程中的数据质量评估与趋势预测任务提供建模支持。

(4) 将模型应用于工业设备云服务平台中。对工业数据质量设计了相应的数据库，将数据质量评估和经过预测模型预测的数据显示到可视化界面上，以一定频率统计当前时间段工业数据不同指标的质量状况，计算质量健康状况。通过与设定的阈值比较，确定是否需要进行预警。

中国知网 https://www.cnki.net

1.4 论文章节安排

论文的章节安排如图 1.1 所示，共分为六个章节。

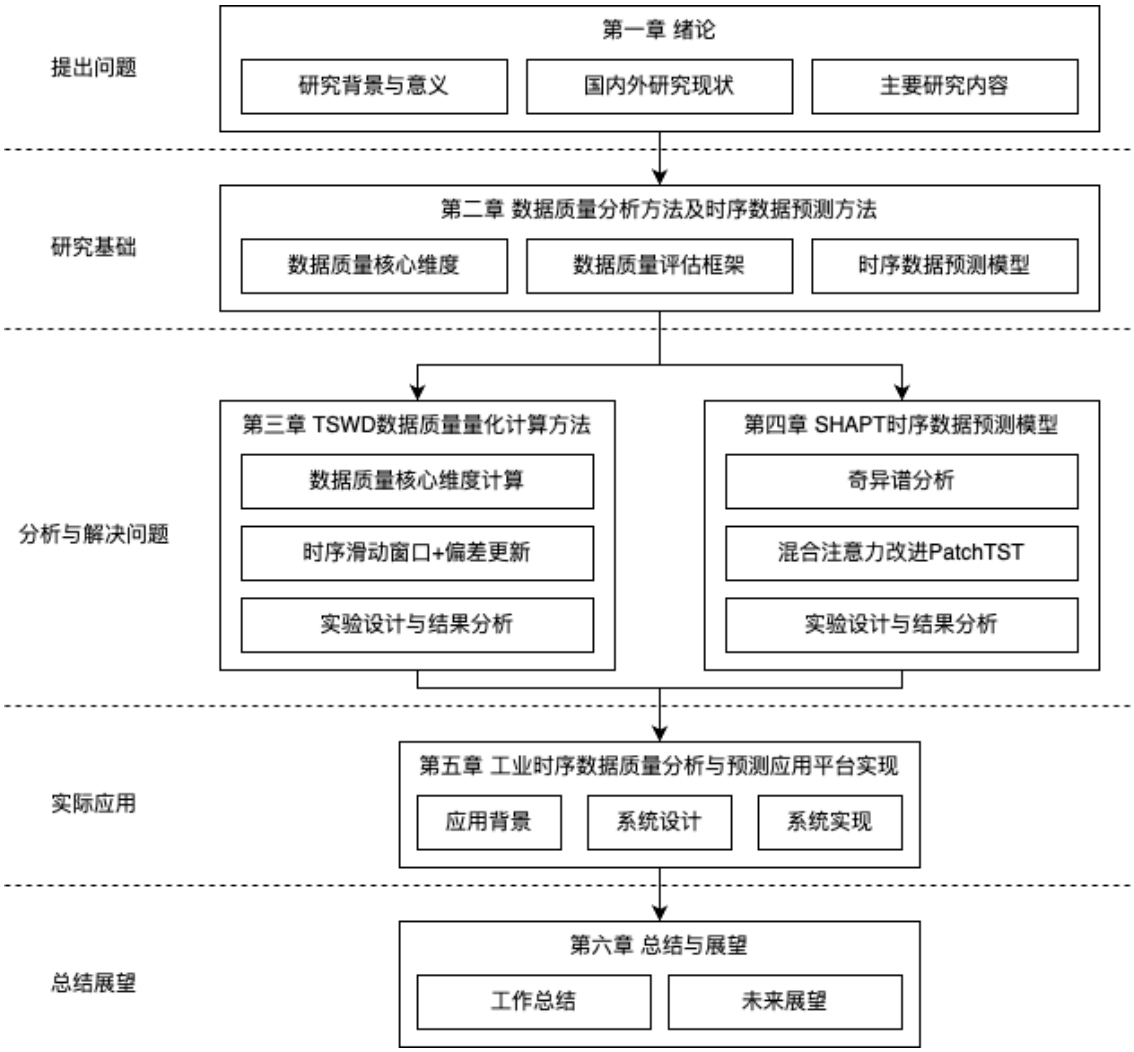


图 1.1 论文章节安排结构图

Fig. 1.1 Section Arrangement Structure of the Thesis

第一章：绪论。作为论文的起始章节，介绍了课题研究的背景，阐明了工业大数据的环境下，对于工业数据质量进行分析和趋势预测的重要意义，并且概述了与本课题相关的国内外研究的算法模型，从此基础上，提出了本文的研究目的和主要内容，最后对论文的组织结构进行说明。

第二章：相关基础与技术分析。论文的重要章节之一，介绍了数据质量的重要性和对业务决策的影响，然后详细说明当前业界对于工业数据质量的定义、界定和维度划分，以及构建有效数据质量评估模型的关键步骤，包括数据质量维度的定义、评估指标的选择、以及评估方法的应用，并对常见的时序数据预测模型

中国知网 https://www.cnki.net

进行分析归纳。

第三章：TSWD 数据质量评估模型构建。核心章节之一，介绍了 TSWD 数据质量评估模型，通过考量历史数据对当前数据的影响和计算偏差值，实现全面而可信的评估。该模型的改进措施、计算公式和规范确保了多维度的数据质量反映。实验设计涵盖了参考和模拟数据集及模型参数配置，验证 TSWD 算法在不同情境下的表现。最后对比了 TSWD 算法与近年来提出的数据质量评估框架，展示了 TSWD 算法在工业设备数据质量量化计算方面的优势。

第四章：SHAPT 预测模型构建。核心章节之一，先分别介绍了奇异谱分析和基于 PatchTST 的混合注意力改进预测算法的原理，再介绍了整体预测模型结构和原理，并且相应的展示了在数据集上的应用效果。最后通过对比实验验证了 SAL 预测模型对比其他预测模型的预测效果，以及通过消融实验验证了 SHAPT 各模块的协同作用。

第五章：工业数据质量检测系统设计和实现。作为模型的应用部分的章节，介绍了典型工业数据质量检测系统的设计，包括整体架构、数据库、功能模块等的设计环节。展示了系统的实现效果，以及对效果进行分析，验证模型的可用性。

第六章：总结和展望。论文的结尾章节，总结论文的工作和成果，并对未来进行展望，提出后续工作方向和可改进的潜在方向。

中国知网 https://www.cnki.net

2 数据质量分析方法及时序数据预测方法

2.1 引言

在电子数据无所不在的今天，数据质量在各类商业及政府应用中显得尤为关键。数据质量被广泛认为是影响运营流程性能、决策活动以及跨组织合作需求的一个重要因素。为了提升数据质量，公共部门和私营部门已经启动了多项倡议，例如美国政府在 2002 年实施的数据质量法案，以及威尔士政府在 2004 年为提升所有普通医疗实践信息质量而启动的数据质量倡议框架。

与此同时，信息系统从层级式或单体式结构转变为基于网络的结构，使得组织可利用的潜在数据源的规模和范围大大增加。这种变革使得数据质量问题变得更加复杂和有争议。在网络化信息系统中，复杂的信息交换过程经常依赖于外部来源的输入，这些来源往往事先不为人知。因此，如果不对过程和信息输入的质量进行控制，信息系统中的数据质量可能会迅速恶化。然而，网络化信息系统也为数据质量管理提供了新机遇，包括更广泛的数据源和选择、比较不同来源数据以便检测和纠正错误的能力，从而提高数据整体质量。

工业场景中的时序数据质量分析与预测方法与其他领域存在显著差异，主要体现在数据特性、异常模式和应用要求等方面。工业设备数据通常由 PLC、SCADA 等系统以毫秒至秒级频率采集，数据量庞大且多为物理量，如温度、压力、电流等，这些变量之间存在强耦合关系和物理约束。此外，工业场景中的数据异常表现为漂移、突变、间歇性波动等复杂模式，远比医疗、金融等领域的离群点或跳变异常更为隐蔽和难以建模。工业系统对数据的实时性和一致性也有更高要求，延迟或误判可能直接影响设备安全与生产效率。因此，相较于其他场景，工业领域的数据质量分析更侧重于动态、连续、多维度的质量评估，且需嵌入工程先验与物理边界。近年来的研究指出，传统数据质量方法在工业预测与健康管理模型中表现出实时性差、误报高、无法适应工况波动等问题，急需更具鲁棒性与解释性的定量分析方法。

2.2 工业时序数据的特征

工业时序数据是指在工业生产和运营过程中，随时间顺序收集的数据，它们通常来自于传感器、机器日志、系统状态记录等。这些数据具有以下几个特征：

(1) 时间相关性与序列依赖性：工业时序数据的基本属性是其与时间的紧密关联，每个数据点都带有时间戳，并且数据点之间的顺序对分析至关重要。这种时间依赖性意味着分析时必须考虑数据的时序特性，包括周期性、季节性及长期

中国知网 https://www.cnki.net

趋势。

(2) 高维多变量特性：工业时序数据通常来源于复杂的工业系统，涵盖了多个参数和指标，如温度、压力、速度等，这些参数间可能存在相互依赖和关联。因此，工业时序数据的分析需要处理高维数据并能够捕捉多变量间的动态关系。

(3) 异常、噪声与数据缺失：工业环境的复杂性和不可预测性导致时序数据常含有噪声、异常值及数据缺失。这些特性要求在数据预处理、分析和模型构建过程中必须采取特定策略来识别异常、处理噪声和补全或忽略缺失数据。

工业时序数据可以根据不同的标准和需求被分类为多个类型。以下是一些常见的分类方式：

按数据源分类：

(1) 传感器数据：直接从物理传感器收集的数据，如温度、压力、流量、振动等。

(2) 操作日志数据：记录设备操作和用户操作的日志数据，如启停机时间、操作员操作记录等。

(3) 过程控制数据：与生产过程控制相关的数据，如设定点、控制器状态、阀门开度等。

按采样频率分类：

(1) 高频数据：以非常高的频率（如每秒、每毫秒）采集的数据，常见于对实时监控要求较高的场景。

(2) 低频数据：以较低的频率（如每分钟、每小时甚至每天）采集的数据，适用于对实时性要求不高的长期趋势分析。

按数据特性分类：

(1) 连续数据：数值连续变化的数据，可以在任意两个数值之间取值，如温度、压力等。

(2) 离散数据：只能在有限或可数的值集合中取值的数据，如设备状态（开/关）、报警代码等。

按时间序列的统计特性分类：

(1) 稳定序列：时间序列的统计特性（如均值、方差）在时间上保持不变。

(2) 非稳定序列：时间序列的统计特性随时间变化，可能包含趋势、季节性等成分。

按用途或应用场景分类：

(1) 监控数据：用于实时监控设备和过程状态的数据。

(2) 预测数据：用于基于历史和当前数据预测未来状态的数据。

(3) 诊断数据：用于分析和诊断设备故障或性能下降的原因的数据。

中国知网 https://www.cnki.net

其中，本文围绕工业生产环境中传感器所采集的连续性数据展开研究，旨在对监控数据进行系统性分析与质量评估，进而使用深度学习模型对其进行建模与预测，以实现对工业生产过程中关键状态的前瞻性判断，为工业运行决策提供数据支撑与智能参考。

2.3 数据质量核心维度

2.3.1 数据质量维度定义与划分

在 1990 年代，由美国麻省理工学院的研究团队，在 Stuart Madnick 和 Richard Y. Wang 教授的领导下，首次系统地提出了全面数据质量管理（TDQM）的概念，从而为数据质量管理领域奠定了坚实的理论基础。该研究主要聚焦于明确数据质量的定义、识别质量的多维度特征以及构建 TDQM 理论框架。当时，学术界对于数据质量尚未有一个广泛认同的定义，MIT 的提议——将数据质量视为数据对于使用者需求的适应度——获得了较高的接受度。这一定义强调，数据质量的评价标准因使用者不同而异，取决于数据如何满足其特定的应用需求。

数据质量维度定义了用于区分和明确数据需求的特性或信息部分，为数据质量和信息管理提供了一个度量和管理的方法。MIT 通过二阶段调查，将质量维度归类为四大类型：固有质量、可获取性质量、语境质量和表现质量，并进一步细化为多个具体的质量维度。后续研究在 MIT 的工作基础上，通过调研方法，识别出针对数据的特定特征和子特征，扩展了数据质量维度的认识。除了学术界的贡献，各国机构和不同行业也发展了自己的质量维度标准。

表 2.1 国际机构和政府部门的常用数据质量维度

Table 2.1 Common Data Quality Dimensions Used by International Organizations and Government Departments

国际机构或者政府部门	数据质量维度
国际货币基金组织	诚信度、方法的健全性、准确性、可靠性、适用性、可获取性
欧盟统计局	相关性、准确性、可比性、连贯性、及时性和准时、可访问性、清晰性
联合国粮食及农业组织	相关性、准确性、及时性、准时性、可访问性、一致性、完整性
美国商务部	可比性、准确性、适用性
美国国防部	准确性、完整性、一致性、适时性、唯一性、有效性
加拿大统计局	准确性、及时性、适用性、可访问性、衔接性、可解释性

中国知网 https://www.cnki.net

表 2.2 国内部分领域或行业的数据质量维度

Table 2.2 Domestically Considered Data Quality Dimensions in Specific Domains or Industries

行业	数据质量维度
气象通信	科学性、标准化、共享性、时效性、稳定性、可维护性
军事	完全性、一致性、准确性、唯一性、时效性、可解释性
医疗	一致性、可靠性、可用性、适用性
交通	完整性、有效性、准确性、实时性
地理信息系统	位置精度、现势性、一致性、完整性、可靠性

数据质量具有众多个维度，它们之间存在大量的重叠和相互关联，导致在实际应用中可能会出现重复的评估和管理工作。例如，数据的可靠性和可信度很大程度上依赖于数据的精确性和完整性，即只有当数据准确无误且内容完整时，用户才能对其产生信任和依赖。

此外，许多维度过于细分，可能会造成在数据质量管理过程中的关注点过于分散。如切题性和问接性关注点虽然重要，但如果没有一个准确、完整、一致和时效的数据基础，这些维度的优化也无法发挥最大效用。因此，过于细化的维度不仅增加了管理的复杂性，也可能导致对数据质量核心影响因素的忽视。

而且，对于数据质量的影响，并非所有维度都同等重要。在多数情况下，某些核心维度对数据质量的影响最为显著。这是因为它们直接关联到数据的基本特性和使用价值，而其他一些细分的维度虽然在特定场景下可能显得重要，但对于提升数据质量的整体效果而言，它们的影响较为有限。

通过对比不同机构和行业的质量维度要求，可以看出存在差异，但普遍关注的核心维度包括准确性、完整性、一致性和时效性。这反映出，在不同领域内，对数据质量的基本要求存在共通之处。

因此，依据上文中对数据质量属性的定义和评价方法的讨论，以及对各种数据质量属性的概括和建模分析，本文将数据质量的维度分为核心维度与外围维度两部分，将研究重点放在可涵盖外围维度的四个核心维度上。

中国知网 https://www.cnki.net

表 2.3 核心维度对外围维度的涵盖

Table 2.3 Coverage of Peripheral Dimensions by Core Dimensions

核心维度	涵盖的外围维度
准确性	声誉、可信度、安全性、客观性、无错性、可靠性、相关性、有效性
完整性	数据覆盖率、重复性、适当的数据量、可理解性、可解释性、可用性、导航
一致性	数据规范、呈现质量、表示、可维护性、简洁、易操作性、可学习能力、效率
时效性	新鲜度、数据衰减、可交易性、增值

2.3.2 数据质量核心维度定义

(1) 精确性（Accuracy）

精确性是指数据值正确反映了现实世界中的对象、事件或情况的真实状态，无误差或偏差。在数据质量的语境下，精确性不仅关乎单个数据点的正确性，还涵盖了数据在收集、录入、处理和存储过程中保持其真实性的能力。精确性高的数据可以提供可靠的信息，为决策提供坚实的基础。

表 2.4 对数据准确性检查的规范

Table 2.4 Standards for Data Accuracy Checks

规范	描述
合法准确性	数据集中包含不合法值的程度
类型准确性	数据集中包含误用字符类型的数据程度
依赖准确性	数据集中包含存在相互依赖关系但不匹配的数据的程度
模式准确性	数据集中包含描述错误的数据的程度
精度准确性	数据集中包含精度未达预期的数据的程度

(2) 完整性（Completeness）

完整性指的是所需数据的可用性和不缺失性。具体而言，这意味着所有必要的数据项都已被收集并且可供使用，没有重要信息的遗漏。完整性是衡量数据集是否包含了足够信息以支持数据分析和业务决策的关键指标。数据的不完整性可能导致误导性的分析结果或错误的决策。

中国知网 https://www.cnki.net

表 2.6 对数据完整性检查的规范

Table 2.6 Standards for Data Completeness Checks

规范	描述
规模完整性	确保数据集的规模足以满足可用性需求
属性完整性	数据集内对于记录所需的最小属性集的完全性
内容完整性	数据集内的表、记录、数据项、符号和标识的缺失情况及其程度
关系完整性	数据集内特性、属性及关系的完整性
数据完整性	数据集在不同特性方面的完备性情况

(3) 一致性（Consistency）

一致性是指数据在整个数据集内以及跨不同数据源的格式、结构和值的标准化程度。数据应当遵循统一的规则和标准，保证在不同系统、部门和过程中的数据是一致的，没有矛盾或冲突。一致性确保了数据在整个组织内的可互操作性，有助于数据整合、共享和分析。

表 2.7 对数据一致性检查的规范

Table 2.7 Standards for Data Consistency Checks

规范	描述
概念一致性	信息系统与数据集物理结构的匹配、符合程度
格式一致性	多源数据集中的数据结构、属性、关系的匹配程度，单源数据集中格式的统一程度
值域一致性	实际值对值域的符合程度
内容一致性	单源数据集中相同属性的具体字段值的准确程度
时间一致性	有序数据(序列)的时间顺序正确性

(4) 时效性（Timeliness）

时效性是指数据是最新的，并且在需要时可用。它涉及数据的收集、更新和提供的及时性。时效性确保了数据反映了当前的情况，为实时决策和操作提供了支持。在快速变化的环境中，时效性对于保持数据的相关性和价值尤为重要。

数据源更新不及时，或者由于系统性能问题或网络延迟导致的数据接收不及时，都会影响数据的时效性。

中国知网 https://www.cnki.net

2.4 数据质量评估框架

近年来，研究人员和实践者们在这一领域进行了不懈的探索与创新，提出了一系列旨在应对不同场景下数据质量挑战的框架和方法。以下是近期发表的三篇代表性文献，它们分别从工业应用中的自适应机制、数据质量评估的普遍挑战与机遇，以及特定领域中的数据质量管理角度，提出了各自独特的见解与解决方案

2.4.1 面向工业应用的自适应数据质量评分操作框架

Bayram 等人[29]提出一种面向工业应用的自适应数据质量评分操作框架（Adaptive Data Quality Scoring Operations Framework, AQSOF），旨在解决数据流中质量维度动态变化所导致的评估不准确问题。该框架将漂移检测机制嵌入质量评估流程中，使得评分模型可以根据数据分布的动态变化，自动更新评分策略与模型参数，从而实现更加真实和高效的质量识别。

AQSOF 的设计核心包括两个关键机制：其一是数据漂移检测器（drift detector），用于监测时间序列中数据分布的演变；其二是自适应质量评分器（adaptive scorer），该组件基于漂移检测结果动态调整评分模型。漂移检测采用 Jensen–Shannon 散度（JSD）作为核心指标来衡量当前数据分布与历史分布之间的差异。若散度值超过统计显著性阈值（通过 p 值判断），系统即触发漂移信号，并据此更新评分模型。文中对 JSD 的数学定义如下：

$$\mathrm{JSD}(P_{\mathrm{his}}||P_{\mathrm{cur}}) \coloneqq H\left(\frac{P_{\mathrm{his}}+P_{\mathrm{cur}}}{2}\right)-\frac{H(P_{\mathrm{his}})+H(P_{\mathrm{cur}})}{2} \tag{2.1}$$

其中$H(\cdot)$为 Shannon 熵，用以衡量分布的信息不确定性。框架还使用了 KS 检验（Kolmogorov–Smirnov test）评估 timeliness 维度，进一步提升对时间分布变化的响应能力。

在数据质量维度的选择上，AQSOF 框架采用五个核心指标作为评分基础，包括准确性（Accuracy）、完整性（Completeness）、一致性（Consistency）、时效性（Timeliness）与偏斜性（Skewness）。各个维度的评分结果通过标准化（z-score）后进行降维处理，采用主成分分析（PCA）将多个维度的信息压缩为单一综合评分（DQS）：

$$TS_i \rightarrow PCA(DQ_1, DQ_2, \dots, DQ_n) = DQS_i \tag{2.2}$$

AQSOF 的评分机制集成于一个两阶段系统中：开发阶段和部署阶段。在开发阶段，研究者首先基于标准规则为历史数据生成质量标签，然后训练一个基于 XGBoost 的监督学习模型作为评分器。为了增强模型的泛化能力，系统引入了“数据变异模拟器”，模拟现实场景中的各类质量问题（如传感器故障、数据重复等），扩充训练数据多样性。部署阶段中，系统基于滑动窗口对每一段实时数据进行评分，并通过漂移检测器实时监控数据分布。当检测到数据漂移后，系统

中国知网 https://www.cnki.net

重新生成历史数据的标签，并重新训练评分模型，确保评分器与现实环境的同步。

2.4.2 五维数据质量评估框架

Mohammed 等人[31]针对当下数据质量评估方法碎片化、工具机制不成体系、评估标准缺乏一致性等问题，提出了一个结构化、系统性的质量评估模型：五维数据质量评估框架（Five-Facet Quality Assessment Framework, 简称 FQAF）。该框架从数据生命周期视角出发，尝试将数据质量的评估问题拆解为五个核心“面向”（Facets），并据此构建更具通用性、可实施性和语境适应性的质量评估逻辑体系。

(1) 数据面向（Data Facet）：聚焦于原始数据本身的语义与结构属性，包括数据值的真实性、数值范围的合法性、格式的规范性，以及与外部知识库之间的可映射性。此外，该面向还涵盖了元数据的结构完整性与语义一致性，强调数据模式（schema）、属性类型与上下文文档是否具备支持质量评估的基础条件。在准确性维度的评估中，数据面向的作用尤为突出。文献指出，准确性可通过将目标数据与高质量参考数据进行匹配、对齐来评估，而这种对齐行为依赖于实体识别、模式匹配、语义映射等技术的集成应用。此外，评估完整性维度时，需要识别显式缺失（如 NaN、NULL）与隐式缺失（如默认值、占位符）的差异，这一过程依赖于元数据、数据词典和先验知识的支持。

(2) 来源面向（Source Facet）：强调数据的生成过程、提供方的可信度以及数据加工链条的透明性。该面向将“数据血缘（lineage）”与“来源可信度（credibility）”视为核心问题，认为数据的质量不仅体现在最终呈现的数值结构上，更在于其从采集、转换、加工到发布的全过程是否清晰、可追溯并合规。例如在“可信度”与“可相信性”维度的评估中，来源面向要求记录每一环节的操作日志与变更信息，并具备自动化的审计支持能力。这一面向对于处理多源数据融合任务、人工标注流程、众包数据治理具有重要现实意义，尤其适用于医疗、金融、政务等对数据出处有严格监管需求的行业。

(3) 系统面向（System Facet）：关注支撑数据存储与访问的信息系统基础结构。该面向聚焦于系统在数据管理过程中的透明性、稳健性与合规性，涵盖的数据质量维度包括可恢复性、可移植性、安全性与访问控制能力等。该面向指出，系统故障可能导致精度损失、字段截断、编码错误等数据完整性问题，因此系统评估不仅需考察系统架构与容灾机制，还必须审视是否存在潜在的系统级质量风险。此外，该面向还涉及合规性评估，例如是否具备对数据访问权限进行动态控制与记录能力，是否支持符合 GDPR 或 AI 法案等法规要求的操作日志与元数据文档存储等。

(4) 任务面向（Task Facet）：将数据质量定义为“面向任务的适配性”，并强调不同任务对数据质量的关注点存在显著差异。该面向通过定义任务目标、建模

中国知网 https://www.cnki.net

目标与质量容忍度，指导评估机制针对性地考察数据能否满足特定任务的要求。以“相关性”为例，任务面向要求分析某一字段或数据块是否对下游预测建模、决策逻辑或结果解释具有支持作用。该面向引入基于任务上下文的评估机制，例如通过 Shapley 值或 LIME 方法计算特征重要性，进而判断某一数据维度对模型输出的实际贡献。此外，对于高风险任务，如金融风控、医疗诊断等，任务面向还需联动其他面向，加强对数据稀疏性、失真率与延迟性的动态控制。

(5) 人类面向（Human Facet）：该面向引入了“用户感知质量（perceived quality）”的概念，关注不同用户群体（如开发者、数据分析师、终端客户）在实际使用过程中的体验与认知偏好。评估方法可包括用户调查、专家访谈、操作日志分析等手段，结合 Likert 量表或半结构化问卷捕捉用户对数据的操控性、可解释性与可用性的判断。该面向指出，人类面向的引入虽增加了评估复杂性，但却能显著提升质量管理系统的可用性与信任水平，尤其在需要人为参与的数据清洗、注释或审核流程中具有现实意义。

2.4.3 面向油气工业场景的全流程数据质量管理框架

Kang 等人[32]提出了一种面向油气工业场景的全流程数据质量管理框架，系统性地将数据质量评估、需求决策、质量提升与风险建模集成，构建了一个贯穿“从数据到模型”的工程闭环。该框架包括五个阶段：数据开发、数据质量评估、数据质量需求决策、数据质量提升与风险估计模型开发。其中每一阶段都围绕“预测风险所需数据质量是否足够”这一中心问题展开。

在数据开发阶段，框架首先从计算化维护管理系统（CMMS）中提取与设备运行、环境条件和维护记录相关的结构化数据。采集后的数据需经过四步预处理流程：清洗、特征提取、特征转换与特征降维。此外，数据标注过程尤为关键，由具备失效机制知识的专业工程师（SMEs）依据设备行为数据与维护工单联合标注，以获得用于建模的健康状态或故障标签。

在数据质量评估阶段，框架采用数据体量与完整性两个维度作为量化指标。体量即为有效失效设备的数量，完整性则定义为数据生命周期覆盖率（已采集时间/总运行时间）。框架进一步采用五项度量标准（极值存在性、区间缩放、聚合合理性等）指导指标选取，强调量化指标必须具有决策支持能力。

完成质量评估后，框架进入第三阶段：数据质量需求判断。框架提出一种全新方法，通过模型性能与数据质量关系的经验知识构建来推导质量是否达标。该方法首先建立一个经济驱动的性能评价函数，然后通过相似设备的大量仿真构造知识函数$K(Q,\Omega,r,\ell)$，实现数据质量与模型表现的映射。

损失函数以平均维护成本最小化为目标，结合设备不同的失效代价与过早更换成本进行加权，具体形式如下：

中国知网 https://www.cnki.net

$$\ell = \frac{1}{N}\sum_{i=1}^{N}[c_1(\hat{t}_i \geq T_i) + c_2(T_i - \hat{t}_i)I(\hat{t}_i < T_i)] \tag{2.3}$$

其中$\hat{t}_i$为模型预测的更换时间，T_i为实际失效时间，c_1、c_2分别为单位失效成本与提前更换单位时间成本。知识函数$K(Q,\Omega,r,\ell)$则通过在相似设备上构造不同质量等级下的仿真数据，训练并评估不同模型（如 MTTF、MeTTF、Quantile Regression、HMM），将各数据质量条件下的模型性能系统性地存储并映射。当给定最低性能需求后，框架构建基于决策树的模型选择与质量判断模型，实现对如下问题的判断：若数据质量满足要求，当前哪一模型最优；若不满足，应如何提升数据质量。

在数据质量提升阶段，框架划分了三个路径：系统升级（传感器替换、CMMS 更换）、管理改进（人员培训、指标体系建设）、预处理优化（缺失补全、异常检测、重复去除）。文中特别详细地探讨了异常值检测（如基于密度、聚类、统计等方法）与缺失值填补（统计/机器学习）等方法的适用范围与代价，并强调，预处理改进是最具短期收益的数据质量提升手段。

最后，在模型开发与部署阶段，框架将决策模型结果转化为实际的建模流程，选定最合适的风险评估模型进行训练、测试、部署与监控。其生产级部署包括 KPI 跟踪、模型漂移检测与迭代更新，从而实现数据驱动的全流程优化闭环。

2.5 基于深度学习的时序数据预测方法

传统时序预测方法（如 ARIMA、指数平滑法和 GARCH 模型）依托于线性统计理论和严格的假设条件，在平稳性数据的建模与预测中曾发挥过重要作用。然而，这些方法普遍要求数据满足平稳性、正态性及线性关系等前提条件，对于存在非线性特征、突发性变化及多重依赖关系的复杂时序数据，往往难以捕捉其内在动态结构；此外，其参数估计过程依赖于先验假设和模型选择，易受噪声和异常值的干扰，导致预测精度和鲁棒性不足。正因如此，深度学习方法凭借其强大的非线性映射和自动特征提取能力，正逐步成为解决传统模型局限性的有效技术路径，从而为时序预测领域带来新的突破。

2.5.1 循环神经网络

人工神经网络无法从输入数据中捕获序列信息，因此在像时序数据预测这样的序列问题中，需要使用之前的历史序列数据来预测下一个未来值时，人工神经网络就会失效，因此，循环神经网络（RNN）应运而生[69]。RNN 是一种神经网络，前一步的输出作为当前步骤的输入。其最重要的特性是隐藏状态中的反馈网络，它能够记住来自前一个序列的信息。

中国知网 https://www.cnki.net

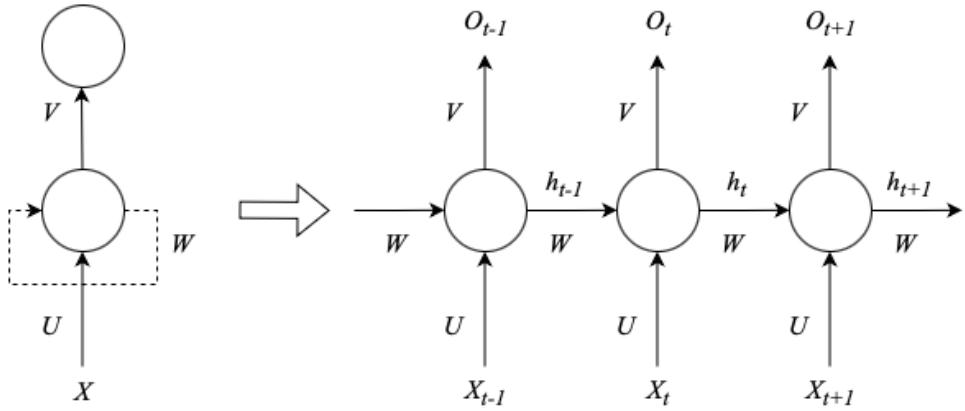


图 2.1 RNN 结构

Fig. 2.1 RNN Architecture

RNN 在时间步骤t的输出受到时间步骤$t-1$的输出的影响。RNN 接受两个输入，当前时间步的输入X_t和隐藏的过去状态输出h_{t-1}。用数学方程表示如下：

$$h_t = \tanh(W \odot h_{t-1} + U \odot X_t) \tag{2.4}$$

$$O_t = V \odot h_t \tag{2.5}$$

其中，h_t是下一个隐藏状态输出；W、U、V是权重；O_t是当前状态的输出。

tanh (·)是递归网络中使用的激活函数，用于将数值压缩至-1 到 1 之间的值。RNN 可以很好地处理大小适中的数据，但随着数据样本大小的增加，RNN 无法保留上一个长期时间步的长期信息，这就是 RNN 的短期记忆问题，这也是循环神经网络因短期记忆和梯度消失问题而表现不佳的原因。其中，短期记忆问题可被视为梯度消失问题的起因。在 RNN 中，信息通过时间传播，这意味着上一时间步的信息被用作下一时间步的输入，从而在每一时间步计算成本函数或误差。当网络变得又大又密集时，梯度开始变小，网络中的权重因此无法更新，这个问题被称为梯度消失问题。

由于 RNN 的这些缺点，长短期记忆网络（LSTM）应运而生[70]，它通过其特殊的门控网络单元解决了短期记忆和梯度消失问题。在预测时间序列数据时，LSTM 模型能够充分利用记忆特性。由于 LSTM 单元的门控和反馈结构，LSTM 模型的单元结构使其能够实现长期记忆。因此，利用时间序列中现有的自相关性，可以获得高度准确和精确的预测。LSTM 是 RNN 的一个变体，因为两者都有一个反馈网络来传播前一状态的信息，但它们的反馈网络有所不同。RNN 会传递存储在前一个存储单元中的全部信息，而 LSTM 则会根据前一个存储单元中的信息对下一步的重要性来传递这些信息，因此 LSTM 比 RNN 更好。

在 LSTM 中，为了选择性地传递重要信息，LSTM 引入了额外的门和单元状态，这样就不会从根本上改变上一个存储单元的全部信息，而是利用 LSTM 单元

中国知网 https://www.cnki.net

门的遗忘和记忆信息的特性，稍微改变一下这些信息。LSTM 单元由三个门（即输入门、输出门和遗忘门）和一个存储单元组成，如图 2.2 所示。

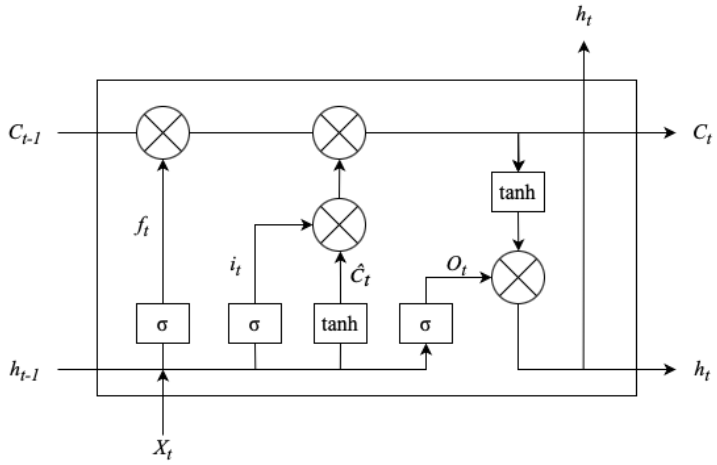


图 2.2 LSTM 单元结构

Fig. 2.2 LSTM Cell Architecture

所有门和存储单元共同负责向下一个 LSTM 单元传播信息。输入门决定当前状态输入中哪些信息需要添加到存储单元中。输出门决定当前存储状态中哪些信息对 LSTM 单元的输出有用，而遗忘门则决定当前存储单元中需要保留上一个存储单元中的哪些信息，遗忘哪些无关信息。描述单个 LSTM 单元动态特性的数学模型如下：

$$f_t = \sigma\left(W_f \cdot X_t + U_f \cdot h_{t-1} + b_f\right) \tag{2.6}$$

$$i_t = \sigma(W_i \cdot X_t + U_i \cdot h_{t-1} + b_i) \tag{2.7}$$

$$\widehat{C_t} = \tanh(W_c \cdot X_t + U_c \cdot h_{t-1} + b_c) \tag{2.8}$$

$$C_t = f_t \cdot C_{t-1} + i_t \cdot \widehat{C_t} \tag{2.9}$$

$$O_t = \sigma(W_o \cdot [h_{t-1}, X_t] + b_o) \tag{2.10}$$

$$h_t = O_t \cdot \tanh(C_t) \tag{2.11}$$

其中，f_t、i_t、O_t 表示 LSTM 单元的门输出；W_f、W_i、W_c 和 W_o 表示 LSTM 单元的权重；b_f、b_i、b_c 和 b_o 表示 LSTM 单元的偏置；C_t表示单元状态。LSTM 网络的权重会在 LSTM 模型的训练步骤中更新，以获得最佳权重，从而使训练误差最小。LSTM 能够通过保留序列数据中的关键信息来传播序列历史模式。

Cho 等人[71]提出了一种门控递归单元（GRU）来解决简单 RNN 中出现的梯度消失问题。GRU 是 LSTM 的类似变体，两者都采用门控架构来控制通过单元的信息流，但与 LSTM 不同的是，GRU 具有门控单元，可以在单元内部充实信息流，

中国知网 https://www.cnki.net

而无需任何单独的存储器。在 GRU 的门控架构中，它有两个门：更新门 z 和复位门 r。GRU 的更新门可以看作是 LSTM 单元的输入门和遗忘门的混合体。

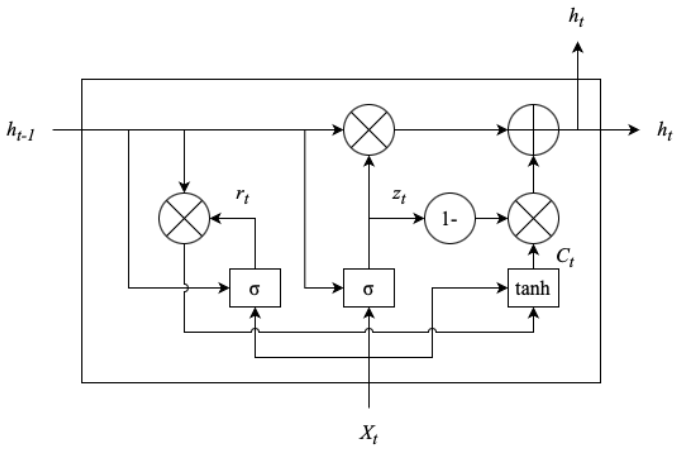


图 2.3 GRU 单元结构

Fig. 2.3 GRU Cell Architecture

GRU 的整体结构如图 2.3 所示。GRU 的更新门通过 sigmoid 函数传递上一隐藏状态输出 h_{t-1} 和当前状态输入 X_t，从而控制从上一时间步到当前状态存储器的信息流。

复位门控制从内存中流出的信息，并决定需要遗忘上一时间步的哪些无关信息。虽然 GRU 没有独立的存储单元状态，但这项工作由 GRU 的隐藏状态完成。GRU 单元的控制机制以数学模型解释为：

$$z_t = \sigma(W_z \cdot [h_{t-1}, X_t] + b_z) \tag{2.12}$$

$$r_t = \sigma(W_r \cdot [h_{t-1}, X_t] + b_r) \tag{2.13}$$

$$C_t = \tanh(W_c(h_{t-1} \odot r) + U_c \cdot X_t) \tag{2.14}$$

$$h_t = z \odot \mathrm{r} + (1 - z)h_{t-1} \tag{2.15}$$

其中，z_t和r_t分别是更新门输出和复位门输出，W_r、W_z、W_c 和 U_c 是 GRU 单元的权重指标；b_z和b_r是偏置指标。⊙表示元素相乘（哈达玛乘积）。

2.5.2 注意力机制

注意力机制（Attention Mechanism）最初于 2014 年由 Bahdanau 等人[72]在神经机器翻译中引入，旨在解决编码器-解码器架构中的信息瓶颈问题。在这一架构中，整个输入序列先被编码到一个固定长度的上下文向量中，然后解码器再将此向量解码为输出序列。然而，当处理长序列时，一个固定长度的向量很难有效承载全部必要信息，导致性能下降。注意力机制通过允许模型在每一步解码时“关注”输入序列的不同部分来解决这一问题，从而显著提升了翻译质量。

中国知网 https://www.cnki.net

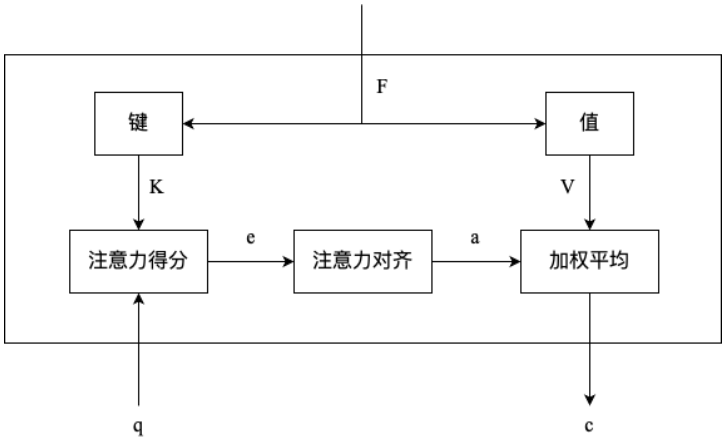


图 2.4 注意力模块的内部机制

Fig. 2.4 The inner mechanisms of the attention module

注意力机制的核心是通过动态地选择输入数据的不同部分来提高模型的关注度和性能。在数学上，注意力机制可以用几个关键步骤来描述，包括注意力分数的计算、分数的对齐（或归一化），以及最终的加权组合。注意力机制的数学模型表示如下：

在计算注意力之前，通常使用一个变换（例如线性变换或通过一个神经网络）来抽取更高级的特征：

$$F = W_f \cdot X + b_f \tag{2.16}$$

其中，W_f是权重矩阵，b_f是偏置项，F 是变换后的特征矩阵。

然后通过当前状态或查询q与每个输入特征的相似度来计算缩放点积注意力分数。注意力分数是衡量输入序列中每个部分对当前任务重要性的指标。

$$e_i = \frac{q^T \cdot x_i}{\sqrt{d_k}} \tag{2.17}$$

然后将计算出的注意力分数通过softmax函数进行归一化，以便将它们表示为权重：

$$\alpha_i = \frac{\exp(e_i)}{\sum_{i=1}^{n} \exp(e_k)} \tag{2.18}$$

此处，α_i是归一化后的注意力权重，指示每个元素对最终输出的贡献大小。

最后利用输入的加权组合，根据注意力权重，计算加权的上下文向量：

$$c = \sum_{i=1}^{n} \alpha_i \cdot x_i \tag{2.19}$$

上下文向量 c 捕捉了输入序列中所有重要特征的加权和，用作后续预测处理步骤的输入。

2.5.3 Transformer

中国知网 https://www.cnki.net

Transformer 是由 Vaswani 等人[73]在 2017 年提出的一种基于自注意力机制的深度学习模型，其最初应用于自然语言处理任务中，凭借其强大的建模能力与高度并行化的结构，在机器翻译等任务中取得了突破性成果。不同于以往循环神经网络（RNN）或长短期记忆网络（LSTM）等顺序结构，Transformer 完全基于注意力机制进行序列建模，摒弃了对时间顺序的强依赖，从而显著提高了训练效率与模型表达能力。

Transformer 的核心在于其多头自注意力机制（Multi-Head Self-Attention），该机制通过在不同子空间中并行计算注意力权重，捕捉输入序列中不同位置之间的相关性。在编码过程中，输入序列首先通过线性变换生成查询（Query）、键（Key）和值（Value）向量，随后利用点积注意力计算得到注意力权重矩阵，从而实现对全局依赖关系的建模。此外，Transformer 结构还包含前馈神经网络（FFN）、残差连接与层归一化（Layer Normalization）等组件，共同提升模型的稳定性与表达能力。

在时序数据预测任务中，Transformer 展现出了极大的潜力，尤其在处理长序列依赖问题方面，优于传统的基于递归结构的方法。由于时序数据通常存在复杂的周期性结构、局部变化和长期依赖关系，Transformer 能够通过其自注意力机制全局建模序列中各时间步之间的关联，从而实现更精准的未来值预测。

其主要工作流程如下：

(1) 输入嵌入与位置编码：

输入序列首先被映射为向量表示（embedding），同时添加位置编码（Positional Encoding）以保留序列的顺序信息，因为 Transformer 本身不具备时序结构。给定输入序列 $X = [x_1, x_2, \dots, x_T] \in \mathbb{R}^{T \times d_{\text{in}}}$，首先进行线性嵌入并添加位置编码：

$$\mathbf{E} = X\mathbf{W}_e + \mathbf{P} \tag{2.20}$$

其中，$\mathbf{W}_e \in \mathbb{R}^{d_{\text{in}} \times d_{\text{model}}}$ 是嵌入矩阵，$\mathbf{P} \in \mathbb{R}^{T \times d_{\text{model}}}$ 是位置编码，$\mathbf{E} \in \mathbb{R}^{T \times d_{\text{model}}}$是最终的输入表示。

(2) 自注意力机制：

对于每一个输入位置，模型都会计算其与所有位置之间的相似性（即注意力权重），再根据这些权重对所有位置的表示进行加权求和，从而获得融合了全局信息的新表示。这个过程通过计算 Query（查询）、Key（键）和 Value（值）三组向量来实现。将输入嵌入$\mathbf{E}$投影为三组向量：

$$\mathbf{Q} = \mathbf{E}\mathbf{W}_Q, \qquad \mathbf{K} = \mathbf{E}\mathbf{W}_K, \qquad \mathbf{V} = \mathbf{E}\mathbf{W}_V \tag{2.21}$$

其中，$\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V \in \mathbb{R}^{d_{\text{model}} \times d_k}$是可学习的权重参数。然后，计算注意力权重矩阵：

中国知网 https://www.cnki.net

$$\mathbf{A} = \mathrm{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^{\top}}{\sqrt{d_k}}\right) \tag{2.22}$$

得到的注意力输出为：

$$\mathbf{Z} = \mathbf{A}\mathbf{V} \tag{2.23}$$

(3) 多头注意力（Multi-Head Attention）：

为了让模型从多个表示子空间中学习信息，引入多头机制，从不同的子空间捕捉信息，最后将结果拼接后线性映射，增强模型的表达能力。设有h个头，第i个头的输出为：

$$\mathrm{head}_i = \mathrm{Attention}(\mathbf{Q}_i, \mathbf{K}_i, \mathbf{V}_i) \tag{2.24}$$

最终多头输出为：

$$\mathrm{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = [\mathrm{head}_1; \ldots ; \mathrm{head}_h]\mathbf{W}_O \tag{2.25}$$

其中$\mathbf{W}_O \in \mathbb{R}^{d_k \times d_{\mathrm{model}}}$。

(4) 残差连接与层归一化：

每一子模块（注意力层和前馈层）之后均加入残差连接与归一化，帮助模型稳定训练并加快收敛：

$$\mathbf{H}_1 = \mathrm{LayerNorm}\big(\mathbf{E} + \mathrm{MultiHead}(\mathbf{Q}, \mathbf{K}, \mathbf{V})\big) \tag{2.26}$$

(5) 前馈神经网络（FFN）：

每个位置的输出向量经过一个两层的全连接网络，引入非线性变换，进一步提升建模能力。对每个位置独立地应用两层前馈神经网络：

$$\mathrm{FFN}(\mathbf{h}) = \mathrm{ReLU}(\mathbf{h}\mathbf{W}1 + \mathbf{b}1)\mathbf{W}_2 + \mathbf{b}_2 \tag{2.27}$$

其中，$\mathbf{W}_1 \in \mathbb{R}^{d_{\mathrm{model}} \times d_{\mathrm{ff}}}$，$\mathbf{W}_2 \in \mathbb{R}^{d_{\mathrm{ff}} \times d_{\mathrm{model}}}$。

输出同样加残差与归一化：

$$\mathbf{H}_2 = \mathrm{LayerNorm}\big(\mathbf{H}_1 + \mathrm{FFN}(\mathbf{H}_1)\big) \tag{2.28}$$

(6) 堆叠多个编码器层：

上述模块作为一个 Transformer 编码器层，多个此类层堆叠构成整个 Transformer 编码器。其最终输出可用于分类、预测等下游任务。

中国知网 https://www.cnki.net

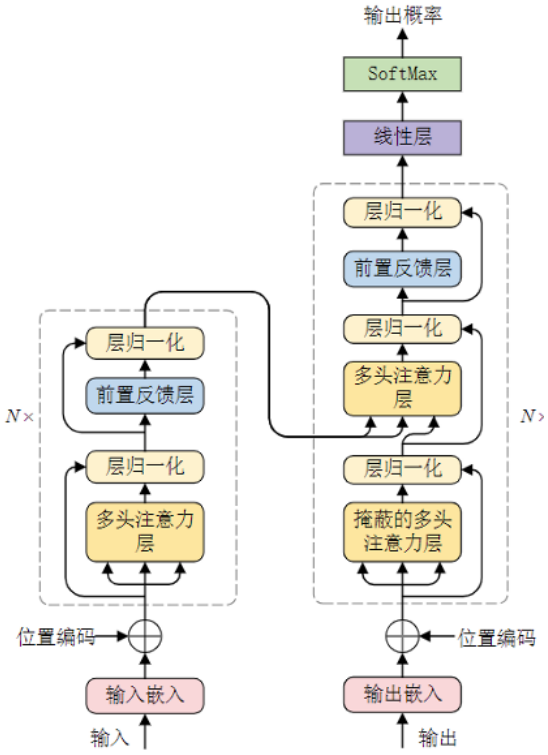


图 2.5 Transformer 模型结构

Fig. 2.5 Transformer Architecture

然而，原始的 Transformer 结构在时序建模中仍面临若干挑战，如计算复杂度高（尤其在长序列情况下为二次复杂度）、对稀疏性结构缺乏建模能力、以及对局部细节捕捉不足等问题。为应对这些问题，近年来研究者提出了多种针对时序预测任务的改进型 Transformer 架构：

(1) Informer（Zhou 等人）[74]：引入了概率稀疏注意力机制（ProbSparse Attention），通过筛选最具代表性的注意力分数降低计算成本，显著提升了对超长时间序列的建模效率；

(2) Autoformer（Wu 等人）[75]：利用时间序列的递归性特征，引入自适应分解机制，将序列分解为趋势项与残差项，分别进行建模，从而提高了对多尺度结构的刻画能力；

(3) FEDformer（Zhou 等人）[76]：在 Autoformer 的基础上进一步引入频域建模思想，通过傅里叶变换将注意力操作迁移到频域，实现了对周期性成分的高效捕捉；

(4) PatchTST（Nie 等人）[77]：借鉴计算机视觉中的图像分块思想，将时间序列划分为多个局部块后并行建模，结合位置编码策略提升模型对局部模式与全局结构的融合能力；

中国知网 https://www.cnki.net

Transformer 及其衍生模型已成为当前时序预测研究中的主流范式，其灵活的结构与强大的表达能力使其在金融、能源、气象等多个实际应用场景中展现出广泛的适用性。随着研究的深入，Transformer 在时序预测领域的建模方式正不断演化，朝着更高效、更稳定、更具解释性的方向持续发展。

2.6 本章小结

本章综述了工业设备时序数据的特性、关键预测技术以及相关基础理论，为工业时序数据预测的应用奠定了理论基础。首先，讨论了工业设备时序数据的本质特征，总结了其分类方式，并详细分析了常见的时序数据类型。随后，围绕数据质量维度的定义与选择，探讨了核心维度的选择依据及现有的量化计算方法，为数据质量评估提供了理论支持。在数据质量评估方面，系统分析了现有模型的发展背景、理论基础与方法论，全面梳理了这些方法的应用场景、优势及潜在局限性。此外，探讨了多种基于深度学习的时序数据预测模型算法，包括循环神经网络（RNN）、长短期记忆网络（LSTM）、门控循环单元（GRU），并解析了注意力机制的原理与计算方法，阐明其在提升模型性能中的作用，最后探讨了 Transformer 及其改进体，并阐述了其工作原理。这些内容为后续提出的 TSWD 数据质量量化算法和 SHAPT 预测模型提供了理论支撑和技术铺垫。

中国知网 https://www.cnki.net

3 TSWD 数据质量量化计算方法

3.1 问题定义与方法总览

目前在工业大数据质量管理中，主要存在以下具体问题：首先，由于通用性模型缺乏针对工业领域复杂数据时序结构的定制化设计，难以准确捕捉诸如数据缺失、不一致和噪声干扰等质量缺陷；其次，现有方法过度依赖定性分析，依靠大量人工判断，导致在大规模数据环境下检测效率低下；再次，缺少系统化的定量计算方法和分析框架，致使数据质量指标难以实现标准化和精细化。针对这些问题，数据质量评估与检测技术能够构建精细的量化指标体系、实现自动化预警以及智能化数据修复，从而有效识别和解决工业大数据中的质量缺陷，保障设备监控、生产调度和风险预警等关键环节的高效运行。

此外，工业场景中的时序数据质量分析具有显著的行业特性，主要体现在数据采集频率高、数据量巨大、来源多为传感器和控制系统，并伴随物理变量间的强耦合关系。与其他场景相比，工业数据更容易受到硬件失效、电磁干扰、环境波动等因素影响，导致缺失、漂移、突变、抖动等质量问题。此外，工业场景对数据的一致性和时效性要求极高，因为这直接关系到设备安全、工艺控制与产线连续性。相比之下，医疗、金融等场景的数据采集多为事件驱动，处理节奏较为宽松，业务容忍度更高。

鉴于上述现状，本文拟在已有研究的基础上，对相关问题进行一定的补充和延伸，针对工业大数据的独特性和复杂需求，开发一套全面、实时且具有高度适应性的、结合定性与定量分析的数据质量综合评估模型。本模型的目标是对工业大数据的质量进行可信的评估，从而提升数据处理的专业性与高效性。本文通过深度剖析工业数据的内在结构与特点，设计了一套量化计算方法，命名为时序滑动窗口偏差（Time-series Sliding Window & Deviation, TSWD）算法，目的是提供一种更加科学和精确的工业时序数据质量评估方法。

定义 1 设$x_1, x_2, \dots, x_T$为需要评估的T条数据，并构成数据集合$X = \{x_1, x_2, \dots, x_T\}$, $T \in N^+$，x_i为集合中任意一条数据，$DQ(t)$为在时间点t上对数据集合X的数据质量评分。

定义 2 设数据存在n个属性，x_t^i表示数据x_t在属性i上的取值，则任一数据点有属性集合$x_t = \{x_t^1, x_t^2, \dots, x_t^n\}, n \in N^+$。$x_t^i$可能存在缺失、错误、不一致、过时等质量问题。

定义 3 设$R = \{r_1, r_2, \dots, r_T\}$为参考数据集合，$r_t = \{r_t^1, r_t^2, \dots, r_t^n\}$为参考数据$r_t$的参考属性集合，$r_t^i$表示数据$r_t$的属性$i$的参考值或期望值。

中国知网 https://www.cnki.net

依据文献[5][29][32]以及业界应用情况，以下是对业界目前对于准确度、完整性、一致性及时效性的建模及量化计算方法的总结。

(1) 准确性（Accuracy）

准确性定义为：准确性=符合参考值的数量/所有值的数量，设$f_{\mathrm{acc}}(\cdot)$为评估数据x_i^j的取值结果到$(0,1)$的映射，若符合参考值则取值 1，否则取值 0，即：

$$f_{\mathrm{acc}}(x_i^j)=\begin{cases}1, x_t^i=r_t^i\\0, x_t^i\neq r_t^i\end{cases} \tag{3.1}$$

则数据集合X在属性i上的准确性为：

$$DQ_{\mathrm{acc}}^i=\sum_{t=1}^{T}\frac{f_{acc}(x_t^i)}{m} \tag{3.2}$$

数据集合X在所有属性上的准确性为：

$$DQ_{\mathrm{acc}}=\sum_{i=1}^{n}\sum_{t=1}^{T}\frac{f_{\mathrm{acc}}(x_t^i)}{T\times n} \tag{3.3}$$

(2) 完整性（Completeness）

完整性定义为：完整性=非空值的数量/所有值的数量，设$f_{\mathrm{comp}}(\cdot)$为评估数据D_{ij}的取值结果到$(0,1)$的映射，若x_i^j非空则取值 1，否则取值 0，即：

$$f_{\mathrm{comp}}(x_t^i)=\begin{cases}1, x_t^i\text{非空}\\0, x_t^i\text{为空}\end{cases} \tag{3.4}$$

则数据集合X在所有属性上的完整性为：

$$DQ_{\mathrm{comp}}=\sum_{i=1}^{n}\sum_{t=1}^{T}\frac{f_{\mathrm{comp}}(x_t^i)}{T\times n} \tag{3.5}$$

(3) 一致性（Consistency）

一致性定义为一致性值的数量与所有值的数量的比例。设集合C^i表示x_t^i在其属性i上可能的取值范围，$f_{\mathrm{cons}}(\cdot)$为评估数据x_t^i的取值结果到$(0,1)$的映射，若x_t^i属于C^i则取值 1，否则取值 0，即：

$$f_{\mathrm{cons}}(x_i^j)=\begin{cases}1, x_t^i\in C^i\\0, x_t^i\notin C^i\end{cases} \tag{3.6}$$

则数据集合X在所有属性上的一致性为：

$$DQ_{\mathrm{cons}}=\sum_{i=1}^{n}\sum_{t=1}^{T}\frac{f_{\mathrm{cons}}(x_t^i)}{T\times n} \tag{3.7}$$

(4) 时效性（Timeliness）

时效性定义为时效内值的数量与所有值的数量的比例。设$f_{\mathrm{time}}(\cdot)$为评估数据x_i^j的取值结果到$(0,1)$的映射，若x_i^j在时效内则取值 1，否则取值 0，即：

$$f_{\mathrm{time}}(x_t^i)=\begin{cases}1, & x_t^i\text{在时效内}\\0, & x_t^i\text{已过时}\end{cases} \tag{3.8}$$

中国知网 https://www.cnki.net

数据集合D在所有属性上的时效性为：

$$DQ_{\text{time}} = \sum_{i=1}^{n}\sum_{t=1}^{T}\frac{f_{\text{time}}(x_t^i)}{T \times n} \tag{3.9}$$

以上为当前被广泛接受的数据质量四个维度的评估模型，但该模型过于简化。考虑到数据质量维度本身的多样性、复杂性和可扩展性，仅仅采用二元化的方法对其进行评估显然是不足够的。数据质量的评估应当是一个多维度、多层次的过程，它需要综合考量各个方面的影响因素和相互作用。因此，仅仅依赖简化的评估框架无法全面捕捉数据质量的各个维度。

此外，当前存在的计算模型主要针对已经完整收集的数据集进行质量评估，缺乏对实时生成数据的评估能力。鉴于工业生产活动本质上是一个持续不断的过程，这种评估模式的局限性导致它们难以为工业生产过程提供实时且精确的质量监控。

3.2 TSWD 算法提出

TSWD 算法旨在对数据质量的四个主要维度进行量化分析。具体而言，模型由两个核心组成部分构成：一是时序滑动窗口部分，该机制通过分析过去时间点的数据评估结果来估计其对当前评估结果的影响；二是偏差计算部分，专注于评估当前时间点的数据如何影响当前的数据质量评估结果。TSWD 算法能够更精准地识别和量化数据质量问题，为提高数据处理和分析的准确性提供了强有力的工具。下面是该模型的简化表达形式：

$$\mathrm{DQ}(t) = \max\left(\min\left(\mathrm{TSW}\left(\mathrm{DQ}(t)\right) + \beta\mathrm{Dev}(t), 1\right), 0\right) \tag{3.10}$$

由于最终对数据质量的评估结果会以百分比的形式呈现，需要将$\mathrm{DQ}(t)$限制在$[0,1]$之间。因此本模型采用了最值函数，防止产生预期外的结果。

3.2.1 时序滑动窗口

时序滑动窗口通过过往时间点的输出结果来计算当前时间点的起始评估结果，其表达式如下：

$$\mathrm{TSW}\left(\mathrm{DQ}(t)\right) = \frac{\sum_{l=1}^{L}\mathrm{DQ}(t-i)e^{-\alpha l}}{\sum_{i=1}^{L}e^{-\alpha l}} \tag{3.11}$$

在该模型中，滑动窗口长度L是一个关键参数，用于确定过去多长时间内的数据仍然对当前的评估结果具有影响。通过适当扩大这一长度，模型能够提高其稳定性，减少因短期异常数据造成的扰动。

权重的引入是通过一个简单的指数函数$e^{-\alpha i}$计算得到的，其中权重因子$\alpha > 0$。这种权重分配机制允许模型在保持对历史数据敏感性的同时，避免了由于滑动窗

中国知网 https://www.cnki.net

口长度过长而导致的历史数据对当前评估结果过度影响的问题。

这一权重化的滑动窗口机制确保了时序数据在整个评估过程中的适当影响，为模型提供了一个坚实的基础。这种机制不仅增加了模型对于时间序列数据变化的适应性和灵敏度，而且通过参数配置，它保障了输出结果的稳定性和可靠性。通过综合考虑滑动窗口长度和权重因子的作用，该模型有效平衡了对近期与远期数据的关注，以此来优化整体的评估精度和模型性能。

3.2.2 偏差更新

本部分专注于通过计算当前时间点数据与预期符合程度的变化值来评估数据的偏离程度。具体而言，若当前数据未达到预期，评估值将会降低；相反，当数据满足预期时，评估值则会相应提高。β是缩放因子，用于调节偏差计算对整体评估结果的影响力度。该部分的核心是偏差函数的设计：

不同的数据质量维度将采用不同的计算方法，将在下文逐一列出。此处展示模型的偏差部分的核心设计——偏差函数。此函数表示为：

$$\mathrm{Dev}(t) = 2^{1-4\left(\frac{x_t-\frac{U+L}{2}}{U-L}\right)^2} - 1 \tag{3.12}$$

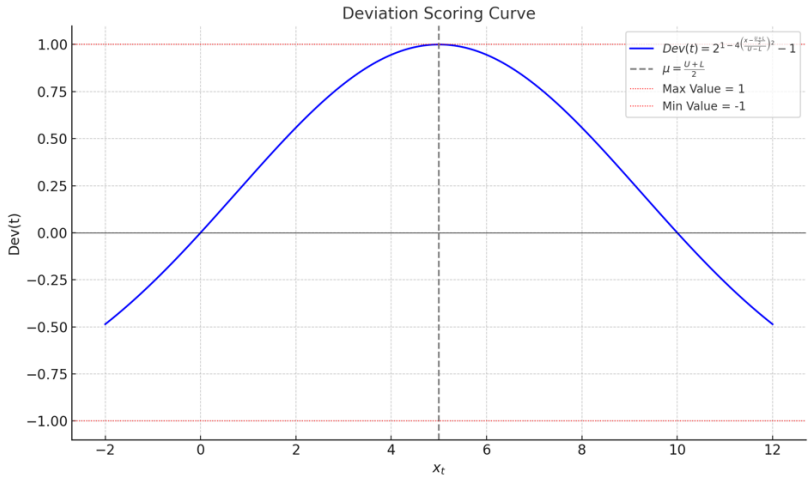


图 3.1 偏差函数曲线

Fig. 3.1 Deviation Scoring Curve

该函数是由高斯函数改进而得的钟形指数曲线，其最大的特点是可显式地指定上下界，在工业生产环境中可直观地用于偏离度评分。同时限制了其值域在(-1,1]内，避免了极端数据对评估结果产生过大的影响。

如果将该偏差函数用于计算某个数据是否落在符合规范的值域的偏离程度，则可直接使用该形式；如果该数据的偏离程度Δ_t需要通过其他方式计算，再将其传入偏差函数，且其规范不是特定的值域(L,U)而是一个阈值θ，则需要令$U =$

中国知网 https://www.cnki.net

$\theta = -L$，则原式变形为：

$$\mathrm{Dev}(t) = 2^{1-\left(\frac{\Delta_t}{\theta}\right)^2} - 1 \tag{3.13}$$

这个阈值θ定义了可接受的数据偏差上限，即数据误差超出此阈值时，则认为数据的准确性不符合要求。通过设定这样一个阈值，可以根据对各个维度的具体需求和容错范围，制定出符合实际情况的数据质量控制策略。

通过综合利用时序滑动窗口机制和偏差计算这两个核心组成部分，本模型实现了对数据质量的量化评估，既从数据的维度（横向考量）进行分析，也从时间序列的角度（纵向考量）考察其变化趋势。这种评估方法使得模型不仅能够精确地衡量数据在特定时间点的质量，还能够追踪和分析数据质量随时间的动态变化，从而提供了一种强有力的工具，用于全方位地评估和保障数据的质量。

TSWD 算法的核心设计包括滑动窗口评分机制和高斯偏差函数的柔性度量策略。通过设置时间加权滑窗，TSWD 能够动态追踪传感器数据的质量波动趋势，避免因短时异常引发错误判定。高斯型偏差函数则使得评分机制对轻微漂移具有容忍性，对突变异常保持敏感性，实现更平滑的质量判断。此外，TSWD 在准确性、完整性、一致性、时效性四个维度上构建了可调参数模型，能够根据不同工业任务调整维度权重与评分阈值，具备良好的通用性与工业适配性。该方法特别适用于制造系统中的生产数据、电力系统的运行日志、化工过程控制等多种工业场景中的多变量采样数据等，目标是实现对数据质量的连续动态评估与预测预警，为工业系统稳定运行提供数据保障。

在评估数据质量时，需要根据对不同维度的需求，动态调整模型的各个参数，对于各个维度的具体分析将在下文解释。

3.3 TSWD 算法模型构建

在进行精确的数据质量评估过程中，为数据的各个属性分配恰当的权重是一个关键步骤。通过给数据的每个属性赋予特定的权重，从而明确地区分和量化不同属性对整体数据质量的贡献度。这一方法使得评估过程可以综合考虑数据的多方面特征，从而得到更为全面和准确的质量评估结果。

根据具体的业务需求和实际应用场景，合理地设定各数据属性的权重尤为重要。例如，某些属性可能对于决策过程具有更高的重要性，因此应相应地赋予更高的权重，以确保评估结果能够真实反映数据质量对业务结果的影响。

定义 4 设$W = \{W_1, W_2, \ldots, W_n\}$为数据的每个属性的权重集合。

定义 5 设准确性阈值为θ_{acc}，它规定了可接受的记录值和参考值欧几里得距离上限。

定义 6 设完整性阈值为θ_{comp}，它规定了可接受的数据缺失百分比上限。

中国知网 https://www.cnki.net

定义 7 设一致性阈值集合为$U=\{U_1,U_2,\dots,U_n\}$和$L=\{L_1,L_2,\dots,L_n\}$，其中U为上限集合，L为下限集合。对于数据属性i，其上限为U_i，下限为L_i。它们规定了数据在每个属性的符合规范的值域，

定义 8 设时效性阈值为θ_{time}，它规定了可接受的数据延迟时间上限。

3.3.1 准确性

准确性（Accuracy）的计算在于量化数据的误差水平。此处将每条数据视为多维空间中的一个点，并通过计算该点与参考值之间的加权欧几里得距离来评估数据的偏离程度。这种方法的背景是基于一个现实而合理的假设：在工业生产等领域，由于各种不可控因素，完美无误的数据序列是不可得的。因此，需要根据历史生产活动中产生的数据，选择一组适当的参照数据点。这些参照数据点旨在代表在特定条件下可实现的最佳性能或状态，从而为生产数据的准确性评估提供一个基准。

在进行准确性计算时，每个时间点的数据都被视为多维空间中的一个点，并将其与同时间点的参考数据进行加权欧几里得距离计算。准确性阈值即为根据过往生产活动中的观测值与参考值的计算而得的常态距离。

对于每个时间点t的数据，其距离参考数据点的加权欧几里得距离为：

$$\Delta_t^{\mathrm{acc}}=\sqrt{\sum_{i=1}^{n}W_i\left(x_t^i-r_t^i\right)^2} \tag{3.14}$$

将Δ_t和阈值θ_{acc}代入偏差函数中，得到准确性偏差：

$$\mathrm{Dev}_{\mathrm{acc}}(t)=2^{1-\frac{\sum_{i=1}^{n}W_i\left(x_t^i-r_t^i\right)^2}{\theta_{\mathrm{acc}}^2}}-1 \tag{3.15}$$

准确性评估模型完全展开式如下：

$$\mathrm{DQ}_{\mathrm{acc}}(t)=\max\left(\min\left(\frac{\sum_{l=1}^{L}\mathrm{DQ}_{\mathrm{acc}}(t-l)e^{-\alpha l}}{\sum_{l=1}^{L}e^{-\alpha l}}+\beta\left(2^{1-\frac{\sum_{i=1}^{n}W_i\left(x_t^i-r_t^i\right)^2}{\theta_{\mathrm{acc}}^2}}-1\right),1\right),0\right) \tag{3.16}$$

3.3.2 完整性

完整性（Completeness）计算的是数据的缺失程度。由于缺失是一个二元属性（即非有即无），因此只能沿用之前式(3.4)所定义的映射方式，并通过加权来反映各个属性的值的缺失所带来的影响。

完整性的偏差程度为：

$$\Delta_t^{\mathrm{comp}}=1-\frac{\sum_{i=1}^{n}W_i f_{\mathrm{comp}}\left(x_t^i\right)}{\sum_{i=1}^{n}W_i} \tag{3.17}$$

每个时间点的数据完整性偏差为：

中国知网 https://www.cnki.net

$$\mathrm{Dev}_{\mathrm{comp}}(t)=2^{1-\left(1-\frac{1-\frac{\sum_{i=1}^{n}W_i f_{\mathrm{comp}}(x_t^i)}{\sum_{i=1}^{n}W_i}}{\theta_{\mathrm{comp}}}\right)^2}-1 \tag{3.18}$$

完整性评估模型完全展开式如下：

$$\mathrm{DQ}_{\mathrm{comp}}(t)=\max\left(\min\left(\frac{\sum_{l=1}^{L}\mathrm{DQ}_{\mathrm{comp}}(t-l)e^{-\alpha l}}{\sum_{l=1}^{L}e^{-\alpha l}}+\beta\left(2^{1-\left(1-\frac{1-\frac{\sum_{i=1}^{n}W_i f_{\mathrm{comp}}(x_t^i)}{\sum_{i=1}^{n}W_i}}{\theta_{\mathrm{comp}}}\right)^2}-1\right),1\right),0\right) \tag{3.19}$$

3.3.3 一致性

一致性（Consistency）计算的是数据符合规范的程度。例如信息系统与数据集物理结构的匹配程度；多源数据集中的数据结构、属性、关系的匹配程度；单源数据集中字段值格式的统一程度；实际值对值域的符合程度；单源数据集中相同属性的具体字段值的准确程度；有序数据(序列)的正确性等。由于这些属性很难量化，同时也很难有一个统一的标准，因此在针对不同的工业系统的设计时需要具体问题具体分析。这里仅对数据的值域一致性的计算进行改进，以对其他的一致性内容作为一个参考。

当数据的值在规定范围内时，即将其视为符合一致性规范。因此，每个属性都需要定义一个值域，将不在范围内的数据根据偏离程度计算其一致性衰减。

由于为不同的属性赋予了不同的权重，因此需要将偏差函数进行加权计算，由此得到每个时间点的数据一致性偏差为：

$$\mathrm{Dev}_{\mathrm{cons}}(t)=\frac{\sum_{i=1}^{n}W_i\left(2^{1-4\left(\frac{x_t^i-\frac{U_i+L_i}{2}}{U_i-L_i}\right)^2}-1\right)}{\sum_{i=1}^{n}W_i} \tag{3.20}$$

一致性评估模型完全展开式如下：

$$\mathrm{DQ}_{\mathrm{cons}}(t)=\max\left(\min\left(\frac{\sum_{l=1}^{L}\mathrm{DQ}_{\mathrm{cons}}(t-l)e^{-\alpha l}}{\sum_{l=1}^{L}e^{-\alpha l}}+\beta\left(\frac{\sum_{i=1}^{n}W_i\left(2^{1-4\left(\frac{x_t^i-\frac{U_i+L_i}{2}}{U_i-L_i}\right)^2}-1\right)}{\sum_{i=1}^{n}W_i}\right),1\right),0\right) \tag{3.21}$$

中国知网 https://www.cnki.net

3.3.4 时效性

时效性（Timeliness）计算的是数据根据时效的可用程度。时效性性质属于时间相关性质，用于描述数据的更新程度对数据质量的影响。在工业数据的管理过程中，从数据的生成、收集到分析，总是需要一定的时间跨度。因此，时间间隔是对数据时效性评估的一个重要方面。值得注意的是，即便数据传输或处理超出了预定时间范围，这部分数据依旧可能保持其部分时新性，并不意味着其已完全失去参考价值。因此，仅仅以是否超出预定时效来判断数据的时效性，这样的做法缺乏精确性和全面性。然而，若数据收集的延误成为常态，不断积累，最终超越了可接受的时间界限，则应该认为这批时序数据的时效性正在逐步下降，直至延迟问题得到妥善解决，数据的时效性才能恢复。

本文用线性模型的时间戳的方式来表示数据产生的时间点，为每个时间点的数据x_t都添加一个单独的属性值x_t^{time}用于记录生成时间。此属性应该符合线性模型分布，即$x_t^{\text{time}} = t$，从而便可以用两值之差的绝对值来表示偏离程度。

时效性的偏离程度为：

$$\Delta_t^{\text{time}} = \left| x_t^{\text{time}} - t \right| \tag{3.22}$$

将偏差函数进行加权计算，由此得到每个时间点的数据时效性偏差为：

$$\text{Dev}_{\text{time}}(t) = \frac{\sum_{i=1}^{n} W_i \left(2^{1-\left(\frac{x_t^{\text{time}}-t}{\theta_{\text{time}}}\right)^2} - 1 \right)}{\sum_{i=1}^{n} W_i} \tag{3.23}$$

时效性评估模型完全展开式如下：

$$\begin{aligned} \text{DQ}_{\text{time}}(t) = \max(\min(&\frac{\sum_{l=1}^{L} \text{DQ}_{\text{time}}(t-i)e^{-\alpha l}}{\sum_{i=1}^{L} e^{-\alpha l}} \\ &+\beta \left(\frac{\sum_{i=1}^{n} W_i \left(2^{1-\left(\frac{x_t^{\text{time}}-t}{\theta_{\text{time}}}\right)^2} - 1 \right)}{\sum_{i=1}^{n} W_i} \right), 1), 0) \end{aligned} \tag{3.24}$$

TSWD 算法的总体结构如图 3.2 所示：

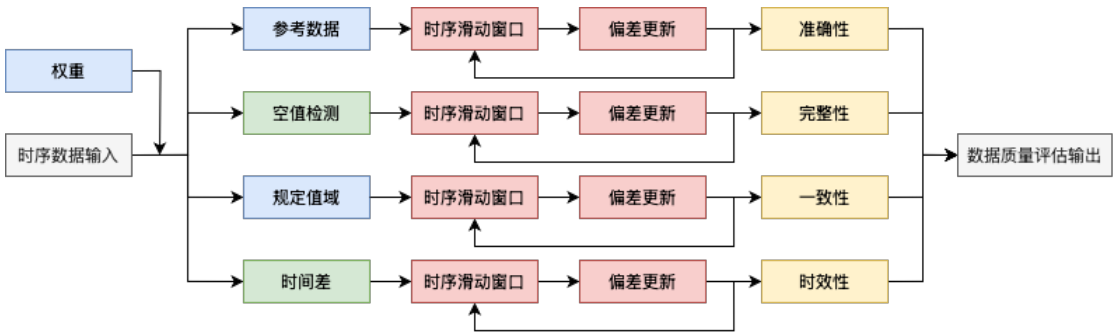


图 3.2 TSWD 算法结构

Fig. 3.2 Architecture of TSWD Algorithm

中国知网 https://www.cnki.net

与经典方法及近年提出的新方法相比，TSWD 算法在多方面实现了结构性改进。传统方法往往基于布尔逻辑规则，如“是否为空”“是否超过阈值”，不适用于工业数据中频繁出现的微小波动与连续异常。相比之下，TSWD 算法结合了滑动窗口机制与偏差评分机制，能够动态地感知历史数据质量的演变趋势，同时实时评估当前数据的质量偏差；在模型层面，TSWD 算法不仅提供了明确的质量计算公式，而且在多个维度上进行独立建模。这种分维度、可调节、具解释性的策略，解决了传统评分模型中维度耦合、缺乏灵活性的问题。此外，TSWD 算法的参数具有高度可调性，便于在不同工业系统中迁移部署。

与文献[29]中的面向工业应用的自适应数据质量评分操作框架仅基于时间漂移调整权重的粗略评分方式不同，TSWD 算法利用指数加权平均与高斯偏差函数融合的方式，更能准确反映单点数据对整体质量的微观影响；与文献[32]提出的面向油气工业场景的全流程数据质量管理框架中以预测性能变化为指标的模型相比，TSWD 算法不依赖外部模型或特定任务，因此具有更好的通用性与独立性；而相对于文献[31]提出的强调的宏观多源评估结构的五维数据质量评估框架，TSWD 算法更强调“可执行、可量化”的微观质量评分，因而更适合嵌入到工业控制、传感器监测等实时系统中。

3.4 实验设计

3.4.1 数据集介绍与构建

实验使用 ETT（Electric Transformer Temperature）数据集，它是一组用于电力变压器油温预测的时间序列数据集，主要用于研究长期时间序列预测（LTSF）问题。该数据集由国家电网提供，数据来自中国同一省份不同地区的多个电力变压器，时间跨度为 2016 年 7 月至 2018 年 7 月，涵盖不同季节和用电模式，记录了电力变压器的油温（Oil Temperature, OT）及 6 种负载特征。

实验选取 ETTh1 数据集中的 4 种特征 HUFL、HULL、MUFL、MULL，并截取 3000 个数据用以模拟工业生产环境中具有 4 种属性的时序数据，并在此基础上进行基准实验以及定制化实验。具体数据集信息如表 3.1 所示。

表 3.1 实验数据集信息表

Table 3.1 Experimental Dataset Information Table

数据集	HUFL	HULL	MUFL	MULL
截取步数	3000	3000	3000	3000
时间步数	17420	17420	17420	17420

中国知网 https://www.cnki.net

3.4.2 实验相关参数

在 TSWD 算法中，对每个维度计算的表达式涵盖了多个关键参数，包括窗口长度 L、时序权重因子 α 以及偏差缩放因子 β。这些参数的设置对模型的性能和适应性有着直接且显著的影响。为了使模型能够灵活应对各种不同的应用场景和需求，这些参数被设计为可单独调节的，对每个维度都可以有一套独立的参数。具体涉及的参数如下：

(1) 窗口长度（L）：该参数决定了在进行时序分析时，所考虑数据的时间跨度，直接影响模型对数据趋势的捕捉能力。设定适宜的窗口长度有助于在分析时充分考虑历史数据对当前时间点评估的影响，也有助于减缓短期异常数据对分析结果的干扰，从而避免因短期数据波动而导致的错误趋势判断。

(2) 时序权重因子（α）：该参数用于调整时间序列中近期数据与远期数据的相对重要性。通过改变 α 的值，可以控制模型对最近数据的重视程度。较高的 α 值意味着模型将赋予近期数据更大的权重，这在快速变化的环境中尤为重要。合理的权重因子设定能够提高模型对动态变化的适应能力。

(3) 偏差缩放因子（β）：该参数用于调节模型对预期值与实际值之间偏差的敏感度，影响偏差处理的严格程度。β 值越大，评估结果的变动越大。通过适当调整 β 值，可以确保模型在评估数据质量时既不过于宽容也不过于严苛，从而在保证准确性的同时提升模型的鲁棒性。

此外，每个数据集的权重分配，以及在不同维度上为各数据集设置的阈值，也会对模型的评估结果有决定性作用。因此，需要根据具体应用需求和数据特性，合理设置这些权重和阈值，以确保模型的评估结果具有科学性和有效性。权重的合理分配可以确保模型在综合评估数据集时，充分反映各数据集的重要性和特征。不同维度阈值的设置则有助于细化评估标准，使模型能够更加精准地捕捉到数据质量的差异和问题。通过这些参数的精细调整和优化，模型不仅能够提升对数据质量的准确评估，还能提高其在实际应用中的适用性和可靠性。

3.5 实验过程和结果分析

3.5.1 基准实验

为了模拟工业生产环境中多种因素对数据质量的影响，本部分将构建带标注的合成数据，在结构化数据中人为注入特定类型错误（缺失值、异常值等）。

(1) 向数据中添加了正弦噪声和随机白噪声，以模拟环境和测量过程中可能出现的随机干扰，并测试模型对于数据精准性的评估。

(2) 为了模拟现实中的数据缺失情况，故意删除了数据集中 HUFL 属性在$t = 100$和$t = 500$处的数据、HULL 属性在$t = 500$处的数据、以及属性 MUFL 在$t =$

中国知网 https://www.cnki.net

1000处的数据，以测试模型对于数据完整性的评估。

(3) 对每个数据集定义一个特定的值域，该值域旨在界定数据在正常运行条件下的预期范围，以测试模型对于数据一致性的评估。

(4) 针对表征“数据生成时间”的字段，此处对$t = 1000$和$t = 2200$处的数据段进行了人为延迟，以此模拟现实中数据收集和传输过程中的潜在延误，以测试模型对于数据时效性的评估。

如图 3.3 所示，模拟数据用橙黄色曲线表示，它模拟了工业环境中的典型异常（如数据漂移、间歇性缺失、突变扰动等）的合成数据流。而真实（参考）数据则用蓝色曲线显示。用这种方式对比帮助直观地展示两者之间的差异，以识别人为注入错误，从而清晰地观察模拟数据在哪些方面与真实数据存在偏差。

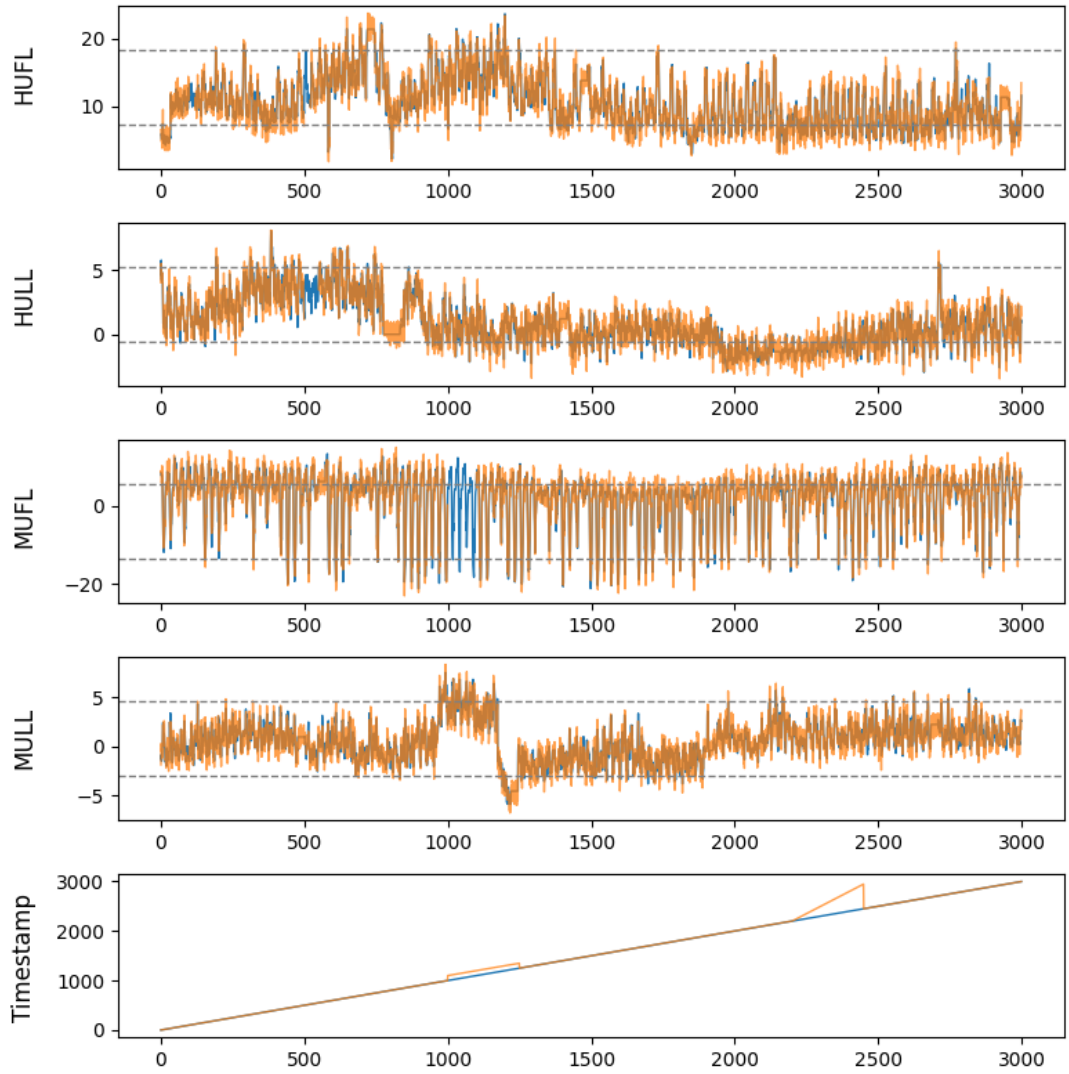


图 3.3 用于 TSWD 算法评估的模拟数据和真实数据对比

Fig. 3.3 Comparison of Simulated and Real Data for TSWD Algorithm Evaluation

中国知网 https://www.cnki.net

评估结果的可视化如图 3.4 所示，其展示了各维度质量指标在滑动窗口机制下的波动趋势与评估效果。实验的输出结果显示，TSWD 算法能够有效识别各类异常数据模式，并在数据质量变化时做出敏感响应。

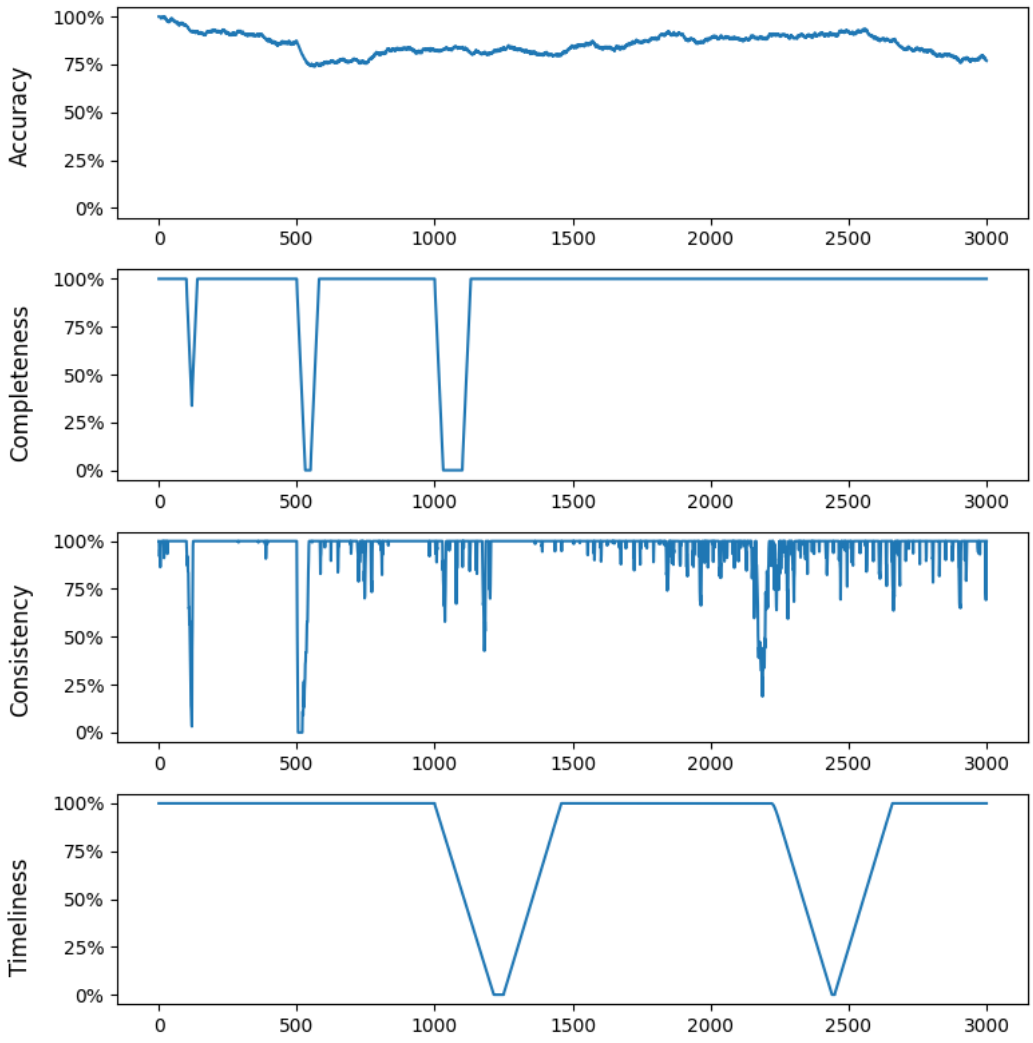


图 3.4 基准实验中 TSWD 算法对于模拟数据的评估结果

Fig. 3.4 Evaluation Results of TSWD Algorithm on Simulated Data in Benchmark Experiment

3.5.2 定制化实验

本部分通过调整模型参数的对比实验方法，验证 TSWD 算法的高度定制化特性。这种方法不仅能够揭示模型在不同参数设置下的表现差异，还能深入探讨其在多样化应用场景中的适应性和有效性，从而全面评估 TSWD 算法的性能和优势。

实验使用来自上一个实验的真实数据集与模拟数据集，将之前的实验结果作为第一组，并将其作为对照组，对其余组别的关键参数进行调整，以评估 TSWD 算法在不同参数设置下的表现。具体而言：

中国知网 https://www.cnki.net

(1) 第二组增大了窗口长度 L 并减小了时序权重因子 α，旨在增加历史数据的权重，从而使当前时刻的评估结果受到更大程度的历史数据影响，以此显示模型在长时间跨度数据上的表现及其对历史数据趋势的捕捉能力。

(2) 第三组增大了偏差缩放因子 β，以加大模型在数据集出现规则违反情况时的惩罚力度，以此评估模型对异常和违规数据的敏感度及其在检测和处理异常数据时的表现。

(3) 第四组则将评估阈值设置得更加宽松，从而降低模型对于数据集的严苛程度，以此显示模型在不同严格程度下的宽容性及其对整体数据质量评估的影响。

定制化实验的评估结果如图 3.5 所示。

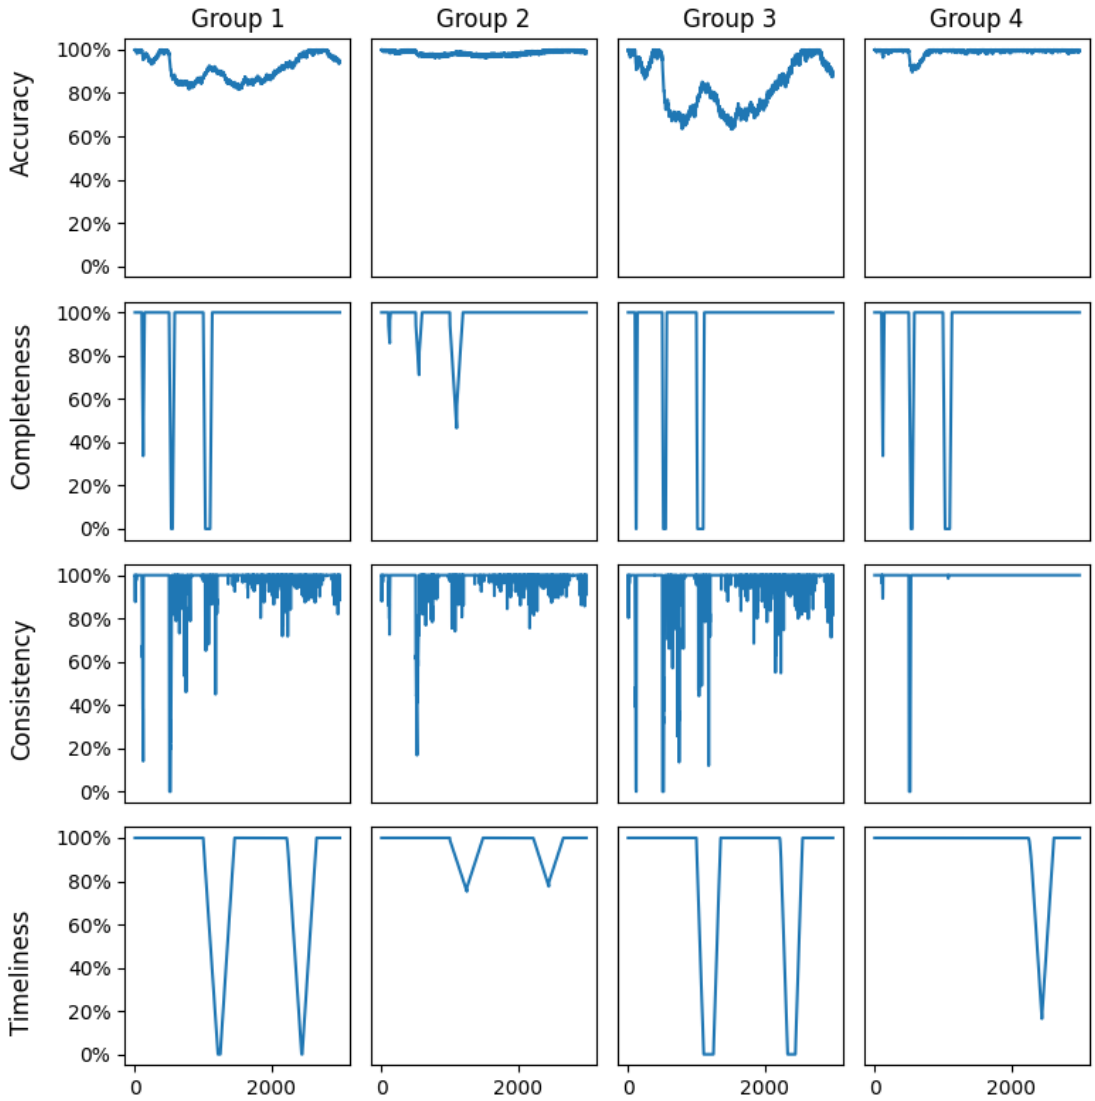


图 3.5 定制化实验中不同参数设置下 TSWD 算法对于模拟数据的评估结果

Fig. 3.5 Evaluation Results of TSWD Algorithm on Simulated Data under Different Sets of Parameters in Customization Experiment

中国知网 https://www.cnki.net

3.5.3 结果分析

基准实验结果表明，TSWD 算法在四个核心维度上表现出色。在精准性方面，该算法能够有效识别并精确捕捉实际数据与参考数据之间的偏差；在完整性方面，算法对数据缺失表现出高度敏感性，能迅速识别并响应缺失数据的情况；在一致性方面，算法对于超出预设值域的数据有着精确的监测能力，能够准确地标识并处理这些异常点。在时效性方面，算法也能够有效地识别数据收集过程中的延迟，对延迟数据提供清晰的反馈。

定制化实验进一步验证了 TSWD 算法的高度定制化特性。实验结果表明，该算法能够根据不同环境中的具体需求灵活调整相应参数，以满足工业生产环境中多种情景的评估标准和要求。这一特性使得 TSWD 算法在实际应用中具有较强的适应性和灵活性，能够在复杂多变的工业生产环境中提供精准可靠的数据质量评估，从而为决策支持和优化生产流程提供有力依据。

综上所述，TSWD 算法不仅兼顾了实时性与维度性，还提供了完整、可解释、适用于高频时序数据场景的质量计算机制，展现出在工业智能化数据治理中的实用性与适应性。能够为提高生产效率和保证产品质量提供重要的数据支持和决策依据。

3.6 本章小结

本章提出了数据质量量化分析算法——TSWD 算法，旨在克服传统评估方法过于片面和粗略的不足。TSWD 算法通过引入历史时间点数据对当前时间点影响的考量，并设定标准以计算每个数据点的偏差值，实现了对数据质量的全面、精确评估。在此基础上，进一步改进现有算法，详细定义了 TSWD 算法的计算公式和规范，确保能够涵盖数据质量的多个核心维度。实验部分设计了参考和模拟数据集，并设置了详细的模型配置参数，以全面验证 TSWD 算法在不同情境下的适用性。测试结果表明，TSWD 算法能够实时输出直观的评估结果，并通过多参数对比实验展示了其在评估精度、效率、稳定性和高定制化方面的优势，证明了 TSWD 算法在实际应用中的广泛适用性和高效性能。

中国知网 https://www.cnki.net

4 SHAPT 时序数据预测模型

4.1 问题定义与方法总览

数据质量直接影响工业生产的效率和成果，而工业时序数据的预测与质量分析之间存在着深刻的耦合关系。预测模型的构建不仅依赖于高质量输入数据，其预测结果与实际观测值的动态偏差分析反过来能够为数据质量评估提供重要反馈。在工业场景中，预测残差的异常模式（如持续偏离、周期性波动或突变尖峰）往往映射着原始数据潜在的质量缺陷：传感器噪声会引发高频残差振荡，数据采集缺失导致局部预测置信度下降，而设备工况漂移则表现为残差分布的非平稳特性。这种预测-质量的双向交互机制表明，高精度时序预测模型的开发不仅服务于未来趋势推演，更构成了数据质量持续监测体系的关键技术组件。

传统时序数据预测方法在此类复杂工业场景中面临显著局限：其固定参数化建模难以适应动态工况变迁，对非线性关系的表达能力不足，且缺乏对数据质量缺陷的自适应容错机制。单独的基于深度学习的时序数据预测模型在一定程度上克服了传统方法对静态参数建模的局限，其端到端训练方式能够自适应地学习数据中的非线性特征和动态模式。然而，这类模型往往侧重于大规模数据的全局特征提取，缺乏对多源异构信号时空耦合特性及工况频繁切换下异常模式的针对性建模，因此在处理复杂工业场景时仍存在不足。

为此，本文提出了一种融合奇异谱分析、混合注意力机制与 PatchTST 的复合预测模型 SHAPT（Singular spectrum analysis - Hybrid Attention - Patch time series Transformer）。该模型首先通过奇异谱分析对原始时序数据进行自适应分解，提取出趋势项、周期项和噪声分量，有效分离信号中的结构化成分与随机扰动；随后，利用 PatchTST 作为核心预测架构，通过分块（Patching）策略降低序列长度，并结合局部-全局混合注意力机制对分解后的分量进行时序建模，精准捕捉数据中的短期波动与长期依赖；最后，通过动态门控融合机制整合不同时间尺度的特征表达，显著提升模型对复杂时序模式的建模能力，为工业大数据的实时监控和智能维护提供有力支持。

4.2 SHAPT 预测模型提出

4.2.1 基于奇异谱分析的时序数据分解

奇异谱分析（Singular Spectrum Analysis, SSA）是一种非参数统计方法，用于分析时间序列数据[78][79]。它起源于 20 世纪 70 年代末到 80 年代初，最初被用于气象学和地球物理学领域，以分析和预测气候变化和地震活动。随着时间的推移，

中国知网 https://www.cnki.net

它的应用范围扩展到了经济学、金融、医学和工程学等多个领域。

这种方法通过分解时间序列来揭示其内在的结构，如趋势、周期性成分和噪声等。SSA 不依赖于先验的模型假设，因此非常灵活，可以应用于各种不同的数据类型和领域。它结合了时间序列分析、信号处理和线性代数的元素，是一种强大的分析工具。

奇异谱分析的流程主要步骤如图 4.1 所示。首先是将原始时间序列转换成轨迹矩阵，以捕捉时间序列的内在结构。然后进行奇异值分解（SVD），利用线性代数的方法分解轨迹矩阵，得到一系列奇异值和对应的奇异向量。然后，根据奇异值的重要性进行分组，将相似或相关的奇异值（及其对应的奇异向量）分为一组，将时间序列中的不同成分，如趋势、周期性成分和噪声区分开。最后，通过对角平均和重构，将这些分组转换回时间序列的形式，从而得到时间序列的各个成分。

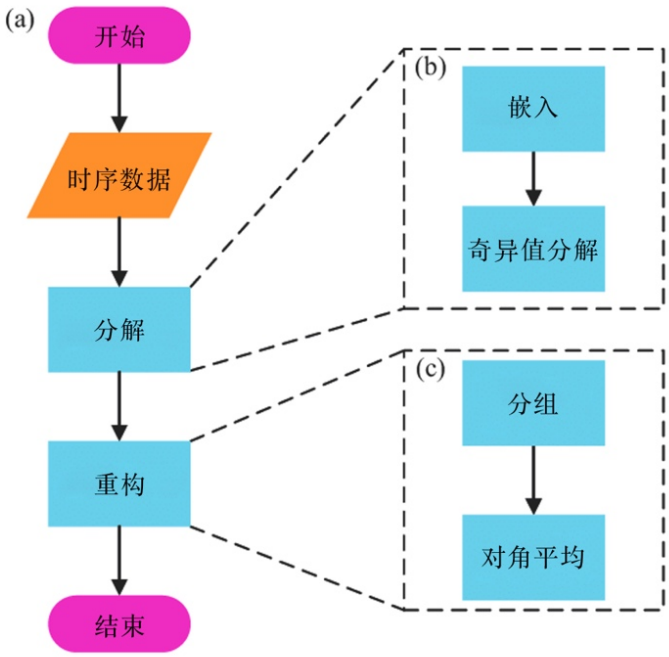


图 4.1 奇异谱分析流程图

Fig. 4.1 Flow Chart of Singular Spectrum Analysis

奇异谱分析的具体算法过程如下：

(1) 嵌入

嵌入可以看作是一种映射，将输入的一维时间序列$X = \{x_1, x_2, \dots, x_T\}$转换成多维序列 $X_1, X_2, \dots, X_K$，其中向量$X_i = (x_i, x_{i+1}, \dots, x_{i+L-1}) \in \boldsymbol{R}^L$，此处$K = T -$

中国知网 https://www.cnki.net

$L+1$。向量X_i被称为$L-$延迟向量（或简称为延迟向量）。嵌入这一步唯一的参数是窗口长度L，它满足 $2 \le L \le T, L \in N$。这一步得到的结果是轨迹矩阵$\mathbf{X}$。

$$\mathbf{X} = [X_1, X_2, \dots, X_K] = \left(x_{ij}\right)_{i,j=1}^{L,K} = \begin{bmatrix} x_1 & x_2 & \cdots & x_K \\ x_2 & x_3 & \cdots & x_{K+1} \\ \vdots & \vdots & \ddots & \vdots \\ x_L & x_{L+1} & \cdots & x_T \end{bmatrix} \tag{4.1}$$

此处得到的轨迹矩阵$\mathbf{X}$是一个汉克尔矩阵，即沿对角线$i+j=const$的所有元素都相等。嵌入是时间序列分析中的标准程序。

(2) 奇异值分解（Singular Value Decomposition，SVD）

对轨迹矩阵执行奇异值分解，并将其表示为一系列秩为 1 的双正交基本矩阵之和。用$\lambda_1, \lambda_2, \dots, \lambda_{\mathrm{L}}$表示$\mathbf{X}\mathbf{X}^{\mathrm{T}}$的特征值，按大小递减的顺序排列$(\lambda_1 \ge \lambda_2 \ge \cdots \ge \lambda_{\mathrm{L}} \ge 0)$，并用$U_1, U_2, \dots, U_L$表示矩阵$\mathbf{X}\mathbf{X}^{\mathrm{T}}$对应于这些特征值的正交单位向量系统，即对于$i \ne j$，有$(U_i, U_j)$（正交性质）且$\|U_i\|$（单位范数性质）。这里$(U_i, U_j)$是向量$U_i$和$U_j$的内积，$\|U_i\|$是向量$U_i$的范数。令：

$$d = \max\left(i, \text{使得} \lambda_i > 0\right) = \operatorname{rank} \mathbf{X} \tag{4.2}$$

若表示$V_i = \frac{U_i}{\sqrt{\lambda_i}}\mathbf{X}'$，则轨迹矩阵的 SVD 可以写为：

$$\mathbf{X} = \mathbf{X}_1 + \mathbf{X}_2 + \cdots + \mathbf{X}_d \tag{4.3}$$

其中$\mathbf{X}_i = \sqrt{\lambda_i} U_i V_i' (i = 1,2, \dots, d)$。矩阵$\mathbf{X}_i$的秩为 1,因此它们是初等矩阵，$U_i$（在 SSA 中被称为“因子实证正交函数”或简称 EOF）和V_i（通常称为“主成分”）分别代表轨迹矩阵的左右特征向量。$(\sqrt{\lambda_i}, U_i, V_i)$被称为矩阵$\mathbf{X}$的第$i$个特征三元组，$\sqrt{\lambda_i}(i = 1,2, \dots, d)$是矩阵$\mathbf{X}$的奇异值，集合$\{\sqrt{\lambda_i}\}$被称为矩阵$\mathbf{X}$的谱。如果所有特征值的重数都为 1，则轨迹矩阵的 SVD 是唯一的。

SVD 在以下意义上是最优的：在所有秩为$r < d$的矩阵$\mathbf{X}^{(\mathrm{r})}$中，矩阵$\sum_{i=1}^{r} \mathbf{X}_i$提供了对轨迹矩阵$\mathbf{X}$的最佳近似，使得$\left\|\mathbf{X} - \mathbf{X}^{(r)}\right\|$最小。其中$\|\mathbf{X}\|^2 = \sum_{i=1}^{d} \lambda_i$，且对于$i = 1,2, \dots, d$，有$\|\mathbf{X}_i\|^2 = \lambda_i$。

因此，可以将比率$\lambda_i / \sum_{i=1}^{d} \lambda_i$视为矩阵$\mathbf{X}_i$对 SVD 的贡献度的特征值。因此，前$r$个比率的和，即$\sum_{i=1}^{r} \lambda_i / \sum_{i=1}^{d} \lambda_i$是轨迹矩阵通过秩为$r$的矩阵的最佳近似的特征。

(3) 分组

分组即将初等矩阵$\mathbf{X}_i$分成若干组，并将每个组内的矩阵相加。这一步是主观的，一般将奇异值作为分组的一个直接依据。奇异值的大小反映了每个成分在时间序列中的重要性或能量。通常，较大的奇异值对应于数据中的主要成分（如趋势和主要的周期成分），而较小的奇异值代表噪声或不太重要的成分。因此，需要根据具体情况和需求，酌情选择特征三元组。

将初等矩阵$\mathbf{X}_i$的下标$\{1,2, \dots, d\}$划分为a个不相交的子集，设为$\{I_1, I_2, \dots, I_a\}$，

中国知网 https://www.cnki.net

对于任意正整数$q \in [1, a]$，有：

$$\mathbf{X}_{I_q} = \sum_{i \in I_q} \mathbf{X}_i \tag{4.4}$$

则轨迹矩阵可表示为：

$$\mathbf{X} = \mathbf{X}_{I_1} + \mathbf{X}_{I_2} + \cdots + \mathbf{X}_{I_a} \tag{4.5}$$

选择集合$I_1, I_2, \ldots, I_b$的过程称为特征三元组分组。对于给定的组I，矩阵$\mathbf{X}_I$对SVD 的贡献度通过相应特征值的比例$\sum_{i \in I} \lambda_i \,/\, \sum_{i=1}^{d} \lambda_i$来衡量。

(4) 对角平均

对角平均将矩阵$\mathbf{X}_{I_1}$转换成时间序列。举例来说，如果z_{ij}代表矩阵$\mathbf{Z}$的一个元素，那么结果序列的第k项是通过对使得$i + j = k + 2$的所有z_{ij}进行平均得到的。这个过程称为对角平均，或矩阵$\mathbf{Z}$的汉克尔化（Hankelization)。矩阵$\mathbf{Z}$的汉克化结果是汉克尔矩阵$H\mathbf{Z}$，它是对应于作为对角平均结果得到的序列的轨迹矩阵。汉克尔化是一种优化过程，因为在所有相应大小的汉克尔矩阵中，矩阵$H\mathbf{Z}$就矩阵范数而言是与$\mathbf{Z}$最接近的。反过来说，汉克尔矩阵$H\mathbf{Z}$通过将对角线上的值与序列中的值相关联，唯一地定义了序列。

对上一步分组的结果中的所有矩阵组分应用汉克尔化过程，可以得到另一个展开式：

$$\mathbf{X} = \widetilde{\mathbf{X}}_{I_1} + \widetilde{\mathbf{X}}_{I_2} + \cdots + \widetilde{\mathbf{X}}_{I_a} \tag{4.6}$$

对每个分组矩阵X_{I_t}应用对角平均，使其转换成时间序列。设正整数$b \in [1, T]$，则有重构式如下：

$$x_b^t = \begin{cases} \dfrac{1}{b} \displaystyle\sum_{c=1}^{b} \mathbf{X}_{I_t}(a, b-c+1), 1 \le b < L \\ \dfrac{1}{L} \displaystyle\sum_{c=1}^{L} \mathbf{X}_{I_t}(c, b-c+1), L \le b < K \\ \dfrac{1}{T-K+1} \displaystyle\sum_{c=b-K+1}^{T-K+1} \mathbf{X}_{I_t}(c, b-c+1), K \le b \le T \end{cases} \tag{4.7}$$

由此便得到经由奇异谱分析处理得到的代表初始序列$X = \{x_1, x_2, \ldots, x_T\}$的趋势成分的序列集合$\{S_1, S_2, \ldots\}$，其中$S_i = \{x_1^i, x_2^i, \ldots, x_T^i\}$。

4.2.2 基于混合注意力改进的 PatchTST 的时序数据预测

传统循环神经网络在处理长序列时间依赖时存在梯度消失和计算效率低下的问题，限制了其在长期时间序列预测中的性能。相比之下，Transformer 架构通过自注意力机制实现了全局信息的高效捕捉，但其计算复杂度随序列长度的平方增长，限制了应用范围。PatchTST 模型[77]通过将时间序列划分为固定长度的子序列（patches），作为 Transformer 的输入 token，保留了局部语义信息，并通过通道独

中国知网 https://www.cnki.net

立性设计（每个通道共享相同的嵌入和 Transformer 权重）降低了计算和内存需求，从而在长期预测任务中取得了显著的性能提升。因此，本文选择 PatchTST 作为基底模型进行进一步改进，以期在长期时间序列预测中获得更优的表现。

在实际工业场景中，由于时序数据往往同时包含密集的局部波动和稀疏的全局依赖，传统 PatchTST 的全局注意力机制可能因过度关注无关时间点而引入噪声。为此，本文提出混合注意力机制改进方案，结合局部注意力与稀疏全局注意力，使模型能够分层处理不同尺度的时序模式。

混合注意力机制的改进显著提升了 PatchTST 在工业场景中的适应性。首先，局部注意力通过约束感受野范围，聚焦于相邻片段内的短期模式（如设备振动周期），有效抑制了远距离噪声干扰；其次，稀疏全局注意力采用拓扑筛选策略，仅保留关键时间节点间的连接（如跨班次的生产指标关联），在降低计算复杂度的同时捕捉必要的长程依赖。这种分而治之的设计既继承了传统 PatchTST 的片段化建模优势，又通过注意力域的智能划分解决了工业数据中局部密集性与全局稀疏性并存的核心矛盾。

以下为混合注意力改进的 PatchTST 模型的工作流程。为方便表示，将上一节经由奇异谱分析处理后得到的所有主成分序列S_i均表示为$X = \{x_1, x_2, \dots, x_T\}$。

(1) 数据归一化

将原始单变量时间序列$\{x_1, x_2, \dots, x_T\} \in \mathbb{R}^T$归一化至均值为 0、方差为 1 的分布，消除量纲差异，提升模型训练稳定性。

$$\hat{x}_t = \frac{x_t - \mu}{\sigma}, \qquad \mu = \frac{1}{T}\sum_{t=1}^{T} x_t\,, \qquad \sigma = \sqrt{\frac{1}{T}\sum_{t=1}^{T}(x_t - \mu)^2} \tag{4.8}$$

(2) 分块

将长序列T压缩为更短的块序列N，每个块代表一个局部时间片段，以降低后续 Transformer 的计算复杂度。

$$\mathbf{X}_{\text{patch}} = \begin{bmatrix} \hat{x}_1 & \hat{x}_2 & \cdots & \hat{x}_P \\ \hat{x}_{P+1} & \hat{x}_{P+2} & \cdots & \hat{x}_{2P} \\ \vdots & \vdots & \ddots & \vdots \\ \hat{x}_{(N-1)P+1} & \hat{x}_{(N-1)P+2} & \cdots & \hat{x}_{NP} \end{bmatrix} \in \mathbb{R}^{N\times P} \tag{4.9}$$

(3) 线性投影和位置编码

通过全连接层将每个块映射到D维向量空间，将原始时间点转换为高维特征表示，增强模型表达能力。

$$\mathbf{Z}^{(0)} = \mathbf{X}_{\text{patch}} \cdot \mathbf{W}_e + \mathbf{b}_e, \qquad \mathbf{W}_e \in \mathbb{R}^{P\times D}, \qquad \mathbf{b}_e \in \mathbb{R}^D \tag{4.10}$$

添加可学习的位置编码$\boldsymbol{P} \in \mathbb{R}^{N\times D}$，确保模型感知块的时序位置$\mathbf{Z}^{(0)} \leftarrow \mathbf{Z}^{(0)} +$

中国知网 https://www.cnki.net

$\mathbf{P}$。

(4) 混合注意力 Transformer 层

模型包含L层 Transformer，对于每一层$l = 1,2,\dots,L$，模型依次计算如下：

①局部窗口注意力（Local Window Attention）

将$\mathbf{Z}^{(l-1)} \in \mathbb{R}^{N\times D}$划分为大小为 W 的局部窗口，共$M = \left\lfloor \frac{N}{W} \right\rfloor$个窗口，以捕捉窗口内块的短期依赖。对于第$m$个窗口$\mathbf{Z}_m^{(l-1)}$，计算查询、键和值矩阵：

$$\mathbf{Q}_m = \mathbf{Z}_m^{(l-1)}\mathbf{W}_Q, \qquad \mathbf{K}_m = \mathbf{Z}_m^{(l-1)}\mathbf{W}_K, \qquad \mathbf{V}_m = \mathbf{Z}_m^{(l-1)}\mathbf{W}_V \tag{4.11}$$

并通过缩放点积自注意力获得局部特征：

$$\mathbf{H}_{\text{local},m}^{(l)} = \text{Softmax}\left(\frac{\mathbf{Q}_m\mathbf{K}_m^{\top}}{\sqrt{D}}\right)\mathbf{V}_m \tag{4.12}$$

随后通过拼接各窗口得到局部窗口注意力$\mathbf{H}_{\text{local}}^{(l)} \in \mathbb{R}^{N\times D}$。

②稀疏全局注意力（Sparse Global Attention）

对整个序列进行全局注意力计算，首先构造全局查询、键和值：

$$\mathbf{Q} = \mathbf{Z}^{(l-1)}\mathbf{W}_Q, \qquad \mathbf{K} = \mathbf{Z}^{(l-1)}\mathbf{W}_K, \qquad \mathbf{V} = \mathbf{Z}^{(l-1)}\mathbf{W}_V \tag{4.13}$$

然后构建全局注意力矩阵，并对每一行选择 Top-k：

$$\mathbf{A}_{\text{sparse}}(i,j) = \begin{cases} \dfrac{\mathbf{q}_i \cdot \mathbf{k}_j^{\top}}{\sqrt{D}}, & \text{if } j \in \text{Top}_k(\mathbf{q}_i\mathbf{K}^{\top}) \\ -\infty, & \text{otherwise} \end{cases} \tag{4.14}$$

进而计算全局注意力输出：

$$\mathbf{H}_{\text{global}}^{(l)} = \text{Softmax}\left(\mathbf{A}_{\text{sparse}}\right)\mathbf{V} \in \mathbb{R}^{N\times D} \tag{4.15}$$

③门控融合机制

为实现局部与全局信息的自适应融合，利用上一层的统计特征，通过门控网络计算融合系数：

$$\lambda^{(l)} = \sigma\left(\mathbf{W}_g \cdot \text{Concat}\left[\mu^{(l-1)}, {\sigma^2}^{(l-1)}\right] + \mathbf{b}_g\right) \tag{4.16}$$

其中$\sigma(\cdot)$为 sigmoid 函数。最终融合局部与全局注意力：

$$\mathbf{H}_{\text{hybrid}}^{(l)} = \lambda^{(l)} \odot \mathbf{H}_{\text{local}}^{(l)} + \left(1-\lambda^{(l)}\right) \odot \mathbf{H}_{\text{global}}^{(l)} \tag{4.17}$$

④前馈网络与残差连接

对融合后的表示进行非线性变换：

$$\mathbf{H}_{\text{ffn}}^{(l)} = \text{ReLU}\left(\mathbf{H}_{\text{hybrid}}^{(l)}\mathbf{W}_1 + \mathbf{b}_1\right)\mathbf{W}_2 + \mathbf{b}_2 \tag{4.18}$$

并利用残差连接和批归一化更新表示：

$$\mathbf{Z}^{(l)} = \text{BatchNorm}\left(\mathbf{H}_{\text{hybrid}}^{(l)} + \mathbf{H}_{\text{ffn}}^{(l)}\right) \tag{4.19}$$

重复以上过程L次后，获得最终隐藏表示$\mathbf{Z}^{(L)} \in \mathbb{R}^{N\times D}$。

(5) 解码与预测生成

将最终层输出$\mathbf{Z}^{(L)}$映射回原始时间维度：

$$\widehat{\mathbf{X}}_{\text{patch}} = \mathbf{Z}^{(L)}\mathbf{W}_d + \mathbf{b}_d, \qquad \mathbf{W}_d \in \mathbb{R}^{D\times P}, \qquad \mathbf{b}_d \in \mathbb{R}^{P} \tag{4.20}$$

中国知网 https://www.cnki.net

展平预测块并截取未来i个时间点：

$$\hat{\mathbf{X}}_{\text{predict}} = \text{Flatten}\left(\hat{\mathbf{X}}_{\text{patch}}\right)[T-i:T] \in \mathbb{R}^{i} \tag{4.21}$$

最后，通过逆归一化将预测值还原为原始尺度：

$$x_{T+t} = \hat{x}_{T+t} \cdot \sigma + \mu, \qquad t = 1,2,\dots,i \tag{4.22}$$

如此，即得到最终输出预测时序数据$\{x_{T+1}, x_{T+2}, \dots, x_{T+i}\}$。

本文提出的 SHAPT 模型架构如图 4.2 所示：

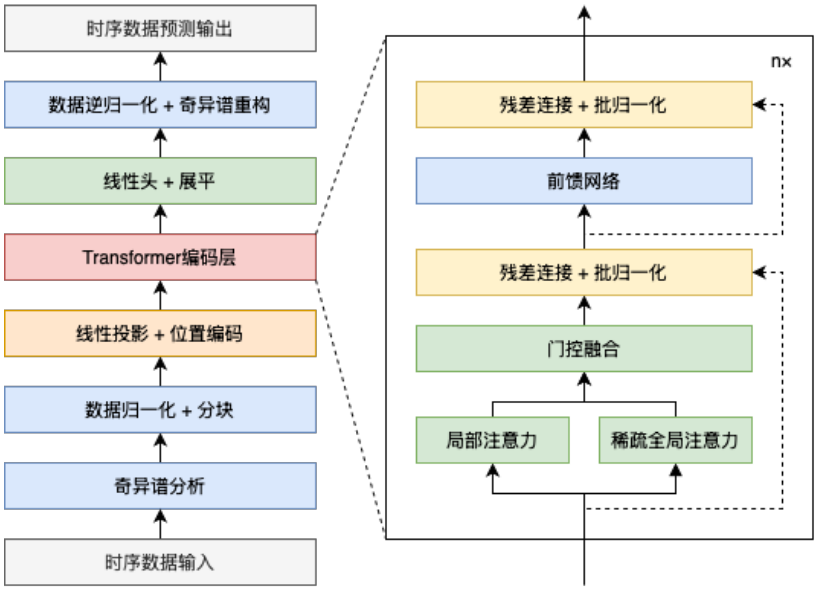


图 4.2 SHAPT 模型架构

Fig. 4.2 Architecture of SHAPT Model

SHAPT 模型由三大关键组成部分构成，分别是奇异谱分析（SSA）、混合注意力机制（Hybrid Attention）以及 PatchTST 模型，它们各自具备在同类方法中突出的技术优势，同时又针对工业场景的特性做了深度适配，形成了一个结构紧凑、性能优异的工业时序预测框架。

首先，奇异谱分析作为一种无模型假设的时序分解方法，在同类方法中相比傅里叶变换、小波分析或经验模态分解（EMD）更加灵活，能将时间序列清晰地分解为趋势项、周期项和噪声项，具有极强的可解释性和对短序列的适应能力。在工业场景中，设备采集的原始传感器数据往往包含复杂的周期性与扰动信息，例如由于机械磨损、电磁干扰或环境波动产生的信号漂移与噪声，这些对预测模型构成重大挑战。SSA 在预处理阶段即可剥离非结构性噪声，保留可建模趋势，从而有效减轻后续模型的学习负担，并提升预测稳定性与精度。

其次，SHAPT 模型引入的混合注意力机制结合了局部注意力和全局稀疏注意力的优点，在同类方法中表现出更强的信息融合能力。与传统的自注意力机制相

中国知网 https://www.cnki.net

比，混合注意力不仅能精准捕捉短期变化和细节特征，还能高效建模长时间依赖关系，同时通过稀疏策略大幅降低了计算复杂度。这一机制尤其适用于工业控制系统中的多尺度信号建模任务。例如，某些工业数据既存在设备周期波动，也可能潜藏低频的退化趋势，通过混合注意力可以同步感知这些异质特征，提高对异常状态的响应速度和预测前瞻性。此外，这种结构具备良好的计算效率和可部署性，非常适合运行于边缘计算节点或实时监控平台。

最后，作为模型的预测主干，PatchTST 在近年来的时序建模研究中被视为 Transformer 系列模型的高效代表。它采用非递归结构，避免了 LSTM 或 GRU 常见的长期梯度消失问题，同时引入 patch 分片机制，将长序列拆分为更易学习的局部块，提升了模型对长时依赖的捕捉能力，并可在训练和推理过程中并行处理数据。在实际工业应用中，PatchTST 适用于处理高维多变量数据流，尤其是在多个传感器异步、异构的数据场景下表现出良好的泛化性与稳定性。它能有效建模如设备压力、温度、电流等信号间的动态关联，完成对设备运行状态的精准预测，并为工业云平台或边缘端部署提供高效、稳定的预测引擎支撑。

综上所述，SHAPT 模型通过 SSA 的预处理能力、混合注意力机制的多尺度感知能力，以及 PatchTST 的深度预测能力的高效耦合，构建出适用于复杂工业环境的时序预测系统。与同类方法相比，SHAPT 在结构设计上体现出更强的可解释性、抗干扰性与实时响应能力，特别适合部署于设备监控系统、预测性维护平台和工业边缘计算终端，满足当前智能制造场景对数据预测精度与效率的双重需求。

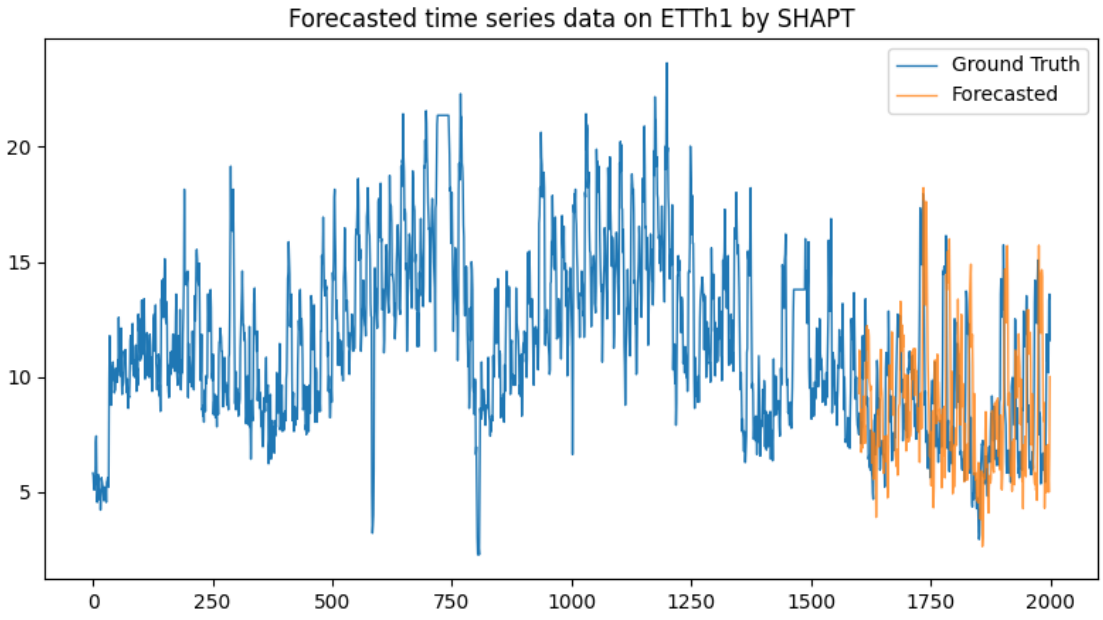


图 4.3 SHAPT 模型时序数据预测演示

Fig. 4.3 Demonstration of SHAPT Model for Time Series Data Forecasting

中国知网 https://www.cnki.net

4.3 实验设计

4.3.1 数据集介绍与构建

实验同样使用 ETT（Electric Transformer Temperature）数据集，选用数据集中分钟级和小时级数据集各两个。并对每一组数据集按 4:1 比例划分为训练集和测试集，具体数据集信息如表 4.1 所示。

表 4.1 实验数据集信息表

Table 4.1 Experimental Dataset Information Table

数据集	ETTh1	ETTh2	ETTm1	ETTm2
特征数	7	7	7	7
时间步数	17420	17420	69680	69680

4.3.2 实验环境

本章实验所采用的环境配置如表 4.2 所示。实验在 NVIDIA GeForce GTX 2060 上完成，采用 PyCharm 作为集成开发环境，采用 TensorFlow 作为深度学习框架。

表 4.2 实验环境配置

Table 4.2 Experimental Environment Configuration

名称	版本信息
CPU	Intel(R) Core (TM) i5-12400F CPU @ 2.5GHz
GPU	NVIDIA GeForce GTX 2060
内存	32GB
Python 版本	3.10
编译器	PyCharm
深度学习框架	TensorFlow2.4.1 GPU 版本

中国知网 https://www.cnki.net

4.3.3 实验相关参数

在本实验中，涉及的参数主要是超参数，这些参数需在模型训练前确定，而非神经网络内部的参数。具体涉及的超参数如下：

(1) Patch Size(P)：决定每个 patch 包含的时间步数，直接影响局部特征的捕获粒度。较大的 P 能捕捉更长的局部模式，但可能导致局部信息模糊；较小的 P 则更细致，但会增加 patch 数量，计算量上升。

(2) 嵌入维度(D)：用于将 patch 映射到低维表示空间，决定了模型的表达能力和计算量。较高的维度可能捕获更多信息，但计算和内存消耗也会增加。

(3) 层数(L)：混合注意力模块堆叠的层数，决定了模型的深度和特征抽象能力。层数太少可能无法充分表达复杂关系，层数太多则可能导致训练困难。

(4) 局部窗口大小(W)：划分局部窗口时每个窗口内包含的 patch 数。窗口大小需平衡局部细节与跨窗口信息传递。

(5) 全局注意力 Top-k 值：在全局注意力计算中，仅保留每一行最高的 k 个注意力分数，以减少计算量并突出关键远程依赖。

(6) 注意力头数(H_a)：多头注意力中头数越多，模型理论上捕获的信息越丰富，使模型可以从多个角度捕捉特征,但也会增加参数和计算复杂度。

(7) 激活函数：常用 ReLU 或 tanh，决定了前馈网络非线性映射的性质。

(8) Dropout 比率：用于防止过拟合，随机丢弃部分神经元的输出，建议在 0.1~0.3 之间调节。

(9) 学习率(Learning Rate)：控制梯度更新的步长，是影响训练稳定性与收敛速度的重要超参数。

(10) 批量大小(Batch Size)：每次模型更新所使用的数据样本数，较大的批量有助于稳定梯度，但占用内存较多。

(11) 训练轮数(Epochs)：整个数据集参与训练的轮数，根据验证效果决定早停策略。

以上参数的设定需根据实验结果进行调整以优化模型表现。相关的参数设置详见表 4.3。这些超参数的正确配置是确保模型训练效果的关键因素。

中国知网 https://www.cnki.net

表 4.3 模型相关的超参数设置

Table 4.3 Model-Related Hyperparameter Settings

SHAPT 预测模型参数	数值设置
P	16
D	64
L	4
W	4
Top-k	4
H_a	4
激活函数	ReLU
Dropout 比率	0.1
学习率	0.001
批量大小	32
训练轮数	50

4.3.4 实验指标

该模型属于预测型，主要功能是基于历史数据生成当前时刻的数据估计，本质上属于回归任务。在本实验中，测试集中的实际观测数据序列被标记为$X = \{X_1, X_2, \dots, X_T\}$，而模型生成的预测数据序列则表示为$\hat{X} = \{\hat{x}_1, \hat{x}_2, \dots, \hat{x}_T\}$。为了量化分析模型的预测性能，实验将计算以下指标：

(1) MSE 平均平方误差

MSE 是衡量模型预测值与真实值之间差异的常用指标。计算方法是对所有样本预测误差的平方求和后再取平均。MSE 越小表示模型的预测越准确。

$$\mathrm{MSE} = \frac{1}{T}\sum_{i=1}^{T}(x_i - \hat{x}_i)^2 \tag{4.23}$$

(2) MAE 平均绝对误差

MAE 用于衡量预测值与真实值之间的平均绝对偏差，适用于适合存在噪声或离群点数据的场景。MAE 的值越小，表示模型的预测越准确。

$$\mathrm{MAE} = \frac{1}{T}\sum_{i=1}^{T}|x_i - \hat{x}_i| \tag{4.24}$$

中国知网 https://www.cnki.net

4.4 实验过程和结果分析

4.4.1 对比实验

为系统验证 SHAPT 模型在时序预测任务中的性能优势，本文设计了严谨的对比实验方案。实验选取了五类具有代表性的基线模型：标准 Transformer 架构作为基础参照；三种基于 Transformer 改进的时序预测专用模型——采用高效注意力机制的 Informer、具有序列分解架构的 Autoformer 以及融合频率增强的 FEDformer；作为改进基底模型的 PatchTST 模型。

所有模型均在前文所述数据集上采用完全相同的实验设置进行训练与测试。

为全面评估模型在不同预测跨度下的表现，实验设置了$T \in \{96,192,336,720\}$四个预测步长，分别对应实际应用中常见的短期、中期和长期预测场景。评估指标选用平均平方误差（MSE）和平均绝对误差（MAE）双重标准，确保结果评估的全面性和可靠性。实验结果如表 4.4 所示，其中最佳结果使用了加粗表示。

表 4.4 多种模型的时序数据预测对比实验结果

Table 4.4 Comparative Experimental Results of Time Series Data Forecasting for Multiple Models

模型		SHAPT		PatchTST		FEDfromer		Autoformer		Informer		Transformer	
指标		MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
ETTh1	96	**0.566**	0.466	0.636	**0.460**	0.625	0.501	0.613	0.514	0.713	0.587	0.828	0.575
	192	**0.707**	**0.591**	0.831	0.641	0.838	0.673	0.859	0.689	0.936	0.730	1.074	0.798
	336	**0.902**	**0.736**	1.095	0.869	1.058	0.917	1.123	0.919	1.170	0.963	1.362	1.044
	720	**1.140**	**0.936**	1.294	1.009	1.353	1.046	1.355	1.146	1.530	1.191	1.705	1.303
ETTh2	96	**2.205**	**0.945**	2.534	1.039	2.629	1.038	2.785	1.090	2.650	1.000	3.051	1.119
	192	**2.984**	**1.222**	3.407	1.342	3.488	1.370	3.735	1.410	3.493	1.385	4.007	1.505
	336	**3.923**	**1.613**	4.383	1.734	4.544	1.818	4.845	1.870	4.519	1.810	5.160	1.925
	720	**4.786**	**1.969**	5.481	2.177	5.591	2.198	5.956	2.273	5.555	2.263	6.385	2.457
ETTm1	96	**0.106**	**0.180**	0.123	0.206	0.133	0.221	0.144	0.239	0.159	0.260	0.187	0.285
	192	**0.141**	**0.240**	0.164	0.274	0.178	0.295	0.193	0.319	0.211	0.346	0.249	0.380
	336	**0.143**	**0.304**	0.226	0.385	0.258	0.404	0.286	0.374	0.320	0.476	0.330	0.455
	720	**0.178**	**0.335**	0.262	0.486	0.302	0.509	0.325	0.496	0.349	0.592	0.415	0.604
ETTm2	96	1.043	0.616	1.048	**0.600**	**1.027**	0.657	1.110	0.664	1.133	0.664	1.367	0.721
	192	**1.354**	**0.771**	1.454	0.832	1.435	0.838	1.464	0.862	1.567	0.898	1.779	0.998
	336	**1.717**	**0.968**	1.896	1.035	1.902	1.107	1.868	1.157	2.080	1.151	2.347	1.272
	720	**2.165**	**1.195**	2.277	1.281	2.333	1.334	2.389	1.395	2.549	1.408	2.872	1.615

中国知网 https://www.cnki.net

预测对比实验结果的可视化如图 4.4 所示，各模型的预测实验结果的平均平方误差和平均绝对误差对比可视化分别如图 4.5 和 4.6 所示。

对比实验结果表明，SHAPT 模型的表现在总体上优于 Transformer、Informer、Autoformer、FEDformer、PatchTST 等基线模型。相比传统 Transformer 模型，SHAPT 模型在 MSE 和 MAE 上的提升达到 33.4%和 25.7%；相比作为基底而进行改进的 PatchTST 模型，SHAPT 模型在 MSE 和 MAE 上的提升也达到 13.9%和 9.9%。这一系列实证数据充分验证了 SHAPT 模型在时序特征提取与长期依赖建模方面的有效性。

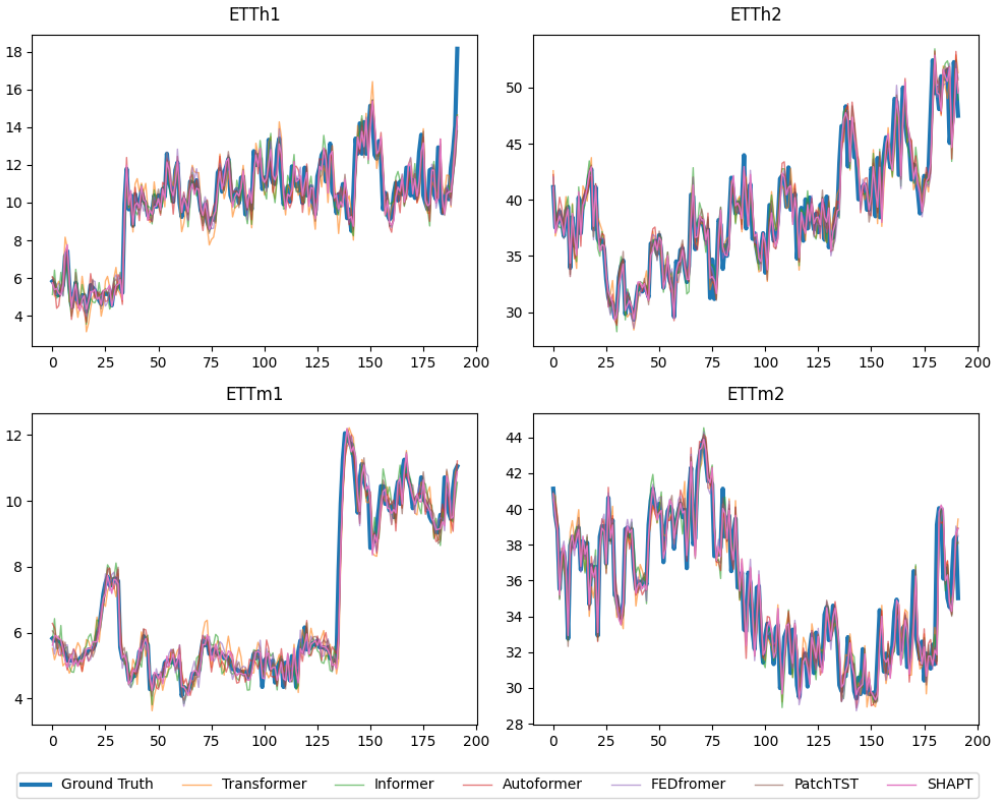


图 4.4 多种模型的时序数据预测对比实验可视化

Fig. 4.4 Visualization of Comparative Experiments on Data Forecasting for Multiple Models

中国知网 https://www.cnki.net

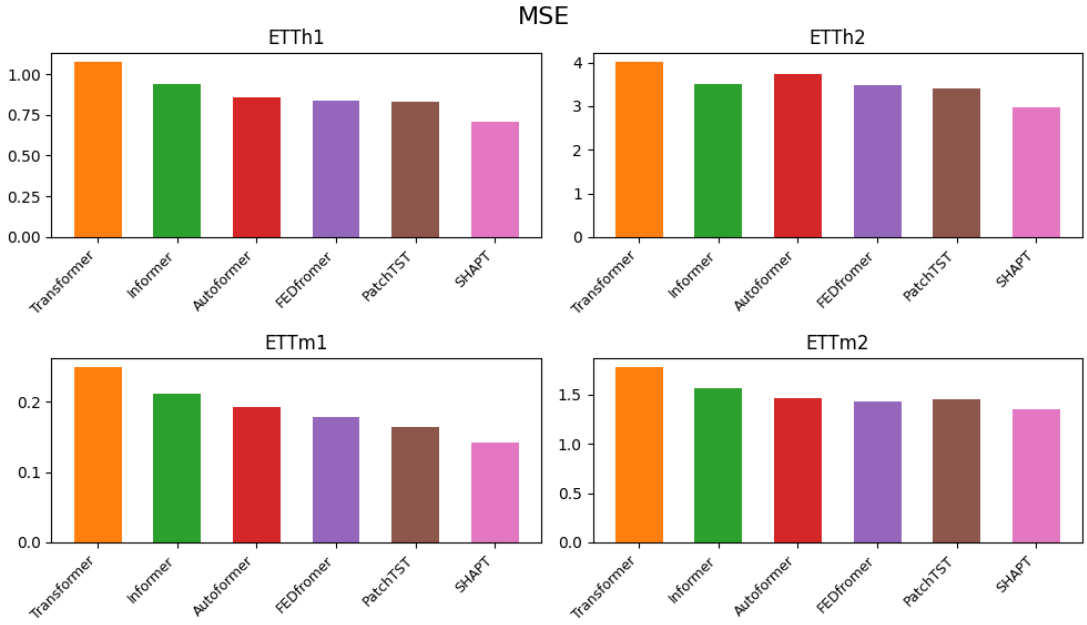


图 4.5 多种模型在不同数据集上的时序数据预测结果的 MSE 对比

Fig. 4.5 Comparison of MSE of Data Forecast Results of Multiple Models on Different Datasets

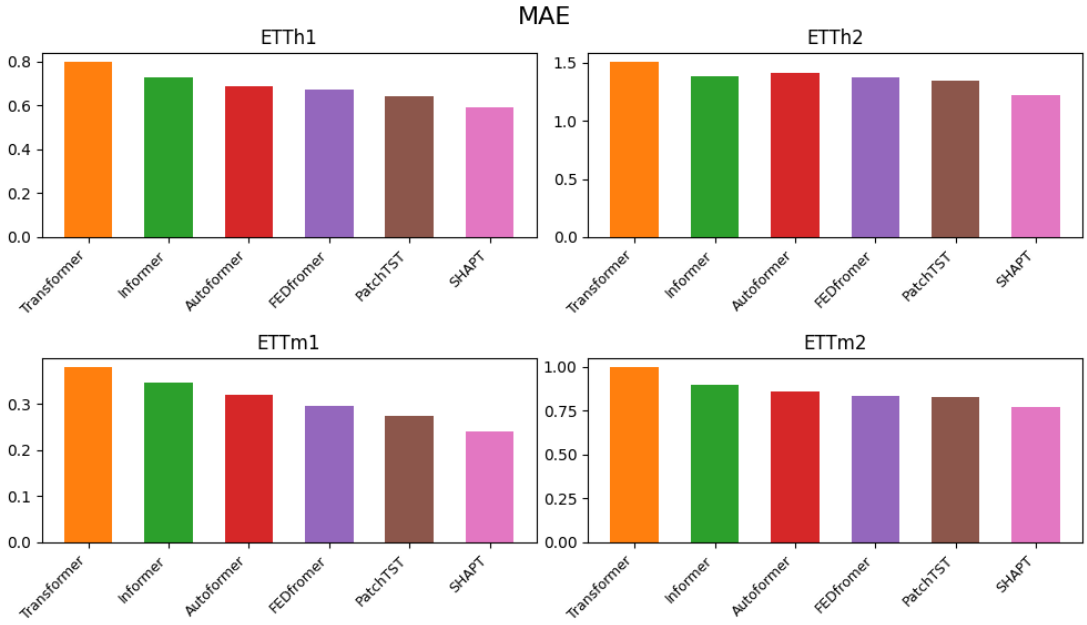


图 4.6 多种模型在不同数据集上的时序数据预测结果的 MAE 对比

Fig. 4.6 Comparison of MAE of Data Forecast Results of Multiple Models on Different Datasets

中国知网 https://www.cnki.net

4.4.2 消融实验

为深入解析 SHAPT 预测模型各核心组件的功能贡献及其协同机制，本文采用控制变量法设计了系统的消融实验研究方案。实验通过模块化拆解策略，逐步移除或替代模型中的关键创新模块，旨在定量评估各组件对模型预测性能的独立贡献与耦合效应。具体实验设置包含五个实验组：

(1) SSA 模块消融组：取消奇异谱分析预处理环节，直接使用原始时序数据作为模型输入。该对照组旨在验证 SSA 在数据降噪、趋势-残差分量分离以及特征空间重构方面的作用，特别是其对非平稳时序数据的适应性处理能力。

(2) 局部注意力消融组：移除局部滑动窗口注意力机制，仅保留稀疏全局注意力模块。通过该实验可定量分析局部注意力在捕捉短期时序模式、微观波动特征以及局部突变响应方面的贡献。

(3) 稀疏全局注意力消融组：禁用稀疏全局注意力结构，仅运行局部注意力机制。此设置重点考察稀疏全局注意力在建模长周期依赖关系、识别跨时段关联模式以及维持时序连续性方面的作用。

(4) 混合注意力全消融组：完全替换创新的混合注意力架构，采用标准 Transformer 的全连接自注意力机制。该对照组用于综合评价混合注意力设计在平衡计算效率与特征捕获能力方面的改进。

(5) 基准模型对照组：将完整 SHAPT 模型作为参照基线，通过横向对比凸显 SHAPT 模型在架构创新带来的整体性能提升。

所有消融实验均在统一实验环境下进行，采用相同的数据划分方案、超参数设置和训练策略。评估指标选用平均绝对误差（MAE）和平均平方误差（MSE）双重标准，确保结果评估的全面性和可靠性。

实验结果如表 4.5 所示，其中最佳结果使用了加粗表示。

通过对 SHAPT 模型进行系统的消融实验，本文验证了各模块对模型预测性能的贡献，以及不同组件之间的协同作用。

首先，奇异谱分析的移除导致性能下降，表明其对时序数据的降噪和趋势-残差分解具有关键作用。SSA 通过分解和重构时序信号，有效增强了模型对潜在时序模式的捕捉能力，而去除该模块后，模型仅依赖原始输入数据，导致噪声干扰增加，预测精度降低。

其次，单独移除局部注意力或稀疏全局注意力均对模型性能产生相近的负面影响，说明两者在时序建模中具有互补性。局部注意力专注于短期依赖关系，能够有效捕捉邻近时间点之间的细粒度模式；而稀疏全局注意力通过降低计算复杂度，实现了对长程依赖的高效建模。二者的结合（即混合注意力机制）使模型能够同时兼顾局部细节和全局趋势，从而提升整体预测能力。

中国知网 https://www.cnki.net

最后，完全移除混合注意力（仅保留标准自注意力）导致性能最差，进一步验证了本文提出的混合注意力机制的优越性。标准 Transformer 的自注意力机制在长序列建模中存在计算效率低和噪声敏感等问题，而混合注意力通过引入局部性和稀疏性先验，显著提升了模型的鲁棒性和预测精度。

表 4.5 SHAPT 模型的时序数据预测消融实验结果

Table 4.5 Ablation Experimental Results of SHAPT Model for Time Series Data Forecasting

模型		完整 SHAPT		去除奇异谱分析		去除局部注意力		去除稀疏全局注意力		去除混合注意力	
指标		MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE	MSE	MAE
ETTh1	96	**0.541**	**0.421**	0.548	0.541	0.734	0.504	0.646	0.511	0.835	0.640
	192	**0.720**	**0.580**	0.723	0.609	0.848	0.662	0.833	0.673	0.987	0.737
	336	**0.894**	**0.704**	0.951	0.788	1.056	0.881	1.109	0.911	1.326	0.983
	720	**1.181**	**0.935**	1.243	0.939	1.348	1.070	1.382	1.121	1.557	1.208
ETTh2	96	**2.305**	**0.899**	2.390	0.938	2.697	1.122	2.460	1.022	2.865	1.116
	192	**3.026**	**1.212**	3.147	1.262	3.618	1.454	3.256	1.355	3.772	1.494
	336	**3.977**	**1.538**	4.103	1.616	4.714	1.863	4.270	1.777	4.893	1.934
	720	**4.845**	**1.930**	5.113	2.038	5.803	2.342	5.166	2.193	5.998	2.380
ETTm1	96	**0.058**	**0.136**	0.192	0.301	0.235	0.316	0.189	0.277	0.219	0.268
	192	**0.131**	**0.240**	0.148	0.268	0.187	0.326	0.152	0.286	0.199	0.333
	336	**0.188**	**0.268**	0.250	0.374	0.305	0.468	0.206	0.467	0.325	0.476
	720	**0.240**	**0.389**	0.249	0.508	0.360	0.562	0.323	0.494	0.378	0.599
ETTm2	96	**1.043**	**0.553**	1.062	0.638	1.220	0.710	1.183	0.688	1.340	0.729
	192	**1.368**	**0.773**	1.408	0.803	1.598	0.901	1.565	0.881	1.668	0.939
	336	**1.804**	**0.958**	1.898	1.050	2.130	1.210	2.036	1.231	2.195	1.314
	720	**2.211**	**1.231**	2.328	1.333	2.634	1.489	2.561	1.436	2.732	1.541

消融预测对比实验结果的可视化如图 4.7 所示，消融实验各部分的预测实验结果的平均平方误差和平均绝对误差对比可视化分别如图 4.8 和 4.9 所示。

中国知网 https://www.cnki.net

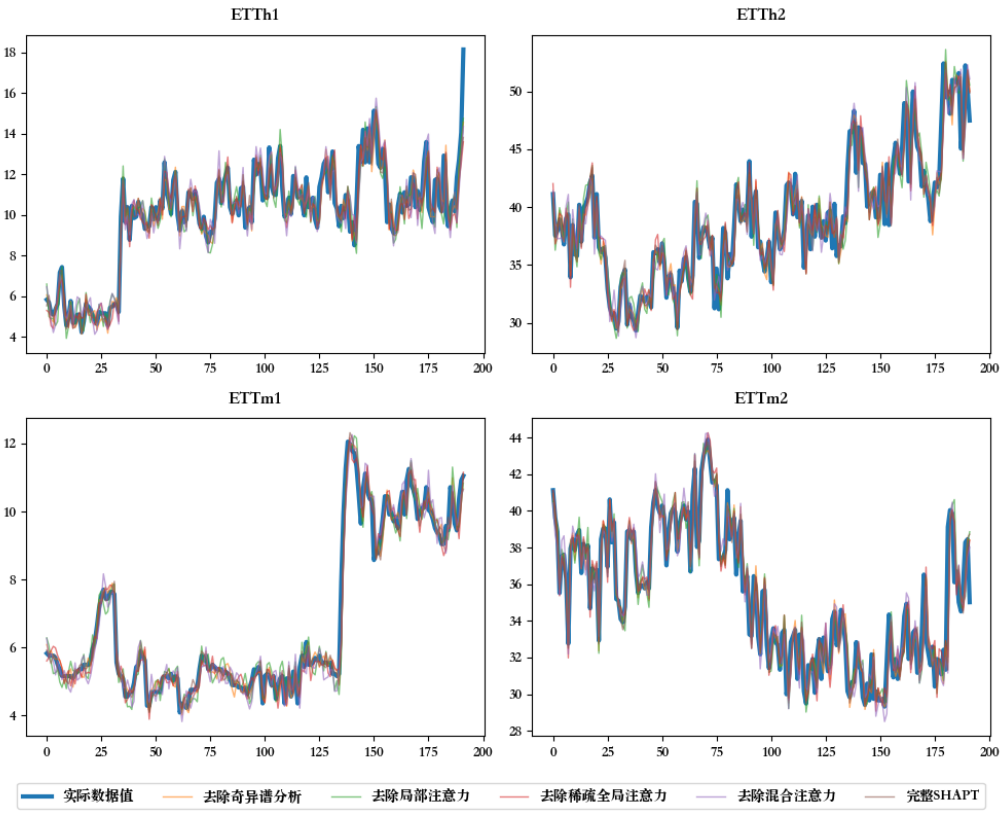


图 4.7 SHAPT 模型的时序数据预测消融实验可视化

Fig. 4.7 Visualization of Ablation Experiments on SHAPT Model for Time Series Data Forecasting

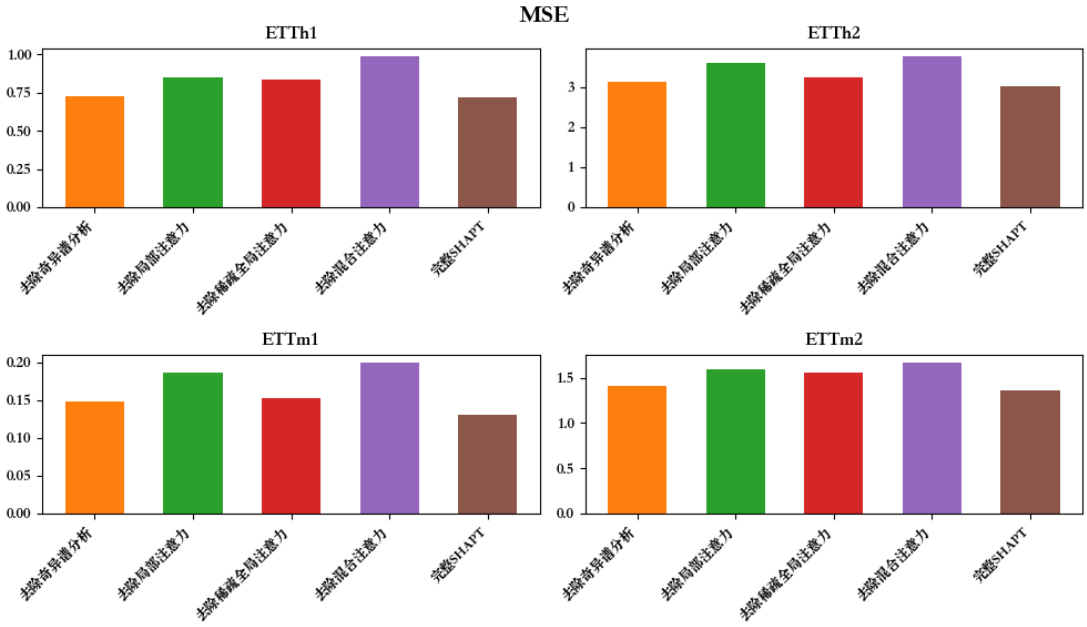


图 4.8 SHAPT 模型消融实验在不同数据集上的时序数据预测结果的 MSE 对比

Fig. 4.8 Comparison of MSE of Ablation Experiments on SHAPT Model for Data Forecasting

中国知网 https://www.cnki.net

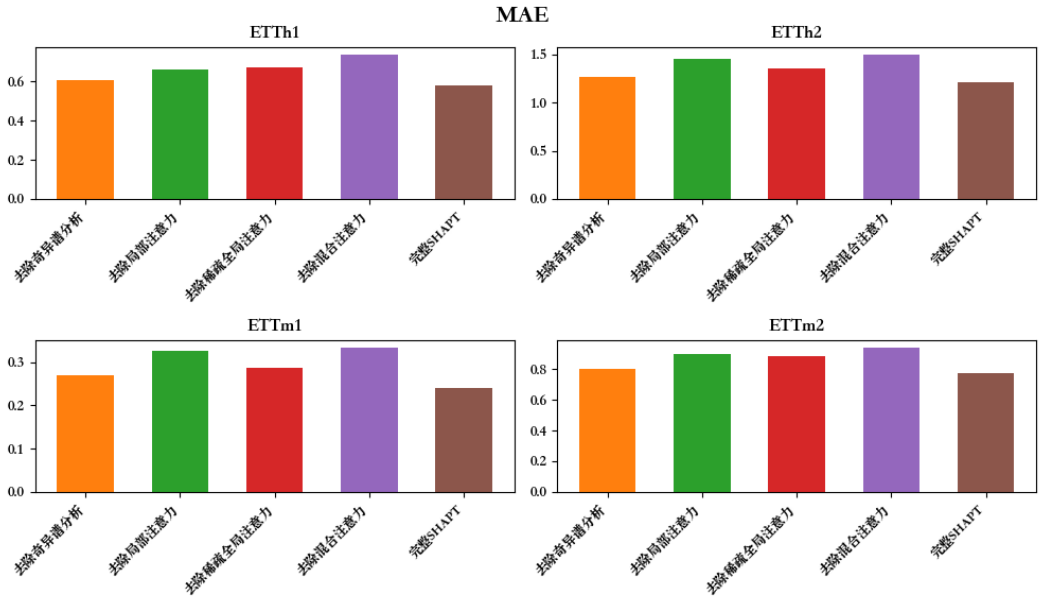


图 4.9 SHAPT 模型消融实验在不同数据集上的时序数据预测结果的 MAE 对比

Fig. 4.9 Comparison of MAE of Ablation Experiments on SHAPT Model for Data Forecasting

消融实验结果表明，SHAPT 模型的优异性能依赖于各模块的协同作用：奇异谱分析提供预处理后的高质量时序特征，混合注意力机制平衡局部与全局建模。此架构设计为时序数据预测任务提供了一种高效且精确的解决方案。

4.5 本章小结

本章围绕所提出的时序预测模型 SHAPT 展开，阐述了其整体架构设计、理论支撑及性能表现。首先，介绍了奇异谱分析（SSA）在预处理阶段的作用，特别是在时序数据分解与重构中的应用，提升了噪声抑制与趋势提取能力，为后续深度特征学习提供了结构化输入。其次，分析了 SHAPT 模型的核心结构——融合混合注意力机制的 PatchTST 架构。该架构通过局部注意力与稀疏全局注意力的协同机制，有效缓解了传统 Transformer 处理长序列时的计算瓶颈与偏差问题。本章进一步设计了时序预测实验方案，结果表明 SHAPT 在预测精度、模型鲁棒性及适应能力方面优于其他模型，验证了其实际应用潜力。最后，设计了消融实验，探讨了各模块的功能与贡献，结果表明 SHAPT 的优异性能依赖于多个模块的互补整合，尤其是 SSA 与混合注意力机制的引入显著提升了时序特征建模能力。

中国知网 https://www.cnki.net

5 工业时序数据质量分析与预测应用平台实现

5.1 应用背景

典型工业设备涵盖了包括用于制造和加工的机床、焊接设备、成型设备、锻压设备，测量和控制的传感器和控制系统，动力设备如电动机和发电机组，物料搬运的输送机和起重机等。监测这些设备通常通过传感器来收集各种运行指标。通过分析这些指标数据，可以建立模型以监测数据变动，从而评估工业设备的运行质量并确保设备的稳定运行。

本章设计开发了一个用于典型工业设备的检测与监控的云平台，应用了之前提出的 TSWD 数据质量评估模型和 SHAPT 预测模型，设计了专门的数据库来存储工业监测数据，这些数据包括由预测模型生成的数据。平台还通过可视化界面展示这些数据，并能定期统计不同指标下的异常数量，进而计算和预测数据质量。系统会根据设定的阈值判断是否需要发出预警或进行设备检修。

5.2 系统设计

5.2.1 系统架构设计

工业时序数据质量评估与预测应用系统平台整体架构分为 3 层，分别是数据层、服务层以及应用层。系统的架构设计如图 5.1 所示：

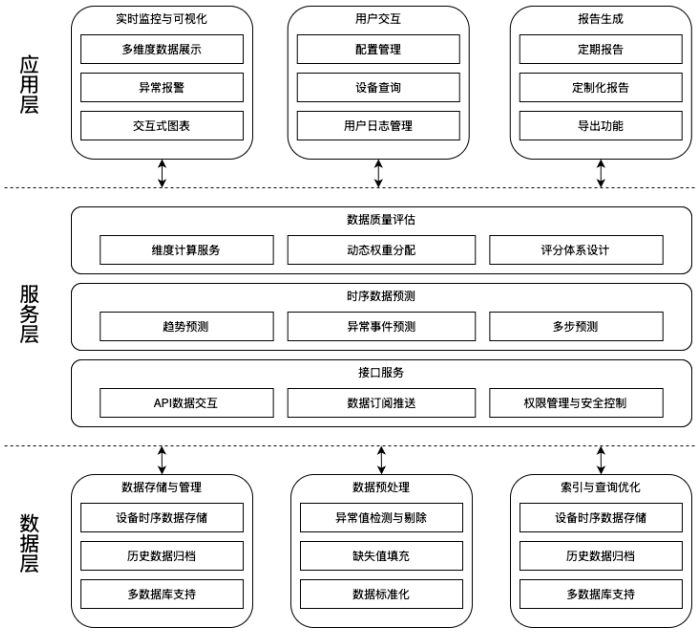


图 5.1 系统架构设计

Fig. 5.1 System Architecture Design

中国知网 https://www.cnki.net

(1) 数据层

数据层主要负责数据的采集、存储、管理及预处理，是系统运行的基础支撑模块。该层实现了对设备时序数据的高效存储和管理，支持对多源异构数据的标准化处理，并结合 MySQL 和 MongoDB 等数据库技术，分别处理结构化和非结构化数据。此外，数据层通过引入异常值检测、缺失值填充、降噪处理等预处理机制，有效提升数据质量，确保后续分析与预测的准确性。索引与分片机制进一步优化了数据查询效率，为系统提供了快速响应能力和高可靠性的数据支撑。其具体组成有：

① 数据存储与管理

设备时序数据存储：支持多种格式（如 JSON、CSV）数据的持久化存储，并分类存储原始数据与处理后数据。

历史数据归档：对长期未访问的历史数据进行归档处理，减轻数据库负载，支持定期归档或手动触发归档功能。

多数据库支持：整合 MySQL 与 MongoDB，分别处理结构化数据（如设备信息）和非结构化数据（如实时传感器数据）。

② 数据预处理

异常值检测与剔除：对采集到的异常数据进行标记或剔除，以提升数据质量。

缺失值填充：支持均值、插值法等多种填充方式，自动补全数据空缺。

数据标准化：对多源异构数据进行统一格式化处理，确保数据一致性。

③ 索引与查询优化

动态索引：针对高频查询的字段（如时间戳、设备 ID）生成索引，优化检索效率。

复杂查询支持：支持按设备、时间段、数据维度等多条件组合查询。

数据分片与分区：对大规模数据进行分片管理，提升查询性能，同时实现负载均衡。

(2) 服务层

服务层承担数据处理与业务逻辑的核心功能，是系统连接数据层与应用层的关键桥梁。该层基于 TSWD 模型实现了多维度的数据质量评估功能，通过动态权重分配和评分体系设计，为用户提供标准化的质量评价结果。同时，服务层结合 SHAPT 模型实现了高精度的时序数据预测功能，能够灵活处理趋势预测、异常事件预测和多步预测等任务。服务层还通过 RESTful API 提供标准化接口，支持与前端应用的实时交互，并通过数据订阅和权限管理机制提升了服务的灵活性与安全性。其具体组成有：

中国知网 https://www.cnki.net

① 数据质量评估

维度计算服务：基于 TSWD 模型计算数据质量的核心维度（如完整性、准确性、实时性）。

动态权重分配：根据用户需求调整不同质量维度的权重，生成更符合实际需求的评估结果。

评分体系设计：将质量评估结果以分数形式量化，提供标准化的质量评分报告。

② 时序数据预测

趋势预测：基于 SHAPT 模型预测关键设备参数未来的变化趋势，如温度、压力等。

异常事件预测：预测设备可能出现的异常行为或故障，为提前维护提供依据。

多步预测：支持短期（分钟级）、中期（小时级）、长期（天级）数据预测，以满足不同业务场景需求。

③ 接口服务

API 数据交互：通过 RESTful API 提供前端调用接口，包括查询数据、调用评估与预测服务。

数据订阅推送：支持用户订阅某设备或某维度数据的实时变化，按需推送更新结果。

权限管理与安全控制：对不同用户或角色设置权限级别，确保数据与服务调用的安全性。

(3) 应用层

应用层聚焦于用户交互和业务场景的实现，为用户提供直观的可视化界面和全面的功能服务。该层设计了多维度的实时监控与数据可视化模块，支持通过图表、仪表盘等形式呈现设备状态和关键指标，并通过异常报警功能实现对异常数据的实时响应。应用层还提供定期与定制化报告生成功能，支持多种格式的导出，方便用户的离线查看与分析。用户交互模块为用户提供了配置管理、设备查询和日志追踪等功能，通过灵活的操作界面，帮助用户高效利用系统完成设备运维和数据驱动决策。其具体组成有：

① 实时监控与可视化

多维度数据展示：通过图表、热力图、仪表盘等方式，实时呈现设备运行状态与关键指标。

异常报警：通过弹窗、短信、邮件等方式，实时报警设备数据的异常波动或超出阈值。

交互式图表：支持用户选择特定时间段、设备或数据维度进行动态查询与分

中国知网 https://www.cnki.net

析。

② 用户交互

配置管理：用户可通过前端界面调整质量评估模型参数、预测模型配置等。

设备查询：提供搜索功能，快速定位某设备的历史数据、评估结果或预测记录。

用户日志管理：记录用户的操作行为，便于追踪系统使用情况与排查问题。

③ 报告生成

定期报告：自动生成设备运行状况和数据质量的周期性报告（如日报、周报）。

定制化报告：用户可指定报告模板或选择特定设备及数据维度来生成报告。

导出功能：支持 PDF、Excel 等多种格式的报告导出，便于离线查看与分享。

5.2.2 功能模块设计

工业时序数据质量评估与预测应用系统平台的功能模块设计流程图如图 5.2 所示：

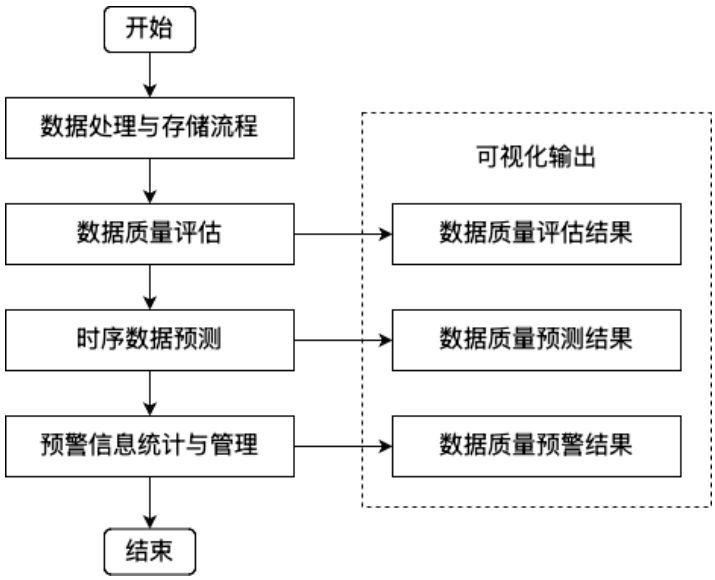


图 5.2 系统功能模块设计流程图

Fig. 5.2 System Functional Module Design Flowchart

工业时序数据质量评估与预测应用系统平台的功能模块主要分为以下四个部分：

(1) 数据处理与存储流程

该模块负责对工业设备产生的原始时序数据$\{X_1, X_2, \ldots, X_t\}$进行全面处理与存储管理。首先对原始数据进行清洗，识别并剔除异常值，同时对缺失数据采用插

中国知网 https://www.cnki.net

值法或统计模型进行填补。随后，通过标准化和归一化对数据$\{X_1, X_2, \ldots, X_t\}$进行预处理，以确保不同维度和尺度的时序数据统一处理。此外，模块采用分布式存储机制，将结构化数据存储于关系型数据库（如 MySQL），非结构化数据存储于文档型数据库（如 MongoDB），并引入索引与缓存策略以提升数据存取效率。

(2) 数据质量评估

数据质量评估模块基于多维度的量化指标对时序数据$\{X_1, X_2, \ldots, X_t\}$的质量进行综合评估。该模块通过 TSWD 模型从数据的完整性、准确性、时效性和一致性等核心维度构建评价体系，并引入动态权重分配方法以适配不同场景的需求。对于每个时间点t，计算该时刻的数据质量评分DQ_t，并结合历史数据$\{DQ_{t-1}, DQ_{t-2}, \ldots, DQ_{t-n}\}$生成质量趋势图。评估结果通过可视化界面以图表形式呈现，为用户直观理解数据质量变化趋势提供支持。

(3) 时序数据预测

该模块通过对历史时间序列数据$\{X_{t-1}, X_{t-2}, \ldots, X_{t-n}\}$的分析与建模，预测未来时间点的时序数据$\{\hat{X}_{t+1}, \hat{X}_{t+2}, \ldots, \hat{X}_{t+m}\}$。模块利用 SHAPT 模型，将原始数据$\{X_1, X_2, \ldots, X_t\}$通过奇异谱分析（SSA）分解为趋势、周期和噪声分量，并基于混合注意力机制改进的 PatchTST 模型对分解后的数据进行建模。预测结果支持短期单步预测和多步预测，提升系统对未来关键指标的预判能力，为设备运维优化提供数据支撑。

(4) 预警信息的统计与管理

预警信息统计与管理模块旨在对时序数据预测结果$\{\hat{X}_{t+1}, \hat{X}_{t+2}, \ldots, \hat{X}_{t+m}\}$进行异常检测与风险评估，从而触发实时预警。该模块基于设定的阈值范围$[L_t, U_t]$，将超出范围的数据标记为异常值，并生成对应的预警事件。系统对每个异常事件进行分类统计，包括发生时间、异常类型及关联设备编号，并通过多维度分析提供预警报告。

5.2.3 数据库设计

以下展示工业时序数据质量评估与预测应用系统平台的数据库中一些关键表的设计。

(1) 时序数据 X 的实际观测值表 observation_x

该表用于存储时序数据的实际观测值以及对应的参考值，包括时间戳、值、格式、上传时间等，具体如表 5.1。

中国知网 https://www.cnki.net

表 5.1 时序数据 X 的观测值表

Table 5.1 Observation Value Table of Time Series Data X

序号	字段名称	数据类型	说明
1	observation_x_id	int	唯一标识的主键
2	time_stamp	timestamp	时序数据的时间戳
3	observation_value	decimal	观测值
4	reference_value	decimal	参考值
5	observation_unit	varchar	数据格式(单位)
6	submit_time	datetime	上传时间

(2) 时序数据 X 的预测值表 forecast_x

用于存储时序数据的预测值，包括时间戳、值、格式、上传时间等，具体如表 5.2。

表 5.2 时序数据 X 的预测值表

Table 5.2 Forecasted Value Table of Time Series Data X

序号	字段名称	数据类型	说明
1	forecast_x_id	int	唯一标识的主键
2	time_stamp	timestamp	时序数据的时间戳
3	forecast_value	decimal	预测值
4	forecast_unit	varchar	数据格式(单位)
5	submit_time	datetime	上传时间

(3) 时序数据 X 的数据质量评估表 data_quality_x

该表用于存储时序数据的数据质量评估值，包括准确性、完整性、一致性、时效性等，具体如表 5.3。

中国知网 https://www.cnki.net

表 5.3 时序数据 X 的数据质量评估表

Table 5.3 Data Quality Assessment Table of Time Series Data X

序号	字段名称	数据类型	说明
1	data_quality_x_id	int	唯一标识的主键
2	observation_x_id	int	观测值 ID
3	forecast_x_id	int	预测值 ID
4	data_accuracy	decimal	数据的准确性
5	data_completeness	decimal	数据的完整性
6	data_consistency	decimal	数据的一致性
7	data_timeliness	decimal	数据的时效性

(4) 数据质量的异常信息统计表 exception

用于存储时序数据质量的异常信息，包括时间戳、异常时间戳、异常评分、异常等级，上传时间，具体如表 5.4。

表 5.4 数据质量异常信息表

Table 5.4 Data Quality Exception Table

序号	字段名称	数据类型	说明
1	exception_id	int	唯一标识的主键
2	time_stamp	timestamp	异常发生时的时间戳
3	exception_degree	decimal	异常的严重程度评分
4	exception_level	varchar	异常的划分等级
5	submit_time	datetime	上传时间

5.3 系统实现

(1) 云平台首页

云平台的主页面作为工业数据质量评估预测系统的门户，它详细展示了关键信息，包括数据质量概览、预警状况、以及各数据源设备的数据量等。这些数据被整合并直观显示，为用户提供一目了然的系统概览。

中国知网 https://www.cnki.net

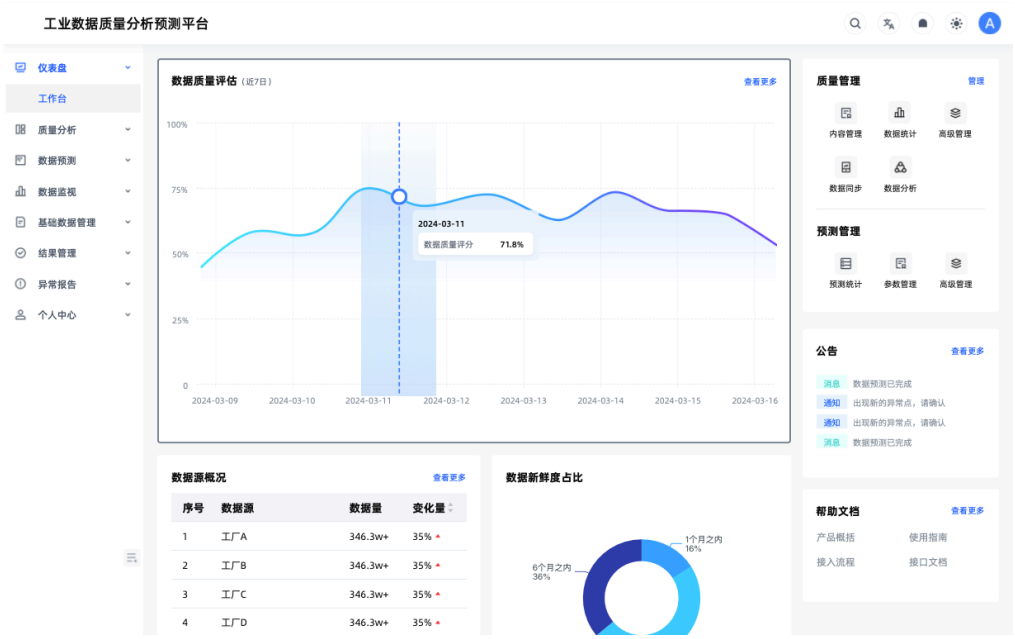


图 5.3 云平台首页

Fig. 5.3 Cloud Platform Home Page

(2) 数据质量总览页面

数据质量总览页面提供了关于各项设备指标的数据质量评估信息概览。此页面不仅展示有史以来的所有数据质量评估结果，还允许用户执行年度同比和季度环比分析，以便跟踪和比较性能变化。

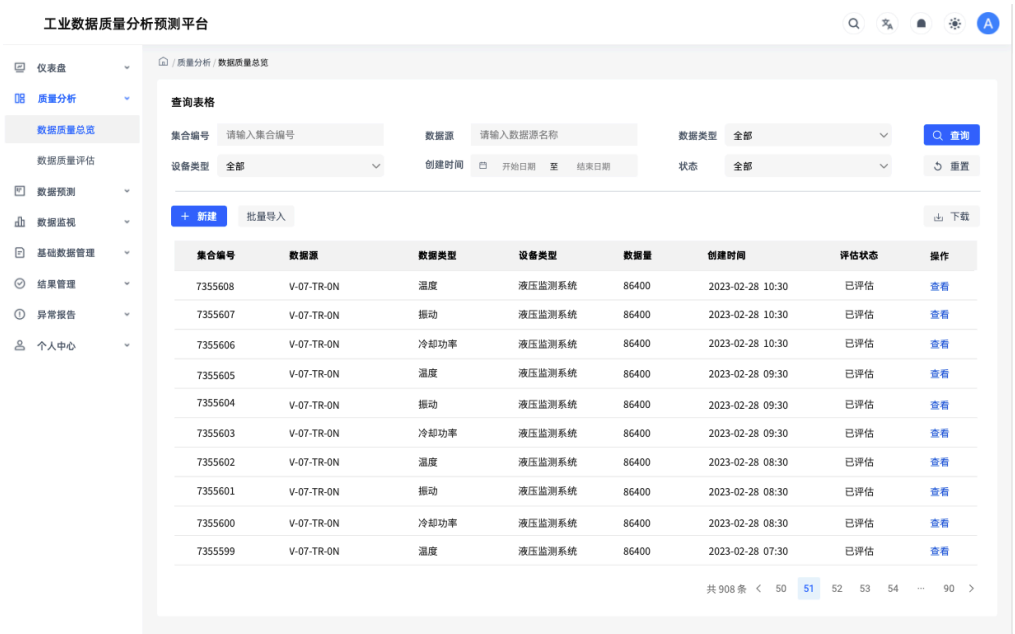


图 5.4 数据质量总览页面

Fig. 5.4 Data Quality Overview Page

中国知网 https://www.cnki.net

(3) 数据质量评估界面

在数据质量评估页面中，用户可以查看到实时的监测数据及其数据质量评估结果。页面通过动态可视化图表，详细呈现了数据质量的变化和可能的问题区域。

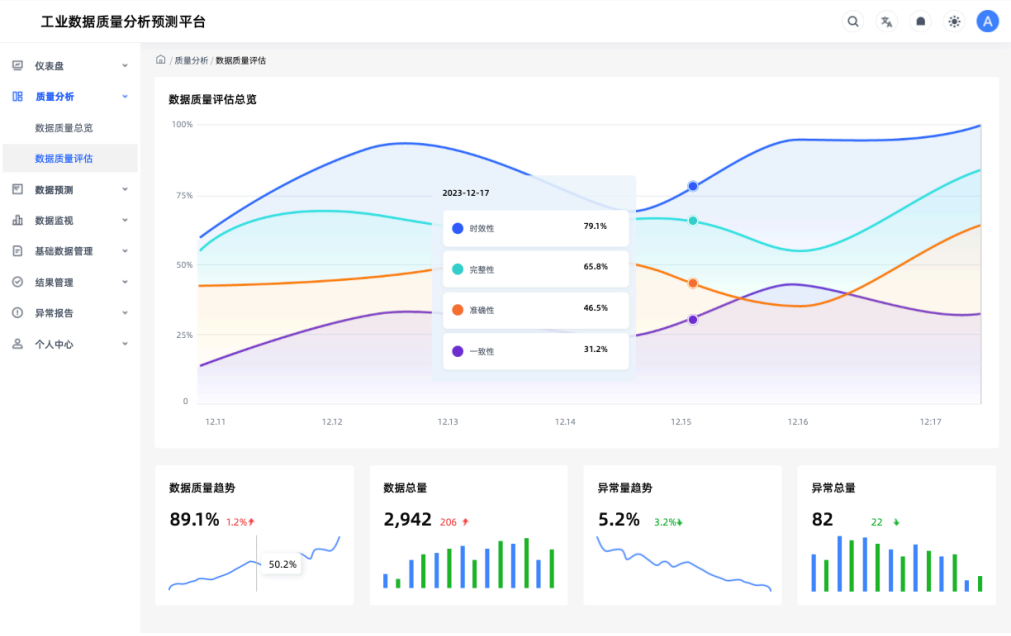


图 5.5 数据质量评估页面

Fig. 5.5 Data Quality Assessment Page

(4) 时序数据预测页面

时序数据预测页面允许用户根据需要选择特定的时间点和数据集，然后通过调用 SHAPT 模型进行数据预测。预测结果将通过可视化方法展示，使用户能够直观地理解模型输出和潜在趋势，以支持更精确的决策制定。

中国知网 https://www.cnki.net



图 5.6 时序数据预测页面

Fig. 5.6 Time Series Data Forecasting Page

5.4 本章小结

本章详述了典型工业设备时序数据异常检测系统的设计，涵盖了之前提出的 TSWD 算法和 SHAPT 模型在工业设备监测云平台的集成和应用。阐释了工业数据质量评估和预测系统的设计细节，包括系统的总体架构以及各功能模块的开发。最后，展示了系统核心页面的界面。

中国知网 https://www.cnki.net

6 总结与展望

6.1 总结

本文的研究以工业大数据环境下的时序数据质量评估与预测问题为切入点，聚焦于当前智能制造与工业物联网背景下数据驱动系统所面临的两个核心挑战：一方面是工业设备产生的数据存在噪声干扰、缺失频发、格式异构等问题，导致数据质量难以保障；另一方面是传统预测方法在面对长依赖性、动态工况变化及多源数据融合需求时，往往表现出预测精度低、适应能力弱等瓶颈。本文从理论研究与工程实践两个层面出发，围绕数据质量评估的动态建模与时序预测建模的深度融合展开系统性探索。通过提出创新性算法和优化模型结构，力求在保证预测准确性的同时，提高系统对工业现场复杂环境的适应性与部署可行性。研究工作的核心目标，是为工业领域提供一套具备实时性、鲁棒性与可扩展性的综合解决方案。

本文主要工作内容围绕以下三个方面展开：

(1) 数据质量量化算法 TSWD

针对工业设备数据具有时间连续性强、异常模式多样、数据状态易变的特点，本文选取了准确性、完整性、一致性和时效性四个质量核心维度，并在此基础上提出了 TSWD 算法。该方法融合滑动窗口机制与偏差动态更新策略，能够实现对数据质量随时间变化的连续评估，克服了传统静态质量评估模型对复杂工况反应迟钝、灵敏度不足的缺陷。

(2) 时序数据预测模型 SHAPT

面对工业现场数据高度非线性、多尺度、多源融合的特性，本文设计了一个新型的深度学习预测框架——SHAPT 模型。该模型首先采用奇异谱分析对原始时序数据进行降噪与趋势提取，有效分离出主导成分与随机干扰；随后通过混合注意力机制结合局部与全局依赖关系，捕捉关键变点与周期特征；最终采用 PatchTST 结构提升对长序列的并行建模能力与计算效率。

(3) 质量分析与时序预测的云平台融合

在模型理论设计的基础上，本文进一步实现了 TSWD 算法与 SHAPT 模型的系统集成，构建了一个面向工业设备监控场景的质量感知型预测系统。该系统不仅具备对原始时序数据的动态质量评估能力，还能基于评估结果进行模型输入优化与预测结果调整，最终实现了“质量诊断—趋势预测—可视化反馈—预警触发”的一体化闭环流程。

综上所述，本文在工业时序数据质量量化与预测建模领域提出了具有针对性

中国知网 https://www.cnki.net

的解决思路与方法。所设计的算法与模型不仅能够提升工业系统对数据波动与异常的感知能力，还为实现预测性维护、异常预警等高级工业智能应用提供了可行路径。

6.2 研究展望

本文对工业设备的数据质量评估和预测进行了深入研究。在回顾研究过程中发现的问题，并分析模型可能的优化方向后，本文提出了几个未来研究的潜在方向：

(1) 数据质量评估的多维性扩展：目前的评估模型主要关注几个关键维度，但为了更全面地评估数据质量，应考虑引入更多的数据属性维度。这将有助于构建一个更综合的评估模型，能够从多角度全面地评估数据的质量，从而为决策提供更加坚实的数据支持。

(2) TSWD 算法的计算方法优化：尽管 TSWD 算法在处理时序性和多维性数据方面表现出了一定的优势，但其计算方法和数学模型还有较大的提升空间。未来的研究将探索更高效的算法，以优化算法的计算速度和准确性，确保算法在处理大规模工业数据时的性能。

(3) SHAPT 模型结构的优化：当前 SHAPT 模型通过融合混合注意力机制显著提高了预测的准确性和相关性，但其结构和训练速度仍有进一步优化的空间。未来的研究可以探索在 SHAPT 模型中引入更新的时序数据预测技术，这不仅可能增强模型捕捉数据间复杂关系的能力，还可能显著提高模型的训练效率和预测精度。通过这些改进，SHAPT 模型将更适合应用于快速变化的工业环境中，实现更高效、准确的数据分析。

中国知网 https://www.cnki.net

参考文献

[1] 丁海龙, 徐宏炳. 数据质量分析及应用[J]. 计算机技术与发展, 2007, 17(3): 236-238.

[2] 宋敏, 覃正. 国外数据质量管理研究综述[J]. 情报杂志, 2007, 26(2): 7-9.

[3] 韩京宇, 徐立臻, 董逸生. 数据质量研究综述[J]. 计算机科学, 2008, 35(2): 1-5.

[4] Batini C, Rula A, Scannapieco M, et al. From data quality to big data quality[J]. Journal of Database Management (JDM), 2015, 26(1): 60-82.

[5] 蔡莉, 梁宇, 朱扬勇, 等. 数据质量的历史沿革和发展趋势[J]. 计算机科学, 2018, 45(4): 1-10.

[6] 刘冰, 庞琳. 国内外大数据质量研究述评[J]. 情报学报, 2019, 38(2): 217-226.

[7] 孙俐丽, 袁勤俭. 数据质量研究述评: 比较视角[J]. 农业图书情报学报, 2019, 31(7): 4-13.

[8] Verma P, Kumar V, Mittal A, et al. The role of 3S in big data quality: a perspective on operational performance indicators using an integrated approach[J]. The TQM Journal, 2023, 35(1): 153-182.

[9] Choi T M, Luo S. Data quality challenges for sustainable fashion supply chain operations in emerging markets: Roles of blockchain, government sponsors and environment taxes[J]. Transportation Research Part E: Logistics and Transportation Review, 2019, 131: 139-152.

[10] Lili S, Qinjian Y. Review of Data Quality Research: Comparative Perspective[J]. Journal of Library and Information Sciences in Agriculture, 2019, 31(7): 4.

[11] 陈才秀. 大数据质量评估和数据治理的关系研究[J]. 大数据与人工智能, 2025, 5(9): 1-3.

[12] 刘桂锋, 聂云贝, 刘琼. 数据质量评价对象, 体系, 方法与技术研究进展[J]. 情报科学, 2021, 39(11): 13-20.

[13] Pipino L L, Lee Y W, Wang R Y. Data quality assessment[J]. Communications of the ACM, 2002, 45(4): 211-218.

[14] Eppler M J, Muenzenmayer P. Measuring Information Quality in the Web Context: A Survey of State-of-the-Art Instruments and an Application Methodology[C]//ICIQ. 2002: 187-196.

[15] 杨青云, 赵培英, 杨冬青, 等. 数据质量评估方法研究[J]. 计算机工程与应用, 2004, 40(9): 3-4.

[16] Su Z, Jin Z. A methodology for information quality assessment in the designing and manufacturing processes of mechanical products[M]//Information Quality Management: Theory and Applications. IGI Global, 2007: 190-220.

[17] 韩京宇, 宋爱波, 董逸生. 数据质量维度量化方法[J]. 计算机工程与应用, 2008, 44(36): 1-6.

[18] Batini C, Cabitza F, Cappiello C, et al. A comprehensive data quality methodology for web and structured data[J]. International Journal of Innovative Computing and Applications, 2008, 1(3): 205-218.

中国知网 https://www.cnki.net

[19] Batini C, Cappiello C, Francalanci C, et al. Methodologies for data quality assessment and improvement[J]. ACM computing surveys (CSUR), 2009, 41(3): 1-52.

[20] Arazy O, Kopak R. On the measurability of information quality[J]. Journal of the American Society for Information Science and Technology, 2011, 62(1): 89-99.

[21] Aggarwal A. Data quality evaluation framework to assess the dimensions of 3V's of big data[J]. International Journal of Emerging Technology and Advanced Engineering, 2017, 7(10): 503-506.

[22] Ardagna D, Cappiello C, Samá W, et al. Context-aware data quality assessment for big data[J]. Future Generation Computer Systems, 2018, 89: 548-562.

[23] 丁小欧, 王宏志, 张笑影, 等. 数据质量多种性质的关联关系研究[J]. 软件学报, 2016 (7): 1626-1644.

[24] Kulkarni A. A study on metadata management and quality evaluation in big data management[J]. International Journal for Research in Applied Science & Engineering Technology (IJRASET), 2016, 4(VII): 455-459.

[25] Mo Z. Construction of big data quality measurement model[J]. Inform. Stud. Theory Appl, 2018, 41: 11-15.

[26] Li W, Xu S, Peng X. Research on comprehensive evaluation of data source quality in big data environment[J]. International Journal of Computational Intelligence Systems, 2021, 14(1): 1831-1841.

[27] Liu X, Li Q, Zhu S, et al. A Multi-Head Attention Mechanism Base Multi-Dimensional Data Quality Evaluation Model[C]//Proceedings of the 7th International Conference on Big Data and Computing. 2022: 1-5.

[28] 谷阳阳. 基于信息熵的遥测数据质量维度量化方法[J]. Ordnance Industry Automation, 2019, 38(12).

[29] Bayram F, Ahmed B S, Hallin E. Adaptive data quality scoring operations framework using drift-aware mechanism for industrial applications[J]. Journal of Systems and Software, 2024, 217: 112184.

[30] Belgoumri M D, Bouadjenek M R, Aryal S, et al. Data Quality in Edge Machine Learning: A State-of-the-Art Survey[J]. arXiv preprint arXiv:2406.02600, 2024.

[31] Mohammed S, Ehrlinger L, Harmouch H, et al. Data quality assessment: Challenges and opportunities[J]. arXiv preprint arXiv:2403.00526, 2024.

[32] Kang J, Al Masry Z, Varnier C, et al. A data quality management framework for equipment failure risk estimation: Application to the oil and gas industry[J]. Engineering Applications of Artificial Intelligence, 2024, 136: 108834.

[33] 莫祖英. 大数据处理流程中的数据质量影响分析[J]. 现代情报, 2017, 37(3): 69-72.

[34] 丁小欧, 王宏志, 于晟健. 工业时序大数据质量管理[J]. 大数据, 2019, 5(6): 0.

[35] Toothman M, Braun B, Bury S J, et al. Overcoming challenges associated with developing

中国知网 https://www.cnki.net

industrial prognostics and health management solutions[J]. Sensors, 2023, 23(8): 4009.

[36] 尤祺,袁堂晓,芬 .基于神经网络的工业时序数据质量管理方法[J].机械制造与自动化,2022,51(03):96-99+112.

[37] Cate M. Enhancing Risk Management Frameworks Through Predictive Analytics[J]. 2025.

[38] Olawade D B, Ayoola F I, Ebo T O, et al. Artificial Intelligence in Forensic Mental Health: A Review of Applications and Implications[J]. Journal of Forensic and Legal Medicine, 2025: 102895.

[39] Raddy U, Asuti M G, Michael G, et al. Achieving Seamless Interoperability of Health Data Across Digital Healthcare Systems[M]//Next-Generation Therapeutics Using Internet of Things and Machine Learning. IGI Global Scientific Publishing, 2025: 243-258.

[40] Zhao Y, Yang R, Ying J, et al. Enhancing online industrial quality index prediction with a general deep temporal feature extraction and incremental ensemble modeling framework[J]. Engineering Applications of Artificial Intelligence, 2025, 156: 111104.

[41] Lu J, Liu B, Pei C, et al. Learning to optimize termination decisions under hybrid uncertainty of system lifetime and task duration[J]. Computers & Industrial Engineering, 2025: 111208.

[42] Box G E P, Jenkins G M, Reinsel G C, et al. Time series analysis: forecasting and control[M]. John Wiley & Sons, 2015.

[43] Zhang G P. Time series forecasting using a hybrid ARIMA and neural network model[J]. Neurocomputing, 2003, 50: 159-175.

[44] Wang J, Li J, Wang X, et al. Air quality prediction using CT-LSTM[J]. Neural Computing and Applications, 2021, 33: 4779-4792.

[45] Wei Y, Liu H. Convolutional long-short term memory network with multi-head attention mechanism for traffic flow prediction[J]. Sensors, 2022, 22(20): 7994.

[46] Priya S S, Dathan R A. Attention based Peephole LSTM model for Soybean crop yield prediction[C]//Journal of Physics: Conference Series. IOP Publishing, 2023, 2571(1): 012013.

[47] Raza M Q, Khosravi A. A review on artificial intelligence based load demand forecasting techniques for smart grid and buildings[J]. Renewable and Sustainable Energy Reviews, 2015, 50: 1352-1372.

[48] Martínez-Álvarez F, Troncoso A, Asencio-Cortés G, et al. A survey on data mining techniques applied to electricity-related time series forecasting[J]. Energies, 2015, 8(11): 13162-13193.

[49] Li S, Jin X, Xuan Y, et al. Enhancing the locality and breaking the memory bottleneck of transformer on time series forecasting[J]. Advances in neural information processing systems, 2019, 32.

[50] Liu M, Zeng A, Chen M, et al. Scinet: Time series modeling and forecasting with sample convolution and interaction[J]. Advances in Neural Information Processing Systems, 2022, 35: 5816-

中国知网 https://www.cnki.net

5828.

[51] Zhang X, Lei Y, Chen H, et al. Multivariate time-series modeling for forecasting sintering temperature in rotary kilns using DCGNet[J]. IEEE Transactions on Industrial Informatics, 2020, 17(7): 4635-4645.

[52] An Q, Zhao M. Time series analysis in the prediction of water quality[C]//7th International Conference on Education, Management, Information and Mechanical Engineering (EMIM 2017). Atlantis Press, 2017: 51-54.

[53] Bergmeir C, Benítez J M. On the use of cross-validation for time series predictor evaluation[J]. Information Sciences, 2012, 191: 192-213.

[54] Zhao J, Wang W, Sheng C. Data-driven prediction for industrial processes and their applications[M]. Springer, 2018.

[55] Christ M, Kempa-Liehr A W, Feindt M. Distributed and parallel time series feature extraction for industrial big data applications[J]. arXiv preprint arXiv:1610.07717, 2016.

[56] Villalobos K, Ramírez V J, Diez B, et al. A hierarchical storage system for industrial time-series data[C]//2019 IEEE 17th International Conference on Industrial Informatics (INDIN). IEEE, 2019, 1: 699-705.

[57] Yuan X, Li L, Shardt Y A W, et al. Deep learning with spatiotemporal attention-based LSTM for industrial soft sensor model development[J]. IEEE Transactions on Industrial Electronics, 2020, 68(5): 4404-4414.

[58] Yuan X, Jia Z, Li L, et al. A SIA-LSTM based virtual metrology for quality variables in irregular sampled time sequence of industrial processes[J]. Chemical Engineering Science, 2022, 249: 117299.

[59] Ren L, Dong J, Wang X, et al. A data-driven auto-CNN-LSTM prediction model for lithium-ion battery remaining useful life[J]. IEEE Transactions on Industrial Informatics, 2020, 17(5): 3478-3487.

[60] 周哲韬, 刘路, 宋晓, 等. 基于 Transformer 模型的滚动轴承剩余使用寿命预测方法[J]. 北京航空航天大学学报, 2021, 49(2): 430-443.

[61] 黄飞虎, 赵红磊, 弋沛玉, 等. 一种改进 Transformer 的电力负荷预测方法[J]. 现代电力, 2023, 40(1): 50-58.

[62] 骆钊, 吴谕侯, 朱家祥, 等. 基于多尺度时间序列块自编码 Transformer 神经网络模型的风电超短期功率预测[J]. 电网技术, 2023, 47(9): 3527-3536.

[63] Kashpruk N, Piskor-Ignatowicz C, Baranowski J. Time series prediction in industry 4.0: a comprehensive review and prospects for future advancements[J]. Applied Sciences, 2023, 13(22): 12374.

[64] Tessoni V. Advanced deep learning techniques for offline and online predictive maintenance[J]. 2025.

中国知网 https://www.cnki.net

[65] Duan Y, Zhang X, Wang X, et al. A Novel Forecasting System with Data Preprocessing and Machine Learning for Containerized Freight Market[J]. Mathematics, 2025, 13(10): 1695.

[66] Huang Y, Ngaopitakkul A, Yoomak S. Charging pile fault prediction method combining whale optimization algorithm and long short-term memory network[J]. Energy Informatics, 2025, 8(1): 1-21.

[67] Abdul Hameed Ashour M, H Al-Salami Q. Optimizing Natural Gas Production Predictions: A Machine Learning Approach with Recurrent Neural Networks[J]. 2025.

[68] Kong L, Liu Z, Yan F, et al. Multi-Domain Graph Meta Learning Network for Few-Shot Prediction in Industrial Processes[J]. IEEE Transactions on Instrumentation and Measurement, 2025.

[69] Rumelhart D E, Hinton G E, Williams R J. Learning representations by back-propagating errors[J]. nature, 1986, 323(6088): 533-536.

[70] Hochreiter S, Schmidhuber J. Long short-term memory[J]. Neural computation, 1997, 9(8): 1735-1780.

[71] Cho K, Van Merriënboer B, Gulcehre C, et al. Learning phrase representations using RNN encoder-decoder for statistical machine translation[J]. arXiv preprint arXiv:1406.1078, 2014.

[72] Bahdanau D, Cho K, Bengio Y. Neural machine translation by jointly learning to align and translate[J]. arXiv preprint arXiv:1409.0473, 2014.

[73] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[74] Zhou H, Zhang S, Peng J, et al. Informer: Beyond efficient transformer for long sequence time-series forecasting[C]//Proceedings of the AAAI conference on artificial intelligence. 2021, 35(12): 11106-11115.

[75] Wu H, Xu J, Wang J, et al. Autoformer: Decomposition transformers with auto-correlation for long-term series forecasting[J]. Advances in neural information processing systems, 2021, 34: 22419-22430.

[76] Zhou T, Ma Z, Wen Q, et al. Fedformer: Frequency enhanced decomposed transformer for long-term series forecasting[C]//International conference on machine learning. PMLR, 2022: 27268-27286.

[77] Nie Y, Nguyen N H, Sinthong P, et al. A time series is worth 64 words: Long-term forecasting with transformers[J]. arXiv preprint arXiv:2211.14730, 2022.

[78] Broomhead D S, King G P. Extracting qualitative dynamics from experimental data[J]. Physica D: Nonlinear Phenomena, 1986, 20(2-3): 217-236.

[79] Hassani H. Singular spectrum analysis: methodology and comparison[J]. 2007.

中国知网 https://www.cnki.net

D. 学位论文数据集

关键词	密级	中图分类号
数据质量；时序数据预测；深度学习；自注意力神经网络	公开	TP

学位授予单位名称	学位授予单位代码	学位类别	学位级别
重庆大学	10611	专业学位	硕士

论文题名	并列题名	论文语种
面向工业设备监控的时序数据质量分析与智能预测方法	无	中文

作者姓名	陈彦卿	学号	202124131111
培养单位名称		培养单位代码	
重庆大学		10611	
学科专业	研究方向	学制	学位授予年
软件工程	大数据技术	3	2025 年
论文提交日期	2025 年 6 月	论文总页数	88
导师姓名	张毅	职称	教授
答辩委员会主席		桑军	

电子版论文提交格式

文本（√） 图像（） 视频（） 音频（） 多媒体（） 其他（）

中国知网 https://www.cnki.net